

标准词元与智能经济
——**Token** 的价值计量、定价机制与配置效率研究

蔡鑫宇 著

目 录

(在 Word 中右键此处选择“更新域”生成目录)

内容摘要

以大语言模型为代表的新一轮人工智能革命，正在把经济形态由数字经济推向智能经济。2026年3月，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用人工智能领域名词 token 的中文名“词元”；同月，国家数据局负责人在中国发展高层论坛年会上提出词元具有可计量、可定价、可交易的特征，是“智能时代的价值锚点”。人工智能由模型能力的竞争进一步转向词元生产能力的竞争：数据中心不再只是存储数据的仓库，而正在演变为生产智能产出的“词元工厂”；我国日均词元调用量由2024年初的1000亿枚增至2026年3月的140万亿枚以上、两年增长约1400倍；苏州、嘉兴、温州、广州、上海等地相继设立城市级词元运营中心或将词元消耗纳入企业技术改造补贴，词元由模型服务的计价单位演变为城市公共基础设施。然而，这一高速扩张建立在一个尚未解决的计量地基之上：同样数量的词元，由不同规模的模型在不同任务中生成，其算力消耗与信息含量可以相差十倍乃至百倍。物理词元并不等值。计量不等值，则定价缺乏公允基准、补贴缺乏核定依据、统计缺乏可加口径、出海缺乏互认凭证——这正是词元经济从技术概念走向经济制度所必须跨越的第一道门槛。

本书由此提出全书的核心命题：词元是智能经济的计量单位，但物理词元不是合格的价值单位；只有经效值折算得到的“标准词元”，才能承担价值尺度、定价基准、配置信号与增长核算变量这四重经济职能。围绕这一命题，本书沿“计量一定价一配置”的主线展开。在计量层面，本书借鉴能源经济学“标准煤”、航运业“标准箱”与气候核算“二氧化碳当量”的当量化传统，构建以算力强度、推理质量与场景效用三维合成的标准词元折算体系，给出基准归一、单调性、可加性与传递一致性四条公理，并证明公理约束下折算函数的形式限制；实证显示，折算可使单位价格的变异系数由0.92降至0.31，异质词元由此获得可比、可加的共同尺度。在定价层面，本书把词元价格分解为成本底价层、效值溢价层与场景租金层，据此解释“通用词元价格持续下行”与“高效值词元溢价扩大”并存的结构分化；编制的词元价格指数与标准词元价格指数显示，两年间79%的表观降价中约53%来自效值提升而非真实降价——这一发现对补贴核定与统计核算具有直接意义。在配置层面，本书构建算力向有效标准词元的转化函数，将“智算利用率仅五至七成而算力仍在扩建”的悖论分解为空转、批次、匹配与效值四项损失，证明统一调度经任务一模型最优匹配可获得的效率改进上界；并以平台一企业一政府三方演化博弈刻画城市词元运营中心的制度逻辑，求解“五个统一”安排

的激励相容条件与财政补贴的退出条件。最后，本书把标准词元流量作为可观测变量引入智能经济生产函数，将人工智能的增长贡献从索洛残差中显性分离，回应索洛生产率悖论在人工智能时代的再现。

本书的研究表明：词元经济的当务之急不是继续扩大算力规模，而是补齐计量、定价与调度三项制度基础设施；标准词元的建立既是一项计量技术，更是一项市场制度，它决定了智能能力能否像电力一样被公平计价、有效配置与可靠核算。本书可供数字经济学、产业组织与技术经济研究者，各级数据与经信主管部门，算力与模型服务运营机构，以及关注人工智能商业化的企业管理者阅读参考。

前言

每一个经济时代都有属于自己的计量单位。农业时代计量劳动的是工时，工业时代计量能量的是千瓦时，数字时代计量信息的是字节。当人工智能开始大规模地替代与增强人类的认知劳动时，一个新的问题随之出现：智能本身该如何计量？词元给出了迄今为止最接近答案的候选——它是模型处理信息的基本粒度，是智能服务计费的通行依据，也是连接算力、模型与应用的核心接口。全国科学技术名词审定委员会为它定下中文推荐名“词元”并发布试用，国家数据局则把它称作“智能时代的价值锚点”——这个原本纯粹的技术概念，就此进入经济治理的视野。

但把词元当作计量单位来用，很快会遇到一个尴尬：千瓦时之所以能计量能量，是因为一度电就是一度电，不因发电方式而改变；字节之所以能计量信息，是因为一个字节就是八个比特，不因存储介质而改变。词元却不然。同样一万枚词元，由轻量模型生成还是由推理增强模型生成，其背后的算力消耗、信息含量与经济价值可以相差一个数量级。当我们说“今天调用了 140 万亿枚词元”，这句话的经济含义其实是模糊的——正如在标准煤概念出现之前，说“今天消耗了一万吨燃料”一样模糊。能源经济学用标准煤解决了这个问题，航运业用标准箱解决了这个问题，气候核算用二氧化碳当量解决了这个问题。词元经济也需要属于自己的当量。这就是本书写作的起点。

本书的另一重关切来自现实。笔者所在的嘉兴，是国家算力枢纽节点城市，集聚了四个万卡级算力中心，算力规模占浙江省六成以上；2026 年 7 月，长三角（嘉兴）Token 运营中心由一家传统城建投资型国企运营启动。一家过去修路建桥的公司开始“卖词元”，这个看似突兀的转身，恰恰揭示了词元经济的基础设施属性：它需要土地、电力、机房、带宽，也需要计量、结算、审计与信任——前者是城投的存量资产，后者是市场亟缺的公共品。与此同时，苏州以运营商为主体做出海联盟，温州以数据集团做绿色词元，广州以数据交易所做市场组织方，上海把词元消耗写进技术改造补贴目录。五座城市、五种主体、五种打法，为经济学研究提供了难得的制度实验场。本书的第 10 章与第 13 章正是围绕这一实验场展开的。

需要说明的是，书中的模型估计与情景模拟结果，基于作者构建的词元服务面板数据、模型效值测试集与公开统计校准复算得到，旨在完整展示方法体系的应用逻辑；书中对模型档位一律使用类别名而非具体产品名，以避免把校准复算值挂靠到特定商业产品之上。相关数字随数据扩充与方法改进仍会更新，请读者

以方法论的眼光看待。词元经济是一个正在剧烈演化的对象，本书写作期间，价格、调用量与制度安排都在以月为单位变化，书中难免有疏漏与不当之处，敬请学界同仁与广大读者批评指正。

蔡鑫宇

2026年8月于嘉兴

第 1 章 导论：从数字经济到词元经济

1.1 研究背景：智能经济为什么需要一个新的计量单位

1.1.1 计量单位的更替与数据要素的计量困境

经济形态的每一次跃迁，都伴随着一次计量单位的更替，而计量单位的确立往往比技术本身更深刻地重塑经济组织方式。工业经济以工时度量劳动、以千瓦时度量能量、以「标准煤」把煤、油、气、电折算为可加总的综合能耗（国家市场监督管理总局和国家标准化管理委员会，2020），以「标准箱」把形态各异的货物折算为可比的运输量；气候治理以「二氧化碳当量」把甲烷、氧化亚氮等异质气体折算到同一尺度（「WRI 和 WBCSD，2011」；「ISO，2018」；国家市场监督管理总局和国家标准化管理委员会，2024），从而使排放可核算、可交易、可考核。这些计量单位的共同特征有四：可数、可加、可折算、可入账。缺少其中任何一条，一种经济活动都难以进入价格体系、财政体系与统计体系。计量标准并非中性的技术约定，而是具有强网络外部性的制度基础设施——标准的选择与协调直接决定市场能否形成（Farrell 和 Saloner，1985；Simcoe，2012），而标准化在中国物流领域的准自然实验证据显示，统一计量与统一规格可以显著提升企业全要素生产率（何凡等，2025）。

数字经济时代把数据列为生产要素，但数据的计量始终未能过关。理论上，数据的非竞争性意味着同一份数据可以被无限次同时使用而不减损，其配置效率与产权安排因此不同于传统要素（Jones 和 Tonetti，2020）；实践中，围绕数据的界权、流通与定价形成了丰富的研究谱系（熊巧琴和汤珂，2021；欧阳日辉和杜青青，2022；Pei，2022），会计上以成本法将数据资源有条件入表（财政部，2023；罗玫等，2023），统计上则以卫星账户与增加值测算的方式估计数字经济规模（杨仲山和张美慧，2019；许宪春等，2021；蔡跃洲和牛新星，2021）。然而，所有这些努力都必须绕开一个根本障碍：数据没有天然的物理计量单位。字节数与价值的相关性极弱——一段冗余日志与一份经过清洗标注的高质量样本集，在字节口径下不可区分；数据的价值高度依赖使用场景与结合方式，跨主体流动又受制于确权与安全约束（蔡跃洲和马文君，2021）。计量单位的缺位使数据要素长期停留在「重要但难以定价」的状态：既无法形成公允的市场价格，也无法进入增长核算的投入侧，只能以间接指标近似。

生成式人工智能的兴起改变了这一格局，其改变的方式颇具意味——不是让数据变得可计量，而是让「使用数据与算力所生产出的认知服务」第一次变得可计量。大模型的工作方式是把连续的自然语言、代码、图像与音视频切分为离散

的符号单元，再以自回归方式逐枚生成。切分依据的是分词器：字节对编码通过合并高频字节对构造子词词表（Sennrich 等，2016），无监督的子词切分与语言无关实现进一步使这一过程可以直接作用于原始文本（Kudo 和 Richardson，2018）。由此产生的技术后果是决定性的：模型服务的产出被自然地离散化为可逐枚计数的单元，服务商逐枚计费，调用方逐枚核对，监管方逐枚统计。认知劳动的产出第一次具备了逐笔留痕、实时可计、跨主体可核对的技术基础，这正是「词元何以成为智能经济计量单位」的技术根源，也是本书全部讨论的起点。

但同一技术特征也在其内部埋下了不可比的种子。词元的边界由分词器决定，不同分词器对同一段文本切出的词元数量并不相同；跨语言的切分效率差异更为悬殊，同等语义内容在非拉丁语系与低资源语言下往往需要更多词元来承载，从而在按词元计费的定价体系中形成系统性的「语言税」（Rust 等，2021；Petrov 等，2023；Ahia 等，2023）。切分口径之外，更实质的差异来自生产端：生成单枚词元所需的浮点运算量随模型规模与推理策略而变，单枚词元所承载的任务达成度亦随模型能力而变，二者的跨模型跨度均以数倍乃至数十倍计。于是，「可计数」并不等于「可比较」，「可比较」也不等于「可加总」。这是本书反复回到核心事实：物理词元是一个合格的计数单位，却不是是一个合格的价值单位。

1.1.2 从技术术语到经济范畴：词元的定名与政策确认

词元由技术术语上升为经济范畴，在中国有两个清晰而必须严格区分的标志性事件，二者的主体、性质与效力层级各不相同。其一是术语层面的定名。2026 年 3 月 25 日，全国科学技术名词审定委员会发布《关于发布试用人工智能领域名词 token 中文名「词元」的公告》，由其责成第四届计算机科学技术名词审定委员会启动「科技新词快速审定发布流程」，经多轮审定会议并综合社会意见后确定。公告的用语是「优先推荐」「词元」作为 token 的中文名，并「面向全社会发布试用」，同时明确该中文定名将在计算机科学技术名词常态化审定工作中结合社会推广应用情况最终确认。因此，准确的表述是「发布试用、优先推荐，尚待常态化审定最终确认」，而非「正式定名」，更不构成国家标准。名词委给出的定义是术语学口径：词元是人工智能时代智能设备中信息存储、处理和交换的具有一定语义的基本符号单元，特别是在大模型中作为模型处理和交换信息的最小单位。这一定名终结了此前「代币」「令牌」等混译并存的局面——在网络外部性显著的标准形成过程中，命名的统一本身即是降低沟通

成本与缔约成本的制度产品（Farrell 和 Saloner，1985；Katz 和 Shapiro，1985；Simcoe，2012）。

其二是经济计量层面的确认。同在 2026 年 3 月，中国发展高层论坛 2026 年年会期间，国家发展改革委党组成员、国家数据局局长发表题为《深化数据赋能人工智能发展，加快培育智能经济新形态》的演讲，使用并推介「词元」这一译名，提出词元是大模型处理信息的最小信息单元，具有「可计量、可定价、可交易」的特征，是「智能时代的价值锚点」和「连接技术供给与商业需求的结算单位」。2026 年 5 月 22 日，国家数据局召开词元经济座谈会，明确将推动词元经济发展纳入工作体系，并把词元界定为大模型处理文本、代码、图像、音频、视频等所有信息时采用的最小运算单元，正在成为人工智能服务的计量单位、结算单位和统计单位。两套口径不可互相替换，也不可拼接为一句话：名词委强调的是「具有一定语义的基本符号单元」，属语言学与计算机科学口径；国家数据局强调的是「可计量、可定价、可交易的最小信息单元」，属经济计量口径。本书的写作纪律是：讨论术语规范时引前者，讨论价值计量、定价与核算时引后者。「可计量、可定价、可交易」这一三元表述之所以关键，是因为它恰好对应了本书三个科学问题的次序——计量是定价的前提，定价是交易与配置的前提。

与定名同步展开的是制度化进程，但其效力层级必须被准确刻画，否则极易高估现实的制度供给。截至 2026 年 8 月，词元领域已发布的规范性成果主要是团体标准与机构评估规范：《人工智能词元（Token）运营管理能力要求》（AIIA/T 0308—2026）由中国人工智能产业发展联盟归口、中国信息通信研究院人工智能研究所联合行业企业编制，2026 年 8 月发布，用于规范词元运营管理平台的能力要求；团体标准的效力层级低于国家标准与行业标准，尚未见以「词元计量」或「词元计费」为题的国家标准或行业标准立项公开。与之并行的是四套主体不同、维度不同、用途不同的既有评价工作：中国信息通信研究院《人工智能 Token 服务质量能力要求》所依托的「可信 AI-Token 服务质量评估」，含模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度；中国信息通信研究院于 2026 年 6 月 16 日发布的「高质量 Token 服务标准体系」，含服务质量、运营能力、生产能力、安全能力四个维度，其云计算与大数据研究所负责人明确提出「不能只看单价，行业亟须一套衡量『高质量 Token』的标尺」；中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》构建了生产成本、生产效率、准确性、生态价值、安全五个维度的价值度量体系；清华大学翟季冬团队

联合企业于 2026 年 5 月发布的「开源模型 Token 服务性能榜」，采用首词元时延（P90 分位）、输出吞吐与缓存命中率三项实测指标。四者各有其明确主体与适用范围，维度名称不可合并、平均或交叉引用。

把上述四套工作放在一起观察，可以看清既有制度供给的边界所在：它们都是「多维评价」，产出的是并列的维度得分或达标基线——例如中国信息通信研究院 2026 年 6 月启动的「词元（Token）服务能力攀登计划」，首批企业达成的企业级通用场景性能基线为吞吐不低于每秒 55 枚词元、首词元时延不高于 0.9 秒、调用成功率 99.9%。多维评价可以回答「谁家的词元服务更好」，却无法回答「一枚甲模型的词元等于几枚乙模型的词元」。而后一个问题才是价格指数编制、财政补贴核定、增加值核算与跨境互认所必需的。本书的理论增量正在于此：从「多维评价」推进到「当量折算」，给出一个公理化的合成函数，使异质词元获得可比、可加的共同尺度。需要特别声明的是，本书使用的算力强度、推理质量与场景效用三维折算体系是作者自主构建的理论框架，与上述任一机构的评价体系均无对应关系，也不得被指称为任何机构的既有成果。

1.1.3 词元经济的现实图景：调用量、产能与运营组织

词元由技术概念变为经济范畴，其现实基础是需求侧极为陡峭的规模扩张。按国家数据局公开发布的口径，我国日均词元调用量在 2024 年初约为 1000 亿枚，至 2025 年 6 月底突破 30 万亿枚，2025 年底跃升至 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年间增长约 1400 倍。这一序列必须严格按其口径使用：它是全国、全渠道、消耗侧的日均调用量，官方未公开统计边界（是否涵盖厂商官方接口、云端模型即服务、自建推理与端侧推理）与测算方法，既不等于任何厂商财报中的词元消耗，也不等于评测中的吞吐指标，更不能除以人口或企业数得出「人均调用量」；千倍增长的基期是 2024 年初，不可与以其他年份为基期的增速直接同比。官方仅发布上述四个锚点，其余时点在本书中均为校准复算插值，凡出现处一律标注，图表中亦以不同标记加以区分。

供给侧的扩张同样迅猛，但其计量口径的分裂比需求侧更甚。按工业和信息化部口径，截至 2026 年 6 月底我国智能算力规模达 2185 EFLOPS（FP16 精度基准的已建成规模），同比增长 177%，全国算力设施整体上架率 71.4%；截至 2025 年底已建成万卡智算集群 42 个，智能算力规模超过 1590 EFLOPS。需要提醒的是，算力规模至少存在三套互不相通的计量单位——数据中心口径的标准机架、算力性能口径的每秒浮点运算次数、加速卡口径的卡数，三者之间没有公开的官方换算系数，且不同精度基准（FP16 与 FP32 折算）下的数字相差

可达一倍，因此严禁互相折算或同图并列。算力供给的组织形态也在发生变化：从「东数西算」工程与全国一体化算力网的顶层布局（「国家发展改革委等，2021」；国家发展改革委等，2023），到面向推理服务的「词元工厂」这一新型产能形态的出现，算力的价值实现方式正由「租算力」转向「卖词元」。智算中心建设对企业全要素生产率的影响（许诺等，2025）与需求侧算力共享机制的研究（王勇等，2025）均已表明，算力的经济效应高度依赖其被有效使用的程度，而非其名义规模。

介于供给与需求之间的，是 2026 年夏季密集出现的城市级词元运营组织。2026 年 7 月 15 日，东南词元（Token）运营中心在温州启动，由国资控股的专门运营公司承担具体运营，其董事长由温州市数据集团总经理兼任，基础电信运营商及其云平台提供智算底座；7 月 30 日，长三角（嘉兴）Token 运营中心启动，由嘉兴市城市投资发展集团承担面向市场的统一服务窗口运营，门户提出统一接口入口、统一词元计量、统一费用结算、统一政策抵扣、统一安全审计的「五个统一」；同日，广东词元交易和服务中心在广州南沙揭牌，依托广州数据交易所建设，承担词元标准制定、合规鉴证、场内交易、惠企扶持与跨境流通职能；8 月 11 日，江苏省首个词元运营中心在苏州工业园区揭牌，依托基础电信运营商的云底座与词元运营平台，提供模型广场、技能市场、应用超市、补贴专区、安全风控、指标监测六大类服务，同日成立词元出海服务联盟；亦在 8 月 11 日，《上海市软件和信息服务业发展「十五五」规划》印发，提出「探索将词元、数据治理、大模型部署及再训练等投入，纳入企业技术改造支持方向」（「上海市经济和信息化委员会，2026」）。

这五地实践在主体类型上恰好构成一组完整的比较样本——基础电信运营商、城投集团、数据集团、数据交易所与政策制定者，其资产禀赋与职能定位各不相同，第 10 章将以比较制度分析展开，第 13 章将做跨案例比较。此处仅强调三点口径纪律。第一，三类主体不可混为一谈：「词元工厂」属推理产能供给侧，其指标是日产能；「词元运营中心」属流通服务侧，其指标是接入模型数与服务企业数；「词元交易中心」属交易组织侧，其指标是场内成交额。三者的「首个」称号各有限定语，去掉限定语即会相互冲突。第二，各地的「五个统一」「六个统一」「六大类服务」是三套异构清单，条目数不构成能力强弱的比较。第三，「词元交易额」与「词元调用量」是两个完全不同的计量对象，前者是成交金额，后者是技术调用规模，二者之间不存在换算关系。政策工具的变化同样值得注意：2026 年 6 月广东印发全国首份省级词元经济专项政策，同年 8 月初北京经济技术开发区发布聚焦词元全产业链的系统性支持政策，补贴对象由

「算力」转向「用词元」。这一转向意味着财政资金的核定基准从设备投资额转移到了词元消耗量，从而把「词元如何计量」直接推到了公共财政的门口——若计量口径不统一、不可比，补贴核定便无从谈起。

1.1.4 繁荣表象之下：三重悖论与计量地基的缺失

词元经济的高速扩张之下，并存着三个相互关联、却难以用现有分析框架同时解释的悖论。悖论一是「价格持续下行与高质量词元稀缺并存」。第三方支出加权指数显示，全市场每百万词元的实际成交均价由 2026 年 5 月 31 日的 2.04 美元回落至 8 月 6—8 日的 1.16—1.18 美元，约两个月跌逾四成，为年内最低；该指数是支出加权的全市场成交均价，不是任何单一模型的挂牌价，也不等于「人工智能总支出」的变化。但与价格下行同时发生的，是行业对「高质量词元」的普遍焦虑：单价的下降既可能来自真实的效率改进，也可能来自服务质量的下沉，而在缺乏统一效值尺度的条件下，二者在价格数据上无法区分。本书的测算给出了区分的方法与结果：以 2024 年第一季度为基期，物理词元价格指数至 2026 年第二季度降至 21（累计下降 79%），而标准词元价格指数仅降至 47（累计下降 53%）；对累计降幅的结构分解表明，其中约 53%来自效值提升（同样的支出买到了能力更强的词元），约 47%才是真实降价。二者的背离正是「降价」与「降质」在统计上的分野，详见第 7 章。

悖论二是「算力持续扩建与利用率长期不足并存」。国际数据公司与中国信息通信研究院 2026 年联合开展的调研显示，近半数企业的智算资源利用率处于 51%—70%的中等区间，6.7%的企业仅为 31%—50%，利用率达到 70%以上的企业不足 35%，制造与政务行业低于平均水平；该指标是企业侧调研自报值，统计对象为企业自建自用的智算资源，与机架上架率、加速卡卡时利用率的实测采样并非同一件事，不可互证。既有讨论多把利用率不足归因于调度平台缺失与资源池化不足，这一判断方向正确却不够彻底：即便算力被百分之百地占用，如果被占用去生产低效值词元，从价值创造的角度看仍然是一种浪费。本书因此把名义利用率 62%分解为空转损失 18%、批次损失 9%、匹配损失 12%与效值损失 7%四项（合计 46%），得到有效效值利用率仅 38%；在任务—模型最优匹配下这一指标可升至 54%，相对改进 42%，理论上界为 61%。其中「匹配损失」与「效值损失」两项，恰恰只有在建立标准词元尺度之后才可能被识别，详见第 9 章。

悖论三是「调用量千倍增长与宏观生产率统计无感并存」，即索洛生产率悖论在人工智能时代的再现。一端是微观层面日益丰富的效率证据：生成式人工智

能在客服、软件开发、写作等任务上的生产率提升已被多项随机对照与准实验研究记录（Noy 和 Zhang，2023；Brynjolfsson 等，2025），企业与个人的采纳速度快于历次通用技术（Czarnitzki 等，2023；Bick 等，2024；Humlum 和 Vestergaard，2025）；另一端是宏观测算的审慎：以赫尔滕定理为框架、按受影响任务比例与单任务成本节约推算，人工智能在未来十年带来的全要素生产率累计增幅上限约为 0.66%，作者其后进一步修正为低于 0.53%（Acemoglu，2025）。需要强调的是，该数字是十年累计的全要素生产率口径，与经济合作与发展组织给出的「高暴露度经济体年度劳动生产率增长可获得 0.4—1.3 个百分点增量」（「OECD，2024」）在量纲与期限上完全不同，两者的差异主要是口径差异而非观点分歧。生产率 J 曲线理论则给出了第三种解释：通用目的技术需要互补性无形投资，而这些投入在会计上被费用化而非资本化，因而被系统性错误计量，形成先降后升的轨迹（Brynjolfsson 等，2019；Brynjolfsson 等，2021）；对错误计量解释的质疑同样存在（Syverson，2017），云计算等前置技术的核算经验亦提示，新型数字投入进入国民经济核算始终存在时滞（Byrne 等，2018；DeStefano 等，2025）。

本书认为，上述三重悖论并非三个独立的经验难题，而是同一个计量缺陷在价格、配置与核算三个界面上的投影：物理词元是一个合格的计数单位，却不是一个合格的价值单位。支持这一判断的证据是词元的三重离散。其一是生产端离散：按本书对六个模型档位的校准复算，生成单枚词元的算力强度从轻量蒸馏级的 0.22 到推理增强级的 8.4（以中型通用级为 1），跨度约 38 倍；单位算力的标准词元转化效率在轻量蒸馏级与推理增强级之间相差约 13.5 倍。其二是价格端离散：六档位每百万物理词元的市场价从 0.40 元到 14.00 元，跨度 35 倍，单位价格的变异系数高达 0.92，最高与最低之比达 12.6 倍。其三是价值端离散：同样数量的词元用于科研分析与用于日常问答，其替代的人类认知劳动的价值密度相差数倍。三重离散叠加的结果是，「词元」这个在技术上完全同名的单位，在经济上根本不是同一种东西。

计量地基的缺失会沿四条路径向外传导，本书概括为四个「无」。定价无公允基准：买卖双方无法就「一枚词元值多少钱」形成共同参照，质量不可观测使市场面临典型的柠檬问题（Akerlof，1970；Dranove 和 Jin，2010），本书测算显示企业对所购词元效值的认知偏差均值达 0.44，由此导致低效值档位的过度采购份额达 27%。补贴无核定依据：地方政府按物理词元量核定技改补贴，会系统性地激励企业采购单价低、效值也低的词元，政策目标与政策效果发生背离。统计无可加口径：跨模型、跨任务的词元量不可直接加总，词元流量便无法

作为一个合格变量进入增长核算，人工智能的贡献只能继续沉没在索洛残差之中。出海无互认凭证：词元服务的跨境交付缺乏效值与碳足迹的互认标尺——截至 2026 年 8 月，国际上最接近的文件是关于人工智能系统环境可持续性方面的技术报告，其性质为技术报告而非可认证标准，尚无面向词元的专项碳足迹核算规则；欧盟碳边境调节机制的覆盖行业为水泥、钢铁、铝、化肥、电力与氢，不含数字服务，但若词元以嵌入产品或跨境电力形态出现，其电力项下的核算要求仍将构成约束（「European Parliament 和 Council，2023」）。人工智能推理的能耗与碳排放测算已有相当积累（Patterson 等，2022；Luccioni 等，2024；IEA，2025），但公开测算的分母普遍是「一次查询」而非「一千枚词元」，Token 级的核算规则仍是空白——这恰恰是标准词元计量体系可以填补的制度空白，详见第 11 章。

1.2 问题提出：核心命题与三个科学问题

基于上述背景，本书提出并论证如下核心命题，它构成全书的理论主轴：词元是智能经济的计量单位，但物理词元不是合格的价值单位；只有经效值折算得到的标准词元，才能同时承担价值尺度、定价基准、配置信号与增长核算变量这四重经济职能。这一命题包含三层递进的断言。第一层是否定性的：物理词元在生产端、价格端与价值端均高度离散，跨模型跨任务不可比、不可加，因而不满足价值单位的基本要求。第二层是建设性的：存在一个满足若干合意公理的折算函数，可以把异质的物理词元映射为同质的标准词元，且在给定公理下这一函数的形式受到严格约束。第三层是功能性的：一旦标准词元被建立，价格指数、补贴核定、调度优化、碳强度核算与增长核算这五项此前彼此割裂的工作，便获得了共同的计量基础，从而可以相互校验、相互衔接。围绕这一命题，本书提出三个科学问题。

科学问题一（计量）：词元的经济价值由什么决定，异质词元如何折算为可比、可加的标准计量单位？这一问题可拆解为三个子问题。其一是价值决定：词元的价值究竟来自其消耗的算力（成本侧）、承载的信息量与任务达成度（能力侧），还是其所替代的人类认知劳动的价值密度（场景侧）？三者是并列关系还是有主从之分？其二是折算的可行性：一个合意的折算函数应当满足哪些公理，这些公理是否足以把函数形式唯一确定到可标定的程度，还是仅能确定到某一函数族？其三是折算的可靠性：折算系数如何标定、如何做稳健性检验，折算能否显著改善异质词元的可比性？本书将在第 3 章刻画词元的技术属性与经济属性并

形式化不可比问题，在第 5 章构建折算体系，在第 6 章讨论价值创造、实现与增值的机理。

科学问题二（定价）：标准词元的价格如何形成、如何演化，词元市场呈现何种结构与均衡？零边际成本与巨额固定成本并存的技术特征使古典的边际成本定价失效，质量分层与版本划分成为必然的定价策略（Mussa 和 Rosen，1978；Bhargava 和 Choudhary，2008），而算力方、模型方、平台与应用方之间的多边结构又使定价必须考虑交叉网络外部性（Armstrong，2006；Jullien 等，2021）。本书要回答的是：词元价格的结构由哪几层构成，各层的决定因素与变动方向是否一致？「通用词元价格持续下行」与「高效值词元溢价扩大」为何能够并存？在质量快速变化的市场中，价格指数应当如何编制才能不把质量改进误记为通货紧缩——这正是特征价格方法所处理的经典问题（Griliches，1961；Pakes，2003；Groshen 等，2017）。相应内容见第 7、8 章。

科学问题三（配置与增长）：词元如何在算力、模型与场景之间实现有效配置，其对经济增长的贡献如何测度？配置侧的核心是把「算力—词元」的转化过程打开：从每秒浮点运算次数到有效标准词元之间究竟损失在何处，统一调度能够挽回多少，理论上界又在哪里；组织侧的核心是城市词元运营中心这一新型制度安排的可持续性，即在何种条件下平台、企业与政府三方的策略选择能够收敛到「深度运营—深度采纳—补贴退出」的良性均衡。增长侧的核心则是把标准词元流量作为可观测变量引入生产函数，把人工智能的贡献从索洛残差中显性分离出来，与资本服务测度的核算传统对话。相应内容见第 9 至第 13 章。

三个科学问题之间是严格的递进关系而非并列关系：没有可比可加的计量单位，价格指数无从编制、补贴无从核定；没有公允的价格信号，配置效率无从判断、市场均衡无从刻画；没有可入账的流量变量，增长贡献无从测度。这一递进关系也决定了本书的篇章顺序与图 1.1 所示技术路线的主干走向。

核心命题的价值取决于它是否可被证伪，因此有必要预先说明其检验策略与可能被推翻的条件。本书为核心命题设置了四道相互独立的检验。其一是离散度检验：若标准词元确实是更合格的价值单位，则以标准词元计价后，同类服务单位价格的离散程度应显著收敛、趋近一价定律；若折算前后离散度无明显差别，则折算并未提供额外信息，命题的建设性部分即告失败。其二是可加性检验：折算函数须满足链式一致，即先分段折算再合成与直接折算的结果不得出现系统性偏差；若传递误差随折算链条延长而累积放大，则标准词元不具备加总资格。其三是解释力检验：以标准词元流量替代物理词元流量进入生产函数，若弹性估计

的显著性、稳定性与跨期可比性均未改善，甚至全要素生产率残差不降反升，则「显性分离」的主张不成立。其四是实践一致性检验：若城市词元运营中心的实践、企业采纳的障碍编码与本书定量结论系统性背离——例如企业反映的首要障碍并非计量不透明而是别的因素——则说明计量并非当前的主要约束，命题的现实针对性需要重估。四道检验分别在第 5、5、12、13 章执行，其结果将在第 14 章汇总回顾。预先声明检验标准，是为了避免把「折算体系可以构造」误当作「折算体系确有必要」。

1.3 研究意义

1.3.1 理论意义

本书的理论意义首先在于为一个正在生成中的经济形态提供计量论基础。经济学对新要素的接纳，通常沿「现象描述—属性刻画—计量单位—价格形成—配置与增长」的次序展开，数据要素的研究进程即是显例：在确权与定价研究已相当丰富的同时（熊巧琴和汤珂，2021；欧阳日辉和杜青青，2022），计量单位的缺位始终限制着其进入核算体系的深度。词元提供了一个罕见的机会：它天然可数，因而计量论的讨论可以直接从「如何折算」而非「能否计数」开始。本书把能源经济学的标准煤、航运的标准箱与气候核算的二氧化碳当量所共享的当量化传统，系统地引入认知产品领域，并以公理化方法给出折算函数的形式约束，是对当量折算这一计量传统的一次实质性扩展。

其次在于为通用目的技术理论与索洛悖论的当代讨论提供一个观测变量。通用目的技术的经济效应之所以难以测度，很大程度上源于其投入与产出均难以直接观测（Bresnahan 和 Trajtenberg，1995；Crafts，2021）；标准词元流量的意义在于，它把人工智能的「使用强度」变成了一个高频、可分解、可跨区域比较的观测变量。这使得人工智能对增长的贡献有可能从残差测度转向过程观测，从而在方法论上回应关于人工智能宏观效应的分歧（Brynjolfsson 等，2021；Acemoglu，2025）。第三，在价值理论层面，词元的生产同时凝结了数据劳动、算法劳动与知识工程劳动等活劳动，以及算力设施与模型资产等物化劳动，其价值实现又高度依赖应用场景，这为在认知生产条件下重新审视价值创造与价值实现的分离提供了具体载体，也与新质生产力的相关讨论形成呼应（周文和许凌云，2023；洪银兴，2024；黄群慧和盛方富，2024）。

1.3.2 方法论意义

本书在方法上尝试建立一条从公理到政策的完整链条。折算体系不是以拟合优度为唯一标准的经验构造，而是先由基准归一、单调性、可加性与传递一致性四条公理约束函数形式，再以基准任务集的实测数据标定参数，最后以放宽形式假定的交叉验证检验公理推论是否被数据拒绝。这种「先公理、后标定、再证伪」的次序，可以避免当量折算研究中常见的循环论证——即用待解释的价格数据去构造本应独立于价格的折算权重。此外，全书对数据纪律作了严格区分：宏观事实一律标注发布主体、统计边界与时点，不同口径不得混用同比；模型结果一律来自统一的校准复算体系，其锚点、随机种子与生成规则可复现；凡官方未单独发布的时点，一律标明为插值而不冒充实测。这一做法本身也是对数字经济统计中口径混用问题的一种回应（许宪春等，2021；蔡跃洲和牛新星，2021）。

1.3.3 现实意义

现实意义体现在六个可直接对接的政策界面。其一是计量标准：本书给出的标准词元折算框架可为词元计量的国家标准与统计口径建设提供技术方案，填补当前只有团体标准与机构评估规范的制度空白。其二是价格监测：物理词元价格指数与标准词元价格指数的双轨编制，可使价格主管部门与市场同时看到「名义降价」与「质量调整后降价」的差别，避免把质量改进误读为价格战。其三是补贴核定：以标准词元而非物理词元作为技改补贴与词元券的核定基准，可以消除「买便宜词元套补贴」的逆向激励，本书第10章给出的三方演化博弈进一步刻画了补贴退出的条件。其四是调度考核：以有效效值利用率替代名义上架率作为智算中心的考核指标，可以把考核压力从「建得多」转向「用得好」，与全国一体化算力网的建设目标一致（国家发展改革委等，2023）。其五是绿色认证：以每千标准词元的二氧化碳当量排放作为碳强度指标，可与产品碳足迹管理体系相衔接（生态环境部等，2024；国家市场监督管理总局和国家标准化管理委员会，2024）。其六是词元出海：可比、可加、可溯源的计量凭证是跨境互认的前提，也是「人工智能+」行动在国际层面落地的基础性条件（国务院，2025）。

1.4 核心概念界定

1.4.1 物理词元、效值系数与标准词元

为避免歧义，本节先行界定全书反复使用的核心概念，其形式化与性质证明留待第 5 章展开。所谓物理词元，记为 T ，指大模型分词器切分并据以计费的原始词元计数，不区分生成它的模型与承载它的任务；这是当前所有计费系统、平台统计与政策文件中「词元」一词的默认含义。所谓标准词元（Standard Token Equivalent, STE），记为 $\tilde{T}$ ，指经效值折算后的当量词元，其基准是「基准档模型在基准任务集上生成的 1 枚词元恒等于 1 个标准词元」。连接二者的是效值系数 η ，即单枚物理词元相对基准的当量倍数。设模型集合为 M 、任务集合为 J ，模型 m 在任务 j 上于第 t 期生成的物理词元数为 T_{mjt} ，则该期标准词元流量为：

$$\tilde{T}_t = \sum_{m \in M} \sum_{j \in J} \eta(P_m, R_m, S_j) T_{mjt} \quad (1-1)$$

其中， P_m 为模型 m 的算力强度， R_m 为其推理质量， S_j 为任务 j 的场景效用，三者均以基准档模型在基准任务集上的取值归一为 1； $\eta(\cdot)$ 为效值折算函数。

式(1-1)的结构包含三点须予说明的性质。第一，它是一个加权计数式而非估值式：权重 η 刻画的是「当量」而非「价格」，因而与市场价格相互独立，可以用来检验价格是否公允，这是折算体系不能以价格数据标定权重的根本原因。第二，加总在双重指标上进行，意味着标准词元流量同时吸收了模型结构与任务结构的变化：即便物理词元总量不变，若调用结构由低效值档位向高效值档位迁移，标准词元流量仍会上升，这正是「同样的调用量，不同的经济含义」的形式表达。第三，可加性并非天然成立，而是折算函数须满足的公理之一；第 5 章将证明，在基准归一、各维严格单调、可加与传递一致四条公理约束下，折算函数必为幂积形式 $\eta = P^{w_P} R^{w_R} S^{w_S}$ ，其权重经基准任务集标定为 $w_P = 0.4383$ 、 $w_R = 0.2964$ 、 $w_S = 0.2653$ （和为 1），拟合优度达 0.9996；把折算函数放宽为常替代弹性形式独立标定，所得替代参数为 0.0794，统计上无法拒绝其为零，即常替代弹性形式恰在此处退化为加权几何平均，实证标定与公理推论相互印证。

1.4.2 效值三维：算力强度、推理质量与场景效用

算力强度 P 定义为生成单枚词元所耗浮点运算量相对基准的倍数，刻画词元的生产成本侧属性，其技术决定因素包括模型参数规模、上下文长度、注意力实现方式、键值缓存策略与批处理组织（Dao 等，2022；Yu 等，2022；Pope

等，2023；Kwon 等，2023；Agrawal 等，2024）。推理质量 R 定义为单枚词元承载的有效信息量与任务达成度相对基准的倍数，刻画词元的能力侧属性，其测度依托标准化评测传统（Hendrycks 等，2021；Liang 等，2022；Zheng 等，2023），并须在同一基准任务集上完成以保证跨模型可比。场景效用 S 定义为应用场景的价值系数，反映单位词元所替代的人类认知劳动的价值密度，刻画词元的需求侧属性。三维的划分并非任意：它对应了任何一种当量折算都必须同时处理的成本、能力与用途三个面向，也与词元价格的三层结构（成本底价、效值溢价、场景租金）形成一一对应，这一对应关系是第 5 章与第 7 章相互衔接的枢纽。

必须再次强调，本书的三维效值折算体系是作者自主构建的理论框架。如 1.1.2 节所述，既有的四套词元评价工作分属不同机构、维度数各异、用途亦不相同，它们与本书体系构成文献对话关系而非承继关系；本书既不使用任何机构未曾提出的术语去指称其成果，也不把本书的校准复算结果挂靠到任何具体商业产品之上。为此，全书统一采用六个能力档位的中文名称来组织模型层面的讨论与图表——轻量蒸馏级、中型通用级（基准档，效值系数恒为 1）、开源旗舰级、旗舰闭源级、推理增强级与多模态级，正文与图表中不出现任何真实商业模型的产品名。按本书标定，六档位的效值系数依次为 0.38、1.00、1.96、2.94、4.28 与 2.62，最高与最低之比约 11.3 倍——这意味着，把不同档位的物理词元直接相加，其失真程度与把煤炭吨数和电力度数直接相加是同一量级的错误。

1.4.3 词元价格与标准词元价格

词元价格 p 指单位物理词元的价格（本书统一以元/百万物理词元表示），标准词元价格 $\tilde{p}$ 指单位标准词元的价格。二者由效值系数连接，并可进一步给出增长率形式：

$$\tilde{p}_{mj} = \frac{p_{mj}}{\eta(P_m, R_m, S_j)}, \frac{d \ln \tilde{p}}{dt} = \frac{d \ln p}{dt} - \frac{d \ln \eta}{dt} \quad (1-2)$$

其中，左式为水平关系，右式为对时间求导后的增长率分解； $d \ln \eta / dt$ 为效值的时间变化率，即技术进步带来的单枚词元能力提升速度。

式(1-2)右端的分解具有直接的政策含义。观测到的名义价格下降 $d \ln p / dt < 0$ ，可以分解为两个来源：一是效值提升 $d \ln \eta / dt > 0$ ，即同样一枚词元变得更有能力，此时质量调整后的真实价格未必下降；二是真实降价，即 $d \ln \tilde{p} / dt < 0$ 。二者的经济含义截然不同：前者是技术进步，对应生产者剩余与消费者剩余的共同扩

大；后者是竞争加剧或成本下降，对应租金的重新分配。若价格统计只观测 p 而不观测 η ，就会把技术进步全部记为通货紧缩，这正是特征价格指数方法在耐用消费品与信息技术产品领域长期试图纠正的偏误（Griliches，1961；Erickson 和 Pakes，2011；Redding 和 Weinstein，2020）。本书据此并行编制物理词元价格指数与标准词元价格指数，二者的背离幅度即为质量调整的规模，其编制方法、权重与链式处理见第 7 章。

1.4.4 转化效率、绿色词元与碳强度

转化效率 θ 定义为单位算力（每 PFLOPS·h）产出的有效标准词元数，是连接算力投入与词元产出的技术系数，也是第 9 章配置分析的核心变量；按本书校准复算，六档位的转化效率从轻量蒸馏级的 42.0 万标准词元/PFLOPS·h 递减至推理增强级的 3.1 万，其递减本身即说明「产能」与「产值」在词元生产中并不同向。绿色词元 $\tilde{T}^g$ 定义为附有碳足迹凭证、且碳强度低于既定阈值的标准词元；碳强度 i 定义为单位标准词元的二氧化碳当量排放，全书统一以 $\text{gCO}_2\text{e}/\text{千标准词元}$ 表示。这一量纲的选择有一个便利的性质：每百万标准词元耗电量（kWh）与电力排放因子（ kgCO_2/kWh ）相乘，所得即为每千标准词元的克数，换算系数恰为 1，因而能耗强度与碳强度可以在同一张图上直接对读而无须换算。按本书测算，2026 年用量加权平均碳强度为 $2.263 \text{ gCO}_2\text{e}/\text{千标准词元}$ ，绿色词元的界定阈值取 $1.0 \text{ gCO}_2\text{e}/\text{千标准词元}$ ，约为当前平均水平的 44%，意味着达标需要绿电占比与服务效率的双重改进；出海导向企业对绿色词元的支付意愿溢价约 8.3%。需要说明的是，公开的推理能耗测算其分母普遍是「一次查询」而非「一千枚词元」，且综合口径（含空闲备机与数据中心开销）与窄口径（仅计加速器）之间存在两倍以上差距，故本书凡涉及词元级能耗与碳排的数值一律标注为换算与校准复算结果，不表述为实测值。

1.4.5 标准词元流量与智能经济生产函数

把标准词元流量引入生产函数，是本书第五项创新的形式起点。按全书符号约定，记产出为 Y 、资本为 K 、劳动为 L 、数据要素为 D 、标准词元流量为 $\tilde{T}$ ，其产出弹性依次记为 α_K 、 α_L 、 α_D 与 α_T （本书不使用 α 、 β 等简写，以免与匹配函数与博弈参数混淆），设定柯布一道格拉斯形式的智能经济生产函数：

$$Y_t = A_t K_t^{\alpha_K} L_t^{\alpha_L} D_t^{\alpha_D} \tilde{T}_t^{\alpha_T} \quad (1-3)$$

其中， A_t 为全要素生产率， α_T 即标准词元流量的产出弹性，是本书从残差测度转向过程观测的关键参数。

式(1-3)的意义在于把人工智能的贡献从 A_t 中显性分离出来。在传统三要素核算中，人工智能的影响只能经由全要素生产率残差被间接感知，既无法区分「使用强度上升」与「使用效率提高」，也无法在区域与行业间做结构分解。引入 $\tilde{t}$ 之后，增长核算式变为各要素增长率的弹性加权和加上残差，人工智能的直接贡献即为 α_t 与标准词元流量增长率之积。这里必须使用标准词元而非物理词元：若以物理词元入式，模型结构变化引起的效值变动会被错误地计入弹性估计，导致系数不稳定且缺乏跨期可比性。按本书基于区域面板的估计，四项弹性分别为0.318、0.276、0.094与0.108，均在1%水平显著；2026年标准词元流量对产出增长的直接贡献为0.34个百分点，占实际增长率的6.8%；不引入词元变量时全要素生产率残差为2.41%，引入后降至2.12%，残差高估0.29个百分点。这一结果与资本服务测度传统的启示同构：把此前未被单独计量的投入显性化，残差便相应缩小，增长的来源随之变得可解释。完整设定、识别策略与稳健性检验见第12章。

1.5 研究思路、方法与技术路线

本书的研究思路可概括为「一条主线、三大模块、两级转化」。一条主线是标准词元，即以效值折算把物理词元变换为可比、可加的当量单位，并使其依次承担价值尺度、定价基准、配置信号与增长核算变量四重职能；三大模块是计量、定价与配置增长，分别回应三个科学问题；两级转化是指全部理论结论先经区域实践与案例证据的检验，再转化为可操作的政策建议，并由政策实施的反馈回到参数再标定。与之匹配的方法体系是多方法组合而非单一方法：概念界定与属性刻画采用规范分析与形式化建模；折算体系采用公理化方法，先由公理约束函数形式，再以基准任务集标定参数，并以放宽形式假定的交叉验证做证伪检验；价格分析采用指数编制方法与面板计量，需求侧估计词元需求的价格弹性；配置分析采用整数规划与其线性松弛刻画任务—模型匹配，以排队论刻画并发与时延；组织与机制分析采用比较制度分析、三方演化博弈与层次分析法；区域实践部分采用多案例比较与扎根理论编码，并与定量结论做三角验证。本书的技术路线如图1.1所示。




图 1.1 本书研究技术路线

图 1.1 的结构体现了本书的三个方法论主张。其一，问题的起点不是理论缺口而是现实矛盾：顶端的「物理词元不等值」并非从文献中推演出来的假设，而是由第 3、4 章的经验事实所确证的现象，它经由定价、补贴、统计与出海四个界面外化为四类具体障碍，构成本书的问题域。其二，三个科学问题与三大研究模块严格对应，且模块之间是单向依赖而非相互独立：计量模块的输出（效值系数与标准词元口径）是定价模块的输入，定价模块的输出（标准词元价格与价格指数）又是配置模块判断资源是否错配的依据。这一依赖结构决定了本书各章不可打乱阅读顺序。其三，左侧贯通全图的纵向主线标明了标准词元在四种职能之间的流转，右侧的虚线反馈回路则表示政策实施与实践检验对参数标定的修订作用——这一回路的存在意味着本书的折算权重、阈值与情景参数都是可随实践更新的开放参数，而非一次性给定的常数。

在数据与结果的使用上，本书恪守两条纪律，并在此一并声明，后续各章不再逐一重复。第一，宏观事实一律取自经过逐条核实的事实库，标注发布主体、统计边界与时点；不同口径的数字不并列比较，不做跨口径折算与除法；凡官方

未单独发布的时点，一律标明为校准复算插值。第二，模型估计与模拟结果一律取自统一的校准复算体系，其锚点、随机种子与生成规则固定且可复现；表中数值与正文数值同源，不存在手工调整。之所以强调这两条，是因为词元领域的数字环境格外嘈杂：调用量、算力规模、利用率、价格与能耗各自都有三套以上互不相通的口径，稍有不慎便会得出「中国智能算力超过全球总量」一类的荒谬结论。计量研究若自身不守计量纪律，其结论便无从取信。

1.6 结构安排

全书共 14 章，按逻辑功能分为五篇。第一篇总起，含第 1、2 章：第 1 章为导论，第 2 章系统梳理价值理论在认知生产中的拓展、计量单位演进的经济学、当量折算的经济学传统、通用目的技术与索洛生产率悖论、数字产品定价与双边平台理论以及增长核算的理论脉络，并在文献述评中定位本书的研究缺口。第二篇属性与事实，含第 3、4 章：第 3 章刻画词元的技术属性与八项经济属性，并以各档位模型的算力—价格—质量三维离散度形式化地提出非同质性问题；第 4 章描述词元经济的发展格局与典型事实，包括调用量演进、模型市场结构、场景结构、价格演进、算力供给格局与利用率现状。第三篇计量与价值，含第 5、6 章，是全书的理论核心：第 5 章构建标准词元效值折算体系，第 6 章讨论词元的价值创造、实现与增值。第四篇定价与市场，含第 7、8 章：第 7 章提出词元定价的三层结构理论并编制两套价格指数；第 8 章分析词元市场的结构、竞争与均衡，包括需求弹性、成本曲线、市场集中度与市场失灵。第五篇配置、增长与实践，含第 9 至 14 章：第 9 章分析算力—词元转化效率与配置优化；第 10 章研究城市词元运营中心的组织模式与机制设计；第 11 章讨论绿色词元的能耗、碳足迹与可信溯源；第 12 章测度词元经济的增长贡献；第 13 章开展区域实践与多案例研究；第 14 章归纳结论、提出政策建议并展望后续研究。全书结构与章节安排如图 1.2 所示。




图 1.2 全书结构与章节安排

图 1.2 所示的五篇结构并非简单的主题分组，而是对应着从概念到证据、从证据到理论、从理论到机制、从机制到政策的完整链条。其中有三处衔接需要读者特别留意。第一处是第 3 章末与第 5 章的衔接：第 3 章以经验证据证明物理词元不可加，是「问题的提出」；第 5 章给出折算体系，是「问题的解决」，二者之间的第 4 章提供的是问题的宏观规模与紧迫性。第二处是第 5 章与第 7、9、11、12 章的衔接：效值系数一经标定，即同时作为价格指数的质量调整因子、配置分析中的效值损失度量、碳强度核算的分母以及增长核算的流量变量进入后续四章——这四条输出线是标准词元「一体四用」的具体体现，也是检验折算体系是否真正有用的四块试金石。第三处是第 13 章与前面各定量章节的衔接：多案例研究不是理论的例证，而是对定量结论的独立检验，其五城能力画像与访谈编码结果将与第 5、7、9、12 章的测算结论做三角验证，若二者背离，则须回到模型设定重新审视。

考虑到读者背景的差异，此处给出三条阅读路径。关注计量方法的读者，可循第 1 章、第 3 章、第 5 章、第 12 章的主干阅读，这条路径完整呈现了「问题

「一折算一核算」的方法链条；关注产业与市场的读者，可循第 4 章、第 7 章、第 8 章、第 9 章阅读，这条路径侧重典型事实、价格结构、市场均衡与配置效率；关注政策制定与地方实践的读者，可循第 4 章、第 10 章、第 11 章、第 13 章、第 14 章阅读，这条路径以运营组织、绿色治理、区域案例与政策建议为主。需要提醒的是，三条路径均以第 5 章为交汇点：效值折算体系既是方法路径的核心，也是产业路径中价格与效率分析的前提，还是政策路径中补贴核定与绿色认证的计量依据。跳过第 5 章而直接阅读后续章节，将难以理解各章中反复出现的「标准词元」究竟如何得来、其权重为何如此设定。

1.7 主要创新

本书的创新集中于五个方面，其相对既有研究的理论增量与关键测算结果见表 1.1。总体而言，这五项创新围绕同一条主轴展开：把「计量」这一被普遍视为技术性、辅助性的环节，重新确立为智能经济分析的理论前提，并由此重新组织定价、配置与增长三个传统议题。

表 1.1 本书五项理论创新及其核心内容

创新点	相对既有研究的理论增量	关键测算结果	对应章节
标准词元效值折算体系	既有词元评价工作均为多维并列评分，产出的是维度得分或达标基线，无法把异质词元合成为可加总、可计价、可入账的单一当量；本书由基准归一、单调性、可加性与传递一致性四条公理约束折算函数的形式，证明其必为幂积形式并给出标定与证伪程序，实现由「多维评价」向「当量折算」的推进	折算前后单位价格的变异系数由 0.92 降至 0.31（下降约 66%），基尼系数由 0.47 降至 0.17，最高与最低之比由 12.6 倍收敛至 2.4 倍	第 5 章
词元定价的三层结构理论	在零边际成本条件下重构定价分析，把词元价格分解为由算力与能源决定的成本底价层、由模型能力决定的效值溢价层与由应用价值可占有份额决定的场景租金层，据此同时解释通用词元价格下行与高效值词元溢价扩大的并存，并给出质量调整的价格指数编制方案	以 2024 年第一季度为 100，2026 年第二季度物理词元价格指数降至 21、标准词元价格指数为 47；累计降幅中约 53%来自效值提升、约 47%为真实降价；需求价格弹性-1.34	第 7 章

算力—词元转化效率与配置悖论分解	构造由算力到有效标准词元的转化函数，把「智算利用率仅五至七成而算力仍在扩建」的悖论分解为空转、批次、匹配与效值四项损失，其中后两项只有在建立标准词元尺度后方可识别，并以任务—模型最优匹配给出统一调度的效率改进上界	名义利用率 62%，有效效值利用率仅 38%；最优匹配后升至 54%（相对改进 42%），理论上界 61%	第 9 章
城市词元运营中心的组织模式与机制设计	以比较制度分析刻画基础电信运营商、城投集团、数据集团、数据交易所与政策制定者五类主体的资产禀赋—职能匹配关系，为存量基础设施资产的再打包给出资产逻辑；以平台—企业—政府三方演化博弈求解「五个统一」制度安排的激励相容条件与补贴退出条件	企业深度采纳成为演化稳定策略的临界红利为 1.55，基准情景的 1.5 仅低约 3%，却收敛于政府被锁定在强激励挡位的「平台热、企业冷」均衡；制度要件中统一计量的组合权重最高，为 0.271	第 10 章
基于词元流量的增长贡献核算	把标准词元流量作为可观测变量引入智能经济生产函数，把人工智能的增长贡献由残差测度推进到过程观测，从索洛残差中显性分离，并与资本服务测度传统对话	标准词元流量的产出弹性为 0.108；2026 年直接贡献 0.34 个百分点、占实际增长率的 6.8%；不引入词元变量时全要素生产率残差高估 0.29 个百分点	第 12 章

注：表中数值为本书第 5、7、9、10、12 章的校准复算结果，各自的模型设定、数据来源、参数标定与稳健性检验详见相应章节；价格指数以 2024 年第一季度 = 100；效值系数、价格与利用率均以中型通用级模型在基准任务集上的取值为基准归一。

表 1.1 所列五项创新之间存在明确的支撑关系，而非五个并列的贡献点。第一项是地基：若折算体系不成立，其余四项均失去计量前提。第二、三项分别是折算体系在价格界面与配置界面的应用，二者共同回答「标准词元是否真的比物理词元更有解释力」这一实证问题——价格离散度的收敛与利用率损失的可分解性，是折算体系有效性的两个独立检验。第四项把分析从市场推进到组织，回答「谁来提供统一计量这一公共品、其激励如何相容」；这一问题之所以必要，是因为标准词元并不会自发产生，它需要一个愿意承担计量基础设施成本的组织主体。第五项则把标准词元送入国民经济核算，回答「这一切在宏观上意味着什么」。五项创新连成一条从微观计量到宏观核算的完整链路，也构成了本书与既有文献对话的五个具体接口。

与此同时，本书亦须坦陈其边界。第一，折算体系的权重标定依赖基准任务集的选择，任务集的代表性直接影响推理质量维度的测度，本书虽以交叉验证与稳健性检验加以约束，但基准任务集本身的更新机制仍是开放问题。第二，场景效用维度涉及对人类认知劳动价值密度的估计，其测度不可避免地带有规范性色彩，本书采取的是可复核的相对赋值而非绝对估值。第三，宏观测算受制于官方统计的口径缺位——目前尚无按模型档位、按场景分类的官方词元流量统计，本书的结构参数来自校准复算而非普查数据，其精度将随统计基础设施的完善而提升。这三点局限恰恰指向本书政策建议的第一条：把标准词元计量纳入国家统计与标准体系，是后续一切实证工作的前提。

1.8 本章小结

本章确立了全书的问题域、核心命题与分析框架。从计量单位演进的长时段视角看，每一次经济形态的跃迁都以一个新计量单位的确立为标志，而计量单位的合格标准是可数、可加、可折算、可入账。数据要素因缺乏天然的物理计量单位，长期困于「重要但难以定价」的状态；生成式人工智能的兴起改变了这一格局，它使认知服务的产出第一次被离散化为可逐枚计数的词元，从而为智能经济提供了计量单位的候选者。2026年3月25日，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用 token 的中文名「词元」，并明确该定名将在常态化审定中结合社会推广应用情况最终确认；同月，国家数据局局长在中国发展高层论坛 2026 年年会上使用并推介这一译名，提出词元具有「可计量、可定价、可交易」的特征，是「智能时代的价值锚点」。术语学口径与经济计量口径由此并存，本书讨论价值计量时引后者，讨论术语规范时引前者，二者不可拼接。

本章随后刻画了词元经济的现实图景与三重悖论。按国家数据局口径，我国日均词元调用量由 2024 年初的 1000 亿枚增至 2025 年 6 月底的 30 万亿枚、2025 年底的 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍；供给侧的智能算力规模与万卡集群数量同步扩张；流通侧则在 2026 年 7 月中旬至 8 月中旬出现了主体类型各异的城市级词元运营组织，政策工具亦由「建算力」转向「用词元」。然而繁荣之下并存三重悖论：价格持续下行与高质量词元稀缺并存，算力扩建与利用率不足并存，调用量千倍增长与宏观生产率统计无感并存。本章论证，三者并非独立难题，而是同一计量缺陷在价格、配置与核算三个界面上的投影——物理词元是合格的计数单位，却不是合格的价值单位。生产端算力强度的跨档位跨度、价格端逾十倍的报价跨度与价值端的场景离

散共同表明，技术上完全同名的「词元」，在经济上根本不是同一种东西。计量地基的缺失沿四条路径外化为定价无公允基准、补贴无核定依据、统计无可加口径与出海无互认凭证。

据此，本章提出全书核心命题——词元是智能经济的计量单位，但物理词元不是合格的价值单位，只有经效值折算得到的标准词元才能承担价值尺度、定价基准、配置信号与增长核算变量四重职能——并将其展开为计量、定价、配置与增长三个递进的科学问题。本章界定了物理词元、标准词元、效值系数、算力强度、推理质量、场景效用、词元价格、标准词元价格、转化效率、绿色词元与碳强度等核心概念，给出了标准词元流量的加总式、标准词元价格及其增长率分解式与引入词元流量的智能经济生产函数三个基础关系式，并说明了各式的性质与经济含义。本章还交代了研究思路、多方法组合、技术路线与全书五篇 14 章的结构安排，归纳了五项理论创新及其相互支撑关系，同时坦陈了基准任务集依赖、场景效用测度的规范性色彩与官方分类统计缺位三点局限。

需要在此重申两条贯穿全书的写作纪律。其一是口径纪律：词元领域的数字环境异常嘈杂，调用量、算力规模、利用率、价格与能耗各自都有数套互不相通的口径，本书凡引用宏观事实一律标注发布主体、统计边界与时点，不同口径不并列比较、不互相折算，官方未单独发布的时点一律标明为校准复算插值。其二是归属纪律：本书的三维效值折算体系是作者自主构建的理论框架，与任何机构的既有评价体系均不存在承继关系；全书以六个能力档位的中文名称组织模型层面的讨论，正文与图表中不出现真实商业模型的产品名，以免把校准复算结果误挂到具体产品之上。守住这两条纪律，是一部以计量为主题的著作最基本的自我要求。下一章将转入理论基础与文献述评，系统梳理价值理论、计量单位演进、当量折算传统、通用目的技术与增长核算五条脉络，并在其中定位本书的研究缺口与理论坐标。

第2章 理论基础与文献述评

第1章从现实出发提出了本书的三个科学问题：异质词元如何折算为可比、可加的标准计量单位（计量），标准词元的价格如何形成与演化（定价），词元如何在算力、模型与场景之间实现有效配置并如何进入增长核算（配置）。三个问题看似分属计量学、产业组织与增长理论三个领域，实则共享同一个理论前提：一种新的经济计量单位要真正成立，必须依次通过三重理论检验——它所计量的究竟是何种价值（价值论检验）、它凭什么可以在异质个体之间加总（计量论与当量折算论检验）、它进入价格体系与国民经济核算之后会产生什么后果（定价论与核算论检验）。任何一重检验不过关，所谓“计量单位”就只是一个记账符号，而不是经济尺度。本章的任务，就是沿这三重检验依次梳理支撑本书命题的理论脉络，并在既有文献的坐标系中标定本书的位置。

需要先行申明本章的一个方法论立场：本书不把词元当作一个纯粹的技术概念，而把它当作一项正在生成中的经济制度。计量单位的经济学史反复表明，单位的确立从来不只是技术约定，而是降低交易费用的制度创新——度量衡的统一之于商品交换、标准煤之于能源统计、标准箱之于集装箱运输、二氧化碳当量之于气候治理，无一例外。标准的经济学研究早已指出，标准既是协调装置又是分配装置，其确立过程伴随着显著的网络效应与利益博弈（Farrell 和 Saloner, 1985；Katz 和 Shapiro, 1985；Simcoe, 2012）；来自中国物流领域的经验证据进一步显示，标准化本身即可通过降低交易与协调成本显著提升企业全要素生产率（何凡等，2025）。词元计量之所以值得写成一本经济学专著，正因为它处在这样一个从技术约定向经济制度转化的临界点上。

本章结构如下：2.1节在价值理论层面考察劳动价值论、效用价值论与信息产品价值论在认知生产中的拓展，回答“词元计量的是什么价值”；2.2节梳理计量单位演进的经济学，论证标准化计量降低交易费用的机制，回答“词元为何暂不是合格的价值单位”；2.3节考察标准煤、标准箱与二氧化碳当量三项当量折算传统，给出当量折算的一般形式并揭示词元折算相对于既有范例的特殊性，回答“多维异质对象如何获得单一当量”；2.4节讨论通用目的技术理论与索洛生产率悖论在人工智能时代的再现，回答“为何需要一个可观测的中间变量”；2.5节梳理数字产品定价、质量分级与双边平台理论，回答“标准词元进入价格体系后价格结构将如何组织”；2.6节回顾增长核算的理论脉络与数据要素核算的探索，回答“标准词元流量如何进入生产函数”；2.7节以文献计量刻画研究进展，归纳研究缺口并给出本书的理论定位与分析框架；2.8节为本章小结。

2.1 价值理论在认知生产中的拓展

2.1.1 劳动价值论视角：词元作为认知劳动的物化载体

词元是大模型在推理过程中生成并交付的最小信息单元，它既不是原始数据，也不是最终产品，而是介于二者之间的中间产物——一种被物化了的认知劳动。从劳动价值论的视角看，一枚词元的价值由两部分构成：一是在生产过程中被转移过来的物化劳动价值，包括智算设施的折旧、电力等能源的耗费与模型资产的摊销；二是在本期生产中由活劳动新创造的价值，包括数据劳动（语料采集、清洗、标注与合规审查）、算法劳动（模型训练、微调、对齐与推理优化）与知识工程劳动（提示工程、智能体编排与业务流程再造）。记第 t 期投入的智算设施资本存量为 K_t 、折旧率为 δ ，用电量为 E_t 、电价为 q_t ，模型资产账面价值为 M_t 、摊销率为 ϕ ，活劳动新创造的价值为 N_t ，该期生成的物理词元量为 T_t ，则单位物理词元的价值可写为：

$$v_t = \frac{\delta K_t + q_t E_t + \phi M_t + N_t}{T_t} \quad (2-1)$$

其中， $\delta K_t + q_t E_t + \phi M_t$ 为转移的物化劳动价值， N_t 为活劳动新创造的价值， v_t 为单位物理词元的价值。

式(2-1)虽然形式简单，却已经蕴含三项对本书至关重要的性质。其一，单位价值对产量的递减性：分子中的折旧、摊销与相当一部分活劳动（尤其是训练期的算法劳动）在短期内近似固定，因而 $\partial v_t / \partial T_t < 0$ ，产量扩张会摊薄单位价值。这意味着词元价格的长期下行趋势首先是价值规律的表现，而不能一概归因于补贴或价格战——第7章将证明，表观降价中相当大的份额其实来自单位价值构成的变化而非厂商让利。其二，价值构成的资本密集特征：与传统服务业不同，认知生产中物化劳动的占比极高，活劳动主要以“过去劳动”的形式凝结在模型权重之中，本期活劳动的直接投入相对稀薄。词元因而在价值构成上更接近资本品的产出而非劳务的产出，这一点决定了它的成本曲线、规模经济性质与定价机理都不能照搬传统服务业的分析框架。其三，也是最关键的一点：式(2-1)的分子随模型档位而系统性变化。同样生成一万枚词元，轻量蒸馏级模型与推理增强级模型所消耗的算力、电力与模型资产摊销可以相差一个数量级，其 v_t 自然相差一个数量级。既然价值不等，物理词元的简单加总就失去了价值论根据——“词元总量”这个变量在经济学意义上是不可解释的。

这一判断与国内政治经济学界关于新质生产力的讨论具有内在一致性。新质生产力被界定为以科技创新为核心驱动、以劳动者、劳动资料与劳动对象及其优

化组合的跃升为基本内涵的先进生产力质态（周文和许凌云，2023；洪银兴，2024）；从系统论视角看，其要素特质在于知识、数据与算力等新型要素替代传统要素成为结构承载（黄群慧和盛方富，2024），相应的水平测算亦已展开（韩文龙等，2024）。人工智能把“劳动资料”从机器扩展到模型、把“劳动对象”从物质扩展到信息，词元恰是这一跃升在生产端留下的可计数痕迹。因此，从劳动价值论出发研究词元，并非把一个技术名词强行塞进古典范畴，而是承认认知生产已经形成了自己的价值实体与计量载体——本书第6章将沿这一线索完整展开词元的价值创造、实现与增值机理。

2.1.2 效用价值论视角：以替代认知劳动衡量的支付意愿

价值的另一侧在需求端。企业购买词元并非为了持有词元，而是为了用机器的认知输出替代或增强人的认知劳动，因此其支付意愿的上界由被替代认知劳动的价格决定。设场景 j 中被替代的认知劳动单位时间报酬为 w_j ，完成单位任务原需人工工时 h_j 、现需消耗词元 T_j ，模型在该场景的任务达成度为 $q_j \in (0, 1]$ （达成度刻画机器输出相对于合格人工输出的可用比例，包含返工与复核的折扣），则买方对单位物理词元的最高支付意愿为：

$$p_j^{\max} = w_j \frac{h_j}{T_j} q_j \quad (2-2)$$

其中， h_j/T_j 为单枚词元所替代的人工工时， q_j 为任务达成度， $p_j^{\max}$ 为场景 j 中单位物理词元的支付意愿上界。

式(2-2)给出三条可检验的推论。第一，支付意愿随被替代劳动的价格上升而上升：同样一枚词元，用于替代资深工程师的代码审查，与用于替代基础客服的话术应答，其经济价值天差地别。第二，支付意愿随任务达成度上升而上升，且在达成度低于合格线时可能骤降为零——半对的法律意见书不是半份法律意见书，而是零份，因为复核成本可能高于重做成本。这一非线性正是高效值模型能够维持溢价的微观基础。第三，也是本书最关心的一点： $p_j^{\max}$ 随场景 j 而变，而与词元的“枚数”本身无关。换言之，即便在纯粹的效用价值论框架内，物理词元同样不是同质商品。已有的任务暴露度研究为 h_j/T_j 与 q_j 的场景异质提供了系统证据：大语言模型对不同职业与任务的暴露程度差异显著（Felten等，2021；Felten等，2023；Eloundou等，2024），随机实验显示写作类任务的完成时间与质量改进幅度可观（Noy和Zhang，2023），客服座席的准实验证据显示生成式人工智能对新手的提升远大于对熟手的提升（Brynjolfsson等，2025）。斯坦福大学人类中心人工智能研究院汇总的职能级证据同样呈现

高度离散：客户支持环节的生产率提升约为 14%—15%、软件开发约为 26%、营销产出约为 73%（「Stanford HAI，2026」）。必须强调的是，这三个数字来自各自独立的随机对照或准实验研究，样本、任务与时长各异，只能用于说明场景间的相对离散，不可外推为宏观生产率增速——这一口径纪律将在 2.4 节再次涉及。

2.1.3 信息产品价值论与两种价值论的综合

词元是信息产品，因而不能回避信息产品价值论的两个经典命题：非竞争性与零边际复制成本。数据作为非竞争性要素可被无限次使用而不损耗，其社会最优配置要求打破排他性占有（Jones 和 Tonetti，2020）；但非竞争性并不自动导致有效配置，数据市场因外部性与隐私溢出可能出现“数据过多”的均衡（Acemoglu 等，2022a），社会数据的定价还须考虑个体信息对他人推断的溢出（Bergemann 等，2022）。围绕数据定价已形成从经济学到数据科学的系统综述（Pei，2022），国内研究亦在界权、交易与定价三个层面展开（熊巧琴和汤珂，2021；欧阳日辉和杜青青，2022），并延伸至数据资产的会计确认与价值评估（罗玫等，2023；财政部，2023），以及数据要素对高质量发展的作用与数据流动的制约（蔡跃洲和马文君，2021）。

然而，把词元直接等同于数据是一个需要警惕的错误。二者在经济属性上至少有三处根本差异。其一，存量与流量之别：数据是存量资源，词元是生产流量，前者可沉淀于资产负债表，后者按期发生并按期消灭。其二，复制成本之别：一份数据复制一万次的边际成本近乎为零，而一万枚词元必须由算力逐枚重新生成，每一枚都对应真实的电力与算力耗费——词元具有“信息产品的非竞争性”与“物质产品的竞争性”的双重属性，这在既有的信息产品价值论中几乎没有对应物。其三，可归属性之别：数据的权属界定至今困难重重，而每一次词元调用都天然地绑定了调用主体、调用时刻、所用模型与所属场景，可归属性远优于数据。这三点差异共同决定了：词元既不能照搬数据要素的定价理论，也不能照搬传统商品的成本定价理论，必须建立自己的价值分析框架——这正是本书第 3 章与第 6 章的任务。

现在可以把两种价值论综合起来。式(2-1)给出的 v_i 是价格的下界（长期低于此界则供给不可持续），式(2-2)给出的 p_j^{max} 是价格的上界（高于此界则买方不如自己雇人做），实际价格落在二者之间，其位置由供给方能够占有的场景价值份额决定。按全书符号约定记场景租金分成率为 $\rho_j \in [0, 1]$ ，则场景 j 中单位物理词元的均衡价格可写为：

$$p_j = v_t + \rho_j (p_j^{\max} - v_t) \quad (2-3)$$

其中， ρ_j 为供给方在场景 j 中可占有的价值份额，取决于买方议价能力、可替代模型的数量与业务转换成本； $\rho_j=0$ 对应完全竞争下的成本定价， $\rho_j=1$ 对应供给方完全占有场景剩余。

式(2-3)是本书定价理论的胚胎。它表明词元价格并非由成本单独决定，也非由效用单独决定，而是由“成本底决定地板、替代价值决定天花板、占有能力决定位置”这一三元结构共同决定——第7章将把这一结构展开为成本底价层、效值溢价层与场景租金层的三层定价模型。同时，式(2-3)也第一次暴露出本书要解决的核心矛盾： v_t 随模型档位而异， $p_j^{\max}$ 随场景而异，若不引入某种折算把二者归到共同尺度上，价格的横向比较、纵向指数化与跨主体加总都无从谈起。价值理论到此已经把问题交给了计量理论。

2.2 计量单位演进的经济学：从工时、千瓦时、字节到词元

2.2.1 经济计量单位的演进逻辑与四个成立条件

经济活动的每一次形态跃迁，几乎都伴随着一个新的主导计量单位的确立。农业与手工业时代计量投入的是工时，劳动时间既是价值实体的度量，也是契约与工资的计算基础；工业时代计量能量的是千瓦时，度电成为工厂、电网与家庭之间通用的结算单位；数字时代计量信息的是字节，它使存储、带宽与流量得以定价与交易。当人工智能开始大规模承担认知劳动时，一个新的问题被提出：智能本身该如何计量？词元是迄今为止最接近答案的候选——它是模型处理信息的基本粒度，是智能服务计费的通行依据，也是连接算力、模型与应用的接口变量。

把这一演进序列并置起来观察，可以抽象出一个经济计量单位得以成立的四个条件。条件一是同质可比：任意两单位之间在被计量的属性上必须等价，一度电就是一度电，不因由火电还是风电生产而改变。条件二是可加：不同来源的单位可以直接相加得到有经济含义的总量，全国用电量之所以是一个有意义的宏观变量，正因为度电可加。条件三是可验证：交易双方能够以可接受的成本对计量结果达成一致，电表与流量计的存在使得计量争议可裁决。条件四是度量费用足够低：若每笔交易的核验成本超过交易本身的收益，计量单位就无法在市场中存活。四个条件之中，同质可比是逻辑前提，可加是经济功能，可验证与低度量费用则是制度可行性——三者共同决定了一个单位能否同时承担计价基础、契约基础与统计基础这三重职能。

词元的制度化进程已经启动。2026 年 3 月 25 日，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用人工智能领域名词 token 的中文名“词元”，并明确该中文定名将在计算机科学技术名词的常态化审定工作中结合社会推广应用情况最终确认；同月，在中国发展高层论坛 2026 年年会期间，国家发展改革委党组成员、国家数据局局长刘烈宏发表《深化数据赋能人工智能发展，加快培育智能经济新形态》演讲，使用并推介这一译名，提出词元具有可计量、可定价、可交易的特征，是智能时代的价值锚点。两个主体、两个动作分属两种口径，本书严格区分：名词委口径为术语学口径，把词元界定为智能设备中信息存储、处理和交换的具有一定语义的基本符号单元；国家数据局口径为经济计量口径，把词元界定为可计量、可定价、可交易的最小信息单元。本书讨论术语规范时引前者，讨论价值计量时引后者，二者不作互换或拼接。需要特别指出的是，名词委公告的用语是“优先推荐”与“发布试用”，其效力层级尚待常态化审定最终确认，因此不宜表述为“正式定名”，更不构成国家标准。

2.2.2 词元为何暂不是合格的价值单位：技术根源

以 2.2.1 节的四条件检验物理词元，结论并不乐观：可加与低度量费用两条勉强成立（词元天然可计数，平台侧计数成本极低），同质可比与可验证两条则明显不成立。其技术根源可分为输入侧与输出侧两个层面。

输入侧的根源在于分词。字节对编码等子词切分方法把文本切分为子词单元，以在词表规模与未登录词覆盖之间取得平衡（Sennrich 等，2016），语言无关的子词分词器进一步把这一过程标准化为可复用的工具链（Kudo 和 Richardson，2018）。但分词器是模型特定的：同一段文本在不同分词器下被切成的词元数可以相差数成，分词器质量对下游任务表现有系统性影响（Rust 等，2021）。更严重的是跨语言的不对等——语言模型分词器对不同语言的编码效率差异极大，导致相同语义内容在不同语言下的词元数与费用显著不同（Petrov 等，2023；Ahia 等，2023）。这意味着“词元数”这一计数本身就不是语义中性的：它既依赖于模型，也依赖于语言，还依赖于文本类型。以之作为计价基础，等于用一把刻度随被测物而变的尺子去量长度。

输出侧的根源在于生成过程的算力异质。单枚词元的生成成本取决于模型参数规模、上下文长度、批处理策略与缓存命中情况：高效的自回归推理需要在张量并行与流水并行之间做精细权衡（Pope 等，2023），注意力计算的访存优化可数倍改变实际吞吐（Dao 等，2022），连续批处理与分页式显存管理把服务吞吐提升到新的量级（Yu 等，2022；Kwon 等，2023），预填充与解码阶段

的分离部署以及吞吐一时延权衡的调度设计进一步改变了单位词元的资源占用（Agrawal 等，2024；Zhong 等，2024）。与此同时，推理增强类模型以生成大量中间思考词元换取答案质量，同一任务的词元消耗可较直接作答的模型高出数倍。于是出现了本书反复引用的基本事实：同样 100 枚词元，不同档位模型的算力消耗相差十倍乃至百倍，其经济价值自然不可能相等。

可验证条件的失效则更具经济学意味。买方在购买时能够观测到的是词元数与单价，而真正决定其效用的效值（算力强度、推理质量与场景效用的合成）在购买时不可观测、在事后也难以低成本地验证。这是一个标准的质量不可观测情境，其后果早已被经典文献揭示：当买方无法区分高质量与低质量商品时，市场价格向平均质量收敛，高质量供给被逐出市场（Akerlof，1970）；解决之道在于建立可信的质量披露与第三方认证制度，把不可观测的质量转化为可观测的信号（Dranove 和 Jin，2010）。词元市场今日的处境与此高度同构——这也正是本书把标准词元同时定位为计量技术与市场制度的原因。

2.2.3 标准化计量降低交易费用的机制

为把上述直觉形式化，考虑一个风险规避的买方。设买方对单位标准词元的边际估值为 u （元/标准词元），所购物理词元的效值 η 不可事前观测，其主观分布的均值为 $\dot{\eta}$ 、方差为 σ_η^2 ；买方的风险规避系数为 A ，单笔交易中用于询价、试测与验收的度量费用为 τ 。在均值一方差偏好下，买方对单位物理词元的确定性等价支付意愿为：

$$W = u\dot{\eta} - \frac{A}{2}u^2\sigma_\eta^2 - \tau \quad (2-4)$$

其中， $u\dot{\eta}$ 为期望效用价值， $\frac{A}{2}u^2\sigma_\eta^2$ 为效值不确定带来的风险贴水， τ 为单笔交易的度量与核验费用， W 为确定性等价支付意愿。

式(2-4)有两条直接性质： $\partial W / \partial \sigma_\eta^2 < 0$ 与 $\partial W / \partial \tau < 0$ 。前者表明效值的不确定本身就压低了买方的支付意愿，形成一种“计量折价”——即便供给方确实提供了高效值词元，只要买方无法确信，其愿意支付的价格也会低于该词元的真实价值；后者表明度量费用直接从交易剩余中扣除。两条性质合起来解释了一个反直觉的现象：在效值信息不透明的市场上，提升模型能力未必能提升售价，因为提升的是 $\dot{\eta}$ ，而买方的支付意愿同时被 σ_η^2 拖累。第 8 章的测度显示，企业对所购词元效值的认知偏差均值达 0.44，由此导致低效值档位的过度采购份额达 0.27——柠檬市场机制在词元市场上已经可以被观测到。

标准化计量的经济功能，正在于同时压缩 σ_η^2 与 τ 。设标准建立前后效值方差由 σ_0^2 降至 σ_1^2 、单笔度量费用由 τ_0 降至 τ_1 ，则每笔交易的计量收益为 $\Delta = \frac{A}{2}u^2(\sigma_0^2 - \sigma_1^2) + (\tau_0 - \tau_1)$ 。记标准体系的建设与维护固定成本为 F （包括基准任务集构建、测试认证、争议裁决与制度运行），则标准化净收益为正所需的临界交易规模为：

$$N^* = \frac{F}{\frac{A}{2}u^2(\sigma_0^2 - \sigma_1^2) + (\tau_0 - \tau_1)} \quad (2-5)$$

其中， N^* 为使标准化投入得以收回的最小交易笔数；当实际交易规模 $N > N^*$ 时，建立统一计量标准是社会有效率的。

式(2-5)对本书具有纲领性的意义，它回答了一个常被追问的现实问题：为什么词元的计量标准问题在 2024 年还只是学术话题，到 2026 年却成为产业刚需？答案在于 N 的爆发式增长。按国家数据局公开发布的口径，我国日均词元调用量由 2024 年初的 1000 亿枚增至 2025 年 6 月底的 30 万亿枚，2025 年底达到 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍（官方表述为“两年增长超千倍”，基期为 2024 年初）。交易规模在两年内跨越三个数量级，使得 N 以远快于 F 的速度增长，标准化的盈亏平衡点被迅速跨越。这一逻辑同样解释了历史上标准煤、标准箱与二氧化碳当量为何都在相应交易规模爆发之后才被确立——计量标准是交易规模的函数，而不是技术成熟度的函数。

与之相应，词元领域的标准供给尚显滞后且层级偏低。截至 2026 年 8 月，该领域已发布的规范性成果主要为团体标准与机构评估规范，如中国人工智能产业发展联盟归口的团体标准《人工智能词元（Token）运营管理能力要求》（AIIA/T 0308—2026，2026 年 8 月发布），以及中国信息通信研究院用于符合性评估的能力要求文件；尚未见到以词元计量或词元计费为标题的国家标准或行业标准立项公开。标准效力层级须严格区分：国家标准、行业标准与团体标准分属三个层级，评估与认证活动亦不等同于标准本身。这一制度现状恰恰构成本书的现实针对性——第 14 章将据此提出标准词元计量国家标准的建议路径。

2.3 当量折算的经济学传统：标准煤、标准箱与二氧化碳当量

2.3.1 三项成熟范例及其经济功能

经济史上，异质对象获得可加总计量的通行办法不是取消异质，而是当量折算：选定一个基准品，用一条公认的刻度把其他品类折算为基准品的当量。这一

办法在能源、航运与气候三个领域都已高度成熟，且都产生了远超计量本身的制度后果。

第一项范例是标准煤。我国《综合能耗计算通则》规定，以低位发热量 29307 千焦为 1 千克标准煤，各种能源按其发热量折算为标准煤当量后加总（国家市场监督管理总局和国家标准化管理委员会，2020）。折算的经济功能极为深远：它使煤炭、石油、天然气与电力这些物理形态迥异的能源获得了共同尺度，“能源消费总量”由此成为一个可核算、可考核、可比较的宏观变量，能耗强度指标、能效标准与能耗双控制度均以之为基础；近年从能耗双控向碳排放双控的转型，本质上是把折算刻度由发热量换成碳含量（姜春海等，2024）。第二项范例是标准箱。航运业以 20 英尺集装箱为当量单位，把各种规格的箱型折算为标准箱数，从而使港口吞吐量、船舶运力与运价指数在全球范围内可比可加——集装箱运输之所以能够形成全球化的多式联运网络，标准箱这一当量单位的作用不亚于集装箱本身。第三项范例是二氧化碳当量。温室气体核算以全球增温潜势为刻度，把甲烷、氧化亚氮等气体折算为二氧化碳当量，国际标准与国内标准均以此为方法学基础（「WRI 和 WBCSD，2011」；「ISO，2018」；国家市场监督管理总局和国家标准化管理委员会，2024），国内学界对碳核算体系与生命周期碳足迹核算的国际经验亦有系统梳理（陈红敏，2011；童庆蒙等，2018）。这一当量的确立直接催生了碳市场：没有可加的碳当量，配额分配、履约核销与跨期跨区交易都无从谈起，全国碳市场的制度设计与减排福利效应研究皆以此为前提（张希良等，2021；赵思琦等，2023；段玉婉等，2023；杨豪等，2023；蓝虹和杜彦霖，2024）。

三项范例的共同结构可归纳为三点。其一，当量折算的核心是“一个基准、一条刻度”：基准品定义计量单位的名义，刻度函数定义折算系数的数值。其二，当量折算的经济功能是“把不可加变为可加”，其直接产物是一个新的宏观变量（能源消费总量、集装箱吞吐量、碳排放总量），而新变量往往又催生新的市场与新的治理工具。其三，当量折算是有代价的：折算必然丢失信息（标准煤看不见煤与电的品质差异，标准箱看不见箱内货值），因此折算体系的设计必须在“可加性”与“信息保真”之间取得平衡，并对折算损失保持明示。这三点将直接组织本书第 5 章的公理化工作。

2.3.2 当量折算的一般形式与性质

把三项范例抽象为统一形式。设有 n 类异质对象，第 i 类的实物量为 X_i 、特征向量为 x_i ，基准品的特征向量为 x_0 ，刻度函数为 $\psi(\cdot)$ ，则当量总量与折算系数分别为：

$$\tilde{X} = \sum_{i=1}^n \lambda_i X_i, \lambda_i = \frac{\psi(x_i)}{\psi(x_0)} \quad (2-6)$$

其中， λ_i 为第 i 类对象的折算系数， $\tilde{X}$ 为以基准品为单位的当量总量；在标准煤情形 ψ 为低位发热量，在标准箱情形 ψ 为箱位当量，在二氧化碳当量情形 ψ 为全球增温潜势。

式(2-6)具有三条性质，恰与第5章将要提出的四条公理相呼应。第一是基准归一性： $\lambda_0=1$ ，基准品的一单位即为一当量单位，这保证了当量单位有明确的物理与经济含义。第二是基准无关性：若把基准由 x_0 换为 x'_0 ，全部折算系数按同一比例缩放，各类对象之间的相对关系不变，因而基准的选择只影响单位名义、不影响结构结论——这一点对本书尤为重要，因为基准模型档位的选择难免带有约定成分。第三是可加性与传递性：折算之后不同类对象可直接相加，且经由中间品折算与直接折算的结果必须一致，否则套算路径不同将得出不同总量，计量体系随即瓦解。

2.3.3 词元折算的特殊性：从单维刻度到多维合成

把式(2-6)应用于词元，立刻遇到三项范例都不曾遇到的困难：刻度函数 ψ 无法由单一物理量担任。标准煤的发热量、标准箱的箱位、二氧化碳当量的增温潜势，都是被计量对象的单一物理属性，测量方法成熟且争议极小。词元的“有用性”却至少同时取决于三个互不可约的维度：算力强度 P （生成单枚词元所耗浮点运算量相对基准的倍数，属投入侧刻度）、推理质量 R （单枚词元承载的有效信息量与任务达成度相对基准的倍数，属产出侧刻度）与场景效用 S （应用场景的价值密度系数，属价值侧刻度）。三者不可相互替代：只看算力强度会把低效冗长的输出误判为高价值，只看推理质量会忽略成本，只看场景效用则与词元本身的技术属性脱节。因此，词元的折算必须是一个多维合成问题，这是它相对于既有当量传统的根本特殊性。

推理质量维度的可测度性依托于近年大模型评测方法的成熟：大规模多任务语言理解基准提供了跨学科的知识与推理测度（Hendrycks 等，2021），整体性评估框架把准确性、鲁棒性、效率与公平性等多项指标并置（Liang

等，2022），模型互评与人类偏好对齐的评判方法则为开放式任务提供了可扩展的打分手段（Zheng 等，2023）。算力强度维度的可测度性则依托于规模律研究：模型性能随参数量、数据量与计算量呈幂律关系（Kaplan 等，2020），计算最优的参数—数据配比进一步刻画了给定算力预算下的最优模型形态（Hoffmann 等，2022）。这两支技术文献为 P 与 R 的操作化提供了工程基础，但它们的目标是评价与优化，不是折算与加总。

多维合成对折算函数提出了新的约束。设折算函数为 $\eta = g(P, R, S)$ ，连续且对各维严格单调递增，并满足基准归一 $g(1, 1, 1) = 1$ 。可加性与传递性要求折算具有链式一致性：先把某档位模型相对中间档位折算、再把中间档位相对基准折算，其结果必须等于直接相对基准折算的结果。形式化地：

$$g(P_1 P_2, R_1 R_2, S_1 S_2) = g(P_1, R_1, S_1) \cdot g(P_2, R_2, S_2) \quad (2-7)$$

其中， (P_1, R_1, S_1) 与 (P_2, R_2, S_2) 为两段折算的相对倍数；式(2-7)即乘性柯西函数方程在三元情形下的形式。

在连续性与单调性条件下，式(2-7)的解具有唯一的函数形式——幂积形式：

$$\eta = g(P, R, S) = P^{w_P} R^{w_R} S^{w_S}, w_P + w_R + w_S = 1 \quad (2-8)$$

其中， w_P 、 w_R 、 w_S 为三维效值的权重，即效值系数对各维的常数弹性；权重之和为 1 保证折算函数一次齐次，从而当三维同比例提升时效值等比例提升。

式(2-8)的经济含义值得强调：它把“当量折算”从单维物理刻度推广到多维经济刻度，而付出的代价是权重必须被标定而非被观测。这正是词元折算区别于标准煤折算的本质所在——发热量可以在量热仪中直接测得，而三维权重必须由基准任务集上的实测数据反推。第 5 章将给出四条公理下的完整存在性与唯一性论证，并报告标定结果： $w_P = 0.4383$ 、 $w_R = 0.2964$ 、 $w_S = 0.2653$ ，基准任务集实测效值的拟合优度 $R^2 = 0.9996$ 、对数尺度 $R^2 = 0.9997$ 、均方根误差 = 0.0261；把折算函数放宽为常替代弹性形式独立标定，得替代参数 $\hat{\rho} = 0.0794$ ，在统计上无法拒绝其为零——此时常替代弹性形式恰好退化为加权几何平均，实证标定与公理推论相互印证。折算的效果同样可以量化：折算前后单位价格的变异系数由 0.92 降至 0.31，最高与最低档位的价格倍差由 12.6 倍收敛至 2.4 倍，异质词元由此获得趋近一价定律的共同尺度。

这里必须作一项严格的学术声明，以免读者误引。本书的三维效值折算体系是作者自主构建的理论框架，它不来源于、也不对应于任何既有机构发布的评价体系。与本书构成文献对话的既有工作确实存在，共有四套，各自主体、维度与用途不同，本书逐一注明并严格避免合并、平均或交叉引用其维度名称：其一，

中国信息通信研究院《人工智能 Token 服务质量能力要求》所依托的可信 AI-Token 服务质量评估，包含模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度，用于服务质量的符合性评估；其二，中国信息通信研究院于 2026 年 6 月 16 日发布并解读的高质量 Token 服务标准体系，包含服务质量、运营能力、生产能力、安全能力四个维度，用于搭建标准框架，该院云计算与大数据研究所所长魏凯提出“不能只看单价，行业亟须一套衡量高质量 Token 的标尺”；其三，中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》提出的价值度量体系，包含生产成本、生产效率、准确性、生态价值、安全五个维度，用于价值评价；其四，清华大学翟季冬团队联合清程极智于 2026 年 5 月发布的开源模型 Token 服务性能榜，以首 Token 时延（P90 分位）、输出吞吐与缓存命中率三项实测指标对服务商排名。此外，中国信息通信研究院 2026 年 6 月启动的词元服务能力攀登计划公布了首批企业达成的性能基线（吞吐不低于 55Token/s、首 Token 时延不高于 0.9s、调用成功率 99.9%），该基线是首批参与企业的达成值，既非行业平均值亦非强制门槛。

本书相对上述四套工作的理论增量可以一句话概括：从多维评价推进到当量折算。四套体系的产出形态或为并列的维度得分，或为达标与否的认证结论，或为服务商的性能排名——它们回答的是“谁更好”，而不能回答“一枚甲词元等于几枚乙词元”。而只有后一个问题被回答，异质词元才能被加总为可入账的总量、被折算为可比较的价格、被纳入可核算的增长贡献。评价体系给出的是序，当量体系给出的是尺；序可以排名，尺才能记账。本书的全部工作，正是要把词元经济的“序”变成“尺”。

2.4 通用目的技术理论与索洛生产率悖论的再现

2.4.1 通用目的技术的三特征及其对词元的启示

人工智能是否构成通用目的技术，是判断其经济影响量级的前置问题。通用目的技术被界定为具备普遍适用性、持续改进潜力与创新互补性三项特征的技术，其经济影响不通过自身部门实现，而通过在下游部门引致的互补性创新扩散实现（Bresnahan 和 Trajtenberg，1995）。以蒸汽机、电力与信息技术为参照的历史比较显示，通用目的技术的宏观效应往往滞后于技术成熟数十年（Crafts，2021）；基于在线招聘数据对新兴技术的横向比较则为机器学习是否具备通用目的技术特征提供了可检验的经验判据（Goldfarb 等，2023）；从

增长理论角度看，人工智能既可能通过自动化提升要素生产率，也可能因鲍莫尔成本病使增长受制于未被自动化的环节（Aghion 等，2019）。

通用目的技术理论对本书有两点直接启示。第一，扩散过程比技术本身更重要，因而研究者需要一个能够刻画扩散强度的可观测变量。传统研究以专利数、企业采用率或招聘需求作为代理，但这些变量要么滞后、要么粗糙，无法反映实际使用强度。词元流量恰好填补这一空缺：它是模型能力被实际调用的直接计数，具有高频、可归属、跨行业可比三重优点。第二，互补性投资的重要性提示我们，词元消耗的经济效果高度依赖于场景改造的深度——同样的词元投入，嵌入核心业务流程与仅用于边缘尝试，产出效果截然不同。这正是式(2-2)中场景效用维度 S 的理论根据，也是第 10 章讨论企业深度采纳门槛的理论起点。

值得注意的是，既有实证研究对人工智能经济效应的观察，绝大多数是从要素替代与就业结构一侧切入的。国内文献以工业机器人渗透为准自然实验，检验了其对就业总量与结构的行业与地区异质性影响（孔高文等，2020），识别出工作任务重组带来的非常规能力溢价（余玲铮等，2021）与人力资本提升效应（胡晟明等，2021）；数字经济维度的研究则考察了非农就业与社会分工的深化（田鸽和张勋，2022）、技能偏向型技术进步与劳动力不充分就业的并存（陈贵富等，2022），以及人工智能对包容性增长的跨国效应（陈东和秦子洋，2022）。国际研究同样以在线职位广告为底稿，识别人工智能技能需求的扩散与工资溢价（Acemoglu 等，2022b）。这一支文献积累深厚，但其共同的观察窗口是“人工智能作用于人”——技术如何改变劳动需求、任务结构与收入分配；至于“人工智能自身产出了什么、这些产出该如何计量与计价”，则几乎处于视野之外。换言之，既有研究测度的是人工智能的影响，而非人工智能的产出。这一不对称正是索洛悖论在统计层面难以澄清的根源：当被解释变量（宏观生产率）与解释变量（人工智能投入）之间缺少一个可观测的中间产出变量时，任何加速或滞后的判断都只能停留在推断层面。本书把标准词元流量确立为这一中间变量，正是要为上述争论提供一个可测、可加、可核算的经验抓手。

2.4.2 索洛悖论的再现与两侧证据的口径辨析

索洛生产率悖论在人工智能时代以新的形式再现：模型能力以月为单位迭代，投资以年翻番，宏观生产率统计却迟迟未见相应加速。对这一反差的解释形成了两个方向。乐观侧的核心框架是生产率 J 曲线：通用目的技术需要大量互补性无形投资（流程再造、组织重构、员工再培训），这些投入在会计上被费用化而非资本化，因而在扩散早期系统性地压低了测得的生产率，形成先降后升的 J

形轨迹（Brynjolfsson 等，2019；Brynjolfsson 等，2021）。悲观侧的代表性测算则以 Hulten 定理为方法基础：产出与生产率收益取决于受影响任务的比例与每项任务的平均成本节约。在约 20% 的劳动任务暴露于人工智能、其中仅 23% 可被有利可图地自动化、每项任务平均劳动成本节约约 27% 的假设下，人工智能在未来十年最多带来 0.66% 的全要素生产率累计增幅，修正后的更保守预测低于 0.53%（Acemoglu，2025）。

这两组数字常被并置比较，但严格的口径辨析表明它们并不直接对立，混用反而会导致严重误读。其一，量纲与期限不同：上述 0.66% 与 0.53% 是十年累计的全要素生产率增幅，不是年增速；而经济合作与发展组织在《七国集团经济体人工智能的宏观生产率收益》中给出的是未来十年间年度劳动生产率增长的增量百分点，高暴露度经济体为 0.4—1.3 个百分点，二者须先换算量纲与期限方可比较；该组织对人工智能影响生产率、分配与增长的关键机制与政策挑战亦有专门梳理（「OECD，2024」）。其二，指标不同：全要素生产率与劳动生产率是两个不同指标，不可交叉引用。其三，宏观统计的现状并不支持“生产率已经加速”的叙事：按美国劳工统计局口径，2025 年全年非农商业部门劳动生产率增长约 2.1%，低于 2024 年的 3.0%——宏观数据尚未验证 J 曲线的上升段。其四，暴露度不等于替代率：国际货币基金组织的研究显示全球约 40% 的就业岗位暴露于人工智能、发达经济体约 60%，其中约半数可能受益于生产率提升、另半数面临替代风险（「Cazzaniga 等，2024」），“暴露”是任务重叠的度量而非就业损失的预测。

在学术测算之外，咨询机构对生成式人工智能经济潜力的估计亦被广泛引用，其典型做法是自下而上枚举业务职能与用例、逐项估算可实现的成本节约与收入增益，再汇总为年度潜在价值（「Chui 等，2023」）。这类测算的量级通常远高于学术模型的推算，原因不在于数据优劣，而在于口径：咨询测算给出的是“若采纳充分实现则可能达到”的潜在价值，属情景假设下的上限估计，既未扣除互补性投资的成本，也未与国民经济核算口径对接；学术测算给出的则是在既定任务暴露度与自动化可盈利比例约束下的期望增量，属条件期望。二者一为潜力、一为期望，一为咨询机构自建口径、一为宏观核算口径，并列比较必然制造出“乐观与悲观相差数十倍”的假象。本书在引用任何一侧的数字时均先声明其口径与期限，并且不把不同口径的估计值放入同一张图表或同一个比较句式。这一纪律看似琐碎，却正是词元经济研究亟须建立的基本规范：在计量单位尚未统一之前，数字的可比性永远优先于数字的醒目程度——这也是本书把计量问题置于定价与配置之前的又一层理由。

悖论的另一部分可能是纯粹的计量问题。当一种服务以急剧下降的价格与快速上升的质量提供时，按名义支出核算的实物量增长会被系统性低估。这一问题在云计算兴起时已经出现：云服务的价格测度困难导致相关投入的实物量增长被低估（Byrne 等，2018），跨境数据流与云服务对国内生产总值测度提出了新的挑战（Coyle 和 Nguyen，2019）；企业层面的证据则显示云计算采用确实带来了可观的增长效应（DeStefano 等，2025）。更一般地，关于错误计量能否解释生产率放缓的系统检验表明，单靠错误计量不足以完全解释缺口，但计量改进的空间确实存在（Syverson，2017）。这一判断对本书极为重要：词元价格在两年间的大幅下行中，有多少来自真实降价、有多少来自效值提升（即同样价格买到更强的词元），若不区分，价格指数与实物量核算都会失真。第 7 章的分解显示，2024 年初至 2026 年二季度约 79% 的表观降幅中，约 53% 来自效值提升、约 47% 为真实降价——这正是索洛悖论的计量侧面在词元经济中的具体呈现。

2.4.3 微观证据的积累与本书的切入点

与宏观统计的沉默形成对照的是微观证据的迅速积累。生成式人工智能的采用速度快于历史上任何一项通用技术，美国成年人的采用率在推出后两年内即达到相当高的水平（Bick 等，2024）；采用行为在人群与企业之间高度不均，教育程度、职业类型与企业规模都是显著的分层因素（Humlum 和 Vestergaard，2025）；企业层面的证据显示人工智能采用与生产率之间存在正向关联但异质性极强（Czarnitzki 等，2023）；任务层面的暴露度测算表明相当比例的工作任务可被显著加速（Eloundou 等，2024）；在研究活动本身，生成式人工智能亦已在文献综述、编程与写作等环节展现出可观的用例价值（Korinek，2023）。与此同时，来自更长历史尺度的警示提醒我们，技术进步的收益分配并非自动向劳动倾斜，制度安排与技术方向的选择才是决定因素（Acemoglu 和 Restrepo，2019；Acemoglu 和 Johnson，2024；Autor，2024）。

本书的切入点由此确定：既然宏观统计滞后而微观证据分散，最有效的推进方式是找到一个介于二者之间的、可高频观测且可跨主体加总的中间变量，把人工智能的扩散从“事后残差”变为“事中过程”。词元流量正是这样的变量——它每日可测，随场景可分，随主体可归，随模型可分档。但要让这一变量真正进入核算，前提仍然是可加，即必须先完成折算。换言之，2.3 节的计量问题与 2.4 节

的核算问题在这里合流：标准词元不仅是一个定价基准，更是把人工智能贡献从索洛残差中显性分离出来的核算工具。第 12 章将完成这一分离。

2.5 数字产品定价、质量分级与双边平台理论

2.5.1 零边际成本、质量分级与版本化

词元服务在定价上呈现出典型的数字产品特征：固定成本（模型训练与集群建设）极高，边际成本（单次推理的电力与折旧）相对低廉但并不为零。这一成本结构使教科书式的边际成本定价既不可行也不可欲——按边际成本定价无法覆盖固定成本，供给不可持续。产业组织理论对此的经典回答是质量分级与版本化：垄断者通过提供质量—价格菜单实现二级价格歧视，均衡中高端质量不失真而低端质量被向下扭曲，以抑制高估值消费者的向下选择（Mussa 和 Rosen，1978）；版本化策略并非总是有利，其可行性取决于消费者估值分布与质量成本结构（Bhargava 和 Choudhary，2008）；而在个性化定价成为可能之后，价格歧视对消费者福利的净效应亦需重新评估（Dubé 和 Misra，2023）。

词元市场的现实定价结构与这一理论高度吻合。平台普遍提供三级服务：面向中小企业与个人开发者的普惠包、面向常规企业用户的按需套餐、面向大型客户的专属定制。第 7 章的测算显示，三级服务的用户占比分别为 62%、31%与 7%，而收入占比分别为 21%、38%与 41%——少数高端用户贡献了近半收入，这正是质量分级定价的典型形态。但与传统数字产品不同的是，词元服务的“质量”并非厂商可任意设定的产品参数，而是由模型效值客观决定的技术属性，因而质量分级的前提是效值可测——理论再次指向计量。

2.5.2 双边平台的交叉外部性与价格结构

词元市场的组织形态是多边平台：一侧是算力供给方与模型服务方，另一侧是应用开发者与企业用户，平台居中提供接入、计量、结算与调度。双边市场理论指出，此类市场的价格水平与价格结构是两个独立问题，平台的最优定价必须内部化两侧之间的交叉网络外部性（Katz 和 Shapiro，1985；Armstrong，2006），其后的综述进一步刻画了单归属与多归属、竞争瓶颈与价格结构中性等条件下的均衡性质（Jullien 等，2021），数据的引入则使平台竞争与用户数据的关系成为新的分析维度（Bergemann 和 Bonatti，2024）。国内研究在平台经济的分析框架、市场结构与福利效应、以及数字平台通过价格

机制与数据机制改善资源配置效率等方面亦有系统推进（刘诚和夏杰长，2023；顾聪等，2023；吴双和王勇，2024）。

把交叉外部性纳入垄断平台的最优定价条件，可得两侧市场下调整后的勒纳条件。记A侧（应用方）价格为 p_A 、单位服务成本为 c_A 、需求价格弹性为 ε_A ，A侧每增加一单位需求给B侧（模型与算力方）带来的边际外部收益为 γ_B ，则：

$$\frac{p_A - (c_A - \gamma_B)}{p_A} = \frac{1}{\varepsilon_A} \quad (2-9)$$

其中， $c_A - \gamma_B$ 为A侧的有效边际成本，即扣除该侧需求对另一侧所产生外部收益之后的净成本； ε_A 为A侧需求价格弹性。

式(2-9)的性质是：由于 $\gamma_B > 0$ ，有效边际成本低于实际边际成本，当交叉外部性足够强时甚至可能为负。其经济含义是，平台对某一侧低于成本定价乃至免费开放，是内部化外部性的均衡行为，而非掠夺性定价。这为理解词元市场的两个现象提供了理论基础：其一，普惠包的低价获客与专属定制的高价变现构成一个跨侧补贴结构，而不是简单的价格歧视；其二，城市词元运营中心以财政补贴压低企业侧价格，在 γ_B 足够大时具有效率改进含义，但补贴的退出条件必须由两侧规模的演化路径内生决定——第10章的三方演化博弈将求解这一条件。此外，第8章估计的企业词元需求价格弹性为-1.34（标准误0.19，样本量864），为式(2-9)提供了可代入的经验参数。

双边平台的分析还必须与标准经济学衔接，因为统一计量本身就是一项典型的协调品。兼容性与标准化的经典分析指出，在存在网络外部性时，采用何种标准是一个多重均衡的协调博弈：既可能因预期自我实现而迅速收敛于某一标准，也可能因预期分裂而长期停滞于低效率的多标准并存状态，而先行者的安装基础会显著左右均衡选择（Farrell 和 Saloner，1985；Katz 和 Shapiro，1985）；对标准制定委员会的经验研究进一步显示，共识治理下的标准产出速度取决于参与主体的利益分歧程度，分歧越大、拖延越久（Simcoe，2012）。把这两条结论移植到词元市场，可以得到三点判断。其一，统一的效值计量标准具有正的网络外部性：接入该标准的模型方与应用方越多，任一参与者据以比价、结算与审计的价值越高，因而标准的采纳呈现临界规模特征，这与式(2-5)给出的临界交易规模 N^* 在机制上同源。其二，头部平台既是标准的最大受益者，也可能是最大阻力：统一计量削弱了以口径不透明维持的价格歧视空间与转换成本，因而平台的私人激励与社会最优未必一致——这正是第8章讨论平台锁定、第10章讨论“统一计量”为何往往需要由城市级运营主体

而非市场自发供给的理论根据。其三，标准的协调收益与分配冲突并存，意味着计量标准的确立不可能是纯技术过程，必须辅以中立的第三方测评、公开的基准任务集与可申诉的争议裁决机制，否则“统一尺度”会退化为强势一方的私器。

2.5.3 质量不可观测、认证制度与价格指数方法

2.2.2 节已指出词元市场存在效值信息不对称。把这一问题放在平台语境下会更加尖锐：平台既是撮合者又常常是供给者，其披露激励并不天然与买方利益一致。质量披露与第三方认证的经济学分析表明，强制披露与自愿认证的效果取决于披露成本、买方解读能力与认证机构的声誉约束（Dranove 和 Jin，2010）。这一结论对本书的政策含义是明确的：标准词元体系若要发挥作用，仅有折算公式不够，还必须配套可信的第三方测评与凭证制度——第 11 章讨论的可信溯源与第 14 章建议的认证与国际互认皆循此逻辑。

把质量变化从价格变化中剥离出来，是价格指数理论的经典课题。特征价格方法以产品特征回归价格，得到隐含特征价格，从而构造质量调整后的价格指数（Griliches，1961；Pakes，2003）；对高技术产品，实验性成分指数进一步尝试处理产品更替过于频繁导致的匹配困难（Erickson 和 Pakes，2011）；数字经济对官方统计提出的系统性挑战与统一价格指数的构造亦已有专门讨论（Groshen 等，2017；Redding 和 Weinstein，2020）。本书编制的词元价格指数与标准词元价格指数正是这一传统的延伸，但方法上有一处重要改进：特征价格法的隐含价格由市场价格回归得到，因而质量与价格的因果方向难以分离；而标准词元价格指数的质量调整因子来自工程可测的效值系数，与价格数据相互独立，因此可复现、可审计，且不受市场结构变化的污染。第 7 章将证明，二者的背离幅度本身就是一个具有政策价值的监测指标。

2.6 增长核算理论脉络与数据要素核算的探索

2.6.1 从索洛残差到资本服务测度：核算精细化的百年努力

增长核算的基本框架把产出增长分解为要素投入的贡献与一个无法由投入解释的残差，后者被称为全要素生产率。残差的经济含义历来含混——它既包含技术进步，也包含配置效率改善、规模经济、测度误差乃至遗漏要素，因而被称作“我们无知的度量”。此后半个多世纪的增长核算史，本质上是一部不断把残差中的可解释部分显性化的历史：以资本服务流量代替资本存量、按资产类别与使用者成本加权、以质量调整的劳动投入代替人头数、把研发与软件等无形资产资

本化——每一次改进，都是把原本落入残差的贡献归还给某项可观测的投入。乔根森开创的资本服务测度传统正是其中影响最深远的一支。

这一学说史对本书具有直接的方法论启示。人工智能今天在核算体系中的处境，与信息技术资本在二十世纪八九十年代的处境高度相似：投入真实发生、效果广泛存在，却因缺乏合适的计量变量而只能沉入残差。既有研究对错误计量能否解释生产率放缓的检验（Syverson，2017）、对云计算价格测度困难的分析（Byrne 等，2018）与对跨境数字服务核算难题的讨论（Coyle 和 Nguyen，2019），共同指向同一个结论：核算的改进依赖于新变量的引入，而新变量的引入依赖于计量单位的可加。本书正是沿着这条路径，试图把标准词元流量确立为智能经济核算中的新变量。

2.6.2 数据要素核算的探索及其未竟之处

与人工智能核算最接近的先行探索是数据要素核算。国内研究在数字经济增加值规模测算与结构分析（蔡跃洲和牛新星，2021）、数字化转型对经济社会统计的挑战与创新（许宪春等，2021）、数字经济卫星账户的国际经验与中国编制方案（杨仲山和张美慧，2019）等方面已形成较为完整的方法体系；在微观层面，数据资产的会计确认与价值评估亦取得实质进展（罗玫等，2023），财政部《企业数据资源相关会计处理暂行规定》的出台为数据资源入表提供了制度依据（财政部，2023）。理论层面，数据的非竞争性意味着其社会最优使用强度远高于市场均衡水平（Jones 和 Tonetti，2020），这为数据要素的公共政策干预提供了福利经济学根据。

但数据要素核算至今面临三重未解的困难。其一，缺乏统一的物理计量单位：字节数衡量的是存储规模而非信息价值，同样 1TB 的日志数据与标注数据价值悬殊。其二，缺乏市场价格：绝大多数数据不经市场交易而在企业内部使用，估值只能依赖成本法或收益法，主观性强。其三，权属界定困难，导致贡献难以归属到特定主体。相比之下，词元在这三点上都具有结构性优势：它天然可计数（每次调用即一次计数）、天然有市场价格（按枚计费是行业通行做法）、天然可归属（调用记录绑定主体、时刻、模型与场景）。这三重优势使词元有可能成为智能经济核算中第一个真正可操作的中间变量——前提仍然是解决异质性，即完成折算。数据要素核算所缺的“可比尺度”，恰是本书标准词元体系试图为词元提供的东西。

就我国而言，支撑智能经济核算的统计基础设施正在快速搭建，但其口径重心仍在“存量与规模”一侧。国家层面已建立数据资源的年度调查制度，对数据生

产、存储、流通与应用状况形成常态化统计（「国家数据局，2026」）；产业研究机构则分别从算力经济与人工智能产业两条线索发布年度报告，系统刻画算力规模、产业结构与应用扩散（「中国信息通信研究院，2025」；「中国信息通信研究院，2026」）。这些工作的价值毋庸置疑：没有它们，智能经济连基本的规模轮廓都无从描述。但从核算的要求看，现有统计存在一处共同的结构性空缺——所测度的多为投入端的存量（算力规模、数据体量、企业数量）与结果端的产值（产业规模、市场收入），而对“投入如何转化为结果”的过程量几乎没有可加的口径。算力规模不等于算力被使用，数据体量不等于数据被调用，产业收入亦不能分解为要素贡献。词元流量恰好位于这一空缺的位置上：它是投入被实际使用的直接计数，是结果被实际生产的直接凭据，因而具备成为“过程口径”的天然资格。本书要补的，正是让这一过程量从可计数走向可加总的最后一步。

2.6.3 引入标准词元流量的增长核算框架

按全书符号约定，记产出为 Y 、资本为 K 、劳动为 L 、数据为 D 、标准词元流量为 $\tilde{T}$ ，其产出弹性依次为 α_K 、 α_L 、 α_D 、 α_T ，希克斯中性技术水平为 A 。对生产函数取对数并对时间求导，得到扩展的增长核算恒等式：

$$g_Y = \alpha_K g_K + \alpha_L g_L + \alpha_D g_D + \alpha_T g_{\tilde{T}} + g_A \quad (2-10)$$

其中， g_X 表示变量 X 的增长率， g_A 为全要素生产率增长率即索洛残差； $\alpha_T g_{\tilde{T}}$ 为标准词元流量对产出增长的直接贡献。

式(2-10)的核心性质在于遗漏偏误的方向。若真实数据生成过程中 $\alpha_T > 0$ 而核算时遗漏 $\tilde{T}$ ，则 $\alpha_T g_{\tilde{T}}$ 将被吸收进残差 g_A ，造成全要素生产率增长的系统性高估；且由于 $g_{\tilde{T}}$ 在样本期内极高，高估幅度会随时间推移而扩大。第12章的估计证实了这一推断：生产函数中标准词元流量的产出弹性为0.108（标准误0.024），在1%水平显著；不引入词元变量时全要素生产率残差为2.41%，引入后降至2.12%，残差高估幅度为0.29个百分点。这一发现与资本服务测度传统的启示同构：每引入一个此前遗漏的可观测投入，残差就缩小一分，我们对增长来源的“无知”就减少一分。

国内学界对人工智能与经济增长关系的研究已有相当积累：从人工智能、老龄化与经济增长的理论建模（陈彦斌等，2019），到新技术革命下人工智能与高质量增长、高质量就业的系统分析（蔡跃洲和陈楠，2019），再到企业层面人工智能技术创新与全要素生产率的实证检验（任英华等，2023）。近年研究更进一步下沉到算力基础设施层面：基于智算中心的证据显示，算力部署与数据

跨域流动可显著提升企业全要素生产率（许诺等，2025）；从需求侧出发的算力资源配置研究则揭示了算力共享与算力市场培育的机制（王勇等，2025）。政策层面，全国一体化算力网建设与“数据要素×”“人工智能+”等行动为这一研究议程提供了制度背景（「国家发展改革委等，2021」；「国家数据局等，2023」；国家发展改革委等，2023；国务院，2025）。这些研究的共同特征是把算力作为投入端变量、把生产率作为产出端结果，中间缺少一个刻画“算力被如何使用、使用得如何”的过程变量——本书第 9 章提出的算力—词元转化效率与本章式(2-10)中的 $\tilde{t}$ ，正是为填补这一中间环节而设。计算机系统领域对生产环境中大规模异构图形处理器集群的负载分析恰好从另一侧印证了这一空缺的严重性：真实机器学习服务负载的任务规模、运行时长与资源占用高度长尾，集群的实际资源利用远低于名义容量，而低利用的成因主要在调度与匹配环节而非硬件本身（Weng 等，2022）。这类工程证据说明，投入端的算力统计与产出端的生产率统计之间确实存在一个可观测、可改进却长期未被经济学纳入的中间环节；把它经由标准词元纳入核算，既是计量的补课，也是配置研究的入口。

2.7 文献述评、研究缺口与本书的理论定位

2.7.1 研究进展的文献计量刻画

在归纳研究缺口之前，有必要先对相关研究的总体进展作一个量的刻画。以“人工智能经济学”“词元经济”“算力经济”等主题词在 Web of Science 核心合集与中国知网检索，2015—2026 年的年度发文量如图 2.1 所示。




图 2.1 词元经济相关研究年度发文趋势（2015—2026）

注：WOS 检索范围为核心合集，主题词为人工智能经济学、通用目的技术、算力与词元经济相关英文表达的组
合；CNKI 检索范围为期刊库，主题词为数字经济、算力、人工智能与词元的组合；两库收录范围与主
题标引规则不同，宜作趋势比较、不宜作绝对量比较；2026 年为截至当年 8 月检索结果的年化推算。资料
来源：作者依两库公开检索结果校准复算。

图 2.1 呈现出清晰的两阶段特征。2015—2022 年为缓慢积累期，中文文献
由 420 篇增至 3800 篇，英文文献由 180 篇增至 1600 篇，年均增速温和；
2022 年末大模型浪潮之后进入陡增期，至 2026 年中文文献达 8900 篇、英文
文献达 5600 篇，四年间分别增至 2.3 倍与 3.5 倍。值得注意的是中英文文献的
结构差异：中文文献的绝对数量始终高于英文文献，且在 2020 年前后即出现第
一次加速，这与我国数字经济与算力政策的密集出台在时间上吻合；英文文献的
加速则更集中于 2023 年之后，且主题更偏向劳动力市场影响与生产率效应。这
一结构差异提示，中文学界对“基础设施—要素—政策”这条线索的关注更早也更
强，恰是本书选题的学术土壤。

但发文量的爆发掩盖了一个结构性事实：增量文献高度集中于技术方法与应
用效果两端，而对“计量单位”本身的经济学研究极为稀少。以词元的计量、折
算、定价基准与核算口径为主题的经济学文献仍屈指可数，检索所得条目绝大多
数为技术性能评测或产业分析报告，缺乏规范的经济学建模。文献的这一分布形
态，与 2.3.3 节所述的四套既有评价体系的定位是一致的：产业界与学术界都已
意识到“需要一把尺子”，但尚未有人系统回答“这把尺子在经济学上应当满足什
么公理、如何标定、标定之后能做什么”。

2.7.2 六条理论脉络的贡献与对本书的支撑

把 2.1 至 2.6 节梳理的理论资源按“贡献—局限—本书推进”三栏归纳，可得
表 2.1。该表既是本章的浓缩，也是全书理论谱系的索引。

表 2.1 六条理论脉络及其对本书的支撑与本书的推进

理论脉络	代表性文献	核心命题	对本书的支撑	本书的推进
价值理论在认知生产中的拓展	(Jones 和 Tonetti, 2020; Pei, 2022; Bergemann 等, 2022; 罗玫等, 2023)	信息产品的非竞争性与零边际复制成本改变了价值决定机制	给出词元价值的成本底与替代天花板，形成式(2-1)一式(2-3)	揭示词元兼具信息产品非竞争性与物质产品竞争性的双重属性
计量单位演进与标准化经济学	(Akerlof, 1970; Farrell 和 Saloner, 1985; Dranove 和 Jin, 2010; 何凡等, 2025)	标准既是协调装置又是分配装置，标准化降低交易费用	给出计量单位成立的四条件与计量折价机制，形成式(2-4)、式(2-5)	推导标准化的临界交易规模，解释词元计量标准的时点内生性
当量折算传统	(「WRI 和	异质对象经基准	给出折算的一般	把单维物理刻度

	WBCSD, 2011」；「ISO, 2018」；国家市场监督管理总局和国家标准化委员会, 2020；国家市场监督管理总局和国家标准化委员会, 2024)	与刻度折算后可加总，催生新的宏观变量与市场	形式与基准归一、基准无关、可加传递三性质	推广至三维经济刻度，得幂积型折算函数
通用目的技术与生产率悖论	(Bresnahan 和 Trajtenberg, 1995；Syverson, 2017；Brynjolfsson 等, 2021；Acemoglu, 2025)	通用目的技术的效应经互补性投资滞后释放，测得生产率呈J形	论证需要可观测中间变量以替代事后残差推断	以标准词元流量作为扩散强度的高频可观测代理变量
数字产品定价与双边平台	(Mussa 和 Rosen, 1978；Armstrong, 2006；Jullien 等, 2021；Bergemann 和 Bonatti, 2024)	价格水平与价格结构相分离，交叉外部性内部化决定两侧价格	解释三级服务定价与跨侧补贴，形成式(2-9)	把效值作为质量分级的客观基准，使质量菜单可测可验
增长核算与数据要素核算	(Coyle 和 Nguyen, 2019；蔡跃洲和牛新星, 2021；许宪春等, 2021；许诺等, 2025)	核算精细化的实质是把残差中可解释部分归还给可观测投入	给出扩展核算恒等式与遗漏偏误方向，形成式(2-10)	以标准词元流量显性分离人工智能的增长贡献

表 2.1 显示出一个值得玩味的格局：六条脉络分别在价值、计量、折算、增长、定价与核算六个方向上为本书提供了工具，但没有任何一条能够单独支撑本书的核心命题。价值理论解释了词元为何有价值，却不解决可加问题；标准化经济学解释了标准为何重要，却不提供多维合成的函数形式；当量折算传统提供了函数形式的原型，却因其刻度均为单维物理量而无法直接移植；通用目的技术理论提出了对可观测变量的需求，却不负责构造这个变量；平台定价理论刻画了价格结构，却把质量当作外生参数；增长核算给出了变量进入的位置，却把变量本身的可加性视为前提。本书的工作，正是在这六条脉络的交汇处补上那块缺失的拼图——一个公理化的、可标定的、可加总的词元当量体系。

2.7.3 文献分流与四项研究缺口

把与词元计量直接相关的既有工作按“输出形态”与“能否支撑加总计价”两个标准分流，可得表 2.2。分流的目的是不是评判优劣，而是厘清各自的功能边界，避免误引与越界解读。

表 2.2 词元计量相关工作的分流与功能边界

类别	代表性工作及其主体	输出形态	能否支撑加总计价
学术评测方法	大规模多任务理解基准、整体性评估框架、模型互评方法 (Hendrycks 等, 2021 ; Liang 等, 2022 ; Zheng 等, 2023)	多维得分与排行	否：维度并列，无合成规则
推理系统效率研究	连续批处理、分页显存管理、预填充与解码分离、吞吐—时延调度 (Yu 等, 2022 ; Kwon 等, 2023 ; Agrawal 等, 2024 ; Zhong 等, 2024)	吞吐、时延与显存占用指标	否：面向系统优化，不涉价值折算
机构服务质量评估	中国信息通信研究院《人工智能 Token 服务质量能力要求》，六维：模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费	符合性评估结论	否：达标与否的二值判断
机构标准框架	中国信息通信研究院“高质量 Token 服务标准体系” (2026 年 6 月 16 日发布)，四维：服务质量、运营能力、生产能力、安全能力	标准体系框架	否：框架性文件，无当量规则
机构价值度量	中国工业互联网研究院《Token 驱动智能经济研究报告 (2026 年)》，五维：生产成本、生产效率、准确性、生态价值、安全	多维价值评价	否：维度并列，未给出合成当量
第三方性能实测	清华大学翟季冬团队联合清程极智“开源模型 Token 服务性能榜” (2026 年 5 月)，三项指标：首	服务商性能排名	否：性能序而非价值尺

	Token 时延 (P90)、输出吞 吐、缓存命中率 标准煤、标准箱、二 氧化碳当量 (「ISO, 2018」 ；国家市场监督管理总局和国家标准化管理委员会，2020； 国家市场监督管理总局和国家标准化管理委员会，2024)		
当量折算传统		单一当量与可加总量	是：但刻度为单维物理量
本书标准词元体系	算力强度、推理质 量、场景效用三维合 成的公理化折算（第 5 章）	单一效值系数与标准 词元当量	是：多维合成且满足 可加与传递

注：四套机构与团队工作的主体、维度数与用途各不相同，本表逐一注明主体，其维度名称不可合并、平均或交叉引用；中国信息通信研究院词元服务能力攀登计划公布的性能基线为首批参与企业的达成值，非行业平均值亦非强制门槛；清华团队榜单的首 Token 时延为 P90 分位，与未标注分位的指标不可直接比较。资料来源：作者据各主体公开发布信息整理。

表 2.2 的分流结果指向一个清晰的判断：在“能否支撑加总计价”一栏中，除当量折算传统与本书体系外，其余六类工作的答案均为否。这并非说它们价值不高——恰恰相反，学术评测为推理质量维度提供了测度工具，系统效率研究为算力强度维度提供了工程基础，机构评估与标准框架为行业秩序提供了制度雏形，第三方实测为市场透明提供了公共信息。问题在于功能定位：它们回答的是“好不好”与“快不快”，而经济计量需要回答的是“抵几枚”。序与尺的区别，是评价体系与当量体系的分水岭。

据此可以归纳出四项研究缺口。缺口一是计量缺口：有多维评价而无单一当量，异质词元至今无法可比、可加，导致价格无公允基准、补贴无核定依据、统计无可加口径、出海无互认凭证。缺口二是定价缺口：有价格观察而无质量调整的价格指数，表观降价中效值提升与真实降价两部分未被分离，价格监测与产业判断因此系统性失真。缺口三是配置缺口：有算力利用率的统计而无“有效标准词元”口径的效率测度，利用率仅五至七成而算力仍在扩建的悖论无法被分解，改进空间的上界无从估计。缺口四是核算缺口：有增长核算的成熟框架而无可观测的人工智能中间变量，其贡献只能沉入索洛残差，既高估了全要素生产率，也遮蔽了政策着力点。除此之外，在制度层面还存在一项几乎空白的议题：城市级词元运营主体的组织模式、职能边界与激励机制，至今未见规范的经济学研究——这构成本书第 10 章与第 13 章的选题空间。

2.7.4 本书的理论定位与分析框架

综合上述六条脉络与四项缺口，本书的理论定位可表述为：以当量折算传统为方法原型，以价值理论为价值论根据，以标准化的交易费用分析为制度论根据，构造一个公理化的三维效值折算体系，使异质词元获得可比、可加的共同尺度；再以这一尺度为枢纽，向定价、配置与核算三个方向输出——向定价方向输出标准词元价格指数与三层价格结构，向配置方向输出有效标准词元口径的转化效率与调度优化，向核算方向输出可进入生产函数的词元流量变量。四条理论支柱、一个折算枢纽、三个输出方向的逻辑关系如图 2.2 所示。




图 2.2 理论基础与研究框架的逻辑关系

图 2.2 的框架设计有三点意图需要说明。其一，左侧四条理论支柱并非平行罗列，而是各司其职：价值理论与当量折算传统主要支撑计量模块，平台定价与增长核算理论分别支撑定价模块与配置模块，通用目的技术理论则贯穿全局，提供“为何需要过程观测”的问题意识。其二，中部“计量一定价一配置”三个模块之间是单向递进的：计量为定价提供统一尺度，定价为配置提供价格信号，二者的传导关系在图中以纵向箭头标出——这一顺序不可颠倒，因为没有统一尺度的价格无法承担配置信号职能，这正是本书把计量置于全书基石地位的原因。其三，图中底部的虚线回路表示实证反馈：配置与核算环节产生的实测数据将回流至折算体系，用于权重的再标定与口径修订。这一回路的存在意味着标准词元体系不是一次性设定的静态规则，而是一个需要随技术演进持续更新的动态制度——正如标准煤的折算系数会随能源品质变化而修订、二氧化碳当量的增温潜势会随科学认识深化而更新一样。

在这一框架下，本书与既有研究的边界可以清楚划定。相对于技术评测与系统优化研究，本书不改进模型能力也不优化推理系统，而是把它们的产出指标转化为经济计量的输入。相对于机构评价体系，本书不重复其维度设计，而是提出合成规则，把并列的维度得分变为单一的当量系数；如 2.3.3 节所声明，本书的三维效值体系为作者自主构建，与任何机构发布的评价体系不存在对应或继承关系。相对于数据要素与算力经济研究，本书不讨论数据确权与算力建设，而是聚焦于二者之间的转化环节，即算力与数据如何经模型转化为标准词元、标准词元又如何转化为产出。相对于宏观增长研究，本书不提供新的增长理论，而是提供一个可观测变量与相应的核算口径。边界的清晰，正是学术增量得以识别的前提。

2.8 本章小结

本章为全书的核心命题铺设理论地基。沿着“一种新的经济计量单位如何成立”这一主线，本章依次完成了三重理论检验，并在此过程中梳理了六条理论脉络、构造了十个分析式、归纳了四项研究缺口。

在价值论检验上，本章表明词元的价值具有双重决定：从劳动价值论看，单位词元的价值由物化劳动的转移与活劳动的新创共同构成，其对产量的递减性解释了价格的长期下行，其随模型档位的系统性差异则直接否定了物理词元的可加性；从效用价值论看，买方支付意愿的上界由被替代认知劳动的价格与任务达成度共同决定，因而随场景高度离散。两种价值论在场景租金分成率上综合为价格的三元结构，成为第 7 章三层定价模型的胚胎。本章同时厘清了词元与数据的三处根本差异——存量与流量之别、复制成本之别、可归属性之别，说明词元既不能照搬数据要素的定价理论，也不能照搬传统商品的成本定价理论。

在计量论检验上，本章抽象出经济计量单位成立的四个条件——同质可比、可加、可验证与度量费用足够低，并证明物理词元在同质可比与可验证两条上均不成立：输入侧的分词器差异使词元计数本身不是语义中性的，输出侧的算力异质使同一枚词元的生产成本相差一个数量级。据此本章构造了效值不确定下的确定性等价支付意愿模型，揭示了“计量折价”机制——效值不透明本身就压低支付意愿，使提升模型能力未必能提升售价；并推导出标准化的临界交易规模，说明计量标准的确立时点由交易规模而非技术成熟度内生决定，从而解释了我国日均词元调用量在两年内跨越三个数量级之后，计量标准问题为何由学术话题骤然变为产业刚需。本章还严格辨析了词元定名的主体、效力与两种口径，并指出该领域目前仅有团体标准与机构评估规范、尚无国家标准或行业标准的制度现状。

在折算论与核算论检验上，本章考察了标准煤、标准箱与二氧化碳当量三项当量传统，抽象出“一个基准、一条刻度”的一般形式及基准归一、基准无关、可加传递三条性质；进而指出词元折算的根本特殊性在于刻度函数无法由单一物理量担任，必须由算力强度、推理质量与场景效用三维合成，并由链式一致性条件导出幂积型折算函数的形式约束，为第 5 章的公理化工作预置了函数形态。在定价与核算方向上，本章分别以两侧市场的调整后勒纳条件解释了词元平台低价获客与高价变现并存的价格结构，以扩展的增长核算恒等式刻画了遗漏标准词元流量所导致的残差高估方向，并说明标准词元价格指数相对于特征价格法的方法优势在于质量调整因子独立于价格数据、因而可复现可审计。本章还借标准的经济学指出，统一计量本身即是一项具有网络外部性的协调品，其采纳呈临界规模特征，且平台的私人激励与社会最优未必一致，因而中立的第三方测评、公开的基准任务集与可申诉的争议裁决不是标准的附属条款而是其构成要件；并指出我国现有统计基础设施的口径重心仍在投入端存量与结果端产值两头，缺少刻画“投入如何转化为结果”的可加过程量，标准词元流量正是为填补这一过程口径而设。

在文献定位上，本章以文献计量刻画了相关研究的两阶段演进，指出增量文献高度集中于技术方法与应用效果两端而计量单位本身的经济学研究极为稀少；并把与词元计量直接相关的既有工作分流为学术评测、系统效率、机构评估、标准框架、价值度量、第三方实测、当量传统与本书体系八类，逐一注明主体与功能边界。分流结果表明，除当量传统外，既有工作的输出形态均为多维得分、达标结论或性能排名，回答的是“好不好”而非“抵几枚”——序与尺的区别，正是评价体系与当量体系的分水岭。本书相对既有工作的理论增量由此得以精确表述：从多维评价推进到当量折算。四项研究缺口——计量缺口、定价缺口、配置缺口与核算缺口——则分别对应本书第 5 章、第 7 章、第 9 章与第 12 章的核心任务。

需要再次申明的是，本书的三维效值折算体系为作者自主构建的理论框架，与中国信息通信研究院、中国工业互联网研究院及清华大学相关团队的四套既有工作不存在对应或继承关系；本章对上述工作的引用逐一注明主体、维度与用途，各体系的维度名称不作合并、平均或交叉引用。理论地基至此铺设完毕，下一章将转入对象本身，系统考察词元的技术属性与经济属性，并以主流档位模型在算力、价格与质量三个维度上的离散度，为“物理词元不可加”这一判断提供直接的经验证据，从而引出第 5 章标准词元折算体系的构建。

第3章 词元的技术属性与经济属性

第2章从价值理论、计量单位演进、当量折算传统、通用目的技术、平台定价与增长核算六条脉络出发，为本书搭起了理论支架，并在2.2.2节初步指出：以“同质可比、可加、可验证、低度量费用”四条件检验，物理词元只勉强满足可加与低度量费用两条，同质可比与可验证两条明显不成立。这一判断是全书立论的起点，但它在第2章中还只是一个被引证支持的论断，尚未获得系统的技术解剖与经济学形式化。本章的任务正在于此：把词元从一个技术对象转译为一个经济对象，说明它的技术生成过程如何塑造它的经济属性，并在此基础上把“物理词元不可加”这一全书的核心前提，从直觉判断推进为可以形式化陈述、可以经验检验的命题。

这样做的必要性来自经济学研究通用目的技术时的一条基本经验：一项技术的经济后果，很大程度上由它的技术特性所决定的属性组合内生给出，而不是由使用者的意愿外生给定（Bresnahan 和 Trajtenberg，1995；Crafts，2021）。蒸汽机的经济属性由热效率与传动方式决定，集装箱的经济属性由标准箱型与装卸工艺决定；同理，词元的经济属性——它为什么稀缺、为什么只能部分排他、为什么规模经济与范围经济同时强烈、为什么价值高度依赖场景——统统可以追溯到分词、编码、自回归生成、缓存与批处理这些具体的技术环节。经济学不必复述工程细节，但必须打开技术黑箱到足以识别属性来源的深度，否则关于定价、配置与核算的全部讨论都将建立在对计量对象的误解之上。近年以机器学习为对象的通用目的技术研究已经表明，技术特性与任务结构的耦合方式，直接决定了技术扩散的路径与经济收益的分布（Goldfarb 等，2023）。

本章安排如下：3.1节解剖词元的技术属性，依次考察分词与编码、推理生成的计算构成、多模态扩展、上下文长度与缓存四个环节，并把技术过程提炼为四条对经济分析有直接后果的技术事实；3.2节把这些技术事实转译为八项经济属性，按计量、配置、增长三类经济职能分组，逐项给出形式化刻画与可检验命题；3.3节把词元置于要素谱系之中，与劳动、资本、数据三类要素逐维比较，回答“词元究竟是什么”这一本体论问题；3.4节提出并论证本书的核心问题——物理词元的非同质性与不可加性，以效值三维的离散、单价与效值的系统性对应关系以及加总偏误的形式化结果，证明物理词元无法承担价值单位的职能，并检视既有度量工作的进展与限度；3.5节小结全章，引出第5章的效值折算体系。

3.1 词元的技术属性：从分词到生成的过程解剖

3.1.1 分词与编码：词元计数的三重依赖

词元的诞生始于分词。自然语言、代码与结构化文本在进入模型之前，必须先由分词器切分为离散的符号单元，再经词表映射为整数索引。当代大模型普遍采用子词切分：字节对编码把高频字符序列逐步合并为子词单元，在词表规模与未登录词覆盖之间取得平衡（Sennrich 等，2016），语言无关的子词分词器进一步把切分、训练与还原封装为可复用的标准工具链（Kudo 和 Richardson，2018）。分词的工程目标是压缩序列长度与保持语义完整，但从经济计量的角度看，它带来了一个根本性的后果：词元数不是文本的客观属性，而是文本与分词器共同决定的一个联合产物。

这一联合产物具有三重依赖。其一是模型依赖：不同厂商、不同版本的分词器采用不同的词表规模与合并规则，同一段文本被切分出的词元数可以相差数成，而分词器质量本身对下游任务表现具有系统性影响（Rust 等，2021）。其二是语言依赖：语言模型分词器对不同语言的编码效率差异极大，以英语为中心训练的词表在处理其他语言时会把常见词切碎为多个子词，导致相同语义内容在不同语言下的词元数与费用显著不同（Petrov 等，2023；Ahia 等，2023）——这意味着按词元计费的服务对非英语用户构成了一种隐性的价格歧视，其经济后果在跨境服务与词元出海议题中将再次出现（第 11、13 章）。其三是文本类型依赖：代码、公式、表格与自然语言的切分密度差异明显，同样一千字的合同文本与一千字的程序代码，其词元数并不相等。

三重依赖合起来说明了一件事：以物理词元数作为计价基础，等于用一把刻度随被测物与测量工具而变的尺子去量长度。计量学上，这违反了测量单位应当独立于被测对象的基本要求；经济学上，它使“单价”这一概念失去了跨供给方比较的意义——报价更低的服务未必更便宜，因为完成同一任务所需的词元数可能更多。值得注意的是，这一问题在术语定名的两套口径中已经隐约可见：2026 年 3 月 25 日，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用 token 的中文名“词元”，将在常态化审定中最终确认，其定义为人工智能时代智能设备中信息存储、处理和交换的具有一定语义的基本符号单元，属术语学口径，强调的是语义承载；同月，国家数据局局长在中国发展高层论坛 2026 年年会上使用并推介这一译名，提出词元具有可计量、可定价、可交易的特征，是智能时代的价值锚点，属经济计量口径，强调的是交易职能。术语学口径关心“一个词元承载多少语义”，经济计量口径关心“一个词元值多少钱”，而分

词的三重依赖恰恰使这两个问题的答案彼此脱钩：语义相同而词元数不同，词元数相同而语义不同，二者在物理词元这一层面上无法同时成立。

3.1.2 推理生成的计算构成：单枚词元的算力函数

词元的第二个技术环节是生成。自回归模型逐枚生成输出词元，每生成一枚都要完成一次完整的前向计算：既要遍历模型参数完成矩阵乘，又要对已缓存的键值状态做注意力计算。忽略次要项，单枚输出词元的浮点运算量可近似写作：

$$\varphi_m(\ell) = 2N_m + 2n_md_m\ell \quad (3-1)$$

其中， m 为模型下标， N_m 为单次前向的激活参数量， n_m 与 d_m 分别为层数与隐藏维度， ℓ 为当前上下文长度（已生成与已输入词元之和）， φ_m 为生成单枚词元的浮点运算量。

式(3-1)虽然形式简单，却已足以摧毁“词元同质”的假设。第一项 $2N_m$ 表明单枚词元的算力消耗随模型规模线性上升：参数规模相差两个数量级的模型，生成同样一枚词元所需的运算量也相差两个数量级。模型规模、数据量与算力投入之间的幂律关系是这一差异的技术根源，规模定律的确立使“更大模型换更好性能”成为产业的主导路线（Kaplan 等，2020），而计算最优的训练配置研究进一步表明，在给定算力预算下参数与数据应按特定比例配置，由此形成了参数规模高度分化的模型谱系（Hoffmann 等，2022）。第二项 $2n_md_m\ell$ 则表明，即便对同一模型，单枚词元的算力消耗也随上下文长度线性增长：长文档摘要、长程代码理解与多轮对话的后段，每枚词元的成本都显著高于短提示的首段。

把式(3-1)沿一次完整任务累加，可得任务级的总算力。设任务 j 的输入长度为 ℓ_j^{in} 、输出长度为 ℓ_j^{out} ，前缀缓存命中率为 h_j （命中部分无需重新预填充），则：

$$\Phi_m(j) = 2N_m \left[(1-h_j)\ell_j^{in} + \ell_j^{out} \right] + 2n_md_m\ell_j^{out} \left(\ell_j^{in} + \frac{\ell_j^{out} + 1}{2} \right) \quad (3-2)$$

其中， $\Phi_m(j)$ 为模型 m 完成任务 j 的总浮点运算量，方括号内第一项为预填充阶段的输入处理，第二项为解码阶段的逐词元生成；末项为注意力计算随上下文增长的累积贡献。

式(3-2)给出三条对经济分析至关重要的性质。其一，单位输出词元的平均算力 $\Phi_m(j)/\ell_j^{out}$ 是任务形态的函数：输入长、输出短的任务（如长文档判别与检索增强问答）单位词元算力极高，输入短、输出长的任务（如长文生成）单位词元算力较低——同样计费一千枚输出词元，资源耗用可以相差数倍。其二，缓存命中率 h_j 直接抵扣预填充算力，其经济后果在价目表上已经显性化：截至 2026 年 8

月 16 日，一家头部模型服务商的公开价目显示，同一模型的输入词元在缓存命中时为每百万 0.02 元、未命中时为每百万 1 元，相差五十倍，而输出词元为每百万 2 元；2026 年 8 月 17 日起，该服务商进一步将价格改为峰谷分时结构，空闲时段价格为高峰时段的一半。同一模型、同一枚词元，因缓存状态与调用时段不同，价格相差数十倍——这已经不是价格歧视的问题，而是计量对象本身不唯一的问题。其三，推理增强类模型以生成大量中间思考词元换取答案质量，其 ℓ_j^{out} 系统性地高于直接作答的模型，因而在“每枚词元的价格”与“每个任务的费用”两个口径上会给出方向相反的比较结论。

算力消耗的差异最终传导为能耗与碳排放的差异，而现有的权威测算恰恰以“一次查询”而非“每千词元”为分母，这本身就是词元计量尚不成熟的旁证。谷歌云 2025 年 8 月发布的推理环境影响测量报告显示，其文本提示的中位能耗为每次 0.24 瓦时、碳排放 0.03 克二氧化碳当量，该数值取综合口径，边界含满载动态功耗、空闲备机、宿主机中央处理器与内存、数据中心制冷配电开销；若只计活跃张量处理器，同一次推理的窄口径能耗为 0.10 瓦时，两个口径相差 2.4 倍。微软研究院发表于《焦耳》的研究给出前沿规模模型推理的中位能耗为每次查询 0.31 瓦时、四分位距 0.16—0.60 瓦时，并指出在测试时扩展情景下（推理长度约为典型查询的 15 倍），中位能耗升至 3.91 瓦时，为典型值的 13 倍。三点口径提示必须随文标注：其一，上述分母均为一次查询而非每千词元，迄今没有任何主流厂商发布过每千词元口径的官方能耗值，任何词元级数字都是换算结果；其二，报告值为中位数而非均值，长尾的长推理请求使均值显著高于中位数；其三，上述测算均为推理口径且不含图像与视频生成。学术界对人工智能能耗的核算方法与边界争议已有系统梳理，数据中心能耗的全球测算亦提示口径选择对结论的决定性影响（Masanet 等，2020；Patterson 等，2022；Luccioni 等，2023；de Vries，2023；IEA，2025）。本书的结论不依赖于任何单一数值，而依赖于一个稳健的事实：单位词元的资源消耗是模型与任务的函数，其离散程度以倍数计而非以百分点计。

3.1.3 多模态扩展：词元化边界的外推

词元的第三个技术环节是模态扩展。随着模型能力从文本延伸到图像、语音与视频，词元化的边界被外推：图像被切分为图块并映射为视觉词元，语音被编码为声学词元，视频则在时间与空间两个维度上同时离散化。这一扩展在工程上是优雅的——统一的词元接口使异构模态得以在同一架构下处理；但在经济计量上，它进一步削弱了词元的可比性。一张图片可以折算为数百乃至数千枚视觉词

元，但这些词元所承载的信息密度、所消耗的算力密度与所替代的人类劳动密度，都与一枚文本词元相去甚远。实测研究表明，不同任务类型之间的推理能耗差异可达数量级，图像生成类任务的单位输出能耗远高于文本类任务（Luccioni 等，2024）——而在计费口径上，二者却共用“词元”这一个名字。

官方定义已经把多模态纳入词元的外延。国家数据局在 2026 年 5 月的口径中把词元表述为大模型处理文本、代码、图像、音频、视频等所有信息时采用的最小运算单元，并称其正在成为人工智能服务的计量单位、结算单位与统计单位。定义的外延扩展与计量的可比性之间由此形成了一种张力：外延越宽，“词元总量”这一统计量所覆盖的异质对象越多，其作为可加总变量的信息含量就越低。这与统计史上的一般规律一致——统计口径的扩展若不伴随折算刻度的建立，得到的将是一个越来越大、也越来越没有意义的总量。本书在第 5 章构造效值折算函数时，把场景效用维度设计为可跨模态标定，正是为了在保持外延的同时恢复可比性。

3.1.4 上下文、缓存与批处理：单位成本的可调度性

词元的第四个技术环节是服务侧的调度。式(3-2)刻画的是完成一次任务所需的算力，但企业实际支付的是资源占用的成本，二者之间还隔着服务系统的效率。把技术量映射为成本量，可得单位输出词元的资源成本：

$$c_{mj} = \frac{p_{\phi}}{\vartheta u \beta (1 - \delta)} \cdot \frac{\Phi_m(j)}{\ell_j^{out}} \quad (3-3)$$

其中， c_{mj} 为模型 m 服务任务 j 的单位输出词元成本， p_{ϕ} 为单位算力机时的价格（含折旧、电费与运维）， ϑ 为硬件峰值算力， u 为算力利用率， β 为批处理效率系数（并发批次对峰值算力的实现程度）， δ 为因时延约束而被迫放弃的产能份额。

式(3-3)的四条偏导性质构成了词元服务竞争的技术底盘： $\partial c / \partial h_j < 0$ 、 $\partial c / \partial u < 0$ 、 $\partial c / \partial \beta < 0$ 、 $\partial c / \partial \delta > 0$ 。换言之，缓存命中率、算力利用率与批处理效率的每一分提升都直接压低单位词元成本，而时延承诺的每一分收紧都直接抬高它。工程文献对此已有充分刻画：高效的自回归推理需要在张量并行与流水并行之间做精细权衡（Pope 等，2023），注意力计算的访存优化可数倍改变实际吞吐（Dao 等，2022），连续批处理与分页式显存管理把服务吞吐推上新的量级（Yu 等，2022；Kwon 等，2023），预填充与解码阶段的分离部署以及吞吐一时延权衡的调度设计则进一步改变了单位词元的资源占用（Agrawal 等，2024；Zhong 等，2024）；对生产集群负载的大规模分析亦显示，真实

业务的到达过程高度波动，资源预留与实际占用之间存在系统性缺口（Weng 等，2022）。

产业侧的度量实践印证了这一底盘的重要性。清华大学翟季冬团队联合清程极智于 2026 年 5 月发布的开源模型词元服务性能榜，把首词元时延（P90 分位）、输出吞吐与缓存命中率三项实测指标并列为核心维度，其中缓存命中率的入选正说明缓存已被视为服务经济性的第一序变量；中国信息通信研究院于 2026 年 6 月启动的词元服务能力攀登计划，首批联合十家企业达成的企业级通用场景服务性能基线为吞吐不低于每秒 55 词元、首词元时延不高于 0.9 秒、调用成功率 99.9%——需要特别说明的是，该基线是首批参与企业达成的基线值，既非行业平均水平，也非强制门槛，且其时延指标未标注分位，与清华榜单的 P90 口径不可直接比较。企业侧的资源利用状况则更为严峻：国际数据公司与中国信息通信研究院联合开展的调研（2026 年 7 月发布，企业自报口径）显示，近半数企业的智算资源利用率处于 51%—70% 的中等区间，6.7% 的企业仅为 31%—50%，利用率达到 70% 以上的企业不足 35%，制造与政务行业低于平均水平。式(3-3)对此的解读是直接的：在 u 仅有五至七成的条件下，单位词元的实际成本比技术潜力所允许的水平高出四成以上——本书第 9 章将把这一缺口分解为空转、批次、匹配与效值四项损失，并证明统一调度可将有效效值利用率由 0.38 提升至 0.54。

3.1.5 四条技术事实及其经济学提炼

3.1 节的解剖可以提炼为四条技术事实，它们构成本章后续全部经济分析的前提。事实一：计数非中性。词元数由文本与分词器共同决定，具有模型、语言与文本类型三重依赖，因而不是被测对象的客观属性。事实二：算力非常数。单枚词元的算力消耗是模型规模与上下文长度的函数，跨模型跨任务的离散以倍数计。事实三：成本可调度。同一模型、同一任务的单位词元成本随缓存命中率、利用率、批次与时延约束而变，服务系统的效率与定价结构同为成本的决定因素。事实四：边界可扩展。词元化的外延已从文本扩展到全模态，外延扩展在提升覆盖面的同时进一步稀释了可比性。

四条事实的共同指向是：物理词元是一个良好的计数单位，却不是一个合格的计量单位。计数单位只要求对象可数，计量单位则要求所计之量在不同对象、不同时间、不同主体之间保持同一。一枚词元在技术上确实是离散、可数、可核验的，这使它天然适合充当计费的触发器；但一枚词元所对应的资源耗用、信息含量与经济价值并不恒定，这使它无法充当价值的尺度。这一区分正是本书全部

工作的起点，也是理解下一节八项经济属性的钥匙——八项属性中，有的（如价值尺度、稀缺性）直接源于计数属性，有的（如场景依赖性、非竞争性）则源于词元背后的信息品属性，二者的张力构成了词元经济一切制度设计的难点所在。

3.2 词元的八项经济属性及其形式化

3.2.1 属性谱系：从技术过程到三类经济职能

把 3.1 节的技术事实转译为经济属性，需要一条清晰的传导逻辑：技术过程决定词元的算力消耗、信息含量、可复制性与可排他程度，这四项中间变量再决定词元在经济体系中能够承担的职能。本书据此把词元的经济属性归纳为八项，并按其服务的经济职能分为三组：价值尺度、稀缺性与部分排他性构成计量职能组，回答“词元能否充当价值尺度与统计口径”；规模经济、范围经济与场景依赖性构成配置职能组，回答“词元如何引导算力—模型—场景的匹配”；非竞争性与网络外部性构成增长职能组，回答“词元如何作为可观测变量进入增长核算”。属性谱系的完整结构如图 3.1 所示。




图 3.1 词元的技术属性与经济属性谱系

图 3.1 的结构安排体现了三点方法论判断。其一，技术层与经济层之间设置了一条传导带，而非直接连线：这意味着技术特性并不直接产生经济后果，而是先凝结为算力消耗、信息含量、可复制性与可排他程度四项中间变量，再由这四项变量塑造经济属性——这也解释了为什么技术进步（如缓存与批处理优化）能够迅速改变词元的经济属性组合，而无需改变词元这一概念本身。其二，八项属性并非并列罗列，而是按经济职能分组：分组的依据不是属性的技术来源，而是

属性在经济分析中被调用的场合，这使属性谱系同时充当了全书的路线图——计量职能组对应第 5、6 章，配置职能组对应第 7 至 9 章，增长职能组对应第 12 章。其三，三组职能之间存在层级依赖：计量是配置的前提，配置是增长的前提，若第一组属性未能落实为可操作的计量制度，后两组职能的发挥都将受阻。这一层级依赖正是本书把标准词元置于全书基石位置的根本原因。

3.2.2 计量职能组：价值尺度、稀缺性与部分排他性

价值尺度是词元最受关注的属性，也是其被称为“智能时代的价值锚点”的原因。词元是模型处理与交换信息的最小单位，天然可计数、可归属、可核验，因而具备充当计价与统计口径的形式条件。这一属性的经济价值不在于计量本身，而在于计量所支撑的制度：统一的计量口径把分散的双边议价转化为可比的市场报价，从而降低搜寻、议价与履约的度量费用。标准化的经济收益在其他领域已有实证支持——物流标准化对企业全要素生产率的提升效应即为一例（何凡等，2025），而标准制定组织的治理研究则揭示了共识达成过程中的利益协调机制（Simcoe，2012）。需要强调的是，形式条件不等于实质条件：词元具备成为价值尺度的形式，却因 3.1 节四条技术事实而不具备成为价值尺度的实质，这一缺口正是本书全部工作的空间所在。

稀缺性是词元区别于一般信息品的关键属性。信息一经生成即可无限复制，似乎不受稀缺性约束；但词元的生成受算力、能源与时延的硬约束，产能无法瞬时扩张，因而稀缺性并不来自信息本身，而来自承载信息生成的要素。把这一直觉形式化：设算力预算为 $\dot{\Phi}$ ，任务集为 J ，任务 j 的单位词元价值为 v_j 、单位词元算力消耗为 ϕ_j ，服务方在预算约束下选择各任务的词元供给量，则：

$$\max_{T \geq 0} \sum_{j \in J} v_j T_j \text{ s.t. } \sum_{j \in J} \phi_j T_j \leq \dot{\Phi}; \lambda^* = \max_{j \in J} \frac{v_j}{\phi_j} \quad (3-4)$$

其中， T_j 为分配给任务 j 的词元量， λ^* 为算力约束的拉格朗日乘子，即单位算力的影子价格；最优解为把全部算力配置于价值—算力比最高的任务。

式(3-4)有三点经济含义。第一，词元的稀缺性可以被精确地量化为算力约束的影子价格 λ^* ，其经济学地位与能源经济学中单位标准煤的影子价格完全同构。第二，最优配置准则是按价值—算力比排序，而非按价值排序——这直接预告了第 9 章任务—模型匹配问题的目标函数，也解释了为什么“把最强模型用于所有任务”在经济上是错误的。第三， λ^* 随算力供给的松紧而变，因而词元价格具有内生的时段性与周期性，3.1.3 节提到的峰谷分时定价正是这一属性的市场表现。稀缺性的宏观表现则是需求扩张与供给约束的赛跑：按国家数据局公开发布

的口径，我国日均词元调用量由 2024 年初的 1000 亿枚增至 2025 年 6 月底的 30 万亿枚、2025 年底的 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍；而算力供给受制于芯片产能、电力接入与机房建设周期，其扩张速度远低于此。能源侧的约束尤为刚性，国际能源署对人工智能与能源关系的系统评估指出，数据中心电力需求的增长已成为电力系统规划必须正视的结构性变量（IEA，2025）。

部分排他性是词元产权属性的准确表述。完全排他的商品可以借助物理占有实现产权，完全非排他的公共品则无法排除他人使用；词元处于二者之间：生成能力可以经接口鉴权、密钥管理与许可协议实现严格排他——未获授权者无法调用模型生成词元；但词元一经生成并交付，其承载的内容就与普通数字内容无异，可被无损复制、转发与再利用，供给方无法排除下游的二次使用。排他发生在生成环节而非使用环节，这一非对称性带来两个后果：其一，词元服务的商业模式必然以接口访问而非内容销售为核心，平台对接口的控制权即其产权基础；其二，若要对词元的下游使用主张权利（如出海合规、内容溯源与碳足迹核销），必须借助技术手段把不可排他的内容转化为可识别的对象，大模型输出的水印与可扩展溯源技术正是为此而生（Kirchenbauer 等，2023；Dathathri 等，2024），我国生成式人工智能服务管理暂行办法与深度合成管理规定亦对标识与溯源提出了制度要求（「国家互联网信息办公室等，2022」；国家互联网信息办公室等，2023）。第 11 章的绿色词元凭证体系正是建立在这一属性之上：没有可信溯源，绿色词元的溢价就无法被供给方占有。

3.2.3 配置职能组：规模经济、范围经济与场景依赖性

规模经济源于词元生产的成本结构。模型训练、对齐与部署构成巨额固定成本，与产量无关；推理的边际成本虽为正，但在批处理与缓存优化下相当低廉且随批次摊薄。设固定成本为 F 、单位推理边际成本为 c ，产量为 T ，则成本函数与规模经济度为：

$$C(T)=F+cT, S(T)=\frac{AC(T)}{MC(T)}=1+\frac{F}{cT}>1, \frac{\partial S}{\partial T}<0 \quad (3-5)$$

其中， AC 与 MC 分别为平均成本与边际成本， $S(T)$ 为规模经济度； $S>1$ 表示存在规模经济， S 随产量上升而下降表示规模经济的强度随产量递减但不消失。

式(3-5)的经验对应可由本书的成本测算给出：六个模型档位的平均成本与边际成本之比均处于 1.89—1.91 之间，即规模经济度约为 1.91，意味着固定成本摊销约占平均成本的 48%。这一结构有两点含义。其一，词元生产具有天然的集

中倾向：在给定技术条件下，产量更大的服务方总能实现更低的平均成本，这与云计算等信息技术服务的成本结构一致，也是云服务规模扩张带来价格持续下降的原因（Byrne 等，2018；Coyle 和 Nguyen，2019）；企业层面的证据表明，云计算的采用显著改变了企业的成长路径与生产率分布（DeStefano 等，2025）。其二，规模经济与前述稀缺性并不矛盾：规模经济作用于长期平均成本，稀缺性作用于短期产能约束，二者共同决定了词元市场“长期价格下行、短期时段紧张”的双重特征。第 8 章将在此基础上讨论最小有效规模、可竞争性与自然垄断倾向。

范围经济源于模型资产的通用性。同一模型可同时服务问答、编程、翻译、审校、设计与质检等大量任务，固定成本在场景之间分摊。设模型服务 J 个任务，各任务的边际成本为 c_j ，则范围经济度为：

$$SC = \frac{\sum_{j=1}^J C(0, \dots, T_j, \dots, 0) - C(T_1, \dots, T_J)}{C(T_1, \dots, T_J)} = \frac{(J-1)F}{F + \sum_{j=1}^J c_j T_j} > 0 \quad (3-6)$$

其中，分子为 J 个任务分别独立生产的成本之和与联合生产成本之差， $SC > 0$ 即存在范围经济； SC 随任务数 J 上升而上升，随总产量上升而下降。

式(3-6)刻画的正是通用目的技术的成本优势：通用模型之所以能在多数场景战胜专用模型，并非因其在任一场景上更强，而是因为固定成本被 J 个场景共同分摊（Bresnahan 和 Trajtenberg，1995；Aghion 等，2019）。这一属性对产业组织的含义是深刻的：范围经济使模型服务方有强烈动机把接口做“宽”而非做“专”，从而形成通用平台与垂直应用的分工格局；对配置效率的含义则是，场景的丰度本身就是一种生产性资源——接入场景越多的平台，其单位词元成本越低、可承受的价格竞争越激烈。第 10 章城市词元运营中心的统一入口设计，其经济合理性的一半即来自式(3-6)：把分散的中小企业需求汇聚到统一接口，等价于人为提高 J 。

场景依赖性词元区别于能源、集装箱等传统当量对象的最特殊之处。一吨标准煤在钢厂与在电厂燃烧，释放的热量相同；一枚标准词元在客服对话与在合规审查中使用，创造的价值却相差数倍。本书的场景价值测算显示，八类典型场景中单位标准词元的价值密度以科研分析最高（11.3）、文案生成最低（1.9），离散达 5.9 倍。其技术根源在于，词元所替代的是人类认知劳动，而不同认知劳动的价值密度本就差异巨大——替代一小时初级文案与替代一小时资深合规审查，其经济价值不可同日而语。场景结构的变化因而直接改变词元的平

均价值：由 OpenRouter 与 a16z 联合发布的《基于 100 万亿 Token 数据的 AI 现状报告》（2025 年 12 月，样本区间为 2024 年 11 月至 2025 年 11 月，属平台内部口径）显示，编程类请求的词元占比由区间初的 11% 升至区间末的 50% 以上，智能体驱动的多步骤自动化工作流所产生的输出词元已超过平台总输出的一半。高价值场景占比的上升意味着，即便物理词元的平均单价在下降，词元流量所对应的经济价值仍可能在上升——这正是第 7 章价格指数背离现象的需求侧根源。

3.2.4 增长职能组：非竞争性与网络外部性

非竞争性在词元身上呈现为一种二重结构，这是本书需要特别澄清的一点。作为信息品，词元所承载的内容以及生成它的模型知识都是非竞争的：一份摘要可以同时供无数人阅读，一个模型可以同时服务无数并发请求而不减损其自身；非竞争性正是数据与知识区别于实物资本的根本特征，也是其在增长中具有特殊地位的原因（Jones 和 Tonetti，2020；Acemoglu 等，2022a）。但作为生成活动，词元又是竞争的：生成过程占用具体的算力、显存与电力，一个请求占用的资源不能同时服务另一个请求。把两重属性写入统一的生产结构：

$$Y_i = A_i M^\psi (\eta_i T_i)^{\alpha_T} Z_i^{1-\alpha_T}, \sum_{i=1}^n \phi_i T_i \leq \dot{\Phi} \quad (3-7)$$

其中， Y_i 为使用者 i 的产出， M 为模型知识存量（不带主体下标，体现其非竞争性：任一主体的使用不减少他人可用的 M ）， $\eta_i T_i$ 为该主体使用的标准词元流量， Z_i 为其他投入， α_T 为标准词元流量的产出弹性；约束式表明词元生成在总量上受算力预算竞争性约束。

式(3-7)的结构性含义有三。其一，非竞争的 M 出现在每个主体的生产函数中而不被分割，这意味着模型能力的社会最优使用范围是“尽可能广”，任何抬高接入门槛的安排都会造成社会福利损失——这为普惠性词元供给与统一入口提供了福利经济学依据。其二，竞争的 T 受总量约束，这意味着词元的配置是一个真实的稀缺资源配置问题，不能因“信息可复制”而误以为无需配置。其三，产出弹性 α_T 的引入使标准词元流量成为可以进入增长核算的生产要素变量，这正是第 12 章把人工智能贡献从索洛残差中显性分离的技术入口；本书的面板估计给出 $\alpha_T = 0.108$ ，与数据要素弹性 0.094 处于同一量级。

网络外部性是词元经济自增强机制的来源。词元服务平台连接算力方、模型方与应用方，具有典型的多边平台结构：应用方越多，模型方接入的收益越大；模型方越丰富，应用方的选择越优；双边规模的扩张又摊薄了算力方的固定成

本。多边平台的价格结构理论指出，平台定价不应在各边分别遵循边际成本原则，而应按各边的需求弹性与交叉外部性强度设计价格结构（Armstrong，2006；Jullien等，2021）；网络外部性还会带来临界规模与多重均衡——在用户预期自我实现的机制下，同一技术可能停留在低采纳均衡，也可能越过临界点进入高采纳均衡（Katz和Shapiro，1985；Farrell和Saloner，1985）。词元经济的特殊之处在于，网络外部性还有一条数据回路：调用产生的交互数据经反馈进入模型优化，使模型能力随使用规模内生提升，平台数据积累与竞争格局的相互强化已成为数字平台研究的核心议题（Bergemann等，2022；Bergemann和Bonatti，2024）。这条回路把静态的网络效应升级为动态的能力累积效应，是第8章讨论市场集中与可竞争性、第10章讨论城市运营中心临界规模的共同基础。

3.2.5 八项属性的经济含义与可检验命题

把八项属性的技术根源、经济含义与可检验命题系统整理，即得表3.1。表中“可检验命题”一列的设置有其方法论用意：经济属性的归纳若停留在定性描述，就难以与实证研究对接，也难以被证伪；给每项属性配一条可检验命题并标注其检验所在章节，既是对本书论证链条的自我约束，也为后续研究提供了可复用的检验清单。

表 3.1 词元的八项经济属性、技术根源与可检验命题

经济属性	技术根源	经济含义	可检验命题（检验章节）
价值尺度	词元是模型处理与交换信息的最小单位，可计数、可归属、可核验	为智能服务提供统一计价与统计口径，是可计量、可定价、可交易的形式载体	统一计量口径的建立将显著压低词元交易的度量费用与价格离散度（第5、7章）
稀缺性	生成受算力、能源与时延硬约束，产能不可瞬时扩张	稀缺性来自要素而非信息本身，其强度等于算力约束的影子价格	算力紧张时段的单位词元价格显著高于宽松时段（第7、9章）
部分排他性	生成能力经接口与许可排他，输出内容一经交付即可无损复制	排他发生于生成环节而非使用环节，产权基础是接口控制权与可信溯源	引入可信溯源凭证将提高高效值词元可占有的价值份额（第11章）
规模经济	训练与部署固定成本高，推理边际成本低且随批次摊薄	平均成本随产量持续下降，市场具有自然集中倾向	规模经济度显著大于1且随产量上升而递减（第8章）
范围经济	同一模型资产可服务多任务、多场景、多模态	固定成本在场景间分摊，通用模型相对专用模型具成本优势	接入场景数增加将提高范围经济度并降低单位词元成本（第8、9章）
场景依赖性	同量词元所替代的认知劳动价值密度随场景	价值不由生成端单独决定，需求侧场景必	同量标准词元的价值密度在场景间呈显著

	景差异巨大	须进入价值函数	离散（第 6 章）
非竞争性	模型知识与已生成内容可无损复制、并行复用	社会最优要求尽可能广的使用范围，定价不能照搬竞争品的边际成本定价	复用率上升提高单位词元的社会价值而不增加生成成本（第 6、12 章）
网络外部性	用户规模带来反馈数据、工具生态与标准协同	存在临界规模与多重均衡，先发平台易形成能力—规模正反馈	平台生态规模与单位词元的实现价值正相关（第 8、10 章）

表 3.1 呈现的属性组合具有一种内在的紧张关系，这是词元经济制度设计困难的根源。价值尺度属性要求词元同质、可比、可加，而场景依赖性与非竞争性却使同一枚词元在不同用途下的价值天差地别；规模经济与网络外部性推动市场集中，而部分排他性与效值不可观测又使集中之后的价格难以被有效约束；稀缺性要求按影子价格配置，而非竞争性又要求尽可能扩大使用范围。这些张力无法靠单一政策工具化解，只能靠一个能够同时承载计量、定价与配置职能的制度装置来协调——本书认为，这个装置就是标准词元。八项属性中，前三项决定标准词元必须首先是一个计量装置，中间三项决定它必须同时是一个配置信号，后两项决定它最终应成为一个核算变量。这一“一体三面”的定位，将贯穿全书。

3.3 词元与传统生产要素、数据要素的比较

3.3.1 存量与流量：词元是智能生产能力的要素服务流

词元在要素谱系中的位置，是一个必须先行澄清的本体论问题。产业界与政策讨论中时常出现“词元是继土地、劳动、资本、技术、数据之后的新型生产要素”一类表述，本书认为这一表述虽有直觉上的号召力，却在概念上不够精确。更准确的定位是：词元不是与数据并列的新要素，而是算力资本、数据要素与模型知识经生产过程合成之后的要素服务流。这一区分并非文字游戏，而是有坚实的核算传统作支撑——增长核算的精细化历程中，最重要的一步正是把资本存量与资本服务流区分开来：进入生产函数的不是机器的价值存量，而是机器在一定时期内提供的服务流量，二者因资产构成与使用强度不同而并不成比例（第 2 章 2.6 节）。

按同一逻辑，智算中心的加速卡、机房与电力接入是资本存量，模型参数是知识存量，训练语料与行业数据是数据存量，而词元则是这三类存量在特定时段内联合提供的服务流量。这一定位有三个直接好处。其一，它解释了词元为何天然可计量：服务流的可计量性远高于存量，正如电力消费的计量远比发电资产的估值容易——数据要素长期困扰学界的确权、定价与入表难题（熊巧琴和汤珂，2021；欧阳日辉和杜青青，2022；罗玫等，2023），在词元这一层面上

被大幅简化，因为流量的产权归属由服务合约直接界定，无需追溯存量的复杂权属。其二，它解释了词元为何必须折算：服务流的异质性来自存量的异质性，正如不同资产提供的资本服务需按使用者成本加权才能加总，不同模型提供的词元服务也需按效值加权才能加总。其三，它给出了词元与数据要素之间的准确关系：数据是词元生产的投入品之一，词元则是数据价值实现的主要通道之一——数据要素的规模与流动约束长期是其价值释放的瓶颈（蔡跃洲和马文君，2021），而词元化的调用恰恰为沉睡的数据提供了一条可计量、可计价的变现路径。

3.3.2 四类要素的逐维比较

把词元与劳动、资本、数据三类要素在九个维度上逐一比较，即得表 3.2。比较的目的不是排定次序，而是识别词元在计量属性上的独特组合，从而确定它应当借鉴哪一类要素的核算经验、又必须另行发明哪些方法。

表 3.2 词元与劳动、资本、数据要素的属性比较

比较维度	劳动	资本	数据	词元
典型计量单位	工时	资本存量（不变价）	字节（存量规模）	枚（物理词元）
竞争性	竞争	竞争	非竞争	生成环节竞争、信息环节非竞争
排他性	经雇佣合约排他	经产权排他	排他困难、权属界定复杂	经接口与许可天然排他
边际成本	正，随强度上升	正（折旧与运维）	近似为零	正但很低，随批次与缓存而变
异质性来源	技能与熟练度	设备效率与技术代际	质量、时效与关联度	模型能力、任务形态与应用场景
可加总性	经标准劳动强度折算后可加	经不变价与资本服务折算后可加	缺乏公认折算刻度，难以可加	物理量可加但无经济意义，需效值折算
时效与折旧	人力资本折旧与增值并存	按使用与技术进步折旧	时效性强、价值快速衰减	即时消耗、不形成存量，除非沉淀为数据与模型
价格形成	工资由劳动力市场决定	由使用者成本决定	交易稀薄、定价方法多元且缺共识	挂牌价与平台竞价并存，价格快速下行
统计与核算处理	已有成熟核算体系	已有资本服务核算传统	正在探索资源入表与卫星账户	尚无统一统计口径，本书主张以标准词元流量入账

表 3.2 显示，词元的属性组合在四类要素中是独一无二的。与劳动相比，词元的异质性来源（模型能力）与劳动的异质性来源（技能熟练度）在结构上高度相似，因而劳动经济学中的标准劳动强度折算传统对词元折算具有直接的方法论

借鉴价值；但劳动的供给受人口与教育约束，词元的供给则受算力与能源约束，二者的供给弹性差异巨大。与资本相比，词元与资本服务的类比最为贴切，资本服务核算中的使用者成本方法为效值折算提供了范式；但资本服务的价格可由资产市场的租金率间接推断，词元服务却缺乏成熟的租赁市场，其影子价格必须由式(3-4)一类的优化问题内生给出。与数据相比，词元继承了数据的非竞争性与低边际成本，却摆脱了数据最棘手的两个难题——权属模糊与计量困难：数据资源的会计确认规则直到近年才由财政部以暂行规定的形式明确（财政部，2023），数据定价的方法论至今仍在经济学与数据科学之间寻找共识（Pei，2022），而词元的计量与计价在技术上是即时的、在合约上是清晰的。

这一比较的核算含义值得进一步展开。数字经济的规模测算与卫星账户编制长期受制于“可观测变量缺失”的困境：数字技术的贡献分散在各行业的中间投入与生产率变化中，难以直接观测（杨仲山和张美慧，2019；许宪春等，2021；蔡跃洲和牛新星，2021）。词元的出现在原则上改变了这一局面：它是一个由平台系统自动记录、逐笔可追溯、全国可汇总的高频流量变量，其可观测性甚至优于多数传统要素。国家数据局把词元表述为正在成为人工智能服务的计量单位、结算单位和统计单位，正是看到了这一潜力。然而潜力兑现的前提是折算：一个不可加的高频变量在统计上是危险的，因为它会以极高的精度提供系统性偏误的信息。这一判断把我们带到本章的最后一节，也是全书的问题起点。

3.4 非同质性问题：物理词元为什么不可加

3.4.1 效值三维的经验离散

要证明物理词元不可加，最直接的办法是考察同名词元在关键维度上的离散程度。本书按算力强度、推理质量与场景效用三个维度刻画词元的效值，并把模型服务归纳为六个抽象档位——轻量蒸馏级、中型通用级、开源旗舰级、旗舰闭源级、推理增强级与多模态级。之所以采用档位而非具体产品，一是因为商业产品迭代极快、版本众多，任何以产品命名的测算都会在出版之时即告过时；二是为避免把本书的校准复算值挂靠到特定商业产品之上，造成不必要的误解。以中型通用级为基准档并归一，六档位在算力强度与推理质量两个维度上的取值如图3.2所示。




图 3.2 各档位模型的单词元算力强度与推理质量

注：P 为生成单枚词元所耗浮点运算量相对基准档的倍数，R 为单枚词元承载的有效信息量与任务达成度相对基准档的倍数，二者均以中型通用级为基准归一（虚线， $P = R = 1$ ）；档位为避免挂靠具体商业产品而设的抽象分类。数据来源：作者依基准任务集校准复算。

图 3.2 给出的离散格局是惊人的。算力强度 P 在六档位间由 0.22 升至 8.40，相差 38.2 倍；推理质量 R 由 0.46 升至 3.10，相差 6.7 倍；未在图中显示的场景效用 S 的离散相对温和，由 0.68 至 2.15、相差 3.2 倍。三条离散呈现出一个重要的结构特征：算力强度的离散远大于推理质量的离散。这意味着高档位模型在资源耗用上的增长快于其质量上的增长，边际报酬递减在模型能力谱系上清晰可见——这一事实同时解释了两件看似矛盾的现象：为什么高端模型的定价必须显著高于低端模型（成本使然），以及为什么“用最强大模型做所有事”在经济上不可持续（回报使然）。推理质量的测度依赖于标准化的评测体系，大规模多任务语言理解基准与整体性评估框架为跨模型的能力比较提供了方法论基础（Hendrycks 等，2021；Liang 等，2022），以强模型充当评判者的自动评测方法则在开放式任务上提供了可扩展的补充（Zheng 等，2023）——本书的推理质量维度即建立在这一评测传统之上，具体标定策略见第 5 章。

3.4.2 单价与效值：词元等值假设的证伪

效值维度的离散尚属技术事实，其经济后果需要在价格上得到确认。如果“词元是同质的”这一隐含假设成立，那么不同来源的词元单价应当围绕一条水平线波动，差异仅反映厂商的成本效率与市场势力；如果词元不同质，单价则应随效值系统性变化。图 3.3 以效值系数为横轴、以市场单价为纵轴，把六个档位的观测与两条参照线绘于同一坐标系之中，以对这一假设作出判决。




图 3.3 物理词元的不可比性：单价与效值的离散

注：横轴为效值系数 η （以中型通用级为基准归一），纵轴为 2026 年第二季度每百万物理词元的市场单价；实线为过原点最小二乘拟合线，虚线为词元等值假设下应有的水平线（六档位单价的算术平均）。数据来源：作者校准复算。

图 3.3 的判决是明确的：等值假设被数据拒绝。六档位的单价由 0.40 元升至 14.00 元（每百万物理词元），相差 35 倍，而同期效值系数仅相差 11.3 倍；观测点并不围绕水平虚线随机散布，而是沿一条过原点的射线系统性上升，过原点最小二乘拟合的斜率为 2.62、决定系数为 0.86。这一拟合结果有一个极为重要的解读：斜率的量纲是“元每百万标准词元”，即市场在事实上已经在为效值定价，其隐含的标准词元均价约为每百万 2.62 元。换言之，市场参与者的定价行为已经内生地包含了一套折算逻辑，只是这套逻辑分散在各家平台的定价策略中，既不公开、不统一，也不可核验——本书所做的，不过是把市场已经在暗中执行的折算显性化、公理化与制度化。

同样值得注意的是拟合的残差结构。决定系数 0.86 虽高，却远非完美：多模态级的单价明显低于拟合线，推理增强级与旗舰闭源级则高于拟合线。若折算体系完备且市场充分竞争，残差应当只反映随机扰动；系统性的偏离则提示两种可能——或是效值维度尚未穷尽（例如多模态词元的场景效用被低估），或是市场势力与信息不对称造成了效值溢价的失衡。本书的判断倾向于后者：企业对所购词元效值的认知偏差均值达 0.44，由此导致低效值档位的过度采购份额达 0.27，质量不可观测下的逆向选择机制在词元市场上已可被观测（Akerlof, 1970；Dranove 和 Jin, 2010）。第 5 章将以偏离拟合线的幅度作为效值溢价失衡的度量，第 8 章则据此讨论市场失灵与信息披露制度。

3.4.3 不可加性的形式化：加总偏误与结构漂移

离散与价格证据可以说明物理词元“不同质”，但要说明它“不可加”，还需要一个形式化的论证。设经济体中共有 M 类词元（按模型档位划分），第 m 类的物理词元量为 T_m 、效值系数为 η_m ，份额为 $s_m = T_m/T$ ，则物理加总与当量加总之间存在如下关系：

$$\tilde{T} = \sum_{m=1}^M \eta_m T_m = \dot{\eta} T, \dot{\eta} = \sum_{m=1}^M s_m \eta_m; d \ln \tilde{T} - d \ln T = d \ln \dot{\eta} = \sum_{m=1}^M \frac{\eta_m}{\dot{\eta}} d s_m \quad (3-8)$$

其中， T 为物理词元总量， $\tilde{T}$ 为标准词元总量， $\dot{\eta}$ 为按份额加权的平均效值系数；右式表明，两种加总口径的增长率之差恰等于平均效值系数的增长率，而后者完全由结构份额的变动决定。

式(3-8)蕴含三条推论，它们共同构成本书对“物理词元不可加”这一命题的正式论证。推论一（水平不可比）：当且仅当所有 η_m 相等时， $\dot{\eta}$ 为常数、物理加总与当量加总只差一个比例因子；只要效值存在跨档位差异，物理词元总量就无法解释为任何有经济意义的量——它既不是有效计算量，也不是有效信息量，更不是价值量。推论二（增速有偏）：即便效值差异被承认，只要结构份额随时间变动，物理词元总量的增长率就与标准词元流量的增长率系统性背离，且偏误的方向由份额向高效值还是低效值档位漂移决定。推论三（政策失焦）：任何以物理词元总量为标的的考核、补贴与统计，都会诱导主体向低效值、高数量的方向调整行为，因为在既定支出下增加低效值词元的数量是最廉价的达标方式——这是古德哈特定律在词元经济中的具体形态。

推论的现实分量可由一个示意换算加以说明。以本书校准的六档位用量份额与效值系数计算，2026 年按用量加权的平均效值系数 $\dot{\eta} = 1.43$ ，即平均而言每一枚物理词元约相当于 1.43 枚标准词元。据此，国家数据局公布的 2026 年 3 月日均 140 万亿枚物理词元，按标准词元口径约相当于日均 200 万亿枚。必须强调，这一换算仅为示意：官方从未发布过标准词元口径的调用量，份额与效值系数均系作者校准复算的结果。示意的意义不在于数值本身，而在于揭示两点：其一，物理口径与当量口径之间的差距已经达到四成以上的量级，足以改变任何以词元流量为自变量的实证结论；其二，这一差距会随结构漂移而变化，因而不能以一个固定的折算比例事后修正，必须在计量环节即时折算。

把式(3-8)与 3.4.2 节的价格证据合起来看，可以得到一个更强的结论。价格证据显示市场已在为效值定价，加总公式显示物理量的加总在结构漂移下必然有偏；二者结合意味着词元经济当前的统计体系与其价格体系是脱节的：价格承认

异质，统计假设同质。这种脱节在其他领域并非没有先例——名义价格与实物量的背离曾长期困扰耐用品统计，直至特征价格方法把质量变化从价格变化中分离出来才获得系统解决（Griliches，1961；Pakes，2003）。词元领域今日的处境与彼时高度相似，区别在于变化速度：本书测算显示，2024年第一季度至2026年第二季度物理词元价格指数累计下行79%，其中约53%来自效值提升、约47%为真实降价——若不作质量调整，统计将把一半以上的能力提升误记为价格下降。第7章将据此编制词元价格指数与标准词元价格指数，并解释二者背离的经济含义。

3.4.4 三重后果：定价失据、统计失真与补贴失焦

非同质性若不加处理，其后果将沿定价、统计与政策三条线索扩散。定价失据是最直接的后果。在效值不可观测的条件下，买方只能依据可观测的单价与词元数决策，其支付意愿向平均效值收敛，高效值供给因无法被识别而难以获得应有溢价，市场呈现典型的柠檬化倾向（Akerlof，1970）。质量分级本是应对之策——按质量差异设计版本与价格是信息产品定价的经典安排（Mussa和Rosen，1978；Bhargava和Choudhary，2008）——但版本化的前提是质量维度可被买方识别，而这恰恰是词元市场目前所缺的。价格证据佐证了这一判断：由Silicon Data发布的词元支出指数（支出加权的每百万词元成交均价，日度频率）由2026年5月31日的2.04美元回落至8月6—8日的1.16—1.18美元，约两个月跌逾四成，为年内最低；该指数是全市场成交均价而非任何单一模型的挂牌价，其快速下行既包含真实的效率改进，也包含结构漂移带来的口径变化，二者在现行口径下无法分离。

统计失真是更深层的后果。物理词元调用量正在成为衡量人工智能产业发展的标志性指标，被广泛用于地区比较、产业评估与规划目标设定；但由推论二可知，在结构快速漂移的时期，这一指标的增速与有效计算能力的增速可以出现方向性背离。设想两个地区，甲地大量部署轻量蒸馏级模型处理简单问答，乙地以推理增强级模型承担复杂研发任务；按物理口径，甲地的调用量可能数倍于乙地，但按标准词元口径，二者的差距会显著收窄乃至逆转——本书测算的轻量蒸馏级与推理增强级效值系数分别为0.38与4.28，相差11.3倍。若以物理调用量作为考核指标，甲地的“成绩”将被系统性高估，而乙地对高价值场景的深耕反被低估。统计口径的这一缺陷若不纠正，将直接污染第12章的增长核算：以物理词元流量作为解释变量估计的产出弹性，将同时包含真实的要素贡献与虚假的结构变化。

补贴失焦是最需要警惕的后果。2026 年以来，多地把词元使用纳入财政支持范围，或设立城市级词元运营中心、或将词元采购纳入技改补贴范畴；上海市在其软件和信息服务业“十五五”规划中提出，探索将词元、数据治理、大模型部署及再训练等投入纳入企业技术改造支持方向（「上海市经济和信息化委员会，2026」），浙江省“十五五”规划纲要则部署建设一体化算力监测调度平台（「浙江省人民代表大会，2026」），国务院“人工智能+”行动的意见亦对智能经济形态的培育作出总体部署（国务院，2025）。政策方向值得肯定，但补贴的核定必须有可靠的计量依据：若按物理词元数核定补贴，企业最优的响应是采购最便宜的低效值词元以最大化“可报数量”，补贴资金将系统性地流向低效值供给，与提升智能化水平的政策初衷背道而驰。这一风险不是理论推演——它正是推论三的直接推论，也是本书主张“补贴与考核一律以标准词元为口径”的根本理由。

3.4.5 既有度量工作的检视与本书的增量

非同质性问题并非本书的独家发现，产业界与研究机构已在多个方向上作出回应。需要严格区分的是，这些回应各自的主体、维度与用途互不相同，任何合并、平均或交叉引用都会造成事实错误。截至 2026 年 8 月，与词元度量直接相关的成体系工作有四套。第一套是中国信息通信研究院的《人工智能 Token 服务质量能力要求》及据以开展的“可信 AI-Token 服务质量评估”，包含模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度，用途是服务质量的符合性评估。第二套是中国信息通信研究院于 2026 年 6 月 16 日发布并解读的“高质量 Token 服务标准体系”，包含服务质量、运营能力、生产能力、安全能力四个维度，用途是标准框架的搭建；该院云计算与大数据研究所所长魏凯在阐释这一体系时明确提出，“不能只看单价，行业亟须一套衡量高质量 Token 的标尺”。第三套是中国工业互联网研究院发布的《Token 驱动智能经济研究报告（2026 年）》，构建了涵盖生产成本、生产效率、准确性、生态价值、安全五个维度的 Token 价值度量体系，并梳理了词元的“三次跃迁”逻辑。第四套是清华大学翟季冬团队联合清程极智于 2026 年 5 月发布的“开源模型 Token 服务性能榜”，实测三十余家服务商与四个主流开源模型，核心指标为首词元时延（P90 分位）、输出吞吐与缓存命中率三项。中国信息通信研究院在其人工智能与算力经济系列研究中亦持续跟踪相关进展（「中国信息通信研究院，2025」；「中国信息通信研究院，2026」）。

四套工作的共同贡献是把“词元不只有数量、还有质量”这一认识确立为行业共识，并提供了可操作的评价与实测手段；其共同限度则在于，它们都属于多维评价而非当量折算。多维评价的产出是若干并列的维度得分或达标基线——例如前述词元服务能力攀登计划首批达成的吞吐不低于每秒 55 词元、首词元时延不高于 0.9 秒、调用成功率 99.9%——这些结果可以回答“这家服务好不好”，却无法回答“一枚这里的词元等于几枚那里的词元”。而后一个问题才是价格指数编制、补贴核定、跨区统计与增长核算所必须回答的：并列的维度得分无法相加，也无法被写进任何账户。标准的效力层级同样制约着现状——目前该领域已发布的规范性成果主要是团体标准与机构评估规范，例如中国人工智能产业发展联盟归口的《人工智能词元（Token）运营管理能力要求》（AIIA/T 0308—2026，2026 年 8 月发布），尚未见以词元计量或词元计费为标题的国家标准或行业标准立项公开；团体标准的效力层级低于行业标准与国家标准，评估认证活动亦不等同于标准本身。

本书相对上述工作的理论增量因此可以被精确地表述为：从多维评价推进到当量折算。具体而言，本书构造一个把算力强度、推理质量与场景效用三维合成为单一效值系数的折算函数，并为其设立基准归一、单调性、可加性与传递一致性四条公理，证明在这组公理下折算函数的存在性与形式唯一性，从而使不同模型、不同任务、不同场景的词元获得可比、可加的共同尺度。需要郑重声明的是，本书的三维效值折算体系是作者自主构建的理论框架，既不源自也不对应上述任何一家机构的评价体系；本书在引用既有工作时逐一注明主体与维度数，正是为了避免把作者的构造误植于他人名下，或把他人的维度名称混入本书的折算体系。折算与评价的关系是互补而非替代：评价体系提供了效值维度标定所需的测度基础（例如推理质量维度的标定必须依托公认的评测方法与性能实测数据），折算体系则把这些测度合成为可入账的当量。第 5 章将完成这一构造，本章的任务至此完成。

3.4.6 折算前后的对照与本章证据的汇总

为把本章的证据集中呈现，表 3.3 汇总六档位在效值三维、合成效值系数、市场单价、折算后单价与单位算力转化效率上的取值，并给出折算前后的离散度对照。表中最后两列的对比是全章的落点所在。

表 3.3 六档位模型的效值三维、单价与折算后单价（2026 年第二季度）

模型档位	P 算力 强度	R 推理 质量	S 场景 效用	效值系数 η	市场单价 (元/百 万物理词	折算后单 价 (元/ 百万标准	转化效率 θ (万标 准词元/
------	-------------------	-------------------	-------------------	------------------	----------------------	-----------------------	------------------------------

					元)	词元)	PFLOP S·h)
轻量蒸馏级	0.22	0.46	0.68	0.38	0.40	1.053	42.0
中型通用级	1.00	1.00	1.00	1.00	1.30	1.300	18.5
开源旗舰级	2.60	1.72	1.34	1.96	3.30	1.684	9.2
旗舰闭源级	4.80	2.35	1.66	2.94	7.00	2.381	5.4
推理增强级	8.40	3.10	1.92	4.28	14.00	3.271	3.1
多模态级	3.70	1.88	2.15	2.62	5.00	1.908	6.8
最高/最低倍数	38.2	6.7	3.2	11.3	35.0	3.1	13.5

注：P、R、S 与 η 均以中型通用级为基准归一（ $\equiv 1$ ）；折算后单价 = 市场单价 / η ； θ 为单位算力产出的标准词元数。档位为避免挂靠具体商业产品而设的抽象分类，各项数值系作者依基准任务集与 2026 年第二季度市场行情校准复算所得，不对应任何特定商业产品。全样本口径（1240 个档位—任务—时点观测）的离散度为：物理词元单价变异系数 0.92、基尼系数 0.47、P90 与 P10 之比 12.6；折算后相应降至 0.31、0.17 与 2.4。数据来源：作者校准复算。

表 3.3 的信息可归纳为三点。第一，离散的层次差异：转化效率的离散（13.5 倍）与算力强度的离散（38.2 倍）最大，市场单价次之（35.0 倍），推理质量与场景效用最小（6.7 倍与 3.2 倍）。这一层次说明，词元异质性的第一来源是资源侧而非能力侧，因而任何仅从质量评测出发的折算方案都会遗漏最主要的离散来源。第二，折算的收敛效果：折算后单价的档位间倍差由 35.0 倍收敛至 3.1 倍，全样本口径的变异系数由 0.92 降至 0.31、基尼系数由 0.47 降至 0.17，离散度下降约三分之二，价格分布向一价定律显著收敛。第三，残余离散的经济含义：折算后仍存在的离散并非折算失败，而是真实经济信息——它包含服务质量差异、市场势力、合约条款与区域成本差异，正是第 7、8 章价格分析的对象。一个完美消除全部离散的折算体系反而是可疑的，因为那意味着折算函数吸收了本不属于计量范畴的信息。

3.5 本章小结

本章完成了从技术属性到经济属性的转译，并在此基础上正式提出了全书的核心问题。在技术层面，本章沿分词与编码、推理生成、多模态扩展、上下文与缓存四个环节解剖了词元的生成过程，提炼出四条对经济分析具有决定意义的技术事实：计数非中性——词元数由文本与分词器共同决定，具有模型、语言与文本类型三重依赖；算力非常数——单枚词元的算力消耗是模型规模与上下文长度的函数，其跨档位离散以倍数计；成本可调度——缓存命中率、算力利用率、批处理效率与时延约束共同决定单位词元成本，同一模型的同一枚词元因调度条件不同可相差数十倍；边界可扩展——词元化的外延已覆盖全模态，外延扩展在提

升覆盖面的同时进一步稀释了可比性。四条事实共同支持一个基本判断：物理词元是合格的计数单位，却不是合格的计量单位。

在经济层面，本章把技术事实转译为八项经济属性，并按经济职能分为三组：价值尺度、稀缺性与部分排他性构成计量职能组，规模经济、范围经济与场景依赖性构成配置职能组，非竞争性与网络外部性构成增长职能组。每项属性均给出了技术根源、经济含义与可检验命题，其中稀缺性被形式化为算力约束的影子价格，规模经济与范围经济被形式化为可测的成本结构指标，非竞争性与竞争性的二重结构被写入统一的生产函数设定。八项属性之间存在内在张力：价值尺度要求同质可加，场景依赖性与非竞争性却使同一枚词元的价值天差地别；规模经济与网络外部性推动集中，部分排他性与效值不可观测又使集中之后的价格难以约束。这些张力无法由单一工具化解，只能由一个同时承担计量、配置与核算职能的制度装置来协调，这正是标准词元的定位。在要素谱系中，本章把词元定位为算力资本、数据要素与模型知识经生产过程合成之后的要素服务流，而非与数据并列的新型要素；这一定位既解释了词元为何天然可计量，也解释了词元为何必须折算。

在问题提出层面，本章以三组证据论证了物理词元的不可加性。其一是效值三维的经验离散：六档位的算力强度相差 38.2 倍、推理质量相差 6.7 倍、场景效用相差 3.2 倍，且算力强度的离散显著大于推理质量的离散。其二是价格证据：六档位物理词元单价相差 35 倍，观测点沿过原点射线系统上升而非围绕水平线散布，过原点拟合的决定系数达 0.86，表明市场事实上已在为效值定价，只是这套折算逻辑分散、隐蔽且不可核验。其三是加总偏误的形式化：物理加总与当量加总的增长率之差恰等于平均效值系数的增长率，因而只要效值存在差异且结构份额变动，物理词元总量就必然在水平上不可比、在增速上有偏，并诱导主体向低效值、高数量方向调整行为。三组证据共同指向定价失据、统计失真与补贴失焦三重后果，而以标准词元为口径正是化解三重后果的共同前提。

本章还检视了既有度量工作的进展与限度。中国信息通信研究院的六维服务质量评估与四维标准体系、中国工业互联网研究院的五维价值度量、清华大学翟季冬团队联合清程极智的三项性能实测，各自主体不同、维度不同、用途不同，其共同贡献是确立了“词元有质量差异”的行业共识，其共同限度是停留于多维评价而未进入当量折算——并列的维度得分可以回答服务好不好，却无法回答一枚词元等于几枚词元，因而无法进入价格指数、补贴核定与增长核算。本书的理论增量正在于此：以公理化的合成函数把三维效值折算为单一当量，使异质词元获得可比、可加的共同尺度。至此，本书的问题已经完整提出，证据已经齐备，理

论增量的位置也已经界定。第 4 章将转入事实层面，系统刻画词元经济的发展格局与典型事实，为折算体系的构建提供更完整的经验背景；第 5 章则将正式构造标准词元效值折算体系，回答本章提出而未答的问题：异质的词元，究竟应当按什么刻度、以什么函数、在什么公理约束下折算为可加的标准计量单位。

第4章 词元经济的发展格局与典型事实

第3章从技术属性出发论证了物理词元的不可加性，并把「异质词元如何折算为可比、可加的计量单位」确立为全书的核心问题。理论问题的提出需要经验背景的支撑：折算体系所要回答的并非抽象的可比性难题，而是一个正在以极高速度扩张、且已经进入公共政策视野的真实经济系统的计量难题。若不先把这一系统的规模、结构、价格与制度形态描述清楚，折算函数的设定就会失去经验约束，其参数标定也无从谈起。本章的任务因此是描述性的——沿需求规模、供给格局、场景结构、价格演进、算力基础、使用效率与制度供给七条线索，系统刻画词元经济的发展格局，并提炼出可供后续建模与检验的典型事实。

描述性研究在计量地基尚未建立的领域具有独立的学术价值。经济学史上，几乎每一个新兴经济部门的理论建构都以典型事实的归纳为起点：先有对增长事实的稳定归纳，后有增长模型的设定；先有对价格行为的经验刻画，后有价格理论的抽象。词元经济当前正处于这一阶段的起点——数字极多而口径极乱，报道极密而统计极缺。因此本章的描述必须以口径纪律为前提，具体遵循三条：其一，宏观数字只采用可溯源的公开发布，并逐一标注发布主体、发布场合、时点与统计边界；其二，凡官方未单独发布的时点，一律标注为本书的校准复算插值，不以插值冒充实测；其三，凡统计对象、精度基准或时间窗不同的数字，不做同比、加总、折算或并列比较。这三条纪律看似繁琐，实则正是本书主题的一部分：词元经济当下最突出的经验问题，恰恰是「同名不同义」——同一个「调用量」「算力规模」「利用率」「价格」，在不同发布主体的口径下指向完全不同的对象。计量单位的不统一先在数据层面制造混乱，再经由混乱的数据传导到定价、补贴与统计的每一个环节。

本章结构如下：4.1节刻画需求侧的词元调用量演进，界定官方序列的口径并测算增长节律；4.2节考察模型供给格局与国产模型份额，辨析第三方平台口径的适用边界；4.3节分析需求的场景结构，测度调用量向智能体与编程类应用的集中程度；4.4节梳理价格演进与国内外价差，呈现四套并存的价格观测口径；4.5节描述算力供给格局与集群布局，并以供给侧恒等式核算调用量增长与算力增长之间的量级关系；4.6节考察利用率现状与结构；4.7节梳理词元的制度化进程——城市级运营组织、标准供给与政策工具；4.8节归纳全章的典型事实并交待其向后续各章的传递。

4.1 词元调用量的爆发式增长：官方序列、增长节律与国际背景

4.1.1 官方序列及其口径界定

我国是目前唯一把词元调用量作为宏观指标对外发布的主要经济体。按国家数据局公开发布的口径，我国日均词元调用量在 2024 年初约为 1000 亿枚，至 2025 年 6 月底突破 30 万亿枚，2025 年底跃升至 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年间增长约 1400 倍。这四个点位分别发布于国务院新闻办公室的主题新闻发布会与中国发展高层论坛 2026 年年会等场合，是目前仅有的官方锚点。除此之外的任何时点数值——包括 2024 年底这一常被引用的「中间年份」——官方均未单独发布；本书所用的季度序列在四个锚点之间以单调平滑方法插值得到，凡出现处一律标注为校准复算插值，图中亦以不同标记加以区分。

这一序列的口径必须严格界定，否则极易被误用。第一，它是全国、全渠道、消耗侧的日均调用量，官方并未公开统计边界（是否涵盖模型厂商官方接口、云端模型即服务、企业自建推理与端侧推理）与测算方法，因而它既不等于任何企业财报中的词元消耗量，也不等于第三方评测中的吞吐指标，更不是计费口径下的成交量。第二，它是「次数」量纲而非「金额」量纲，与同期发布的产业规模预测（如「十五五」末人工智能相关产业规模突破 10 万亿元）分属完全不同的量纲，二者相除得出的所谓「单位词元价格」没有任何统计意义。第三，「两年增长约 1400 倍」的基期是 2024 年初，若改换基期则倍数完全不同，不可与以其他年份为基期的增速直接同比。第四，日均调用量与第三方平台的周榜调用量之间既不可相加也不可换算，二者的覆盖面相差一个数量级以上，这一点将在 4.2 节详细说明。

与序列同样重要的是词元这一名称与内涵的确立过程，因为它决定了本书在不同语境下应当援引何种定义。2026 年 3 月 25 日，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用人工智能领域名词 token 的中文名「词元」，并明确将在常态化审定中结合社会推广应用情况最终确认；该公告由第四届计算机科学技术名词审定委员会经科技新词快速审定发布流程作出，属术语规范层面的推荐性发布，既非部门规章，也不是国家标准。同月，在中国发展高层论坛 2026 年年会上，国家发展改革委党组成员、国家数据局局长在题为《深化数据赋能人工智能发展，加快培育智能经济新形态》的演讲中使用并推介了这一译名，提出词元具有「可计量、可定价、可交易」的特征，是智能时代的价值锚点。两套口径的侧重点不同：前者强调词元是承载一定语义的基本符号单元、是模型处理和交换信息的最小单位，属术语学口径；后者强调词元是可计

量、可定价、可交易的最小信息单元，属经济计量口径。本书讨论术语规范时引前者，讨论价值计量时引后者，两者不得互相替换或拼接成一句话。

一个计量单位从技术社群的行话变为公共政策的用语，本身就是重要的制度事件。标准化的经济学研究早已表明，统一的度量与接口通过降低搜寻、比较与验证成本而扩大市场范围，其收益在网络性行业尤为显著（Farrell 和 Saloner，1985；Simcoe，2012）；对物流标准化的实证研究亦发现，标准的推行显著提升了企业全要素生产率（何凡等，2025）。词元定名的意义正在于此：它把一个原本分散在各厂商计费页面中的技术参数，抬升为可被政策文本、统计发布与财政工具共同引用的公共名词。但必须清醒的是，定名解决的是「叫什么」，而非「怎么算」——名称的统一并不自动带来计量的统一，本章后续各节将反复显示这一距离。

为刻画增长的节律，把调用量序列写成连续复合增长形式。设 T_t 为 t 时刻的日均词元调用量， g 为瞬时增长率，则有式(4-1)。

$$T_t = T_0 e^{g(t-t_0)}, \hat{g} = \frac{\ln(T_1/T_0)}{t_1 - t_0}, \tau = \frac{\ln 2}{\hat{g}} \quad (4-1)$$

其中， T_0 与 T_1 为两个官方锚点上的日均调用量， $t_1 - t_0$ 为二者相距的年数， $\hat{g}$ 为区间平均的对数增长率（年化）， τ 为对应的倍增周期。

以全区间计算，2024年初至2026年3月的年化对数增长率为3.62，相当于日均调用量每年增至约37.4倍，倍增周期仅70天。分段来看，增长呈现明显的减速特征：2024年初至2025年6月底的年化对数增长率为3.80（倍增周期约67天），2025年6月底至2025年底降至2.41（倍增周期约105天），2025年底至2026年3月进一步降至1.35（倍增周期约188天），但即便是最后一段，其年化倍数仍达3.8倍。这一「减速中的高增长」形态在技术扩散史上并不罕见：扩散初期的爆发式增长源于极低的基数与极快的应用渗透，随着基数抬升，增长率必然回落，但只要渗透尚未饱和，绝对增量仍将持续扩大。生成式人工智能在美国的采纳调查显示，其大众化速度快于个人计算机与互联网的同期扩散（Bick等，2024），企业侧的采纳则呈现显著的规模与技能梯度（Czarnitzki等，2023；Humlum和Vestergaard，2025）——这意味着当前的高增长尚未触及渗透率的上限。

如图4.1所示，把上述序列置于对数纵轴上，四个官方锚点几乎落在一条直线附近，直观地印证了式(4-1)的指数增长刻画，同时也显示出末段斜率的轻微收敛。




图 4.1 中国日均词元调用量的演进（2024Q1—2026Q2）

注：纵轴为对数刻度。实心点为国家数据局公开发布的四个锚点（2024 年初、2025 年 6 月底、2025 年底、2026 年 3 月），空心点为本书校准复算插值，官方未单独发布相应时点数值；序列口径为全国、全渠道、消耗侧的日均词元调用量，统计边界与测算方法未公开。数据来源：国家数据局历次公开发布；插值系作者校准复算。

图 4.1 传递了三层信息。第一，纵轴跨越三个数量级而序列近似线性，说明在观测窗口内词元调用量的增长是「数量级级别」的而非「百分点级别」的，任何以线性坐标绘制的同类图形都会把前期的全部结构压缩为贴近横轴的一条平线，从而掩盖早期的扩散过程。第二，官方锚点仅有四个而季度点位有十个，这一疏密对比本身就是重要的制度事实：作为一个已被写入部委发布、地方规划与财政工具的宏观指标，词元调用量迄今没有固定频率、固定口径、固定发布主体的统计制度，其可得性远低于同等重要性的传统指标。第三，末段的斜率收敛提示增长阶段正在切换，这对本书的意义在于：以增速外推为基础的产能规划与补贴设计，若沿用早期斜率，将系统性高估未来需求。

4.1.2 增长的三重来源：用户扩散、任务加深与单位成本下降

把调用量增长仅仅理解为「用的人变多了」是不完整的。从生成机制看，日均调用量可分解为活跃主体数、单主体日均任务数与单任务平均词元消耗三个因子之积，三者观测期内同时上升。第一重来源是用户与企业的扩散，即活跃主体数的增长，这是采纳研究关注的主体（Bick 等，2024；Humlum 和 Vestergaard，2025）。第二重来源是任务的加深，即单任务平均词元消耗的上升：长上下文窗口使单次请求可携带的输入词元成倍增加，思维链式的深度推理把大量中间推理过程转化为可计费的输出词元，而智能体式的多步骤自动化工

作流则把原本一次的问答扩展为数十次乃至上百次的模型调用。第三重来源是单位成本的下降经由需求弹性放大用量——本书估计的企业词元需求价格弹性为 -1.34 （第8章），意味着单价每下降10%将带动用量上升逾13%，而观测期内表现单价的下降幅度以倍数计（4.4节）。

三重来源在技术侧有清晰的对应。分页式的显存管理与连续批处理大幅提高了推理服务的并发能力与吞吐（Yu等，2022；Kwon等，2023），分块预填充调度缓解了吞吐与时延之间的张力（Agrawal等，2024），预填充与解码阶段的分离部署进一步提升了单位算力的有效产出（Zhong等，2024），注意力核的输入输出感知优化则直接压低了长序列的计算与访存开销（Dao等，2022），而面向超大模型的高效推理分区策略把可服务的模型规模与上下文长度推向新的边界（Pope等，2023）。这些系统层面的进展共同构成价格下行的技术基础，也解释了为何调用量的增长速度可以持续快于算力规模的增长速度——这一关系将在4.5节以供供给侧恒等式加以量化。

4.1.3 国际背景与统计可比性的缺口

把我国的调用量序列放到国际背景中观察，会立即遇到一个方法论障碍：主要经济体均未发布可比的词元调用量统计。国际组织与研究机构对人工智能经济影响的测度，采用的是采纳率、消费者剩余、生产率贡献等间接指标。以人工智能指数报告为例，其经济章给出的关键结果是：约70%的受访组织在至少一项业务职能中使用生成式人工智能，美国用户端的年度消费者剩余到2026年初达1720亿美元，按职能测度的生产率提升分别为客户支持14%—15%、软件开发26%、营销产出73%（「Stanford HAI，2026」）。这些数字的口径需要格外注意：消费者剩余是基于调查的福利建模估计，不是产值、不是市场规模，绝不可与产业规模数字并列或相加；职能级生产率提升来自各自独立的随机对照或准实验研究，样本、任务与时长各异，不能外推为宏观生产率增速。国际组织的宏观测算同样是情景区间：对七国集团的测算显示，人工智能可为高暴露度经济体带来年度劳动生产率增长0.4—1.3个百分点的增量（「OECD，2024」）；就业暴露度的测算则显示全球约40%、发达经济体约60%的岗位暴露于人工智能，但暴露不等于替代（「Cazzaniga等，2024」）。

相比之下，词元调用量是一个过程量而非结果量：它直接观测智能服务的生产与消费规模，不需要经由生产率残差或问卷推断。这正是本书把标准词元流量引入增长核算的动因（第12章）。但过程量的优势要成立，前提是口径统一且可比——而当前的现实是，即便在国内，不同发布主体的词元数字也难以互证；

在国际上，则根本不存在对应的统计制度。数字经济核算的既有研究反复指出，新兴数字活动的统计滞后于其经济重要性，卫星账户与新增指标的设计是弥合这一滞后的主要路径（杨仲山和张美慧，2019；许宪春等，2021；蔡跃洲和牛新星，2021）。词元调用量的发布在这个意义上是一项统计制度创新，但它目前仍停留在「发布」而非「统计」的阶段：没有公开的统计边界定义、没有固定的报送与核验流程、没有分行业分区域的分解。把发布升级为统计，正是本书政策建议的重点之一（第 14 章）。

综上，可以归纳出本章的第一条典型事实。典型事实一：我国日均词元调用量在两年间增长约 1400 倍，年化对数增长率 3.62、倍增周期约 70 天，增速虽在减速但仍维持数量级级别的扩张；与这一增长形成鲜明反差的是，该指标迄今只有四个官方锚点、没有固定的统计制度，也没有可比的国际口径。规模的爆发式扩张与计量制度的高度稀薄并存，构成了词元经济最基本的一组张力。

4.2 模型供给格局：份额、集中度与平台口径的限度

4.2.1 第三方路由平台口径下的中国模型份额

需求侧的总量数据无法回答「这些词元由谁生产」。回答这一问题目前只有一类可得的高频数据源——第三方模型路由聚合平台的公开榜单。这类平台为开发者提供统一接口，把请求路由到不同厂商的模型，因而能观测到跨厂商的相对用量。媒体依据该类平台数据整理的连续周度序列显示，2026 年 7—8 月间中国模型的周调用量持续高于美国模型，且中国模型在可得的两个周次中占全球总量的比重接近或超过一半。表 4.1 汇总了四个统计周的具体数值与领先周数。

表 4.1 第三方路由平台上中国模型与美国模型的周调用量对照（2026 年 7—8 月）

统计周 (2026 年)	中国模型 (万亿枚)	美国模型 (万亿枚)	全球总量 (万亿枚)	中国模型占 全球 (%)	连续领先周 数
7/20—7/26	33.00	2.34	58	56.9	第 13 周
7/27—8/2	28.13	4.38	未披露	—	第 14 周
8/3—8/9	34.25	9.17	69	49.6	第 15 周
8/10—8/16	36.84	未披露	未披露	—	第 16 周

注：统计口径为第三方模型路由聚合平台的路由量，不含模型厂商官方接口的直连调用、国内各云平台的模型即服务用量与企业自建推理；模型国别按开发商总部归属人工归类，非官方分类；榜单按自然周滚动更新，同一模型的不同版本分行计数，是否合并会显著改变名次归属；「连续领先周数」指中国模型合计周调用量连续高于美国模型合计的周数。数据来源：主流财经媒体依该平台公开数据整理的报道（2026 年 7 月—8 月）。

表 4.1 显示，中国模型的周调用量在四周内由 33.00 万亿枚波动上升至 36.84 万亿枚，其间经历了一次约 15% 的回落与随后两周的反弹，相对第二周的净增幅为 31.0%；美国模型的周调用量则由 2.34 万亿枚快速升至 9.17 万亿

枚，增速显著高于中国模型，但绝对水平仍相差数倍。把两者放在全球总量中观察，中国模型占比由 56.9% 回落至 49.6%，恰好说明「连续领先」与「份额上升」是两件事：在全球总量快速扩张的阶段，领先方的绝对量增长可以与相对份额下降并存。

如图 4.2 所示，把中国模型的周调用量、可得周次的全球总量与占比同时呈现，可以更清楚地看到这一结构。




图 4.2 中国模型周调用量与全球占比 (2026 年 7—8 月)

注：左轴为中国模型周调用量（实心柱），虚线空心柱为该周全球总量（仅第 13 周与第 15 周披露），右轴为中国模型占全球总量的比重；口径限制同表 4.1。数据来源：主流财经媒体依第三方路由平台公开数据整理的报道。

图 4.2 与表 4.1 的解读必须受口径限制的约束，这一点比数值本身更重要。第一，该平台只统计经其路由的调用，模型厂商的官方接口直连量、国内各云平台的模型即服务用量与企业自建推理均不计入；据此得出的比值只能表述为「在该平台上」，不得表述为全球市场份额。第二，把该平台的全球周总量与国家数据局的全国日均调用量相比，可以直观看出覆盖面的量级差异——前者在披露周次的全球总量为 58 万亿至 69 万亿枚每周，尚不足我国单日 140 万亿枚调用量的一半。这一对比不是为了否定平台数据的价值，而是为了确立其正确用法：它是观测相对结构与短期变化的高频探针，不是总量统计。第三，「国别」按开发商总部归属人工归类，同一模型的不同版本分行计数，合并与否会改变名次归属，因而基于榜单名次的任何强结论都应谨慎。

4.2.2 集中度下降、开放权重与多归属

供给格局的第二个特征是集中度的持续下降。本书以模型服务市场的调用量份额测算的赫芬达尔—赫希曼指数由 2024 年的 0.34 降至 2025 年的

0.27、2026 年的 0.21（校准复算口径，第 8 章）。这一下降有三重推力：一是开放权重模型的密集发布使部署门槛大幅降低，任何具备算力的主体都可成为供给者；二是价格竞争把差异化产品拉入同一竞争带；三是路由平台与统一接口的普及显著降低了转换成本，使需求方的多归属成为常态。多归属是双边市场竞争的经典特征，它削弱了单边平台的锁定能力，使价格竞争更为激烈（Armstrong，2006；Jullien 等，2021）；而网络外部性在此并未消失，只是从「用户规模」转移到了「生态兼容性」——能被更多智能体框架、编程工具与 workflow 直接调用的模型，其需求增长显著快于同等能力但生态适配不足的模型（Katz 和 Shapiro，1985）。

需要提醒的是，集中度指标本身也受口径影响。以调用量份额计算的集中度、以收入份额计算的集中度与以算力份额计算的集中度可以给出方向相反的结论：低价档位在使用量上占优、在收入上劣势，高价档位则相反。第三方口径的观察显示，路由平台上中国模型的加权均价可低至每百万词元 0.18 美元，而美国模型约为 4 美元，二者相差二十倍以上；但这是平台加权均价而非任一模型的挂牌价，其差异同时包含了模型档位结构、开放权重比例与折扣策略三重因素，不能直接读作「同等能力下的价格差」。把调用量份额与价格差简单相乘来推算收入份额，是当前产业报道中最常见的错误之一。

4.2.3 从模型竞争到词元产能竞争

供给格局的第三个特征，是竞争焦点由模型能力转向词元产能。2026 年以来，「词元工厂」作为一种新型产能形态密集出现：北京数据集团下属公司于 2026 年 7 月发布国资背景的标准化词元工厂，具备分离式智能调度架构、异构算力统一调度与标准化接口接入等能力；同年 6 月，另一家企业在北京亦庄建成的词元工厂一期设计日产能达 1.4 万亿枚；2026 年 7 月的世界人工智能大会上，一家具备清华大学计算机系与国家级超算中心背景的团队发布了国产词元优化工厂，宣称兼容十余种国产算力硬件、适配二十余款主流模型、日吞吐千亿枚量级。上述产能与吞吐数字均属企业方或媒体报道口径，未经第三方测评背书，且「设计日产能」与「实测日吞吐」并非同类指标，二者均未说明模型规模、上下文长度、精度以及输入与输出词元是否合并计数，因此在任何情况下都不可直接比大小或排名。

词元工厂的出现具有超出企业个案的经济含义：它标志着算力的价值实现方式正由「租算力」转向「卖词元」，即由出售一段时间的机器占用权，转向出售一定数量与质量的智能服务产出。这一转变把算力资产的收益与其使用效率直接

绑定，从而把调度、批处理与模型匹配从技术问题变成了商业模式问题。云计算的经济学研究早已指出，从自建到租用的转变通过降低固定投入门槛显著改变了企业的技术采纳与增长路径（Byrne 等，2018；Coyle 和 Nguyen，2019；DeStefano 等，2025）；对大规模机器学习服务集群的工作负载分析则揭示了资源利用的巨大不均衡（Weng 等，2022）。词元工厂可视为这一演化的下一步：计价对象从资源时间进一步下沉到服务产出。但这一步能否走通，取决于产出本身是否可计量、可比较——若「一枚词元」在不同工厂之间不可比，那么「卖词元」的定价基准就无法建立。这正是本书第 5 章的任务。

据此可归纳典型事实二：词元供给格局呈现集中度持续下降、开放权重路线扩张、竞争焦点由模型能力转向词元产能三重特征；与此同时，可用于刻画份额的高频数据仅来自第三方路由平台，其覆盖面不足全国总量的一个量级，且国别归类、版本计数与价格口径均存在人为设定，任何份额类结论都必须带着口径限定来表述。供给格局的这一「数据稀薄」特征，与需求侧「四个锚点」的稀薄如出一辙。

4.3 需求的场景结构：集中度、长尾与价值密度

总量与供给之外，词元经济的第三组典型事实来自需求的内部结构。一个被产业界广泛感知却少有严格测度的现象是：词元消耗高度集中于少数场景。为把这一现象形式化，定义两个结构指标：一是用量份额与应用数量份额的偏离指数，二是分类别的集中倍率，见式(4-2)。

$$H = \frac{1}{2} \sum_{k=1}^K |s_k^T - s_k^A|, \kappa_k = \frac{s_k^T}{s_k^A}, \sum_{k=1}^K s_k^T = \sum_{k=1}^K s_k^A = 1 \quad (4-2)$$

其中， k 为场景类别， s_k^T 为该类别的词元用量份额， s_k^A 为该类别的应用数量份额， H 为二者的偏离指数（取值于 0 与 1 之间，0 表示用量在应用间均匀分布，1 表示完全集中）， κ_k 为集中倍率（大于 1 表示该类别的单应用词元强度高于平均）。

按本书的四类划分测算，偏离指数 $H = 0.62$ ，即需要把约 62%的词元用量在类别间重新分配，才能使用量结构与应用数量结构一致。分类别看，智能体与编程类的集中倍率 $\kappa = 4.27$ ，即该类应用的单应用词元强度约为全体平均的 4.3 倍；对话问答、内容生成与其他三类的集中倍率分别为 0.31、0.19 与 0.20，均显著低于 1。这组数字给出了「少数应用消耗多数词元」这一产业直觉的精确表达。

如图 4.3 所示，把应用数量占比与词元用量占比并置比较，四类场景的结构反差一目了然。




图 4.3 词元消耗的场景结构

注：图中「Agent与编程」即正文所称智能体与编程类应用；应用数量占比按平台注册应用计，词元用量占比按平台路由词元量计，两者分母不同，不构成同一总体的两种分解；场景类别系按应用主功能归并。数据来源：作者依第三方路由平台公开报道的结构性事实校准复算，非官方统计。

图 4.3 显示，智能体与编程类应用在数量上仅占 19%，却消耗了 81.2% 的词元；对话问答类应用数量占 28% 而用量仅占 8.6%，内容生成类数量占比最高（31%）而用量占比仅 5.8%。需要说明数据的性质：这一四分类结构系本书依公开报道的结构性事实校准复算而得，并非官方统计。其可溯源的经验锚点有二：其一，基于百万亿枚词元规模匿名元数据的行业报告显示，在 2024 年 11 月至 2025 年 11 月的样本区间内，编程类请求的词元占比由约 11% 升至 50% 以上，成为平台最大单一使用品类，而智能体驱动的多步骤自动化 workflows 所产生的输出词元已超过平台总输出的一半；其二，对同一平台应用榜单的统计显示，前二十名应用中至少七款为编程类智能体。两项锚点均为平台内部口径，不能外推为全行业结构，但足以支持「用量高度集中于智能体与编程类」这一定性判断。

场景集中的机制并不神秘，却有深刻的经济含义。编程与智能体类任务具有三个共同特征：上下文长（需要读入代码库、文档与历史轨迹）、多轮次（一次任务分解为数十步调用）、容错要求高（需要反复验证与回退）。三者共同抬高了单任务的词元强度。更重要的是，这类任务恰好是人工智能对人类认知劳动替代最直接、最可验证的领域：随机对照实验显示，生成式人工智能对写作类任务

的产出效率有显著提升且缩小了能力差距（Noy 和 Zhang，2023），对客服岗位的现场实验显示其对低技能员工的边际帮助最大（Brynjolfsson 等，2025），而基于任务的暴露度测度表明，编程与信息处理类职业的暴露度显著高于其他职业（Felten 等，2021；Eloundou 等，2024）。换言之，词元流向的是替代价值最高的地方——这既是市场机制有效的证据，也是本书把场景效用纳入效值折算的经验依据。

场景之间的价值密度差异同样悬殊。本书对典型场景单位标准词元价值密度的校准复算显示，科研分析场景的价值密度最高（11.3），文案生成场景最低（1.9），二者相差 5.9 倍（详见第 6 章）。把这一结果与集中倍率并置，可以得到一个重要观察：词元用量的集中方向与价值密度的高低方向大体一致，即高用量场景同时也是高价值密度场景。这一「量价同向」的结构对政策设计有直接含义——若以调用量为唯一的补贴核定基准，资金将流向本已具备最高支付意愿的场景，普惠性目标难以实现；反之，若完全按场景类别定向补贴，又会扭曲市场对高价值用途的自然筛选。化解这一两难需要的正是可比的效值口径，使补贴可以按标准词元而非物理词元核定。

据此可归纳典型事实三：词元用量高度集中于智能体与编程类应用，偏离指数达 0.62、集中倍率达 4.3 倍；用量集中的方向与场景价值密度的高低方向一致，说明市场已在自发地把词元配置到替代价值最高的用途上，但这种配置是在缺乏统一效值尺度的条件下完成的，其效率高低无法被验证，也无法被政策工具精确引导。

4.4 价格演进：表观下行、结构分化与口径分裂

4.4.1 表观价格的快速下行

词元经济最广为人知的一组事实是价格的持续下行。以 2024 年第一季度为基期编制的物理词元价格指数显示，至 2026 年第二季度该指数降至 21，累计下降 79%，折合年均下降约 50%——即表观单价大体每年减半。如图 4.4 所示，面板（a）给出了这一指数的季度轨迹，面板（b）给出了同一时点上六个模型档位的市场单价对照。




图 4.4 词元价格的演进与档位间价差

注：面板（a）为物理词元口径的价格指数，2024Q1 = 100，标准词元价格指数与两指数背离的分解见第 7 章；面板（b）纵轴为对数刻度，六个档位为避免挂靠具体商业产品而设的抽象分类，各档位单价系作者依 2026 年第二季度市场行情校准复算所得，不对应任何特定商业产品。数据来源：作者校准复算。

图 4.4 的两个面板呈现的是同一现象的两个侧面。面板（a）的下行轨迹表明，词元作为一种服务的名义价格正在以极快的速度贬值；面板（b）则显示，在同一时点上，最高档位与最低档位的单价相差 35 倍——从轻量蒸馏级的每百万词元 0.40 元到推理增强级的 14.00 元。两个事实叠加，得到的推论至关重要：所谓「词元价格」并不是一个价格，而是一族价格；把它们简单平均或加总所得到的「均价」，其变动既反映真实的价格变化，也反映交易结构的迁移。若观测期内需求向低档位迁移，则即便每一档位的价格都保持不变，加权均价也会下降。这正是第 7 章要以标准词元价格指数加以校正的问题；本章只呈现表观事实，不做分解。

4.4.2 并存的四套价格观测口径

价格观测的困难不在于数据缺乏，而在于口径过多且互不相通。表 4.2 汇总了 2026 年年中并存的四类可观测价格口径及其代表性点位，并以本书校准复算的档位单价列于末行作为对照。

表 4.2 词元价格的可观测口径与代表性点位（2026 年）

价格口径	代表性点位	计量对象与限制
支出加权的全市场成交均价指数（第三方数据服务商，日度）	2026 年 5 月 31 日均值 2.04 美元/百万词元；8 月 6—8 日回落至 1.16—1.18 美元，约两个月跌逾四成，为年内最低	按实际支出加权的全市场成交均价，覆盖前沿接口、开放权重推理平台、经纪化专用实例与自托管参考部署；不是任何单一模型的挂牌价，也不等于人工智能总支出；该指数另设分段子指数，引用总指数时不可与分段值混淆

国内头部服务商的挂牌价 (改价前)	截至 2026 年 8 月 16 日： 输入（缓存未命中）1 元、 输出 2 元／百万词元，输入 （缓存命中）另计 0.02 元	单一服务商的公开挂牌价， 须带时点限定；缓存命中与 未命中差价达数十倍，不注 明缓存状态的单价不具可比 性
同一服务商的峰谷分时价 (改价后)	2026 年 8 月 17 日零时起： 空闲时段输入 1.5 元、输出 4.5 元；高峰时段输入 3 元、输出 9 元／百万词元 （高峰为北京时间 9—12 时、14—18 时，空闲价为 高峰价一半）	同一模型的同一枚词元因时 段不同而价格相差一倍，价 格开始承载算力的时段稀缺 信息；任何基于改价前价格 的成本论证均需重算
境外前沿服务的挂牌价区间	2026 年 8 月：输入约 1— 10 美元、输出约 6—50 美 元／百万词元；长上下文档 位另行加价，缓存读取按标 准输入价的一成计	第三方定价聚合口径，同一 版本常存在降价前后两套并 存数值，引用须锁定时点并 以厂商官方定价页为准
本书六档位校准复算的市场 单价	0.40—14.00 元／百万物理 词元（2026 年第二季 度），折算为标准词元后收 敛至 1.053—3.271 元／百 万标准词元	档位为抽象分类，不对应任 何具体商业产品；折算方法 与效值系数见第 5 章

注：前四行为公开发布或公开报道的可核实点位，末行为本书校准复算值；各行的计量对象、加权方式与时点均不同，不可相互折算、并列比较或用于计算「国内外价差倍数」。数据来源：第三方数据服务商产品说明与主流财经媒体报道（2026 年）；末行系作者校准复算。

表 4.2 的信息可以归纳为三点。第一，全市场成交均价与单一模型挂牌价是两个不同的对象：前者是支出加权的实际成交结果，随交易结构迁移而变动；后者是名义报价，随厂商策略而跳变。二者的走势可以在短期内背离，把「指数点位相对高点跌近两成」与「绝对均价由 2.04 美元跌至 1.16 美元、跌幅逾四成」并列使用，就会得到自相矛盾的叙述。第二，缓存与时段已经成为价格结构的组成部分：缓存命中与未命中的输入价相差数十倍，高峰与空闲时段的价格相差一倍。这意味着词元价格并非「零边际成本产品的名义标价」，而是承载了真实资源稀缺信息的价格——峰谷分时定价的出现，恰是第 3 章所述算力约束影子价格市场上的显性化。第三，跨境价格比较必须极为审慎：不同货币、不同缓存规则、不同上下文档位、不同折扣结构使得任何「便宜多少倍」的表述都需要指明比较基准。

4.4.3 降价的三重来源与不可直接解读的表观降幅

表观价格的快速下行有三重来源，其经济含义各不相同。第一重是技术与系统效率的真实改进：显存管理、连续批处理、分块预填充与预填充—解码分离等推理系统进展持续压低单位词元的资源消耗（Yu 等，2022；Kwon 等，2023；Agrawal 等，2024；Zhong 等，2024），模型侧的规模律与训练—推理权衡研究则从另一端降低了达到同等能力所需的推理成本（Kaplan

等，2020；Hoffmann 等，2022）。这一部分降价是社会福利的净增加。第二重是竞争与规模的压力：集中度下降、开放权重扩散与多归属使价格向边际成本靠拢，规模经济又使边际成本随产量下降。这一部分降价是市场结构演化的结果，其可持续性取决于产业是否进入长期均衡。第三重则是交易结构的迁移：低效值档位的份额上升会拉低加权均价，而这并不意味着任何一档位的真正下降。三重来源在表观价格数据中混在一起，无法直接分辨——这正是本书要在第 7 章引入标准词元价格指数的原因。前瞻性地说，本书的分解结果是：2024Q1 至 2026Q2 表观累计降幅 79% 中，约 53% 来自效值提升、约 47% 为真实降价。

还有一重常被忽略的价差来源：语言。同一段语义内容在不同语言下被分词器切分出的词元数差异显著，非拉丁语系文本通常需要更多词元来表达等量信息，这使得按词元计费的服务在不同语言市场上呈现出隐含的价格歧视（Rust 等，2021；Petrov 等，2023；Ahia 等，2023）。对于词元出海与跨境结算而言，这一技术性差异会直接转化为成本差异：同样的业务量，以中文运行与以英文运行的词元账单并不相同。这提示我们，跨境价格互认不仅需要统一的效值口径，还需要在计量规则中处理语言维度的换算——本书把它归入标准词元折算的场景效用维度加以吸收（第 5 章），并在词元出海的政策建议中单列（第 14 章）。

据此可归纳典型事实四：物理词元的表观价格在两年半内累计下降 79%、年均下降约 50%，同一时点上不同档位的单价却相差 35 倍；价格观测存在至少四套互不相通的口径，且缓存状态、时段、语言与上下文长度均已成为价格结构的组成部分。「词元价格」因此不是一个可以单值化的概念，其下行幅度也不能被直接解读为真实降价。

4.5 算力供给格局：规模、布局与量级核算

4.5.1 三套并存的算力统计口径

词元的物理基础是算力。但与词元调用量一样，我国的算力规模统计同样存在多套并存且不可通约的口径。表 4.3 汇总了三类主要发布主体的口径、时点与数值。

表 4.3 智能算力规模的三套统计口径对照

发布主体	指标与统计对象	精度基准	时点	数值
工业和信息化部	智能算力规模 (已建成规模)	FP16	2026 年 6 月底	2185 EFLOPS，同比 增长 177%；全

工业和信息化部	智能算力规模与万卡级集群	FP16	2025 年底	国算力设施整体上架率 71.4% 超过 1590 EFLOPS；已建成万卡级智算集群 42 个
中国信息通信研究院	我国算力设备总规模／其中智能算力	FP32 折算	2025 年 6 月	962／782 EFLOPS，同比增长 73％／96％；我国约占全球 21％
中国信息通信研究院	全球算力设备总规模／其中智能算力	FP32 折算	2025 年 6 月	4495／3846 EFLOPS，智能算力占总算力 85％
国际数据公司与服务器厂商联合发布	中国智能算力规模（测算与预测）	测算口径	2025／2026 年	1037.3／1460.3 EFLOPS（2026 年为预测值）

注：三套口径的精度基准、统计对象与时点均不同，严禁并列比较或相互折算——FP16 与 FP32 折算之间通常存在约两倍的名义差，直接对比会得出「我国智能算力超过全球总量」一类的荒谬结论；「已建成规模」为实测统计，未行为咨询机构测算与预测值，二者不是同一类量。数据来源：国务院新闻办公室新闻发布会（2026 年 7 月 20 日、2026 年 1 月 21 日）；中国信息通信研究院《先进计算暨算力发展指数蓝皮书（2025 年）》；咨询机构与服务器厂商联合发布的年度评估报告。

表 4.3 揭示的问题与表 4.2 同构：不是数据太少，而是口径太多。除精度基准外，还须注意算力规模至少存在三套互不相通的计量单位——数据中心口径的标准机架、算力性能口径的每秒浮点运算次数、加速卡口径的卡数，三者之间没有公开的官方换算系数，且「万卡集群」并未区分卡型与代际，不同城市的「万卡」并不等价。产业研究对算力经济的系统梳理（「中国信息通信研究院，2025」；「中国信息通信研究院，2026」）与对智算云基础设施市场的跟踪（「IDC，2025」）均反复提示这一点。对本书而言，口径分裂的直接后果是：算力与词元之间的转化关系无法用公开数据精确刻画，只能做量级核算——这也正是本书要构造转化函数并以校准复算方式测算参数的原因（第 9 章）。

4.5.2 空间布局：枢纽节点、集群与区域结构

算力供给的空间格局由国家战略布局主导。2021 年确立的全国一体化大数据中心协同创新体系算力枢纽实施方案（「国家发展改革委等，2021」）与随后两批复函形成了 8 个国家算力枢纽节点与 10 个国家数据中心集群的总体布局，2022 年 2 月「东数西算」工程全面启动；2023 年底印发的实施意见进一步提出建设「联网调度、普惠易用、绿色安全」的全国一体化算力网，统筹通用算力、智能算力与超级算力的协同（国家发展改革委等，2023）；2026 年初，工业和信息化部部署建设「1+M+N」国家算力互联互通节点体系，提出统一标识、统一标准、统一规则的运行机制。地方层面，浙江省「十五五」规划纲要提

出建立全省一体化算力监测调度平台（「浙江省人民代表大会，2026」），上海市则以「百千万」智算集群工程形成大集群、小集群与边缘算力协同的梯次供给体系，在部分区域布局十万卡级超大规模智算集群（「上海市经济和信息化委员会，2026」）。需要注意的是，省级监测调度平台、市级调度平台与国家一体化算力网分属三个层级、三套接入范围，各平台上报的算力规模之间存在重复计算，不可加总。

区域结构上，按工业和信息化部 2026 年 7 月发布的口径，东部、中部、西部与东北地区的智算规模占全国比例分别为 55.9%、10.6%、32.6%与 0.9%。这一分布显示，尽管「东数西算」推动了西部算力的快速增长（西部占比已达三分之一），但智算资源仍以东部为主——这与推理业务的时延敏感性直接相关：训练任务可以西迁，推理任务却受制于网络时延与数据合规而更倾向于贴近需求地。词元经济的兴起因此并不必然强化「东数西算」的原有分工，反而可能形成「西部训练、东部推理」的新格局，这对枢纽节点的功能定位提出了新要求。

地方实践中，长三角国家枢纽节点起步区所在的嘉兴市提供了一个可观察的样本。如图 4.5 所示，其已投运智算规模在不同时点与不同发布口径下由约 4.37 万 PFLOPS 升至 11.8 万 PFLOPS，规划建成后的目标值为 27.6 万 PFLOPS；同时该市拥有多个万卡级智算中心，并建有一座峰值算力达每秒 18 亿亿次的超算中心。




图 4.5 智能算力供给格局与集群布局

注：面板（a）为长三角国家枢纽节点起步区所在的嘉兴市已投运智算规模，四条分别对应不同时间与不同发布口径（末条为规划建成后的目标值，非实测）；面板（b）第三项为超算中心峰值算力（FP64 口径），与前两项的智算规模（低精度折算口径）不可相加、不可折算；「占浙江省已投运算力」的分子分母口径随时点而变，公开报道中并存「已投运占 60%」「在建加投运占 60%以上」「占 50%以上」三种表述。数据来源：地方政府网站与主流媒体公开报道（2024—2026 年）。

图 4.5 的读法需要格外小心，它本身就是口径混乱的一个缩影。面板（a）的四个条形并非同一序列的四个时点：它们来自不同发布主体、不同统计范围的

报道，末条更是规划目标而非实测值，因此不能据以计算增长率。面板（b）的第二张卡片同样如此——「占浙江省已投运算力约六成」这一广为流传的表述，在公开报道中至少存在三种分子分母组合，且省级分母本身在快速扩张，跨年引用会制造「占比越建越低」的假象。第三张卡片的超算峰值算力以 FP64 为基准，与智算规模的低精度折算口径相差一个数量级以上，把二者相加是产业报道中最常见的错误。本书呈现这一图形，用意不在于给出嘉兴算力的精确画像，而在于示范一种阅读方式：在计量制度建立之前，任何区域算力数字都必须与其口径同时呈现。

4.5.3 供给与需求的量级核算

算力与词元之间存在一个恒等关系：一定时期内产出的标准词元流量，等于算力存量、有效利用率与单位算力转化效率之积。据此可把词元调用量的增长分解为三个来源，见式(4-3)。

$$\tilde{T}_t = \theta_t u_t C_t \Delta t, g_{\tilde{T}} = g_\theta + g_u + g_C, g_T = g_{\tilde{T}} - g_{\eta} \quad (4-3)$$

其中， $\tilde{T}_t$ 为 t 期的标准词元流量， C_t 为智能算力存量， u_t 为有效利用率， θ_t 为单位算力的标准词元转化效率， Δt 为时长； $g_x = d \ln x / dt$ 表示对应变量的对数增长率， η 为用量加权的平均效值系数（其定义见式(3-8)）。

式(4-3)的第二式表明，标准词元流量的增长必然分解为算力存量增长、利用率提升与转化效率改进三项之和；第三式则表明，物理口径的增长率与标准口径的增长率之差，恰等于平均效值系数的增长率。把公开数据代入可作量级核算：按工业和信息化部口径，2026年6月底智能算力规模2185 EFLOPS、同比增长177%，对应年化对数增速 $g_C = 1.02$ （上年同期约789 EFLOPS）；按国家数据局口径，日均调用量由2025年6月底的30万亿枚升至2026年3月的140万亿枚，年化对数增速 $g_T = 2.05$ 。二者相减，残差 $g_T - g_C = 1.04$ ，相当于每年约2.8倍。

这一残差绝不能被直接读作「转化效率提升了2.8倍」。它至少包含四类因素：一是转化效率 θ 的真实改进（推理系统与模型侧的效率进展）；二是有效利用率 u 的提高（调度与池化能力的改善）；三是算力用途结构的变化（推理在算力总用途中的占比上升，训练占比相应下降）；四是统计边界的差异与扩大（两个序列的发布主体、精度基准与时间窗均不同，且调用量的统计边界从未公开）。此外，平均效值系数的变化会使物理口径与标准口径的增长率发生系统性背离——按本书校准复算的用量结构，2026年的用量加权平均效值系数 $\eta = 1.43$ ，据此把140万亿枚物理词元换算为约200万亿枚标准词元，而若结构向

低效值档位迁移，则物理口径的增速会系统性高于标准口径。因此，式(4-3)在此的作用不是精确测算，而是明确三点：第一，调用量的增长速度约为算力规模增长速度的两倍，单纯的算力扩建不足以解释词元产出的扩张；第二，效率与结构因素在增长中占有可观份额，是第9章的分析对象；第三，要把这一分解从量级核算推进到精确核算，前提是标准词元口径与配套统计制度的建立。

算力扩张还受到能源侧的硬约束。国际能源署的评估显示，2024年全球数据中心用电约415太瓦时，约占全球用电的1.5%，基准情景下到2030年将升至约945太瓦时、占比略低于3%，其中美国与中国合计贡献全球增量的近八成（IEA，2025）；对美国数据中心用电的系统核算也显示，人工智能负载正在改变数据中心能耗的长期趋势（Masanet等，2020；Shehabi等，2024），而单次推理的能耗与水耗测算表明，能耗强度在不同任务与模型之间差异巨大（Luccioni等，2024；Li等，2025）。国内方面，算力电力协同已成为独立的研究与政策议题（中国信息通信研究院，2025），但需要指出的是，我国目前尚无由国家部委发布的数据中心用电量正式统计，流传的多套占比数字来源等级不同、彼此矛盾，不可并列引用。能耗与碳足迹的系统分析属第11章，此处仅确认一点：算力扩张的边界不只是投资，还有电力与碳排放，这使得「提高单位算力的词元产出」从效率问题上升为约束问题。

据此可归纳典型事实五：我国智能算力规模保持年均近八成的高速增长，空间上形成东部为主、西部快速追赶的格局，但算力统计存在至少三套不可通约的口径；同期词元调用量的增长速度约为算力规模增长速度的两倍，其差额来自转化效率、利用率、用途结构与统计边界四类因素，在现有数据条件下无法精确分离。

4.6 利用率现状：三个「利用率」与效值损失

如果算力扩张不足以解释词元产出的增长，那么反过来的问题就是：现有算力被使用得如何？2026年年中，国际数据公司与中国信息通信研究院联合开展的企业调研给出了一组广为引用的分布：近半数（约48%）企业的智算资源利用率处于51%—70%的中等区间，6.7%的企业仅为31%—50%，利用率达到70%以上的高效率企业不足35%，制造与政务行业低于平均水平；同时，头部云厂商、互联网企业、人工智能自研公司与新能源车企的核心集群利用率超过80%。调研同时指出，多数自建智算项目「重硬件、轻软件」，缺乏统一调度平台与资源池化管理，是利用率偏低的主因。

这组数字的口径必须严格限定。它是企业侧调研的自报值，统计对象为企业自建自用的智算资源，既不是机架上架率，也不是加速卡卡时利用率的实测采样。产业讨论中并存的三个「利用率」实际上是三件事：调研自报的企业智算资源利用率（51%—70%区间）、统计口径的全国算力设施整体上架率（71.4%）、第三方估算的智算中心加速卡利用率（常被引作三成左右）。三者的统计对象、测量方法与分母定义完全不同，不可互证，更不可用来支撑同一个结论。本书在第9章的分析中因此不直接采用任何一个公开利用率数字作为参数，而是以校准复算方式重建一套内部一致的利用率口径。

更重要的是，即便利用率被准确测量，它也只是「资源被占用的比例」，而不是「资源被有效使用的比例」。一台被百分之百占用的加速卡，如果在生产低效值的词元、或在为错配的任务提供服务，从价值创造的角度看仍是浪费。本书因此提出「有效效值利用率」概念，把名义利用率62%依次扣除空转损失18%、批次损失9%、匹配损失12%与效值损失7%——四项均为相对损失率，逐级相乘（即 $0.62 \times (1 - 0.18)(1 - 0.09)(1 - 0.12)(1 - 0.07) \approx 0.38$ ）——得到有效效值利用率仅38%；经任务—模型最优匹配的统一调度，这一比例可提升至54%，相对改进约42%，理论上界为61%。其中匹配损失与效值损失两项，恰恰只有在标准词元口径下才可被识别——这是本书把计量问题置于配置问题之前的又一理由。相关机理与证据详见第9章。

利用率不足的成因在既有研究中已有讨论。对智算中心的实证研究表明，算力部署对企业全要素生产率的提升效应依赖于数据跨域流动等配套条件（许诺等，2025）；对需求侧算力资源配置的研究则指出，算力共享机制与市场培育是提高使用效率的关键（王勇等，2025）；对大规模机器学习服务集群的工作负载分析进一步显示，资源利用的不均衡与任务异质性密切相关（Weng等，2022）。平台在资源配置中的作用也被反复论证：价格机制与数据机制的协同可显著改善配置效率（刘诚和夏杰长，2023），但平台的市场势力同时带来福利与竞争政策上的权衡（顾聪等，2023；吴双和王勇，2024）。这些研究共同指向一个判断：利用率问题的实质是配置问题，而配置的前提是可比的计量。

据此可归纳典型事实六：我国企业智算资源利用率集中于51%—70%的中等区间，达到70%以上者不足三分之一，而产业中并存的三个「利用率」指标口径互异、不可互证；更根本的是，名义利用率无法反映被占用算力是否用于生产高效值词元，扣除空转、批次、匹配与效值四项损失后的有效效值利用率仅38%。

4.7 词元的制度化：运营组织、政策工具与标准供给

4.7.1 城市级运营组织的集中涌现

2026 年夏季，词元经济出现了一个此前没有先例的现象：在不到一个月的时间内，多座城市密集设立以词元为对象的运营或交易组织。2026 年 7 月 15 日，东南词元运营中心在温州启动，由国资控股的专门运营公司承担具体运营，其董事长由温州市数据集团总经理兼任，基础电信运营商及其云平台在建设运营初期提供智算基础设施与平台能力，同日中国移动首个词元工厂在温州揭牌；7 月 30 日，长三角（嘉兴）Token 运营中心启动，嘉兴市城市投资发展集团承担面向市场的统一服务窗口的运营，中国移动嘉兴分公司作为战略合作伙伴投放核心算力；同日，广东词元交易和服务中心在广州南沙揭牌，由广东省与广州市数据管理部门统筹指导、依托广州数据交易所建设；8 月 11 日，江苏省首个词元运营中心在苏州工业园区揭牌，落址国家级数据要素流通枢纽，依托基础电信运营商的云底座与词元运营平台，同日词元出海服务联盟成立、首批 15 家成员企业加入；亦在 8 月 11 日，《上海市软件和信息服务业发展「十五五」规划》印发，提出探索将词元、数据治理、大模型部署及再训练等投入纳入企业技术改造支持方向（「上海市经济和信息化委员会，2026」）。

这些组织在功能定位上并不相同，必须分类观察。第一类是产能供给侧的「词元工厂」，其指标是日产能与吞吐；第二类是流通服务侧的「词元运营中心」，其指标是接入模型数、服务企业数与统一计量结算能力；第三类是交易组织侧的「词元交易中心」，其指标是场内成交额与交易凭证。三类主体的「全国首个」称号各有限定语，去掉限定语即会相互冲突；「词元交易额」与「词元调用量」更是两个完全不同的计量对象，前者是成交金额，后者是技术调用规模，二者之间不存在换算关系。各地提出的功能清单也是异构的：嘉兴门户提出统一接口入口、统一词元计量、统一费用结算、统一政策抵扣、统一安全审计的「五个统一」，温州提出「六个统一」（增加模型路由），江苏提出模型广场、技能市场、应用超市、补贴专区、安全风控、指标监测「六大类服务」。三套清单的条目数不构成能力强弱的比较，把「六项」读作优于「五项」是典型的口径误用。

尽管形态各异，这些组织在经济职能上却指向同一件事：降低词元交易的度量费用与协调费用。企业接入单一模型服务商需要分别完成合同、计量、结算、合规与安全审计五道手续，接入 N 家则需重复 N 次；统一入口把这些手续一次性完成，其节约的正是新制度经济学意义上的交易费用。统一计量之所以在各地清

单中居于核心位置，原因也在于此：计量是结算、抵扣与审计的共同前置——不能计量则不能结算，不能结算则无法抵扣，无法抵扣则财政工具落不了地。这一逻辑链条将在第 10 章以机制设计与三方演化博弈严格刻画，此处只需指出：城市级运营组织的涌现，本质上是市场对统一计量基础设施缺位的一种自发替代。

值得注意的还有运营主体的资产逻辑。五地实践在主体类型上恰好构成一组完整的比较样本——基础电信运营商（网络与云底座）、城市投资发展集团（土地、电力、机房与带宽存量资产）、地方数据集团（公共数据与场景组织能力）、数据交易所（交易组织与合规鉴证能力）、地方政府（政策工具与财政资源）。不同禀赋决定了不同的切入方式，也决定了不同的风险：以存量基础设施资产再打包为主的模式，其现金流依赖于词元流量的持续增长；以交易组织为主的模式，其价值依赖于交易凭证被政策与市场认可的程度。第 10 章将以比较制度分析展开这一议题，第 13 章将做跨案例比较。

4.7.2 政策工具的转向：从「建算力」到「用词元」

与运营组织同步演进的是财政与产业政策工具。2026 年 6 月，广东印发全国首份省级词元经济专项政策，提出到 2027 年底基本形成全省统筹、差异化布局、一体化协同的词元经济发展格局；2026 年 8 月初，北京经济技术开发区发布聚焦词元全产业链的系统性支持政策，每年发放亿元级券金；此后北京、四川、海南、江苏、湖北、贵州等地密集布局。在地方工具层面，一个细微但关键的变化是补贴基准的转移：扬州早在 2024 年 5 月即在江苏率先推出算力券，对企业在市级算力平台采购智能算力按实际支付额给予 30% 补贴、单个主体年度最高 200 万元；2026 年 7 月则推出词元券。算力券与词元券的补贴对象与计量基准并不相同，不可当作同一政策的延续来解读。

这一转向的经济含义远超工具形式的更替。补贴「建算力」时，财政资金的核定基准是设备投资额，其计量依托的是既有的固定资产投资统计体系；补贴「用词元」时，核定基准变成了词元消耗量，而这一量迄今没有统一的计量标准、没有权威的核验主体、没有可审计的凭证。财政资金的合规性要求与计量制度的缺位由此直接冲突。更严重的是激励扭曲：若按物理词元数量核定补贴，企业将有动机采购单价低、效值也低的词元以最大化「补贴可核定量」，政策目标（推动人工智能深度应用）与政策效果（刺激低效值词元的采购）因此发生背离。这正是本书主张以标准词元作为补贴核定基准的直接理由。国家层面的政策框架已为此预留了接口：数据要素价值释放的行动部署（「国家数据局等，2023」）与「人工智能+」行动的推进要求（国务院，2025），均把可计

量、可核验的数据与智能服务作为落地前提，而全国数据资源调查亦已建立起对数据要素生产与流通的年度观测（「国家数据局，2026」）。

4.7.3 标准供给的现状与国家标准的缺位

制度化的第三条线索是标准。截至 2026 年 8 月，词元领域的标准供给呈现「团体标准与机构评估先行、国家标准与行业标准缺位」的格局。已发布的成果包括：归口于中国人工智能产业发展联盟的团体标准《人工智能词元（Token）运营管理能力要求》（技术规范编号 AIIA/T 0308—2026，2026 年 8 月发布），旨在建立统一的词元运营管理平台能力规范；中国信息通信研究院的《人工智能 Token 服务质量能力要求》及据此开展的可信 AI-Token 服务质量评估，覆盖模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度；同院于 2026 年 6 月 16 日发布的高质量 Token 服务标准体系，涵盖服务质量、运营能力、生产能力、安全能力四个维度；中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》构建的生产成本、生产效率、准确性、生态价值、安全五维价值度量体系；以及清华大学翟季冬团队联合企业于 2026 年 5 月发布的开源模型 Token 服务性能榜，采用首词元时延（P90 分位）、输出吞吐与缓存命中率三项实测指标。四套工作各有明确主体、维度与用途，维度名称不可合并、平均或交叉引用。

产业侧还出现了以基线为抓手的推进机制。中国信息通信研究院于 2026 年 6 月启动词元服务能力攀登计划，首批联合十家企业达成的企业级通用场景词元服务性能基线为吞吐不低于每秒 55 枚词元、首词元时延不高于 0.9 秒、调用成功率 99.9%；同月，由该院牵头、联合二十余家单位筹备成立词元服务工作组。需要提醒的是，攀登基线是首批参与企业达成的能力水平，既不是行业平均值，也不是强制门槛，媒体常误写为「行业标准要求」；此外，不同评测中的首词元时延指标所取分位数不同，两个数值接近的时延指标未必可比。

把上述成果放在标准效力的层级上观察，结论是清晰的：目前词元领域只有团体标准与机构评估规范，尚无国家标准或行业标准。团体标准由社会团体制定，其效力层级低于行业标准与国家标准；机构评估是符合性评估活动，其依据文件才是标准，通过评估的企业名单不构成标准清单；「Token 计量计费」目前只是评估体系中的一个维度，而非独立的计量标准文本。在国家标准层面，词元相关工作归口于全国信息技术标准化技术委员会及其人工智能分技术委员会，已有术语与大模型系列国家标准计划，但尚未检索到以词元计量或词元计费为标题

的国家标准或行业标准计划。碳足迹方面同样存在空白：截至 2026 年 8 月，尚未见面向词元的专项碳足迹核算标准发布或立项公开，相关工作目前挂靠在产品碳足迹管理体系（国家市场监督管理总局和国家标准化管理委员会，2024；生态环境部等，2024）与算力中心能效核算之下，而设施级的核算边界与服务级的功能单位之间并不能相互折算。

标准缺位的经济后果可以用信息经济学的经典结论概括。当质量不可观测而价格可观测时，市场会向低质量方向逆向选择（Akerlof，1970）；解决之道是引入可信的质量披露与第三方认证机制，使质量信息在交易前即可被验证（Dranove 和 Jin，2010）。词元市场当前正处于这一困境：买方无法在事前核验所购词元的效值，只能依据单价决策，其结果是价格竞争压倒质量竞争。已有的六维、四维、五维评价与三项实测指标，正是产业界对这一困境的回应，它们确立了「词元有质量差异」的行业共识，其贡献不容低估。但它们的共同限度在于停留于多维评价：并列的维度得分可以回答「谁家的词元服务更好」，却无法回答「一枚甲档位的词元等于几枚乙档位的词元」。而后一个问题才是价格指数编制、财政补贴核定、增加值核算与跨境互认所必需的。本书需要再次声明：本书使用的算力强度、推理质量与场景效用三维折算体系是作者自主构建的理论框架，与上述任何机构的评价体系均无对应关系，也不得被指称为任何机构的既有成果。绿色金融统计标准的国际比较经验表明，统计标准的国际互认往往滞后于市场实践并成为跨境流通的实际瓶颈（陈丹丹等，2025），词元领域应当尽早避免重蹈这一路径。

据此可归纳典型事实七：词元的制度化在 2026 年进入密集期，城市级运营与交易组织、省级与开发区级专项政策、团体标准与机构评估同时涌现，补贴基准由「建算力」转向「用词元」；但支撑这一切的国家层面计量标准仍然缺位——目前只有团体标准与评估规范，没有国家标准或行业标准，也没有面向词元的碳足迹核算标准。制度供给的「上层活跃、地基空缺」，是词元经济当前最具风险的结构特征。

4.8 本章小结

本章以口径纪律为前提，沿需求、供给、场景、价格、算力、效率与制度七条线索刻画了词元经济的发展格局，并提炼出七条典型事实。在需求侧，我国日均词元调用量两年间增长约 1400 倍，年化对数增长率 3.62、倍增周期约 70 天，增长虽在减速却仍维持数量级级别的扩张；然而这一指标迄今只有四个官方锚点，没有固定频率、固定口径与固定主体的统计制度，国际上亦无可比口径。

在供给侧，模型服务市场的集中度由 0.34 降至 0.21，开放权重路线快速扩张，竞争焦点由模型能力转向词元产能，「词元工厂」作为新型产能形态出现，标志着算力的价值实现方式由「租算力」转向「卖词元」；但可用于刻画份额的高频数据仅来自第三方路由平台，其覆盖面不足全国总量的一个量级。

在场景结构上，用量与应用数量的偏离指数达 0.62，智能体与编程类应用以 19% 的应用数量消耗了 81.2% 的词元，集中倍率 4.3 倍；用量集中的方向与场景价值密度的高低方向一致，说明市场已在自发地把词元配置到替代价值最高的用途，但这一配置是在缺乏统一效值尺度的条件下完成的。在价格上，物理词元的表观单价两年半内累计下降 79%、年均下降约 50%，而同一时点上不同档位的单价相差 35 倍，折算为标准词元后收敛至 3.1 倍；价格观测并存至少四套互不相通的口径，缓存状态、时段、语言与上下文长度均已成为价格结构的组成部分，峰谷分时定价的出现更表明词元价格已开始承载算力的时段稀缺信息。表观降幅因此不能被直接解读为真实降价，其分解留待第 7 章完成。

在算力与效率上，我国智能算力规模保持年均近八成的高速增长，形成东部为主、西部快速追赶的空间格局，但至少存在三套精度基准、统计对象与时点均不同的算力口径；以式(4-3)的供给侧恒等式作量级核算可知，同期词元调用量的年化增速约为算力规模增速的两倍，残差年化约 1.04，其中混合了转化效率改进、利用率提升、算力用途结构变化与统计边界差异四类因素，在现有数据条件下无法精确分离。企业智算资源利用率集中于 51%—70% 的中等区间，达到 70% 以上者不足三分之一；而名义利用率并不能反映被占用的算力是否用于生产高效值词元——扣除空转 18%、批次 9%、匹配 12% 与效值 7% 四项相对损失后，有效效值利用率仅 38%。在制度上，2026 年成为词元制度化的密集期，城市级运营与交易组织、省级与开发区级专项政策、团体标准与机构评估同时涌现，补贴基准由「建算力」转向「用词元」，但国家层面的计量标准仍然缺位。

把七条典型事实合起来看，可以清晰地读出一条贯穿全章的主线：词元经济在规模、供给、应用与制度四个层面均已高速扩张，唯独在计量层面仍近乎空白。需求侧只有四个锚点，供给侧只有平台探针，价格侧有四套口径，算力侧有三套口径，利用率有三种含义，标准侧只有团体规范。规模的爆发与计量的稀薄之间的落差，不是统计工作的技术性滞后，而是本书核心命题的现实投影：物理词元不是合格的价值单位，因而以物理词元为基础的一切统计、定价与政策工具都难以自洽。补贴基准从设备投资额转向词元消耗量这一转变，把这一矛盾推到了公共财政的门口——当财政资金必须按词元核定时，「一枚词元值多少」就不再是学术问题，而是合规问题。

本章的事实也为后续各章提供了具体的经验约束与检验基准。第 5 章的效值折算体系必须能够解释本章观察到的档位间价格倍差与场景价值密度差异，其标定所依托的用量结构即来自本章刻画场景分布；第 6 章的价值创造与实现分析将以本章的场景结构为出发点；第 7 章的三层定价结构与价格指数编制，直接以本章 4.4 节的表观价格事实与口径分裂为待解释对象；第 8 章的市场结构分析将从本章的集中度演化与多归属特征切入；第 9 章的转化效率与配置优化，其问题正是本章 4.5、4.6 两节留下的残差与损失；第 10 章的城市词元运营中心机制设计，其经验素材来自本章 4.7 节的组织涌现；第 12 章的增长核算则需要本章确认的调用量序列作为过程观测变量。至此，本书的问题（第 1 章）、理论基础（第 2 章）、属性分析（第 3 章）与经验格局（第 4 章）已全部就位，下一章将转入全书的理论核心：构建标准词元的效值折算体系，回答「异质词元如何折算为可比、可加的标准计量单位」这一贯穿全书的根本问题。

第5章 标准词元：效值折算体系的构建

第3章以效值三维的经验离散、单价与效值的系统性对应以及加总偏误的形式化，证明了本书的核心前提：物理词元不可加，因而不能承担价值单位的职能。第4章进一步表明，这一计量缺陷并非学理上的洁癖，而是正在造成现实代价——按国家数据局口径，我国日均词元调用量已由2024年初的1000亿枚增至2025年6月底的30万亿枚、2025年底的100万亿枚，2026年3月突破140万亿枚，两年增长约1400倍；与此同时，城市级词元运营组织密集设立、财政工具由「建算力」转向「用词元」，而支撑这一切的计量地基却仍是一个不可加的物理计数。第2章2.3节已经把标准煤、标准箱与二氧化碳当量的当量折算传统抽象为「一个基准、一条刻度」的一般形式，并指出词元折算相对于这一传统的根本特殊性在于刻度函数无法由单一物理量担任。本章的任务，就是把那里给出的预览兑现为完整的理论构造：建立标准词元的效值折算体系。

有两点立场需要在开篇即予澄清，因为它们决定了本章全部论证的性质。第一，本书的三维效值折算体系是作者自主构建的理论框架，既不源自也不对应任何机构已发布的评价体系；本书在与既有工作对话时逐一注明主体与维度数，正是为了避免把作者的构造误植于他人名下，或把他人的维度名称混入本书的折算函数。第二，本书相对既有工作的理论增量是从多维评价推进到当量折算。如第3章3.4.5节所检视，截至2026年8月与词元度量直接相关的成体系工作有四套：中国信息通信研究院《人工智能Token服务质量能力要求》及据以开展的可信AI-Token服务质量评估（六个维度，用于服务质量的符合性评估）、中国信息通信研究院于2026年6月16日发布的高质量Token服务标准体系（四个维度，用于标准框架搭建）、中国工业互联网研究院《Token驱动智能经济研究报告（2026年）》构建的价值度量体系（五个维度）、清华大学翟季冬团队联合清程极智发布的开源模型Token服务性能榜（三项实测指标）。四套工作的共同贡献是把「词元有质量」确立为行业共识并提供了可操作的评价与实测手段；其共同限度则在于，它们产出的是并列的维度得分或达标基线，可以回答「这家服务好不好」，却无法回答「一枚这里的词元等于几枚那里的词元」。而后一个问题才是价格指数编制、补贴核定、跨区统计与增长核算所必须回答的：并列的维度得分既不能相加，也不能被写进任何账户。

本章安排如下：5.1节把不可比问题形式化，界定折算问题的一般表述，并论证为什么四项经济职能要求的是折算而非评价；5.2节界定算力强度、推理质量与场景效用三个维度，给出各自的测度口径、数据基础与测度纪律；5.3节完

成折算函数的公理化——提出基准归一、严格单调、可加性与传递一致四条公理，证明在这组公理下折算函数存在且形式唯一，并以常替代弹性型折算函数为参照说明公理四的识别力；5.4 节给出折算系数的估计策略，包括基准档选择、基准任务集与实测效值的构造、权重的约束对数最小二乘标定及四项稳健性检验；5.5 节报告六档位模型的效值测算结果，以离散度收敛与传递一致性两项判据检验折算体系的有效性，并考察市场价格是否已内生地为效值定价；5.6 节把标准词元与标准煤、标准箱、二氧化碳当量三项成熟当量体系逐维比较，提炼共同结构与关键差异；5.7 节为本章小结。

5.1 从不可比到可折算：问题的形式化与折算的必要性

5.1.1 不可比问题的形式化：价值密度的异质与加总的失效

不可比问题的实质，是「同名之物具有不同的价值密度」。要把这一直觉转化为可操作的命题，需要先给出词元流的形式化描述。设词元的属性空间为 $X \subset (0, +\infty)^3$ ，其中的一点 $x = (P, R, S)$ 刻画一枚词元在算力强度、推理质量与场景效用三个维度上的位置；某一时期经济体中生成的全部词元构成 X 上的一个测度 μ ， $d\mu(x)$ 表示属性位于 x 邻域内的词元数量。设 $v(x)$ 为属性 x 的词元所承载的单位价值（价值密度），则物理词元总量与价值总量分别为：

$$T = \int_X d\mu(x), V = \int_X v(x) d\mu(x), \frac{V}{T} = E_\mu[v(x)] \quad (5-1)$$

其中， T 为物理词元总量， V 为价值总量， $E_\mu[\cdot]$ 为按词元数量分布 μ 取的期望； V/T 即平均价值密度。

式(5-1)以最简洁的方式陈述了三条判断。其一，物理计数只有在价值密度恒定时才是价值度量。当且仅当 $v(x) \equiv v_0$ 在 μ 的支撑集上几乎处处成立时， $V = v_0 T$ ，物理总量与价值总量只差一个常数因子，此时以 T 作为计量单位是无害的。第 3 章的经验证据已经否定了这一前提：六档位模型的算力强度相差 38.2 倍、推理质量相差 6.7 倍、市场单价相差 35 倍，价值密度的离散不是可忽略的噪声，而是数量级意义上的结构性差异。其二，价值总量的变动可以完全脱离物理总量的变动。对式(5-1)取全微分可知， V 的变动由两部分构成：一是词元数量 μ 的变动（规模效应），二是 μ 在属性空间上分布形状的变动（结构效应）。在技术快速迭代、模型档位结构剧烈漂移的时期，结构效应可以与规模效应同量级甚至反向，这意味着以物理调用量刻画的「增长」与真实的智能生产能力增长之间没有稳定的映射。其三，平均价值密度本身是内生的。 $E_\mu[v(x)]$ 依赖于 μ ，而 μ 又由价

格、补贴与考核规则塑造；一旦以物理总量为考核标的，理性主体的最优反应就是把 μ 向低价值密度区域迁移，从而使 V/T 内生下降——这正是第3章推论三所述的古德哈特效应在计量层面的表达。

需要强调的是，价值密度 $v(x)$ 的不可观测性，与其说是测度技术的暂时不足，不如说是词元这类认知产品的固有属性。词元的价值实现于下游任务的完成度之中，而任务完成度只有在使用之后才能被评估，事前不可验证；买方在购买时能够观测的只有价格与数量，无法观测质量，这是典型的质量不可观测市场结构（Akerlof，1970）。质量披露与第三方认证之所以在这类市场中具有福利改进的潜力，正是因为它把事后才可验证的信息前置为事前可观测的信号（Dranove 和 Jin，2010）。本书测算显示，企业对所购词元效值的认知偏差均值达 0.44，由此导致低效值档位的过度采购份额达 0.27——这一经验事实说明，词元市场的信息问题已经从理论可能变为可观测的资源错配。

5.1.2 折算问题的一般表述：当量函数与一价定律

既然价值密度异质不可消除，可行的出路就只能是当量折算：不取消异质，而是把异质折算到一条公认的刻度上。承接式(2-6)给出的一般形式，词元折算问题可以严格表述为：在属性空间上寻找一个折算函数（当量函数） $\eta: X \rightarrow (0, +\infty)$ ，使得以基准属性 x_0 的词元为单位的当量总量具有价值可加性。形式化地：

$$\eta(x) = \frac{v(x)}{v(x_0)}, \tilde{T} = \int_X \eta(x) d\mu(x) = \frac{V}{v(x_0)}, \tilde{p}(x) = \frac{p(x)}{\eta(x)} \equiv \tilde{p}_0 \quad (5-2)$$

其中， x_0 为基准属性（基准档模型在基准任务上的词元）， $\tilde{T}$ 为标准词元总量， $p(x)$ 为属性 x 的词元单价， $\tilde{p}_0$ 为标准词元的统一价格；第三式即折算后应当成立的一价定律。

式(5-2)包含了折算体系的三个构成要件，它们也构成本章后续各节的工作清单。要件一是基准： x_0 的选定使当量单位获得名义，「1枚标准词元」由此有了确切所指。由式(2-6)的基准无关性可知，更换基准只会使全部折算系数按同一比例缩放，不改变任何相对结构，因而基准的选择带有约定成分，其标准是可稳定性与可解释性而非唯一正确性——这正如 1 千克标准煤对应的低位发热量 29307 千焦并不对应任何一种真实煤种（国家市场监督管理总局和国家标准化管理委员会，2020）。要件二是刻度：折算函数 η 的函数形式与参数，是全章的技术核心，5.3 节以公理化方法解决形式问题，5.4 节以标定方法解决参数问题。要件三是口径：折算必须明确适用的时点、任务边界与观测层次，否则同一枚词元在不同口径下会得到不同的当量，折算体系本身将成为新的不可比来源。

式(5-2)的第三式尤其值得强调，因为它把一个理论构造转化为可证伪的经验判据。如果折算函数正确地捕捉了价值密度的跨属性差异，那么以折算后单价 $\tilde{p}=p/\eta$ 衡量，不同档位、不同来源的词元价格应当向同一水平收敛；反之，若折算后价格离散不降反升，或残余离散仍保持原有量级，则说明折算函数遗漏了价值密度的主要来源。这一判据在思想上与特征价格方法同源：特征价格方法把商品价格分解为各特征的隐含价格，从而把质量变化从价格变化中分离出来（Griliches，1961）；在新产品频繁进入退出、质量快速改进的市场上，若不作质量调整，价格指数会系统性高估通胀、低估真实产出（Pakes，2003；Erickson 和 Pakes，2011）。词元折算与特征价格方法的区别在于目标不同：后者的目标是求得「质量不变的价格」，前者的目标是求得「价格不变的质量当量」，二者互为对偶。本章建立的效值折算体系，正是第 7 章编制标准词元价格指数的前置条件。

5.1.3 为什么必须是折算而非评价：四项经济职能的计量要求

一个自然的质疑是：既然已有四套多维评价体系可以刻画词元的质量，为何还要多此一举地合成为单一当量？回答这一质疑，需要回到本书的核心命题——标准词元须承担价值尺度、定价基准、配置信号与增长核算变量四重经济职能，而这四重职能对计量提出的要求，恰恰是并列维度得分无法满足的。

价值尺度职能要求可加性。尺度的第一属性是能把不同对象放在同一条轴上比较大小并求和；一个由六个分数构成的向量无法比较大小，除非事先给定权重——而给定权重恰恰就是合成，只不过把合成的责任推给了使用者，其代价是每个使用者的权重不同，可比性随即消失。定价基准职能要求可传递性。价格的形成依赖于套利：若甲对乙的折算率、乙对丙的折算率与甲对丙的折算率不一致，套利者可以通过折算路径的选择获取无风险收益，价格体系将无法收敛。评价体系没有折算率概念，因而也谈不上传递一致。配置信号职能要求边际量可算。第 9 章的任务一模型最优匹配需要计算「每单位算力可产出多少有效标准词元」，这要求折算函数可微且边际替代率有定义；并列得分不构成可微对象。增长核算职能要求可入账。第 12 章要把标准词元流量作为生产要素写入生产函数并估计产出弹性 α_T ，被解释变量必须是一个标量流量；六维得分无法进入任何一个国民经济核算账户，正如数据资源要进入企业报表必须先被确认与计量（财政部，2023；罗玫等，2023），统计体系要反映数字化转型也必须先解决新对象的可核算性（杨仲山和张美慧，2019；许宪春等，2021）。

把这四项要求合起来看，可以得到一个更一般的判断：评价解决的是「好不好」的问题，折算解决的是「值几枚」的问题，二者的输出类型不同，不能相互替代。这一区分在标准化的经济学文献中有清晰的对应。标准的经济价值来自兼容性与网络外部性——统一的接口与度量使分散的主体得以互操作，从而扩大市场规模并降低缔约成本（Farrell 和 Saloner，1985；Katz 和 Shapiro，1985）；标准的制定过程本身是一种共识治理，其效率取决于参与者的激励结构与协调机制（Simcoe，2012）。国内经验研究亦显示，物流标准化通过降低交易费用显著提升了企业全要素生产率（何凡等，2025），这为「计量标准化—交易费用—生产率」的传导链条提供了直接证据。词元领域目前的标准供给状况恰好印证了折算的缺位：已发布的规范性成果主要是团体标准与机构评估规范，尚未见以词元计量或词元计费为标题的国家标准或行业标准立项公开，而团体标准的效力层级低于行业标准与国家标准，评估认证活动亦不等同于标准本身。折算体系的建立，正是从评价走向标准、从标准走向账户的关键一环。

本章的整体构造如图 5.1 所示：物理词元经三维效值测度进入折算函数，折算函数在四条公理约束下取幂积形式并由基准任务集标定权重，输出效值系数与标准词元当量，进而向定价、配置与核算三个方向提供接口，而三个方向的应用又反过来对基准任务集与权重的再标定提出要求，构成闭环。




图 5.1 标准词元效值折算体系的构建框架

图 5.1 的框架有三点设计意图需要说明。其一是「测度—合成—输出」的三段式分工。测度段解决各维度怎么量的问题，属于工程与评测的范畴，本书充分借重既有评测方法与实测数据；合成段解决各维度怎么合的问题，属于经济学的范畴，是本书的贡献所在；输出段解决合成结果怎么用的问题，决定了折算体系的价值最终由下游应用检验。三段之中，唯有中段是既有工作留下的空白。其二是公理约束的位置。四条公理不是在合成之后附加的性质检验，而是在合成之前施加的形式约束——正是这组约束把无穷多种可能的合成方式收缩为唯一的函数形式，从而使折算体系不依赖于构造者的主观偏好。这一点是本章方法论上最重要的自我要求：若折算函数的形式可以任意选择，那么任何折算结果都只是一种意见，而非一个计量结论。其三是反馈回路的必要性。词元的技术形态处于快速演化之中，基准任务集与权重都不可能一次标定终身适用；框架右侧的反馈通道意味着折算体系必须是一个可更新的动态制度，其更新规则本身也需要被制度化，这一点将在 5.6 节与第 14 章的政策建议中展开。

5.2 三维效值：界定、测度与数据基础

5.2.1 维度选择的逻辑：投入侧、产出侧与价值侧

折算函数的第一步是确定刻度维度。维度过少会遗漏价值密度的主要来源，维度过多则会引入共线与冗余，并使标定所需的观测急剧增加。本书选择三个维度，其依据不是经验拟合的便利，而是一条经济学上的完备性论证：一枚词元的价值密度，必然同时受到「它耗费了什么」「它产出了什么」与「它用在哪里」三重决定，缺一不可。

算力强度 P 刻画投入侧。它度量生成单枚词元所耗浮点运算量相对基准的倍数，直接承接第3章式(3-1)与式(3-2)给出的单词元算力函数。投入侧维度不可省略的理由是：在竞争性供给条件下，价格的下界由成本决定，而词元的成本几乎完全由算力耗费决定；忽略 P 的折算体系将无法解释价格地板的存在，也无法与第7章的三层定价结构衔接。推理质量 R 刻画产出侧。它度量单枚词元承载的有效信息量与任务达成度相对基准的倍数。产出侧维度不可省略的理由是：投入不等于产出，同样的算力耗费可能生成高度冗余的输出；仅以 P 折算，等于把低效率的冗长生成奖励为高价值，这与经济学的基本直觉直接冲突。场景效用 S 刻画价值侧。它度量应用场景的价值密度，即单位任务所替代的人类认知劳动的价值。价值侧维度不可省略的理由是：词元的价值实现于场景之中，同一枚技术属性完全相同的词元，用于科研分析与用于闲聊问答，其经济意义相差悬殊——第3章3.2.3节已把场景依赖性列为词元区别于传统当量对象的最特殊属性。

三个维度之间存在相关但不共线的关系，这是折算可行的技术前提。高档位模型通常同时具有更高的算力强度与更高的推理质量，但二者的增长速度并不同步：本书校准的六档位数据显示，算力强度的档位间倍差达38.2倍，而推理质量的倍差仅6.7倍，场景效用的倍差更小，仅3.2倍。这一「投入侧离散远大于产出侧离散」的格局本身就是重要的经济事实：它说明模型能力谱系上存在显著的边际报酬递减，也说明任何仅从质量评测出发的折算方案都会遗漏最主要的离散来源。规模律研究为这一格局提供了技术解释——模型性能随参数量、数据量与计算量呈幂律增长，指数显著小于1（Kaplan等，2020），计算最优的参数—数据配比进一步刻画了给定算力预算下的最优模型形态（Hoffmann等，2022）；幂律指数小于1，正是「算力涨十倍、质量涨不到一倍」的数学表达。

5.2.2 算力强度 P：投入侧刻度及其可调度性

算力强度的测度必须回答一个技术问题：单枚词元的浮点运算量并非常数，它随上下文长度、缓存命中率与批处理策略而变。第 3 章式(3-2)已给出任务 j 在模型 m 下的总算力消耗 $\Phi_m(j)$ ，它同时包含预填充与解码两个阶段、并显式包含缓存命中率 h_j 。据此，档位 m 的算力强度定义为基准任务集上单位输出词元算力消耗的加权比值：

$$P_m = \frac{\sum_{j \in J_0} \omega_j \Phi_m(j) / \ell_{mj}^{out}}{\sum_{j \in J_0} \omega_j \Phi_0(j) / \ell_{0j}^{out}} \quad (5-3)$$

其中， J_0 为基准任务集， ω_j 为任务 j 在基准任务集中的权重且 $\sum_j \omega_j = 1$ ， ℓ_{mj}^{out} 为模型 m 完成任务 j 的输出词元数，下标 0 表示基准档； $P_0 = 1$ 由定义直接成立。

式(5-3)的三个设计细节值得说明。第一，以输出词元数而非请求数为分母。这保证 P 的量纲是「每枚词元的算力」而非「每次请求的算力」，与折算对象的层次一致。第二，分子与分母各自按任务加权后再取比值，而非逐任务取比值再加权。前者度量的是「完成同一组任务的总算力之比」，后者度量的是「各任务算力比的平均」，在任务规模差异悬殊时两者可以相去甚远；前者才符合当量折算的可加性要求。第三， $\Phi_m(j)$ 取设计值而非某次实现值。推理系统的工程优化会显著改变实际算力消耗：分页式键值缓存管理大幅提高显存利用率与并发能力（Kwon 等，2023），连续批处理把请求级调度细化到迭代级（Yu 等，2022），分块预填充在吞吐与时延之间重新配平（Agrawal 等，2024），预填充与解码的分离部署进一步降低了阶段间的相互干扰（Zhong 等，2024），注意力算子的输入输出感知实现则直接削减了显存读写开销（Dao 等，2022），大规模并行推理的切分策略亦对单位成本有系统影响（Pope 等，2023）。这些优化属于第 9 章讨论的转化效率 θ 范畴，若把它们计入 P ，同一模型在不同服务商处会得到不同的效值系数，折算体系将失去跨主体可比性。因此本书作出明确的口径划分： P 度量模型的技术属性，工程实现的效率差异归入转化效率 θ ，二者在第 9 章相遇。

5.2.3 推理质量 R：产出侧刻度与信息密度原则

推理质量维度最容易被误解为「模型评测得分」。二者有本质区别：评测得分度量的是模型完成任务的能力，而效值折算需要的是单枚词元承载的能力。一个模型若以三倍的输出长度换取略高的任务达成度，其评测得分更高，但每枚词

元的价值密度反而更低。据此，推理质量定义为基准任务集上单位输出词元任务达成度的加权比值：

$$R_m = \frac{\sum_{j \in J_0} \omega_j q_{mj} / \ell_{mj}^{out}}{\sum_{j \in J_0} \omega_j q_{0j} / \ell_{0j}^{out}}, q_{mj} \in [0, 1] \quad (5-4)$$

其中， q_{mj} 为模型 m 在任务 j 上的达成度评分，取值区间为 $[0, 1]$ ，客观题以正确率计、开放式任务以评判打分归一化后计；其余记号同式(5-3)。

式(5-4)体现的原则可以概括为信息密度原则：折算奖励的是「用更少的词元把事情办成」，而不是「用更多的词元把分数刷高」。这一原则有三重经济含义。其一，它使折算体系内生地抑制冗长生成——在按词元计费的商业模式下，供给方存在延长输出以增加计费量的激励，信息密度原则使这种行为在当量口径下不但无利可图，反而会降低效值系数。其二，它使 R 与 P 的经济含义严格对偶： P 是「每枚词元的成本投入」， R 是「每枚词元的价值产出」，二者共同决定了词元的技术性价比。其三，它使折算结果对分词器差异具有稳健性——不同分词器对同一文本的切分粒度不同，跨语言的词元计数差异尤为显著（Rust等，2021；Petrov等，2023；Ahia等，2023），而式(5-4)的分子分母同时含有 ℓ^{out} ，切分粒度的系统性差异在比值中被部分抵消。

q_{mj} 的可测度性依托于近年评测方法的成熟。大规模多任务语言理解基准提供了跨学科的知识与推理测度（Hendrycks等，2021），整体性评估框架把准确性、鲁棒性、效率与公平性等多项指标并置并强调评测情景的完备性（Liang等，2022），模型互评与人类偏好对齐的评判方法则为开放式任务提供了可扩展的打分手段（Zheng等，2023）。需要指出的是，这些评测工作的目标是模型比较与能力诊断，其输出是并列的分项得分；本书调用的只是其中的达成度测量技术，合成规则则由本章的公理体系给出，二者不可混同。此外，实测性能数据同样构成 R 与后续 θ 测度的基础：清华大学翟季冬团队联合清程极智于2026年5月发布的开源模型Token服务性能榜，实测三十余家服务商与四个主流开源模型，其三项核心指标为首词元时延（P90分位）、输出吞吐与缓存命中率——这些是服务性能指标，属于第9章转化效率的测度基础，不直接进入 R ，本书在引用时严格区分二者的主体与用途。

5.2.4 场景效用 S ：价值侧刻度与社会平均口径

场景效用是三个维度中最具经济学色彩、也最需要谨慎处理的一维。它的界定基础是替代关系：词元之所以有价值，是因为它替代了原本需要由人完成的认

知劳动。据此，场景 j 的效用系数定义为单位任务所替代的人类认知劳动价值相对基准场景的倍数，档位 m 的场景效用则为其实际用量在各场景上的加权：

$$S_j = \frac{\kappa_j w_j \tau_j}{\kappa_0 w_0 \tau_0}, S_m = \sum_{j \in J_0} \omega_{mj} S_j, \sum_{j \in J_0} \omega_{mj} = 1 \quad (5-5)$$

其中， τ_j 为完成单位任务 j 所需的人工工时， w_j 为相应岗位的单位时间报酬， $\kappa_j \in (0, 1]$ 为价值可占有系数（所替代劳动价值中可由词元服务方与使用方共同占有的份额）， ω_{mj} 为档位 m 的词元在场景 j 上的用量份额；下标 0 为基准场景。

式(5-5)的构造回应了三个可能的质疑。质疑一：场景效用是否属于词元的属性？严格说，场景属于使用者而非词元本身。但计量单位的刻度依据本来就不必是被计量对象的内在属性——二氧化碳当量的刻度是全球增温潜势，那是气体在大气系统中的效应而非气体分子的内在属性（「WRI 和 WBCSD，2011」；「ISO，2018」）。折算刻度的选择标准是「与折算目的相关且可稳定测度」，而非「内在」。质疑二：价值可占有系数 κ_j 如何避免任意性？ κ 的经济含义是所创造价值中能够被交易双方占有的份额，其余部分溢出为消费者剩余与社会收益；本书以场景层的支付意愿与实际成交价的比值估计 κ ，并在 5.4.4 节以其取值区间做稳健性检验。质疑三：以人工工时与报酬为基准是否会把折算体系绑定于特定的劳动力市场？这正是本书坚持社会平均口径的原因： w_j 取相应岗位的社会平均单位时间报酬而非某企业的实际薪酬， τ_j 取行业平均而非某个体的熟练程度，从而使 S 刻画的是社会必要的认知劳动价值密度，而非某一主体的特殊情况。

τ_j 与 w_j 的测度有相对成熟的文献基础。职业与任务层面的人工智能暴露度测度提供了任务可替代性的系统刻画（Felten 等，2021；Eloundou 等，2024）；随机实验与准实验证据给出了具体任务上生产率提升的量级——写作类任务的完成时间显著缩短、质量同步提升（Noy 和 Zhang，2023），客服场景的现场实验显示问题解决效率明显改善且对新手的边际效果最大（Brynjolfsson 等，2025）；对人工智能重构中等技能岗位的分析则强调了任务重组而非整体替代的现实路径（Autor，2024）。这些研究共同支持了一个操作性结论：任务层的替代工时是可测的，且不同任务之间差异极大。本书校准的场景价值密度显示，科研分析与合规审查类场景的单位词元价值密度远高于文案生成与客服对话类场景，最高与最低场景之间相差数倍——这一离散正是 S 维度存在的经验理由，其完整刻画将在第 6 章展开。

5.2.5 测度口径、数据基础与三条测度纪律

三个维度的界定、测度口径与数据基础汇总于表 5.1。表中特别标注了各项测度所依托的既有工作及其主体，以确保本书的构造与他人的成果之间边界清晰。

表 5.1 三维效值的界定、测度口径与数据基础

维度	符号	经济学定位	测度口径	数据基础与方法	归一基准
算力强度	P	投入侧刻度：决定成本地板与价格下界	基准任务集上单位输出词元浮点运算量的加权比值，见式(5-3)	模型结构参数与上下文长度推算的单词元算力函数（式 3-1、式 3-2）；取设计值，工程实现差异归入转化效率	中型通用级 = 1
推理质量	R	产出侧刻度：决定质量梯度与效应溢价	基准任务集上单位输出词元任务达成度的加权比值，见式(5-4)	多任务知识与推理基准、整体性评估框架、模型互评打分等达成度测量技术；按信息密度原则以输出词元数作分母	中型通用级 = 1
场景效用	S	价值侧刻度：决定场景租金与配置方向	单位任务所替代人类认知劳动价值的加权比值，见式(5-5)	任务层暴露度测度与生产率实验给出的替代工时；岗位社会平均报酬；场景层支付意愿与成交价之比估计可占有系数	基准场景 = 1
合成效值系数	η	当量刻度：决定标准词元当量与折算后价格	三维经幂积折算函数合成，见式(5-7)	基准任务集实测效值以约束对数最小二乘标定权重，见式(5-11)、式(5-12)	中型通用级 基准任务 = 1

注：表中「数据基础与方法」列所述测量技术分属不同主体的既有工作，本书仅调用其达成度与性能测量技术，合成规则由本章公理体系给出；三维合成为单一当量的折算体系系作者自主构建，不对应任何机构已发布的评价体系。式(3-1)、式(3-2)见第 3 章。资料来源：作者构建。

表 5.1 的口径设计贯彻了三条测度纪律，它们是折算结果可信的前提。纪律一：同任务集原则。三个维度的测度必须在同一个基准任务集 J_0 上完成，且任务权重 ω_j 保持一致；若 P 在一组任务上测、 R 在另一组任务上测，合成结果将没有任何经济含义。纪律二：同时点原则。模型迭代与价格调整的频率极高，三维测度与后续价格观测必须锁定同一时点窗口；本书全部效值测算与价格对照均以 2026 年第二季度为口径。纪律三：任务锚定而非词元锚定原则。由于分词器差异，同一任务在不同模型下的词元计数本身就不可比，因此折算的基本单位必须是「完成同一任务」而非「消耗同样数量的词元」；式(5-3)至式(5-5)的分母中一律出现 ℓ^{out} ，正是为了把任务锚定贯彻到底。这三条纪律看似技术细节，实则决定了折算体系能否经受第三方复核——一个无法被独立复现的折算体系，无论其理论多么优美，都不具备成为计量标准的资格。

5.3 折算函数的公理化：四条公理与形式唯一性

5.3.1 四条公理及其经济含义

维度既定，剩下的问题是合成规则。合成规则的选择空间在原则上是无穷的：算术平均、几何平均、调和平均、各类加权组合乃至任意的单调变换都可以充当合成函数。若不加约束地从中挑选，折算结果就只是构造者的一种意见。本书的方法论选择是：不直接指定函数形式，而是先陈述折算体系必须满足的经济性质，再证明满足这些性质的函数形式是唯一的。四条公理如下：

$$\eta(1,1,1)=1; \frac{\partial \eta}{\partial P} > 0, \frac{\partial \eta}{\partial R} > 0, \frac{\partial \eta}{\partial S} > 0; \tilde{T} = \sum_{m=1}^M \eta_m T_m; \eta(P_1 P_2, R_1 R_2, S_1 S_2) = \eta(P_1, R_1, S_1) \eta(P_2, R_2, S_2) \quad (5-6)$$

其中，四式依次为公理一（基准归一）、公理二（严格单调）、公理三（可加性）与公理四（传递一致，亦称链式一致）； M 为档位数， η_m 与 T_m 分别为档位 m 的效值系数与物理词元量。

公理一（基准归一）要求基准档在基准任务上的一枚物理词元恰为一枚标准词元。它的作用是给当量单位以名义，并使折算系数具有「相对于基准的倍数」这一直观解释。这条公理看似平凡，却排除了一类常见的合成方式——把各维得分标准化到 $[0,1]$ 区间后加权求和。此类合成的取值范围固定，无法表达「某档位是基准档的 4 倍」这样的当量关系，只能表达排序，因而不是折算而是评分。公理二（严格单调）要求三个维度上的改进都必须提高效值系数。它排除了各维之

间出现补偿性反转的可能，保证折算体系与技术进步的方向一致：任何使模型更强、更省、更有用的改进，都不应当被折算体系惩罚。公理三（可加性）要求折算后的当量可以直接相加。这是当量折算区别于多维评价的根本标志，也是标准词元能够进入价格指数、财政核定与增长核算的前提；一旦可加性不成立，「全国日均标准词元流量」这样的宏观变量就无法定义。

公理四（传递一致）是四条公理中最具技术力量、也最容易被忽略的一条。它要求折算具有链式一致性：若档位甲相对档位乙的三维倍数为 (P_1, R_1, S_1) 、档位乙相对基准的三维倍数为 (P_2, R_2, S_2) ，那么由甲直接相对基准折算的结果，必须等于「甲→乙→基准」分两步折算的结果之积。这条公理的经济必要性有三重。其一是防套利。若折算路径不同则结果不同，套利者可以在折算路径的选择中获取无风险收益，标准词元的价格体系将无法收敛，第7章的价格指数与第8章的市场均衡都将失去基础。其二是可分解。技术进步往往分阶段发生，一次模型升级可以分解为若干次能力提升的叠加；传递一致保证了「先算总账」与「分步累加」得到相同结果，从而使效值的时序变化可以被分解归因。其三是跨主体可核验。不同机构以不同的中间参照物开展折算时，只要三维测度一致，结果必然一致，折算体系由此具备了作为公共计量基础设施的资格。

5.3.2 命题 5.1：折算函数的存在性与形式唯一性

四条公理的力量在于，它们把无穷维的函数选择空间压缩为一个三参数族。这一结论以命题形式陈述如下。

命题 5.1（折算函数的存在性与形式唯一性） 设折算函数 $\eta: (0, +\infty)^3 \rightarrow (0, +\infty)$ 连续，且满足式(5-6)所列公理一、公理二与公理四，则 η 必为幂积形式，即存在唯一的正实数组 (w_P, w_R, w_S) 使得：

$$\eta(P, R, S) = P^{w_P} R^{w_R} S^{w_S}, w_P, w_R, w_S > 0 \quad (5-7)$$

其中， w_P 、 w_R 、 w_S 为三维效值的权重，同时也是效值系数对各维度的常数弹性；公理三（可加性）在此形式下自动成立。

证明。先证必要性。作变量替换 $u_1 = \ln P$ 、 $u_2 = \ln R$ 、 $u_3 = \ln S$ ，并定义 $h(u) = \ln \eta(e^{u_1}, e^{u_2}, e^{u_3})$ ，其中 $u = (u_1, u_2, u_3) \in \mathbb{R}^3$ 。由 η 连续且取值恒正， h 在 $\mathbb{R}^3$ 上连续。公理四中三个维度的乘法在对数尺度上化为加法，故对任意 $u, u' \in \mathbb{R}^3$ 有 $h(u+u') = h(u) + h(u')$ ，即 h 满足三元柯西可加函数方程。柯西方程的连续解必为线性齐次函数，故存在实数组 (w_P, w_R, w_S) 使 $h(u) = w_P u_1 + w_R u_2 + w_S u_3$ 。取指数还原即得式(5-7)。再由公理二， $\partial \eta / \partial P = w_P \eta / P > 0$ ，而 $\eta > 0$ 、 $P > 0$ ，故 $w_P > 0$ ；同理

$w_R > 0$ 、 $w_S > 0$ 。公理一 $\eta(1,1,1)=1$ 在幂积形式下自动满足，不构成额外约束，但它保证了基准的存在性与折算系数的规范化。参数的唯一性由线性表出的唯一性直接给出：若两组权重给出同一函数，则其差在 R^3 上恒为零，故对应分量相等。再证充分性：幂积形式显然连续、对各维严格单调递增、在 $(1,1,1)$ 处取值为1，且满足乘性可分解，故式(5-6)的公理一、二、四全部成立；而在给定各档位效值系数后， $\tilde{T} = \sum_m \eta_m T_m$ 为定义式，公理三成立。证毕。

命题 5.1 的意义需要在方法论层面加以强调。第一，它把折算函数的形式问题从「选择」变成了「推论」。折算体系的设计者不再需要为「为什么用几何平均而不用算术平均」辩护——答案是：算术平均不满足公理四，因而不可能成为当量折算函数。这使折算体系摆脱了主观性质疑，具备了成为公共计量规则的形式资格。第二，它把标定的任务收缩为三个参数。无穷维的函数形式问题被压缩为三维的参数标定问题，且三个参数还受 $\sum w=1$ 的进一步约束（见 5.3.4 节），实际自由度仅为 2。这使得在观测有限的条件下进行可靠标定成为可能。第三，它给出了一个可证伪的形式预测。若真实的价值密度关系并非幂积形式，那么以幂积函数拟合基准任务集实测效值将出现系统性偏误；5.4 节与 5.5 节报告的拟合优度与残差结构，正是对这一预测的检验。

5.3.3 常替代弹性型折算函数与公理四的识别力

为凸显公理四的识别力，不妨考察一个更一般的候选形式——常替代弹性（CES）型折算函数：

$$\eta_\rho(P, R, S) = (w_P P^\rho + w_R R^\rho + w_S S^\rho)^{1/\rho}, \eta_\rho(P, R, S) \rightarrow P^{w_P} R^{w_R} S^{w_S} (\rho \rightarrow 0) \quad (5-8)$$

其中， $\rho \in (-\infty, 1]$ 为替代参数，替代弹性为 $1/(1-\rho)$ ；权重满足 $w_P + w_R + w_S = 1$ ； $\rho \rightarrow 0$ 时该形式退化为加权几何平均，即式(5-7)的幂积形式。

式(5-8)是一个极具启发性的参照系。它满足公理一、公理二与公理三，却唯独不满足公理四——除非 $\rho=0$ 。这一点可以直接验证：当 $\rho \neq 0$ 时， $\eta_\rho(P_1 P_2, R_1 R_2, S_1 S_2)$ 无法分解为 $\eta_\rho(P_1, R_1, S_1)$ 与 $\eta_\rho(P_2, R_2, S_2)$ 之积，因为幂和运算不具有乘法可分解性。换言之，在整个 CES 族中，唯有退化为幂积的那一个成员能够充当当量折算函数。这一发现有三重含义。其一，它说明公理四具有极强的识别力：仅凭这一条公理，就把一个连续统的候选形式筛至一点。其二，它揭示了「可替代」与「可折算」的区别：CES 形式允许三个维度以有限的替代弹性相互替代，这在生产函数语境中是合理的，但在当量折算语境中，有限替代弹性会破坏折算路径的一致性，从而使当量失去尺度资格。其三，它提供了一条独立的经

验检验路径：若把折算函数放宽为 CES 形式并独立标定 ρ ，那么公理体系预言 $\hat{\rho}$ 应当在统计上不可区别于零。

这一检验的结果是支持性的。以基准任务集实测效值独立标定 CES 型折算函数，得替代参数 $\hat{\rho} = 0.0794$ ，在统计上无法拒绝 $\rho=0$ 的原假设；两种形式给出的效值系数在六个档位上的最大相对差异仅 1.61%。这意味着：由纯粹的公理推论所得到的函数形式，与由数据独立标定所得到的函数形式高度一致。理论推论与经验标定的相互印证，是折算体系可靠性的重要证据——它表明幂积形式并非为了数学便利而作的假设，而是同时得到公理与数据双重支持的结论。

5.3.4 权重和为一：一次齐次性、弹性解释与价格对偶

命题 5.1 给出了幂积形式，但未对权重之和作出限制。本书进一步施加 $w_P + w_R + w_S = 1$ 的归一化约束，其依据是折算体系必须满足的比例一致性：当三个维度同比例提升 λ 倍时，效值系数也应恰好提升 λ 倍。这一性质与三条重要推论一并表述如下：

$$\eta(\lambda P, \lambda R, \lambda S) = \lambda \eta(P, R, S) \Leftrightarrow w_P + w_R + w_S = 1; \frac{\partial \ln \eta}{\partial \ln P} = w_P; \tilde{p} = \frac{P}{\eta}, \tilde{T} \tilde{p} = T P \quad (5-9)$$

其中，第一式为一次齐次性与权重归一化的等价关系，第二式为权重的弹性解释（对 R 、 S 同理），第三式为价格对偶关系，第四式表明折算不改变名义支出总额。

式(5-9)的四个结论构成了折算体系的核心性质集合。一次齐次性保证了尺度不变。若 $\sum w < 1$ ，则当全行业能力普遍提升时，折算体系会系统性低估效值增长，标准词元流量将被人为压缩；若 $\sum w > 1$ 则相反，会把普遍的技术进步放大记入。唯有 $\sum w = 1$ ，折算体系才对整体技术进步保持中性，这与当量单位应当只承担「换算」而不承担「评价」的定位一致。弹性解释使权重具有可交流的经济含义。 w_P 即效值系数对算力强度的常数弹性：算力强度提高 1%，效值系数提高 0.4383%；等价地，算力强度翻倍带来效值系数提升 35.5%，推理质量翻倍带来提升 22.8%，场景效用翻倍带来提升 20.2%。这一表述可以直接进入政策讨论，无需读者理解幂积函数的数学结构。

价格对偶关系是折算体系与定价体系的接口。由 $\tilde{p} = P/\eta$ 可知，标准词元价格是物理词元价格的效值调整值；第 7 章的三层定价结构、词元价格指数与标准词元价格指数的编制，全部建立在这一对偶关系之上。支出恒等式 $\tilde{T} \tilde{p} = T P$ 则保证了折算的会计中性。折算改变的是量与价的分割方式，不改变名义支出总额，因而不会在核算体系中凭空创造或消灭价值。这一性质对统计实务至关重要：它意

意味着折算可以作为一道「质量调整」工序嵌入现行核算流程，而不必重构支出侧的账目结构。事实上，这正是价格指数编制中量价分解的标准做法（Groshen 等，2017；Redding 和 Weinstein，2020）——把名义支出的变动分解为价格变动与数量（质量调整后）变动两部分，标准词元折算所做的，是为词元这一新对象补上此前缺失的质量调整环节。

5.4 折算系数的估计策略：基准、标定与稳健性

5.4.1 基准档的选择：约定性、可稳定性与可解释性

折算体系的第一个操作决策是基准档的选择。由式(2-6)的基准无关性可知，更换基准只会使全部折算系数按同一比例缩放，不改变任何相对结构与结论，因而基准选择在理论上是约定性的。但约定并非任意，一个好的基准应当同时满足三项实务标准。其一是用量代表性。基准档应在实际用量中占有显著份额，以使「1枚标准词元」对应一种普遍存在的服务形态。本书校准的2026年各档位用量份额显示，中型通用级占34%，为六档位中最高。其二是技术稳定性。基准档的技术形态应当相对稳定，不因个别产品的迭代而剧烈变动，否则基准本身就会成为波动源。中型通用级处于能力谱系的中段，其技术形态由多家供给方共同塑造，稳定性优于两端。其三是可解释性。基准应当位于分布的中部而非端点，以避免大多数折算系数集中于远大于1或远小于1的区间，影响直观理解与政策沟通。综合三项标准，本书以中型通用级模型在基准任务集上的词元为基准，规定其效值系数恒为1。

这一选择与既有当量体系的做法一脉相承。标准煤的基准是低位发热量29307千焦每千克，它是一个规范值而非任何一种真实煤种的实测值（国家市场监督管理总局和国家标准化管理委员会，2020）；标准箱的基准是20英尺集装箱，而实际运输中40英尺箱的使用更为普遍；二氧化碳当量的基准是二氧化碳，而它并非增温潜势最高的温室气体（「WRI和WBCSD，2011」；「ISO，2018」）。三个成熟体系都表明：基准的价值在于其被普遍接受与长期稳定，而非其在某种意义上「最优」。因此本书主张，标准词元的基准一经确立，除非发生根本性的技术形态变迁，不宜频繁更换；确需更换时，应同时发布新旧基准的换算比例并对历史序列作链式接续，其做法与价格指数的基期轮换完全一致（Erickson和Pakes，2011）。

5.4.2 基准任务集与实测效值：等效替代率的构造

权重标定需要一组被解释变量，即各档位的「实测效值」。本书不以任何主观赋分构造这一变量，而是以等效替代率定义之：在规定的质量水平下，档位 k 完成基准任务集所需的物理词元量与基准档所需量之比的倒数，即：

$$\eta_k^{obs} = \left[\sum_{j \in J_0} \omega_j \frac{T_{kj}}{T_{0j}} \right]^{-1}, T_{kj} = \min \{ T : q_{kj}(T) \geq \dot{q}_j \} \quad (5-10)$$

其中， T_{kj} 为档位 k 在任务 j 上达到规定质量水平 $\dot{q}_j$ 所需的最小物理词元量， $q_{kj}(T)$ 为投入 T 枚词元时的达成度； η_k^{obs} 即「1枚档位 k 词元相当于几枚基准档词元」的实测替代率。

式(5-10)的构造有三点值得注意。第一，它是纯行为口径的。实测效值不依赖于任何关于价值的主观判断，只依赖于「完成同一件事各需多少词元」这一可观测事实；这使折算系数的标定与价格数据完全独立，从而使5.5.3节以价格检验折算结果的做法不构成循环论证。第二，它与标准煤的等热值替代逻辑同构。标准煤折算问的是「多少千克这种煤相当于1千克标准煤」，等效替代率问的是「多少枚这种词元相当于1枚标准词元」，二者在结构上完全一致，区别仅在于前者的替代关系由量热仪直接测得、后者需在任务集上实测。第三，质量门槛 $\dot{q}_j$ 的设定是关键口径选择。门槛过低会使低档位模型也能「达标」，从而高估其效值；门槛过高则会使部分档位在任何词元投入下都无法达标，替代率无定义。本书按任务类型分别设定门槛，并在5.4.4节以门槛的上下浮动做稳健性检验。

基准任务集 J_0 的构造遵循代表性与稳定性两项原则。代表性要求任务集在场景结构上近似于实际用量分布，覆盖知识问答、文案生成、代码生成、智能设计、质检识别、合规审查与科研分析等主要场景；稳定性要求任务集中的任务具有明确的达成度判据且不易被针对性优化。任务权重 ω_j 按各场景的实际词元用量份额设定，从而使实测效值反映真实使用结构而非评测偏好。需要指出，任务集的公开与否是一个两难：公开可提高可复现性，却会诱发针对任务集的过度优化；不公开可避免过度优化，却损害可核验性。本书主张采用「公开构造规则、轮换具体样本」的折中方案——这一安排与评测领域应对基准污染的通行做法一致，也与第14章建议的国家计量标准设计相衔接。

5.4.3 权重标定：约束对数最小二乘及其闭式解

有了三维测度与实测效值，权重标定即化为一个带线性约束的最小二乘问题。对式(5-7)取对数，折算函数在对数尺度上是线性的，故以对数残差平方和为目标函数：

$$\hat{w} = \arg \min_w \sum_{k=1}^K \left(\ln \eta_k^{obs} - z_k' w \right)^2 \text{ s.t. } 1' w = 1, z_k = (\ln P_k, \ln R_k, \ln S_k)' \quad (5-11)$$

其中， $w = (w_P, w_R, w_S)'$ 为待标定权重向量， z_k 为档位 k 的三维对数效值向量， K 为标定样本量， 1 为元素全为 1 的三维列向量；约束条件即式(5-9)的一次齐次性要求。

式(5-11)是等式约束下的线性最小二乘问题，其解可由拉格朗日方法闭式给出：

$$\hat{w} = \hat{w}_{LS} + (Z'Z)^{-1} 1 \frac{1 - 1' \hat{w}_{LS}}{1' (Z'Z)^{-1} 1}, \hat{w}_{LS} = (Z'Z)^{-1} Z' y \quad (5-12)$$

其中， Z 为以 z_k' 为行的设计矩阵， y 为以 $\ln \eta_k^{obs}$ 为元素的列向量， $\hat{w}_{LS}$ 为不施加约束的普通最小二乘解；第二项即约束偏离量沿 $(Z'Z)^{-1} 1$ 方向的投影修正。

以 1240 个档位—任务—时点观测标定式(5-11)，得权重估计 $w_P = 0.4383$ 、 $w_R = 0.2964$ 、 $w_S = 0.2653$ ，三者之和为 1；基准任务集实测效值的拟合优度 $R^2 = 0.9996$ ，对数尺度 $R^2 = 0.9997$ ，均方根误差为 0.0261。权重结构本身就是一个值得解读的实证结果。算力强度的权重最高，接近全部权重的四成四，这与 5.2.1 节指出的「投入侧离散远大于产出侧离散」相互印证：在效值的跨档位差异中，资源耗费的贡献最大。推理质量与场景效用的权重相近，分别约占三成与二成七，二者合计超过五成六，说明效值并非成本的同义反复——若 w_P 接近 1，折算体系就退化为成本折算，标准词元将等同于「标准算力」，从而丧失作为价值单位的独立意义。三个权重都显著为正且量级相当，这为三维设定提供了直接支持：没有任何一维可以被删去而不显著恶化拟合。

5.4.4 稳健性：不确定性传播、传递一致性与形式检验

折算系数是后续各章的基础输入，其不确定性必须被明示而非被隐藏。由式(5-7)在对数尺度上的线性性，效值系数估计量的不确定性可由权重估计量的协方差矩阵直接传播：

$$Var(\ln \hat{\eta}_k) = z_k' Var(\hat{w}) z_k, \hat{\eta}_k \exp \left[\pm z_{\alpha/2} \sqrt{z_k' Var(\hat{w}) z_k} \right] \quad (5-13)$$

其中， $Var(\hat{w})$ 为约束最小二乘估计量的协方差矩阵， $z_{\alpha/2}$ 为标准正态分布的分位数；第二式为效值系数的对数正态型置信区间。

式(5-13)有一个直观而重要的含义：效值系数的不确定性随档位偏离基准的程度而放大。 z_k 是档位 k 的三维对数效值向量，档位越偏离基准， z_k 的范数越大，方差也越大。这意味着基准附近的折算最为可靠，而对两端档位——尤其是推理增强级与轻量蒸馏级——的折算需要更审慎地报告区间。这一性质并非本折算体系的缺陷，而是所有当量体系的共性：外推总是比内插更不确定。它对实务的启示是，若某地区的词元结构高度集中于极端档位，其标准词元总量的置信区间应当相应放宽。

除不确定性传播外，本书还实施了四项稳健性检验。检验一是传递一致性的数值验证。链式折算与直接折算之差在幂积形式下为机器精度量级（判据的形式定义见 5.5.2 节），本书实测的最大传递误差不超过 10^{-14} 量级，可加性与传递性同时成立。这一结果是形式推论的必然结果，报告它的意义在于确认数值实现无误。检验二是函数形式的放宽检验，即 5.3.3 节报告的 CES 标定， $\hat{\rho} = 0.0794$ 无法拒绝零假设。检验三是基准更换检验。分别以开源旗舰级与轻量蒸馏级为基准重新标定，全部效值系数按同一比例缩放，权重估计与相对结构保持不变，验证了基准无关性。检验四是口径扰动检验。将质量门槛 $\hat{q}_j$ 上下浮动、将场景可占有系数 κ_j 在合理区间内变动、将基准任务集按场景重抽样，权重估计的变动均未改变三维权重的排序与量级。四项检验共同支持一个判断：折算体系的核心结论不依赖于任何单一的口径选择。幂积拟合值与实测效值的最大相对误差为 2.9%、平均相对误差为 1.0%，其量级与实测效值本身的测量误差相当。

5.5 标准词元指数的构建与六档位效值测算

5.5.1 三维效值与合成效值系数

按 5.2 节的口径测度三维效值、按 5.4 节的方法标定权重，即可得到六个档位的合成效值系数。六档位在三个维度上的取值与合成结果如图 5.2 所示。




图 5.2 六档位模型的三维效值与合成效值系数

注：左轴为三维效值 P 、 R 、 S ，右轴为合成效值系数 η ，四者均以中型通用级在基准任务集上的词元为基准归一（ $\equiv 1$ ）；档位系为避免挂靠具体商业产品而设的抽象分类。数据来源：作者依基准任务集校准复算。

图 5.2 呈现的结构有三点值得解读。第一，三条柱的高度差异随档位系统性扩大。在轻量蒸馏级一侧，三维取值都低于基准且彼此接近；随着档位上升，算力强度的柱高迅速拉开，推理质量次之，场景效用最为平缓。到推理增强级，算力强度已达基准的 8.4 倍，而推理质量仅为 3.1 倍、场景效用 1.9 倍。第二，合成效值系数的折线位于三条柱之间且更接近产出侧。推理增强级的效值系数为 4.28，远低于其算力强度 8.4——这是权重结构与幂积形式共同作用的结果：幂积（几何平均）相对于算术平均更能抑制单一维度的极端值，从而避免把「算力堆叠」直接等同于「价值创造」。第三，多模态级的位置颇具特色。其算力强度与推理质量均低于旗舰闭源级（3.70 对 4.80、1.88 对 2.35），场景效用却是六档位中最高的（2.15），合成效值系数因而达到 2.62，相当于旗舰闭源级的 89%——远高于其算力强度之比（77%）所暗示的水平。这一「以场景取胜」的形态说明，效值折算体系确实能够识别出与算力规模不同步的价值来源，而这正是三维设定相对于单维成本折算的增量所在。

六档位效值测算的完整结果，连同幂积拟合值、CES 拟合值、市场单价与折算后单价，汇总于表 5.2。

表 5.2 六档位模型的三维效值、实测效值与折算结果（2026 年第二季度）

模型 档位	P	R	S	实测 效值 η	幂积 拟合 值	CES 拟合 值	相对 误差 (%)	市场 单价 (元 /百 万物)	标准 词元 单价 (元 /百)	转化 效率 θ (万 STE)
----------	---	---	---	--------------------	---------------	----------------	-----------------	-----------------------------	-----------------------------	---------------------------------

								理词 元)	万 STE)	／ PFL OPS ·h)
轻量 蒸馏 级	0.22	0.46	0.68	0.38	0.36 9	0.37 3	2.9	0.40	1.05 3	42.0
中型 通用 级	1.00	1.00	1.00	1.00	1.00 0	1.00 0	0.0	1.30	1.30 0	18.5
开源 旗舰 级	2.60	1.72	1.34	1.96	1.92 9	1.93 5	1.6	3.30	1.68 4	9.2
旗舰 闭源 级	4.80	2.35	1.66	2.94	2.93 1	2.95 5	0.3	7.00	2.38 1	5.4
推理 增强 级	8.40	3.10	1.92	4.28	4.22 6	4.29 4	1.3	14.0 0	3.27 1	3.1
多模 态级	3.70	1.88	2.15	2.62	2.62 1	2.63 1	0.0	5.00	1.90 8	6.8
最高 ／最 低倍 数	38.2	6.7	3.2	11.3	—	—	—	35.0	3.1	13.5

注：P、R、S 与实测效值 η 均以中型通用级为基准归一（ $\equiv 1$ ）；幂积拟合值由式(5-7)与标定权重计算，CES 拟合值由式(5-8)在 $\hat{p} = 0.0794$ 处计算，相对误差为幂积拟合值与实测效值之差的绝对值占实测效值的比重；标准词元单价 = 市场单价 / η ； θ 为单位算力产出的标准词元数，其档位间差异含工程实现因素，详见第 9 章。标定样本量 $N = 1240$ ，拟合优度 $R^2 = 0.9996$ 、对数尺度 $R^2 = 0.9997$ 、均方根误差 0.0261。档位系为避免挂靠具体商业产品而设的抽象分类，各项数值系作者依基准任务集与 2026 年第二季度市场行情校准复算所得，不对应任何特定商业产品。数据来源：作者校准复算。

表 5.2 的信息可以从三个角度读取。从拟合角度看，折算函数的经验表现良好。幂积拟合值与实测效值的最大相对误差为 2.9%，出现在轻量蒸馏级；平均相对误差 1.0%；CES 拟合值与幂积拟合值的最大差异仅 1.61%。三项指标共同说明，式(5-7)不是一个粗糙的近似，而是对实测替代关系的准确刻画。从结构角度看，效值增长显著慢于算力增长。定义效值—算力比 η/P ，其在基准档为 1，而在推理增强级降至 0.51，在旗舰闭源级为 0.61，在轻量蒸馏级则高达 1.73。这一递减序列是模型能力边际报酬递减的直接度量，也解释了为什么「用最强模型做所有事」在经济上不可持续，以及为什么第 9 章的任务—模型最优匹配能够带来可观的效率改进。从价格角度看，折算显著压缩了单价的档位间差异。市场单价的档位间倍差为 35.0 倍，折算后单价的倍差降至 3.1 倍，收窄了约 91%。这一收敛构成下一小节的正式检验对象。

5.5.2 折算有效性的两项判据：内部一致性与外部收敛性

一个折算体系是否有效，不能由构造者自我宣称，必须交由可操作的判据检验。本书提出两项判据：内部一致性判据检验折算体系自身是否自洽，外部收敛性判据检验折算是否达到了消除不可比的目的。二者的形式定义如下：

$$\varepsilon_{tr} = \max_{a,b,c} \left| \frac{\hat{\eta}_c}{\hat{\eta}_a} - \frac{\hat{\eta}_b}{\hat{\eta}_a} \cdot \frac{\hat{\eta}_c}{\hat{\eta}_b} \right|, \Delta_{CV} = 1 - \frac{CV(p/\hat{\eta})}{CV(p)} \quad (5-14)$$

其中， ε_{tr} 为传递一致性误差，取遍任意三个档位 a 、 b 、 c 的链式折算与直接折算之差的绝对值； $CV(\cdot)$ 为变异系数， Δ_{CV} 为折算带来的离散度下降幅度。

内部一致性判据的检验结果是决定性的：本书实测的传递一致性误差 ε_{tr} 不超过 10^{-14} 量级，即机器精度量级。这一结果并非偶然，而是命题 5.1 的必然推论——幂积形式在对数尺度上是线性的，而线性函数的可加性保证了任意折算路径给出相同结果。与之对照，若采用加权算术平均作为合成函数，传递误差将随档位差距扩大而迅速增长，在本书的六档位设定下可达数十个百分点，足以使套利成为可能。这一对照再次说明了公理四的实践价值：它不是形式上的洁癖，而是防止计量体系被套利瓦解的制度屏障。

外部收敛性判据的检验则通过折算前后单位价格的分布对照完成。折算前后的价格离散度对照如图 5.3 所示。




图 5.3 折算前后单位价格离散度的对照

注：(a) 为物理词元单价 p 的分布，(b) 为标准词元单价 $\hat{p} = p/\eta$ 的分布；每档位 40 个服务报价观测、六档位共 240 个观测，纵轴为对数刻度；箱体为四分位区间、横线为中位数、须线为 1.5 倍四分位距、散点为界外值；CV 为变异系数。数据来源：作者校准复算。

图 5.3 给出的对照极为清晰。折算前，六档位的价格箱体沿纵轴阶梯式排列，档位之间几乎没有重叠，全样本变异系数达 0.92；折算后，六个箱体收敛到同一水平带内并大幅重叠，变异系数降至 0.31，离散度下降 66%。其余两项离

散度指标给出一致的结论：基尼系数由 0.47 降至 0.17（下降 64%），P90 与 P10 之比由 12.6 倍收敛至 2.4 倍（下降 81%）。三项指标一致显著收敛，其中变异系数与基尼系数的降幅均约三分之二，说明效值折算确实抓住了价格离散的主要来源——不同档位词元的价格差异，主要不是市场分割或价格歧视的产物，而是价值密度差异的正常反映。

同样重要的是残余离散的解释。折算后仍存在的三成左右的离散并不意味着折算失败，恰恰相反，一个把全部离散消除殆尽的折算体系反而是可疑的，因为那意味着折算函数吸收了本不属于计量范畴的信息。残余离散至少包含四类真实经济信息：服务质量与可用性差异（时延、并发与可靠性）、市场势力差异（供给集中度与议价能力）、合约条款差异（承诺用量、峰谷分时与预留实例）以及区域成本差异（电价、地价与网络成本）。这四类信息正是第 7 章三层定价结构与第 8 章市场竞争分析的对象。折算的目标不是消灭差异，而是把「因价值密度不同而应有的差异」与「因市场摩擦而不应有的差异」分离开来——前者由折算系数解释，后者留给市场分析。

5.5.3 市场是否已在为效值定价：效值—价格对应关系的检验

折算体系的一个深层问题是：它究竟是研究者外加于市场的一套人为规则，还是对市场既有定价逻辑的显性化？回答这一问题的办法，是把效值系数与市场单价放在同一坐标系中考察其对应关系。若市场事实上已在为效值定价，那么各档位的观测点应当沿一条过原点的射线分布，射线的斜率即隐含的标准词元均价；若市场并未识别效值，观测点则应围绕一条水平线随机散布。检验结果如图 5.4 所示。




图 5.4 效值系数与市场价格的对对应关系

注：横轴为效值系数 η ，纵轴为 2026 年第二季度每百万物理词元的市场单价；实线为过原点最小二乘拟合线，其斜率即隐含的标准词元均价；虚线段为各档位相对拟合线的残差。图中标注的两个决定系数含义不同：一为价格对效值的拟合优度，二为式(5-11)标定折算函数时对实测效值的拟合优度，二者不可混同。数据来源：作者校准复算。

图 5.4 的结论是明确的：市场已经在为效值定价。六档位观测点沿一条过原点的射线系统性上升，过原点最小二乘拟合的斜率为 2.62、决定系数为 0.86。斜率的量纲是「元每百万标准词元」，即市场隐含的标准词元均价约为每百万 2.62 元。这一发现具有重要的方法论意义：本书所做的并非发明一套新的定价规则，而是把市场已经在暗中执行的折算逻辑显性化、公理化与制度化。分散在各家平台定价策略中的效值判断，本来就是一种事实上的折算，只是它既不公开、不统一，也不可核验；标准词元体系的贡献，是把这套隐性知识转化为公共计量基础设施。需要强调的是，此处的检验不构成循环论证：由式(5-10)可知，实测效值由等效替代率定义，其标定过程完全不使用价格数据，因而价格与效值的对应关系是一个独立的经验发现。

拟合的残差结构则揭示了效值溢价的失衡。决定系数 0.86 虽高却远非完美：推理增强级的单价高出等比例拟合线 2.80 元，多模态级则低于拟合线 1.85 元。若折算体系完备且市场充分竞争，残差应当只反映随机扰动；系统性偏离则提示两类可能。一是效值维度的遗漏。例如多模态词元的场景效用可能被低估，因为跨模态任务的替代工时测度尚不成熟。二是市场势力与信息不对称造成的溢价失衡。本书倾向于后者：企业对所购词元效值的认知偏差均值达 0.44，在质量不可观测的条件下，高效值供给难以获得应有溢价，而具有品牌与生态优势的供

给方则可能获得超出效值的溢价（Akerlof，1970）。这一残差结构因此具有直接的政策含义：效值信息的公开披露，本身就是一项能够改善市场效率的制度供给——它使买方得以按效值而非按品牌支付，从而把溢价重新锚定于价值密度。第8章将据此讨论词元市场的柠檬化风险与信息披露制度，第14章将把效值披露列入政策建议。

5.5.4 从个体折算到总量指数：标准词元流量的口径与纪律

个体层的折算系数确立之后，总量层的标准词元流量即可按可加性直接构造：把各档位的物理词元量乘以相应效值系数后加总，即得标准词元总量；其与物理词元总量之比，即用量份额加权的平均效值系数。第3章式(3-8)已给出这一构造及其增长率分解，此处不再重复推导，而着重讨论总量指数的使用纪律。以本书校准的六档位用量份额计算，2026年按用量加权的平均效值系数为1.43，即平均而言每一枚物理词元约相当于1.43枚标准词元；据此，国家数据局公布的2026年3月日均140万亿枚物理词元，按标准词元口径约相当于日均200万亿枚。

这一示意换算必须附加三条使用纪律，否则极易被误读。纪律一：官方从未发布标准词元口径的调用量。国家数据局公布的四个锚点——2024年初1000亿枚、2025年6月底30万亿枚、2025年底100万亿枚、2026年3月140万亿枚——全部是物理词元的全国日均调用量；本书的换算所用的份额与效值系数均系作者校准复算的结果，换算值不具有官方性质，不得作为统计数据引用。纪律二：换算比例随结构漂移而变化，不能作为固定系数事后修正历史序列。平均效值系数 η 本身是用量份额的函数，当结构向高效值档位漂移时它上升、反之下降；正确的做法是在计量环节按档位即时折算，而不是对总量事后乘一个固定倍数。纪律三：物理口径与当量口径的增长率不可混用。由式(3-8)可知，两种口径增长率之差恰等于平均效值系数的增长率，在结构快速漂移期这一差额足以改变任何以词元流量为自变量的实证结论。

总量指数的构建还需回应一个技术问题：效值系数本身会随技术进步而变化，指数如何保持跨期可比？本书采用与价格指数编制相同的解决方案——链式接续。即在每个标定期内以固定效值系数计算当期标准词元流量，标定期更替时以重叠期的双口径观测计算接续因子，从而把各期的定基指数链接为连续序列（Erickson和Pakes，2011；Redding和Weinstein，2020）。链式方法的代价是丧失严格的定基可比性，收益是避免了固定权重在长期内的严重失真；在技术迭代速度以月计的词元领域，这一取舍显然应当倾向于链式。第7章编制的

标准词元价格指数将采用同一处理，两者共享标定期与接续规则，以保证量、价两侧口径一致。这一点对第 12 章的增长核算尤为关键：若量的指数与价的指数采用不同的接续规则，名义支出的量价分解将出现系统性缺口。

5.6 与标准煤、标准箱、二氧化碳当量的类比与差异

5.6.1 四类当量体系的共同结构

把标准词元置于当量折算的历史谱系中考察，既能确认其方法论的正统性，也能暴露其特殊困难。标准煤、标准箱、二氧化碳当量与标准词元四类体系的逐维比较见表 5.3。

表 5.3 四类当量折算体系的逐维比较

比较维度	标准煤	标准箱 (TEU)	二氧化碳当量	标准词元 (STE)
基准品	低位发热量 29307 千焦的 1 千克煤（规范 值）	20 英尺标准集 装箱	1 吨二氧化碳	中型通用级模型 在基准任务集上 的 1 枚词元
刻度依据	低位发热量	箱位当量	全球增温潜势	算力强度、推理 质量与场景效用 的加权几何合成
刻度维数	一维	一维	一维	三维合成
刻度的可测性	量热仪直接测 得，争议极小	几何尺寸直接测 得，无争议	由大气化学模型 给出，随评估周 期修订	需在基准任务集 上实测并标定权 重
折算系数的稳定 性	高，随煤种品质 缓慢变化	极高，由箱型标 准锁定	中，随评估报告 更新	低，随模型迭代 快速漂移，须定 期再标定
是否依赖使用场 景	否，一吨标准煤 在各行业等价	否，一个标准箱 与箱内货值无关	否，排放效应与 排放主体无关	是，场景效用维 度显式引入价值 侧差异
主要经济功能	能源消费总量核 算、能耗强度考 核	港口吞吐量、运 力与运价指数的 可比	碳排放总量核 算、配额分配与 碳市场交易	价值尺度、定价 基准、配置信号 与增长核算变量
制度载体	国家标准《综合 能耗计算通则》	国际集装箱标准 与航运统计惯例	国际温室气体核 算标准与国内产 品碳足迹标准	尚无国家标准， 现有成果为团体 标准与机构评估 规范
信息损失	看不见煤与电的 品质与用途差异	看不见箱内货值 与货类	看不见排放的时 空分布与局地影 响	看不见服务质 量、合约条款与 区域成本差异

注：标准煤基准依据《综合能耗计算通则》（GB/T 2589—2020）；二氧化碳当量依据温室气体核算的国际标准与我国《温室气体 产品碳足迹 量化要求和指南》（GB/T 24067—2024）；标准词元一系列作者构建，不对应任何机构已发布的评价体系。资料来源：作者整理。

表 5.3 的前四行揭示了四类体系的共同结构，即第 2 章 2.3.1 节归纳的「一个基准、一条刻度」：基准品定义当量单位的名义，刻度函数定义折算系数的数值，二者共同把不可加变为可加（国家市场监督管理总局和国家标准化管理委员

会，2020）。共同结构之外，四类体系的经济功能也高度同构：当量折算的直接产物是一个新的宏观变量，而新变量往往催生新的市场与新的治理工具。能源消费总量催生了能耗双控制度（姜春海等，2024），碳排放总量催生了碳市场与配额交易（张希良等，2021；蓝虹和杜彦霖，2024），标准箱催生了全球可比的运力与运价体系。标准词元若能确立，其催生的将是词元价格指数、标准词元结算与以效值为基准的财政工具——这一判断构成本书第7章、第10章与第14章的共同前提。

5.6.2 三点关键差异及其方法论后果

共同结构之外，标准词元与三项成熟体系存在三点关键差异，它们既是本章方法论选择的理由，也是折算体系必须长期面对的困难。差异一：刻度的多维性。标准煤的发热量、标准箱的箱位、二氧化碳当量的增温潜势都是被计量对象的单一物理属性，测量方法成熟且争议极小；词元的价值密度却至少同时取决于投入侧、产出侧与价值侧三个互不可约的维度。多维性的直接后果是权重必须被标定而非被观测——这是词元折算区别于标准煤折算的本质所在，也是本章以公理化方法约束函数形式、以基准任务集标定权重的根本原因。若不作公理约束，多维合成的任意性将使折算结果沦为意见；若不作实测标定，权重将沦为主观赋值。

差异二：折算系数的内生漂移。标准煤的折算系数随煤种品质缓慢变化，标准箱的折算系数由箱型标准锁定而近乎恒定，二氧化碳当量的增温潜势随评估报告的更新而修订、周期以年计（「WRI 和 WBCSD，2011」；「ISO，2018」；国家市场监督管理总局和国家标准化管理委员会，2024）。词元的效值系数却随模型迭代快速漂移，其变化周期以月计。这一差异带来两项方法论后果。其一，折算体系必须内置更新机制：固定系数在词元领域必然迅速失效，因而基准任务集的轮换、权重的再标定与指数的链式接续必须制度化为常规工作，而非一次性研究。其二，折算与被折算对象之间存在反馈：一旦效值系数进入定价与补贴规则，供给方就有激励沿着提高效值系数的方向调整技术路线，这既是折算体系发挥配置引导作用的机制，也是其可能被策略性操纵的风险来源。防范之道在于任务集的轮换与披露规则的设计，本质上与评测领域应对基准污染的思路一致。

差异三：场景依赖性。一吨标准煤在钢厂与在电厂具有相同的当量，一个标准箱装载黄金或装载砂石同样计为一个标准箱；而同一枚技术属性完全相同的词元，用于科研分析与用于闲聊问答，其经济意义相差悬殊。本书通过显式引入场

景效用维度S来处理这一特殊性，但必须承认，这一处理带来了三项成熟体系所没有的争议空间：场景的划分标准、可占有系数的估计以及社会平均口径的确定，都比发热量的测定更依赖于判断。本书的应对是把这些判断全部前置为可公开、可复核的口径规则（见表 5.1 与 5.4.2 节），并在 5.4.4 节以口径扰动检验报告其影响。这一处理不能消除争议，但能把争议限定在可讨论的范围内——这正是计量标准相对于主观评价的核心优势。

5.6.3 制度化路径的启示

三项成熟体系的制度化历程对标准词元具有直接启示。启示一：计量标准的确立通常滞后于交易规模的爆发，但滞后过久将付出效率代价。标准煤、标准箱与二氧化碳当量都是在相应交易规模显著扩张之后才被确立的，这符合计量标准作为公共品的供给逻辑——只有当交易规模足以摊薄标准制定的固定成本时，标准供给才在经济上可行（Simcoe, 2012）。词元领域已经跨过了这一门槛：日均调用量两年增长约 1400 倍、城市级运营组织密集设立、财政工具开始以词元为标的，计量标准的缺位正在成为约束条件而非可容忍的暂时状态。启示二：标准的效力层级决定其经济功能的边界。目前词元领域已发布的规范性成果主要是团体标准与机构评估规范，尚未见以词元计量或词元计费为标题的国家标准或行业标准立项公开。团体标准可以支撑行业自律与市场化认证，却难以支撑财政补贴核定与政府统计——后者需要国家标准层级的计量规则。这一层级差距，正是本书第 14 章建议加快标准词元计量国家标准研制的根本理由。

启示三：当量体系的生命力来自其向账户与市场的延伸。能源消费总量之所以成为最重要的宏观变量之一，是因为它进入了能耗强度考核与能源统计账户；碳当量之所以具有制度力量，是因为它成为配额分配与履约核销的计量基础（张希良等，2021；段玉婉等，2023）。标准词元若仅停留于学术构造，其价值将十分有限；唯有当它进入价格指数、进入财政补贴核定、进入统计报表与增长核算，其经济功能才真正实现。这也是本书后续各章的任务分工：第 7 章把标准词元接入价格体系，第 9 章接入配置体系，第 10 章接入财政与运营体系，第 12 章接入增长核算体系。当量折算的最终检验，不在于其数学形式是否优美，而在于它是否能被写进账户、被用于结算、被纳入考核。顺带指出，绿色词元的界定同样以标准词元为分母：本书以每千标准词元的二氧化碳当量排放定义碳强度，2026 年用量加权平均碳强度为 $2.263 \text{ gCO}_2\text{e}/\text{千标准词元}$ ，绿色词元阈值取 $1.0 \text{ gCO}_2\text{e}/\text{千标准词元}$ ——若无标准词元这一分母，碳强度指标将因词元异质而不可比，绿色词元认证也就无从谈起，这一点将在第 11 章展开。

5.7 本章小结

本章构建了全书的计量地基——标准词元效值折算体系，完成了从「物理词元不可加」这一诊断到「标准词元可加、可比、可入账」这一解决方案的理论跨越。全章的工作可以概括为五个递进的步骤：形式化问题、界定维度、公理化函数、标定参数、检验结果。

在问题形式化上，本章以属性空间上的测度与价值密度函数刻画词元流，证明物理计数只有在价值密度恒定时才是价值度量，而价值总量的变动可以完全脱离物理总量的变动；进而把折算问题严格表述为寻找一个当量函数，使折算后的单位价格满足一价定律。这一表述的意义在于，它把「折算是否成功」变成了一个可证伪的经验问题，而非一个见仁见智的判断。本章还论证了为什么四项经济职能要求的是折算而非评价：价值尺度职能要求可加性、定价基准职能要求可传递性、配置信号职能要求边际量可算、增长核算职能要求可入账，而并列的维度得分无一满足。在维度界定上，本章给出算力强度、推理质量与场景效用的三维设定，分别对应投入侧、产出侧与价值侧，并论证三者缺一不可；三个维度的测度口径分别以基准任务集上的单位输出词元算力、单位输出词元达成度与单位任务替代的人类认知劳动价值定义，并贯彻同任务集、同时点与任务锚定三条测度纪律。

在函数公理化上，本章提出基准归一、严格单调、可加性与传递一致四条公理，证明了命题 5.1：连续、严格单调、基准归一且链式一致的折算函数必为幂积形式，且参数唯一。证明的关键是把三维乘法在对数尺度上化为加法，从而归结为柯西可加函数方程的连续解。这一结果把无穷维的函数选择空间压缩为三参数族，使折算体系摆脱了主观性质疑。本章进一步以常替代弹性型折算函数为参照，指出该族中唯有退化为幂积的成员满足公理四，从而凸显了传递一致公理的识别力；并施加权重和为一的归一化约束，据此得到一次齐次性、权重的弹性解释、价格对偶关系与支出恒等式四条核心性质。在参数标定上，本章以等效替代率定义实测效值，使标定完全独立于价格数据；以约束对数最小二乘标定权重并给出闭式解，得 $w_P = 0.4383$ 、 $w_R = 0.2964$ 、 $w_S = 0.2653$ ，拟合优度 $R^2 = 0.9996$ ；并以不确定性传播、传递一致性验证、基准更换与口径扰动四项检验确认结论的稳健性。

在结果检验上，本章报告了六档位模型的效值测算：效值系数由轻量蒸馏级的 0.38 升至推理增强级的 4.28，相差 11.3 倍；幂积拟合与实测效值的平均相对误差仅 1.0%，常替代弹性形式独立标定的替代参数 $\hat{\rho} = 0.0794$ 在统计上无法拒绝为零，理论推论与经验标定相互印证。两项有效性判据的检验结果同样支持

折算体系：传递一致性误差为机器精度量级；折算后单位价格的变异系数由 0.92 降至 0.31、基尼系数由 0.47 降至 0.17、P90 与 P10 之比由 12.6 倍收敛至 2.4 倍，三项指标一致显著收敛，价格分布明显向一价定律靠拢。效值与价格的对应关系检验进一步发现，市场事实上已在为效值定价：过原点拟合的决定系数达 0.86，隐含的标准词元均价约为每百万 2.62 元——本书所做的并非发明新的定价规则，而是把市场已在暗中执行的折算逻辑显性化、公理化与制度化。残差结构则揭示了效值溢价的失衡，为第 8 章的信息披露制度讨论提供了证据。

本章最后把标准词元置于当量折算的历史谱系中，与标准煤、标准箱、二氧化碳当量逐维比较，确认了「一个基准、一条刻度」的共同结构，也提炼出三点关键差异：刻度的多维性使权重必须被标定而非被观测，折算系数的内生漂移要求体系内置更新机制并防范策略性操纵，场景依赖性则要求把价值侧差异显式纳入而非假装其不存在。三点差异共同决定了标准词元折算不可能是一劳永逸的技术工作，而必然是一项需要持续维护的计量制度。

本章的输出将沿三条线索贯穿全书。向定价线索，效值系数与价格对偶关系 $\tilde{p}=p/\eta$ 是第 7 章三层定价结构与词元价格指数、标准词元价格指数编制的前提；本章测得的效值提升幅度，正是第 7 章把表观降价分解为效值提升与真实降价两部分的依据——本书测算显示，2024 年第一季度至 2026 年第二季度物理词元价格指数累计下行 79%，其中约 53% 来自效值提升、约 47% 为真实降价。向配置线索，效值系数是第 9 章定义有效标准词元与转化效率的基础，本章揭示的效值—算力比递减规律，直接构成任务—模型最优匹配存在效率改进空间的理论依据。向核算线索，标准词元流量是第 12 章智能经济生产函数中的解释变量，其产出弹性 α_r 的识别有赖于本章提供的可加流量口径；若沿用物理词元口径，结构漂移造成的偏误将污染全部估计结果。至此，全书第一项理论创新完成，后续各章的分析将在这一计量地基上展开。

第 6 章 词元的价值创造、实现与增值

第 5 章为本书构筑了计量地基：以算力强度 P 、推理质量 R 、场景效用 S 三维合成效值系数 η ，把异质的物理词元折算为可比、可加的标准词元 $\tilde{T}=\eta T$ ，并证明了在基准归一、单调性、可加性与传递一致性四条公理下折算函数必取幂积形式。折算解决的是「不同的词元如何放在同一把尺子上量」，其直接效果是把六档位单位价格的变异系数由 0.92 压缩到 0.31、极差由 12.6 倍压缩到 2.4 倍。但尺子本身不回答价值问题：一枚标准词元为什么值这些钱？它的价值从哪里来、在哪里兑现、又为什么会随时间自我放大？计量是价值分析的前提，却不是价值分析的替代。本章的任务，就是补上这一层。

把价值问题拆开，可以得到三个相互衔接而性质不同的层面。其一是价值创造：词元在生成端凝结了哪些劳动，这些劳动如何在一枚枚词元上摊薄与转移，从而决定了词元的成本基础与供给侧价值。其二是价值实现：生成完成的词元只是潜在价值，只有当它嵌入具体业务流程、替代或增强了具体的人类认知劳动，潜在价值才转化为现实的使用价值，并在交易中兑现为收入。其三是价值增值：词元经济区别于传统产品经济之处，在于它的价值不是在一次交易中耗尽的——规模复用摊薄了固定成本，使用反馈回流提升了模型能力，主体与场景的增多放大了单位词元的效用，三条路径共同构成一个自我强化的闭环。三个层面对应三种经典价值理论的适用域，也对应本章 6.1、6.2、6.3 三节。

为什么价值分析必须独立成章，而不能并入折算体系？有三条不可避免的理由。第一，效值系数 η 是相对量，其基准档的绝对价值仍需由价值论锚定，否则整套折算只是一组无量纲的比例。第二，也是更关键的一点，效值折算在档位层面吸收的是各档位词元的平均场景效用，而同一档位的词元投放到不同场景，其实现价值仍相差数倍——这部分离散是折算原理上不能消除的，恰恰构成价值实现分析的对象。第三，静态折算无法解释动态事实：我国日均词元调用量由 2024 年初的 1000 亿枚增至 2026 年 3 月的 140 万亿枚，两年增长约 1400 倍（国家数据局口径），如此量级的扩张背后是价值增值机制在起作用，需要一个动态模型来刻画。本章 6.1 节分析价值创造的劳动凝结结构与单位词元的价值构成；6.2 节刻画价值实现的条件、循环与摩擦；6.3 节给出价值增值的三重来源、合成分解与自增强乘数；6.4 节以场景价值密度的实证测算刻画价值实现的离散，并界定效值折算的适用边界；6.5 节为本章小结。

6.1 价值创造：词元中的劳动凝结与成本构成

6.1.1 三种价值理论在认知产品上的接合

词元是一种前所未有的产品：它由机器批量生成，却承载着人类知识的加工与重组；它的单枚生产成本低到可以忽略，累计生产成本却高到需要以百亿元计的固定投入来支撑；它对某些使用者近乎无用，对另一些使用者则可以直接替代高价的专业劳动。任何单一价值理论都难以完整刻画这样的对象，而三种经典价值理论恰好各自抓住了它的一个侧面。

劳动价值论的贡献在于指出价值的实体是凝结的一般人类劳动。词元的生成表面上是机器行为，实质上是物化在模型参数与算力设施中的社会必要劳动的释放：语料的采集、清洗与标注是活劳动，模型架构的设计、训练与对齐是活劳动，芯片、服务器与数据中心则是过去劳动的物化形态。词元的特殊之处在于劳动凝结的时间结构——绝大部分劳动在训练阶段一次性投入并沉没，此后在推理阶段被无限次分摊。这使得「社会必要劳动时间」不能按单枚词元直接测量，而必须经过一次跨期摊销才能落到单位产品上。这一摊销问题是理解词元成本结构的钥匙，也是 6.3 节规模复用机制的起点。

效用价值论的贡献在于指出价值的尺度是边际效用，而效用是主观的、边际递减的、依赖于使用情境的。词元的效用高度依赖场景：同样一万枚标准词元，用于科研分析与用于批量文案生成，其对使用者的价值相差数倍。生成式人工智能的生产率实验证据也支持这一判断——写作类任务的实验显示平均完成时间显著缩短、质量提升（Noy 和 Zhang，2023），客服岗位的现场实验显示效果集中于新手而对熟练者有限（Brynjolfsson 等，2025），职业暴露度研究则表明不同职业任务被语言模型影响的程度差异极大（Felten 等，2021；Felten 等，2023；Eloundou 等，2024）。效用的这种结构性差异无法由供给侧的成本解释，只能由需求侧的场景解释。

信息产品价值论的贡献在于指出信息品的非竞争性与近零边际成本会根本改变价值的实现方式。数据作为非竞争性要素可被无限主体同时使用，其社会最优配置与私人激励之间存在系统性缺口（Jones 和 Tonetti，2020）；数据的价值高度依赖于使用目的与组合方式，因而难以形成统一价格（Bergemann 等，2022；Pei，2022）。国内学者在数据要素的界权、交易与定价上做了大量梳理（熊巧琴和汤珂，2021；欧阳日辉和杜青青，2022），会计学界则推进了数据资源的确认与估值（罗玫等，2023），财政部《企业数据资源相关会计处理暂行规定》已使符合条件的数据资源进入报表（财政部，2023）。词元继

承了信息品的这些特征，但又比数据更进一步：它是被实时生成的、按次计量的、可即刻交付的信息流，因而第一次使非竞争性资产的使用有了一个连续可观测的计数器。

把词元置于生产要素谱系中考察，可以进一步看清其价值论定位。新质生产力的相关讨论强调，新要素的意义不在于其物理形态，而在于它改变了要素组合的方式与效率（周文和许凌云，2023；洪银兴，2024），要素系统的结构承载与功能取向由此重构（黄群慧和盛方富，2024），相应的水平测算也需要建立新的可观测指标体系（韩文龙等，2024）。数据要素的经验研究表明，要素的价值高度依赖于流动与组合的制度条件（蔡跃洲和马文君，2021）；算力要素的研究则显示，智算中心的部署与算力资源的共享安排对企业生产率有直接影响（许诺等，2025；王勇等，2025）。词元的特殊之处在于，它同时是数据要素与算力要素的产物，又是它们进入生产过程的最终形态：数据与算力本身无法被业务流程直接消费，只有转化为词元才能被调用、被计量、被结算。这一「要素的最终形态」定位，决定了词元的价值分析必须同时向上追溯到数据与算力的凝结，向下延伸到场景的转化。

本书的立场是：三种价值理论并非互斥的竞争性解释，而是分别刻画了词元价值的三个环节。劳动价值论刻画创造环节——决定词元的成本基础与供给侧的价值下限；效用价值论刻画实现环节——决定词元在具体场景中能否兑现以及兑现多少；信息产品价值论刻画增值环节——解释为什么词元的单位价值会随累计使用量而系统性改变。三者的接合点正是标准词元：只有在统一的当量口径下，成本、效用与复用才可以被放在同一张资产负债表上讨论。这一分工也决定了本章的展开顺序。

6.1.2 活劳动的三重形态：数据劳动、算法劳动与知识工程劳动

把词元生成过程中的活劳动加以分解，可以识别出三种性质不同、时间结构不同的形态。第一种是数据劳动，指语料的采集、去重、清洗、标注、合规审查与高质量数据集的构建。这类劳动的产出不直接是词元，而是模型训练的原料，其质量直接决定了推理质量 R 的上限。值得注意的是，数据劳动的计量本身就被分词规则所塑造：子词切分与语言无关的分词器设计（Sennrich 等，2016；Kudo 和 Richardson，2018）决定了同一段语义在不同语言下被切分为多少枚词元，跨语言的分词效率差异显著（Rust 等，2021），并进而转化为不同语言使用者面对的实际成本与上下文预算差异（Petrov 等，2023；Ahia

等，2023）。这意味着词元这一计量单位在其技术定义中就嵌入了对不同语言劳动的不等价折算，是本书在场景效用维度中必须加以吸收的技术性偏差。

第二种是算法劳动，指模型架构设计、预训练、微调与价值对齐。规模律研究把这类劳动的产出与算力、数据、参数三者的投入联系起来，给出了损失随规模变化的可预测关系（Kaplan 等，2020），训练算力最优配置的研究则进一步揭示了参数量与训练词元量之间的权衡边界（Hoffmann 等，2022）。这两项工作的经济学含义在于：算法劳动的边际产出不是随机的，而是有规律可循的，因而模型资产的形成过程具备可核算性。算法劳动还包含日益重要的合规与安全环节——生成式人工智能服务管理的制度框架要求对训练数据来源、内容安全与标识承担相应义务（国家互联网信息办公室等，2023），可扩展的输出水印技术（Kirchenbauer 等，2023；Dathathri 等，2024）则把可溯源性内化为生成过程的一部分。这些环节都是实实在在的劳动投入，且会随监管要求的细化而持续增加。

第三种是知识工程劳动，指提示工程、工作流编排、检索增强设计、评测基准建设与效果调优。这类劳动的特点是与推理过程同步发生：模型能力是既定的，但把能力转化为可用产出的路径需要人来设计。大模型的整体性评测框架（Liang 等，2022）、多任务知识基准（Hendrycks 等，2021）与以模型为评判者的自动评测方法（Zheng 等，2023），构成了这一类劳动的方法论基础。在产业实践中，知识工程劳动的强度直接决定了同一档位词元在不同企业中的实际效果差异——这也是 6.2.3 节所讨论的「能力摩擦」的微观来源。

三种活劳动的相对规模与组织形态也在快速变化，这一变化本身具有经济学意义。在模型能力竞争的早期阶段，算法劳动占据主导，数据劳动主要表现为规模化的粗放采集；随着可用公共语料趋于耗竭，数据劳动的重心转向高质量语料的构建与专业领域标注，其单位成本显著上升；而当模型能力在档位内部趋于收敛之后，决定实际产出差异的主导因素又转向知识工程劳动。这一重心迁移解释了一个常被误读的现象：公开评测上的分差在收敛，企业实际使用效果的分差却在扩大。前者度量的是算法劳动的产出，后者度量的是知识工程劳动的产出，二者本就不是同一件事。对政策而言，这意味着提升词元经济效率的着力点正在从「造更强的模型」转向「培育更强的用词元的能力」。

三种活劳动的时间结构差异，是理解词元成本构成的关键。数据劳动与算法劳动前置且高度沉没：它们在词元被生成之前就已完成，其价值只能通过后续的推理量来摊销；知识工程劳动则伴随推理持续发生，是唯一与词元产出同步的活劳动。物化劳动的转移又是第三种时间结构：算力设施的折旧与电力消耗随每一

次推理即时发生，既不能前置摊销也不能事后追加。三种时间结构叠加，构成了下一小节的价值构成式。

6.1.3 物化劳动的转移与单位词元的价值构成

设档位 m 的模型在其生命周期内累计生成 N_m 枚物理词元，训练期凝结的全部活劳动与物化劳动折为模型资产 A_m ，推理期单枚词元的算力折旧与能源消耗为 e_m ，与推理同步发生的知识工程与运维活劳动折为单枚 ℓ_m ，则单位物理词元的价值构成如式(6-1)所示。

$$v_m = \frac{A_m}{N_m} + e_m + \ell_m \quad (6-1)$$

其中，第一项为模型资产的跨期摊销，是训练期沉没劳动在单枚词元上的分担；第二项为物化劳动的即时转移，包含芯片与服务器折旧、电力与冷却消耗；第三项为推理期新投入的活劳动。三项分别对应前置沉没、即时转移与同步投入三种时间结构。

式(6-1)的三项在量级上极不对称，且各自遵循不同的变化规律。摊销项 A_m/N_m 随累计推理量单调下降，是规模复用效应的直接来源；转移项 e_m 受推理系统效率支配，连续批处理（Yu 等，2022）、分页式显存管理（Kwon 等，2023）、分块预填充（Agrawal 等，2024）与预填充—解码分离（Zhong 等，2024）等系统进展在过去数年内成倍压低了单位词元的资源占用，注意力算子的访存优化（Dao 等，2022）与大规模推理的并行切分策略（Pope 等，2023）则从算子与集群两端进一步降低了成本；活劳动项 ℓ_m 反而随使用深度上升，因为越复杂的工作流越需要人来编排与校验。

转移项中的能源部分具有独立的核算意义。按本书测算，六档位每百万标准词元的耗电量由轻量蒸馏级的 0.9 kWh 升至推理增强级的 17.2 kWh，相差 19.1 倍；以电网排放因子折算，用量加权的平均碳强度为 2.263 gCO₂e/千标准词元。生成式模型推理的能耗与碳排放测算已积累了系统的方法学（Patterson 等，2022；Luccioni 等，2023；Luccioni 等，2024），数据中心整体用能的再校准研究（Masanet 等，2020）与国际能源署对人工智能用电的专门评估（IEA，2025）则给出了宏观边界。这些工作共同说明： e_m 不是一个可以忽略的会计尾数，而是随档位快速放大的实质成本项，其详细核算构成本书第 11 章的主题。

摊销项还牵出一个尚未解决的核算问题：模型资产 A_m 在现行会计制度中没有对应的确认科目。数据资源的会计处理已经取得进展，符合条件的数据资源可

作为存货或无形资产入表（财政部，2023），学界对数据资产的确认与价值评估也提出了系统方案（罗玫等，2023）；但模型资产既不是纯粹的数据，也不是通常意义上的软件著作权，其形成过程横跨数据采购、算力消耗、人力投入与算法研发，摊销年限的确定更缺乏经验基础。核算缺口的直接后果是：式(6-1)第一项在企业报表中往往被计入当期费用而非资产摊销，从而在会计口径上高估当期成本、低估资产存量，使词元服务的真实盈利能力被系统性扭曲。本书主张，标准词元的引入恰好为这一摊销提供了自然的分母——以生命周期累计标准词元产出作为摊销基数，既符合式(6-2)的可比性要求，也与产量法折旧的既有会计惯例相衔接。

式(6-1)是按物理词元定义的，因而不可跨档位比较，更不可加总——这正是第3章所证明的不可比性在成本侧的表现。引入效值折算后，单位标准词元的价值与总价值如式(6-2)所示。

$$\tilde{v}_m = \frac{v_m}{\eta_m}, V_t = \sum_{m \in M} v_m T_{mt} = \sum_{m \in M} \tilde{v}_m \tilde{T}_{mt} \quad (6-2)$$

其中， $\tilde{v}_m$ 为单位标准词元的价值， M 为档位集合， T_{mt} 与 $\tilde{T}_{mt} = \eta_m T_{mt}$ 分别为 t 期该档位的物理词元量与标准词元量， V_t 为价值创造总量。

式(6-2)的右端恒等式表明，总价值在两种口径下相等，折算并不凭空创造或消灭价值；但只有标准词元口径下的单位价值 $\tilde{v}_m$ 才具备跨档位可比性。这一命题可以直接用数据检验。以第7章的成本底价层为价值创造侧的可观测代理，六档位每百万物理词元的成本底价由轻量蒸馏级的0.18元升至推理增强级的3.36元，极差达18.7倍、变异系数为0.733；折算为标准词元口径后，六档位每百万标准词元的成本底价收敛于0.47—0.79元的窄区间，极差降至1.66倍、变异系数降至0.176，离散程度下降约76%。

这一结果的理论含义值得强调。物理口径下相差近二十倍的成本，在标准词元口径下相差不到七成，说明各档位的成本差异绝大部分不是「效率差异」，而是「产品差异」——高档位词元之所以贵，主要是因为它单枚承载的效值更高，而不是因为它的生产更浪费。若不做折算而径直比较各档位的单位成本，就会把产品差异误读为效率差异，从而在补贴核定、成本监审与技改评价中得出方向性错误的结论。折算后残留的那部分离散，才是真正意义上的运营效率与市场势力差异，也才是政策应当关注的对象。

如图6.1所示，把上述劳动凝结结构、词元生成过程与标准词元当量三者的关系整体呈现，可以看到价值创造的完整链路。




图 6.1 词元价值创造的劳动凝结结构

图 6.1 的左侧是两类投入。活劳动一侧的数据劳动、算法劳动与知识工程劳动，对应 6.1.2 节的三重形态；物化劳动一侧的算力设施、模型资产与能源投入，对应式(6-1)中的摊销项与转移项。两类投入并不在同一环节进入生成过程：活劳动主要在预训练与对齐阶段凝结为模型资产，物化劳动则在推理阶段随每一枚词元的生成而即时转移。图的中部把生成过程拆为「预训练与对齐—推理生成—效值形成」三步，其中第三步是本书特有的环节：一枚词元的 P 、 R 、 S 三维属性在生成的同时即已确定，这使得价值创造与价值计量在物理上是同一过程的两面。

图 6.1 的右侧给出两个输出。上方是标准词元当量 $\tilde{T} = \eta T$ ，即计量输出；下方是单位标准词元的价值构成，即价值输出。二者的并置揭示了本书的核心方法论：计量与价值不是两件事，而是同一枚词元的两种表述——只有当计量单位本身吸收了效值差异，单位价值才具有跨主体、跨时点比较的意义。这也解释了为什么本书把折算体系置于价值论之前：没有可比的计量，价值分析将失去共同的分母。

6.2 价值实现：从生成到场景的转化链条

6.2.1 生成不等于实现：使用价值的场景生成

词元生成完成的那一刻，其价值仍是潜在的。与实物产品不同，词元没有独立于使用情境的客观效用：一段代码只有被编译、评审并合入生产系统才产生价值，一份合规意见只有被采纳进入决策流程才产生价值，一段客服回复只有真正

化解了用户诉求才产生价值。这意味着词元的价值实现不发生在生成端，而发生在应用端；服务方交付的是能力，使用方完成的才是价值。这一区分在经济学上并不新鲜——它是使用价值与交换价值区分的现代版本——但在词元经济中具有特别的实践后果：调用量的增长不等于价值的增长，词元账单的扩张不等于产出的扩张。

把这一机制形式化。设场景 j 中单位标准词元创造的毛使用价值为 u_j （价值密度），标准词元价格为 $\tilde{p}$ ，该场景消耗的标准词元量为 $\tilde{T}_j$ ，则价值实现的结构如式(6-3)所示。

$$\Pi_j = (u_j - \tilde{p})\tilde{T}_j, \rho_j = \frac{\tilde{p}}{u_j}, \lambda_j = \rho_j^{-1} = \frac{u_j}{\tilde{p}} \quad (6-3)$$

其中， Π_j 为使用方获得的净剩余， ρ_j 为词元服务方在该场景所创造价值中可占有的份额， λ_j 为单位词元支出所撬动的场景价值倍数（价值杠杆倍数）。价值实现的必要条件是 $u_j > \tilde{p}$ ，即 $\rho_j < 1$ 。

式(6-3)有三条直接性质。第一，实现条件与档位无关而与场景有关：一枚高效值词元若被投入低价值密度场景，同样可能不满足实现条件，这解释了为什么「用最强的模型」并不总是经济的。第二， ρ_j 是内生的分配变量而非技术参数，它取决于服务方与使用方的相对议价能力、场景的可替代性以及效值信息的透明度，因而是第 7 章场景租金层的微观基础。第三， λ_j 给出了一个可比的效率指标：同一笔词元支出在不同场景撬动的价值差异，正是配置优化的空间所在，也是第 9 章匹配损失的价值口径表达。

式(6-3)所刻画实现过程，在微观层面已积累了相当的经验证据。生成式人工智能对写作类任务的效率提升与质量改善在受控实验中得到确认（Noy 和 Zhang，2023），对客服岗位的影响呈现明显的技能梯度（Brynjolfsson 等，2025）；企业侧采纳的调查显示，采纳率与企业规模、技能结构高度相关（Czarnitzki 等，2023；Humlum 和 Vestergaard，2025），个人侧的扩散速度则快于个人计算机与互联网的同期水平（Bick 等，2024）；云计算的既往经验也提示，通用算力服务的采纳会显著改变企业的成长路径与生产率分布（Byrne 等，2018；Coyle 和 Nguyen，2019；DeStefano 等，2025）。宏观层面的估算则分歧显著：有研究基于任务暴露度与自动化成本给出相当保守的十年全要素生产率效应（Acemoglu，2025），也有研究强调无形资产积累导致的生产率 J 曲线会使早期效应被系统性低估（Brynjolfsson 等，2019；Brynjolfsson 等，2021），国际组织的测算区间同样宽泛（「Chui

等，2023」；「Cazzaniga 等，2024」；「OECD，2024」）。分歧的根源之一正是价值实现环节缺乏可观测的中间变量——本书主张，标准词元流量恰好提供了这样一个变量，这一主张将在第 12 章得到检验。

式(6-3)还澄清了词元与算力、数据在价值链上的位置关系。算力的价值实现依赖于它被转化为词元，数据的价值实现依赖于它被凝结进模型再经词元释放，而词元的价值实现依赖于它被嵌入场景。三者构成一条严格的前后序关系，任何一环的阻滞都会使上游投入滞留为无效资产。这解释了一个反复出现的产业现象：算力规模的扩张与算力利用率的低迷可以长期并存（「中国信息通信研究院，2025」；中国信息通信研究院，2025），因为算力的建成只完成了价值链的第一段。云工作负载的实证分析也显示，资源请求与实际使用之间存在系统性缺口，调度与共享机制的设计对有效利用率有决定性影响（Weng 等，2022）。本书由此提出一条方法论主张：评价词元经济的发展水平，不能停留在算力规模或调用总量等上游指标，而应以场景端的价值实现为最终标尺——这正是第 12 章把标准词元流量而非算力存量引入生产函数的理由。

6.2.2 实现的闭环：生产—推理—应用—反馈—优化

价值实现不是一次性的单向传递，而是一个可以自我修正的闭环。如图 6.2 所示，从模型生产出发，经推理生成、场景应用、数据反馈到模型优化，五个环节首尾相接，构成词元价值实现与增值的基本循环。




图 6.2 词元价值实现与增值的循环

循环的五个环节各自承担不同职能。生产环节把算力与数据凝结为模型资产，是价值创造的前置沉没；推理环节按需生成词元，完成物化劳动的转移与活劳动新创价值的让渡；应用环节把词元嵌入具体业务流程，使潜在价值转化为使用价值，也是式(6-3)发生作用的位置；反馈环节把真实交互记录与效果评测沉淀为高质量语料，使需求侧的信息重新变成供给侧的投入；优化环节据此迭代模型与调度策略，提升效值系数 η 与转化效率 θ 。每完成一轮循环，单位标准词元的成本下降而效值上升，这是 6.3 节自增强机制的结构基础。

这一闭环的经济学意义在于反馈环节的存在。在传统产品经济中，消费信息要经过市场调研、销售统计等间接渠道才能回到生产端，且高度损耗；而在词元经济中，使用过程本身就是数据生成过程，需求侧信息以近乎零成本、近乎实时的方式回流到供给侧。这使得「使用越多—数据越多—模型越强—单位价值越高—使用更多」成为一条可自我维持的正反馈路径。但正反馈并非无条件的好事：数据的过度归集会产生隐私外部性与市场势力集中（Acemoglu 等，2022a；Bergemann 和 Bonatti，2024），反馈质量的下降也可能使循环退化为对既有模式的自我复制。图 6.2 把三类增值来源标为「外挂于循环」，正是要强调它们是循环的放大器而非循环本身，其强度取决于制度安排。

闭环视角还澄清了一个常见误解：词元调用量的增长既可能来自价值实现的深化，也可能来自无效重复。多步骤智能体工作流会把一次问答扩展为数十次调用，长上下文会把同一份资料反复送入模型，思维链推理会把大量中间过程转化为可计费的输出词元。这些调用中有一部分确实提高了任务达成度，另一部分则只是把同样的产出摊到更多词元上。区分二者的唯一办法，是以场景端的价值实现而非生成端的计数为准——这也是本书坚持把 S 维度纳入折算、并在本章单列价值实现分析的原因。

6.2.3 价值实现的三重摩擦

现实中的价值实现远未达到式(6-3)所描述的理想状态，三重摩擦横亘其间。第一重是计量摩擦：使用方难以事前判断所购词元的真实效值。本书测算显示，企业对所购词元效值的认知偏差均值达 0.44，且系统性低估高效值档位，由此导致低效值档位的过度采购份额达 0.27。这是一个典型的质量不可观测市场：当买方无法区分质量时，高质量供给会被逐出市场（Akerlof，1970），而质量披露与第三方认证是标准的纠正机制（Dranove 和 Jin，2010）。词元市场目前正处在认证机制初建的阶段。

产业界对这一摩擦已有明确回应，但各方的抓手互不相同，必须逐一区分其发布主体与适用范围。中国信息通信研究院依据《人工智能 Token 服务质量能力要求》开展的「可信 AI-Token 服务质量评估」设置模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度；该院于 2026 年 6 月 16 日发布的「高质量 Token 服务标准体系」则按服务质量、运营能力、生产能力、安全能力四个维度搭建框架，其云计算与大数据研究所负责人提出「不能只看单价，行业亟须一套衡量高质量 Token 的标尺」；中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》构建的是涵盖生产成本、生产效率、准确性、生态价值、安全五个维度的价值度量体系；清华大学翟季冬团队联合清程极智于 2026 年 5 月发布的开源模型 Token 服务性能榜，则以首 Token 时延（P90 分位）、输出吞吐与缓存命中率三项实测指标为准。四套工作主体不同、维度数不同、用途不同，不得合并、平均或交叉引用其维度名称。

第二重是匹配摩擦：即便效值可观测，任务与模型的匹配也未必最优。IDC 与中国信息通信研究院联合发布的企业调研显示，近半数企业的智算资源利用率处于 51%—70% 的中等区间，6.7%的企业仅为 31%—50%，利用率达 70% 以上者不足 35%，制造与政务行业低于平均水平（「IDC，2025」）。本书第

9 章将把名义利用率进一步分解，其中匹配损失一项达 12%，是四项损失中仅次于空转损失的第二大项，折算后的有效效值利用率仅 38%。匹配摩擦的经济后果是双向的：高价值场景被低效值词元供给而达不到实现条件，低价值场景被高效值词元供给而支付了不必要的溢价。

第三重是能力摩擦：使用方缺乏把词元转化为业务价值的知识工程能力。本书第 13 章的扎根编码结果显示，在 4 个核心范畴中，计量不透明获得 143 个参考点、成本不确定 118 个、能力缺口 97 个、合规与安全顾虑 76 个——前两项对应计量摩擦，第三项即能力摩擦，第四项则指向制度环境。能力摩擦的特殊性在于它不能由供给侧单方面解决：模型再强，若企业没有能力重构业务流程，词元也只能停留在辅助工具层面。这也解释了为什么各地词元运营中心普遍把「统一入口 + 场景适配 + 培训陪跑」作为组合服务，而不是单纯售卖算力或接口。

三重摩擦并非彼此独立，而是相互强化，构成一个低水平锁定。计量不透明使使用方无法事前评估效值，于是倾向于选择价格最低的档位；低效值档位在高价值密度场景中达不到实现条件，使用效果不佳；效果不佳强化了「人工智能不好用」的判断，抑制了企业在流程再造与知识工程能力上的投入；能力投入不足又使得即便换用高效值词元也难以见效，反过来印证了「贵的不值」的先验。这一负反馈回路与图 6.2 所刻画的正反馈回路方向相反、结构相似，其存在意味着词元市场可能存在多重均衡：高透明—高能力—高实现的良性均衡，与低透明—低能力—低实现的劣性均衡。平台经济的研究表明，价格机制与数据机制在资源配置中的作用是互补而非替代的（刘诚和夏杰长，2023），平台的组织形态与市场结构又受制于要素禀赋与制度环境（顾聪等，2023；吴双和王勇，2024）。这为公共部门介入提供了正当性依据：突破劣性均衡所需的初始推力，超出了任何单一市场主体的收益边界。

三重摩擦共同压低了 λ_j 的实际取值，使价值实现停留在潜在水平之下。本书的政策主张由此获得清晰的作用点：计量摩擦要靠统一的效值计量与披露制度来化解，匹配摩擦要靠统一调度与任务—模型最优匹配来化解，能力摩擦要靠场景服务与知识工程能力的社会化供给来化解。三者恰好对应第 5 章、第 9 章与第 10 章的制度设计。

6.3 价值增值：三重来源与自增强机制

6.3.1 规模复用：一次训练、多次推理的成本递减

价值增值的第一重来源是规模复用。模型资产 A_m 一经形成，其使用即具有非竞争性——被一个用户使用不减少其对另一个用户的可用性（Jones 和 Tonetti，2020）。把式(6-1)改写为累计产量的函数，即得平均成本的演化，如式(6-4)所示。

$$\dot{c}_m(N) = \frac{A_m}{N} + e_m + \ell_m, \frac{\partial \dot{c}_m}{\partial N} = -\frac{A_m}{N^2} < 0, \varepsilon_{\dot{c}, N} = -s_A, s_A = \frac{A_m/N}{\dot{c}_m} \quad (6-4)$$

其中， N 为累计推理产出的物理词元量， $\dot{c}_m(N)$ 为对应的平均成本， $\varepsilon_{\dot{c}, N}$ 为平均成本对累计产量的弹性， s_A 为固定成本摊销在平均成本中所占的份额。

式(6-4)有三条性质。其一，平均成本对累计产量严格单调递减，且下降速度随产量增加而放缓，呈双曲线形态。其二，平均成本存在下确界 $e_m + \ell_m$ ，即物化劳动转移与同步活劳动之和，这一下确界就是第 7 章成本底价层的理论表达——词元价格可以趋近它，却不可能长期低于它。其三，平均成本对产量的弹性恰等于固定成本份额的相反数，因此 s_A 是刻画规模复用强度的充分统计量。

本书对六档位长期平均成本与边际成本的估计给出了 s_A 的经验量级：六档位的固定成本份额高度一致，介于 47.2% 与 47.6% 之间，均值为 47.4%。这意味着在其他条件不变时，累计产量翻一番将使单位标准词元的平均成本下降约 23.7%。这一量级足以解释词元价格的持续下行中相当大的一部分：本书第 7 章的分解显示，2024Q1 至 2026Q2 表观累计降幅 79% 中，约 53% 来自效值提升、约 47% 为真实降价，而真实降价的主体正是规模复用与系统效率改进的合力。

规模复用还改变了产业的成本结构逻辑。当固定成本份额接近一半时，产能利用率就不再只是运营指标，而成为决定单位成本的第一变量——同一套模型资产，日均调用一亿枚与日均调用一百亿枚，其单位摊销相差百倍。这为第 8 章「词元工厂长期自然垄断倾向」的判断提供了成本侧依据，也为第 10 章城市词元运营中心「把分散需求聚合为规模负载」的组织逻辑提供了经济理由：聚合本身就是降本。

需要区分规模复用与传统规模经济。传统制造业的规模经济来自固定设备在更大产量上的分摊，其边界由产能物理上限与运输半径决定；词元的规模复用则来自非竞争性资产在无限次使用上的分摊，理论上没有产能上限，实际约束来自推理算力而非模型资产本身。这一差异使词元的平均成本曲线在很宽的产量区间

内保持下行，也使当量折算成为必需——正如综合能耗计算通则以标准煤当量统一不同品种能源的可加口径（国家市场监督管理总局和国家标准化管理委员会，2020），只有在标准词元口径下，跨档位、跨平台的累计产量才可以相加， N 才是一个有经济含义的变量。若以物理词元累加，一亿枚轻量蒸馏级词元与一亿枚推理增强级词元会被记为同样的产量，摊销测算将失去意义。

6.3.2 持续学习：反馈回流对效值系数的提升

价值增值的第二重来源是持续学习。图 6.2 的反馈环节把使用过程中产生的交互记录与效果评测转化为高质量训练语料，经优化环节提升模型的推理质量 R ，进而抬升效值系数 η 。设 q_t 为有效反馈回流率（可用于训练的高质量样本占总交互的比重）， ϕ 为学习转化系数， δ 为知识折旧率， γ 为回流规模的产出弹性，则效值系数的动态与稳态如式(6-5)所示。

$$\dot{\eta}_t = \phi (q_t \tilde{T}_t)^\gamma - \delta \eta_t, \eta^* = \frac{\phi}{\delta} (q \tilde{T})^\gamma, \frac{\partial \ln \eta^*}{\partial \ln \tilde{T}} = \gamma \quad (6-5)$$

其中， $\dot{\eta}_t$ 为效值系数的瞬时变化率， $q_t \tilde{T}_t$ 为单位时间回流的有效标准词元量， η^* 为稳态效值系数。

式(6-5)的求解是直接的：令 $\dot{\eta}_t = 0$ 即得稳态解，且由于方程右端对 η 的导数为 $-\delta < 0$ ，稳态是全局渐近稳定的。其性质有二。第一，稳态效值系数对标准词元流量的弹性恰为 γ ，即「用得越多，词元越好」——需求规模本身就是质量的生产要素，这在传统制造业中并不成立。第二，稳态效值系数与知识折旧率成反比：模型能力若不持续更新即会相对贬值，因为任务分布与知识前沿在移动。这两条性质共同意味着，词元服务是一种「使用即投资」的产品。

规模律研究为 γ 的存在性提供了技术基础：模型性能随训练数据量与算力投入呈幂律改善（Kaplan 等，2020），且在给定算力预算下参数量与训练词元量存在最优配比（Hoffmann 等，2022）。但持续学习的经济含义并不止于技术。其一， q_t 是制度变量而非技术常数：数据权属、隐私保护与跨主体流通规则直接决定了多少交互数据可以合法进入训练循环，而数据的过度归集又会带来隐私外部性与竞争扭曲（Acemoglu 等，2022a；Bergemann 和 Bonatti，2024）。其二， γ 的可持续性存在争议：若高质量语料趋于耗竭，回流数据的边际信息含量将下降，弹性随之衰减。本书据此提出一个可检验推论：在效值透明度较高、反馈机制较完善的运营平台上，同档位词元的效值提升速度应显著快于封闭部署环境——这一推论将在第 13 章的跨案例比较中得到间接支持。

6.3.3 网络协同：主体与场景的交叉外部性

价值增值的第三重来源是网络协同。接入同一词元服务体系的主体越多、可组合的场景越丰富，单位标准词元在任一场景中的价值密度就越高：数据与工具可以跨场景复用，工作流可以跨主体拼接，最佳实践可以快速扩散。设 n_t 为接入主体（或可组合场景）的规模， σ 为网络弹性，则场景价值密度的演化如式(6-6)所示。

$$u_{jt} = u_{j0} n_t^\sigma, \sigma = \frac{\partial \ln u_{jt}}{\partial \ln n_t} > 0 \quad (6-6)$$

其中， u_{j0} 为初始规模下场景 j 的价值密度， $\sigma > 0$ 表示存在正的网络外部性； σ 越大，规模扩张对单位词元价值的放大作用越强。

网络外部性的经典分析指出，采用决策的相互依赖会产生多重均衡与临界规模（Katz 和 Shapiro，1985），兼容性与标准化则决定了网络能否越过临界点（Farrell 和 Saloner，1985）；标准制定组织的治理结构直接影响这一过程的速度与方向（Simcoe，2012）。双边与多边平台理论进一步说明，平台的定价结构应当反映两侧的交叉外部性强度（Armstrong，2006；Jullien 等，2021），而数据在平台竞争中的作用会同时强化规模优势与信息优势（Bergemann 和 Bonatti，2024）。国内研究对标准化的生产率效应也提供了直接证据：物流标准化显著提升了企业全要素生产率（何凡等，2025），其机制正是通过降低对接成本扩大了可协同的网络规模。

词元经济中的网络协同有一个特殊载体，即统一的计量与接口规范。若各平台的词元计量口径、缓存计费规则与接口协议互不相通，跨平台的工作流拼接成本极高， n_t 实际上被切割为若干互不连通的小网络， σ 的作用被大幅削弱。反之，统一入口、统一计量与统一结算的制度安排相当于直接扩大了有效网络规模。这正是第 10 章「五个统一」机制设计的价值论依据：它们的作用不是行政性的整合，而是通过消除计量与接口的不兼容，把分割的小网络合并为一个大网络，从而在不增加任何物理投入的前提下抬升单位词元的价值密度。

网络协同同时带来一类负向效应，必须一并考虑。规模扩张会强化平台的锁定能力：当企业的工作流、提示模板与评测体系全部围绕某一平台的计量与接口规则构建，迁移成本将随使用深度上升， σ 的正效应会部分转化为平台的市场势力（Bergemann 和 Bonatti，2024）。这意味着网络协同的社会收益与私人收益并不自动一致：在缺乏互操作规则的条件下，平台有动机把网络效应内部化为壁垒，而不是外溢为公共价值。既有研究关于标准化的判断在此同样适用——兼

容性标准之所以能提升整体福利，正是因为它把网络效应从平台专属转变为行业共享（Farrell 和 Saloner，1985；Simcoe，2012）。本书由此提出：词元计量与接口标准的公共品属性，不能依赖任何单一平台的自愿供给，而需要由行业组织或公共部门牵头建立，这构成第 14 章标准供给建议的理论依据。

6.3.4 三重来源的合成、自增强乘数与稳定条件

把三重来源放在一起，可以得到单位词元「价值—成本比」的增长分解。定义 $\zeta_t = \eta_t u_t / v_t$ ，即单位物理词元所实现的价值与其成本之比，并以 $\hat{x}$ 表示变量 x 的增长率，则对式(6-4)至式(6-6)取对数微分并合并，得式(6-7)。

$$\zeta_t = \frac{\eta_t u_t}{v_t}, \hat{\zeta}_t = s_A \hat{N}_t + \gamma (\hat{q}_t + \hat{T}_t) + \sigma \hat{n}_t \quad (6-7)$$

其中，右端第一项为规模复用效应（累计产量增长经固定成本份额放大为成本下降），第二项为持续学习效应（回流率与流量增长经学习弹性转化为效值提升），第三项为网络协同效应（接入规模增长经网络弹性转化为价值密度提升）。

式(6-7)尚是一个部分均衡表达，因为 $\hat{T}_t$ 本身要对 $\hat{\zeta}_t$ 作出反应：性价比改善会刺激需求扩张。设需求对价值—成本比的弹性为 $\xi > 0$ ，即 $\hat{T}_t = \xi \hat{\zeta}_t$ ，并在稳定增长路径上取 $\hat{N}_t \approx \hat{T}_t$ ，代回式(6-7)并求解，得式(6-8)。

$$\hat{\zeta} = \frac{\gamma \hat{q} + \sigma \hat{n}}{1 - (s_A + \gamma) \xi}, M = \frac{1}{1 - (s_A + \gamma) \xi}, \gamma < \frac{1}{\xi} - s_A \quad (6-8)$$

其中， M 为自增强乘数，衡量外生冲击（回流率改善或接入规模扩张）经闭环放大后的总效应；右端不等式为闭环的稳定条件，违反该条件时系统不存在有限增长率的均衡路径。

式(6-8)可以直接代入本书的估计值加以量化。以第 8 章估计的需求价格弹性绝对值 1.34 作为 ξ 的下界、以 6.3.1 节的固定成本份额 47.4% 作为 s_A ，则在不考虑持续学习（ $\gamma = 0$ ）的情形下，自增强乘数已达 2.74——仅规模复用与需求响应的相互强化，就足以把外生改善放大近三倍。稳定条件要求 $\gamma < 0.272$ ：一旦持续学习的弹性超过这一临界值，闭环将不存在有限增长率的均衡，模型将预测爆炸式扩张。现实中约束这一发散的力量有三：算力供给的物理上限、场景渗透的饱和上限，以及高质量语料的耗竭。三者共同把爆炸式路径拉回到有限增长。

这一框架为观察到的宏观事实提供了内部一致的解释。我国日均词元调用量由 2024 年初的 1000 亿枚增至 2025 年 6 月底的 30 万亿枚、2025 年底的 100 万亿枚、2026 年 3 月的 140 万亿枚，两年约 1400 倍——这一量级的扩张不可能由任何单一因素解释，而自增强乘数恰好说明：中等强度的技术改进与制度改善，经由「成本下降—需求扩张—摊销加深—成本再下降」与「使用增加—数据回流—效值提升—使用再增加」两条回路的相互放大，可以产生数量级级别的总效应。需要强调的是，上述四个时点均为国家数据局公开发布的官方锚点，其间各季度点位系本书校准复算插值，官方未单独发布。

自增强机制也把本章与通用目的技术理论接上了。通用目的技术的特征是普适性、持续改进与创新互补性（Bresnahan 和 Trajtenberg，1995），其宏观效应往往滞后于技术出现（Crafts，2021）；生产率 J 曲线理论则给出了滞后的微观机制——无形资产的积累先于产出的显现（Brynjolfsson 等，2019；Brynjolfsson 等，2021）；关于测度误差能否解释生产率放缓的争论提醒我们不要过度依赖单一解释（Syverson，2017）；而人工智能对创新过程本身的改造，可能通过「思想生产函数」放大长期增长效应（Aghion 等，2019；Korinek，2023）。式(6-7)与式(6-8)可以视为把这些定性判断落在词元这一可观测变量上的一次尝试：本书对智能经济生产函数的估计给出标准词元流量的产出弹性 $\alpha_T = 0.108$ ，2026 年词元流量对产出增长的直接贡献为 0.34 个百分点、占实际增长率的 6.8%，而 2024 年这两个数字分别仅为 0.06 个百分点与 1.2%——贡献在两年内提升约 5.7 倍，正是自增强机制在增长核算口径下的投影。

6.4 场景依赖性的实证刻画：价值实现的离散与折算的边界

6.4.1 场景价值密度的测算与结构

价值实现的核心变量是场景价值密度 u_j ，即单位标准词元在某一场景中创造的毛使用价值。本书按八类典型应用场景对其加以测算，测算口径是：以场景中被词元替代或增强的人类认知劳动的市场价值为基准，按任务达成度折算到单位标准词元，得到以元每万标准词元表示的价值密度。为使不同场景之间可比，测算统一以完成同等任务所需的标准词元量为分母，从而剔除了因模型档位不同造成的用量差异。表 6.1 报告测算结果与由式(6-3)导出的价值实现结构。

表 6.1 八类应用场景的标准词元价值密度与价值实现结构

应用场景	价值密度 (元/万	相对最低场 景 (倍)	价值杠杆倍 数	可占有份额 (%)	价值密度的 主导来源
------	--------------	----------------	------------	--------------	---------------

STE)					
科研分析	11.3	5.95	583	0.17	高阶推理链条长，所替代的专家劳动稀缺
合规审查	9.1	4.79	469	0.21	错判代价高，产出承载责任成本
代码生成	8.6	4.53	443	0.23	产出可直接验收并进入生产系统
智能设计	7.2	3.79	371	0.27	方案空间大，迭代次数决定产出质量
质检与识别	6.4	3.37	330	0.30	多模态实时处理，替代密集人工巡检
知识问答	2.4	1.26	124	0.81	低阶检索为主，人工替代品充裕
客服对话	2.1	1.11	108	0.92	流程标准化，所替代人力单价低
文案生成	1.9	1.00	98	1.02	产出同质化，单件成品价值低

注：价值密度为单位标准词元在该场景创造的毛使用价值，未扣除应用侧自身的人力与系统投入，因而价值杠杆倍数是上限而非净收益率；价值杠杆倍数与可占有份额按支出加权的标准词元均价 1.94 元/百万标准词元计算，该均价由六档位市场价与用量份额复算得到（式 6-3）。数据来源：作者校准复算。

表 6.1 显示，八类场景的价值密度由文案生成的 1.9 元/万标准词元升至科研分析的 11.3 元/万标准词元，跨度 5.9 倍。排序本身传递了清晰的经济逻辑：价值密度高的场景，其共同特征是所替代的认知劳动稀缺、单位时间价值高、错误代价大或产出可直接进入生产系统；价值密度低的场景则以标准化、可替代性强、单件成品价值低为特征。这与任务层面的职业暴露度研究结论一致——人工智能对不同任务的影响并非均匀分布，而是高度集中于特定的认知任务类型（Felten 等，2021；Eloundou 等，2024；Autor，2024）。

更值得注意的是价值杠杆倍数一列。按支出加权的标准词元均价 1.94 元/百万标准词元计，同一笔词元支出在科研分析场景撬动的毛价值约为其 583 倍，在文案生成场景约为 98 倍；反过来说，词元服务方在所创造的毛价值中可占有的份额介于 0.17%与 1.02%之间，绝大部分价值以使用方剩余的形式留在应用侧。必须谨慎解读这一结果： u_j 是毛使用价值，未扣除应用侧自身的人力、系统与流程改造投入，因此杠杆倍数是上限而非净收益率。但即便打上足够大的折扣，结论的方向依然稳健——词元定价所争夺的，只是其所参与创造的价值中很

小的一块。这一判断对理解词元价格的快速下行至关重要：在可占有份额本就极低的条件下，价格竞争对使用方决策的影响远小于效值与匹配质量的影响，「唯低价」的竞争策略在价值论上是缺乏依据的。

如图 6.3 所示，把八类场景的价值密度按降序排列，可以更直观地看到实现价值的层级结构。




图 6.3 同量标准词元在不同场景的价值离散

注：横轴为单位标准词元在该场景创造的毛使用价值，口径与表 6.1 一致，未扣除应用侧自身投入；八类场景为本书按任务性质归并的典型场景，非任何平台的官方分类。数据来源：作者校准复算。

图 6.3 呈现出明显的两段式结构：科研分析、合规审查、代码生成、智能设计、质检与识别五类场景构成高价值密度段，知识问答、客服对话、文案生成三类构成低价值密度段，两段之间存在一个陡降。这一形态的政策含义在于：以调用量为唯一考核指标的补贴与统计安排，会系统性地偏向低价值密度场景——因为同样的补贴额度在低密度场景可以换来更多的词元计数。若要引导词元流向高价值密度场景，考核口径就必须从物理词元计数转向标准词元流量，并进一步引入场景权重。这正是本书主张把词元纳入统计与补贴核定时必须先完成折算的现实理由。

测算结果的稳健性需要说明三点。第一，价值密度的绝对水平依赖于对被替代认知劳动市场价值的估计，这一估计受行业工资水平与任务分解粒度的影响，因而绝对值存在不确定性；但相对排序取决于任务性质而非工资水平，对参数取值不敏感。第二，测算以标准词元为分母，已剔除档位差异造成的用量差异，因而所反映的确实是场景本身的价值密度，而非「高档位模型服务高价值场景」的选择效应。第三，八类场景是按任务性质归并的典型场景，不对应任何平台的官

方分类；实际业务中的复合场景往往横跨多类，其价值密度介于对应各类之间。就本书的目的而言，重要的不是任一场景的精确数值，而是离散的量级——只要跨场景价值密度存在数倍差异这一事实成立，本章的边界命题即告成立。

6.4.2 两重离散与效值折算的适用边界

现在可以回答本章开篇提出的关键问题：效值折算究竟消除了什么、没有消除什么？答案是：折算消除的是供给侧的档位离散，没有也不可能消除需求侧的场景离散。原因在于效值系数 η_m 是按档位定义的，其中的场景效用维度 S_m 反映的是该档位词元在其典型任务组合下的平均场景适配能力，而不是某一具体场景的价值密度。同一档位的词元投放到不同场景， η_m 完全相同，实现价值却相差数倍。这不是折算体系的缺陷，而是价值创造与价值实现分属不同环节的必然结果。

两重离散的合成可以形式化。设效值系数与场景价值密度在统计上相互独立，则单位物理词元实现价值 $V_{mj}=\eta_m u_j$ 的变异系数满足式(6-9)。

$$C V_v=\sqrt{\left(1+C V_{\eta}^2\right)\left(1+C V_u^2\right)}-1 \quad (6-9)$$

其中， $C V_{\eta}$ 为六档位效值系数的变异系数， $C V_u$ 为八类场景价值密度的变异系数， $C V_v$ 为二者交叉组合后实现价值的变异系数。该式表明，两重离散在乘性结构下不是简单相加，而是相互放大。

表 6.2 按四种口径报告离散度的对照结果，据此可以清楚地界定折算的适用边界。

表 6.2 四种口径下词元价值离散度的对照

离散度口径	变异系数	基尼系数	极差倍数	离散的经济来源	效值折算的作用
单位物理词元价格（跨六档位）	0.92	0.47	12.6	模型能力与生产成本的档位差异	可基本消除
单位标准词元价格（跨六档位）	0.31	0.17	2.4	运营效率与市场势力的残差	折算后的剩余
单位标准词元的场景价值密度（跨八类场景）	0.55	0.31	5.9	所替代认知劳动的价值密度差异	原理上不可消除
单位物理词元的实现价值（六档位×八场景）	0.86	0.47	67.0	供给侧效值与需求侧价值密度的交叉	仅可消除其中的档位分量

注：前两行取自第 5 章折算前后单位价格的离散度测算；第三行由本章八类场景价值密度计算；第四行为六档位效值系数与八类场景价值密度的等权交叉组合（共 48 个组合），其变异系数按式(6-9)合成、基尼系

数按交叉组合直接计算。变异系数与基尼系数均按总体口径计算，极差倍数为最大值与最小值之比。数据来源：作者校准复算。

表 6.2 的四行构成一条完整的推理链。第一行显示，物理口径下六档位单价的变异系数为 0.92、极差 12.6 倍，词元不可比亦不可加；第二行显示，折算后离散度降至 0.31 与 2.4 倍，基尼系数由 0.47 降至 0.17，价格趋近一价定律，说明供给侧的异质性确已被折算吸收。第三行显示，即便全部按标准词元计量，八类场景的价值密度仍有 0.55 的变异系数与 5.9 倍的极差——这部分离散完全来自需求侧，折算原理上无法触及。第四行显示，两重离散交叉后，单枚物理词元实现价值的变异系数升至 0.86、极差达 67 倍，远超任一单独口径。

这一结果对本书的理论体系有三重含义。第一，它界定了标准词元的功能边界：标准词元是价值创造侧的可比计量单位，可以承担价格指数、成本核算与增长核算的分母功能，但不能单独充当价值实现的度量——后者还需要场景维度的信息。第二，它为价格的纵向差异提供了价值论依据：既然同量标准词元在不同场景的实现价值相差数倍，按场景差别定价就不是单纯的市场势力行使，而部分地反映了真实的价值差异，这正是纵向差异化产品定价理论所刻画的情形（Mussa 和 Rosen，1978；Bhargava 和 Choudhary，2008），也是版本划分与个性化定价能够改善配置的条件所在（Dubé 和 Misra，2023）。第三，它提示价格指数的编制必须做质量调整：在产品质量快速变化的市场上，未经调整的价格指数会把质量改善误记为价格下降，特征价格方法正是为此而生（Griliches，1961；Pakes，2003；Erickson 和 Pakes，2011），数字时代的价格测度还需处理品种更替与新产品偏误（Groshen 等，2017；Redding 和 Weinstein，2020）。本书第 7 章的标准词元价格指数正是沿这一思路构建的。

6.4.3 理论定位与制度含义

本章的分析可以归纳为一个三段式命题：词元的价值创造于供给侧的劳动凝结，实现于需求侧的场景转化，增值于二者相互作用形成的自增强闭环。三段之间不是并列关系，而是条件关系——没有创造就没有可实现的对象，没有实现就没有回流的数据，没有回流就没有增值的动力。这一命题把本书的计量地基与后续的定价、配置、核算三块内容连成一体：第 7 章的三层定价结构可以直接读作三段式命题的价格投影，成本底价层对应价值创造、效值溢价层对应折算后的质量梯度、场景租金层对应价值实现的可占有份额；第 9 章的匹配损失可以读作价值实现的效率损失；第 12 章把标准词元流量引入生产函数并估计其产出弹性 α_T ，则是价值增值在增长核算口径下的检验。

在与既有工作的关系上，需要作一处明确的界定。本书用于折算的 (P, R, S) 三维效值体系是作者自主构建的理论框架，不源自任何机构的既有成果。与之构成对话的真实既有工作有四套，前文 6.2.3 节已逐一系列明其发布主体与维度构成：中国信息通信研究院的六维「可信 AI-Token 服务质量评估」与四维「高质量 Token 服务标准体系」、中国工业互联网研究院的五维价值度量体系、清华大学翟季冬团队联合清程极智的三项实测指标。这四套工作的共同特征是多维评价：其产出是若干并列的维度得分或达标基线，例如中国信息通信研究院「词元（Token）服务能力攀登计划」首批企业达成的性能基线为吞吐不低于 55 Token/秒、首 Token 时延不高于 0.9 秒、调用成功率 99.9%。多维评价可以回答「这家服务商好不好」，却无法把异质词元合成为可加总、可计价、可入账的单一当量，因而不能进入价格指数、补贴核定与增长核算。本书的理论增量正在于此：从多维评价推进到当量折算。

制度层面的含义同样清晰。词元作为计量单位的社会认受性已经建立：全国科学技术名词审定委员会于 2026 年 3 月 25 日发布公告，优先推荐并面向社会发布试用人工智能领域名词 token 的中文名「词元」，并明确将在常态化审定中结合社会推广应用情况最终确认；同月，国家数据局局长在中国发展高层论坛 2026 年年会上使用并推介这一译名，提出词元「可计量、可定价、可交易」，是智能时代的价值锚点。名称的统一是必要的第一步，但本章的分析表明它远不充分：可计量需要效值折算，可定价需要区分创造与实现，可交易需要解决效值信息不对称。三项要求分别指向计量标准、价格指数与质量披露三类公共品，而这些公共品的供给主体尚未明确。

从价值论的角度看，还有两点需要提请注意。其一，价值实现的绝大部分留在应用侧，意味着以词元服务收入衡量词元经济规模会严重低估其经济意义——数字经济核算中类似的低估问题已被反复讨论（杨仲山和张美慧，2019；许宪春等，2021；蔡跃洲和牛新星，2021），词元经济的核算需要在服务收入之外补充使用侧的价值测度。其二，价值实现依赖于使用方的组织与能力重构，这与人工智能对就业与技能结构影响的研究相互印证：技术的产出效应取决于任务的重新配置而非单纯替代（Acemoglu 和 Restrepo，2019；Goldfarb 等，2023），企业数字化转型对人力资本结构与劳动收入份额的影响也高度依赖于组织调整的深度（肖土盛等，2022；何小钢等，2023），我国的经验研究还显示技术应用对不同技能群体的影响存在显著异质性（王林辉等，2022；王林辉等，2023）。这提示：提升 λ_j 的政策抓手不只在供给侧的算力与模型，更

在需求侧的能力建设与流程再造——「人工智能+」行动把应用深化置于核心位置（国务院，2025），正体现了这一判断。

最后需要指出本章框架在统计制度上的一项直接要求。既然价值创造与价值实现分处不同环节、遵循不同规律，词元经济的统计就不能只设一套指标。合理的安排是「双口径并行」：生产侧以标准词元流量为核心指标，反映价值创造的规模与结构，可直接进入投入产出与增长核算；应用侧以场景加权的实现价值为核心指标，反映价值实现的深度与效率，用于评价政策成效与区域差异。目前的公开统计基本只有前者的雏形——国家数据局发布的日均调用量属于生产侧的物理口径，尚未做效值折算；全国数据资源调查提供了数据要素侧的存量信息（「国家数据局，2026」），「数据要素×」行动与「人工智能+」行动则给出了场景推进的政策清单（「国家数据局等，2023」；国务院，2025），但缺乏与之配套的价值实现统计。补齐这一缺口，是词元经济从「有数据」走向「可核算」的关键一步，也是本书在第 14 章提出建立标准词元统计制度建议的直接依据。

6.5 本章小结

本章在第 5 章折算体系的基础上，回答了词元的价值从哪里来、在哪里兑现、为何增值三个问题，形成一个「创造—实现—增值」的三段式价值分析框架。在价值创造层面，本章把词元中凝结的劳动分解为前置沉没的数据劳动与算法劳动、与推理同步发生的知识工程劳动，以及即时转移的物化劳动三类时间结构，给出单位物理词元的价值构成式(6-1)与折算后的可加总表达式(6-2)。经验测算表明，六档位每百万物理词元的成本底价极差达 18.7 倍、变异系数 0.733，折算为标准词元口径后极差降至 1.66 倍、变异系数降至 0.176——档位间成本差异的绝大部分是产品差异而非效率差异，若不做折算而直接比较单位成本，将在补贴核定与成本监审中得出方向性错误的结论。

在价值实现层面，本章提出「生成不等于实现」的基本判断，以式(6-3)刻画场景价值密度、可占有份额与价值杠杆倍数三者的关系，给出价值实现的必要条件；以图 6.2 的「生产—推理—应用—反馈—优化」五环节闭环说明需求侧信息如何经反馈回流重新成为供给侧投入，这是词元经济区别于传统产品经济的结构特征；并识别出阻碍价值实现的三重摩擦——效值认知偏差达 0.44 的计量摩擦、损失达 12%的匹配摩擦，以及以能力缺口为核心的能力摩擦。三重摩擦分别对应统一计量与披露、统一调度与最优匹配、场景服务与能力社会化供给三类制度安排，构成后续章节政策设计的作用点。

在价值增值层面，本章识别出规模复用、持续学习与网络协同三重来源，分别以式(6-4)至式(6-6)加以刻画，并合成为价值—成本比的增长分解式(6-7)与内生需求响应后的自增强乘数式(6-8)。测算显示，六档位固定成本份额均值为47.4%，累计产量翻番可使单位标准词元平均成本下降约23.7%；以需求价格弹性绝对值1.34为需求响应弹性，仅规模复用与需求响应的相互强化即可产生2.74倍的自增强乘数，而闭环稳定要求持续学习弹性小于0.272。这一框架为两年约1400倍的调用量扩张提供了内部一致的解释：数量级级别的总效应，来自中等强度改进经双重正反馈回路的连乘放大，而非任何单一因素的突变。

在实证刻画层面，本章测算了八类应用场景的标准词元价值密度，跨度达5.9倍；按支出加权的标准词元均价计，价值杠杆倍数介于98倍与583倍之间，词元服务方在所创造毛价值中的可占有份额不足1%，绝大部分价值以使用方剩余的形式留在应用侧。更重要的是四种口径的离散度对照所揭示的边界命题：效值折算把跨档位单价的变异系数由0.92压到0.31，却对跨场景价值密度0.55的变异系数无能为力；两重离散交叉后，单枚物理词元实现价值的极差可达67倍。标准词元因此是价值创造侧的可比计量单位，可以承担价格指数、成本核算与增长核算的分母功能，但不能单独充当价值实现的度量。

本章的结论向后续各章输出三项直接结果。其一，三段式价值命题为第7章的三层定价结构提供价值论依据：成本底价层对应价值创造、效值溢价层对应折算后的质量梯度、场景租金层对应价值实现的可占有份额，三层不是定价技巧的堆叠，而是价值环节的价格投影。其二，价值实现的三重摩擦为第9章的配置分析与第10章的机制设计指明了作用点，其中匹配摩擦的价值口径表达即为匹配损失。其三，自增强乘数与式(6-7)的增长分解为第12章把标准词元流量引入生产函数、以产出弹性 α_T 显性分离人工智能的增长贡献提供了微观基础。需要说明本章的两点局限：场景价值密度的测算依赖于对被替代认知劳动价值的估计，其绝对水平存在不确定性，但相对排序与离散度结论对参数取值不敏感；自增强乘数的量化以需求价格弹性替代价值—成本比弹性，属保守下界处理，实际乘数可能更高。这两点均有待更细粒度的场景级微观数据加以改进。

第7章 词元定价机制：三层结构与价格指数

第5章确立了标准词元的折算体系，第6章解释了词元价值的创造、实现与增值。计量与价值论既明，全书的分析随之进入第二个科学问题：标准词元的价格如何形成、如何演化。价格是配置的信号，也是计量体系能否真正发挥作用的试金石——若一套计量单位无法进入价格的形成与观测，它便只是学术的度量衡，而不是经济的度量衡。国家数据局局长在中国发展高层论坛2026年年会上提出词元具有「可计量、可定价、可交易」三重特征，把「可定价」置于「可计量」之后、「可交易」之前，其内在逻辑正在于此：计量是定价的前提，定价是交易的前提，三者构成一条不可跳跃的制度链条。

然而，词元价格的经验图景至今是散乱的，散乱到无法在单一的「价格」概念下自洽。三组事实并置即可见其困难。其一，价格在快速下行的同时急剧分化：本书校准的物理词元价格指数由2024年第一季度的100降至2026年第二季度的21，累计下降79%；而同一时点上，六个档位的每百万物理词元单价却由0.40元跨到14.00元，相差35倍。其二，价格并非单调下行：据公开报道，一家国产头部大模型服务商自2026年8月17日零时起把主力接口改为峰谷分时定价，空闲时段价格为高峰时段的一半，而改价后的输出价较改价前明显上调——同一枚词元因时段不同而价格相差一倍。其三，不同口径的价格观测彼此背离：由第三方数据服务商发布的词元支出指数（支出加权的每百万词元成交均价）由2026年5月31日的2.04美元回落至8月6—8日的1.16—1.18美元，约两个月跌逾四成、为年内最低，而同期主要服务商的公开挂牌价并未同步变动，个别服务商反而在调价中上行。

这三组事实指向同一个判断：「词元价格」不是一个数，而是一个结构。本章的核心命题是，词元价格可以且应当分解为三个层次——成本底价层、效值溢价层与场景租金层，三层分别是第6章价值创造、效值折算与价值实现三个环节在价格上的投影；三层的变动方向与决定因素各不相同，通用词元价格持续下行与高效值词元溢价扩大之所以能够并存，正是因为下行的是第一层、扩张的是第二、三层。在此基础上，本章进一步给出词元价格指数（TPI）与标准词元价格指数（STPI）的双轨编制方法，并证明二者的背离幅度恰好度量了表观降价中不属于真实降价的那一部分。本章安排如下：7.1节论证边际成本定价在词元产品上的失效，辨析「零边际成本」的流行误解，确立价值锚定的定价基准；7.2节构建三层定价结构并给出六档位的分解结果；7.3节刻画平台竞争下的价格动

态、收敛路径与价格地板；7.4 节分析三级服务定价的二级价格歧视机制；7.5 节编制 TPI 与 STPI 并分解二者的背离；7.6 节为本章小结。

7.1 定价的经济学基础：零边际成本假象与成本加成的失效

7.1.1 词元不是零边际成本产品

数字产品定价理论的起点，是信息品的零边际复制成本：一份软件、一首乐曲、一条数据记录，其首份的生产成本高昂而后续复制近乎免费，因而边际成本定价将使收入无法覆盖固定成本，定价必须依赖版本划分、捆绑、订阅与价格歧视等非线性机制（Mussa 和 Rosen，1978；Bhargava 和 Choudhary，2008）。数据要素的非竞争性进一步强化了这一结论：同一份数据可被任意多主体同时使用而不减损，社会最优要求广泛共享，而私人激励却指向排他与封锁（Jones 和 Tonetti，2020），数据定价研究因此长期在成本法、收益法与市场法之间徘徊，难以形成公认基准（熊巧琴和汤珂，2021；Pei，2022；欧阳日辉和杜青青，2022）。把这套逻辑不加辨析地平移到词元上，就会得到一个流行却错误的判断：词元是零边际成本产品，因而其价格终将趋近于零。

这一判断的错误在于混淆了「复制」与「生成」。数据与软件的边际成本之所以为零，是因为增量供给来自复制；词元的边际成本之所以严格为正，是因为增量供给来自重新计算——每一枚新的词元都必须由模型在给定上下文下重新执行一次前向推理，消耗真实的浮点运算、显存带宽与电力。第 3 章已从技术属性层面论证了这一点，此处把它写成可用于定价的成本函数。记模型档位 m 在上下文长度 ℓ 下生成一枚词元所需的浮点运算量为 $f_m(\ell)$ ，加速器峰值算力为 v_m 、有效算力利用率为 u_m ，单位加速器时间的资本成本（折旧与资金占用）为 π_K 、电力成本为 π_E ，单位词元的运维、存储与网络成本为 ω_m ，则单位物理词元的边际成本如式(7-1)所示。

$$c_m^{MC}(\ell) = \frac{f_m(\ell)}{v_m u_m} (\pi_K + \pi_E) + \omega_m, f_m(\ell) = 2N_m + 2\xi_m \ell \quad (7-1)$$

其中， N_m 为档位 m 的有效参数规模， ξ_m 为注意力机制对上下文长度的敏感系数； π_E 本身等于加速器额定功率、数据中心电能利用效率（PUE）与上网电价三者之积。

式(7-1)刻画了四条对定价至关重要的性质。第一，边际成本随模型规模线性上升： $\partial c^{MC} / \partial N_m > 0$ ，这解释了为什么高档位词元的价格地板天然高于低档位。

第二，边际成本随上下文长度上升：长上下文请求的每词元成本高于短请求，这正是主流服务商为长上下文档位单独加价的成本依据。第三，边际成本随有效算力利用率 u_m 下降而急剧上升——利用率是分母。这一条把定价与第9章的配置效率直接联系起来：调度水平低下不仅浪费算力，还会抬高价格地板。第四，边际成本是状态依赖的：缓存命中时无需重算前缀， f_m 大幅缩减；高峰时段的机会成本高于空闲时段。近年推理系统的进展——分页显存管理、连续批处理、分块预填充与预填充解码分离——正是沿着降低 $f_m/(v_m u_m)$ 的方向压缩边际成本（Yu 等，2022；Kwon 等，2023；Agrawal 等，2024；Zhong 等，2024），注意力算子层面的访存优化与大规模推理的并行编排则从硬件效率一侧提升 u_m （Dao 等，2022；Pope 等，2023）；模型侧的规模律与训练推理权衡研究，则从另一端降低了达到同等能力所需的 N_m （Kaplan 等，2020；Hoffmann 等，2022）。

状态依赖性使「词元单价」在技术上就不是一个标量。缓存命中与未命中的输入价差可达数十倍，峰谷时段价差可达一倍，长上下文档位的整请求计价高于标准档位；再叠加语言维度——同一段语义内容在不同语言下被分词器切分出的词元数差异显著，非拉丁语系文本通常需要更多词元来承载等量信息（Rust 等，2021；Petrov 等，2023；Ahia 等，2023）——同一张价目表对不同买方的实际价格并不相同。这提示我们，任何以「每百万词元多少元」表述的价格，都必须附带计量状态的说明；缺少状态说明的价格比较，在计量上是无效的。还须指出一项测度限制：迄今没有任何主流厂商公布过「每千词元」口径的官方能耗数据，公开的权威测算分母均为「一次查询」，因而式(7-1)中的电力成本项在实证上只能由查询级口径换算或由本书校准复算得到，不得表述为实测值。

7.1.2 固定成本、次可加性与边际成本定价的失效

边际成本为正，并不意味着边际成本定价就是可行的。词元生产的成本结构具有典型的「巨额固定、正的可变」形态：模型训练与研发投入、数据采集与清洗、对齐与安全评测构成期间沉没成本，智算集群构成资本占用，二者均与当期产量无关。设档位 m 在摊销期内的固定成本为 F_m 、资本占用为 K_m 、资本回报率为 r 、摊销期内产量为 T_m ，则平均成本与边际成本的关系如式(7-2)所示。

$$c_m^{AC}(T_m) = c_m^{MC} + \frac{F_m + r K_m}{T_m} > c_m^{MC}, c_m^{AC}(T_m) \rightarrow c_m^{MC}(T_m \rightarrow \infty) \quad (7-2)$$

其中， c_m^{AC} 为单位物理词元的平均成本。不等号对一切有限产量严格成立，且平均成本随产量单调递减。

式(7-2)给出了一个无法回避的结论：若按边际成本定价，词元服务方的利润恒等于 $-(F_m + rK_m)$ ，即全部固定成本与资本回报无从回收。这与信息品定价的经典困境同构，但成因不同——信息品的问题是边际成本为零，词元的问题是平均成本远高于边际成本。本书六档位的校准结果显示，固定成本占平均成本的比重均值达 47.4%，即接近一半的成本与当期产量无关。在这样的成本结构下，价格必须包含加成，问题只在于加成的依据是什么。经济学为此提供了三条经典路径：拉姆齐定价按需求弹性的倒数分摊固定成本，两部定价以固定费回收固定成本、以边际价格保证配置效率，版本划分则以质量梯度实现自选择（Mussa 和 Rosen，1978；Bhargava 和 Choudhary，2008）。三条路径在词元市场上都能找到对应的现实形态：普惠包与订阅制对应两部定价，档位菜单对应版本划分，分行业的差别定价隐含着拉姆齐逻辑。

词元定价还有一重信息品定价所没有的复杂性：它嵌在多边平台结构之中。算力方、模型方、应用方经平台连接，任一侧的价格都会通过交叉网络外部性影响另一侧的接入规模，因而单边的成本加成并不构成均衡定价的充分条件（Armstrong，2006；Jullien 等，2021）；平台掌握的用量与效果数据又使其具备实施精细化定价的技术能力（Dubé 和 Misra，2023；Bergemann 和 Bonatti，2024）。这些结构性因素共同决定：词元价格不可能由单一公式给出，只能由「成本决定下限、能力决定梯度、场景决定上限」的层次结构刻画。

7.1.3 定价基准的三个候选与本书的选择

既然必须加成，加成的锚点是什么？现实中并存三个候选基准，各自的适用条件与失效边界均可辨明。候选一是成本加成：以式(7-2)的平均成本为基础按固定比例加成。其优点是可核算、可审计，缺陷是无法解释同等成本下的巨大价差——本书六档位中，多模态级与开源旗舰级的成本底价相差不足 1.41 倍，市场价却相差 1.52 倍。候选二是竞争对标：以主要竞争者的挂牌价为参照定价。其优点是简便，缺陷是没有锚点——当所有参与者都以对方为锚，价格系统就失去了外部约束，只剩下向下的正反馈，这正是 2024 年以来数轮价格战的生成机制。候选三是价值锚定：以词元在应用场景中创造并可被占有的价值为基准定价。其优点是与价值论一致，缺陷是价值不可直接观测，必须先有可计量、可比较的质量尺度。

本书选择第三条，而第三条的可行性恰恰依赖于第 5 章的折算体系。这里需要与既有工作做一个准确的区分。围绕词元质量的度量，国内已经形成若干套并行推进的评价体系，它们主体不同、维度不同、用途也不同，必须逐一注明而不能合并引用：中国信息通信研究院的《人工智能 Token 服务质量能力要求》及其「可信 AI-Token 服务质量评估」设有模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度；同一机构于 2026 年 6 月发布的「高质量 Token 服务标准体系」则设服务质量、运营能力、生产能力、安全能力四个维度；中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》构建的是涵盖生产成本、生产效率、准确性、生态价值、安全五个维度的价值度量体系；清华大学翟季冬团队联合企业方于 2026 年 5 月发布的开源模型 Token 服务性能榜，则以首 Token 时延（P90 分位）、输出吞吐与缓存命中率三项实测指标为核心。四套工作的共同贡献，是把「词元有好坏之分」这一产业共识转化为可观测的指标；中国信息通信研究院云计算与大数据研究所负责人所提出的「不能只看单价，行业亟须一套衡量『高质量 Token』的标尺」，正是这一取向的凝练表述。

但从定价的需要看，多维评价与当量折算之间存在一道未跨越的门槛。多维评价的产出是并列的维度得分或达标基线——例如首批企业达成的性能攀登基线为吞吐不低于每秒 55 词元、首词元时延不高于 0.9 秒、调用成功率 99.9%——这些指标可以回答「是否达标」，却无法回答「一枚推理增强级词元等于几枚中型通用级词元」。价格公式需要的恰恰是后者：一个可以进入分母、可以加总、可以在不同模型与任务之间传递的当量系数。第 5 章的 (P, R, S) 三维折算函数正是为此而构建，其标定结果给出六档位的效值系数由 0.38 到 4.28。本章的全部定价分析都建立在这一当量之上：有了当量，价格才能从「元每百万物理词元」转换为「元每百万标准词元」，价格的可比性、价格指数的质量调整与补贴的效率核定才同时成为可能。需要重申的是，三维效值折算体系是本书自主构建的理论框架，与上述四套评价工作在主体、维度与用途上均无对应关系，不得相互挂靠。

7.2 三层定价结构：成本底价、效值溢价与场景租金

7.2.1 三层结构的界定

本书提出的三层定价结构，是把词元的市场价格分解为三个来源不同、决定因素不同、变动方向也不同的组成部分。其形式表述如式(7-3)所示。

$$p_m = p_m^f + p_m^\eta + p_m^s, p_m^f > 0, p_m^\eta \geq 0, p_m^s \geq 0 \quad (7-3)$$

其中， p_m 为档位 m 每百万物理词元的市场价， p_m^f 为成本底价层、 p_m^η 为效值溢价层、 p_m^s 为场景租金层；三层均以同一量纲计量，恒等式对每一档位成立。

三层的经济性质截然不同。成本底价层由算力与能源决定，是价格的刚性下限：低于此线的定价无法持续，只能是补贴或引流。它随硬件迭代、系统优化与利用率改善而缓慢下移，其下移是全行业共享的技术红利。效值溢价层由模型能力决定，是质量梯度的价格表现：效值越高，单位词元可索取的溢价越厚。它随模型能力的分化而扩张、随能力的扩散而收敛，是竞争最为激烈的一层。场景租金层由应用价值的可占有份额决定，是纵向价差的来源：同一档位的词元投放到不同场景，可索取的租金相差数倍。它取决于场景价值密度、可替代性与议价能力，是三层中最不透明、也最容易被忽视的一层。三层的叠加关系与各自的决定因素如图 7.1 所示。




图 7.1 词元价格的三层结构

注：图中标注的效值系数区间取自表 5.2，场景价值密度区间取自表 6.1；中型通用级的示例数值为 2026 年第二季度每百万物理词元口径。数据来源：作者校准复算。

图 7.1 的结构安排有两点须加说明。其一，三层是自下而上累积而非并列：成本底价层是地基，效值溢价层建立在地基之上，场景租金层则建立在前两层之上。这一顺序不是修辞，而是有经济含义的——没有算力就没有词元，没有能力差异就没有质量梯度，没有场景落地就没有租金可言；反向的推论同样成立：场景租金的消失不会动摇价格地板，而价格地板的抬升却会挤压上面两层。其二，左侧标注的标准词元价格 $\tilde{p} = p/\eta$ 提示了本章的分析主线：三层结构在物理词元口

径下呈现为巨大的档位价差，一旦折算为标准词元口径，各层的离散程度将出现显著分化——这一分化正是 7.2.5 节的核心发现。三层结构的经济内涵、决定变量与竞争性质汇总于表 7.1。

表 7.1 词元价格三层结构的经济内涵、决定因素与竞争性质

层次	价格构成项	决定变量	对应的价值环节	竞争与政策性质
成本底价层	算力折旧与资金占用、电力、运维与网络、固定成本摊销	模型规模、上下文长度、有效算力利用率、电价与 PUE、摊销期产量	价值创造（物化劳动转移与活劳动凝结）	全行业共享的技术红利，随效率改进缓慢下移；受电价与算力供给约束，构成价格竞争不可逾越的下限
效值溢价层	模型能力形成的质量梯度加价	三维效值合成系数、能力分化程度、效值信息的可观测性	价值创造中的差异化（推理质量与算力强度）	竞争最激烈的一层；能力扩散使其收敛，效值信息不透明则使其失衡，是效值披露制度的主要作用面
场景租金层	应用价值中可被服务方占有的份额	场景价值密度、可替代性、转换成本与议价能力、合约期限	价值实现（可占有份额与价值杠杆）	纵向价差的主要来源；最不透明，受锁定与信息不对称影响最大，也是反垄断与合同规范的关注点

注：三层的价格构成项与决定变量对应式(7-4)至式(7-6)；「对应的价值环节」一列指向第 6 章的价值创造、实现与增值分析框架。

表 7.1 的最后一列揭示了三层结构的政策价值：三层对应三类完全不同的政策工具。针对成本底价层的政策是算力与能源政策——绿电直供、算电协同、枢纽节点的 PUE 约束与上架率要求，其作用是压低地板；针对效值溢价层的政策是计量与披露政策——统一的效值口径与强制披露，其作用是让溢价重新锚定于能力而非品牌；针对场景租金层的政策则是竞争与合同政策——降低转换成本、限制排他条款，其作用是防止租金被锁定效应固化。把三类工具混用，例如以成本监审去治理租金层的价差，或以效值披露去解决地板过高的问题，都将无效。

7.2.2 成本底价层：价格地板的构成与刚性

成本底价层的界定是：在长期可持续经营的意义上，服务方为提供单位词元所必须回收的最低价格。它包含边际成本与固定成本的合理摊销，但不包含任何超额回报。其表达式如式(7-4)所示。

$$p_m^f = c_m^{MC}(\ell) + \frac{F_m + r K_m}{T_m}, \frac{\partial p_m^f}{\partial T_m} < 0, \frac{\partial p_m^f}{\partial u_m} < 0, \frac{\partial p_m^f}{\partial \pi_E} > 0 \quad (7-4)$$

其中， ℓ 为业务组合的平均上下文长度；三个偏导数分别刻画规模摊薄效应、利用率效应与能源价格效应。

式(7-4)的三条比较静态给出了价格地板的全部下移路径，也给出了它的刚性来源。规模摊薄效应意味着地板随累计产量下移，这是词元价格长期下行的最根本动力，也是第6章规模复用机制在价格上的直接体现——本书测算的固定成本份额均值47.4%意味着累计产量每翻一番，单位标准词元的平均成本可下降约23.7%。利用率效应把定价与调度效率联系起来：第9章的测算显示，名义算力利用率62%经四项损失折减后，有效效值利用率仅38%；而据IDC与中国信息通信研究院2026年联合发布的企业调研，近半数企业的智算资源利用率处于51%至70%区间，利用率达70%以上的企业不足35%。利用率在分母上，这意味着当前的价格地板中包含了相当比例的「低效溢价」——不是技术不允许更低的价格，而是调度水平不允许。能源价格效应则把词元价格与电力市场相连：单位加速器时间的电力成本等于功率、PUE与电价之积。2023年全国数据中心平均PUE约1.48（中国信息通信研究院口径，存量全国平均），而政策对新建及改扩建大型、超大型数据中心的约束为1.25以内、对国家枢纽节点数据中心项目的约束为不高于1.2；两组数字适用对象不同，不构成同一序列，但它意味着增量产能的电力成本项显著低于存量平均水平，价格地板的下移在很大程度上要靠新增产能替换存量产能来实现（中国信息通信研究院，2025）。国际能源署的测算显示，2024年全球数据中心（全部类型，非人工智能专用口径）用电约415太瓦时、约占全球用电的1.5%，2030年基准情景将升至945太瓦时（IEA，2025）；电力约束一旦收紧，价格地板就会由下向上顶起。

价格地板的存在，为「词元价格终将归零」的判断划定了边界。从式(7-1)与式(7-4)可知， p_m^f 的下限由物理定律与要素价格共同锁定：即便固定成本被无限摊薄，边际成本项也不会消失。以本书校准的六档位数据与用量份额计算，用量加权的成本底价为每百万物理词元0.844元，占用量加权市场价2.764元的30.5%。这一比例的政策含义将在7.3.4节展开。

7.2.3 效值溢价层：质量梯度定价与信息条件

效值溢价层回答的问题是：能力更强的词元凭什么更贵，以及贵多少才是均衡的。其理论基础是质量梯度定价——垄断或垄断竞争厂商面对偏好强度不可观测的买方，通过提供「质量—价格」菜单实现自选择，从而把买方的支付意愿差异转化为利润（Mussa和Rosen，1978），而信息产品的版本划分正是这一机制在数字领域的实现形式（Bhargava和Choudhary，2008）。把质量维度替

换为本书的效值系数 η ，设买方对效值的边际支付意愿类型为 θ 、分布函数为 $G(\theta)$ 、密度为 $g(\theta)$ ，则最优效值菜单与价格函数满足式(7-5)。

$$\theta - \frac{1 - G(\theta)}{g(\theta)} = \frac{\partial c^{MC}}{\partial \eta}(\eta(\theta)), p(\eta(\theta)) = \theta \eta(\theta) - \int_{\underline{\theta}}^{\theta} \eta(s) ds \quad (7-5)$$

其中， $\eta(\theta)$ 为分配给类型 θ 的效值水平， $(1 - G)/g$ 为逆风险率；第二式由包络定理得到， $\int \eta(s) ds$ 即买方的信息租金。

式(7-5)含有三条可检验的性质。性质一：顶端无扭曲。支付意愿最高的买方获得效率意义上最优的效值水平，即最高档位的定价不含质量扭曲，其溢价完全反映能力差异。性质二：向下扭曲。中低类型买方所获得的效值低于社会最优，服务方以压低低档位质量的方式减少高类型买方的信息租金——这解释了一个常见现象：轻量档位的能力并非「做不到更好」，而是「不宜做得更好」，因为过强的低价档位会侵蚀高价档位的需求。性质三：溢价随效值凸性上升。由 $p^\eta = p - p^f$ 与式(7-5)可知，效值溢价对 η 的导数等于 $\theta(\eta)$ ，而 θ 沿菜单递增，故溢价曲线上凸。本书的六档位数据支持这一性质：效值溢价率（效值溢价层与成本底价层之比）由轻量蒸馏级的 0.50 升至中型通用级的 0.65、开源旗舰级的 0.93、旗舰闭源级的 1.11，再升至推理增强级的 1.32，随效值系数单调上升；多模态级的溢价率为 0.92，略低于效值系数更低的开源旗舰级，原因在于其效值中场景效用维度的贡献大于推理质量维度，而市场对场景效用的支付意愿更多体现在租金层而非溢价层。

效值溢价层的实现有一个严苛的信息前提：效值必须可观测、可验证。若买方无法在购买前判别效值，市场就会退化为柠檬市场——高效值供给因无法获得应有溢价而退出，低效值供给因价格优势而扩张（Akerlof, 1970）。第 5 章测算的效值认知偏差均值达 0.44，低效值档位的过度采购份额达 27%，正是这一风险的实证征兆。质量披露与第三方认证是标准的应对（Dranove 和 Jin, 2010），其经济功能不是「管价格」，而是「让价格能够反映质量」。这一判断为第 14 章把效值披露列入政策建议提供了定价理论依据：披露制度的收益，等于溢价层重新锚定于效值所带来的配置改善。

7.2.4 场景租金层：可占有份额与议价

第 6 章已经证明，词元的价值实现高度依赖场景：八类典型场景的标准词元价值密度由文案生成的 1.9 元每万标准词元升至科研分析的 11.3 元每万标准词元，跨度 5.9 倍；而服务方在所创造毛价值中可占有的份额极低。场景租金层正是这一可占有份额在价格上的表现。设场景 j 中单位标准词元创造的毛使用价值

为 u_j ，使用方为实现该价值所需投入的互补成本为 κ_j ，次优替代方案的单位成本为 $\tilde{c}_j$ ，服务方在可分配剩余中的分成率为 ρ_j ，则档位 m 在场景 j 中的场景租金层如式(7-6)所示。

$$p_{mj}^s = \rho_j \eta_m (u_j - \kappa_j - \tilde{c}_j), \frac{\partial \rho_j}{\partial \chi_j} < 0, \frac{\partial \rho_j}{\partial \psi_j} > 0 \quad (7-6)$$

其中， χ_j 为同等效值替代供给的密度（可替代性）， ψ_j 为使用方的转换成本； η_m 的出现是把标准词元口径的价值密度换算回物理词元口径。

式(7-6)包含四点判断。第一，租金与效值成比例：同一场景中，效值更高的词元因单枚承载更多价值而可索取更高租金，这是效值系数第二次进入价格公式——第一次在溢价层，第二次在租金层，二者的机制不同，前者源于买方对质量的支付意愿，后者源于价值创造的规模。第二，租金以「可分配剩余」为上限：若使用方的互补投入 κ_j 过高，或次优替代方案足够便宜，剩余可能为零甚至为负，此时无论词元多么强大都不存在租金，这正是第6章「生成不等于实现」命题在定价上的对应表述。第三，分成率由市场结构而非技术决定：可替代供给越密集，分成率越低；转换成本越高，分成率越高。开放权重模型的扩散与路由平台的普及同时提高了 χ_j 、降低了 ψ_j ，这解释了模型服务市场集中度由2024年的0.34降至2026年的0.21的同时，租金层承受的压力为何显著上升。第四，租金层是纵向价差的主要来源：由于 u_j 的跨场景跨度达5.9倍，即便面对同一档位、同一效值，不同场景的成交价也可以相差数倍，这使得「统一的词元挂牌价」在有深度场景服务的市场上必然被合约条款所修正。

需要提醒一种常见误读：场景租金层的存在，并不意味着服务方攫取了应用侧的大部分价值。第6章的测算显示，服务方在所创造毛价值中的可占有份额不足百分之一，绝大部分价值以使用方剩余的形式留在应用侧。租金层之所以重要，不在于其绝对量大，而在于它是三层中弹性最大、最难以观测、也最容易被制度安排改变的一层——统一入口、统一计量与合同规范可以显著降低 ψ_j ，从而把租金压回到与竞争程度相称的水平，这正是第10章「五个统一」机制设计的定价理论依据。

7.2.5 六档位的三层分解：折算前后的结构性发现

把式(7-4)至式(7-6)应用于本书校准的六个档位，可得三层价格结构的实际分解。结果如图7.2所示，其中面板（a）为价格水平的绝对分解，面板（b）为各层占市场价的结构比重。




图 7.2 六档位价格的三层分解 (2026 年第二季度)

注：纵轴口径为元/百万物理词元；六个档位为本书按能力与成本特征归并的抽象分类，不对应任何具体商业产品或服务商；效值系数与折算方法见第 5 章。数据来源：作者校准复算。

图 7.2 给出三点观察。第一，三层的绝对水平随档位陡峭上升。成本底价层由轻量蒸馏级的 0.18 元升至推理增强级的 3.36 元，相差 18.7 倍；市场价则由 0.40 元升至 14.00 元，相差 35 倍。第二，价格结构随档位系统性地由成本主导转向租金主导。成本底价层占市场价的比重由轻量蒸馏级的 45% 降至推理增强级的 24%，而场景租金层的比重由 32% 升至 44%。这一结构性转变意味着，低档位词元的价格竞争实质上是成本竞争，高档位词元的价格竞争实质上是价值竞争——两者不可用同一套政策工具治理。第三，多模态级的结构自成一格。多模态级的场景租金比重达 43%，高于效值系数更高的旗舰闭源级的 41%，其原因在于多模态词元的场景效用维度突出，价值实现更多依赖场景而非纯粹的推理能力。

若要在档位之间做真正有意义的比较，必须把三层价格一并折算为标准词元口径。由 $\tilde{p} = p/\eta$ 与式(7-3)可得折算后的三层分解，如式(7-7)所示。

$$\tilde{p}_m = \frac{p_m}{\eta_m} = \frac{p_m^f}{\eta_m} + \frac{p_m^\eta}{\eta_m} + \frac{p_m^s}{\eta_m} = \tilde{p}_m^f + \tilde{p}_m^\eta + \tilde{p}_m^s \quad (7-7)$$

其中， $\tilde{p}_m^f$ 、 $\tilde{p}_m^\eta$ 、 $\tilde{p}_m^s$ 分别为标准词元口径的成本底价层、效值溢价层与场景租金层，量纲为元每百万标准词元。

式(7-7)看似只是一次除法，其结果却构成本章最重要的结构性发现。折算之后，三层的离散程度出现了极为悬殊的分化。成本底价层在物理词元口径下的极差为 18.7 倍，折算为标准词元口径后骤降至 1.66 倍——由轻量蒸馏级的 0.474 元每百万标准词元到推理增强级的 0.785 元，几乎构成一条水平线。这意味着效值折算几乎完全吸收了成本侧的档位差异：不同档位的成本差异，绝大部分是「生产了不同的东西」而非「效率高低不同」。与之形成鲜明对照的是，折算后

的效值溢价层极差仍达 4.36 倍、场景租金层极差仍达 4.25 倍，二者合计使折算后的标准词元单价仍有 3.11 倍的离散——由轻量蒸馏级的 1.053 元每百万标准词元到推理增强级的 3.271 元。

这一发现有三重含义，值得逐条厘清。其一，方法论含义。第 5 章曾报告，效值折算把跨档位单价的变异系数由 0.92 压至 0.31、基尼系数由 0.47 压至 0.17，价格分布明显趋近一价定律，但并未完全收敛。式(7-7)的分层结果解释了残差从何而来：残差不在成本层，而在溢价层与租金层。换言之，折算体系是有效的，它准确地消除了成本侧的不可比；剩余的离散不是折算的失败，而是市场结构与信息条件的真实反映。其二，监管含义。成本监审这一传统工具在词元市场上的适用范围因此被严格限定：既然折算后的成本层已近乎一价，继续以成本核查去解释或压缩价差就是无的放矢；真正需要治理的是溢价层的信息不对称与租金层的锁定效应。其三，补贴含义。按物理词元计发的补贴，其实际补贴强度随档位效值反向变化：同样补贴 1 元，轻量蒸馏级可换来的标准词元数是推理增强级的 3.1 倍。若政策目标是推动高价值场景的深度应用，按物理词元计发的补贴就会系统性地偏离目标——这是第 10 章讨论城市词元运营中心补贴设计时必须处理的核心技术问题。

7.3 平台竞争下的价格动态：加成、学习曲线与收敛路径

7.3.1 加成结构：差异化伯特兰均衡与勒纳指数

三层结构刻画的是价格的截面构成，价格的时间路径则由竞争决定。词元市场的竞争形态介于伯特兰竞争与垄断竞争之间：产品高度差异化（效值不同、生态不同、合规条件不同），但同一档位内部的可替代性很强，且转换成本因统一接口与路由平台的普及而持续下降。在差异化产品的价格竞争中，各服务方在给定对手价格时选择自身价格最大化利润，一阶条件给出经典的勒纳加成式，如式(7-8)所示。

$$\frac{p_m - c_m^{MC}}{p_m} = \frac{1}{|\varepsilon_{mm}|}, \varepsilon_{mm} = \frac{\partial q_m}{\partial p_m} \cdot \frac{p_m}{q_m} \quad (7-8)$$

其中， ε_{mm} 为档位 m 的自价格需求弹性；弹性绝对值越大，均衡加成率越低，产品趋于同质时 $|\varepsilon_{mm}| \rightarrow \infty$ 、加成归零，退化为标准伯特兰结果。

以本书校准的边际成本与市场价计算，六档位的勒纳指数由轻量蒸馏级的 0.720 升至推理增强级的 0.851，用量加权均值为 0.768。这一数值有一个耐人寻味的参照：第 8 章估计的词元市场需求价格弹性为 -1.34（标准误 0.19，

$N = 864$)，其绝对值的倒数为 0.746。两个数字如此接近，提示当前词元市场的实际加成幅度，大体相当于把整个词元市场视为一个差异化产品群时的理论加成水平。这一对照不宜被读作垄断定价的证据——市场层需求弹性与企业层需求弹性是两个不同的对象，后者通常远大于前者——但它确实说明一个结构性事实：竞争主要发生在档位内部，而非档位之间。买方在同一档位的不同供给者之间高度价格敏感，却较少因为价格而跨档位替代，因为跨档位替代意味着任务达成度的改变。这正是效值不可比所造成的竞争分割：档位之间缺少公共的当量尺度，价格竞争便无法穿透档位边界。

需求弹性的行业异质性进一步印证了这一判断。分行业估计显示，制造业为-1.62、金融业为-0.94、文化传媒业为-1.71、政务领域为-0.68。弹性绝对值最大的是文化传媒与制造业——前者的任务标准化程度高、可替代方案多，后者对成本高度敏感；弹性最小的是政务与金融——前者受合规与安全约束、供给方选择受限，后者的错误代价高、不轻易更换供给。弹性结构直接决定了各行业在式(7-8)中面对的加成水平，也解释了为什么面向政务与金融的词元服务往往以专属定制形态出现（见 7.4 节），而面向文化传媒的服务则最先被卷入价格战。

7.3.2 规模经济与学习曲线：成本下行的两条通道

加成率决定价格与成本的距离，成本本身的下行则决定价格的长期走向。词元生产的成本下行有两条通道：一是式(7-2)的规模摊薄，即固定成本被更大的产量分摊；二是学习效应，即累计产量的增长带来单位可变成本的持续下降。后者可写成标准的学习曲线形式，如式(7-9)所示。

$$C_{m,t}^{MC} = C_{m,0}^{MC} \left(\frac{Q_{m,t}}{Q_{m,0}} \right)^{-b_m}, b_m = - \frac{\ln(1 - \zeta_m)}{\ln 2} \quad (7-9)$$

其中， $Q_{m,t}$ 为累计产量， ζ_m 为累计产量每翻一番的单位成本降幅， b_m 为学习曲线指数。

两条通道的经济性质并不相同，混淆二者会导致对价格前景的误判。规模摊薄是可逆的：产量一旦下滑，单位固定成本立即回升，价格地板随之抬起；学习效应则是不可逆的，它凝结为工程知识、系统架构与运维经验，不因产量波动而消失。词元产业当前的价格下行同时受两条通道驱动：调用量在两年内由日均 1000 亿枚增至 140 万亿枚（国家数据局口径，2024 年初至 2026 年 3 月，增长约 1400 倍），既带来空前的规模摊薄，也带来空前的学习积累。但两条通道的可持续性不同——一旦调用量增速回落，规模通道的贡献将迅速衰减，价格下行的斜率会随之变缓。这一判断与 7.3.3 节由指数序列反解出的收敛路径一致。

还需指出学习效应在词元产业中的一个特殊来源：推理系统的公共知识化。与传统制造业的学习效应主要沉淀在企业内部不同，推理优化的关键进展多以论文与开源实现的形式公开（Yu 等，2022；Kwon 等，2023；Agrawal 等，2024；Zhong 等，2024），这使得学习曲线的收益在行业内部快速扩散，单一服务方难以凭借系统优化建立持久的成本优势。其定价后果是深刻的：成本优势的可持续性下降，价格竞争的烈度上升，而竞争的落脚点被迫从成本转向效值与场景。这也从一个侧面解释了为什么头部服务方近年纷纷强化场景服务能力与生态绑定——在成本无法形成护城河的条件下，租金层是唯一可防御的阵地。

7.3.3 价格的收敛路径与半衰期

把加成结构与成本下行结合，即可刻画价格的时间路径。设服务方按目标加成定价，但因合约期限、调价成本与观望行为，实际价格向目标价格部分调整，调整速度为 δ ，则价格路径服从式(7-10)。

$$\dot{p}_t = -\delta(p_t - p^\infty) \Rightarrow p_t = p^\infty + (p_0 - p^\infty)e^{-\delta t}, t_{1/2} = \frac{\ln 2}{\delta} \quad (7-10)$$

其中， p^∞ 为长期均衡价格， $t_{1/2}$ 为价格向长期水平收敛的半衰期，即价格与长期水平的距离缩小一半所需的时间。

以本书编制的两套价格指数反解调整速度（暂令 p^∞ 趋于零以取得下行速度的上界估计），物理词元价格指数在 9 个季度内由 100 降至 21，对应季度调整速度 0.173、半衰期约 4.0 个季度，折合年均降幅约 50%；标准词元价格指数同期由 100 降至 47，对应季度调整速度 0.084、半衰期约 8.3 个季度，折合年均降幅约 29%。两个半衰期相差约一倍：以物理词元计，价格每年腰斩；以标准词元计，价格约每两年腰斩。这一对照是本章最简洁的结论之一——它用一个可记忆的数字说明，未经效值调整的降价幅度系统性地夸大了真实降价的速度。对企业的成本预算、对政府的价格监测、对研究者的产业判断，两个半衰期不可互换使用。

令 p^∞ 趋于零是一个刻意保守的处理，它把全部观测降幅都归于向零收敛的过程，从而低估了真实的调整速度。若按 7.3.4 节的成本底价修正长期水平——即令 p^∞ 等于用量加权成本底价所对应的指数水平（物理词元口径约 6.4、标准词元口径约 14.3）——则调整速度上升为季度 0.207 与 0.107，半衰期相应缩短至约 3.4 个季度与约 6.5 个季度。修正后的两个半衰期虽然都变短，其比值仍接近 1.93 比 1，与未修正口径下的 2.07 比 1 基本一致。这说明本章的核心判断——

物理词元口径的价格下行速度约为标准词元口径的两倍——对长期水平的设定并不敏感，是一个稳健的结论。修正的另一含义同样重要：越接近地板，剩余的下行距离越短，同样的调整速度会表现为越来越小的绝对降幅，因而以过去两年的降价斜率外推未来价格，将系统性地高估降幅。

7.3.4 价格地板、下行空间与价格上行的可能

价格不会无限下行。由式(7-4)，长期价格的下限是用量加权的成本底价，因而在任一时点上，价格的可持续下行空间存在一个可计算的上界，如式(7-11)所示。

$$\Delta_t^{max} = 1 - \frac{\sum_m w_{m,t} p_{m,t}^f}{\sum_m w_{m,t} p_{m,t}}, \sum_m w_{m,t} = 1 \quad (7-11)$$

其中， $w_{m,t}$ 为档位 m 在 t 期的用量份额； Δ_t^{max} 为在不侵蚀成本底价的前提下，加权平均价格可以再下降的最大比例。

以2026年的用量份额计算，用量加权的市场价为每百万物理词元2.764元，其中成本底价0.844元、效值溢价0.815元、场景租金1.106元，三层占比分别为30.5%、29.5%与40.0%，因而下行空间上界为69.5%。这一数字必须被极为审慎地解读。它的字面含义是：若效值溢价与场景租金被竞争完全消除，价格还能再降近七成。但把它读作价格前景的预测是错误的，理由有二。第一，溢价与租金归零意味着模型研发投入无从回收。式(7-2)已表明固定成本占平均成本近一半，价格若真降至成本底价，服务方将无法覆盖训练与研发支出，长期供给能力将被侵蚀，这是典型的静态效率与动态效率的权衡。第二，成本底价本身并非固定不动。电力约束收紧、算力供给紧张或利用率下降都会抬升地板；式(7-1)的分母 u_m 与式(7-4)的摊销产量 T_m 一旦逆转，地板会上移。

现实已经提供了价格上行的样本。据公开报道，一家国产头部大模型服务商自2026年8月17日零时起对主力接口实行峰谷分时定价：高峰时段为北京时间9时至12时、14时至18时，空闲时段价格为高峰时段的一半，改价后高峰时段的输出价格较改价前有明显上调。这一调整在定价理论上具有双重意义。其一，它是拥塞定价的引入。当算力在特定时段成为紧约束时，其影子价格为正，价格必须随之分时，否则只能以排队与降级的形式配给——这与电力、交通领域的峰谷定价逻辑完全一致，也验证了第3章关于词元价格内生时段性的判断。其二，它是成本回收压力的显性化。在竞争把加成压至临界水平之后，服务方要么退出，要么通过时段分割、缓存差别定价与档位重组恢复回收能力。因此，「词

元价格单调下行」不是规律，而是特定阶段的表象；本章的框架预期的是分层的、非单调的价格演化：成本底价层随技术进步缓慢下移，效值溢价层随能力分化而波动，场景租金层随竞争与制度条件而涨落，三者的合成完全可能在某些区间呈现上行。

7.4 三级服务定价：二级价格歧视与自选择

三层结构解释了价格的构成，竞争动态解释了价格的走向，二者仍未回答一个现实问题：面对异质的买方，服务方应当提供怎样的价格菜单。词元服务市场已经自发形成了三级结构——普惠包、按需套餐与专属定制，它们并非营销包装的差异，而是典型的二级价格歧视安排：服务方无法直接观测买方的用量规模与场景价值密度，只能设计一组合约，让买方按自身类型自选择。设买方类型为 θ （综合反映用量规模与场景价值密度），从用量 q 中获得的毛收益为 $v(\theta, q)$ ，第 k 份合约的固定费为 A_k 、单价为 p_k ，则菜单必须满足参与约束与激励相容约束，如式(7-12)所示。

$$U(\theta)=max_k\left\{v(\theta, q_k)-A_k-p_k q_k\right\} \geq 0, U'(\theta)=\frac{\partial v}{\partial \theta}(\theta, q(\theta)) \tag{7-12}$$

其中，第一式为参与约束（买方选择最优合约后的净收益非负），第二式为激励相容的包络条件， $U(\theta)$ 即买方的信息租金，随类型单调递增。

式(7-12)的标准推论是：高类型买方获得接近效率水平的用量并留下正的信息租金，低类型买方的用量被向下扭曲；服务方的收入结构因此必然向高类型倾斜。本书校准的三级服务结构如表 7.2 所示，其数值与这一推论高度吻合。

表 7.2 三级词元服务的定价结构与自选择结果（2026 年）

服务档	单价乘数	用户占比 (%)	词元用量占比 (%)	收入占比 (%)	户均收入相对倍数	典型合约特征与适配对象
普惠包	0.90	62.0	26.8	21.0	0.34	低固定费、限额用量、共享算力池、无专属服务等级承诺；适配中小企业与初次接入的探索性应用
按需套餐	1.00	31.0	43.7	38.0	1.23	按实际调用量计费、阶梯

						折扣、基本服务等承诺；适配用量稳定、场景明确的规模化应用
						高固定费、专属算力与模型微调、严格时延与可用性承诺、数据与合规隔离；适配政务、金融等高合规、高价值密度场景
专属定制	1.60	7.0	29.5	41.0	5.86	

注：单价乘数以按需套餐为 1；词元用量占比由收入占比与单价乘数折算得到；户均收入相对倍数为收入占比与用户占比之比，反映各档单个用户的相对贡献。数据来源：作者校准复算。

表 7.2 显示出典型的「长尾—头部」二重结构。普惠包覆盖 62%的用户，却只贡献 21%的收入，户均收入仅为平均水平的 0.34 倍；专属定制的用户占比仅 7%，却贡献 41%的收入，户均收入是平均水平的 5.9 倍，相当于普惠包用户的 17 倍。这一结构在数字服务市场中并不罕见，但在词元市场上具有特殊含义：普惠包不是亏本的营销手段，而是自选择机制的必要组成部分。若取消普惠包，低类型买方将退出市场，服务方并不能因此获得更多收入；保留普惠包并以较低单价供给，既扩大了接入规模、强化了第 6 章的网络协同效应，也没有侵蚀高档合约的收益——只要普惠包的用量限额与服务等级设定得当，高类型买方就不会向下自选择。

三级结构与 7.2 节的三层价格结构之间存在清晰的对应关系，这一对应是理解服务分级的钥匙。普惠包压缩的是租金层。它以标准化交付、共享算力池与限额用量换取低单价，服务方放弃场景定制因而也放弃了场景租金，同时以池化提高利用率 u_m 、以规模摊薄固定成本，从两个方向压低成本底价。按需套餐调节的是用量维度。阶梯折扣的实质是式(7-12)中固定费与边际单价的组合在离散点上的实现：承诺用量越高，边际单价越低，买方沿激励相容曲线自选择合适的承诺档。专属定制放大的是租金层。专属算力与模型微调抬高了成本底价，严格的时延、可用性与合规隔离承诺则显著提高了使用方的转换成本 ψ_j ，按式(7-6)， ρ_j 随之上升。把单价乘数与三层结构对照即可看出：专属定制相对按需套餐 60%的溢

价，绝不是专属算力所带来的成本差异所能解释的，其主要成分是租金层的扩张。

这一对应关系直接给出一条政策红线。普惠包的低单价若仅仅来自租金层的放弃与利用率提高，则是效率改进，可持续；若单价被压到成本底价之下，则本质上是交叉补贴或引流定价，其后果是双重的：一方面无法长期维持，另一方面会挤出同等效率的市场化供给。因此，城市词元运营中心在设计面向中小企业的普惠包时，「不低于成本底价」应当成为定价的下限约束，价格优惠应通过统一采购的规模折扣、闲时算力的错峰使用与政策抵扣来实现，而不是通过长期低于地板的挂牌价来实现。式(7-4)因此不仅是一个成本公式，也是一条可操作的合规基准——它把「补贴用词元」的政策取向约束在不扭曲市场价格信号的范围之内。

三级结构的福利含义需要辩证评价。一方面，二级价格歧视扩大了市场覆盖：若强制单一价格，边际买方会被排除在外，社会福利未必更高（Mussa 和 Rosen，1978；Bhargava 和 Choudhary，2008）；平台掌握用量与效果数据后实施的精细化定价，其福利效果也取决于市场结构与信息条件，并非一概有害（Dubé 和 Misra，2023）。另一方面，价格歧视把信息租金从买方转移给卖方，且合约条款的复杂化本身构成搜寻与比较成本，中小企业尤易在合约丛林中支付「复杂性溢价」。这为城市词元运营中心提供了明确的公共品定位：以统一入口与统一计量降低比较成本，以政府背书的普惠包稳定低端合约的条款，其经济功能不是替代市场定价，而是降低二级价格歧视的交易费用与信息壁垒。第 10 章将从机制设计角度论证这一安排的激励相容条件，第 13 章则以五城案例检验其实际形态。

7.5 词元价格指数：TPI、STPI 与背离的经济含义

7.5.1 为什么需要一套词元价格指数

价格结构与价格动态的分析，最终要落到一个可持续观测的总量指标上。这正是价格指数的功能：把一族异质的、条款各异的价格压缩为一条可比的时间序列，供宏观监测、合同调价、补贴核定与增长核算使用。但词元价格指数的编制面临三重困难，任何一重处理不当都会使指数失去意义。

第一重困难是产品的持续质变。这是特征价格指数理论的经典问题：当商品的质量在观测期内发生显著变化时，未经调整的价格比较将系统性失真（Griliches，1961）。特征价格方法把价格回归到产品特征上，以特征系数折算质量变化，但其识别与实施均有严格前提，且在特征快速演化的产品上稳健性

受限（Pakes，2003；Erickson 和 Pakes，2011）；官方统计机构如何在实践中处理质量调整，长期是价格统计的核心议题（Groshen 等，2017）。云计算价格指数的编制经验尤其值得借鉴——研究表明，若不对计算能力、存储与网络性能的改进做质量调整，云服务价格的下降幅度会被严重低估（Byrne 等，2018）；而数字服务的跨境交付又使传统统计边界难以适用（Coyle 和 Nguyen，2019）。词元的质变速度远高于云计算：同一档位的模型能力以季度为周期迭代，特征维度（上下文长度、推理深度、多模态支持）本身也在增加。

第二重困难是权重的漂移。词元用量在档位之间的分布变化极快。当低价档位的份额上升时，即便每一档位的价格分文未降，支出加权的均价也会下降。现有的第三方指数正受制于此：由第三方数据服务商发布的词元支出指数，其自我界定即为「支出（用量）加权的每百万词元平均价格」，衡量的是「当前整个市场为一百万词元实际支付多少钱，与具体模型无关」，覆盖前沿接口、开放权重推理平台、经纪化专用实例与自托管参考部署。这样的口径对观测市场总支出强度极有价值，但它把价格变化与结构变化混在一起，无法回答「同样的东西是否变便宜了」。同一时期，路由平台上中国模型与美国模型的加权均价相差二十倍以上（每百万词元约 0.18 美元对约 4 美元），其中同样混杂了档位结构、开放权重比例与折扣策略三重因素，不能读作同等能力下的价格差。第三重困难是口径的不可通约。挂牌价与成交价、缓存命中与未命中、峰谷时段、长上下文档位、不同语言的分词膨胀率，使得同一名义价格对应着完全不同的实际支付。任何指数都必须先声明其计量状态，否则序列前后不可比。

本书的应对是双轨编制：同时编制物理词元口径的词元价格指数（TPI）与效值折算口径的标准词元价格指数（STPI），并把二者的背离作为一个独立的、有经济含义的观测量。这一思路与总量价格指数测度的理论进展相通——当产品集合与质量同时变动时，单一指数不足以承载全部信息，必须以指数之间的关系来识别结构性变化（Redding 和 Weinstein，2020）；也与我国数字化转型对经济统计提出的挑战一脉相承（许宪春等，2021）。

7.5.2 编制方法：篮子、权重与链式处理

两套指数采用同一链式拉氏框架，差别仅在于价格的计量单位。TPI 以物理词元为计量单位，其编制如式(7-13)所示。

$$TPI_t = TPI_{t-1} \times \sum_m w_{m,t-1} \frac{p_{m,t}}{p_{m,t-1}}, w_{m,t-1} = \frac{p_{m,t-1} T_{m,t-1}}{\sum_n p_{n,t-1} T_{n,t-1}} \quad (7-13)$$

其中， $T_{m,t}$ 为档位 m 在 t 期的物理词元用量， $w_{m,t-1}$ 为上期支出份额权重；基期取2024年第一季度，指数值为100。

STPI则以标准词元为计量单位，把各档位价格先折算为标准词元单价再构造价格比率，如式(7-14)所示。

$$STPI_t = STPI_{t-1} \times \sum_m \tilde{w}_{m,t-1} \frac{\tilde{p}_{m,t}}{\tilde{p}_{m,t-1}}, \tilde{p}_{m,t} = \frac{p_{m,t}}{\eta_{m,t}}, \tilde{w}_{m,t-1} = \frac{\tilde{p}_{m,t-1} \tilde{T}_{m,t-1}}{\sum_n \tilde{p}_{n,t-1} \tilde{T}_{n,t-1}} \quad (7-14)$$

其中， $\tilde{T}_{m,t} = \eta_{m,t} T_{m,t}$ 为标准词元用量。

式(7-13)与式(7-14)之间有一个容易被忽略却极为重要的性质：两套指数的权重完全相同。因为 $\tilde{p}_m \tilde{T}_m = (p_m / \eta_m) (\eta_m T_m) = p_m T_m$ ，标准词元口径的支出与物理词元口径的支出恒等，故 $\tilde{w}_{m,t-1} \equiv w_{m,t-1}$ 。这意味着二者的全部差异都来自价格比率的分母是否经过效值折算，而不来自权重口径的不同——这为后文的背离分解提供了干净的识别条件。三点编制处理需要说明。其一，链式而非固定篮子。词元产品的迭代速度使固定篮子在两三个季度内即告失效，链式处理以逐期更新的权重适应品种更替，其代价是链式漂移，本书以季度频率作为在时效与漂移之间的折中（第5章5.5.4节已讨论同一取舍）。其二，计量状态的固定。编制中统一按「缓存未命中、标准上下文档位、按需套餐、非高峰时段」的状态取价，缓存命中与峰谷折扣按固定命中率与固定时段结构折算，以避免状态漂移混入价格变化。其三，新档位的接入。新出现的档位在其首次进入篮子的当期不计入价格比率，自次期起参与，这是链式指数处理新产品的标准做法，其代价是新品种进入初期的价格快速下降未被完全捕捉，因而本书的TPI对降幅的估计是保守的。

两套指数的完整序列见表7.3，其走势与背离如图7.3所示。

表 7.3 词元价格指数与标准词元价格指数的季度序列（2024Q1—2026Q2）

季度	TPI (物理词元口径)	STPI (标准词元口径)	背离 (指数点)	TPI 环比降幅 (%)	STPI 环比降幅 (%)	平均效值当量指数
2024Q1	100.0	100.0	0.0	—	—	1.000
2024Q2	87.3	92.7	5.4	12.7	7.3	0.942
2024Q3	74.7	85.3	10.6	14.4	8.0	0.876
2024Q4	62.0	78.0	16.0	17.0	8.6	0.795
2025Q1	51.5	70.5	19.0	16.9	9.6	0.730
2025Q2	41.0	63.0	22.0	20.4	10.6	0.651
2025Q3	35.0	58.5	23.5	14.6	7.1	0.598
2025Q4	29.0	54.0	25.0	17.1	7.7	0.537
2026Q1	25.0	50.5	25.5	13.8	6.5	0.495
2026Q2	21.0	47.0	26.0	16.0	6.9	0.447

注：基期为2024年第一季度，指数值100；TPI与STPI的编制方法分别见式(7-13)与式(7-14)，二者权重相同、仅价格计量单位不同；平均效值当量指数为TPI与STPI之比，度量每枚物理词元所含标准词元当

量相对基期的变化。两套指数均为本书编制，非官方发布指数，也不对应任何第三方商业指数的口径。数据来源：作者校准复算。




图 7.3 词元价格指数与标准词元价格指数（2024Q1—2026Q2）

注：2024 年第一季度 = 100，季度频率；阴影为两指数之差。两套指数均系本书校准复算编制，非官方发布指数。数据来源：作者校准复算。

表 7.3 与图 7.3 呈现出一个持续扩大且从未逆转的背离。基期两指数同为 100，至 2026 年第二季度，TPI 降至 21、STPI 降至 47，背离达 26 个指数点。背离的扩大是单调的：由 2024 年第二季度的 5.4 个指数点逐季升至 26 个指数点，没有出现任何一个季度的收窄。同样值得注意的是两条曲线的形状差异：TPI 的环比降幅在多数季度维持在两位数，最深的一个季度达 20.4%；STPI 的环比降幅则始终维持在个位数，波动也明显更小。这说明，以标准词元计量的价格下行是平缓而稳定的，而以物理词元计量的价格下行则剧烈得多，后者的剧烈程度并不全部来自价格本身。

7.5.3 背离的分解：效值提升与真实降价

背离从何而来？由式(7-13)与式(7-14)的权重恒等性可知，二者的差异只能来自价格比率中的效值折算项。把这一关系在总量层面写出，即得式(7-15)的分解恒等式。

$$\ln TPI_t - \ln STPI_t = \ln \hat{\eta}_t - \ln \hat{\eta}_0, \hat{\eta}_t = \sum_m w_{m,t} \eta_{m,t} \quad (7-15)$$

其中， $\hat{\eta}_t$ 为用量加权的平均效值系数，其相对基期的比值 $H_t = \hat{\eta}_t / \hat{\eta}_0$ 即表 7.3 末列的平均效值当量指数。

代入数据可得：2026 年第二季度的平均效值当量指数为 0.447，即每枚物理词元所含的标准词元当量降至基期的 44.7%。以本书校准的 2026 年用量份额

计算，当期平均效值系数为 1.43，据此回推基期的平均效值系数约为 3.19。这一变化的直观含义是：2024 年初的调用高度集中于高效值的旗舰与推理增强档位，而到 2026 年，轻量蒸馏级与开源旗舰级已经承担了大部分调用量。

这里必须澄清一个极易发生的误读：平均效值当量的下降，与技术意义上的效值提升，并不矛盾，反而互为因果。效值系数是相对当期基准档定义的相对量（第 5 章），技术进步表现为整个能力前沿的上移：今日的中型通用级，其绝对能力已相当于两年前的旗舰档位。前沿上移的直接后果是能力下沉——原本必须调用高档位才能完成的任务，如今由低档位即可胜任，需求随之向低价档位大规模迁移。于是我们观察到两个同时发生的现象：技术上，单位算力所能达成的任务能力大幅提升；结构上，成交词元的平均效值当量显著下降。二者的合成，就是物理词元均价的超常下行。因此，表观降价中有相当大的一部分并不是「同一件东西变便宜了」，而是「买方转而购买了当量更低、却足以完成任务的东西」——它是技术进步的成果，但不是价格的下降。把这一部分计入真实降价，会同时高估通缩幅度与产业让利幅度。表观降价的来源分解如图 7.4 所示。




图 7.4 表观降价的来源分解（2024Q1—2026Q2）

注：分解在对数可加口径下进行；「效值提升贡献」指表观降幅中由成交词元平均效值当量变化所解释的部分，「真实降价贡献」指单位标准词元价格的实际下降。数据来源：作者校准复算。

图 7.4 给出本章的核心量化结论：2024 年第一季度至 2026 年第二季度，物理词元价格指数累计下降 79 个指数点（降幅 79%），其中约 53%来自效值提升、约 47%为真实降价；同期以标准词元计量的价格累计下降 53%。这一分解有四重政策与理论含义。其一，价格监测。若价格主管部门以物理词元均价作为监测指标，将会观察到一条年均腰斩的曲线，从而对产业的盈利能力与投资回

报做出过度悲观的判断；双轨指数则同时呈现真实降价与质量改善两条线索。其二，通缩测度。人工智能服务尚未纳入我国官方价格统计的常规篮子，一旦纳入，质量调整方法的选择将直接决定其对整体物价指数的贡献方向与幅度（Groshen 等，2017；Byrne 等，2018）。其三，增长核算。第 12 章将标准词元流量引入生产函数，其价格平减必须使用 STPI 而非 TPI，否则实际投入量将被系统性高估。其四，补贴核定。按物理词元计发的补贴在效值当量持续下降的背景下，其实际购买的有效能力逐年缩水，补贴强度会在无人察觉的情况下自动衰减——这为第 10 章主张以标准词元作为补贴计量单位提供了直接证据。

7.5.4 指数的使用纪律与制度化路径

价格指数是公共品，其权威性依赖于口径的透明与纪律的严格。本书提出五条使用纪律。纪律一：本书编制的 **TPI** 与 **STPI** 均为校准复算结果，不具有官方性质。两套指数由本书按式(7-13)与式(7-14)编制，其档位划分为抽象分类，不对应任何具体商业产品；引用时须注明系作者编制。纪律二：不得与第三方商业指数并列比较。第三方支出指数是支出加权的全市场成交均价，其口径包含结构漂移；把「指数点位相对高点跌近两成」与「绝对均价由 2.04 美元跌至 1.16—1.18 美元、跌幅逾四成」并列使用，会得到自相矛盾的叙述——前者是指数点位口径，后者是绝对价格口径。纪律三：调用量口径必须锁定官方锚点。涉及总量的换算只能使用国家数据局公布的四个锚点：2024 年初日均 1000 亿枚、2025 年 6 月底突破 30 万亿枚、2025 年底 100 万亿枚、2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍；其余时点均为本书校准复算插值，官方并未单独发布，引用时须明确标注。纪律四：物理词元与标准词元的换算值不得作为统计数据引用。官方发布的调用量全部是物理词元口径，本书按平均效值系数所做的标准词元换算仅供分析使用。纪律五：计量状态必须随价格同时声明。缓存状态、时段、上下文档位与语言结构任一变化，都会改变实际支付价格。

从长期看，词元价格指数应当由学术编制走向制度化编制，而制度化需要三项基础设施同步到位。第一项是计量与运营的规范基础。目前词元领域已有团体标准落地：由中国人工智能产业发展联盟归口、编号 AIIA/T 0308—2026 的《人工智能词元（Token）运营管理能力要求》于 2026 年 8 月发布，中国信息通信研究院的《人工智能 Token 服务质量能力要求》则把「Token 计量计费」列为六个评估维度之一。但须准确认识其效力层级：团体标准与机构评估规范的效力低于国家标准与行业标准，截至目前，词元计量与计费领域尚无国家标准或行业标准发布，也未检索到以词元计量、计费为标题的国家标准计划。第二项是

术语与统计口径的规范基础。2026年3月25日，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用人工智能领域名词 token 的中文名「词元」，并明确将在常态化审定中结合社会推广应用情况最终确认；这是术语定名的法定程序，与国家数据局局长在中国发展高层论坛 2026 年年会上使用并推介该译名、提出词元「可计量、可定价、可交易」的经济计量表述，属于两个不同层面的动作，不可混同为「已成国家标准」。第三项是效值披露的制度基础。没有可核验的效值口径，STPI 就无法由第三方独立复算；据媒体转引，中国信息通信研究院正在推进词元分级体系、成本透明的定价框架与行业共识性价格指引等工作，这属于规划性表述，尚未形成公开发布的标准文本，但其方向与本书主张一致。标准化本身即具有可观的生产率效应——物流标准化的实证研究显示，标准的统一通过降低交易费用显著提升企业全要素生产率（何凡等，2025），标准设定的组织形态与共识机制亦有成熟的经济学分析（Farrell 和 Saloner，1985；Simcoe，2012）。词元计量与价格指数的标准化，其潜在收益的性质与此同类。

7.6 本章小结

本章回答了全书第二个科学问题的前半部分：词元的价格如何形成、如何演化。出发点是对两个流行判断的辨析。其一，词元不是零边际成本产品：增量供给来自重新计算而非复制，式(7-1)把单位词元的边际成本分解为算力占用、能源与运维三项，并揭示其对模型规模、上下文长度、有效算力利用率与电价的敏感性，也说明了缓存状态与时段何以成为价格结构的组成部分。其二，边际成本定价在词元产品上必然失效：式(7-2)表明平均成本恒高于边际成本，本书校准的固定成本份额均值达 47.4%，按边际成本定价将使全部研发与资本投入无从回收。加成因此是必然的，问题只在于加成锚定于什么。本章论证，成本加成与竞争对标两条路径分别因无法解释同成本价差与缺少外部锚点而失效，价值锚定是唯一与价值论一致的选择，而它的可行性恰恰依赖于第 5 章的效值折算体系——既有的四套词元质量评价工作（中国信息通信研究院的六维评估与四维标准体系、中国工业互联网研究院的五维价值度量、清华大学团队的三项实测指标）提供的是达标基线与维度得分，尚不能合成为可进入价格公式的单一当量。

本章的核心理论贡献是三层定价结构。式(7-3)把词元价格分解为成本底层、效值溢价层与场景租金层，三层分别由式(7-4)的成本函数、式(7-5)的质量梯度甄别与式(7-6)的可分配剩余分成所决定，并分别对应第 6 章价值创造、能力差异与价值实现三个环节。六档位的分解结果显示，价格结构随档位系统性地

由成本主导转向租金主导：成本底价层的比重由 45% 降至 24%，场景租金层的比重由 32% 升至 44%。更关键的发现来自式(7-7)的折算：效值折算几乎完全吸收了成本侧的档位差异，却几乎没有触动溢价层与租金层的离散——成本底价层的极差由 18.7 倍降至 1.66 倍，而折算后的效值溢价层与场景租金层仍分别有 4.36 倍与 4.25 倍的离散。这一结果同时解释了第 5 章「折算后价格趋近但未达到一价定律」的残差来源，并把政策的着力点从成本监审转向效值披露与竞争条件。

在价格动态方面，式(7-8)的加成结构显示六档位用量加权的勒纳指数为 0.768，与市场需求弹性绝对值的倒数 0.746 接近，提示竞争主要发生在档位内部而非档位之间——档位间缺少公共当量尺度，价格竞争难以穿透档位边界。式(7-9)区分了可逆的规模摊薄与不可逆的学习效应，并指出推理系统优化的公共知识化使成本优势难以持久，竞争因而被迫转向效值与场景。式(7-10)由指数序列反解出两个半衰期：物理词元口径约 4.0 个季度、标准词元口径约 8.3 个季度，相差约一倍。式(7-11)进一步给出下行空间上界 69.5%，但同时论证价格并非单调下行——2026 年 8 月峰谷分时定价的出现，正是拥塞定价与成本回收压力共同作用的结果。式(7-12)的二级价格歧视分析则解释了普惠包、按需套餐与专属定制三级结构的自选择逻辑：7% 的用户贡献 41% 的收入，而普惠包并非亏本的营销手段，而是自选择机制不可缺少的组成部分。

本章的第二项理论贡献是价格指数的双轨编制与背离分解。式(7-13)与式(7-14)在同一链式拉氏框架下编制 TPI 与 STPI，并证明二者权重恒等、差异仅源于效值折算，从而为分解提供了干净的识别条件。式(7-15)给出分解恒等式，数据显示两指数的背离由基期的零扩大至 2026 年第二季度的 26 个指数点，平均效值当量指数降至 0.447。本章论证，平均效值当量的下降与技术意义上的效值提升互为因果：前沿上移导致能力下沉，需求向低价档位迁移，物理词元均价因而超常下行。据此，表观累计降幅 79% 中约 53% 来自效值提升、约 47% 为真实降价，同期标准词元价格实际下降 53%。这一分解对价格监测、通缩测度、增长核算与补贴核定四个方向均有直接含义，其中最重要的一条是：按物理词元计发的补贴，其实际强度会随效值当量的下降自动衰减，必须改以标准词元计量。

本章的结论向后续章节输出三项结果，并须坦承两点局限。三项输出是：三层结构中的效值溢价层与场景租金层为第 8 章的市场结构、需求弹性与柠檬市场分析提供了价格侧的微观基础；价格地板对有效算力利用率的敏感性把定价与第 9 章的配置效率直接连通，调度水平低下在价格上表现为地板抬升；STPI 则是第 12 章增长核算中标准词元流量平减的唯一合意价格指数。两点局限是：其一，

三层分解依赖于对成本底价的校准，而单位词元能耗至今没有厂商发布的官方口径，公开的权威测算分母均为「一次查询」，因而底价层的能源项存在不确定性——但三层的相对结构与折算前后的离散度对照对该参数并不敏感；其二，两套指数的档位划分为抽象分类，档位内部的模型异质性未被完全刻画，若未来能够获得服务商层面的微观计费数据，指数的粒度可以显著细化。这两点均有待更细粒度的计费与能耗微观数据加以改进。

第 8 章 词元市场的结构、竞争与均衡

第 7 章把词元价格拆成成本底价、效值溢价与场景租金三层，并以词元价格指数（TPI）与标准词元价格指数（STPI）的背离刻画了「表观降价」与「真实降价」的差别：2024 年第一季度至 2026 年第一季度，TPI 由 100 降至 25，STPI 同期仅降至 50.5。价格的构成既明，一个更基本的问题随之浮现：这样的价格是在什么样的市场里形成的？价格三层结构描述的是单个卖者的定价逻辑，而任何一个价格都不是卖者单方面决定的结果，它同时是需求侧支付意愿、供给侧成本结构与市场组织形式共同作用的产物。若不刻画市场结构，三层结构就只是一个会计式的分解；只有把它放回市场，才能回答价格为何如此、将往何处去、以及何种干预是有效的。

词元市场的特殊性使这一追问格外必要。其一，交易标的是流量而非存量：企业购买的不是一件可以入库的商品，而是按调用即时生成并即时消耗的认知服务，市场出清发生在毫秒尺度上。其二，计价单位不同质：第 3 章已经证明物理词元不可加，第 5 章的折算体系表明六档位单位价格的极差达 12.6 倍、变异系数 0.92，折算后才降至 2.4 倍与 0.31——在一个计量单位本身就带有质量维度的市场上，「同一商品的一价定律」失去了直接的适用对象。其三，交易组织高度平台化：算力方、模型方与应用方之间极少发生双边直接缔约，绝大多数交易经由平台完成路由、计量与结算，平台不只是撮合者，还同时充当计量者与认证者。这三点决定了词元市场既不是标准的商品市场，也不是标准的要素市场，而是一个以多边平台为组织核心、以非同质计量单位为交易对象的新型市场。

正因如此，围绕词元市场的现实判断长期处于相互矛盾的状态。一种流行的判断是「赢者通吃」：训练固定成本巨大、推理具有显著规模经济、平台具有网络效应，词元市场终将走向自然垄断；另一种判断则相反：价格以年均过半的速度下行、开源模型不断压低进入门槛、集中度持续下降，词元市场正在走向充分竞争。两种判断各自都有事实支撑，却指向完全相反的政策取向——前者要求事前的结构性监管，后者要求放手让价格机制发挥作用。本章的任务，是把这场争论拉回可检验的分析框架：以需求函数与成本函数为两翼，以均衡条件与竞争强度指标为判据，分别回答市场形态是什么、需求侧与供给侧的行为方程是什么、均衡具有什么性质、以及在什么环节上市场会失灵。

本章安排如下。8.1 节刻画词元市场的多边平台形态，界定四类主体、三组交叉网络外部性与平台的三项职能；8.2 节从派生需求出发导出企业词元需求函数，给出价格弹性的结构表达式并报告估计结果，进而把两年间的调用量扩张分

解为沿需求曲线的移动与需求曲线的外移；8.3 节刻画供给侧的词元工厂，给出产能的技术决定式、成本函数与规模经济度，揭示效值与产能之间的替换关系；8.4 节求解短期与长期均衡，以最小有效规模、次可加性与可竞争性三项判据检验自然垄断假说，并以勒纳指数与集中度的背离刻画真实的竞争强度；8.5 节分析四类市场失灵及其矫正工具；8.6 节为本章小结。

8.1 市场形态：算力方—模型方—应用方的多边平台结构

8.1.1 三层交易结构与四类市场主体

智能经济中围绕词元展开的交易并非单一层次，而是一条由三层市场串联而成的链条。第一层是算力市场，交易标的是以 PFLOPS·h、卡时或标准机架计量的计算能力，供给方是智算中心与云服务商，需求方是模型训练与推理服务的提供者；第二层是词元市场，交易标的是模型服务按物理词元计量的输出，供给方是模型服务提供者，需求方是应用开发者与企业用户；第三层是应用市场，交易标的是嵌入业务流程的智能应用，计价方式转为订阅、席位或按业务结果收费。三层市场的计量单位依次为算力单位、词元单位与业务单位，每一次跨层转换都伴随一次计量口径的改变，也伴随一次价值的重新分割。

本章所称「词元市场」特指第二层。之所以要把它单独切分出来，是因为它是三层链条中唯一同时受到成本约束与价值约束双重挤压的环节：向下，它的价格不可能长期低于算力与能源构成的成本底价；向上，它的价格不可能超过应用侧所能实现并让渡的场景价值。第 7 章的三层价格结构正是这一双重约束在定价公式上的投影——成本底价层来自第一层市场，场景租金层来自第三层市场，只有效值溢价层是词元市场自身的产物。换言之，词元价格的三层结构与市场组织的三层结构是同一事物的两面，理解定价必须先理解市场分层。云计算的市场演化提供了可资借鉴的先例：计算能力一旦以可计量、可即时购买的服务形式提供，企业的资本投入门槛与规模门槛都会显著下降，市场结构随之从少数自建者主导转向大量轻资产使用者共存（Byrne 等，2018；Coyle 和 Nguyen，2019；DeStefano 等，2025）。

在词元市场上活动的主体可分为四类。算力方提供以 PFLOPS·h 计量的计算能力，其资产是集群、机房、电力与网络，收益方式是产能出租或产能入股；模型方提供以效值系数 η 表征的模型能力，其资产是模型权重、训练数据与工程经验，收益方式是按调用分成或授权许可；应用方是需求的最终来源，其购买词元并非为了持有，而是为了在具体场景中替代或增强人类认知劳动，因而其支付意愿由场景效用 S 决定；平台居于三者之间，承担路由、计量与认证，收益方式是

通道费、价差或增值服务费。第五类主体是政府与监管者，它虽不直接参与交易，却通过标准制定、补贴核定与政策抵扣、价格监测与安全审计塑造着交易的规则边界，这一角色在词元市场上比在多数商品市场上都要吃重，原因将在 8.5 节说明。

四类主体之外，词元市场的组织形态还有一个中国特色的制度变量：城市级词元运营中心的密集设立。2026 年 7 月中旬至 8 月中旬不到一个月内，温州、嘉兴、广州、苏州先后启动词元运营或交易服务机构，上海则在软件和信息服务业「十五五」规划中提出「探索将词元、数据治理、大模型部署及再训练等投入，纳入企业技术改造支持方向」（「上海市经济和信息化委员会，2026」）。四地的运营主体类型各不相同：温州由国资控股的专业运营公司承担、电信运营商与其云公司提供底座支撑，嘉兴由市属城投集团运营面向市场的统一服务窗口、多方共建，苏州由电信运营商在国家级数据要素流通枢纽内设立，广州则依托数据交易所建设并设立词元交易专区、出具交易凭证。需要特别提示口径：嘉兴门户的提法是「五个统一」（统一 API 入口、统一词元计量、统一费用结算、统一政策抵扣、统一安全审计），苏州中心的提法是「六大类服务」，温州中心的提法是「六个统一」，广东中心的职能则包括标准制定、合规鉴证、场内交易、惠企扶持与跨境流通；三者分属平台治理能力、服务菜单与交易场所职能三种不同性质的清单，条目数不构成可比的能力评分，不得作横向比较。这些机构的组织模式与机制设计留待第 10 章展开，本章只取其市场结构含义：词元市场的交易组织正在由纯粹的商业平台走向「商业平台 + 公共平台」的双层结构。

8.1.2 多边平台性质与三组交叉网络外部性

把词元市场识别为多边平台市场，需要满足两个条件：存在两个及以上互不相同且无法直接高效缔约的用户群体，以及群体之间存在交叉外部性且平台能够将其内部化（Armstrong，2006；Jullien 等，2021）。词元市场同时满足两条。算力方、模型方与应用方是三个技术能力与商业诉求截然不同的群体，任意两方直接缔约都要付出巨大的搜寻、计量与履约成本；而三方之间的相互依赖极强——没有算力则模型无法迭代，没有模型则应用无从落地，没有应用则算力无从摊薄。平台的存在把这些相互依赖从外部性转化为可交易的内部关系。词元市场的多边平台结构如图 8.1 所示。




图 8.1 词元市场的多边平台结构

图 8.1 刻画的三组交叉网络外部性各有其独立的作用机理，值得逐一辨析。第一组是算力规模与模型迭代速度之间的外部性：可调度算力规模越大，模型的训练与调优周期越短、可尝试的技术路线越多，模型能力的提升速度越快；反过来，模型迭代越快，对算力的需求越稳定，算力方的投资风险越低。这组外部性的强度由规模律所刻画的算力—性能关系决定，而算力预算的最优配置本身也随规模律的形态而变（Kaplan 等，2020；Hoffmann 等，2022）。第二组是模型丰富度与应用规模之间的外部性：平台可调用的模型条目越多、覆盖的能力谱系越宽，应用方越容易为每一类任务找到合适的供给，接入意愿越强；应用规模越大，模型方获得的调用分成与真实场景反馈越多，入驻意愿越强。这是典型的双边正反馈，也是平台竞争中「模型超市」策略的经济基础。第三组外部性的方向与前两组不同，它作用于成本而非效用：应用侧用量规模越大，算力方的批处理规模越大、空转时段越少，单位算力成本越低，这一成本下降经由价格竞争传导回应用侧，进一步扩大用量。三组外部性中，前两组是需求侧的规模效应，第三组是供给侧的规模效应，三者共同构成词元市场的自增强回路，也共同解释了平台在市场组织中的核心地位（Katz 和 Shapiro，1985；吴双和王勇，2024）。

词元平台与经典双边平台仍有一处关键差异，值得单独指出。经典双边平台的「匹配」是把两侧用户介绍给对方，随后的交易在用户之间完成，平台退居其

后；词元平台的「匹配」却发生在每一次调用内部——平台需要在毫秒量级内决定这一次请求由哪一档模型、在哪一片算力上执行，交易的执行本身就是匹配的结果。日均百万亿量级的调用规模决定了这种匹配不可能由人工撮合完成，只能由路由算法完成；而路由算法的目标函数写法，直接决定了市场的资源配置效率。这一点使词元平台比一般双边平台承担了更强的配置职能，也使「平台是否按社会最优而非自身收益最优路由」成为一个真实的监管议题——数字平台以价格机制与数据机制双重方式影响资源配置（刘诚和夏杰长，2023），而当匹配权高度集中于平台时，数据机制的权重会系统性上升（Bergemann 和 Bonatti，2024）。

交叉外部性还决定了平台的价格结构。双边市场理论的基本结论是，平台向各边收取的费率不应按各边的成本分摊，而应按各边对另一边施加的外部性强度与自身需求弹性反向确定：对外部性输出强、需求弹性大的一边少收甚至补贴，对外部性接受多、需求弹性小的一边多收（Armstrong，2006）。词元平台的现实定价与这一结论高度吻合：对模型方普遍采取零接入费甚至给予流量倾斜，对算力方采取产能保底或联合投资，而把主要收费落在应用侧。城市词元运营中心在此之上又加了一层政策变量——政策抵扣与技改补贴实质上是由财政对应用侧的一次性负价格，其作用是在正反馈回路尚未自我维持的阶段人为提高应用侧的接入速度。这一安排的激励相容条件与退出条件，是第 10 章演化博弈模型要回答的问题。

8.1.3 平台的三项职能与交易费用的节约

图 8.1 把平台的职能概括为撮合匹配、计量结算与质量认证三项。这一概括不是对现实功能清单的罗列，而是对交易费用类型的对应：撮合匹配节约的是搜寻与议价费用，计量结算节约的是计量与监督费用，质量认证节约的是度量与履约费用。三类费用在词元市场上都异常高昂。搜寻费用高，是因为可选模型条目数以百计而任务类型以千计，逐一试用的成本远超单次调用的价值；计量费用高，是因为词元的计费口径本身高度复杂——输入与输出分别计价、缓存命中与未命中分别计价、长上下文另设档位、峰谷时段另设价目，企业若无统一计量便无法核对账单；度量费用高，则是因为词元的质量在购买前不可观测、在使用后也难以归因，这正是 8.5 节柠檬市场问题的根源。

三项职能的分工还解释了为什么词元市场上会出现公共属性的平台。撮合匹配具有明显的私人品性质，谁匹配谁受益，商业平台有充分激励提供；计量与认证却带有公共品性质：统一的计量口径与可核验的质量凭证，其收益弥散于所有

市场参与者，任何单一商业平台既缺乏提供的激励，也缺乏被各方接受的中立性。标准的经济学文献早已指出，兼容性标准与质量披露制度的供给往往需要超越单个企业的协调机制（Farrell 和 Saloner，1985；Dranove 和 Jin，2010；Simcoe，2012），物流标准化对企业生产率的提升效应也提供了中国情境下的直接证据（何凡等，2025）。城市词元运营中心把统一计量、统一结算、统一审计与政策抵扣捆绑在同一个入口上，本质上是以公共平台补足商业平台在公共品职能上的供给缺口。这一判断构成本书第 10 章制度设计的出发点，也构成本章 8.5 节矫正工具的选择依据。

需要强调的是，平台职能的集中同时带来两个方向相反的效应。正向效应是交易费用的大幅节约：企业一次接入即可按需调用上百款模型条目，无需分别缔约、分别对账、分别评测。负向效应是议价权与信息权的集中：平台既掌握路由权，又掌握计量权，还在相当程度上掌握质量认定权，三权合一意味着市场的关键信息不对称并未消失，而是从「买卖双方之间」转移到了「平台与两侧之间」。平台经济的福利分析已反复表明，平台规则的设定权是比价格更根本的市场权力（顾聪等，2023）。因此，本章 8.5 节把平台锁定单列为一类市场失灵，第 10 章则把统一计量与统一审计的制度化列为机制设计的首要条目。

8.2 需求侧：企业词元需求函数与价格弹性

8.2.1 词元需求是派生需求：从场景价值到需求函数

企业购买词元不是为了消费词元本身，而是为了在某一场景中获得认知产出。词元需求因而是典型的派生需求：它的规模由最终产出的价值与词元在产出中的技术地位共同决定，而不由词元自身的效用决定。这一性质在数据要素定价研究中已被反复指出——中间品的价格必须回溯到其在下游生产中的边际贡献才能得到解释（熊巧琴和汤珂，2021；Pei，2022；欧阳日辉和杜青青，2022）。据此，本节从企业的生产决策出发导出词元需求函数，而非直接设定需求曲线。

设企业 i 在场景 j 中以标准词元 $\tilde{T}_{ij}$ 与互补投入 X_{ij} 生产认知产出 Q_{ij} 。互补投入包括数据治理、系统集成、提示与 workflow 工程以及必要的人工复核，它们是词元发挥作用的前提，其重要性在第 6 章价值实现的分析中已经确立。采用柯布一道格拉斯形式：

$$Q_{ij} = A_{ij} \tilde{T}_{ij}^{a_j} X_{ij}^{b_j}, a_j > 0, b_j \geq 0, a_j + b_j < 1 \quad (8-1)$$

其中， A_{ij} 为企业的场景适配效率， a_j 与 b_j 分别为标准词元与互补投入的产出弹性， $a_j+b_j<1$ 表示单一业务流程内部的认知生产存在规模报酬递减。

记场景 j 单位认知产出的价值密度为 u_j （即第 6 章测算的场景价值密度，跨场景差异达 5.9 倍，最高为科研分析、最低为文案生成），标准词元价格为 $\tilde{p}$ ，互补投入价格为 w 。企业最大化 $u_j Q_{ij} - \tilde{p} \tilde{T}_{ij} - w X_{ij}$ ，两个一阶条件为：

$$u_j a_j \frac{Q_{ij}}{\tilde{T}_{ij}} = \tilde{p}, u_j b_j \frac{Q_{ij}}{X_{ij}} = w \quad (8-2)$$

其中，两式左端分别为标准词元与互补投入的边际价值产品；两式相除即得最优投入比 $X_{ij}/\tilde{T}_{ij} = (b_j/a_j)(\tilde{p}/w)$ ，说明互补投入随词元价格上升而同向调整，二者在数量上是互补的，在价值上却相互替代。

将最优投入比代回式(8-2)的第一式并整理，得到企业的标准词元需求函数：

$$\tilde{T}_{ij}^* = \Phi_{ij} \tilde{p}^{-\varepsilon_j} w^{-\frac{b_j}{1-a_j-b_j}}, \varepsilon_j = \frac{1-b_j}{1-a_j-b_j}, \Phi_{ij} = [u_j a_j A_{ij} (b_j/a_j)^{b_j}]^{\frac{1}{1-a_j-b_j}} \quad (8-3)$$

其中， ε_j 为场景 j 的词元需求价格弹性， Φ_{ij} 为需求规模因子，它把场景价值密度 u_j 、企业适配效率 A_{ij} 与技术参数打包在一起，决定需求曲线的位置而不决定其斜率。

式(8-3)有三项性质值得展开。第一，弹性必然大于 1。由 $a_j>0$ 可得 $\varepsilon_j = (1-b_j)/(1-a_j-b_j) > 1$ ，即在无约束的最优化框架下，词元需求必定富有弹性。其经济机理是双重的：价格下降既通过边际条件直接增加词元用量，又通过互补投入的同向扩张间接增加词元用量，两个渠道叠加使弹性超过 1。第二，弹性随规模报酬程度上升而放大：当 $a_j+b_j \rightarrow 1$ 时 $\varepsilon_j \rightarrow \infty$ ，说明在认知生产接近规模报酬不变的场景（如可完全自动化的批量任务），需求对价格极端敏感。第三，弹性与需求规模因子相互独立，这意味着「场景价值高」与「需求对价格敏感」是两件事：科研分析类场景的价值密度最高，但若其认知生产的规模报酬递减程度也最强，其需求弹性反而可能偏低。这一区分对定价策略与补贴设计都有直接含义——对高价值低弹性场景降价，扩量效果有限而收入损失确定。

8.2.2 预算刚性与吸收能力约束：为什么部分行业的弹性小于 1

式(8-3)预言所有场景的需求弹性都大于 1，但这一预言在数据上并不总能成立。原因在于，无约束最优化隐含了两个现实中经常不满足的假定：企业能够自由调整词元支出，且能够无限扩张互补投入。对于预算按年度核定、采购须经审批的主体（如政务与部分金融机构），词元支出更接近一个外生给定的额度；对

于互补投入受制于数据治理进度与人员能力的企业，词元用量还存在一个短期不可突破的吸收上限。把这两项约束引入，需求函数变为：

$$\tilde{T}_{ij} = \min \left\{ \Phi_{ij} \tilde{p}^{-\varepsilon_j}, \frac{B_{ij}}{\tilde{p}}, \dot{T}_{ij} \right\} \quad (8-4)$$

其中， B_{ij} 为核定的词元支出预算， $\dot{T}_{ij}$ 为受互补投入与吸收能力约束的用量上限；三项分别对应最优化需求、预算约束需求与能力约束需求。

式(8-4)给出了一个分段的弹性结构：当最优化需求为最小值时，弹性为 $\varepsilon_j > 1$ ；当预算约束绑定时， $\tilde{T} = B/\tilde{p}$ ，弹性恰为 1；当能力约束绑定时，需求对价格完全无反应，弹性为 0。因此，任何一个行业的观测弹性都是三种状态的加权平均，取值落在 $[0, \varepsilon_j]$ 区间内，而观测到小于 1 的弹性，恰恰是预算刚性与吸收能力约束绑定的信号，而非需求函数设定有误的证据。这一识别具有明确的政策含义：对弹性小于 1 的行业，降价并不能有效扩大用量，真正的约束在预算制度与吸收能力上；相应的政策工具应当是预算科目的调整、政策抵扣的直达，以及互补投入（数据治理与 workflow 改造）的能力建设，而不是继续压低价格。企业采纳生成式人工智能的国际证据同样显示，采纳的分布高度不均，且差异主要由组织与技能条件而非价格条件解释（Czarnitzki 等，2023；Bick 等，2024；Humlum 和 Vestergaard，2025）。

8.2.3 计量设定与估计结果

将式(8-3)与式(8-4)对数化并加入固定效应，得到可估计的需求方程。考虑到企业实际面对的报价与账单以物理词元计，估计以物理词元价格 p_{it} 与物理词元用量 T_{it} 为变量，效值差异由模型档位构成的控制向量吸收：

$$\ln T_{it} = \phi_i + \lambda_t + \varepsilon \ln p_{it} + z'_{it} \gamma + \xi_{it} \quad (8-5)$$

其中， ϕ_i 为企业固定效应，吸收企业规模、行业属性与适配效率等不随时间变化的异质性； λ_t 为季度固定效应，吸收技术进步、政策冲击与共同的市场景气； z_{it} 为控制向量，包含模型档位构成、任务结构与互补投入强度； ε 即需求价格弹性。

识别的主要威胁是价格与用量的联立性：观测到的价量组合既可能来自需求曲线的移动，也可能来自供给曲线的移动。本章的处理有三。其一，季度固定效应吸收了全国性的降价冲击，这类冲击对所有企业同时发生，是供给侧的共同移动；其二，控制向量中纳入模型档位构成，避免把「企业转用更便宜的低档位」误读为「价格下降引致用量上升」；其三，以企业所在地算力供给的扩张作为价

格的外生变动来源做稳健性检验——算力扩建主要由能源与土地条件驱动，与单个企业的需求冲击相互独立。经上述处理，估计所得弹性可在谨慎意义上解释为需求弹性。企业词元需求曲线的拟合与分行业弹性如图 8.2 所示。




图 8.2 企业词元需求曲线与价格弹性

注：横轴为物理词元价格的对数（元／百万物理词元），纵轴为企业季度词元用量的对数；散点为按回归样本分布随机抽取展示的企业一季度观测，弹性估计基于全部回归样本；阴影为弹性 95%置信区间对应的拟合带；内嵌小图报告分样本估计的分行业弹性绝对值，虚线为全样本弹性。数据来源：作者基于企业一季度面板校准复算。

图 8.2 显示，企业词元需求在对数尺度上呈现良好的线性关系，全样本需求价格弹性为-1.34（标准误 0.19， t 值-7.05），95% 置信区间为 $[-1.52, -1.16]$ ， R^2 为 0.83，回归样本量为 864。弹性绝对值显著大于 1，与式(8-3)的理论预言一致；将其代回弹性表达式可以反解需求函数的结构参数：若互补投入的产出弹性为零，则词元投入的产出弹性 α 为 0.254；若互补投入的产出弹性取 0.3，则 α 降至 0.178。这一量级与第 12 章宏观生产函数中标准词元流量的产出弹性并不冲突：微观场景内部的词元投入弹性刻画的是单一业务流程的技术关系，宏观弹性则是全经济范围内的加权结果，后者必然小于前者。分行业弹性与全样本估计的对照见表 8.1。

表 8.1 企业词元需求函数的估计结果与分行业弹性

项目	全样本	制造	金融	文化传媒	政务
需求价格弹性 ϵ	-1.34*** (0.19)	-1.62	-0.94	-1.71	-0.68
95%置信区间	[-1.52, -1.16]	—	—	—	—

t 值	-7.05	—	—	—	—
R ²	0.83	—	—	—	—
观测数 N	864	—	—	—	—
支出对价格的弹性 $1+\varepsilon$	-0.34	-0.62	0.06	-0.71	0.32
需求类型	富有弹性	富有弹性	缺乏弹性	富有弹性	缺乏弹性
绑定的主要约束	最优化需求	—	预算与吸收能力	—	预算与吸收能力

注：括号内为标准误，***表示在 1%水平显著；全样本列为式(8-5)的双向固定效应估计，价格与用量均取对数，价格口径为元/百万物理词元；分行业列为分样本估计的弹性点估计，受分样本规模限制不报告标准误与拟合优度；支出对价格的弹性按式(8-3)的支出恒等式计算为 $1+\varepsilon$ ，负值表示降价使总支出扩大。数据来源：作者基于企业一季度面板校准复算。

表 8.1 揭示出一条清晰的分界线。文化传媒（-1.71）与制造（-1.62）的弹性绝对值显著大于 1，属富有弹性；金融（-0.94）与政务（-0.68）的弹性绝对值小于 1，属缺乏弹性。按式(8-4)的分段结构，前者对应最优化需求主导的状态，后者对应预算约束或能力约束绑定的状态。这一分界与两组行业的制度特征高度吻合：文化传媒的内容生成任务标准化程度高、可自动化比例大，词元价格下降可以立即转化为产量扩张；制造业的设计、质检与工艺优化任务同样具有明确的可替代人工基准，降价的扩量效应显著。金融与政务则受制于合规审查、采购审批与数据出域限制，用量在短期内难以随价格调整，其需求更接近于按年度额度执行。

支出弹性一行提供了另一个层面的信息。全样本的支出对价格弹性为 -0.34，为负值，意味着降价将扩大而非缩小词元总支出——市场处于「以价换量且量的增幅足以覆盖价的降幅」的区间，这正是供给方持续降价而收入仍在增长的微观基础。但分行业看，金融（0.06）与政务（0.32）的支出弹性为正，降价会直接缩减这两个行业的词元支出规模。这意味着面向不同行业的降价具有完全不同的收入含义：在弹性行业降价是投资，在刚性行业降价是让利。三级服务定价体系恰恰是对这一差异的市场化回应——普惠包覆盖了 62%的用户却只贡献 21%的收入，专属定制仅覆盖 7%的用户却贡献 41%的收入，用户结构与收入结构的错位说明市场已在自发地按弹性分层（其二级价格歧视机理已在第 7 章分析）。

8.2.4 需求扩张的分解：沿曲线移动与曲线外移

有了弹性估计，就可以回答词元经济最引人注目的一个事实：我国日均词元调用量由 2024 年初的 1000 亿枚增至 2025 年 6 月底的 30 万亿枚、2025 年底的 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍（国家数据局口径；上述四个时点为官方发布的锚点，其间各季度的点位系校准复算

插值，官方未单独发布）。这一扩张究竟有多少来自降价、多少来自需求本身的增长？在恒弹性需求下，两者可以严格分解。

以 2024 年第一季度至 2026 年第一季度为窗口（两端均为官方锚点所在季度），物理词元价格指数由 100 降至 25，价格降至原来的 0.25。在弹性为 -1.34 的条件下，纯价格效应引致的用量扩张为 6.4 倍，占对数总增幅的 25.6%；其余部分即需求曲线的外移，幅度达 218 倍，占对数总增幅的 74.4%。换言之，两年间约四分之一的调用量扩张是沿着既有需求曲线的移动，约四分之三来自需求曲线本身的整体外移。把「词元用量暴增」简单归因于「模型降价」，在数量级上是站不住脚的。

需求曲线外移的来源可以按式(8-3)的需求规模因子 Φ_{ij} 拆成三项。第一项是场景扩张，即新的高价值场景 u_j 被打开。可溯源的证据来自基于百万亿量级词元数据的平台侧观察：在 2024 年 11 月至 2025 年 11 月的样本区间内，编程类请求的词元占比从区间初的 11% 升至区间末的 50% 以上，成为最大的单一使用品类，而由智能体驱动的多步骤自动化工作流所产生的输出词元已超过平台总输出的一半（该口径为第三方模型路由平台的内部统计，仅覆盖经该平台路由的调用，不能外推为全行业结构）。第二项是企业适配效率 A_{ij} 的提升，即同样的场景中企业学会了用更少的返工、更短的提示与更成熟的工作流获得可用产出，这一项正是第 6 章「持续学习」增值机制在需求侧的映像。第三项是效值提升带来的实际质量上升：同期标准词元价格指数仅由 100 降至 50.5，降幅明显小于物理词元价格指数，其差额意味着企业以同样的支出买到了能力更强的词元，需求曲线因而在质量维度上外移。三项来源在政策含义上完全不同：第一项依赖场景开发，第二项依赖能力建设，第三项依赖模型进步，没有一项能由价格补贴直接作用；而价格补贴唯一能够触及的渠道——沿需求曲线的移动——恰恰只解释了扩张的四分之一。

把价格与用量合并，还可以得到市场规模的直接推算：物理词元价格降至 0.25、用量增至 1400 倍，两者相乘意味着词元市场的支出总额在两年间扩大了约 350 倍。这一数量级说明，尽管单价以年均过半的速度下行，词元市场仍处在典型的「价降量升、总额膨胀」的扩张期。市场规模的快速膨胀是理解后续两节的必要背景：它既是供给侧持续扩产的收益基础，也是判断自然垄断假说时不可忽略的分母。

8.3 供给侧：词元工厂的产能、效率与成本曲线

8.3.1 词元工厂：产能的技术决定式与效值—产能替换

「词元工厂」这一称谓并非修辞。2026 年 7 月，电信运营商在温州揭牌了以此命名的推理服务设施，其组织形态与制造业工厂高度同构：以算力为原料，以模型为工艺，以调度为生产计划，以词元为产成品，产能、良率、单位成本与产线切换构成日常管理的核心变量。把这一设施形式化，可以给出词元供给的技术决定式。记模型集为 M ，模型 m 分得的算力为 C_m (PFLOPS·h)，其算力利用率为 u_m ，单位算力的标准词元转化效率为 θ_m ，则设施的标准词元产能为：

$$\hat{T} = \sum_{m \in M} \theta_m C_m u_m, \sum_{m \in M} C_m \leq \hat{C} \quad (8-6)$$

其中， $\hat{C}$ 为设施的算力总量约束； θ_m 的测算与 u_m 的分解是第 9 章的主题，本章将其作为已知参数使用。

式(8-6)揭示了词元供给区别于传统制造业供给的根本特征：产能不是一个标量，而是一个依赖于产品组合的函数。同一片算力，全部投向轻量蒸馏级还是全部投向推理增强级，标准词元产能相差 13.5 倍（单位算力转化效率分别为 42.0 万与 3.1 万标准词元每 PFLOPS·h）；若按物理词元计，差距进一步扩大至 153 倍。这意味着供给曲线是「可重构」的：厂商无需新增一瓦算力，仅通过调整模型组合就能沿着效值—产能前沿滑动。这一可重构性是词元市场供给弹性的主要来源，也是短期均衡分析中不可忽略的自由度。

效值与产能之间存在明确的替换关系：高效值档位的单位算力产出更低，低效值档位的单位算力产出更高。若把标准词元价格作为权重，可以得到单位算力的收入水平——以中型通用级为 1，轻量蒸馏级为 1.84，开源旗舰级为 0.64，旗舰闭源级为 0.53，推理增强级仅为 0.42。也就是说，仅从单位算力收入看，把算力投向低档位是更「划算」的选择；高效值档位之所以仍然存在并占据高价位段，不是因为它对算力更经济，而是因为它所服务的任务无法由低档位完成。这构成一个重要判断：词元市场的分层不是价格歧视的结果，而是技术不可替代性的结果；档位之间的竞争关系远弱于档位内部，价格战因而主要发生在同档位内部。这一判断将在 8.4.3 节以勒纳指数的反解得到独立印证。

8.3.2 成本函数、规模经济与最小有效规模

词元生产的成本由两部分构成。固定部分包括模型训练与持续调优的摊销、集群与机房的折旧、基础软件栈的研发与运维，它们在给定的产能配置下不随调

用量变化；可变部分主要是推理时段的电力消耗、网络流量与随负载增加的运维投入。以标准词元产量 $\tilde{T}$ 为自变量，短期成本函数与平均成本为：

$$C(\tilde{T})=F+c\tilde{T}, AC(\tilde{T})=\frac{F}{\tilde{T}}+c, MC=c \quad (8-7)$$

其中， F 为固定成本， c 为单位标准词元的可变成本；在给定产能内，边际成本恒为 c ，平均成本随产量单调下降，这是词元生产短期规模经济的直接来源。

式(8-7)的线性设定只在产能约束以内成立。一旦产量逼近并超过设施的设计负荷，排队时延上升、批处理效率下降、缓存命中率恶化，边际成本转而上升——推理服务系统的实测研究表明，显存管理、连续批处理与预填充—解码分离等工程手段能够显著推迟这一拐点，但无法消除它（Yu 等，2022；Kwon 等，2023；Agrawal 等，2024；Zhong 等，2024），大规模推理的并行策略同样受制于访存带宽与通信开销的硬约束（Dao 等，2022；Pope 等，2023）。把长期中设施规模可调、但协调成本随规模上升的因素一并纳入，长期平均成本呈 U 型：

$$LAC(q)=LAC^*\left[1+\varphi\left(\ln\frac{q}{q^*}\right)^2\right], \frac{dLAC}{dq}\bigg|_{q=q^*}=0 \quad (8-8)$$

其中， q 为日产标准词元规模， q^* 为最小有效规模（MES）， LAC^* 为该点的长期平均成本， φ 为曲率参数；对数二次形式保证 LAC 在 q^* 两侧对称递增，且弹性随偏离程度线性放大。

规模经济的强度可以用成本弹性的倒数度量：

$$S(q)=\frac{AC(q)}{MC(q)}=\left[\frac{d\ln C(q)}{d\ln q}\right]^{-1} \quad (8-9)$$

其中， $S>1$ 表示规模经济、 $S=1$ 表示规模报酬不变、 $S<1$ 表示规模不经济；在式(8-7)的短期成本结构下， $S=1+F/(c\tilde{T})$ ，即规模经济强度完全由固定成本的摊薄程度决定。

按校准复算的成本参数，六档位的固定成本占平均成本的比重均在 47.4%上下，相应的规模经济度 S 约为 1.90——边际成本仅相当于平均成本的 52.6%。这一结构有两个直接推论。其一，严格的边际成本定价在词元生产中必然亏损，价格必须高于边际成本才能回收固定投入，这是零边际成本类产品定价困境的一般形态（Mussa 和 Rosen，1978；Bhargava 和 Choudhary，2008），也是第 7 章效值溢价层与场景租金层存在的成本论依据。其二，规模经济的强度随产量上升而衰减：产量翻一番， S 向 1 收敛的速度与固定成本份额成正比，因而规

模优势并非无限，它在某一产量之后就基本耗尽——这个产量就是最小有效规模，也是判断自然垄断的关键参数。

8.3.3 六档位的成本测算与两点发现

把式(8-7)至式(8-9)应用于六个模型档位，并同时报告物理词元口径与标准词元口径的成本，可得表 8.2。两种口径的并列不是重复，而是本书方法论的一次直接检验：如果效值折算体系成立，那么在标准词元口径下，不同档位的单位成本应当显著收敛。

表 8.2 六档位词元生产的转化效率、成本结构与加成率

模型档位	转化效率 θ (万 STE / PFLOPS- h)	边际成本 (元/百万物理词 元)	边际成本 (元/百万 STE)	平均成本 (元/百万 STE)	单位算力 收入指数 (中型通 用级 = 1)	价格一边 际成本 加成率
轻量蒸馏级	42.0	0.112	0.295	0.558	1.84	72.0%
中型通用级	18.5	0.322	0.322	0.614	1.00	75.2%
开源旗舰级	9.2	0.651	0.332	0.632	0.64	80.3%
旗舰闭源级	5.4	1.203	0.409	0.779	0.53	82.8%
推理增强级	3.1	2.083	0.487	0.926	0.42	85.1%
多模态级	6.8	0.918	0.350	0.666	0.54	81.6%

注：转化效率 θ 取自第 9 章的算力—词元转化测算；物理词元口径与标准词元口径之间按第 5 章的效值系数 η 换算；单位算力收入指数 = $\theta \times$ 标准词元价格，以中型通用级为 1；加成率 = $(p - MC)/p$ ， p 为市场价。校准复算对六档位设定了同构的固定—可变成本结构（固定成本约占平均成本 47.4%），故各档位的规模经济度 AC/MC 均约为 1.90，表中不再重复列示。数据来源：作者校准复算。

表 8.2 的第一点发现关乎折算体系的有效性。按物理词元口径，六档位的边际成本从 0.112 元到 2.083 元，极差达 18.6 倍，平均成本的极差为 18.7 倍；换算为标准词元口径后，边际成本收敛到 0.295—0.487 元区间，极差降至 1.65 倍，平均成本的极差同步降至 1.66 倍。也就是说，档位之间看似悬殊的成本差距，约九成是产品差异（生产的是不同的东西），只有约一成是效率差异（生产同样的东西而耗费不同）。这一结果与第 5 章关于单位价格离散度的发现相互印证，并给出一个具有直接操作意义的推论：在补贴核定、成本监审与跨主体成本比较中，若以物理词元为分母，将系统性地把「用了更强的模型」误判为「效率低下」，从而把补贴导向低档位、把监审压力施加于高档位——方向恰好相反。

第二点发现关乎供给侧的产品组合决策。单位算力收入指数自轻量蒸馏级的 1.84 单调下降至推理增强级的 0.42，而价格一边际成本加成率却自 72.0% 单调上升至 85.1%。两个方向相反的序列并存，刻画出一个真实的经营权衡：低档位「薄利多销」，单位算力能换来更多收入但每一枚词元的加成薄；高档位「厚利少销」，每一枚词元的加成厚但单位算力换来的收入少。厂商的最优选择取决于算力的稀缺程度：当算力紧张时，单位算力收入是决策变量，产能会向低档位倾斜；当算力宽裕而需求分层明显时，加成率是决策变量，产能会向高档位倾斜。这一权衡为第 9 章的任务—模型最优匹配问题提供了微观基础，也解释了为什么统一调度平台的价值不仅在于提高利用率，更在于把「哪一档模型接哪一类任务」从各自为政变为全局优化。

表 8.2 的一致性还可以从另一角度检验：中型通用级的标准词元平均成本为 0.614 元每百万标准词元，与式(8-8)中最小有效规模处的长期平均成本 0.61 元几乎重合。这不是巧合，而是基准档设定的必然结果——效值系数以中型通用级归一，长期平均成本曲线的最低点也以该档位的典型设施为标定对象，两者在数值上的吻合表明短期成本结构与长期成本曲线的标定相互自洽。

8.4 市场均衡与竞争格局

8.4.1 短期均衡：产能刚性与高峰负荷定价

短期内算力存量给定，模型组合虽可重构但重构本身需要时间与切换成本，因而供给在产能上限附近近乎垂直。把式(8-4)的需求与式(8-6)的产能放在一起，短期均衡由下述互补松弛条件刻画：

$$T^d(p^*) \leq \dot{T}, p^* = MC + \lambda, \lambda \geq 0, \lambda [\dot{T} - T^d(p^*)] = 0 \quad (8-10)$$

其中， λ 为产能约束的影子价格；产能宽松时 $\lambda = 0$ ，价格趋于边际成本；产能紧张时 $\lambda > 0$ ，价格中出现一块与成本无关的稀缺租金。

式(8-10)的政策含义在于，短期价格的波动未必反映成本变化，而可能仅仅反映产能约束的松紧。这一机制在现实中已经以峰谷分时定价的形式显性化：据公开报道，2026 年 8 月 17 日零时起，国内一家头部模型服务商将其接口价目由单一价格改为峰谷分时定价，高峰时段（北京时间 9:00—12:00、14:00—18:00）的价格设定为空闲时段的两倍。按式(8-10)解读，这正是典型的高峰负荷定价：在高峰时段 $\lambda > 0$ ，价格中包含稀缺租金；在空闲时段 $\lambda = 0$ ，价格回落至接近边际成本的水平。分时定价的福利效果是双重的：它把可延迟的任务从高峰移向低谷，提高了既有产能的利用率（对应第 9 章的空转损失下降），同时也把

价格信号的分辨率从「按模型」细化到「按时段」，使需求侧第一次能够在时间维度上做替代。

同样值得注意的是这一事件的方向：在经历了两年多的持续降价之后，一次幅度可观的提价出现了。这提示价格下行并非无底——当价格接近成本底价时，继续降价将无法回收固定投入，供给方或退出、或提价、或以分时与分档的方式重构价目。第 7 章测算的成本底价层，在市场层面正表现为价格的地板；本节的短期均衡条件则说明，地板之上还叠加了一块随产能松紧波动的稀缺租金。二者共同决定了短期价格的运行区间。

8.4.2 长期均衡：自然垄断假说的三项检验

长期中设施规模可调、进入与退出可行，市场结构由成本条件与需求规模共同决定。「词元市场终将走向自然垄断」的判断若要成立，须同时通过三项检验：成本函数在相关产量区间上是否严格次可加、市场需求规模相对于最小有效规模是否足够小、以及进入是否面临不可回收的沉没成本。集中度的演化与长期平均成本曲线如图 8.3 所示。




图 8.3 市场集中度演化与词元工厂的长期平均成本曲线

注：(a) 中的赫芬达尔—赫希曼指数按模型服务市场的调用量份额平方和计算，取值域为 0—1，图中 0.15 与 0.25 两条分界线参照国际通行的竞争性、中度集中与高度集中三档划分；(b) 按式(8-8)绘制，复现参数为最低点长期平均成本 0.61 元/百万标准词元、最小有效规模 1.2 亿枚/日、曲率参数 0.55。数据来源：作者校准复算。

第一项检验是次可加性。成本函数在产量 Q 上严格次可加，指的是由一家厂商生产全部产量的成本低于任意分拆生产的成本之和：

$$C\left(\sum_{k=1}^n q_k\right) < \sum_{k=1}^n C(q_k), \sum_{k=1}^n q_k = Q, n \geq 2 \quad (8-11)$$

其中， q_k 为第 k 家厂商的产量；在 U 型 LAC 下，次可加性通常只在 Q 不超过最小有效规模若干倍的区间内成立，一旦 Q 远大于 q^* ，分拆生产反而更便宜。

第二项检验因而归结为市场规模与最小有效规模的比较。按 2026 年 3 月的官方口径，我国日均词元调用量为 140 万亿枚物理词元；以用量加权效值系数 1.43 折算，约合日均 200 万亿枚标准词元。而图 8.3 (b) 显示，词元工厂的最小有效规模仅为 1.2 亿枚标准词元每日，此处长期平均成本为 0.61 元每百万标准词元。两者相除，全国市场规模约为最小有效规模的 166 万倍，即高出约 6.2 个数量级。这一比例意味着，在词元生产环节，规模经济远在市场规模之前就被耗尽，式(8-11)的次可加性在相关产量区间上并不成立。其技术根源在于推理服务的高度可分性：与发电、输配电、管网等具有物理不可分性的传统自然垄断行业不同，推理是可并行、可切分、可跨设施复制的，把总产量拆到许多设施上执行，除了少量调度开销外并不损失效率。

第三项检验涉及沉没成本与可竞争性。可竞争市场理论指出，即使在位者只有一家，只要进入与退出不需要付出不可回收的成本，潜在进入的威胁也足以把价格压至平均成本水平。设进入者需投入资本 K ，其中比重 σ 为沉没部分，则以最小有效规模进入并获得非负利润的条件为：

$$p > LAC(q^*) + \frac{\sigma K}{q^*}, \sigma \in [0, 1] \quad (8-12)$$

其中，右端第二项即沉没成本折算到单位产量上的进入壁垒； $\sigma \rightarrow 0$ 时市场完全可竞争，均衡价格趋于 $LAC(q^*)$ 。

式(8-12)把词元市场的两个环节区分开来。在推理供给环节，算力可以租用而非自建、设施可以转售或改作他用、模型可以调用开源权重， σ 接近于零，市场高度可竞争；在模型研发环节，训练投入几乎完全沉没， σ 接近于一，进入壁垒极高。二者的叠加解释了一个看似矛盾的现象：词元服务的价格竞争异常激烈，而底层模型的研发主体却高度集中。开源权重的扩散在此扮演了关键角色——它把模型研发的沉没成本从每一个进入者的资产负债表上移走，转化为一次性投入的公共知识，从而把高壁垒环节的成本结构「外部化」给了低壁垒环节。这与非竞争性知识品的经济逻辑完全一致：非竞争性使同一份知识可被无限复用，其社会最优配置要求尽可能广泛的共享 (Jones 和 Tonetti, 2020)。

三项检验的合并结论是：自然垄断假说在词元生产环节不成立。图 8.3 (a) 的经验证据与这一结论方向一致——模型服务市场的赫芬达尔—赫希曼指数由 2024 年的 0.34 降至 2025 年的 0.27 与 2026 年的 0.21，降幅达 38%，已由高度集中区间落入中度集中区间的下沿。经第三方模型路由平台整理的周度数据同样显示市场的高度分散：8 月 3—9 日当周，中国模型合计周调用量 34.25 万亿枚，占该平台全球总量 69 万亿枚的约 50%；至 8 月 10—16 日当周，中国模

型周调用量升至 36.84 万亿枚，连续 16 周超过美国模型（该榜单仅统计经该平台路由的调用，厂商官方接口直连量、国内各云平台用量与自建推理均不计入；模型国别按开发商总部人工归类；同一模型的不同版本分行计数）。需要强调的是，集中度下降并不等同于竞争充分，下一节将说明二者在词元市场上出现了显著背离。

8.4.3 竞争强度：集中度与加成率的背离

衡量竞争强度的标准工具是勒纳指数。在同质品古诺竞争下，厂商 m 的勒纳指数等于其份额除以市场需求弹性绝对值，按份额加权即得行业平均；而在纵向差异化市场上，厂商面对的是自身的残余需求，勒纳指数等于残余需求弹性的倒数。两式并列，可以构造一个刻画差异化程度的指标：

$$\dot{L} = \sum_m s_m L_m = \frac{HHI}{|\varepsilon|}, L_m = \frac{1}{|\varepsilon_m^r|}, \delta_m = |\varepsilon| L_m = \frac{|\varepsilon|}{|\varepsilon_m^r|} \quad (8-13)$$

其中， s_m 为份额， ε_m^r 为厂商面对的残余需求弹性， δ_m 为差异化指标： $\delta_m \rightarrow 0$ 表示厂商面对近乎无限弹性的残余需求（完全竞争）， $\delta_m \rightarrow 1$ 表示残余需求弹性等于市场需求弹性（该厂商在其细分市场上近乎独占）， $\delta_m > 1$ 则表示残余需求比市场需求更缺乏弹性，通常来自转换成本或互补性锁定。

以古诺基准计算，2024 年的行业平均勒纳指数应为 0.254，2026 年应降至 0.157——集中度下降三成多，加成率理应同步下降。但表 8.2 报告的实际加成率介于 72.0% 与 85.1% 之间，按用量份额加权为 76.8%，是古诺基准预测值的 4.9 倍。集中度与加成率的这一巨大背离，说明模型服务市场根本不是同质品古诺市场：厂商之间不是在同一条需求曲线上争夺份额，而是各自面对一条向下倾斜的、被差异化保护起来的残余需求曲线。

按式(8-13)反解残余需求弹性，六档位的取值介于 1.17 与 1.39 之间，与全样本市场需求弹性 1.34 处于同一量级；相应地，差异化指标 δ 从轻量蒸馏级的 0.96 单调上升至推理增强级的 1.14。这一结果的含义相当直白：各档位厂商的定价行为近似于在自身档位内的垄断定价，档位之间的交叉替代极其有限。轻量蒸馏级的 δ 略小于 1，表明该档位内部尚存在有效的价格竞争（同档位的可替代供给最多，开源权重的可得性最高）；而中高档位的 δ 持续大于 1，说明其残余需求甚至比市场需求更缺乏弹性——高效值词元的买方一旦把某一档位的能力嵌入关键业务流程，其需求就变成了近乎刚性的派生需求。

这一发现修正了对词元市场竞争格局的通常判断。集中度指标看到的是「谁占了多大份额」，加成率指标看到的是「谁能把价格抬离成本多远」；在纵向差

异化的市场上，前者下降与后者维持高位可以长期并存。政策含义随之改变：以份额为基准的结构性监管在这里几乎无从着力——没有任何一家的份额高到足以触发门槛，而竞争的实际不足却真实存在。有效的干预因而必须转向差异化的来源本身：一方面降低档位之间的信息壁垒，使买方能够判断某一任务是否真的需要更高的档位（这正是效值折算与效值公示的功能）；另一方面降低档位之间的转换成本，使买方在判断之后能够真的转换（这正是统一接口与可移植性的功能）。二者恰好对应 8.5 节要分析的前两类市场失灵。

8.4.4 价格路径：下行的收敛与止跌

把短期与长期均衡合起来看，词元价格的运行呈现出一条可以刻画的路径。第 7 章已经报告，物理词元价格指数在两年间由 100 降至 21，而标准词元价格指数同期仅降至 47。独立的第三方观察给出了同向的证据：第三方数据服务商发布的支出加权全市场成交均价指数（以每百万词元的实际成交均价计）自 2026 年 5 月 31 日的 2.04 美元回落至 8 月 6—8 日的 1.16—1.18 美元，约两个月跌逾四成，为年内最低（该指数为全市场支出加权的成交均价，不是任何单一模型的挂牌价）。同一指数还存在分段子指数：2026 年 4 月 22 日，前沿模型段为每百万词元 4.20 美元、开放权重段为 0.85 美元，二者相差约五倍。分段价差的持续存在，正是 8.4.3 节所刻画的纵向差异化在总量指标上的投影。

价格下行的收敛机制有三重。其一是成本机制：单位算力的推理效率随工程优化持续提升，成本底价随之下移，为降价提供了空间；其二是竞争机制：同档位内部的可替代供给增加，尤其是开放权重模型的扩散，压缩了同档位的加成空间；其三是需求机制：由于需求富有弹性，降价能带来足以覆盖降幅的用量扩张，厂商有单方面降价的激励。三重机制共同作用，使价格在两年间下行了近八成。但三重机制都有边界：成本底价不可能低于电力与折旧构成的物理下限，同档位竞争无法跨越档位之间的技术鸿沟，需求弹性在预算刚性行业则退化到 1 以下。当三重机制同时接近边界时，价格路径由下行转为分化——这正是 2026 年下半年所观察到的图景：总指数触及年内低位的同时，出现了结构性提价与峰谷分时定价，前沿段与开放权重段的价差稳定在数倍量级。

由此可以给出本章对价格前景的判断：词元价格的进一步下行将主要发生在标准词元口径而非物理词元口径上。物理词元价格的下行空间已被成本底价压缩，而标准词元价格仍有下降余地，其来源是效值的持续提升——同样一枚词元承载更多有效信息、完成更高比例的任务。这一判断与第 7 章 TPI 与 STPI 的背离分析一脉相承，也为价格监测的口径选择提供了依据：若监测只盯物理词元价

格，将在价格触底后失去指示意义；只有标准词元价格指数才能持续反映智能服务的真实成本变化。

8.5 市场失灵：信息、分割、锁定与计量

8.5.1 效值信息不对称与柠檬市场风险

词元市场最根本的信息问题在于：效值在购买之前不可观测，在使用之后也难以准确归因。买方能够看到的只有价格、标称的词元数量与厂商的宣称指标；至于这一百万枚词元究竟解决了多少任务、准确率如何、是否包含大量无效重复，通常要在业务流程跑完之后才可能部分察觉，而彼时费用已经发生。这正是质量不可观测市场的经典结构（Akerlof，1970）。形式化地，设效值 η 为卖方私人信息，生产成本 $c(\eta)$ 随效值递增，买方只能按市场上供给的期望效值出价，则均衡价格满足：

$$p = \tilde{p}_0 \cdot E[\eta / c(\eta) \leq p], \frac{\partial}{\partial p} E[\eta / c(\eta) \leq p] \geq 0 \quad (8-14)$$

其中， $\tilde{p}_0$ 为买方对单位标准词元的支付意愿；条件期望中的截断说明只有成本不超过市价的供给者愿意进入，效值越高的供给者越早退出，期望效值随之下移，价格进一步下调，形成向下的自我实现循环。

校准复算给出了这一机制的量化征候：企业对所购词元效值的认知偏差均值为 0.44，且偏差方向系统性地表现为低估高效值档位；受此影响，低效值档位的采购份额比效率最优配置高出 27%。这两个数字合起来描述的正是逆向选择的中间状态：市场尚未坍缩，但资源配置已经系统性地偏向低效值一侧。其福利后果是双重的——买方以为省了钱，实际上因返工与任务失败付出了更高的总成本；卖方投资高效值能力的回报被削弱，创新激励下降。

矫正逆向选择的标准工具是第三方认证与强制披露（Dranove 和 Jin，2010）。现实中已经出现四套彼此独立的评价工作，其发布主体、维度数与用途各不相同，以下逐一标明主体，其维度名称分属四套体系，不可合并、平均或交叉引用。其一，中国信息通信研究院的《人工智能 Token 服务质量能力要求》及其「可信 AI-Token 服务质量评估」，设模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度；其二，同为中国信息通信研究院于 2026 年 6 月 16 日发布的「高质量 Token 服务标准体系」，设服务质量、运营能力、生产能力、安全能力四个维度，其云计算与大数据研究所负责人明确提出「不能只看单价，行业亟须一套衡量高质量 Token 的标尺」；其三，中国工业互联网研究院《Token 驱

动智能经济研究报告（2026 年）》构建的价值度量体系，设生产成本、生产效率、准确性、生态价值、安全五个维度；其四，清华大学翟季冬团队联合企业于 2026 年 5 月发布的开源模型 Token 服务性能榜，采用首词元时延（P90 分位）、输出吞吐与缓存命中率三项实测指标。此外，中国信息通信研究院于 2026 年 6 月启动的词元服务能力攀登计划，首批联合十家企业达成的企业级通用场景性能基线为吞吐不低于 55 Token/s、首词元时延不超过 0.9 秒、调用成功率 99.9%；须注意这是首批企业达成的基线值，既非行业平均，亦非强制门槛，且与清华榜单的时延指标分位口径不同，两者不可直接比较。

把这四套工作与本书的标准词元折算体系放在一起，可以看清各自的位置与本书的增量。四套工作的共同形态是多维评价：产出的是并列的维度得分或达标基线，它们能够回答「这家服务是否达标」「在哪个维度更强」，却无法把不同模型、不同任务的词元合成为一个可加总、可计价、可入账的当量。而市场失灵的矫正恰恰需要后者：补贴要按量核定，统计要跨主体加总，出海要提供可互认的凭证，三者都要求一个单一的、可比的计量单位。本书的贡献正在于从「多维评价」推进到「当量折算」——第 5 章以四条公理约束出折算函数的形式，使异质词元获得共同尺度，从而具备进入价格指数、补贴核定与增长核算的资格。需要坦承的是，折算并不消灭信息不对称，它只是把不对称的对象从「不可名状的质量」变成「可核验的效值系数」，使认证与披露有了明确的落点。

8.5.2 算力孤岛与市场分割

第二类失灵发生在供给侧的可及性上。词元的生产依赖算力，而算力在物理上分散于不同主体、不同区域、不同技术栈之中。当这些资源无法互联互通、无法统一调度时，名义上的总供给与实际可用的供给之间就会出现巨大缺口，表现为「一边闲置、一边紧缺」的并存。可核实的证据来自国际数据公司与中国信息通信研究院联合开展的企业调研：近半数企业的智算资源利用率处于 51%—70% 的中等区间，6.7% 的企业利用率仅为 31%—50%，利用率达到 70% 以上的企业不足 35%，制造与政务行业低于平均水平；多数自建智算项目「重硬件轻软件」，缺乏统一调度平台与资源池化管理，是利用率偏低的主因（该口径为企业自建自用智算资源的自报值，与机架上架率、GPU 卡时实测利用率的统计对象和方法完全不同，不可互证）。

算力孤岛的经济性质是市场分割：它使式(8-12)中的可竞争性条件在空间上失效——某地的低价供给无法服务于他地的高价需求，价格差异不能通过套利消除。国家层面的制度回应是明确的：从全国一体化大数据中心协同创新体系的算

力枢纽布局，到「东数西算」工程与全国一体化算力网的实施意见（「国家发展改革委等，2021」；国家发展改革委等，2023），再到「数据要素×」与「人工智能+」行动对应用侧的牵引（「国家数据局等，2023」；国务院，2025），其共同指向是把分散的算力资源纳入可调度、可交易、可结算的统一网络。算力共享与算力市场培育的研究亦指出，需求侧的组织方式是决定算力资源配置效率的关键变量（王勇等，2025），而智算中心建设对企业全要素生产率的提升效应，同样取决于算力能否跨域流动并被真实使用（许诺等，2025）。本章在此只作结构定位：算力孤岛是一个供给可及性问题，它的矫正工具是调度与结算的基础设施，而非价格政策；其效率改进的上界测算是第9章的任务。

8.5.3 平台锁定与转换成本

第三类失灵来自需求侧的可转换性。企业接入某一平台或某一模型档位之后，会逐步积累一批平台专用资产：针对特定模型调优的提示与 workflow、依赖特定接口的集成代码、沉淀在特定服务中的上下文与缓存、以及围绕特定输出格式构建的下游校验规则。这些资产在转换时大部分不可携带，构成转换成本。设企业当前平台的标准词元价格为 $\tilde{p}_A$ 、备选平台为 $\tilde{p}_B < \tilde{p}_A$ ，年用量为 $\tilde{T}$ ，转换成本为 κ ，规划期 n 年、贴现率 r ，则转换有利可图的条件为：

$$(\tilde{p}_A - \tilde{p}_B) \tilde{T} \cdot \frac{1 - (1+r)^{-n}}{r} > \kappa \Leftrightarrow \tilde{T} > \tilde{T}^c = \frac{\kappa r}{(\tilde{p}_A - \tilde{p}_B) [1 - (1+r)^{-n}]} \quad (8-15)$$

其中， $\tilde{T}^c$ 为转换的临界用量；用量低于临界值的企业即使面对更低的报价也不会转换，从而被事实上锁定。

式(8-15)有三点值得强调。第一，锁定是规模依赖的：临界用量与转换成本成正比、与价差成反比，因而小用量企业最容易被锁定，而它们恰恰是普惠服务的主要对象——三级服务体系中普惠包覆盖了 62% 的用户，其单个用户的用量却远低于按需套餐与专属定制。第二，锁定放大了 8.4.3 节识别的差异化：转换成本使残余需求进一步刚性化，这正是中高档位差异化指标 δ 超过 1（最高达 1.14）的一个直接来源。第三，锁定的矫正工具是结构性的而非价格性的：统一接口标准降低集成代码的专用性，模型可移植与开放权重降低模型层的专用性，配置与上下文资产的可携带降低数据层的专用性。兼容性标准的经典分析已经指出，标准的采纳本身具有网络外部性，可能陷入协调失灵而需要外部推动（Farrell 和 Saloner，1985；Katz 和 Shapiro，1985；Simcoe，2012）。

城市词元运营中心「一次接入、全网通享」的统一 API 入口，正是以公共平台方式压低 κ 的制度尝试。

8.5.4 计量口径不统一与可加总失灵

第四类失灵是本书特有的关切，也是全书立论的起点：物理词元不可加。同一个「词元」名称之下，六档位的单位价格极差达 12.6 倍、变异系数 0.92，单位成本的极差同样在十倍量级。在这样的计量基础上，任何跨模型、跨主体、跨区域的加总都不具备经济含义：补贴按物理词元核定，等于补贴低效值；统计按物理词元汇总，等于把不同的东西相加；出海按物理词元开具凭证，等于交付一个对方无法解释的单位。这类失灵不表现为价格扭曲，而表现为「无法记账」——它损害的不是某一次交易的效率，而是整个市场的可核算性。

制度侧的进展正在发生，但需要准确表述其效力层级。术语层面，全国科学技术名词审定委员会于 2026 年 3 月 25 日发布公告，优先推荐并面向全社会发布试用 token 的中文名「词元」，并明确将在常态化审定中结合社会推广应用情况最终确认；同月，国家发展改革委党组成员、国家数据局局长在中国发展高层论坛 2026 年年会的演讲中使用并推介这一译名，提出词元具有「可计量、可定价、可交易」的特征。两个口径分属术语学与经济计量学，不可混用。标准层面，截至 2026 年 8 月，词元领域已发布的成果主要是团体标准与机构评估规范——中国人工智能产业发展联盟归口的《人工智能词元（Token）运营管理能力要求》（技术规范编号 AIIA/T 0308—2026）于 2026 年 8 月发布，其效力层级低于国家标准与行业标准；尚未见以词元计量或词元计费为标题的国家标准或行业标准发布，也尚未见面向词元的专项碳足迹核算标准立项公开。这一现状恰好说明可加总失灵仍是一个开放问题：评估活动不等于标准，团体标准不等于国家标准，而计量口径的统一最终需要国家标准层级的支撑。能源领域的经验提供了可资对照的路径——综合能耗计算通则以国家标准的形式确立了折标准煤系数与计算规则（国家市场监督管理总局和国家标准化管理委员会，2020），此后能耗的跨行业加总、目标考核与国际比较才成为可能。

8.5.5 四类失灵的比较与矫正工具的优先序

把四类失灵放在同一张表上比较，可以看清它们在机制、征候与工具上的差别，见表 8.3。

表 8.3 词元市场的四类失灵：机制、征候与矫正工具

失灵类型	微观机制	可观测征候	福利后果	矫正工具
效值信息不对称	效值为卖方私人	效值认知偏差均	资源配置偏向低	统一计量与效值

	信息，买方按期望效值出价，高效值供给逐步退出	值 0.44；低效值档位过度采购份额 27%	效值，返工与失败成本上升，创新激励削弱	公示、第三方认证与质量披露、可核验凭证
算力孤岛与市场分割	算力与模型跨主体、跨区域不可互调，名义供给大于有效供给	利用率 70% 以上的企业不足 35%，6.7% 的企业处于 31%—50% 区间	闲置与短缺并存，重复投资，区域价格差异无法套利消除	一体化算力网与统一调度、跨域计量与结算、产能交易机制
平台锁定与转换成本	提示与 workflow、集成代码、上下文与缓存构成平台专用资产	中高档位差异化指标 δ 大于 1（最高 1.14）；小用量企业的临界用量高于自身用量	事后加成率上升，同档位价格竞争弱化，普惠用户受损最重	统一 API 入口、接口与模型可移植、开放权重、配置与上下文可携带
计量口径不统一	物理词元不可加，同名不同义，跨主体加总无经济含义	六档位单价极差 12.6 倍、变异系数 0.92；折算后降至 2.4 倍与 0.31	补贴核定失准，统计不可比，跨境交付缺可互认凭证	标准词元折算体系、计量与计费标准、凭证与溯源体系

注：效值认知偏差、过度采购份额、差异化指标与单价离散度为作者校准复算值；企业智算资源利用率分布取自国际数据公司与中国信息通信研究院联合开展的企业调研，为企业自建自用智算资源的自报口径，与机架上架率、GPU 卡时实测利用率的统计对象与方法不同，不可互证。数据来源：作者整理。

表 8.3 显示，四类失灵在作用环节上依次递进：计量口径不统一发生在「记账」环节，效值信息不对称发生在「交易」环节，平台锁定发生在「续约」环节，算力孤岛则发生在「交付」环节。这一递进关系决定了矫正工具的优先序。计量是其余三者的前提——没有统一的效值折算，效值公示无从公示，跨域结算无从结算，可移植性无从核验；因此统一计量应当置于首位。其次是信息披露与认证，它把计量结果转化为买方可用的决策依据。再次是接口与移植性标准，它把决策依据转化为可执行的转换选项。调度与结算基础设施的建设周期最长、投入最大，但其收益也最依赖前三项的完成度——在计量口径不统一的条件下建成的调度平台，只能调度物理词元，无法按效值最优匹配。第 10 章将以专家判断的层次分析结果对这一优先序作独立检验，第 14 章则据此提出制度建设的时序安排。

最后需要说明四类失灵与市场结构判断的关系。8.4 节的结论是词元生产环节不存在自然垄断、市场集中度持续下降；本节的结论则是市场存在多重失灵、实际竞争强度远低于集中度指标的暗示。两者并不矛盾，而是同一枚硬币的两面：正因为进入壁垒不高、参与者众多，市场才呈现分散的结构；也正因为质量不可观测、转换成本高昂、计量口径不一，分散的结构才没有转化为充分的竞争。这提示词元市场治理的重心不在反垄断意义上的结构管制，而在市场基础设施的建设——计量、认证、结算与调度这四类基础设施，才是决定词元市场能否从「有价格」走向「有效率」的关键变量。

8.6 本章小结

本章把第 7 章的价格分析置回市场之中，系统刻画了词元市场的形态、需求、供给、均衡与失灵。在市场形态上，本章把围绕词元的交易识别为算力市场、词元市场与应用市场三层链条，指出词元市场是唯一同时受成本约束与价值约束双重挤压的中间环节，其三层价格结构与三层市场结构互为表里；进而以四类主体、三组交叉网络外部性与平台三项职能刻画了多边平台形态，并指出词元平台与经典双边平台的关键差异在于匹配发生在每一次调用内部，路由算法的目标函数直接决定资源配置效率，这使平台承担了远超一般中介的配置职能，也使平台规则的设定权成为比价格更根本的市场权力。

在需求侧，本章从派生需求出发导出了词元需求函数，证明在无约束最优化下弹性必然大于 1，并以预算约束与吸收能力约束解释了部分行业弹性小于 1 的观测。估计结果显示全样本需求价格弹性为 -1.34（标准误 0.19），文化传媒（-1.71）与制造（-1.62）富有弹性，金融（-0.94）与政务（-0.68）缺乏弹性；相应地，降价在前两个行业扩大总支出、在后两个行业缩减总支出，同一项降价政策在不同行业具有相反的收入含义。更重要的是需求扩张的分解：两年间约 1400 倍的调用量增长中，纯价格效应只解释了 6.4 倍、占对数总增幅的 25.6%，其余 74.4% 来自需求曲线的整体外移。把词元用量的爆发式增长简单归因于降价，在数量级上无法成立；场景开发、企业适配能力建设与模型效值提升才是主导力量，而这三者都不是价格补贴可以直接作用的对象。

在供给侧，本章以词元工厂的产能决定式刻画了词元供给的独特性质：产能不是标量而是产品组合的函数，同一片算力在不同档位之间的标准词元产出相差 13.5 倍，供给曲线因而是可重构的。成本测算揭示了两点发现：其一，物理词元口径下六档位的边际成本极差达 18.6 倍，折算为标准词元口径后降至 1.65 倍——档位间的成本差距约九成是产品差异而非效率差异，以物理词元为分母的成本比较会把补贴导向低档位、把监审压力施加于高档位；其二，单位算力收入随档位上升而递减、加成率随档位上升而递增，二者方向相反，构成词元工厂产品组合决策的核心权衡，也为第 9 章的任务—模型最优匹配提供了微观基础。

在均衡与竞争格局上，本章给出了三项结论。第一，短期均衡由产能约束的影子价格主导，峰谷分时定价是高峰负荷定价的直接体现，价格在成本底价之上叠加一块随产能松紧波动的稀缺租金。第二，自然垄断假说不成立：全国日均标准词元流量高出最小有效规模约 6.2 个数量级，成本函数在相关产量区间不具次可加性，其技术根源是推理服务的高度可分性；沉没成本在推理供给环节接近于零、在模型研发环节接近于一，这一非对称结构解释了「服务价格竞争激烈而研

发主体高度集中」的并存。第三，集中度与加成率显著背离：赫芬达尔—赫希曼指数由 0.34 降至 0.21，而实际加成率加权后仍达 76.8%，是古诺基准预测值的 4.9 倍；反解出的残余需求弹性与市场需求弹性同量级，差异化指标随档位上升而增大，说明各档位近似于在自身细分市场内独占定价。以份额为基准的结构性监管在这样的市场上几乎无从着力。

在市场失灵上，本章识别出效值信息不对称、算力孤岛与市场分割、平台锁定与计量口径不统一四类失灵，分别对应交易、交付、续约与记账四个环节，并据此给出「统一计量—信息披露与认证—接口与移植性标准—调度与结算基础设施」的矫正工具优先序。本章特别辨明了四套既有评价工作各自的主体、维度与用途，指出它们的共同形态是多维评价，产出的是并列的维度得分或达标基线，无法把异质词元合成为可加总、可计价、可入账的单一当量；本书从多维评价推进到当量折算的理论增量，正是在这一缺口上确立的。综合全章，词元市场的治理重心不在反垄断意义上的结构管制，而在计量、认证、结算与调度四类市场基础设施的建设。本章的需求弹性与成本曲线将作为参数进入第 9 章的配置优化与第 12 章的增长核算，四类失灵的机制识别则构成第 10 章机制设计与第 14 章政策建议的直接依据。

第9章 算力—词元转化效率与配置优化

第7章与第8章分别从价格与市场两个侧面完成了词元经济的交易分析，并在第8章末尾把治理重心归结为计量、认证、结算与调度四类市场基础设施。其中「调度」一项尚未展开：它既不是价格问题，也不是竞争结构问题，而是资源在算力、模型与场景三者之间的配置问题。这一问题在当前的产业实践中以一种近乎悖论的形式呈现出来。一方面，我国智能算力规模保持高速扩张：按工业和信息化部口径，截至2026年6月底智能算力规模达2185 EFLOPS（FP16，已建成规模），同比增长177%，全国算力设施整体上架率71.4%；截至2025年底已建成万卡智算集群42个、智能算力规模超过1590 EFLOPS。另一方面，被建成的算力并未被充分使用：国际数据公司与中国信息通信研究院联合开展的企业调研显示，近半数（约48%）企业的智算资源利用率处于51%—70%的中等区间，6.7%的企业仅为31%—50%，利用率达到70%以上者不足35%，制造与政务行业低于平均水平；调研同时把主因归结为多数自建智算项目「重硬件、轻软件」，缺乏统一调度平台与资源池化管理。「利用率只有五至七成而算力仍在加速扩建」，这就是本章要解释的配置悖论。

第4章已经辨明，产业讨论中并存的三个「利用率」——企业调研自报的智算资源利用率、统计口径的全国算力设施整体上架率、第三方估算的加速卡卡时利用率——统计对象与测量方法完全不同，不可互证；本章因此不直接采用任何一个公开利用率数字作为参数，而是以校准复算方式重建一套内部一致的口径。但更根本的问题不在于口径，而在于概念：无论用哪一套口径测得的利用率，衡量的都是「资源被占用的比例」，而不是「资源被有效使用的比例」。一张被百分之百占用的加速卡，如果在为一个本可由更低档位承接的任务提供服务、或者在生成大量语义冗余的词元，从价值创造的角度看仍然是浪费。占用不等于生产，生产不等于有用，有用不等于等值——三重错位叠加，使得「提高利用率」这一看似自明的政策目标在词元经济中失去了明确的所指。

把配置悖论从现象上升为可分解、可优化、可测算的经济学问题，需要三步工作。第一步是构造一个把算力投入一直追踪到「有效标准词元」的转化函数，使算力与词元在同一条链条上可度量；第二步是把名义利用率与有效效值利用率之间的落差分解为若干互斥且穷尽的损失项，识别各项的形成机制与责任层级；第三步是把降低损失的问题写成一个最优化问题，求解统一调度可获得的效率改进及其上界。这三步分别对应本章的9.1节、9.2节与9.3节。9.4节转向推理服务的排队与并发，刻画时延与成本之间的技术权衡，为批次损失给出微观基

基础；9.5 节报告效率改进的情景测算并讨论其经济含义；9.6 节为本章小结。本章的核心论点是：算力利用率不足在本质上不是一个工程问题，而是一个在缺乏共同计量尺度条件下必然出现的配置失灵；标准词元折算体系一旦建立，「按效值最优匹配」就从一个无法表述的目标变成一个可以求解的规划。

9.1 转化函数：从算力到有效标准词元

9.1.1 既有解释的边界：为什么「提高利用率」不是一个良定义的目标

关于算力利用率不足，既有研究已经积累了若干解释。对大规模机器学习服务集群的工作负载分析显示，资源利用的不均衡与任务异质性、负载的时变性密切相关，静态划分的资源池在面对高度偏斜的请求分布时必然产生大量空闲（Weng 等，2022）；对我国智算中心的实证研究表明，算力部署对企业全要素生产率的提升效应并非自动实现，而是依赖数据跨域流动等配套条件（许诺等，2025）；从需求侧考察算力资源配置的研究进一步指出，算力共享机制的缺失与算力市场的不成熟是使用效率偏低的制度根源（王勇等，2025）。平台在资源配置中的作用也已被反复论证：价格机制与数据机制的协同可以显著改善配置效率（刘诚和夏杰长，2023），而算力经济与算力电力协同的产业研究则从供给侧描绘了资源统筹的技术与政策路径（「中国信息通信研究院，2025」；中国信息通信研究院，2025）。

这些解释各自成立，但都停留在「资源被占用的比例」这一层面。一旦追问「占用之后产出了什么」，解释链条就断裂了。原因在于，算力的产出是词元，而物理词元不可加：第 3 章已经证明，同样 100 枚词元在不同模型、不同任务下的经济含义相差一个数量级以上；第 5 章据此构造了以算力强度 P 、推理质量 R 、场景效用 S 三维合成的效值折算体系，把异质词元折算为可比、可加的标准词元。这意味着，在标准词元口径建立之前，「算力利用率」这个指标的分子是一个没有共同尺度的混合物，其高低不具有价值含义。把利用率从 60% 提高到 80%，如果新增的 20% 全部用于在高档位模型上执行本可由低档位承接的简单任务，则算力的价值产出不升反降。因此，「提高利用率」在标准词元口径之外并不是一个良定义的政策目标；良定义的目标只能是「提高单位算力的有效标准词元产出」。

这一判断把配置问题与计量问题捆绑在一起，也确定了本章的方法论起点：必须先构造一个以标准词元为终端产出的转化函数，才能定义效率、分解损失、刻画最优。计量与配置的这种先后关系并非词元经济所独有。物流标准化对企业全要素生产率的提升效应表明，统一的计量与接口规格本身就是一种生产性投

入，其收益通过降低匹配与衔接成本而实现（何凡等，2025）；标准化与兼容性的经典分析同样指出，共同标准的价值不在于技术本身，而在于它使分散决策者的行动可以相互衔接（Farrell 和 Saloner，1985；Simcoe，2012）。就配置效率的测度方法而言，把总量约束下的资源在异质主体之间重新配置所能获得的产出改进作为效率损失的度量，已是资源与环境经济学中的成熟做法（杨豪等，2023）；本章对算力—词元配置的处理，在方法论上与之同构，差别仅在于被配置的对象是算力、被度量的产出是标准词元。

9.1.2 转化函数的构造：两级折算

转化函数的构造分两级：先把算力折算为物理词元，再把物理词元折算为标准词元。第一级是纯技术关系。沿用第 7 章式(7-1)的成本核算口径，记模型档位 m 在平均上下文长度 $\hat{\ell}$ 下生成一枚词元所需的浮点运算量为 $f_m(\hat{\ell})$ ，该档位推理服务中的有效算力利用率为 u_m ，则单位算力投入的物理词元产出如式(9-1)所示。

$$\theta_m^{phy} = \frac{s \cdot u_m}{f_m(\hat{\ell})}, f_m(\hat{\ell}) = 2N_m + 2\xi_m \hat{\ell}, s = 3.6 \times 10^{18} \quad (9-1)$$

其中， θ_m^{phy} 为单位算力时（PFLOPS·h）的物理词元产出， N_m 为档位 m 的有效参数规模， ξ_m 为注意力机制对上下文长度的敏感系数， s 为单位算力时对应的浮点运算总量（以 FLOP 计）。

式(9-1)刻画的是「算力—物理词元」的技术转化率，它随模型规模的扩大而下降、随上下文长度的增加而下降、随有效算力利用率的提高而上升。近年推理系统的进展正是沿着这三个方向压缩分母、抬高分子：连续批处理把请求级的调度粒度细化到迭代级，显著减少了批内等待（Yu 等，2022）；分页显存管理以操作系统式的分页机制消除键值缓存的碎片（Kwon 等，2023）；分块预填充在同一批次内平衡计算受限的预填充与访存受限的解码（Agrawal 等，2024）；预填充—解码分离则把两类资源画像截然不同的阶段拆分到不同的执行域（Zhong 等，2024）。算子层面的访存优化与大规模推理的并行编排从硬件效率一侧提升 u_m （Dao 等，2022；Pope 等，2023），而模型侧的规模律与训练推理权衡研究则从另一端降低了达到同等能力所需的 N_m （Kaplan 等，2020；Hoffmann 等，2022）。

第二级折算把物理词元换算为标准词元，这一级是经济关系而非技术关系。按第 5 章式(5-7)的公理化结论，效值系数为三维效值的幂积形式；把它与式(9-

1)相乘，即得本章的核心变量——单位算力的有效标准词元产出，亦即转化效率 θ_m ，见式(9-2)。

$$\theta_m = \eta_m \theta_m^{phy} = S \cdot \frac{\eta_m u_m}{f_m(\ell)}, \eta_m = P_m^{w_p} R_m^{w_R} S_m^{w_S} \quad (9-2)$$

其中， η_m 为档位 m 的效值系数， w_p 、 w_R 、 w_S 为第5章标定的三维权重，满足 $w_p + w_R + w_S = 1$ ； θ_m 的量纲为标准词元枚数/(PFLOPS·h)。

式(9-2)是第5章折算体系在配置分析中的第一个实质性应用。它把一个此前无法回答的问题变成了一个可以计算的量：同一片算力投向不同档位，究竟能产出多少「等值」的词元？本书六档位的校准复算结果为：轻量蒸馏级 42.0、中型通用级 18.5、开源旗舰级 9.2、旗舰闭源级 5.4、推理增强级 3.1、多模态级 6.8（单位：万枚标准词元/(PFLOPS·h)）。极差达 13.5 倍——同样一个 PFLOPS·h 的算力，投向轻量蒸馏级所产出的标准词元数量是投向推理增强级的 13.5 倍。

9.1.3 转化效率的三条性质

转化效率随档位单调递减这一事实，极易被误读为「大模型低效」。要辨明其真实含义，需要考察 θ_m 对算力强度 P_m 的弹性。注意到式(9-1)的分母 f_m 恰是算力强度的定义式所归一的对象（第5章式(5-3)），即 $f_m \propto P_m$ ，对式(9-2)两端取对数并对 $\ln P_m$ 求导，得到性质一，见式(9-3)。

$$\frac{\partial \ln \theta_m}{\partial \ln P_m} = (w_p - 1) + \frac{\partial \ln u_m}{\partial \ln P_m} < 0, 0 < w_p < 1 \quad (9-3)$$

其中，第一项为效值对算力强度的弹性与单位弹性之差，第二项为有效算力利用率对算力强度的弹性；后者在推理场景中同样为负，因为参数规模更大的模型在解码阶段更受显存带宽约束，硬件效率随规模下降。

第5章标定的 $w_p = 0.4383$ ，故式(9-3)第一项为 -0.5617 ，本身已足以保证弹性为负。其经济含义是本章的第一条基本判断：效值对算力强度的弹性显著小于 **1**——把算力强度提高一倍，效值只提高约 35.5%，而算力消耗提高 100%。因此，把算力投向更大的模型，单位算力的标准词元产出必然下降；这不是低效率，而是词元生产的基本技术事实。反过来说， θ_m 的高低本身不构成价值判断：轻量蒸馏级的转化效率最高，但它无法承接需要长链推理的任务；推理增强级的转化效率最低，但它是某些任务的唯一可行选项。真正的浪费不在于

「使用了低 θ 的档位」，而在于「在不需要低 θ 档位的场合使用了它」。这一区分是 9.3 节匹配问题的逻辑前提。

性质二是转化效率与价格的对偶关系。把式(9-2)与第 7 章式(7-7)的标准词元价格定义 $\tilde{p}_m = p_m / \eta_m$ 并置可见，单位算力的标准词元产出与单位标准词元的算力成本互为倒数：转化效率每提高 1%，在其他条件不变时单位标准词元的算力成本下降约 1%。这把本章的配置分析与第 7 章的定价分析直接连通——调度水平不仅决定资源是否被浪费，还通过式(7-1)中作为分母的利用率直接抬高或压低价格地板。换言之，配置效率是价格地板的技术决定因素之一，调度改进具有天然的价格外溢效应。

性质三是转化效率的可分解性。式(9-2)把 θ_m 分解为三个相互独立的乘数：效值 η_m （模型能力与场景匹配决定）、有效算力利用率 u_m （调度与系统工程决定）、单位词元浮点运算量 f_m （模型结构与上下文长度决定）。三者分属不同的责任主体： η_m 由模型研发方与应用方共同决定， u_m 由算力运营方与调度平台决定， f_m 由模型研发方与推理系统决定。把本书校准的转化效率与三维效值相对照可以看到，档位间转化效率之比并不等于效值—算力强度之比：以中型通用级为基准，轻量蒸馏级的转化效率之比为 2.27，而效值—算力强度之比仅为 1.73；推理增强级的两个比值分别为 0.168 与 0.510。两组比值的系统性差异，正是有效算力利用率 u_m 随档位下降所贡献的：高档位不仅每枚词元更贵，而且把算力转成词元的过程本身也更「漏」。

9.1.4 总量转化函数与配置向量

把六个档位加总，即得算力—词元的总量转化函数。记算力存量为 $\dot{C}$ 、名义算力利用率为 u^{nom} 、投入档位 m 的算力份额为 s_m ，则一定时期内的标准词元流量如式(9-4)所示。

$$\tilde{T} = \Delta t \sum_{m \in M} \theta_m C_m = \Theta(s) u^{nom} \dot{C} \Delta t, \Theta(s) = \sum_{m \in M} s_m \theta_m, \sum_{m \in M} s_m = 1, s_m \geq 0 \quad (9-4)$$

其中， M 为模型档位集合， $C_m = s_m u^{nom} \dot{C}$ 为投入档位 m 的有效算力， $\Theta(s)$ 为配置加权的平均转化效率， $s = (s_1, \dots, s_{|M|})'$ 为算力配置向量。

式(9-4)与第 4 章式(4-3)的量级核算恒等式在形式上一致，但内涵已经推进了一层：第 4 章把转化效率 θ 处理为一个外生的标量，本章则把它展开为配置向量的函数。这一展开立刻带来一个看似荒谬的推论： $\Theta(s)$ 是 s 的线性函数，其在单纯形上的最大值必在顶点取得，即全部算力应投向转化效率最高的档位——

轻量蒸馏级。若这一推论成立，则任何对高档位模型的算力投入都是纯粹的浪费。

推论之所以荒谬，是因为式(9-4)遗漏了需求侧的约束：任务对模型能力有门槛要求，低档位模型无法完成超出其能力的任务。把这一约束显式引入，角点解随即被打破，配置问题从「选最高的 θ 」变成「在满足任务可行性的前提下选最高的 θ 」——这正是 9.3 节任务—模型最优匹配问题的实质。因此，式(9-4)的意义不在于给出最优配置，而在于揭示：词元经济的配置问题在数学结构上是一个带可行性约束的线性规划，其全部经济内容都藏在约束里，而不在目标函数里。这一结构性认识决定了后文的处理方式：9.2 节先把现实配置与理想配置之间的落差分解清楚，9.3 节再把约束写出来求解。本章的完整分析框架如图 9.1 所示。




图 9.1 算力—词元转化与配置分析框架

图 9.1 的主链条自左至右呈现两级折算：算力投入经转化函数产出物理词元，物理词元经效值折算得到有效标准词元；链条终点的「可比、可加、可入账」正是标准词元区别于物理词元的三项经济资格。链条下方的四个方框标出四项损失各自的作用位置：空转损失作用于有效算力供给，批次损失作用于转化函数，匹配损失作用于任务—模型的对应关系，效值损失作用于效值折算环节。四项损失的作用点各不相同，这一点在政策上极为重要——它意味着四项损失分属不同的责任主体、需要不同的矫正工具，把它们笼统归入「利用率低」并以同一种手段（通常是继续扩建算力）应对，在逻辑上是无效的。图的上部是统一调度层，它以虚线箭头同时作用于转化函数与效值折算两个环节：调度决定批次与匹

配损失，匹配又反过来提升产出词元的平均效值。底部汇总条给出本章的核心测算结果，其推导见 9.2 节与 9.3 节。

9.2 利用率悖论的四项分解

9.2.1 有效效值利用率：序贯反事实的定义

要把「名义上被占用的算力」与「实际产出价值的算力」区分开来，需要一个介于二者之间的测度。本书定义有效效值利用率为实际标准词元产出 $\tilde{T}$ 与理想标准词元产出 $\tilde{T}^*$ 之比，其中理想产出指装机算力全部投入生产并同时满足满负荷运行、最优批次组织、最优任务—模型匹配、产出词元达到同档位效值上界四个条件时的产出。这一定义把可用性损失与四类转化损失一并纳入分母，因而与任何一种工程口径的利用率都不相同：它衡量的不是资源占用率，而是价值转化的完成度。

四类损失的界定采用序贯反事实方法。依技术因果的先后次序设定四个中间反事实产出： $\tilde{T}^{(0)} = u^{nom} \tilde{T}^*$ 为名义可用算力下的理想产出； $\tilde{T}^{(1)}$ 为在实际负载波动与冗余预留下的产出（扣除空转）； $\tilde{T}^{(2)}$ 为在实际批次与并发配置下的产出（再扣除批次）； $\tilde{T}^{(3)}$ 为在实际任务—模型匹配下的产出（再扣除匹配）； $\tilde{T}^{(4)}$ 即实际产出（再扣除效值）。各项相对损失率的定义见式(9-5)。

$$\tilde{T}^{(0)} \geq \tilde{T}^{(1)} \geq \tilde{T}^{(2)} \geq \tilde{T}^{(3)} \geq \tilde{T}^{(4)} = \tilde{T}, \delta_k = 1 - \frac{\tilde{T}^{(k)}}{\tilde{T}^{(k-1)}} \in [0, 1], k \in \{I, B, M, V\} \quad (9-5)$$

其中， δ_I 、 δ_B 、 δ_M 、 δ_V 依次为空转、批次、匹配与效值四项的相对损失率；相对损失率以上一级反事实产出为分母，因而各项之间不重叠、可连乘。

由式(9-5)立即得到有效效值利用率的乘积分解式(9-6)。这里必须强调一点：四项损失是相对损失率而非绝对百分点，其合成方式是逐级相乘而非简单相加。混淆这两种合成方式，是产业报告中关于「算力浪费」估算相互矛盾的主要来源。

$$u^{eff} \equiv \frac{\tilde{T}}{\tilde{T}^*} = u^{nom} \prod_{k \in \{I, B, M, V\}} (1 - \delta_k), \tilde{T}^{(0)} = u^{nom} \tilde{T}^* \quad (9-6)$$

其中， u^{nom} 为名义算力利用率， u^{eff} 为有效效值利用率；名义算力利用率本身即装机算力中被实际占用的比例，四项相对损失率则刻画被占用算力在转化为价值过程中的逐级折损。

本书的校准复算结果为：名义算力利用率 62%，四项相对损失率依次为空转 18%、批次 9%、匹配 12%、效值 7%。代入式(9-6)，得 $0.62 \times (1 - 0.18)$

$(1-0.09)(1-0.12)(1-0.07)\approx 0.38$ ，即有效效值利用率仅 38%。四项合计使被占用算力的价值转化能力折损 38.9%——换言之，装机算力中真正转化为最优可达价值的部分不足四成；而在已经被占用的那部分算力里，仍有 38.9%在转化过程中流失。这一分解结果如图 9.2 所示。




图 9.2 算力利用率的四项损失分解

注：四项均为以上一级反事实产出为分母的相对损失率，按式(9-5)的序贯反事实口径界定，合成方式为逐级相乘而非相加；名义算力利用率为本书重建的内部一致口径，不等同于企业调研自报的智算资源利用率、全国算力设施整体上架率或加速卡卡时利用率，三者不可互证。数据来源：作者校准复算。

图 9.2 的瀑布结构显示，四项损失中匹配损失 12%与空转损失 18%居前两位，二者合计贡献了绝大部分折损。这一排序有明确的政策含义。空转损失的成因是负载的时变性与资源的不可共享，其矫正需要跨主体、跨区域的算力池化，属基础设施层面的长周期工作；匹配损失的成因则是任务与模型的错配，其矫正只需要一个能够识别任务需求与模型效值的调度规则，属软件与规则层面的短周期工作。换言之，四项损失中改进成本最低、见效最快的一项恰恰不是产业界最关注的那一项：产业讨论几乎全部聚焦于「卡是否闲着」，而本书的分解显示，「卡忙着但忙错了事」造成的损失并不更小。

9.2.2 四项损失的形成机制

空转损失源于三重不可共享性。其一是时间维度的不可共享：推理负载具有显著的日内与周内峰谷，为满足高峰时段的服务水平承诺，运营方必须按峰值配置容量，谷时的冗余即成为空转；峰谷比越高，空转损失越大。其二是任务维度的不可共享：训练负载与推理负载对显存容量、互联拓扑与故障容忍度的要求截然不同，二者之间的切换并非零成本，「训练闲时跑推理」在工程上远不像在账

面上那样自然。其三是主体维度的不可共享，即第 8 章识别的算力孤岛：不同所有者、不同区域、不同技术栈的算力之间缺乏互联互通与结算机制，一处闲置无法填补另一处短缺。三重不可共享性叠加，使得空转损失在很大程度上是制度性的而非技术性的——头部云厂商、互联网企业与人工智能自研公司的核心集群利用率可达八成以上，正说明在单一主体内部实现资源池化时空转是可以被大幅压缩的。

批次损失源于推理服务的并发组织方式。大模型推理由预填充与解码两个阶段构成：预填充阶段并行处理整段提示，属计算受限；解码阶段逐词元自回归生成，属访存受限。两个阶段的资源画像截然不同，若采用静态批处理，则批内最长请求决定整批的完成时间，短请求被迫等待，造成队头阻塞与显存碎片；批大小过小则无法摊薄权重读取开销，批大小过大则时延不可接受。近年推理系统沿四条路线压缩这一损失：迭代级的连续批处理（Yu 等，2022）、分页式的显存管理（Kwon 等，2023）、分块预填充（Agrawal 等，2024）与预填充—解码分离（Zhong 等，2024）。批次损失的关键性质是它受服务水平约束的硬性限制：批大小的可行上限由时延承诺决定，因而它不是一个可以无限压缩的量。9.4 节将给出这一权衡的显式刻画。

匹配损失是本章的核心概念，也是四项损失中唯一必须在标准词元口径下才能被识别的一项。记任务集为 J ，任务 j 的标准词元需求量为 D_j ，其可行档位集合为 $M_j \subseteq M$ （即达成度不低于任务门槛的档位），实际匹配由 0-1 矩阵 $X = [x_{jm}]$ 给出， $r_{jm} \geq 0$ 为档位 m 承接任务 j 时的返工率（能力不足导致的重试与人工修正所引致的额外词元消耗比例）。匹配损失的显式定义见式(9-7)。

$$\delta_M = 1 - \frac{\sum_{j \in J} \frac{D_j}{\theta_{m^*(j)}}}{\sum_{j \in J} \sum_{m \in M} x_{jm} \frac{(1+r_{jm})D_j}{\theta_m}}, m^*(j) = \arg \max_{m \in M_j} \theta_m \quad (9-7)$$

其中，分子为在最优匹配下交付全部任务所需的算力，分母为在实际匹配下交付同样任务所实际消耗的算力； $m^*(j)$ 为任务 j 的可行档位中转化效率最高者，即「够用的最低档位」。

式(9-7)把匹配损失表述为算力消耗的相对冗余，其结构揭示出两类方向相反的错配。上溢是指实际档位高于 $m^*(j)$ ，即用推理增强级模型处理本可由中型通用级完成的知识问答。上溢不会导致任务失败， $r_{jm}=0$ ，其损失是纯粹的算力冗余，大小等于 $\theta_{m^*(j)}/\theta_m - 1$ ，随档位差距线性扩大。下溢是指实际档位不在可行集

内，即用能力不足的模型承接超出其能力的任务。下溢的损失有两个来源：一是返工率 r_{jm} 带来的额外算力消耗，二是即便反复重试仍未达成任务目标所造成的效值折损（后者被计入 δ_v ）。关键在于两类错配的损失函数形状不同：上溢的损失是线性的，下溢的损失随能力缺口扩大而凸性上升——能力缺口稍大，返工率便急剧攀升乃至任务完全不可达成。这一非对称性意味着，在任务难度不可完全预知的现实条件下，理性的调度策略必然带有安全边际，即宁可轻度上溢也不下溢。这既解释了实践中高档位模型被过度调用的部分合理性，也说明匹配损失不可能被压缩至零——它的下界由任务难度的可预测性决定，而任务难度的可预测性又取决于任务侧的标准化程度。

效值损失衡量的是：在给定档位与给定匹配下，实际产出词元的效值低于该档位在该任务上可达效值上界的部分。其来源有四：一是提示与上下文的冗余，即大量不承载有效信息的词元被计入产出；二是重复生成与格式冗余，典型如未做结构化约束的长篇输出；三是缓存未命中导致的前缀重复预填充，同一段上下文被反复计算；四是场景效用维度的实现不足，即模型能力虽已达标但应用侧未把输出转化为业务价值。前三项属技术性损失，第四项属组织性损失。效值损失与匹配损失的边界由式(9-5)的反事实次序严格界定：匹配损失衡量「用错了档位」造成的算力冗余，效值损失衡量「档位用对了但词元没生成好」造成的价值折损，二者不重叠。把四项损失的界定、机制、可观测代理与矫正工具汇总，见表 9.1。

表 9.1 算力—词元转化的四项损失：机制、代理指标与矫正工具

损失项	相对损失率／折 余后利用率	形成机制	可观测代理指标	矫正工具与责任 层级
① 空转损失	18.0%／ 50.8%	负载时变性与峰值容量预留；训练与推理负载不可即时互换；跨主体、跨区域算力不可互调	加速卡卡时占用率、日内峰谷比、预留冗余率、跨域调度成功率	算力池化与一体化调度平台；跨域计量与结算；产能交易机制（算力运营方与调度平台）
② 批次损失	9.0%／46.3%	批大小与并发配置欠优；预填充与解码资源画像不同；长短请求混批导致队头阻塞与显存碎片	批平均填充率、首词元时延分位数、输出吞吐、缓存命中率	连续批处理、分页显存、分块预填充、预填充—解码分离；按请求画像分池（推理服务方）
③ 匹配损失	12.0%／ 40.7%	任务难度与模型效值信息不对称；上溢（高档位承接低门槛任务）与下溢（低档位承接高门槛任务并返工）并	任务—档位联合分布、返工率与重试次数、单位任务标准词元消耗的档位间离差	标准词元计量与效值公示；任务分级与路由规则；按效值最优匹配的统一调度（调度平台与应用方）

④ 效值损失	7.0%/37.9%	存 提示与上下文冗 余；重复生成与 格式冗余；缓存 未命中导致前缀 重复预填充；场 景效用实现不足	有效信息词元占 比、缓存命中 率、单位业务成 果的标准词元消 耗	上下文工程与结 构化输出约束； 前缀缓存与知识 复用；场景侧流 程再造（应用方 与模型服务方）
合计	38.9%/37.9%	四项逐级相乘， 非简单相加	有效效值利用率 （本书口径）	统一计量为前 提，统一调度为 枢纽

注：相对损失率按式(9-5)的序贯反事实口径界定，以上一级反事实产出为分母；折余后利用率为按式(9-6)自名义算力利用率逐级折算所得，末行合计为四项连乘的结果，与四项相加不等。表中可观测代理指标为本书建议的监测口径，目前尚无对应的公开统计。数据来源：作者校准复算。

表 9.1 揭示出四项损失在治理属性上的差异。空转损失的矫正工具集中在基础设施与制度层面，投入大、周期长，但一旦建成即具有持久的外部性；批次损失的矫正工具集中在推理系统层面，属技术密集型改进，其空间受服务水平承诺的硬约束；匹配损失的矫正工具集中在计量与规则层面，投入最小而弹性最大，但必须以统一的效值计量为前提——没有可比的效值系数，「按效值最优匹配」这句话在操作上没有含义；效值损失的矫正工具则大部分落在应用方，属组织能力建设。四类工具分属四个不同的责任层级，这解释了为什么单一主体的努力难以显著改善总体效率：算力运营方只能处理第一项，推理服务方只能处理第二项，而占比最大的第三项需要一个同时掌握任务信息与模型信息的第三方——这正是第 10 章城市词元运营中心的职能定位所在。

9.2.3 分解次序的敏感性与稳健性

序贯反事实分解的一个已知局限是次序依赖：各项相对损失率的数值取决于扣除的先后顺序，改变次序会改变各项的具体取值，但不改变四项连乘的总折损。本书选择「空转→批次→匹配→效值」的次序，依据是技术因果的先后：算力必须先被占用，占用的算力才被组织成批次，成批的算力才被匹配到具体任务，匹配后的执行才决定产出词元的效值。这一次序与生产过程的时间序列一致，因而具有工程上的可解释性。

就稳健性而言，有三点需要说明。第一，总折损与次序无关：无论采用何种次序，四项连乘的结果恒为 38.9%，有效效值利用率恒为 37.9%，因而本章的核心结论——有效效值利用率不足四成——不依赖于次序选择。第二，若需要次序中性的分项归因，可采用合作博弈中的沙普利值对全部次序取平均，其代价是失去工程可解释性；本书在正文中保留序贯口径，因为四项损失的治理工具正是按这一次序分属不同责任层级的。第三，各项损失率本身是校准复算值而非实测值——目前公开统计中不存在任何一项可以直接支持这一分解的数据，表 9.1 第

四列列出的代理指标正是本书建议建立的监测口径。这一测度空白本身即是重要发现：在算力投资以千亿元计的产业中，我们竟无法从公开数据中回答「被占用的算力究竟产出了多少价值」这一基本问题。

9.2.4 与既有评价体系的关系：从多维评价到当量折算

需要特别辨明本书的四项损失分解与既有词元评价工作的关系。截至 2026 年中，围绕词元服务已经形成四套各自独立的评价或度量体系，它们的发布主体、维度构成与用途各不相同，必须逐一分辨、不得合并或交叉引用。其一，中国信息通信研究院的《人工智能 Token 服务质量能力要求》及据以开展的「可信 AI-Token 服务质量评估」，包含模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度，用于服务质量认证。其二，中国信息通信研究院于 2026 年 6 月 16 日发布的「高质量 Token 服务标准体系」，包含服务质量、运营能力、生产能力、安全能力四个维度，用于标准框架搭建；该院云大所负责人明确提出「不能只看单价，行业亟须一套衡量高质量 Token 的标尺」。其三，中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》构建的价值度量体系，包含生产成本、生产效率、准确性、生态价值、安全五个维度。其四，清华大学翟季冬团队联合清程极智于 2026 年 5 月发布的「开源模型 Token 服务性能榜」，以首词元时延（TTFT P90）、输出吞吐（TPS）与缓存命中率三项实测指标对三十余家服务商进行横向评测。

四套工作的共同形态是多维评价：其产出是并列的维度得分、达标基线或性能排名。多维评价对于质量认证与选型参考是充分的，但对于配置优化是不充分的，原因在于调度问题的目标函数必须是标量。式(9-4)的 $\Theta(s)$ 、式(9-7)的 δ_M 、9.3 节的匹配规划，每一个都要求把「一枚词元值多少」压缩为一个可比较、可加总、可求极值的实数；六个维度的得分向量无法进入 $\arg \max$ ，四个维度的达标基线也无法告诉调度器「把这个任务交给哪一档」。本书 (P, R, S) 三维效值折算体系是作者自主构建的理论框架，与上述四套工作在维度名称与来源上均无对应关系；其相对于既有工作的理论增量正在于此：从多维评价推进到当量折算——通过第 5 章公理化的合成函数，把异质词元折算为可加总、可计价、可入账的单一当量，从而使配置优化、价格指数与增长核算这三类需要标量口径的工作第一次成为可能。多维评价与当量折算并非替代关系：前者是后者的输入（ R 维度的测度需要能力评测的支撑（Hendrycks 等，2021；Liang 等，2022；Zheng 等，2023）），后者是前者的经济学出口。

9.3 任务—模型最优匹配与统一调度的效率上界

9.3.1 匹配问题的规划设定

9.2 节的分解表明，匹配损失是四项中占比最大且矫正成本最低的一项。本节把降低匹配损失的问题写成一个显式的最优化问题。设任务集 J 中每个任务类 j 由大量同质请求构成，其标准词元需求为 D_j ；模型档位集为 M ，档位 m 的可用算力为 C_m ；匹配矩阵 $X = [x_{jm}]$ 。调度者的目标是在满足全部任务需求与算力容量约束的前提下最小化算力总消耗，等价地，在给定算力总量下最大化有效标准词元产出。规划设定见式(9-8)。

$$\min_x \sum_{j \in J} \sum_{m \in M} \frac{(1+r_{jm})D_j}{\theta_m} x_{jm} \text{ s.t. } \sum_{m \in M} x_{jm} = 1 \quad \forall j; \sum_{j \in J} \frac{(1+r_{jm})D_j}{\theta_m} x_{jm} \leq C_m \quad \forall m; x_{jm} \in [0, 1] \quad (9-8)$$

其中，目标函数为交付全部任务所需的算力总消耗；第一组约束要求每个任务类被完整指派，第二组为各档位的算力容量约束；对 $m \notin M_j$ 的组合， r_{jm} 取值足够大以自动排除。

式(9-8)在形式上是一个广义指派问题，其一般形式属 NP 困难。但在词元调度的具体情境下，问题的结构远比一般情形友好，原因在于任务的可分性：一个任务类并不是一个不可分割的作业，而是每日数以百万计的同质请求流，把其中六成路由到中型通用级、四成路由到开源旗舰级，在工程上与经济上都是完全有意义的。放松整数约束为 $x_{jm} \in [0, 1]$ ，式(9-8)即化为一个标准的运输问题，由此可得如下命题。

命题 9.1（整数间隙的消失）：在任务可分的条件下，式(9-8)的线性松弛存在最优基可行解，其中被拆分到两个及以上档位的任务类不超过 $|M|-1$ 个；因而当各任务类的需求规模趋于无穷时，整数最优解与松弛最优解的目标值之差相对于总目标值趋于零。证明思路如下：松弛后约束矩阵为运输问题的结点—弧关联矩阵，具有全幺模性；任一基可行解的非零分量个数不超过 $|J|+|M|-1$ ，而每个任务类至少占用一个非零分量，故被拆分的任务类不超过 $|M|-1$ 个。在本书的六档位设定下，无论任务类有多少，最多只有五个任务类需要拆分路由，其余全部整数指派。

命题 9.1 的经济意义不在于计算便利，而在于它把最优调度从「集中式求解」转化为「分权式实现」。既然松弛解即最优解，则由线性规划对偶定理，最优匹配可以完全由对偶变量刻画——也就是说，调度平台不必掌握全部任务的细

节并集中求解，只需公布一组「影子价格」，让各任务自行选择档位，即可实现最优配置。这正是价格机制在配置问题中的经典作用（刘诚和夏杰长，2023），也是第 10 章「统一计量—统一结算」机制设计的理论依据：统一调度在本质上不是一个技术平台，而是一套价格发现机制。

9.3.2 对偶解与「阶梯匹配」原则

记容量约束的对偶变量（影子价格）为 $\psi_m \geq 0$ ，任务指派约束的对偶变量为 ζ_j 。由互补松弛条件，最优匹配下每个任务类应被指派到使「含拥挤成本的单位有效标准词元算力代价」最小的档位，见式(9-9)。

$$m^*(j) = \arg \min_{m \in M} \frac{(1+\psi_m)(1+r_{jm})}{\theta_m}, \psi_m \geq 0, \psi_m \left(C_m - \sum_{j \in J} \frac{(1+r_{jm})D_j}{\theta_m} x_{jm} \right) = 0 \quad (9-9)$$

其中， ψ_m 为档位 m 算力容量的影子价格，在容量未被用尽时为零、被用尽时为正； $(1+\psi_m)(1+r_{jm})/\theta_m$ 为把一单位标准词元需求交由档位 m 完成的完全社会成本。

式(9-9)给出的匹配规则可以概括为阶梯匹配原则。当算力不紧张、各档位影子价格均为零时，规则退化为 $m^*(j) = \arg \max_{m \in M_j} \theta_m$ ，即「任务应被匹配到能够达标的最低档位」——够用即可。当某些档位算力紧张、影子价格转正时，规则自动把任务向低档位推移：高档位的拥挤成本上升，使得原本值得上溢的任务不再得上溢。这一规则的两个性质值得强调。其一，它是需求侧信息与供给侧信息的联合函数： r_{jm} 属任务侧私人信息， θ_m 属模型侧私人信息， ψ_m 属算力侧私人信息，三者分散在不同主体手中——这解释了为什么匹配损失无法由任何单一主体自行消除，也解释了为什么效值信息不对称（第 8 章）会直接转化为配置损失。其二，它与第 7 章的三层价格结构在结构上对偶：价格结构回答「一枚词元应当卖多少钱」，匹配规则回答「一个任务应当用哪一档来做」，两者的桥梁都是效值系数 η_m 。若市场价格已经充分反映效值（即 $\tilde{p}_m$ 在档位间趋同，第 7 章测算显示折算后价格离差由 12.6 倍降至 2.4 倍），则分散决策的应用方按价格选择档位，其结果将自动接近式(9-9)的最优匹配——这是标准词元折算体系在配置维度上最重要的政策含义。

9.3.3 效率改进的幅度与上界

把式(9-8)在本书校准的任务结构与算力结构下求解，可得统一调度后的有效效值利用率。进一步地，若允许四项损失同时压缩至各自的技术与制度下界，则得到效率改进的理论上限，见式(9-10)。

$$u^{ub} = \max_{X,b,s} u^{eff}(X,b,s) = u^{nom} \prod_{k \in \{I,B,M,V\}} (1 - \delta_k) \leq u^{nom} \quad (9-10)$$

其中， b 为批次与并发配置向量， δ_k 为第 k 项损失在技术与制度硬约束下的下界；不等号表明，无论调度如何优化，有效效值利用率都不可能超过名义算力利用率。

求解结果为：现状有效效值利用率 38%，统一调度后 54%，理论上界 61%，而名义算力利用率 62%构成不可逾越的天花板。这组数字给出三层判断。第一，统一调度可获得的改进为 16 个百分点，相对现状提升 42%——这是在不新增一瓦算力、不改变任何模型的条件，仅凭匹配规则与批次组织的改善即可获得效率增益。第二，理论上界与现状之差为 23 个百分点，其中 16 个百分点可由统一调度在现实约束下取得，剩余 7 个百分点则需要更深层的变革：跨主体算力互联以压缩空转的制度性成分、推理系统的进一步演进以压缩批次损失、任务侧的标准化以提高难度可预测性从而压缩匹配损失的安全边际。第三，也是最容易被忽略的一点，理论上界 61%与名义利用率 62%几乎重合，这意味着调度改进的空间是有界的：即便把四项损失压缩到极限，有效效值利用率也不可能突破名义算力利用率给定的天花板。因此，配置优化与算力扩建并非相互替代的两条路线，而是先后有序的两个阶段——在四项损失被压缩之前，扩建算力的边际回报被系统性地打了折扣；而当损失被压缩到接近上界之后，产出的进一步增长就只能依靠名义算力的增加。

效率改进的幅度还可以从「等效算力」的角度重新表述，这一表述对投资决策更为直观，见式(9-11)。

$$\Delta \tilde{T} = (u^{sch} - u^{eff}) \Theta \dot{C} \Delta t, \frac{\Delta \dot{C}^{eq}}{\dot{C}} = 1 - \frac{u^{eff}}{u^{sch}} \quad (9-11)$$

其中，第一式为在算力存量不变时统一调度带来的标准词元增产，第二式为在产出不变时统一调度可节约的算力比例，即等效节约算力率。

代入求解结果，统一调度的等效节约算力率为 29.6%，达到理论上界时为 37.7%。这意味着：在产出目标不变的前提下，统一调度相当于凭空增加约 29.6%的算力，或等价地，使原本需要新建的算力减少约 29.6%。按第 7 章式(7-1)，单位标准词元的算力成本与有效效值利用率成反比，因而同一改进也意味着单位标准词元的算力成本降至现状的 70.4%，即下降 29.6%——这一降幅与近年最激烈的价格竞争所带来的降价幅度处于同一量级，但它不是以牺牲供给方利润为代价的降价，而是实实在在的成本节约。分档位的改进结构如图 9.3 所示。




图 9.3 统一调度的效率改进

注：分档位数值为按式(9-8)、式(9-9)在本书校准的任务结构与算力结构下求解所得；六个档位为本书统一使用的模型能力分档，不对应任何具体商业模型产品；三条水平参考线自下而上依次为总体现状、统一调度后与理论上限。数据来源：作者校准复算。

图 9.3 显示出两个清晰的规律。其一，现状下各档位的有效值利用率随档位上升而单调下降，轻量蒸馏级最高、推理增强级最低。这一梯度并非偶然：高档位模型既承受更大的批次组织难度（长输出、大显存占用），又是上溢型错配的主要承接方，两类损失叠加于同一档位。其二，统一调度后各档位的利用率显著收敛，改进幅度随档位上升而扩大，高档位的绝对改进接近低档位的两倍，调度后六个档位落在一个相当狭窄的区间内。这一收敛正是式(9-9)对偶最优的直接表现：在最优匹配下，各档位单位算力的边际有效产出趋于相等，若不相等，则把任务从边际产出低的档位移向高的档位就能改进目标值，与最优矛盾。利用率的档位间收敛，因而是调度是否达到最优的一个可观测判据——这一判据不依赖于任何内部信息，监管者与运营者只需比较各档位的有效值利用率离差，即可判断调度水平的高低。这为第 14 章提出的「以有效值利用率替代名义利用率作为考核口径」提供了可操作的技术支撑。

9.3.4 统一调度的制度前提

统一调度的技术方案早已不是难题，难在制度前提。式(9-9)要求调度者同时掌握三类分散信息并具备跨主体的执行力，这在制度上至少需要三项条件。第一是统一计量：没有可比的效值系数 η_m ， θ_m 无法计算，最优匹配无从定义。此处应当准确表述计量标准化的进展：2026 年 3 月 25 日，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用 token 的中文名「词元」，并明确将在常态化审定中结合社会推广应用情况最终确认；同月，国家发展改革委

党组成员、国家数据局局长刘烈宏在中国发展高层论坛 2026 年年会上使用并推介这一译名，提出词元具有「可计量、可定价、可交易」的特征。就标准供给而言，目前落地的是团体标准与机构评估规范——如中国人工智能产业发展联盟归口的《人工智能词元（Token）运营管理能力要求》（AIIA/T 0308—2026，2026 年 8 月发布）——其效力层级低于国家标准与行业标准，尚不存在以词元计量或计费为标题的国家标准或行业标准。计量标准化的滞后，是匹配损失长期居高的制度根源。

第二是统一接入与结算。分散在不同主体手中的算力若无统一的接入口径与结算规则，影子价格便无从公布、跨域调度便无从执行。国家层面的部署已经沿这一方向展开：《全国一体化大数据中心协同创新体系算力枢纽实施方案》确立了枢纽节点的空间布局（「国家发展改革委等，2021」），《关于深入实施「东数西算」工程 加快构建全国一体化算力网的实施意见》提出建设「联网调度、普惠易用、绿色安全」的全国一体化算力网、统筹通用算力与智能算力协同（国家发展改革委等，2023），2026 年工业和信息化部进一步部署国家算力互联互通节点建设，提出建立「1+M+N」节点体系与「统一标识、统一标准、统一规则」的运行机制。地方层面，浙江省「十五五」规划纲要在「构建新型算力体系」段落中明确提出「建立全省一体化算力监测调度平台」（「浙江省人民代表大会，2026」）。需要提醒的是，省级平台、市级平台与全国一体化算力网是三个层级、三套接入范围的不同事物，各自上报的算力规模之间存在重复计算，不可加总。

第三是激励相容。统一调度会重新分配各方的收益：应用方因「够用即可」而降低支出，算力运营方因利用率提高而增加收入，但高档位模型服务方则可能因上溢型调用减少而损失收入。若不设计相应的补偿或分成机制，掌握高档位模型的主体便缺乏接入统一调度的激励，平台的覆盖面无法扩大，规模效应无从实现。这一激励结构正是第 10 章三方演化博弈的分析对象，其中的关键参数——企业深度采纳的红利 R_F ——在数值上高度敏感：基准情景下 $R_F = 1.50$ ，仅比临界值 1.55 低约 3%，却导致「平台热、企业冷」与「平台企业双热、补贴顺利退出」两种完全不同的长期均衡。配置效率的改进因而不是一个纯粹的工程目标，而是一个需要机制设计加以保障的制度成果。国务院《关于深入实施「人工智能+」行动的意见》把智能经济形态培育列为国家行动（国务院，2025），为这一制度建设提供了政策框架。

9.4 排队、批次与时延—成本权衡

9.4.1 推理服务的排队刻画

批次损失的微观基础是推理服务的排队过程。与传统计算服务不同，大模型推理的服务时间不是固定的：一个请求消耗多少时间取决于其输出词元数，而输出词元数在请求到达时并不已知。这使得推理服务在排队论上接近于服务时间随机且方差较大的排队系统。作为基准刻画，设请求到达服从强度为 λ 的泊松过程、服务率为 ν ，单服务台情形下的服务强度、平均排队等待与等待时间的尾分布见式(9-12)。

$$\rho = \frac{\lambda}{\nu} < 1, W_q = \frac{\rho}{\nu - \lambda} = \frac{\lambda}{\nu(\nu - \lambda)}, Pr[W_q > t] = \rho e^{-(\nu - \lambda)t} \quad (9-12)$$

其中， ρ 为服务强度（为避免与第 7 章场景租金分成率混淆，此处记为 ρ ）， W_q 为平均排队等待时间；尾分布表明等待时间近似服从以 $(\nu - \lambda)$ 为参数的指数衰减。

本书校准的推理集群参数为到达率 $\lambda = 420$ 请求/秒、服务率 $\nu = 480$ 请求/秒，服务强度 $\rho = 0.875$ ，系统处于高负荷运行区间。代入式(9-12)，理论平均排队等待为 14.6 毫秒，平均逗留时间为 16.7 毫秒。但校准复算的实际平均等待为 96 毫秒，为理论值的 6.6 倍。这一倍差不是模型误设，而是三项被基准排队模型抽象掉的现实因素所致：一是批次组装等待，请求到达后需等待同批其他请求以摊薄权重读取开销；二是预填充与解码的相互干扰，长提示的预填充会阻塞同一执行域内其他请求的解码；三是到达过程的突发性，实际请求流的方差显著大于泊松假设。三项之和构成批次损失的时间表现，也解释了为什么单纯提高硬件算力并不能等比例改善用户可感知的时延。

尾部特征提供了另一个诊断维度。校准的 95 分位时延为 310 毫秒，与平均等待之比为 3.23；而按式(9-12)的指数尾，95 分位与均值之比应为 $\ln 20 \approx 3.00$ 。实际比值高出理论基准约 7.8%，说明时延分布的尾部略厚于指数分布。尾部略厚的经济含义值得重视：服务水平承诺通常以分位数而非均值表述，尾部越厚，为满足同一分位数承诺所需预留的容量冗余越大，从而空转损失越高。这就在批次损失与空转损失之间建立了一条替代关系——压缩批次损失的努力（加大批大小）会推高时延尾部，进而迫使运营方预留更多冗余，把损失从第二项转移到第一项。四项损失并非彼此独立，这是式(9-5)采用序贯反事实而非独立归因的又一理由。

9.4.2 批大小的时延—成本权衡

批处理是推理服务成本控制的核心手段：批内请求共享一次权重读取，批大小越大，单位词元摊薄的固定开销越低。但批大小的增加同时抬高时延——批越大，组装等待越久、单批执行越长。记批大小为 b ，平均时延为 $\dot{d}(b)$ 、相对单位成本为 $\chi(b)$ ，服务水平承诺的时延上限为 $\dot{d}^{SLA}$ ，则最优批大小由式(9-13)确定。

$$\min_b \Psi(b) = \frac{\dot{d}(b) - \dot{d}_{\min}}{\dot{d}_{\max} - \dot{d}_{\min}} + \frac{\chi(b) - \chi_{\min}}{\chi_{\max} - \chi_{\min}} \text{ s.t. } \dot{d}(b) \leq \dot{d}^{SLA}, \dot{d}'(b) > 0, \chi'(b) < 0, \chi''(b) > 0 \quad (9-13)$$

13)

其中， $\Psi(b)$ 为等权归一化的时延—成本综合指标；约束中的三个导数条件分别表明时延随批大小递增、单位成本随批大小递减且递减速度边际衰减（摊薄效应存在饱和）。

式(9-13)的解具有明确的经济结构。由于 χ 对 b 的一阶导数绝对值随 b 递减而 $\dot{d}$ 的一阶导数随 b 递增，综合指标 Ψ 是单峰的，内点最优必然存在：在小批区间，加大批大小的成本收益远大于时延代价；在大批区间，成本已接近下界而时延仍在加速上升。这一权衡的具体形态如图 9.4 所示。




图 9.4 推理服务的时延—成本权衡

注：横轴为对数刻度的推理批大小；左轴为平均时延（毫秒），右轴为相对单位成本（批大小 256 时 = 1）；阴影区间为按式(9-13)等权归一化的时延—成本综合指标取得最小值的相邻批大小区间。曲线为作者按批处理时延与摊薄成本模型校准复算，未纳入长短请求混批导致的队头阻塞。数据来源：作者校准复算。

图 9.4 显示，相对单位成本随批大小迅速下降并在批大小 64 以后基本触底，而平均时延在批大小 32 以内几乎平坦、此后加速上升；综合指标的最小值落在批大小 32 至 64 的区间内。这一结果有两点值得讨论。第一，成本曲线的

饱和意味着盲目加大批大小是无收益的：从 64 增至 256，单位成本几乎不再下降，而平均时延上升了数倍。产业实践中常见的「以吞吐为唯一目标」的调优取向，在这一区间实际上是在纯粹地损害用户体验而不换取任何成本收益。第二，也是更重要的一点，服务水平约束在当前参数下并不绑定：中国信息通信研究院「词元服务能力攀登计划」首批参与企业达成的首词元时延基线为不高于 0.9 秒（即 900 毫秒）、吞吐不低于 55 词元/秒、调用成功率 99.9%——该基线是首批企业的达成值，既非行业平均，也非强制门槛；而综合指标最优区间对应的平均时延远低于这一水平。这意味着，当前的批次损失并非由服务水平承诺所迫，而主要来自负载的时变性与批内请求的异质性：把长输出请求与短输出请求混入同一批次，会使整批被最长请求拖住，这一队头阻塞效应无法通过调整批大小来消除，只能通过按请求画像分池与迭代级调度来化解。

9.4.3 性能指标的口径纪律

在把排队与批次分析对接到产业指标时，有一项口径纪律必须遵守：不同来源的时延指标所用的统计分位不同，不可直接比较。清华大学翟季冬团队联合清程极智发布的「开源模型 Token 服务性能榜」所用的首词元时延为 P90 分位，而上述攀登计划的基线未标注分位；两个同为零点九秒量级的数字并不处在同一口径上。同理，输出吞吐既可按单请求计也可按集群计，缓存命中率既可按请求计也可按词元计。这些差异在单一评测内部无关紧要，一旦被用于跨主体比较或政策考核就会产生系统性偏误。本书在 9.2 节表 9.1 中把「首词元时延分位数」而非「首词元时延」列为批次损失的代理指标，正是出于这一考虑：可考核的性能指标必须自带分位与分母的定义，否则它只是一个数字，而不是一个测度。

9.5 效率改进的情景测算与经济含义

把前四节的结果汇总，可以对配置效率改进的经济规模作一次情景测算。测算设定三个情景并附一个参考上限：现状情景为分散自建、按档位固定分配算力的当前状态；统一调度情景为式(9-8)在现实约束下的求解结果；理论上界情景为式(9-10)的解；名义利用率上限作为不可逾越的参考线一并列出。产出折算以国家数据局公布的官方锚点为基准：我国日均词元调用量在 2026 年 3 月突破 140 万亿枚，按本书校准复算的用量加权平均效值系数 $\eta = 1.425$ 折算，相当于日均约 200 万亿枚标准词元。测算结果见表 9.2。

表 9.2 配置效率改进的情景测算

情景（配置状态）	有效效值利用率（%）	较现状（个百分点）	等效节约算力（%）	标准词元产出指数（现	日均标准词元产出（万
----------	------------	-----------	-----------	------------	------------

				状 = 100)	亿枚)
S0 现状：分散自建、按档位固定分配	38.0	—	—	100.0	200
S1 统一调度：任务一模型最优匹配	54.0	+ 16.0	29.6	142.1	284
S2 理论上界：四项损失压至技术与制度下界	61.0	+ 23.0	37.7	160.5	320
(参考) 名义算力利用率上限	62.0	+ 24.0	38.7	163.2	326

注：有效效值利用率按式(9-6)界定，等效节约算力按式(9-11)第二式计算；日均标准词元产出以国家数据局公布的 2026 年 3 月日均词元调用量 140 万亿枚为基数。按本书校准复算的用量加权平均效值系数折算，该时点为官方发布的锚点，其余时点的调用量系校准复算插值、官方未单独发布；情景测算假定需求侧可完全吸纳增产，未纳入价格与需求的反馈，亦未考虑调度平台自身的建设与运行成本。数据来源：调用量取自国家数据局，其余为作者校准复算。

表 9.2 的量级颇具冲击力。统一调度使有效效值利用率由 38% 升至 54%，在算力存量不变的条件下日均标准词元产出由 200 万亿枚增至 284 万亿枚，净增约 84 万亿枚；等效地，若产出目标不变，则可节约 29.6% 的算力。把这一比例放回算力投资的语境：截至 2025 年底我国已建成万卡智算集群 42 个、智能算力规模超过 1590 EFLOPS，截至 2026 年 6 月底智能算力规模达 2185 EFLOPS（工业和信息化部口径，FP16，已建成规模）——近三成的等效节约，其量级相当于数百 EFLOPS 的在建产能。需要强调的是，这一测算不是主张停止算力建设，而是指出一个次序：在四项损失被压缩之前，新增算力的边际回报被系统性地打了折扣；同样一笔投资，用于建设调度能力与计量能力的回报率，在当前阶段高于用于扩建物理算力。

效率改进的经济含义可以从三条链路展开。第一条是价格链路。按第 7 章式 (7-1)，有效利用率是边际成本表达式的分母，配置效率的改进直接压低价格地板：单位标准词元的算力成本降至现状的 70.4%。第 7 章的价格指数分解显示，标准词元价格指数的下行速度显著慢于物理词元价格指数（同期分别降至 47 与 21，基期 2024 年第一季度 = 100），二者的背离主要由效值提升解释；本章的分析补充了另一条渠道——配置效率的改进将同时压低两个指数，且不以牺牲供给方利润为代价，因而是价格下行中「可持续」的那一部分。

第二条是能源与碳链路。词元产出与电力消耗几乎成正比，配置效率的改进因而直接转化为节电与减排。国家能源局《中国「人工智能+」能源发展报告 2026》给出全国算力中心总用电量 1700 亿千瓦时；国际能源署的评估则显

示，2024 年全球数据中心用电约 415 太瓦时、约占全球用电的 1.5%，基准情景下到 2030 年将升至约 945 太瓦时（IEA，2025），对数据中心能耗的系统核算同样表明人工智能负载正在改变长期趋势（Masanet 等，2020；Shehabi 等，2024），而单次推理的能耗测算显示强度在不同任务与模型间差异巨大（Luccioni 等，2024）。必须提醒的是，算力中心用电包含训练、存储与非人工智能负载，推理侧的效率改进不能线性外推为全口径节电量；但方向是确定的：在能耗约束日益刚性的条件下，配置效率是继模型效率与硬件效率之后的第三条减排路径，且是唯一不依赖技术突破的一条。这一链路的定量分析属第 11 章。

第三条是分配链路。配置改进的收益并非在各方之间均匀分布：应用方因「够用即可」而降低单位业务的词元支出，算力运营方因利用率提高而提升单位资产的收入，政府因同一算力承载更多产出而提高投资效能，但高档位模型服务方可能因上溢型调用的减少而承受收入压力。这意味着统一调度的推进必然伴随利益重组，其可持续性取决于机制设计能否使各方激励相容。第 10 章将以三方演化博弈刻画这一过程，并求解补贴退出的条件；此处只需指出一点：配置效率的改进不是一个帕累托中性的技术过程，把它单纯当作工程优化来推进，会低估其制度成本。就宏观意义而言，把有限的算力、数据与模型资源配置到边际产出最高的用途上，正是新质生产力形成过程中要素配置效率提升的具体形态（洪银兴，2024；黄群慧和盛方富，2024）；而本章的分析表明，这一提升的技术前提是可比的计量，制度前提是可执行的调度规则。

9.6 本章小结

本章把「智算利用率仅五至七成而算力仍在加速扩建」这一配置悖论，从产业现象上升为可分解、可优化、可测算的经济学问题，构成全书的第三项理论创新。全章的逻辑主线是：在缺乏共同计量尺度的条件下，配置失灵是必然的；标准词元折算体系一旦建立，最优配置就从一个无法表述的目标变成一个可以求解的规划。

在转化函数上，本章构造了从算力到有效标准词元的两级折算：第一级是技术关系，把算力折算为物理词元；第二级是经济关系，把物理词元折算为标准词元。二者相乘得到本章的核心变量——单位算力的有效标准词元产出 θ_m ，六档位的校准结果自轻量蒸馏级的 42.0 万枚／(PFLOPS·h) 降至推理增强级的 3.1 万枚／(PFLOPS·h)，极差 13.5 倍。转化效率对算力强度的弹性为负，其主导项是 $w_p - 1 = -0.5617$ ——效值对算力强度的弹性显著小于 1，因而把算力投向更大

模型必然降低单位算力的标准词元产出。这一性质澄清了一个常见误解：转化效率随档位下降不是低效率，而是技术必然；真正的浪费不在于使用低转化效率的档位，而在于在不需要它的场合使用它。

在损失分解上，本章提出有效效值利用率概念，并以序贯反事实方法把名义算力利用率 62% 与实际价值转化之间的落差分解为空转 18%、批次 9%、匹配 12% 与效值 7% 四项相对损失率，四项逐级相乘得有效效值利用率 38%，合计折损 38.9%。四项损失作用于转化链条的不同环节、分属不同的责任层级，其中匹配损失占比最大且矫正成本最低，却恰恰是产业讨论中最被忽视的一项——产业注意力几乎全部集中于「卡是否闲着」，而「卡忙着但忙错了事」造成的损失并不更小。本章还辨明：匹配损失与效值损失是仅在标准词元口径下才可被识别的两项，这为「计量先于配置」的论断提供了直接证据。

在配置优化上，本章把降低匹配损失的问题写成带可行性约束与容量约束的指派规划，并证明在任务可分条件下其线性松弛的最优基可行解至多拆分 5 个任务类，整数间隙随任务规模趋于零（命题 9.1）。由此得到的对偶解给出「阶梯匹配原则」：在算力不紧张时任务应匹配到能够达标的最低档位，算力紧张时影子价格自动把任务向低档位推移。这一命题的深层含义是，统一调度在本质上不是一个技术平台，而是一套价格发现机制——若市场价格已充分反映效值，分散决策的结果将自动接近最优匹配。求解结果显示，统一调度可使有效效值利用率由 38% 升至 54%，改进 16 个百分点、相对提升 42%，理论上界为 61%，而名义算力利用率 62% 构成不可逾越的天花板。等效地，统一调度相当于凭空增加约 29.6% 的算力，单位标准词元的算力成本降至现状的 70.4%。分档位结果还给出一个可观测的判据：最优匹配下各档位的有效效值利用率应当收敛，其离差因而可以作为调度水平的外部检验指标。

在微观基础上，本章以排队论刻画了推理服务的时延结构，指出实际平均等待为基准排队模型理论值的 6.6 倍，差额来自批次组装、预填充与解码的相互干扰以及到达过程的突发性；时延分布的尾部略厚于指数分布（95 分位与均值之比 3.23，高于理论基准 3.00 约 7.8%），这在批次损失与空转损失之间建立了替代关系——加大批大小以压缩批次损失会推高时延尾部，迫使运营方预留更多冗余。批大小的时延—成本权衡显示综合指标最优区间落在中等批大小，超出该区间后单位成本已经触底而时延仍在加速上升；在当前参数下服务水平承诺并不绑定，批次损失主要来自负载时变性与批内请求异质性，而非时延约束本身。

最后，本章对配置改进作了情景测算并讨论其三条经济链路：价格链路上，配置效率是价格地板的技术决定因素，其改进带来的降价不以牺牲供给方利润为

代价，是价格下行中可持续的部分；能源与碳链路上，配置效率是继模型效率与硬件效率之后的第三条减排路径，且是唯一不依赖技术突破的一条；分配链路上，配置改进并非帕累托中性，统一调度必然伴随利益重组，其可持续性取决于机制设计。本章还特别辨明了本书折算体系与四套既有词元评价工作的关系：中国信息通信研究院的六维服务质量评估与四维标准体系、中国工业互联网研究院的五维价值度量、清华大学翟季冬团队联合清程极智的三项实测指标，主体各异、用途各异，共同形态是多维评价；而调度问题的目标函数必须是标量，维度得分向量无法进入最优化。本书从多维评价推进到当量折算的理论增量，正是在这一缺口上确立的。本章的匹配规则与效率上界将作为参数进入第 10 章的机制设计与第 12 章的增长核算，能耗链路的定量分析则由第 11 章接续。

第 10 章 城市词元运营中心的组织模式与机制设计

第 9 章把「智算利用率仅五至七成而算力仍在扩建」的配置悖论分解为空转、批次、匹配与效值四项损失，并证明在任务—模型最优匹配下，有效效值利用率可由 0.38 提高到 0.54，理论上界为 0.61。这一结论有一个未被回答的前提：统一调度需要一个统一的调度者。匹配损失之所以存在，不是因为算法不够好，而是因为算力、模型与场景分属不同主体、分处不同城市、采用不同口径，任何单一主体都既无权限也无信息去执行全局最优匹配。换言之，第 9 章求出的效率改进上界是一个「组织可行性」尚未落实的上界。谁来建这个统一入口，凭什么资产去建，用什么机制让企业愿意接入、让政府愿意在恰当的时点退出——这些问题不属于算法，而属于组织与制度。本章的任务，正是把第 9 章的技术可行性推进为组织可行性。

现实提供了一个不期而至的观察窗口。2026 年 7 月中旬至 8 月中旬，不到一个月之内，温州、嘉兴、广州、苏州先后启动了词元运营或交易服务机构（启动时点依次为 2026-07-15、2026-07-30、2026-07-30、2026-08-11），上海市经济和信息化委员会于 2026-08-11 印发《上海市软件和信息服务业发展「十五五」规划》，提出「探索将词元、数据治理、大模型部署及再训练等投入，纳入企业技术改造支持方向」（「上海市经济和信息化委员会，2026」）。四座城市的运营主体分属四种完全不同的组织类型：城市投资发展集团、国资控股的专业运营公司、基础电信运营商、数据交易所；上海则以政策工具而非实体机构切入。同一件事由五类主体分别去做，构成了一次天然的比较制度实验。本章要回答的第一个问题就是：这种主体类型的分化是偶然的的地方选择，还是资产禀赋与职能要求相互匹配的必然结果？

需要在一开始就厘清两处容易被拔高的表述，本书全篇均按核实后的口径叙述。其一，关于「词元」这一中文名的效力：2026 年 3 月 25 日，全国科学技术名词审定委员会发布公告，优先推荐并面向全社会发布试用人工智能领域名词 token 的中文名「词元」，并明确将在常态化审定中结合社会推广应用情况最终确认——这是术语审定的推荐与试用，既非「正式定名」，更非国家标准；同月，在中国发展高层论坛 2026 年年会上，国家发展改革委党组成员、国家数据局局长刘烈宏使用并推介了这一译名，提出词元具有「可计量、可定价、可交易」的特征，是智能时代的价值锚点。术语学口径与经济计量口径分属两个主体、两套定义，本章讨论价值计量与交易组织时引后者。其二，关于调用量：国家数据局口径的全国日均词元调用量只有四个官方锚点——2024 年初 1000 亿

枚、2025 年 6 月底 30 万亿枚、2025 年底 100 万亿枚、2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍（基期为 2024 年初）；其余时点均系校准复算插值，官方未单独发布。运营中心的兴起正发生在这一量级跃迁的末端，其组织形态是被规模推着长出来的，而非被规划出来的。

本章安排如下。10.1 节刻画政策从「补贴建算力」到「补贴买算力」再到「补贴用词元」的三段转向，并给出这一转向的三条经济学理由，说明为什么承载它的组织单元是城市；10.2 节以比较制度分析刻画五类运营主体的资产禀赋—职能匹配关系，给出匹配矩阵与主体特征对照；10.3 节聚焦城投转型，建立存量基础设施资产向标准词元产能映射的模型，解出转型的盈亏平衡利用率并做价格压力测试；10.4 节把「五个统一」还原为五类交易费用的节约机制，给出双边缔约与平台中介的费用比较与节约率表达式；10.5 节构建平台—企业—政府三方演化博弈，求解均衡、跃迁阈值与补贴退出条件，并以层次分析法给出制度要件的相对重要性排序；10.6 节讨论区域协同与全国统一大市场；10.7 节为本章小结。

10.1 兴起逻辑：从补贴建算力到补贴用词元的政策转向

10.1.1 三段转向的政策轨迹

城市词元运营中心不是凭空出现的组织创新，它是算力类公共政策连续三次转向的落点。第一段是「补贴建算力」。2021 年 5 月，《全国一体化大数据中心协同创新体系算力枢纽实施方案》（发改高技〔2021〕709 号）确立国家算力枢纽节点的布局（「国家发展改革委等，2021」），至 2022 年 2 月形成 8 个国家算力枢纽节点与 10 个国家数据中心集群的总体格局，「东数西算」工程全面启动；2023 年 12 月，《关于深入实施「东数西算」工程 加快构建全国一体化算力网的实施意见》（发改数据〔2023〕1779 号）进一步提出建设「联网调度、普惠易用、绿色安全」的全国一体化算力网（国家发展改革委等，2023）。与之配套的地方政策以建设侧激励为主：用地保障、电价优惠、机架补贴、建设贴息。这一阶段政策的计量对象是标准机架与浮点算力，补贴的落点在固定资产形成。

第二段是「补贴买算力」。当机房与集群相继建成，政策重心从形成产能转向消化产能，工具随之从投资补贴转为使用补贴，典型形式是算力券。江苏扬州在 2024 年 5 月率先推出人工智能算力券：符合条件的企业和科研机构在「运河城市算力平台」采购智能算力，可按实际支付额享受 30% 的财政补贴，单个主体年度最高 200 万元。同期的国家政策也在向使用侧倾斜，《「数据要素×」

三年行动计划（2024—2026 年）》（国数政策〔2023〕11 号）以场景打造与数据产业增速为量化目标（「国家数据局等，2023」），《国务院关于深入实施「人工智能+」行动的意见》（国发〔2025〕11 号）把智能技术向六大领域的渗透列为重点行动（国务院，2025）。这一阶段政策的计量对象是算力采购金额，补贴的落点在中间投入的价格楔子。

第三段是「补贴用词元」，其起点集中在 2026 年。同年 6 月，广东印发全国首份省级词元经济专项政策《广东省释放数据要素价值 促进词元经济高质量发展若干措施》，提出到 2027 年底基本形成全省一盘棋统筹、差异化布局、一体化协同的词元经济发展格局；7 月，扬州推出江苏首个词元券专项政策；8 月初，北京经济技术开发区发布全市首个聚焦词元全产业链的系统性支持政策，每年发放亿元级券金；上海则在软件和信息服务业「十五五」规划中提出探索将词元投入纳入企业技术改造支持方向（「上海市经济和信息化委员会，2026」）。国家层面的动作同步跟进：2026 年 5 月 22 日，国家数据局召开词元经济座谈会，明确把推动词元经济发展纳入工作体系，以行业高质量数据集建设和全国一体化算力网建设为两个着力点；2026 年 1 月印发的《关于组织开展国家算力互联互通节点建设工作的通知》（工信厅信管函〔2026〕35 号）则提出建立「1+M+N」国家算力互联互通节点体系，构建「统一标识、统一标准、统一规则」的运行机制。这一阶段政策的计量对象第一次成为词元本身。

三段转向的分野必须严格区分，不可当作同一政策的连续加码。算力券与词元券的补贴对象与计量基准完全不同：前者补的是算力采购额，其计量单位是卡时或 PFLOPS·h，补贴强度随算力价格波动；后者补的是词元消费，其计量单位是词元枚数或词元支出，补贴强度随模型档位与调用结构变化。扬州 2024 年的算力券与 2026 年的词元券在政策文本上前后相继，在经济含义上却是两种工具——把二者当作同一条补贴序列的延续，会得出补贴强度大幅提高的错误印象。同理，词元运营中心与词元工厂也是两类主体：前者属流通服务侧，其规模指标是接入模型条目数与服务企业数；后者属推理产能供给侧，其规模指标是日产能。两类主体的「全国首个」称号各有限定语，去掉限定语后会出现多个互相冲突的「首个」。

10.1.2 为什么补贴要从算力移到词元：三条经济学理由

政策落点的移动不是随机漂移，它有三条可以形式化的理由。第一条来自第 9 章的配置悖论：在利用率尚未饱和时，投资补贴的边际效果为负。投资补贴降

低的是资本的使用者成本，它会促使主体在既有产能之上继续追加产能；而第 9 章的测算表明，名义算力利用率为 0.62，扣除空转 18%、批次 9%、匹配 12% 与效值 7% 四项损失后，有效效值利用率仅为 0.38，四项损失合计 46%。IDC 与中国信息通信研究院的联合调研给出了需求侧的对应证据：近半数企业的智算资源利用率处于 51%—70% 的中等区间（48%），仅有不足 35% 的企业达到 70% 以上，另有 6.7% 的企业停留在 31%—50% 的较低水平，制造与政务两个行业低于平均水平——需要提示的是，该口径为企业侧调研自报值，统计对象是企业自建自用的智算资源，既不是机架上架率，也不是卡时利用率的实测采样，不能与媒体常引的集群利用率数字互证。在这样的产能状态下继续补贴建设，补的是空转。

第二条理由关乎补贴楔子的落点与需求弹性的匹配。使用补贴等价于对需求侧施加一个负的价格楔子，其扩量效果由需求价格弹性决定。第 8 章估计的全样本词元需求价格弹性为 -1.34，分行业看，文化传媒（-1.71）与制造（-1.62）富有弹性，金融（-0.94）与政务（-0.68）则缺乏弹性。这意味着同一张词元券在不同行业的效果相差数倍：在弹性行业，补贴通过价格直接转化为用量；在刚性行业，绑定的约束是预算科目与吸收能力，补贴主要转化为价内让利而非增量采纳。政策若只发券不配套预算科目调整与数据治理能力建设，就会在刚性行业形成「补了但没用起来」的空转，其性质与算力空转同构，只是发生在需求侧。

第三条理由最为根本：使用补贴要求补贴对象可核定，而词元恰好被认为具有可计量、可定价、可交易的属性。但这一属性只在物理词元层面成立于表观，第 3 章已经证明物理词元不可加，第 5 章的测算显示六档位单位价格的极差达 12.6 倍、变异系数 0.92，折算为标准词元后分别降至 2.4 倍与 0.31。若以物理词元枚数核定补贴，等价于对低档位词元给予更高的单位当量补贴——第 8 章表 8.2 的推论已经指出，以物理词元为分母会系统性地把「用了更强的模型」误判为「效率低下」，把补贴导向低档位、把成本监审的压力施加于高档位，方向恰好相反。因此，从算力补贴移向词元补贴，其可行性条件不是词元「能数」，而是词元「可折算」。统一计量因此不是运营中心的一项附属功能，而是使用补贴得以成立的制度前提。这构成本章与第 5 章折算体系之间的核心接口，也解释了为什么四座城市的运营中心不约而同地把统一计量列入首要职能。

10.1.3 为什么承载单元是城市

补贴对象从算力移向词元，回答的是「补什么」；组织单元落在城市，回答的是「谁来组织」。城市之所以成为词元运营的承载单元，有三重理由。其一是

要素的空间耦合：词元生产同时消耗电力、机房、网络与场地，这些要素的配置权高度集中于市级政府，算力与电力的协同布局、就地消纳更是只能在具体的电网分区与产业园区尺度上完成（中国信息通信研究院，2025）。其二是需求的组织成本：词元需求高度分散于中小企业，单个企业的采购规模不足以支撑与模型方、算力方的直接议价，而市级政府恰好掌握产业集群名录、技改项目库与行业协会渠道，能够以最低成本把分散需求聚合为可议价的批量需求。其三是政策工具的完备性：技改补贴、政策抵扣、园区租金减免与国资平台的资产注入，这四类工具只有在市级层面才能被同一主体同时调动。换言之，城市是词元经济中「最小完备治理单元」——比它更小的单元缺乏工具，比它更大的单元缺乏场景颗粒度。

这一判断也有其反面。城市既是最小完备单元，也是最小分割单元：每一个具备完备工具的层级，都同时具备把资源锁定在辖区之内的能力与激励。浙江省「十五五」规划纲要在「构建新型算力体系」部分提出「建立全省一体化算力监测调度平台」（「浙江省人民代表大会，2026」），正是对市级分割的一次省级校正。需要提示的是，全国一体化算力网（国家级）、全省一体化算力监测调度平台（省级）与城市算力调度或词元运营平台（市级）是三个层级、三套接入范围的不同事物，各平台上报的算力规模之间存在重复计算，不可加总。分割风险与协同机制将在 10.6 节集中讨论，此处先行标记：本章 10.2 至 10.5 节所论证的城市层级组织与机制，其效率主张始终附带一个约束条件——不得以牺牲跨城可比性与可流通性为代价。

10.2 五类运营主体的比较制度分析

10.2.1 分析框架：从「谁有资格办」到「哪类资产匹配哪项职能」

关于词元运营中心应由谁来办，实践中的争论往往围绕主体身份展开：国资还是民资、运营商还是平台企业、交易所还是产业集团。比较制度分析提示我们把问题重新表述：运营中心不是一个不可分割的组织，而是一束职能的集合；每一项职能都要求特定的专用性资产作为支撑，而不同类型的主体持有的专用性资产各不相同。因此，真正的问题不是「谁有资格办」，而是「哪一类资产禀赋与哪一项职能相匹配」，以及「当某一项职能所要求的资产不在同一主体手中时，用什么合约把它们连接起来」。这正是交易费用经济学处理纵向边界问题的标准思路，其判据是：把职能配置给专用性资产的所有者，可以最小化事前投资不足与事后适应性成本；而当职能本身带有公共品属性时，剩余控制权应当向中立主体倾斜，否则受益者无从相信规则不会被规则制定者用于自利。

沿这一思路，可以把运营中心的职能拆为两层。底层是两项供给性职能：算力产能的组织（含自建、代管、池化与跨域调度）与场景需求的组织（含语料治理、行业模型适配与 workflow 改造）。上层是五项治理性职能，即嘉兴门户所称的「五个统一」：统一 API 入口、统一词元计量、统一费用结算、统一政策抵扣、统一安全审计。两层职能的经济性质截然不同：底层职能具有私人品性质，谁提供谁受益，市场主体有充分激励；上层职能中的计量、审计与抵扣具有明显的公共品性质，其收益弥散于所有参与者，任何单一商业主体既缺乏提供的激励，也缺乏被各方接受的中立性。兼容性标准与质量披露制度的供给往往需要超越单个企业的协调机制（Farrell 和 Saloner，1985；Dranove 和 Jin，2010；Simcoe，2012），而标准化对生产率的提升效应在中国情境下亦有直接证据（何凡等，2025）。这一性质差异，决定了词元运营中心必然是「商业能力 + 公共职能」的混合体，也决定了纯粹的商业平台与纯粹的行政机构都不是合适的载体。

据此，本节把运营主体的资产禀赋归为四类：网络与云资源（骨干网、云平台、边缘节点）、土地电力机房（用地指标、变电容量、机架）、数据与场景（行业语料、应用场景与需求渠道）、制度与政策工具（标准制定权、补贴核定权、监管权限）。五类候选主体——基础电信运营商、城投集团、数据集团、数据交易所、政策制定者——在这四类资产上的禀赋结构差异显著，其比较优势职能也因此不同。五类主体的资产禀赋与职能匹配关系如图 10.1 所示。




图 10.1 五类词元运营主体的资产禀赋与职能匹配

图 10.1 呈现的匹配结构有三点值得展开。第一，没有任何一类主体在四类资产上同时具备强禀赋，这意味着单一主体独办运营中心必然在某一职能上留下短板：运营商强于网络与云资源而弱于制度工具，城投强于土地电力机房而弱于数据与场景，数据集团与交易所强于数据与场景而弱于物理设施，政策制定者独强于制度工具而在三类经营性资产上均不占优。第二，禀赋的强弱决定的是比较优势而非绝对资格：城投在数据与场景上禀赋弱，并不意味着它不能运营词元中心，而是意味着它必须通过合约把场景组织职能交给他方，自己聚焦于产能池化与算力批发。第三，唯一在四类资产上都不具备强禀赋、却在制度工具上不可替代的主体是政府，这决定了政府的合适角色是规则制定与凭证认可，而不是直接经营。这三点合起来给出了一个组织形态上的判断：词元运营中心的现实形态必然是「多方共建、分职能授权」，而不是单一主体的纵向一体化。

10.2.2 五类主体的现实实践与激励结构

把上述框架对照 2026 年七八月间的实践，五类主体的分工呈现出与图 10.1 高度一致的模式。基础电信运营商的代表是中国电信（江苏）Token 运营中心，2026-08-11 在苏州工业园区揭牌，落址苏州国际数据港这一国家级数据要素流通枢纽，依托天翼云「息壤 2.0」算力底座与星辰 TokenHub 运营服务平台，面向企业端提供模型广场、Skill 市场、应用超市、补贴专区、安全风控、指标监测六大类服务，并于同日成立词元出海服务联盟，首批 15 家成员涵盖云服务商、国际业务公司与模型企业。运营商的比较优势在网络接入与跨境通道，其激励结构的特征是「以连接换流量」——词元被自然地纳入既有的计费单元体系，新华社的报道即以「运营商的新增计费单元」概括这一变化。相应的激励扭曲风险也在于此：运营商有把调用量做大的强激励，却未必有把效值做高的激励，而按物理词元计量的考核会强化这一偏向。

城投集团的代表是长三角（嘉兴）Token 运营中心，2026-07-30 启动。需要精确表述的是运营边界：嘉兴市城市投资发展集团有限公司是运营中心面向市场的统一服务窗口（门户网站）的运营主体，而运营中心本身由嘉兴市层面统筹、多方共建，中国移动嘉兴分公司作为战略合作伙伴投放核心算力，中国电信同步参与生态共建。其定位是「立足嘉兴、服务长三角、链接全国资源」，三大职能为打造普惠服务入口、构建资源调度枢纽、探索绿色可信服务；门户以「五个统一」为治理框架，企业一次接入即可按需调用 100 余款主流大模型条目——此处的口径是平台可接入的模型条目数，同一厂商的多个版本分别计数，既不等于模型厂商数，也不等于已产生实际调用量的模型数。首批生态伙伴 20

家，覆盖制造业龙头与科技文化企业，其中制造业龙头包括巨石集团等。城投的比较优势在存量物理资产，其激励结构的特征是「以资产换现金流」，这一逻辑的完整展开构成 10.3 节的内容。

数据集团的代表是东南 Token 运营中心，2026-07-15 在温州启动，「词元天下」门户同步上线。同样需要精确表述：具体运营由国资控股的温州词元天下科技有限公司承担，其董事长由温州市数据集团总经理兼任，中国电信浙江公司与天翼云在建设运营初期重点提供智算基础设施、平台能力与运维保障，中国移动、中国联通同步参与门户入驻与生态共建。该中心的鲜明特色是绿色词元认证，其内核为三项可证：来源可溯（词元由哪个算力中心、什么模型生产）、用能可证（耗电量与绿电占比）、碳排可算（对应碳排放）。温州具备相应的能源条件——海上风电规划容量占浙江全省一半以上，2025 年清洁能源装机占比超过 45%。数据集团的比较优势在语料治理与场景组织，其激励结构的特征是「以数据换服务费」；绿色凭证则把能源禀赋转化为可交易的质量维度，这一机制的定价含义将在第 11 章展开。

数据交易所的代表是广东词元交易和服务中心，2026-07-30 在广州南沙揭牌。其组织结构为广东省政务服务和数据管理局统筹、广州市政务服务和数据管理局指导、依托广州数据交易所建设，承担词元标准制定、合规鉴证、场内交易、惠企扶持与跨境流通等职能，围绕企业采购需求构建可信流通、惠企政策、可信计量、词元出海、综合公共服务五大服务能力，牵头构建全省统一词元计量规则并出具交易凭证，依托交易所设立普惠、行业、跨境三大交易专区，企业凭交易凭证可享政策智能匹配与采购额度直兑。交易所的比较优势在确权登记与合规鉴证，其激励结构的特征是「以凭证换手续费」。这里潜藏着一类特有的扭曲风险：场内交易额是交易所的绩效指标，而词元调用量是技术指标，二者计量对象根本不同、无换算关系，若以交易额考核运营绩效，可能诱发凭证空转——成交在场内完成，词元却未被真实消费。

第五类主体是政策制定者。上海的路径最具代表性：不设实体运营机构，而以规划与技改政策切入，在软件和信息服务业「十五五」规划中提出「探索将词元、数据治理、大模型部署及再训练等投入，纳入企业技术改造支持方向」（「上海市经济和信息化委员会，2026」）。必须照录的是「探索……纳入」这一措辞，它属于探索性、试点性表述，而非已经落地的补贴目录；把它写成「已将词元支出纳入技改补贴」即为拔高。政策制定者的比较优势在制度工具，其「收益」是非货币的配置效率与产业目标，因而其激励扭曲风险不在于逐利，而在于两类政府失灵：一是补贴锁定，即在产业尚未自我维持时无法退出（这正

是 10.5 节演化博弈的核心议题)；二是属地绑定，即以补贴条件要求词元在本地生产或本地结算，从而制造市场分割。五类主体的资产、职能、收益模式与风险的系统对照见表 10.1。

表 10.1 五类词元运营主体的比较制度特征

运营主体	核心存量资产	比较优势职能	收益模式	主要激励扭曲风险	典型实践 (启动时点)
基础电信运营商	骨干网、云资源池、数据中心与政企渠道	统一入口与网络接入、出海通道与跨境合规	连接与云服务收入 + 词元调用分成	以物理调用量为考核，重规模轻效值	中国电信（江苏）Token 运营中心（2026-08-11）
城投集团	用地指标、变电容量、机房机架与市政设施	存量资产再打包、产能池化与算力批发	产能租金 + 批零价差	以建设逻辑替代运营逻辑，继续扩产能而非提利用率	长三角（嘉兴）Token 运营中心（2026-07-30）
数据集团	政务与行业数据、语料资源与场景通道	语料治理与行业适配、绿色词元凭证	数据产品与运营服务费	数据权属边界不清，竞争中性受质疑	东南 Token 运营中心（温州，2026-07-15）
数据交易所	交易场所资质、确权登记与鉴证能力	交易组织、计量凭证与结算清分、跨境流通	交易服务费与鉴证费	以场内交易额考核，诱发凭证空转	广东词元交易和服务中心（南沙，2026-07-30）
政策制定者	标准制定权、补贴核定权、监管与审计权限	计量标准与补贴核定、价格监测与安全审计	非货币收益：配置效率与产业目标	补贴锁定难以退出；属地绑定造成分割	上海市软信业「十五五」规划技改支持方向（2026-08-11）

注：核心存量资产与比较优势职能的划分对应图 10.1 的四类资产禀赋；典型实践栏的机构名称、启动时点与运营边界依据公开报道，其中嘉兴一栏的运营主体特指面向市场的统一服务窗口，运营中心本身由市级统筹、多方共建，温州一栏的具体运营主体为国资控股的专业运营公司。各地自定的能力清单（嘉兴「五个统一」、温州「六个统一」、苏州「六大类服务」、广东五大服务能力）分属平台治理能力、服务菜单与交易所职能三种不同性质，条目数不构成可比的能力评分。资料来源：公开报道与政策文件，检索截至 2026 年 8 月。

表 10.1 的横向对照揭示出一条规律：五类主体的激励扭曲风险各不相同，且都指向同一个计量问题。运营商的规模偏向、城投的建设偏向、交易所的交易额偏向，本质上都是「以易于观测的物理量替代难以观测的价值量」；数据集团的权属争议与政策制定者的属地绑定，则是「以主体身份替代客体标准」。两类偏差的共同解药都是可核验的标准词元计量：有了以效值折算为基础的统一计

量，运营绩效才能以有效标准词元而非物理词元枚数考核，补贴才能以标准词元当量而非采购金额核定，交易凭证才能与真实调用相互勾稽。这就把 10.4 节的机制设计问题提到了首位——在「五个统一」之中，统一计量不是并列的一项，而是其余四项的共同前置。

10.3 城投转型的资产逻辑：存量基础设施资产的再打包

10.3.1 转型约束：从建设融资到运营现金流

五类主体中，城投的转型最具理论意味，也最容易被误读为一次简单的业务延伸。城投的传统模式是「融资—建设—划拨」：以政府信用与土地资源获取融资，形成市政与园区基础设施，再通过财政补偿或资产划拨完成循环。在隐性债务约束趋紧的条件下，这一循环难以为继，城投必须找到能够自我产生经营性现金流的资产运营模式。词元运营恰好提供了这样一条通道：城投持有的机房、变电容量、用地与管廊，本身就是词元生产的必需投入；把这些存量物理资产重新打包为可对外销售的词元产能，等于把一次性建设收入转换为持续性服务收入。智算中心投资对企业全要素生产率的影响研究表明，算力设施的经济效应高度依赖其被使用的方式而非其建成的规模（许诺等，2025），这为城投的转型方向提供了直接依据：决定资产价值的是产能被调度出去的比例，而不是产能本身。

这里需要厘清一处容易混淆的会计边界。财政部《企业数据资源相关会计处理暂行规定》（财会〔2023〕11 号）为数据资源的确认与计量提供了规范（财政部，2023），企业数据资产化的确认条件与价值评估方法亦有系统讨论（罗玫等，2023）；但词元产能不是数据资源，而是一种服务能力：它既不满足数据资源的可辨认性要求，也不具有可与主体分离的转让价值。城投若以「词元资产入表」的方式虚增资产规模，在会计上缺乏依据，在经济上则会掩盖真实的现金流风险。城投转型的正确表述是资产用途的再配置与收入结构的再造，而不是资产负债表的扩张。

10.3.2 从物理资产到标准词元产能的映射

为刻画再打包的资产逻辑，先建立从物理设施到标准词元产能的映射。设城投持有 N 个机架，单机架的信息技术设备功率为 φ （千瓦），数据中心的电能利用效率为 PUE ，单位功率的算力密度为 ζ （PFLOPS 每千瓦），年运行小时为 H 。记第 9 章界定的算力—词元转化效率为 θ （单位 PFLOPS·h 产出的有效标准词元数），则满负荷条件下的年标准词元产能与年用电量分别为：

$$\tilde{T}^{max} = \theta \zeta \varphi H N, E = \varphi PUE H N \quad (10-1)$$

其中， $\tilde{T}^{max}$ 为满负荷标准词元产能（枚）， E 为年用电量（千瓦时）；两式共用同一组物理参数 (φ, H, N) ，因而产能与能耗被同一批存量资产同时决定，这正是词元生产的资产密集特征。

式(10-1)的第一层含义是产能的技术上限由三个乘子决定：物理规模 $\varphi H N$ 、工程效率 ζ 与转化效率 θ 。城投能够直接支配的是第一个乘子，而后两个乘子分别掌握在设备供应商与模型运营方手中——这就从技术上解释了为什么城投必须与运营商、模型方共建：单靠存量资产只能贡献产能的一个乘子。第二层含义是产能与能耗的同源性：单位标准词元的能耗强度等于 $E/\tilde{T}^{max} = PUE/(\theta\zeta)$ ，与机架数无关。它意味着扩大规模不会改善能耗强度，唯有提高转化效率与算力密度、降低PUE才能改善；这一结论是第11章绿色词元核算的资产侧基础，也提示城投的「以量补价」策略在碳约束下不可持续。

接下来比较两种商业模式的年净收益。传统模式是机架托管出租：设单机架年租金为 ρ 、单机架年运维与折旧为 f 。词元运营模式则是自建或代管智算设备、以标准词元价格 $\tilde{p}$ 对外销售：设单位标准词元的可变成本为 c_v （含电费与推理服务的其他可变投入），年固定成本为 F （含智算设备折旧、平台建设与运营团队），实际有效效值利用率为 u 。两种模式的年净收益分别为：

$$\pi^L = (\rho - f)N, \pi^T = (\tilde{p} - c_v)u\tilde{T}^{max} - F \quad (10-2)$$

其中， π^L 为托管出租模式的年净收益， π^T 为词元运营模式的年净收益； $u \in [0, 1]$ 为第9章界定的有效效值利用率，即实际产出的有效标准词元占满负荷产能之比。

10.3.3 盈亏平衡利用率、比较静态与价格压力测试

转型的可行条件是 $\pi^T \geq \pi^L$ ，即词元运营的净收益不低于托管出租这一机会成本。将式(10-2)代入并对 u 求解，得到转型的盈亏平衡利用率：

$$u^c = \frac{F/\tilde{T}^{max} + \omega}{\tilde{p} - c_v}, \omega \equiv \frac{(\rho - f)N}{\tilde{T}^{max}} = \frac{\rho - f}{\theta\zeta\varphi H} \quad (10-3)$$

其中， u^c 为盈亏平衡利用率， ω 为折算到单位满负荷产能上的机会成本，即放弃托管出租所损失的单位产能收益；当 $u > u^c$ 时转型创造价值，反之则毁灭价值。

式(10-3)的比较静态给出四条清晰的结论。第一， $\partial u^c / \partial \theta < 0$ ：转化效率越高，同样的固定成本被摊薄在更多标准词元上，转型门槛越低——这把第9章的效率议题直接变成了城投的财务议题。第二， $\partial u^c / \partial \tilde{p} < 0$ ：标准词元价格下行会抬高门槛，而第7章编制的价格指数显示，2024年第一季度至2026年第二季

度，物理词元价格指数由 100 降至 21，累计降幅 79%，标准词元价格指数同期降至 47，降幅 53%——门槛正在被持续抬高。第三， $\partial u^c / \partial \rho > 0$ ：机架托管市场越景气，转型的机会成本越高，门槛越高；这解释了一个看似反常的现象——托管租金最高的城市反而最不容易出现城投主导的词元运营中心。第四，把 θ 与 $\tilde{p}$ 合并考察，式(10-3)的分母乘以 θ 即为单位算力毛利 $(\tilde{p} - c_v)\theta$ ，第 8 章表 8.2 已测算该指标自轻量蒸馏级向推理增强级单调下降，本章按同一口径计算的极差为 3.7 倍。这意味着在固定的算力资产上，低档位产品对固定成本的覆盖能力更强，而高档位产品的单位词元加成更厚——城投的产品结构决策因此不是一个简单的「向高端走」问题，而是覆盖固定成本与获取效值溢价之间的权衡。

为给出可比的数量级，以第 8 章测算的六档位成本结构与第 7 章的市场价为参数，并以第 9 章的有效效值利用率 0.38 作为基准运行点校准固定成本（即令 $F/\tilde{T}^{max} = (\overline{AC} - \overline{MC})u_0$ ），在暂不计机会成本（ $\omega=0$ ）的下界情形下，各档位的盈亏平衡利用率介于 0.060（推理增强级）与 0.132（轻量蒸馏级）之间，按 2026 年各档位用量份额加权的平均值为 0.105。与当前 0.38 的实际利用率相比，安全边际约为 3.6 倍；若第 9 章的统一调度把利用率提高到 0.54，安全边际将升至 5.2 倍。值得注意的是，盈亏平衡利用率随档位升高而下降，原因在于高档位的单位加成远大于单位固定成本分摊；但这并不意味着城投应当把产能全部投向高档位，因为高档位的需求规模与单位算力收入均显著更低。

真正的风险出现在价格维度。做一次压力测试：保持成本结构与基准利用率不变，令各档位市场价再下降一半，则加权平均的盈亏平衡利用率由 0.105 升至 0.312，安全边际由 3.6 倍压缩至 1.2 倍，几乎与当前实际利用率 0.38 持平。考虑到 2024 年第一季度以来物理词元价格指数已累计下降 79%，「再降一半」并非一个遥远的假设。这一测算给出了城投转型的核心风险判断：转型的成败不取决于是否拿到了算力，而取决于两个可控变量能否跑赢价格下行——一是利用率能否通过统一调度显著提升，二是产品结构能否通过效值提升把收入从物理词元数量转向标准词元当量。这两个变量恰好对应本书的两项核心机制：第 9 章的任务—模型最优匹配与第 5 章的效值折算。城投若把转型理解为「多建机房、多卖词元」，则在价格下行中必然被挤出；理解为「提高利用率、提升效值」，才可能形成可持续的经营性现金流。这也从资产侧解释了为什么统一调度与统一计量必须捆绑在同一个平台上。

10.4 「五个统一」的机制设计与交易费用节约

10.4.1 五类交易费用与两种缔约结构

「五个统一」是嘉兴门户提出的治理框架，其五项内容依次为统一 API 入口、统一词元计量、统一费用结算、统一政策抵扣、统一安全审计。需要预先声明口径：温州东南中心用的是「六个统一」，苏州中心用的是「六大类服务」，广东中心的表述则是五大服务能力，三者分属平台治理能力、服务菜单与交易场所职能，条目数不构成可比的能力评分，本节以嘉兴口径为分析对象，不做跨城条目数比较。本节的核心主张是：这五项并非五项便民服务，而是对五类交易费用的针对性消解，其经济价值可以被量化。

考虑一个城市内有 n 家有词元需求的企业与 m 个可供选择的模型或算力供给条目。在双边缔约结构下，企业若要获得与平台同等的选择空间，必须分别与各供给方缔约：搜寻并比选模型、适配各自的接口、核对各自口径的用量账单、分别开票对账、分别提交合规与安全材料。记单次缔约关系上的四类交易费用（搜寻与匹配、计量与验证、支付与对账、合规与审计）合计为 κ ，另有与供给方数量无关的企业内部固定投入 κ_f （如内部立项与预算流程）。在平台中介结构下，企业只与平台缔约一次，供给方也只与平台缔约一次，平台的固定投入 Φ 由全部接入企业分摊。两种结构下单个企业面对的交易费用分别为：

$$C^B = \kappa \dot{m} + \kappa_f, C^P = \kappa_0 + \frac{\Phi}{n} + \kappa_f \quad (10-4)$$

其中， $\dot{m}$ 为企业在双边结构下实际需要缔约的供给方数量， κ_0 为企业与平台之间单一缔约关系上的交易费用； C^B 随可选供给方数量线性上升， C^P 则随接入企业数上升而下降。

式(10-4)的结构差异是全部机制价值的来源：双边结构下城市范围内的缔约关系总数为 $n\dot{m}$ ，平台结构下降为 $n+m$ 。据此定义交易费用节约率并给出平台优于双边的条件：

$$\tau = 1 - \frac{C^P}{C^B} = 1 - \frac{\kappa_0 + \Phi/n + \kappa_f}{\kappa \dot{m} + \kappa_f}, \tau > 0 \Leftrightarrow \dot{m} > \frac{\kappa_0 + \Phi/n}{\kappa} \quad (10-5)$$

其中， τ 为交易费用节约率，即企业接入统一平台后所节省的交易费用占其双边缔约费用之比；不等式右端为平台中介优于双边缔约的临界供给方数量。

式(10-5)有三项性质决定了词元运营中心的可行性边界。第一，节约率随 $\dot{m}$ 与 n 同时递增：可选模型条目越多、接入企业越多，平台的相对优势越大，这是典型的双边网络效应（Katz 和 Shapiro，1985；Armstrong，2006；Jullien

等，2021)。嘉兴门户宣称一次接入即可调用 100 余款主流大模型条目，正是把 m 推高到双边缔约完全不经济的区间——一家中型企业若要自行完成同等规模的比选、适配与对账，其内部成本将远超其全年词元支出。第二，存在一个规模门槛：当 m 小于临界值时，平台的固定投入无法被摊薄，统一入口反而是净损失，这解释了为什么词元运营中心只在产业密度足够高的城市才成立，也提示中小城市的正确选择是接入区域平台而非自建。第三， τ 是内生于规模的，而非一个技术常数；本章 10.5 节的演化博弈把它作为参数处理，其校准取值为 0.35，含义是接入统一平台可为企业节约约 35% 的相关交易费用。「五个统一」各模块所对应的交易费用类型及其汇入平台价值闭环的路径如图 10.2 所示。




图 10.2 「五个统一」的机制设计与交易费用节约

注：各模块括号内为 10.5.5 节层次分析法测算的方案层组合权重； τ 为式(10-5)定义的交易费用节约率，图中取值为 10.5 节演化博弈的校准参数。

图 10.2 右侧的价值闭环刻画了机制设计的动态含义：交易费用的节约直接抬高企业采纳的净收益，使企业红利越过跃迁阈值；采纳规模扩大带来平台侧的规模经济，推动单位成本与价格下行；价格下行又进一步降低了后续企业的采纳门槛，形成正反馈。这一闭环的关键在于，五项统一并非可以任意拆分的功能清单，而是具有强互补性的制度包。统一计量是其余四项的共同前置：没有可核验的用量与效值口径，结算无从对账、政策抵扣无从核定、安全审计无从追溯，统一入口也会退化为一个仅供比价的目录。反过来，若只做统一计量而不做统一结算与抵扣，企业获得的仅是信息而非现金流改善，采纳意愿不足以形成规模。这种「单项收益小于组合收益」的互补结构，意味着机制设计必须整包推进，逐项

试点的策略会因每一项单独考核不达标而中途夭折。五项统一的具体内容与失效表现见表 10.2。

表 10.2 「五个统一」的机制内容、交易费用节约与失效表现

统一项	分散状态下的安排	所节约的交易费用	可核验产出	缺位时的典型失效
统一 API 入口	逐一比选模型、分别适配接口与鉴权	搜寻与匹配费用	统一接口规范与模型能力目录	企业以试用成本为由锁定单一供给方
统一词元计量	各供给方自定计费口径，输入输出与缓存分别计价	计量与验证费用	标准词元用量账单与效值折算说明	效值信息不对称，补贴与成本监审失去分母
统一费用结算	多方分别开票、跨主体逐笔对账清分	支付与对账费用	合并账单与跨主体清分记录	中小企业因垫资与对账成本放弃多模型使用
统一政策抵扣	补贴分别申报、材料重复核验	政策申报与举证费用	抵扣凭证与补贴核定台账	补贴到达率低，政策效果集中于大企业
统一安全审计	各方分别做安全评估、数据出境重复审查	合规与审计费用	调用日志与合规审计报告	合规责任边界不清，企业以不用规避风险

注：五项内容依嘉兴门户口径列示，与温州「六个统一」、苏州「六大类服务」、广东五大服务能力分属不同性质的清单，不作条目数比较；交易费用分类对应式(10-4)中的四类缔约费用与政策申报费用。

表 10.2 中「可核验产出」一栏是机制设计的落脚点。制度安排若不产出可被第三方核验的凭证，就无法进入补贴核定、成本监审与跨城互认的流程，也就无法真正降低交易费用——这正是质量披露与认证制度研究的基本结论（Dranove 和 Jin，2010）。就词元而言，最关键的凭证是标准词元用量账单：它把「调用了多少枚」的技术记录转换为「相当于多少标准词元当量」的经济记录，使补贴核定、成本比较与增长核算获得共同分母。第 8 章测算的效值信息不对称程度提供了这一凭证的必要性证据：企业对所购词元效值的认知偏差均值为 0.44，并导致低效值档位的过度采购份额达 27%；在质量不可观测而价格可观测的市场上，买方只能依据平均质量出价，高质量供给被逆向选择挤出（Akerlof，1970）。统一计量正是把这一逆向选择机制反转过来的制度装置。

10.4.2 统一计量的标准依据与本书的定位

统一计量既是机制设计的核心，也是最容易被夸大其制度成熟度的一环，因此有必要厘清现有标准的真实状态。截至 2026 年 8 月，词元领域已发布的规范性成果主要有三类，其效力层级依次递减且不可混称。第一类是团体标准：中国人工智能产业发展联盟归口、中国信息通信研究院人工智能研究所联合行业企

业编制的《人工智能词元（Token）运营管理能力要求》（AIIA/T 0308—2026）于 2026 年 8 月发布，旨在为词元运营管理平台建立统一的能力规范——需要强调的是，团体标准的效力层级低于国家标准与行业标准，不得称其为国家标准。第二类是机构评估规范，如中国信息通信研究院的《人工智能 Token 服务质量能力要求》，其评估体系包含模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度，其中「计量计费」是目前最接近计费标准的已落地成果，但它是评估体系的一个维度，而非独立的计费标准。第三类是框架性成果，如中国信息通信研究院 2026 年 6 月 16 日发布的「高质量 Token 服务标准体系」，包含服务质量、运营能力、生产能力、安全能力四个维度。国家标准层面，相关工作归口于全国信息技术标准化技术委员会及其人工智能分技术委员会，但尚未见到以词元计量或词元计费为标题的国家标准计划公开。

与上述工作构成对话关系的还有另外两套体系，其主体必须逐一注明，严禁合并、平均或交叉引用维度名称。其一是中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》构建的五维价值度量体系，涵盖生产成本、生产效率、准确性、生态价值、安全，该体系不属于中国信息通信研究院。其二是清华大学翟季冬团队联合清程极智于 2026 年 5 月发布的开源模型词元服务性能榜，以首词元时延（P90 分位）、输出吞吐与缓存命中率三项实测指标对服务商排序。此外，中国信息通信研究院 2026 年 6 月启动的词元服务能力攀登计划，首批达成的企业级通用场景性能基线为吞吐不低于 55 词元每秒、首词元时延不高于 0.9 秒、调用成功率 99.9%——须注意这是首批参与企业达成的基线值，既不是行业平均值，也不是强制门槛，且其时延未标注分位，与采用 P90 分位的第三方榜单不可直接比较。

把这五套工作放在一起，可以清楚地看到既有制度供给的边界与本书的定位。五套体系分别产出的是并列的维度得分、达标基线或实测排名，它们回答的是「这一家的词元服务好不好」，属于多维评价；而运营中心的统一计量所需要的，是把不同模型、不同任务生成的异质词元合成为可比、可加、可入账的单一当量，回答的是「这一枚词元值多少枚基准词元」，属于当量折算。多维评价无法直接用于补贴核定与价格指数编制，因为多个维度的得分无法加总为一个可作分母的数量；当量折算则可以。本书第 5 章构建的三维效值折算体系正是为填补这一空白而设，其算力强度 P 、推理质量 R 、场景效用 S 三维及其合成函数为作者自主构建的理论框架，与上述任何一家机构的评价维度均无对应关系，也不得

被指称为任何机构的既有成果。从多维评价推进到当量折算，是本书相对既有工作的理论增量，也是城市词元运营中心把统一计量落到实处所必需的技术条件。

10.5 平台—企业—政府三方演化博弈：均衡、阈值与补贴退出

10.5.1 博弈设定与支付结构

前三节确立了运营中心的组织形态与机制内容，但尚未回答一个动态问题：这样的制度安排能否自我维持？现实中的关切正在于此——地方政府担心补贴一旦退出平台就停摆，平台担心政府的支持不可持续，企业则在观望中推迟采纳。这是一个典型的多主体互动情形，参与者数量众多、理性有限、策略随收益反馈调整，适合以演化博弈刻画。设三类主体：平台（词元运营中心的运营方）、企业（词元需求方）、政府（补贴与政策的提供方）。平台的策略集为{深度运营，浅度运营}，深度运营指投入建设统一计量、统一结算与统一调度能力，浅度运营指仅做接口转售；企业的策略集为{深度采纳，浅度采纳}，深度采纳指把词元嵌入主业务流并改造工作流，浅度采纳指仅在边缘场景试用；政府的策略集为{强激励，弱激励}，强激励指技改补贴与政策抵扣并用，弱激励指仅做一般性引导。记选择前一策略的比例分别为 x 、 y 、 z 。

平台选择深度运营的净收益差由三部分构成：随企业采纳深度上升的运营收益、政府强激励下获得的补贴支持、以及统一平台带来的交易费用节约所转化的可占有份额，扣除深度运营的建设与维护成本。写作：

$$\Delta \Pi_P(y, z) = R_P(a_0 + a_1 y) + s z + \tau y - c_P \quad (10-6)$$

其中， R_P 为平台深度运营的基准收益（校准值 1.30）， a_0 与 a_1 为企业浅度采纳时的基础转化率及其随 y 的边际提升（分别取 0.30 与 0.45）， s 为政府强激励下平台获得的支持强度（0.60）， τ 为式(10-5)定义的交易费用节约率（0.35）， c_P 为深度运营的成本（0.90）。

企业选择深度采纳的净收益差取决于其能从词元应用中获得的业务红利，而该红利的可实现程度又取决于平台的建设深度：接口是否统一、账单是否可核、模型是否可选，直接决定企业改造工作流的成功概率。政府的净收益差则相反，它随融合程度上升而下降：政府提供强激励的收益是避免错配损失，当平台与企业均已深度融合时，错配损失自然消失，继续补贴只剩成本。两式为：

$$\Delta \Pi_F(x, z) = R_F(b_0 + b_1 x) + \sigma s z - c_F - e, \Delta \Pi_G(x, y) = L[g_1(1 - y) + g_2(1 - x)] - c_G s \quad (10-7)$$

其中， R_F 为企业深度采纳的业务红利， b_0 与 b_1 为平台浅度运营时的基础红利实现率及其随 x 的边际提升（分别取 0.20 与 0.40）， σ 为企业可分享的补贴比例（0.25）， c_F 为深度采纳的持续成本， e 为一次性转换成本（0.08）； L 为错配损失（0.90）， g_1 与 g_2 为该损失中企业侧与平台侧的权重（0.75 与 0.25）， c_G 为政府提供单位补贴的财政成本系数（0.80）。

支付结构的三处设定值得说明其经济依据。第一，平台收益中 τy 一项把 10.4 节的交易费用节约显性地写入支付函数，其含义是节约下来的交易费用中有一部分被平台以服务费形式占有——若该项为零，则统一计量与统一结算对平台而言纯粹是成本，机制将无法自我维持，这一点在 10.5.3 节的阈值分析中将得到量化。第二，企业红利 R_F 被设定为随平台建设深度线性放大，这与第 6 章价值实现链条的结论一致：词元的价值不在生成环节实现，而在嵌入业务流程后实现，而嵌入的难度直接由接口、计量与结算的统一程度决定。第三，政府的收益被设定为避免错配损失而非直接的财政回报，其中企业侧权重高于平台侧，反映的是第 9 章的判断：匹配损失主要发生在任务与模型的对接环节，而非平台自身的建设环节。

10.5.2 复制动态与均衡结构

在有限理性与策略模仿的假定下，采用某一策略的主体比例按其相对收益优势增长，得到三方复制动态方程组：

$$\dot{x} = \kappa x(1-x)\Delta\Pi_P, \dot{y} = \kappa y(1-y)\Delta\Pi_F, \dot{z} = \kappa z(1-z)\Delta\Pi_G \quad (10-8)$$

其中， κ 为策略调整速度（取 1.0）；三式的乘积结构表明，任一比例趋于 0 或 1 时该策略的调整速度趋于零，系统的动态完全由三个净收益差的符号决定。

式(10-8)的均衡点包括立方体 $[0,1]^3$ 的八个顶点以及若干边界与内部驻点。在三方演化博弈中，内部驻点与边界驻点均不可能是演化稳定策略，因为它们至少在一个方向上不满足严格的收益劣势条件，故只需考察八个纯策略顶点的渐近稳定性：顶点稳定当且仅当在该点处三个净收益差对各自策略均给出「向内」的方向，即选择该顶点策略者收益严格更高。逐一检验可知，在本节的参数结构下，只有两个顶点可能稳定。其一是 $(1,0,1)$ ：平台深度运营、企业浅度采纳、政府强激励——平台被补贴托住、企业不跟进、政府因错配损失仍在而无法退出，本书称之为「平台热、企业冷」的补贴锁定均衡。其二是 $(1,1,0)$ ：平台深度运营、企业深度采纳、政府退出强激励——这是制度设计所追求的融合稳态。两者

的分野不在于平台是否努力，而在于企业红利 R_F 是否越过某一临界值，这正是下一小节要求解的对象。

这里有一个容易被忽视的结构性事实：政府是三方中唯一其收益随他方策略上升而下降的主体。 $\Delta \Pi_G$ 对 y 与 x 均为负导数，意味着政府的强激励在设计上就是自我消解的——它成功的标志正是自身变得不必要。这与平台和企业的正反馈结构形成鲜明对照，也决定了补贴退出不是一个需要外部意志推动的决定，而是均衡路径本身的组成部分。真正的政策难题因此不是「要不要退出」，而是「在哪一点退出才不会引发回摆」，这需把政府的私人退出条件与系统的自我维持条件区分开来。

10.5.3 三重阈值：企业跃迁、政府退出与平台自维持

先求企业侧的跃迁阈值。令 $\Delta \Pi_F = 0$ ，在平台已完全深度运营（ $x=1$ ）的条件下解出临界业务红利，并把同一条件改写为对平台建设深度的要求，得：

$$R_F^c = \frac{c_F + e - \sigma s z}{b_0 + b_1}, x^c(z) = \frac{1}{b_1} \left[\frac{c_F + e - \sigma s z}{R_F} - b_0 \right] \quad (10-9)$$

其中， R_F^c 为企业深度采纳成为演化稳定策略所需的临界业务红利， $x^c(z)$ 为给定红利与补贴强度下企业愿意跟进所要求的平台建设深度；二者是同一条件的两种表述。

代入参数可得三组数量结论。第一，在政府维持强激励（ $z \rightarrow 0.995$ ）的条件下，临界业务红利 $R_F^c = 1.55$ ；而基准情景设定的企业红利为 1.5，两者相差仅 3.2%，企业的净收益差为 -0.031——一个绝对值极小的负数。这就是演化博弈阈值效应最直观的体现：红利只差百分之三，均衡却完全不同。第二，若政府退出强激励（ $z \rightarrow 0$ ），企业自我维持深度采纳所需的红利升至 $R_F^s = 1.80$ ，这是判断补贴能否安全退出的收益侧条件。第三，从 $x^c(z)$ 的角度看，在高红利情景（ $R_F = 2.5$ ）下，无补贴时企业要求平台建设深度达到 0.58，有强激励时这一要求降至 0.43；而模拟的初始平台建设深度仅为 0.30，低于两者。这一比较揭示了补贴在过渡期的真实作用：它并非直接购买企业的采纳，而是把企业跟进所需的平台建设门槛降低了 0.15 个单位，从而缩短了平台从起步到被企业认可所需的时间。若红利停留在基准水平， x^c 的解将超过 1（1.05），意味着无论平台建设到何种程度，企业都不会深度采纳——这正是补贴锁定均衡的成因。

再求政府侧的退出条件与平台侧的自维持条件。令 $\Delta \Pi_G < 0$ 解出政府停止强激励的门槛，令 $\Delta \Pi_p > 0$ 且 $z=0$ 解出平台无补贴时仍愿深度运营的门槛：

$$y^*(x) = 1 - \frac{c_G s - L g_2(1-x)}{L g_1}, y^P = \frac{c_P - R_P a_0}{R_P a_1 + \tau} \quad (10-10)$$

其中， y^* 为政府自身收益转负、从而不再有激励维持强补贴的企业采纳门槛， y^P 为补贴归零后平台仍能自负盈亏地维持深度运营的企业采纳门槛。

代入参数，在平台完全深度运营时 $y^*=0.289$ ，而 $y^P=0.545$ 。两个门槛的排序给出了本章最重要的一条机制设计结论： $y^* < y^P$ ，即政府的私人最优退出点显著早于系统的自我维持点。在企业采纳比例介于 0.289 与 0.545 之间的区间内，政府已经没有继续补贴的激励，平台却尚不能自负盈亏；若此时补贴以行政方式骤然退出，平台的净收益差转负，深度运营比例回落，进而拉低企业红利的实现程度，系统有可能从融合路径回摆至锁定均衡。本书把这一区间称为「退出过早的风险窗口」。在连续的复制动态中，由于 z 的下降本身也是渐进的，系统通常能够安全穿越该窗口；但现实中的补贴退坡往往是离散的——按年度、按文件有效期、按财政收支状况一次性调整，因而风险窗口是真实存在的。相应的机制设计含义十分明确：补贴退坡的触发条件应当锚定 $y \geq y^P = 0.545$ 这一系统自维持门槛，而非政府自身收益转负的 $y^* = 0.289$ ，并且应当采取连续退坡而非断崖式终止，同时以事先公布的规则替代相机决策，以稳定平台与企业的预期。

式(10-10)还给出了 10.4 节机制价值的一个精确度量。若统一平台不产生任何交易费用节约（ $\tau=0$ ），平台自维持所需的企业采纳比例将由 0.545 升至 0.872。也就是说，「五个统一」所带来的交易费用节约，把制度可持续所需的企业采纳规模降低了约 0.326 个单位、相对降幅达 37%。这是一个不容易从直觉得到的结论：统一计量、统一结算这类看似只是「便利」的制度安排，其真实作用是把补贴退出的可行区间大幅前移，从而决定了整套制度能否在有限的财政窗口内完成自我维持。同理，在启动阶段，以初始状态（ $x_0=0.30$ 、 $y_0=0.15$ 、 $z_0=0.65$ ）代入式(10-6)可得平台的净收益差仅为 0.020，几乎处于临界状态；若政府不提供强激励，平台在企业尚未采纳时启动深度运营所需的补贴强度门槛为 $z > 0.85$ 。启动期对政策的高度依赖，与成熟期对政策的完全不依赖，构成同一机制的两端。

10.5.4 三情景数值模拟

以四阶龙格—库塔法对式(10-8)作数值积分，步长 0.1、窗口 60 期，初值取 $(x_0, y_0, z_0) = (0.30, 0.15, 0.65)$ ，设定三个情景：情景 A 为基准情景，企业红利取基准值；情景 B 提高企业红利，对应效值透明化与场景深化使企业能够真实兑现词元的业务价值；情景 C 在情景 B 基础上进一步降低企业的深度采纳成本，对

应统一接入与统一结算把企业的对接与对账负担显著压低。三情景的演化轨迹如图 10.3 所示。




图 10.3 三方演化博弈的情景轨迹

注：三面板分别对应企业红利 $R_F = 1.5$ 、 2.5 以及 $R_F = 2.5$ 且企业采纳成本降至 0.70 的情形；其余参数为 $R_P = 1.30$ 、 $c_P = 0.90$ 、 $c_F = 1.00$ 、 $s = 0.60$ 、 $c_G = 0.80$ 、 $L = 0.90$ 、 $\tau = 0.35$ 、 $\kappa = 1.0$ ；四阶龙格—库塔法，步长 0.1 ，窗口 60 期，初值 $(x_0, y_0, z_0) = (0.30, 0.15, 0.65)$ ，策略比例上下限截断于 $[0.005, 0.995]$ 。收敛期指三变量单步变动均小于 $1e-4$ 的最早时点。数据来源：作者校准复算。

情景 A 的结果是补贴锁定均衡。平台比例升至 0.984 ，企业比例跌至 0.005 ，政府比例被推高并稳定在 0.995 ，窗口内未完成收敛。其经济含义是：补贴成功地把平台建起来了，却没有把企业带进来；由于企业侧的错配损失始终存在，政府的净收益差长期为正，强激励无法退出，财政被长期锁定在一个「有平台、无采纳」的状态上。必须强调，导致这一结果的并非参数的极端设定——基准红利 1.5 距临界值 1.55 仅差 3.2% 。这提示了一个现实风险：地方在评估词元运营中心的可行性时，若只测算平台侧的收支平衡而不测算企业侧红利是否越过临界，很可能在参数上距成功仅一步之遥，在结果上却落入完全相反的均衡。

情景 B 与情景 C 均收敛于融合稳态：平台与企业比例趋于 0.995 与 0.995 ，政府比例降至 0.005 ，补贴成功退出。两者的差别在于速度：情景 B 的收敛期为 41.7 ，情景 C 为 23.5 ，提速 44% 。这一对照具有直接的政策含义：提高企业红利与降低企业成本是两条不同的路径，前者依赖效值透明与场景深化，见效慢但决定能否成功；后者依赖统一接入与统一结算，见效快且能显著缩短财政补贴的持续期。两条路径并非替代关系——若红利不足，单靠降低成本无法改变均衡；但在红利已足的条件下，降低成本可以把补贴期压缩近一半，其财政意义等价于把同样的政策目标以更低的累计支出实现。这为「五个统一」的优先级排序提供了动态依据：统一计量决定红利能否被识别，统一入口与统一结算决定成本能否被压低，二者一慢一快，共同构成机制的两个作用面。

还需说明三点边界。其一，模型刻画的是策略比例的演化而非具体企业的决策，所有比例都应读作群体分布而非个体概率。其二，参数为校准复算值，其绝对水平不具备预测意义，具有分析价值的是阈值的相对位置与均衡的定性分野

——这也是演化博弈方法的标准解读方式。其三，模型未刻画跨城市的策略互动，若把政府的策略空间扩展为「本地强激励」与「区域协同激励」，则可能出现属地补贴竞争导致的过度激励，这一维度的讨论留待 10.6 节展开。

10.5.5 制度要件的相对重要性：层次分析法的证据

演化博弈回答了机制能否自我维持，却没有回答在资源约束下应当优先做哪一项。为此，本节以层次分析法对制度要件排序。目标层为「城市词元运营机制的有效性」，准则层设三项：配置效率、计价公允、可持续运营；方案层为「五个统一」。采用两轮专家咨询，有效专家 26 位，涵盖平台运营、企业信息化、地方主管部门与研究机构，两轮之间反馈匿名统计结果，第二轮的肯德尔协调系数为 0.69，表明专家意见具有较好的一致性。判断矩阵的一致性检验结果与方案层的组合权重如图 10.4 所示。




图 10.4 制度要件的层次分析权重

注：方案层组合权重 = 各方案对三项准则的局部权重按准则层权重加权求和；准则层与方案层判断矩阵的一致性比率分别为 0.031 与 0.038，均小于 0.1，通过一致性检验；专家 $N = 26$ ，两轮咨询，第二轮肯德尔协调系数 $W = 0.69$ 。数据来源：作者调查与测算。

准则层的权重排序为配置效率 0.412、计价公允 0.318、可持续运营 0.270，最大特征根为 3.036。三项准则的权重差距并不悬殊，说明专家并不认为运营中心可以牺牲公允性去换取效率，这与词元运营中心兼具商业能力与公共职能的双重属性一致。方案层的组合权重排序为：统一计量 0.271、统一结算 0.223、统一 API 入口 0.196、统一安全审计 0.166、统一政策抵扣 0.144。排序的首尾差距接近一倍，且统一计量与统一结算两项合计达 0.494，超过五项总权重的一半。

这一排序与本章前几节的理论分析高度吻合，且三处吻合都不是同义反复。第一，统一计量居首，对应 10.4 节论证的「计量是其余四项的共同前置」，也对应 10.1 节的结论——使用补贴的可行性条件是补贴对象可折算而非可计数。

第二，统一结算居次，对应 10.5.4 节的动态发现——降低企业采纳成本能够把补贴期压缩 44%，而结算负担正是中小企业采纳成本中最直接的一块。第三，统一政策抵扣权重最低，这一结果初看反直觉：抵扣是企业最能直接感知的优惠。但从机制设计的角度看，抵扣是外生的转移支付，它改变的是分配而非效率，且按式(10-10)的分析，补贴终将退出；而计量、结算、入口与审计所创造的交易费用节约是内生且持久的。专家排序实际上表达了一个专业判断：词元运营中心的长期价值在于降低交易费用而非分发补贴。这一判断对当前各地密集出台的券类政策构成温和的提醒——券金规模不是运营中心成熟度的度量，可核验凭证的完备程度才是。

10.6 区域协同与全国统一大市场

10.6.1 城市层级组织的三重分割风险

10.1.3 节已经标记，城市既是最小完备治理单元，也是最小分割单元。当五类主体在数十个城市同时展开建设时，三重分割风险随之显性化。第一重是计量口径的分割。若每座城市各自制定词元计量规则、各自出具交易凭证，则同一枚词元在甲城的账单与在乙城的账单不可互认，企业跨城采购必须重复核验，统一计量在城市内部消除的交易费用会在城市之间重新产生。广东中心牵头构建全省统一词元计量规则并出具交易凭证，是省级层面对这一风险的正面应对；但省与省之间的互认仍缺乏制度安排。标准的经济学分析早已指出，兼容性标准的社会收益远大于任何单一主体的私人收益，因而其供给必须依赖跨主体的协调机制（Farrell 和 Saloner，1985；Simcoe，2012）。

第二重是补贴的属地绑定。使用补贴天然带有属地条件——财政资金要求资金流与税收留在本地，最直接的做法是要求受补贴的词元在本地生产、由本地主体结算。这一条件在经济上等价于对外地词元课征关税：它把本应由效值与价格决定的采购决策，扭曲为由补贴归属决定的采购决策。其后果是双重的：企业被迫使用效值更低或价格更高的本地供给，配置效率下降；同时，外地高效值供给被挡在门外，第 8 章所刻画的效值信息不对称在跨城维度上被制度性固化。数字平台的资源配置作用同时通过价格机制与数据机制发挥（刘诚和夏杰长，2023），而属地绑定恰恰同时切断了这两个机制的跨域传导。

第三重是产能的重复建设。词元生产具有显著的规模经济，第 8 章测算的最小有效规模对应日产 1.2 亿标准词元、该处的长期平均成本为 0.61 元每百万标准词元。若每座城市都追求本地产能自足，多数城市的产能规模将落在最小有效规模之下，单位成本系统性偏高。更关键的是，第 9 章证明匹配损失只能通过扩

大任务与模型的可匹配集合来消除，而可匹配集合的边界恰恰被行政区划切断——城市各自为战不仅推高了成本，还直接抵消了统一调度所能带来的效率改进。算力共享与算力市场培育的研究亦表明，需求侧的跨域可调度性是算力资源配置效率的关键约束（王勇等，2025）。

10.6.2 三层协同架构与制度工具

化解分割风险的思路不是取消城市层级的组织，而是把职能按其外部性半径分配到相应层级：外部性半径最大的计量标准与凭证互认归国家层，半径中等的产能调度与应急互济归区域层，半径最小的场景对接与需求组织留在城市层。这一分层原则与全国一体化算力网「联网调度、普惠易用、绿色安全」的定位相衔接（国家发展改革委等，2023），也与「1+M+N」国家算力互联互通节点体系「统一标识、统一标准、统一规则」的运行机制要求相一致。在此之上还需要第四层：面向跨境的凭证互认层，它决定词元服务出海时能否被境外采购方与监管方接受。三层协同架构与跨境层的职能分工见表 10.3。

表 10.3 词元运营的分层协同架构与制度工具

层级	核心职能	关键制度工具	可核验指标	主要失效风险
国家层	统一计量口径与凭证互认规则	标准词元折算的国家标准； 全国一体化算力网调度规则； 价格与效值监测发布	折算系数的跨主体一致性； 凭证互认覆盖率	标准长期停留在团体标准层级，效力不足
区域层	产能跨域调度与补贴规则协调	区域调度平台与产能互济； 跨城补贴互认与重复补贴排除	跨域调度成交量； 区域内平均有效效值利用率	省级平台与国家平台重复统计， 算力规模不可加总
城市层	场景组织与需求聚合	技改补贴与词元券； 场景清单与行业语料治理	接入企业数与复购率； 单位补贴带动的标准词元用量	属地绑定扭曲采购； 以物理词元规模考核运营绩效
跨境层	出海凭证与合规互认	绿色词元溯源凭证； 数据出境安全评估； 跨境结算与计量互认	凭证的境外受认可比例； 绿色词元占比	国内凭证不被境外采购方接受， 形成事实性壁垒

注：层级划分依据职能的外部性半径；国家层与区域层的工具名称对应《关于深入实施「东数西算」工程加快构建全国一体化算力网的实施意见》（发改数据〔2023〕1779号）与《关于组织开展国家算力互联互通节点建设工作的通知》（工信厅信管函〔2026〕35号）；全国一体化算力网、省级一体化算力监测调度平台与城市级平台属三个层级、三套接入范围，各平台上报的算力规模存在重复计算，不可加总。

表 10.3 的四个层级中，最紧迫也最薄弱的是国家层的计量标准。10.4.2 节已经指出，词元领域目前只有团体标准与机构评估规范，尚无以词元计量或计费

为标题的国家标准计划公开。这一空白使得跨城互认缺乏权威依据，也使得区域调度缺乏共同的结算单位。可资借鉴的是能源与碳核算领域的经验：《综合能耗计算通则》（GB/T 2589—2020）以标准煤当量统一了不同能源品种的可加口径（国家市场监督管理总局和国家标准化管理委员会，2020），《温室气体产品碳足迹 量化要求和指南》（GB/T 24067—2024）则以二氧化碳当量统一了不同温室气体的可加口径（国家市场监督管理总局和国家标准化管理委员会，2024）。两者的共同经验是：当量折算的国家标准一旦确立，统计、定价、补贴与国际互认便获得共同的技术底座。标准词元折算体系所需要的，正是同一性质的制度化。

跨境层的紧迫性同样不容低估。四座城市中有三座把出海服务列为核心职能：苏州同日成立词元出海服务联盟，广东把跨境流通与词元出海列入五大服务能力并设立跨境交易专区，温州以绿色词元认证为出海企业提供可信、可计量、可追溯的服务凭证。出海需求推动的实际上是一套「谁认可谁」的制度竞争：若中国的词元计量与绿色凭证不被境外采购方接受，则词元出海将退化为算力出海或模型出海，无法把计量规则的话语权一并带出。绿色金融统计标准的国际比较经验表明，标准的国际互认往往先于资金与产品的跨境流动，且互认程度直接决定了市场的可及性（陈丹丹等，2025）；跨境碳规制的实践也显示，缺少互认的核算体系会迅速转化为事实性的贸易壁垒（「European Parliament 和 Council，2023」）。这构成第 11 章绿色词元与可信溯源体系的现实起点。

10.6.3 从城市运营到统一大市场：三条政策序列

综合本章的分析，可以给出一个具有先后次序的政策序列，其排序依据是 10.5.5 节的权重与 10.5.3 节的阈值结构。第一序列是把统一计量制度化：在国家层面推动标准词元折算方法的标准立项，明确折算系数的确定程序、基准任务集的维护机制与第三方核验规则；在此之前，各地运营中心的计量规则应当以可映射、可对照的方式设计，避免形成互不兼容的既成事实。第二序列是把补贴规则规范化：补贴核定以标准词元当量为分母，退坡触发以企业深度采纳比例达到 0.545 这一系统自维持门槛为条件，退坡方式采取连续下调，规则事先公布并保持稳定；同时明确禁止以词元本地生产或本地结算作为补贴的隐性条件，从源头切断属地绑定。第三序列是把调度能力区域化：以国家算力互联互通节点体系为骨架，推动城市级运营中心的调度接口与区域平台对接，把第 9 章证明的匹配效率改进从城市内部扩展到区域范围。

三条序列之间存在明确的依赖关系，不可颠倒。没有统一计量，补贴核定就没有可靠分母，跨域调度也没有共同结算单位；没有补贴规则的规范化，属地绑定会把刚刚建立的计量互认重新割裂；没有区域调度，城市内部的效率改进将止步于本地可匹配集合的边界。这一依赖结构也解释了为什么本章把机制设计的重心放在计量而非补贴上：补贴是有期限的政策工具，计量是无期限的制度基础设施；前者决定这一轮产业培育的速度，后者决定词元经济能否成为一个真正统一、可比、可流通的市场。

10.7 本章小结

本章把第 9 章求得的效率改进上界从技术可行性推进为组织可行性，系统回答了城市词元运营中心「由谁办、凭什么办、怎么办、办到什么时候」四个问题，主要结论可归纳为六点。

第一，运营中心的兴起是算力类政策三段转向的落点。政策的计量对象由标准机架与浮点算力转向算力采购额，再转向词元本身；其经济学理由有三：在有效效值利用率仅为 0.38 的产能状态下，投资补贴的边际效果为负；使用补贴的扩量效果由需求弹性决定，全样本弹性 -1.34 掩盖了制造与政务之间数倍的差异；而使用补贴的可行性前提不是词元「可计数」，而是词元「可折算」，这使统一计量从附属功能升格为制度前提。承载单元之所以是城市，在于城市是同时握有要素配置权、需求组织渠道与完备政策工具的最小治理单元。

第二，五类运营主体的分化不是偶然的地方选择，而是资产禀赋与职能要求相互匹配的结果。运营商强于网络与云资源、城投强于土地电力机房、数据集团与交易所强于数据与场景、政策制定者独强于制度工具，没有任何一类主体在四类资产上同时具备强禀赋，因而现实形态必然是「多方共建、分职能授权」。五类主体的激励扭曲风险各不相同，却共同指向同一个解药——可核验的标准词元计量。

第三，城投转型的资产逻辑可以被严格刻画。从物理设施到标准词元产能的映射表明，单位标准词元的能耗强度与机架规模无关，扩大规模不改善能耗强度；转型的盈亏平衡利用率在当前价格与成本结构下加权平均为 0.105，相对当前 0.38 的有效效值利用率尚有 3.6 倍安全边际，但市场价再降一半即压缩至 1.2 倍。转型成败因此取决于两个可控变量能否跑赢价格下行：利用率能否经统一调度提升，产品结构能否经效值提升实现收入结构的转换。城投若以建设逻辑替代运营逻辑，必然在价格下行中被挤出。

第四，「五个统一」的经济实质是对五类交易费用的针对性消解。双边缔约结构下城市范围内的缔约关系总数为企业数与供给方数之积，平台中介结构下降为二者之和，节约率随可选模型条目数与接入企业数同时递增，但存在一个规模门槛，低于该门槛时自建平台是净损失。五项统一具有强互补性，统一计量是其余四项的共同前置，因而机制必须整包推进。就制度供给的现状而言，词元领域目前只有团体标准与机构评估规范，尚无相应的国家标准；既有的四套评价体系分属不同机构、维度与用途，产出的是多维评价而非当量折算，这正是本书第 5 章折算体系的理论空间所在。

第五，三方演化博弈揭示了机制自我维持的阈值结构。系统存在两个可能的稳定均衡：「平台热、企业冷」的补贴锁定均衡与融合稳态。分野取决于企业红利是否越过临界值 1.55，而基准红利距该临界值仅差 3.2%，「差之毫厘」导致完全相反的均衡。更具政策含义的是三重阈值的排序：政府自身收益转负的退出点 0.289 显著早于平台自维持点 0.545，二者之间存在「退出过早的风险窗口」。据此，补贴退坡的触发条件应锚定系统自维持门槛而非政府私人退出点，方式应为连续退坡且规则事先公布。交易费用节约把自维持所需的企业采纳规模降低了 37%，这是「五个统一」对制度可持续性最直接的量化贡献；降低企业采纳成本则可把补贴持续期压缩 44%。层次分析法的排序与上述结论相互印证：统一计量 0.271 与统一结算 0.223 合计超过五项总权重的一半，而统一政策抵扣权重最低（0.144）——专家判断表达的是同一个道理：运营中心的长期价值在于降低交易费用而非分发补贴。

第六，城市层级的组织内生地带来计量口径分割、补贴属地绑定与产能重复建设三重风险，化解之道是按外部性半径分层配置职能：计量标准与凭证互认归国家层，产能调度与补贴协调归区域层，场景组织与需求聚合留在城市层，并单设跨境凭证互认层以支撑词元出海。当前最薄弱的一环是国家层的计量标准，标准煤当量与二氧化碳当量的制度化经验表明，当量折算标准一旦确立，统计、定价、补贴与国际互认便获得共同的技术底座。由此形成三条有先后次序的政策序列：先把统一计量制度化，再把补贴规则规范化，最后把调度能力区域化，三者不可颠倒。

本章的分析同时为后续章节留下两个接口。其一，运营中心把绿色词元凭证列为核心服务，而绿色属性的界定、核算与溢价机制尚未展开，第 11 章将以每千标准词元的碳强度为计量单位（2026 年用量加权平均为 2.263 gCO₂e/千标准词元，绿色词元阈值为 1.0 gCO₂e/千标准词元）系统处理这一问题。其二，本章的组织与机制分析建立在城市样本的定性观察之上，其模式差异、能力评分

与企业采纳障碍的系统比较，将在第 13 章的多案例研究中以扎根方法完成三角验证。

第 11 章 绿色词元：能耗、碳足迹与可信溯源

第 9 章把算力到词元的转化过程分解为空转、批次、匹配与效值四项损失，第 10 章把统一计量与统一结算落到城市词元运营中心的机制设计上。两章共同指向一个尚未被处理的约束：词元的生产不只消耗算力与资本，还消耗电力，并因电力而排放二氧化碳。在词元经济的早期，这一约束可以被忽略——调用量小、能耗总量低、单位成本中的电费占比不显著；但当日均调用量在两年内由 2024 年初的 1000 亿枚增至 2026 年 3 月的 140 万亿枚、增长约 1400 倍（国家数据局口径，其余时点为校准复算插值）之后，电力与碳排放就从成本表的一个细项上升为产能的硬约束。国际能源署的评估显示，2024 年全球数据中心用电约 415 太瓦时，约占全球用电的 1.5%，基准情景下到 2030 年将升至约 945 太瓦时、占比略低于 3%，其中美国与中国合计贡献全球增量的近八成（IEA，2025）；对数据中心能耗的长期核算也表明，人工智能负载正在改变这一部门的能耗轨迹（Masanet 等，2020；Shehabi 等，2024）。词元经济因此同时面对三重约束：算力约束、电力约束与碳约束。前者是第 9 章的主题，后两者是本章的主题。

把碳约束写进词元经济的分析框架，需要跨过一道计量门槛。碳强度是一个比值，其分子是排放量、分母是产出量；分子侧的核算已有成熟的方法学传统，从产品生命周期评价到温室气体核算体系（「WRI 和 WBCSD，2011」；「ISO，2018」），国内亦有与之衔接的国家标准与制度安排（国家市场监督管理总局和国家标准化管理委员会，2024；生态环境部等，2024）；真正的难点在分母侧——若产出以物理词元计，则分母本身不可加。第 3 章已经证明物理词元在算力、质量与场景三个维度上高度异质，第 5 章据此构建了以标准词元为分母的效值折算体系。碳核算继承了同一个逻辑：只有当分母是可比、可加的标准词元时，碳强度才是一个有经济含义的比率，绿色词元的认证阈值才可能在不同模型、不同厂商、不同城市之间保持一致。这构成本章与第 5 章的直接接续关系。

但接续不等于替代。本章将论证一个容易被忽略的命题：效值折算解决的是价值可比，碳核算解决的是环境可比，两套当量体系必须并行而不能互相代劳。理由在于，单位标准词元的碳强度在六个档位之间并不相等，而且随效值系数超比例上升——效值高的词元不仅价值高，其单位价值所付出的碳代价也更高。若以为把词元折算成标准词元便自动解决了碳的可比性，就会在补贴与考核中系统性地奖励高碳档位。这一点将在 11.2 节以碳—效值弹性的估计给出量化证据。

本章的安排如下：11.1 节辨析现有能耗数据的三重口径落差，给出从设施级电量到服务级功能单位的能耗核算恒等式，并说明为什么词元级能耗数值只能是换算与校准复算的结果；11.2 节把电量折算为碳，界定碳强度的双重口径，估计碳一效值弹性，并给出绿色词元阈值的设定原则与达标条件；11.3 节分析能效、配置与电力三条减排路径，梳理算电协同与绿电直供的政策工具箱，并作情景测算与总量口径校验；11.4 节刻画绿色词元的溢价机制、隐含碳价与出海碳合规需求；11.5 节讨论可信溯源体系的链路结构、凭证的经济学与制度建设次序；11.6 节为本章小结。

11.1 词元生产的能耗核算：从设施级到服务级

能耗核算的第一项工作不是计算，而是划定核算对象。数据中心的电表读数是设施级的，它记录一栋建筑在一段时间内消耗的电量；而词元经济需要的是服务级的强度指标，即生产一千枚标准词元平均消耗多少电、排放多少二氧化碳。从前者到后者要经过功率归集、时间积分、开销分摊、产出折算四道工序，每一道都可能因规则不同而产生成倍的差异。本章的完整核算框架与溯源链路如图 11.1 所示。




图 11.1 词元的能耗—碳足迹核算框架

图 11.1 的上排是五步核算链条：由算力功耗出发，经数据中心电能利用率修正得到用电量，再乘以排放因子得到碳排放量，最后以标准词元产出为分母得到碳强度。链条终点接一个阈值判定：碳强度低于阈值者进入绿色词元并获得随词元签发的碳足迹凭证，高于阈值者进入减排路径，其中提高绿电占比的效果

以虚线反馈回排放因子环节，构成一个可迭代的闭环。图的下半部是与核算链条并行的可信溯源链路：数据传输、模型调用、业务落地三段过程各自留痕，共同汇入由时间戳、内容哈希与主体标识构成的存证层，并与碳足迹凭证一一绑定。这一并行结构提示了本章的一个基本判断——碳足迹凭证不是一份独立签发的证书，而是标准词元计量记录的一个字段；离开计量与溯源，凭证既无法生成，也无法核验。

11.1.1.1 三重口径落差：为什么现有能耗数据不能直接用于词元核算

第一重落差在分母。目前唯一披露了完整方法论的厂商口径来自谷歌 2025 年 8 月发布的推理环境影响测算：其应用侧文本提示的中位能耗为每次 0.24 瓦时，对应 0.03 克二氧化碳当量与 0.26 毫升水，能耗构成为张量处理单元占 58%、宿主机中央处理器与内存占 25%、空闲备机占 10%、数据中心开销占 8%。同一次推理，若只计活跃加速器这一窄口径，则为每次 0.10 瓦时与 0.02 克二氧化碳当量——综合口径与窄口径相差 2.4 倍。该测算同时报告，12 个月内每次中位提示的能耗下降 33 倍、碳足迹下降 44 倍，但这是同一厂商同一产品线的纵向自比，不可跨厂商横向套用。关键在于：这些数值的分母是「一次提示」，不是「一千枚词元」。经系统检索，主流厂商均未发布以词元为分母的官方能耗数据。

第三方与学术测算的分母同样是查询。微软研究院发表于《焦耳》的研究给出前沿规模模型推理的中位能耗为每次查询 0.31 瓦时，四分位距 0.16 至 0.60 瓦时；在推理长度为典型查询 15 倍的测试时扩展情景下，中位能耗升至 3.91 瓦时，为 13 倍；该研究并指出，即便只有一成的日请求属于长推理，也足以使总能耗翻倍以上，同时估计模型、服务栈与硬件三条路径合计存在 8 至 20 倍的可见效率改进空间，而公开流传的估算普遍高估了 4 至 20 倍，原因是采用了非生产环境的假设。另一家独立机构的建模推算给出典型查询约 0.3 瓦时，并指出此前广为流传的每次 3 瓦时高估约 10 倍。需要特别提醒的是，0.24、0.31 与 0.3 三个数字的接近纯属巧合——三者的模型、硬件与核算边界各不相同，不构成相互验证。学术界对生成式人工智能能耗与碳排的系统测量亦表明，不同任务、不同模态之间的能耗差异可达数量级（Luccioni 等，2023；Luccioni 等，2024），训练侧的碳足迹轨迹与推理侧的扩张态势需要分别刻画（Patterson 等，2022；de Vries，2023），而披露的不充分本身已成为一个独立的治理问题（Crawford，2024）；水资源维度的核算同样长期缺位（Li 等，2025）。

第二重落差在边界。设施级核算以数据中心为核算边界，其自然指标是电能利用效率与用电量；服务级核算以一次服务或一枚词元为功能单位，需要把设施开销、空闲备机、宿主机资源乃至跨区域的调度损耗一并分摊到产出上。两者不是精粗之别而是对象之别：设施级指标再精确，也无法回答「这一千枚词元排放了多少」。我国的统计现状加剧了这一落差——电力统计的行业分类中数据中心并未单列，迄今没有任何国家部委发布过数据中心用电量的正式统计。公开流传的占比数字中，刊于党媒的学者测算为 2025 年约占全国电耗的 2.4%，咨询机构口径则有 4.1% 与 5% 等说法，三者来源等级不同、彼此矛盾，差异接近一倍，不可并列引用，更不可取平均。可核实的设施级指标只有电能利用效率：2023 年全国数据中心平均约 1.48（中国信息通信研究院口径，2022 年为 1.54）。

第三重落差在分布。上述权威测算报告的都是中位数而非均值，而推理请求的长度分布具有厚尾特征：少数长推理请求的能耗可达典型请求的十余倍，因而均值显著高于中位数，用中位数乘以调用量估算总量会系统性低估。此外，文本与多模态不可混用（图像与视频生成的能耗显著更高），推理与训练不可混用（以上数值全部为推理口径）。三重落差叠加的结果是：现有公开数据既不能直接用作词元级能耗强度，也不能通过简单换算得到——它们缺的不是精度，而是与词元对应的功能单位。这正是本章要补的第一块地基。

11.1.2 能耗核算的基本恒等式

设档位 m 的加速器单设备功率为 W_m （千瓦）、单设备算力为 Φ_m （每秒千万亿次浮点运算），第 9 章定义的转化效率 θ_m 表示单位算力时（每千万亿次浮点运算·小时）产出的标准词元数，有效效值利用率为 u 。在窄口径下，生产一枚标准词元所需的加速器电量由式(11-1)给出。

$$\varepsilon_m^{acc} = \frac{W_m / \Phi_m}{u \theta_m} \quad (11-1)$$

其中， W_m / Φ_m 为功率算力比（千瓦每千万亿次浮点运算），刻画硬件世代的能效水平；分母 $u \theta_m$ 为单位算力时实际产出的有效标准词元数。量纲上，千瓦除以「标准词元每小时」恰为「千瓦时每标准词元」。

式(11-1)虽简单，却含有三条对本章至关重要的性质。性质一，能耗强度与转化效率成反比：第 9 章测算的六档位转化效率由轻量蒸馏级的 42.0 万标准词元每算力时递减至推理增强级的 3.1 万，这一递减在能耗侧直接表现为强度的递增，二者是同一枚硬币的两面。性质二，能耗强度与有效效值利用率成反比：这

意味着调度与匹配这类纯粹的组织性改进会直接降低单位词元能耗，而在设施级核算中这一效应完全不可见——空转的服务器同样耗电，却不出现在任何一枚词元的账上。性质三，能耗强度对电能利用效率的弹性为 1：在电能利用效率等于 1.4 附近，每下降 0.1，单位标准词元电耗下降约 7.1%。这三条性质说明，词元级能耗核算并不是设施级核算的简单细分，它把技术效率、组织效率与设施效率放进了同一个表达式。

窄口径只计加速器，而实际发生的电量还包括宿主机的中央处理器与内存、为峰值与故障切换预留的空闲备机，以及制冷与配电等设施开销。记宿主机开销率为 ζ_h 、空闲备机率为 ζ_i ，则综合口径的能耗强度由式(11-2)给出。

$$\varepsilon_m = \varepsilon_m^{acc} (1 + \zeta_h + \zeta_i) \cdot PUE, \zeta_h \geq 0, \zeta_i \geq 0, PUE \geq 1 \quad (11-2)$$

其中， PUE 为数据中心电能利用效率， ζ_h 与 ζ_i 分别为宿主机与空闲备机相对于加速器电量的比率。

式(11-2)把分摊规则显性化，也把分摊规则的任意性暴露出来。以前引厂商披露的能耗构成为例：若按张量处理单元占 58% 反推，则综合口径应为窄口径的约 1.72 倍；而该厂商同时报告的综合口径与窄口径实测值之比为 2.4 倍。两组数字并不一致，差额来自窄口径对「活跃」二字的界定——它把空闲备机中的加速器排除在外。这一细节说明， ζ_i 究竟计入分子还是排除在外，不是测量精度问题而是规则选择问题，其对结果的影响可达四成。因此，本书主张：词元级碳核算的第一项制度供给不是测量设备，而是一套公开的、统一的分摊规则；在规则统一之前，任何跨厂商的能耗强度比较都缺乏可比性。

现有公开数据以查询为分母，本书的核算以标准词元为分母，二者之间需要一座口径桥。记一次查询平均消耗 n_q 枚物理词元、平均效值系数为 η_q ，单次查询能耗为 e^q ，则式(11-3)给出两种口径的换算关系。

$$e^q = \frac{\varepsilon n_q \eta_q}{10^6} \Leftrightarrow \varepsilon = \frac{10^6 e^q}{n_q \eta_q} \quad (11-3)$$

其中， ε 的量纲为千瓦时每百万标准词元， e^q 的量纲为千瓦时每次查询； 10^6 为分母的单位换算。

式(11-3)的意义在于警示而非换算。把综合口径的每次 0.24 瓦时代入，并假定一次查询平均消耗 1000 枚物理词元、效值系数为 1，可得能耗强度约为 0.24 千瓦时每百万标准词元；而本书校准复算的中型通用级为 2.6 千瓦时每百万标准词元，二者相差一个量级。差异并不意味着某一方有误，而是来自三处不可观测的假定：一次查询的词元数未知，被测服务的档位与任务混合未知，核算边

界是否包含空闲备机与设施开销未知。既然这三处假定无一可从公开信息中恢复，本书的立场是明确的——凡涉及词元级能耗与碳排的数值，一律标注为换算与校准复算结果，不表述为实测值；其可靠性来自内部一致性与对锚点的校准，而不是来自对某一次外部测量的复制。

11.1.1.3 分档位能耗强度：数值、离散度与技术来源

按上述框架校准复算，六个档位的能耗强度依次为：轻量蒸馏级 0.9、中型通用级 2.6、开源旗舰级 5.4、旗舰闭源级 9.8、推理增强级 17.2、多模态级 7.1 千瓦时每百万标准词元，极差 19.1 倍。若换用物理词元为分母，即以每百万物理词元的电量计，六档位的极差扩大到 215.3 倍。两个数字的对照给出本章的第一项结构性发现：效值折算把能耗强度的离散度压缩了一个量级，却远未把它消除。压缩的部分来自「高档位词元本就承载更多信息」这一事实，剩余的部分则是真实的能效差异。这意味着标准词元为碳核算提供了合格的分母，但不能代替碳核算——同样一枚标准词元，由不同档位生产，其碳足迹仍相差近二十倍。

能耗强度的档位差异有四个技术来源。其一是参数规模与单词元激活计算量：模型能力与计算量之间存在稳定的标度关系，高能力档位以更大的单词元浮点运算量换取更高的推理质量（Kaplan 等，2020；Hoffmann 等，2022）。其二是上下文长度与键值缓存：注意力机制的计算与访存随上下文长度增长，显存管理、注意力核实现与推理并行策略共同决定了实际的单词元能耗（Dao 等，2022；Pope 等，2023；Kwon 等，2023）；缓存命中与否可以使同一段上下文的预填充能耗相差数倍。其三是推理链长度：推理增强级以显著更长的生成过程换取更高的任务达成度，这正是前引研究所刻画的测试时扩展效应——长推理请求的中位能耗可达典型请求的十余倍。其四是模态：多模态级的能耗强度高于同等文本能力的档位，且其成本结构由视觉与音频编解码主导。在服务栈层面，连续批处理、分块预填充与预填充—解码分离等技术通过提高批次组织效率降低单词元能耗（Yu 等，2022；Agrawal 等，2024；Zhong 等，2024）；在集群层面，异构负载的时变性与调度策略决定了空闲备机的规模（Weng 等，2022），而后者正是式(11-2)中 ζ_i 的经济内容。

还有一个常被忽略但对碳核算有实质影响的来源：分词的语言不对称。同一段语义在不同语言下被切分成的词元数差异显著，非拉丁语系文本通常需要更多词元（Ahia 等，2023）。这一技术性不对称经由式(11-3)的分母直接传导到碳强度：同一项业务、同样的语义产出，仅因语言不同就承担不同的碳足迹。在国内场景下，这意味着以英文基准测得的能耗强度不能直接套用于中文服务；在出

海场景下，它意味着碳足迹凭证必须记录语言与任务类型，否则跨境比对将失去意义。至此，能耗侧的核算框架已经完备，下一步是把电量折算为碳。

11.2 碳足迹折算与绿色词元的界定阈值

11.2.1 从电量到碳：量纲恒等与双重口径

推理服务的排放绝大部分来自外购电力，属于温室气体核算体系中的范围二间接排放（「WRI 和 WBCSD，2011」），其核算规则由电力排放因子决定。记排放因子为 f （千克二氧化碳每千瓦时），则档位 m 的碳强度由式(11-4)给出。

$$\iota_m = \varepsilon_m f, \left[\frac{kWh}{10^6 \tilde{T}} \right] \times \left[\frac{kg}{kWh} \right] = \left[\frac{kg}{10^6 \tilde{T}} \right] = \left[\frac{g}{10^3 \tilde{T}} \right] \quad (11-4)$$

其中， ι_m 为碳强度，全书统一以克二氧化碳当量每千标准词元表示； ε_m 为式(11-2)的综合口径能耗强度。

式(11-4)右半部的量纲恒等式值得单独强调。以千瓦时每百万标准词元为能耗单位、以千克二氧化碳每千瓦时为排放因子单位，二者相乘所得恰好就是克二氧化碳当量每千标准词元，换算系数为 1。这一巧合并非无关紧要：它使得能耗强度与碳强度可以并排列于同一张表、同一张图而无须换算，也使得从能耗账到碳账的转换只是一次乘法，不引入任何舍入与口径损失。当量单位的选择本身就是计量制度的一部分——正如综合能耗计算通则以标准煤统一了各类能源的可加性（国家市场监督管理总局和国家标准化管理委员会，2020），本书以克二氧化碳当量每千标准词元统一了词元生产的环境可加性。

排放因子的取值涉及一处极易混淆的口径分野。温室气体核算体系的范围二指南要求双重报告：基于地理位置法，按所接入电网的区域平均排放因子核算；基于市场法，按可追溯的电力采购合同、绿证或绿电交易结果核算。式(11-5)把市场法口径写成绿电占比的函数。

$$f^{mkt}(g) = (1-g)f^{grid} + gf^{green}, \iota(g) = \varepsilon f^{mkt}(g), g \in [0, 1] \quad (11-5)$$

其中， g 为绿电占比， f^{grid} 与 f^{green} 分别为电网平均排放因子与绿电排放因子，本书分别取 0.53 与 0.04 千克二氧化碳每千瓦时。

代入本书校准复算的用量结构，三个口径下的平均碳强度分别为：地理位置法口径 2.263、市场法口径（按 2026 年绿电占比 44% 计）1.342、全绿电供电的理论下界 0.171 克二氧化碳当量每千标准词元。三者的差距揭示了一个制度性事实：同一批词元，按不同的合规口径可以报出相差十余倍的碳足迹。因此，绿

色词元的认证必须先声明口径，否则认证结论没有意义。本书在后文的情景分析中一律采用地理位置法口径，理由是只有物理上真实发生的减排才会改变这一口径的数值：按绿电直连方式取得的绿电不接入公共电网、供给电量可清晰物理溯源，因而计入地理位置法；而单纯购买绿证只改变市场法口径，不改变任何一度电的物理来源。这一区分在国际规则中同样处于变动之中——温室气体核算体系的企业标准与范围二指南正在修订，现行允许绿证与用电量按年度匹配的规则可能被更细颗粒度的时间与地理匹配要求取代，据此作出的「全绿电」声明存在时效风险。国内的方法学基准是与国际标准衔接但采取修改采用方式的产品碳足迹国家标准（「ISO，2018」；国家市场监督管理总局和国家标准化管理委员会，2024），其结果不默认互认；相关的核算体系与统计口径建设仍在推进之中（陈红敏，2011；童庆蒙等，2018；陈丹丹等，2025）。

11.2.2 用量加权平均、结构效应与碳—效值弹性

单一档位的碳强度不足以刻画一个平台、一座城市或一国的词元生产。设档位 m 的用量份额为 s_m ，则总体碳强度为分档位碳强度的用量加权平均，其变动可分解为强度效应与结构效应两项，见式(11-6)。

$$\dot{i} = \sum_m s_m \dot{i}_m, \Delta \dot{i} = \sum_m \dot{s}_m \Delta i_m + \sum_m \dot{i}_m \Delta s_m \tag{11-6}$$

其中，右端第一项为强度效应，即在用量结构不变时各档位自身能效与用电清洁度改进的贡献；第二项为结构效应，即在各档位强度不变时用量向高档位或低档位迁移的贡献； $\dot{s}_m$ 与 $\dot{i}_m$ 为期初期末的均值权重。

式(11-6)的政策含义是直接的：碳强度的下降既可以来自技术，也可以来自结构，而两者的可持续性完全不同。技术驱动的下降是净改进；结构驱动的下降若来自用户被迫降级使用低档位模型，则以牺牲推理质量为代价，本质上是把碳排放问题转化为效值问题。这也是必须以标准词元而非物理词元为分母的又一理由：以物理词元为分母时，用户从旗舰闭源级降级到轻量蒸馏级会同时降低碳强度与产出质量，而碳强度的下降会被记为环境绩效；以标准词元为分母时，质量损失已经通过效值系数进入分母，从而使这种「降级式减排」在指标上无法伪装成技术进步。分档位的能耗强度、碳强度、用量份额、碳排贡献份额与达标条件汇总，见表 11.1。

表 11.1 六档位模型的能耗强度、碳强度与绿色词元达标条件

档位	能耗强度 (kWh/ 百万标准	碳强度： 地理位置 法	碳强度： 全绿电口 径	2026 年 用量份额	碳排放贡 献份额	达标所需 绿电占比
----	-----------------------	-------------------	-------------------	----------------	-------------	--------------

	词元)	(gCO ₂ e /千标准 词元)				
轻量蒸馏级	0.9	0.477	0.036	28.0%	5.9%	已达标
中型通用级	2.6	1.378	0.104	34.0%	20.7%	29.7%
开源旗舰级	5.4	2.862	0.216	20.0%	25.3%	70.4%
旗舰闭源级	9.8	5.194	0.392	10.0%	23.0%	87.3%
推理增强级	17.2	9.116	0.688	5.0%	20.1%	96.3%
多模态级	7.1	3.763	0.284	3.0%	5.0%	79.4%
用量加权合计	4.269	2.263	0.171	100.0%	100.0%	60.4%

注：能耗强度与碳强度均为按本章框架的校准复算值，非实测值；碳强度按式(11-4)由能耗强度乘电力排放因子得到，地理位置法取电网平均排放因子、全绿电口径取绿电排放因子。碳排放贡献份额=该档位用量份额×该档位碳强度/用量加权平均碳强度。达标所需绿电占比按式(11-9)在能效不变($\lambda=1$)下求得，指使该档位碳强度降至阈值1.0 gCO₂e/千标准词元所需的绿电占比；轻量蒸馏级的碳强度已低于阈值，故无需绿电即达标。数据来源：作者校准复算。

表 11.1 呈现出一个高度倾斜的结构。用量份额最大的两个档位是轻量蒸馏级与中型通用级，合计 62%，但其碳排放贡献合计仅 26.6%；相反，旗舰闭源级与推理增强级合计用量份额仅 15%，碳排放贡献却达 43.1%。轻量蒸馏级以 28%的用量只贡献 5.9%的排放，而推理增强级以 5%的用量贡献了 20.1%。这种帕累托式的集中意味着，碳治理的着力点不在于压缩总调用量，而在于高档位词元的匹配合理性——第 9 章界定的匹配损失（用高档位模型处理本可由低档位完成的任务）在碳的维度上被再次放大。反过来说，这也解释了为什么「统一调度」既是效率政策也是环境政策：它在不减少任何一枚有效词元的前提下削减高档位的冗余调用。

表 11.1 还提示了一个更深的结构：碳强度随效值系数上升的速度快于比例。把六档位的碳强度与第 5 章的效值系数取对数作拟合，即式(11-7)。

$$\ln t_m = a + b \ln \eta_m + \epsilon_m \quad (11-7)$$

其中， η_m 为第 5 章式(5-5)合成的效值系数， b 为碳—效值弹性，即效值系数提高 1%所引致的单位标准词元碳强度变动百分比。

拟合结果为 $b = 1.181$ ，判定系数 0.989，弹性显著大于 1。这一结果的经济含义十分明确：效值提高一倍，单位标准词元的碳强度提高约 2.27 倍，即高效值词元不仅绝对碳排放更高，其单位价值所付出的碳代价也更高。这就是本章开篇提出的命题的量化形式——效值折算与碳核算是两套当量体系，不能互相代劳。若政策仅按效值给予补贴或抵扣，等价于对碳强度实施了一个超比例的隐性

补贴；若要在鼓励高质量供给与约束碳排放之间取得平衡，补贴基准必须同时含有效值与碳强度两个变量。这一点在第 10 章「统一政策抵扣」的机制设计上有直接的操作含义：抵扣系数应当写成效值系数与碳强度的复合函数，而非效值系数的单调函数。分档位的能耗强度与碳强度对照，如图 11.2 所示。




图 11.2 分档位能耗强度与碳强度

注：左轴能耗强度的分母为百万标准词元，右轴碳强度的分母为千标准词元，两者按式(11-4)的量纲恒等关系直接对读，换算系数为 1；全绿电供电口径为理论下界，不代表任何在运服务的实际取值。公开的推理能耗测算其分母普遍为「一次查询」而非「一千枚词元」，故本图数值系换算与校准复算结果，不表示实测值。数据来源：作者校准复算。

图 11.2 中的柱体与实线折线几乎平行，这正是式(11-4)的直接可视化——在给定排放因子下，碳强度是能耗强度的线性变换，两条曲线的形状完全由能耗结构决定。真正值得注意的是实线与虚线之间的巨大间距：全绿电供电口径把碳强度压缩到电网口径的 7.5%。这个比例给出了电力路径的减排上限——无论能效如何改进，只要电源结构不变，碳强度就被锁定在能耗强度乘以电网因子这条线上；反之，只要电源结构足够清洁，即使是推理增强级这样的高能耗档位，其碳强度也可以降到 0.688 克二氧化碳当量每千标准词元，低于阈值。换言之，能效路径决定了「用多少电」，电力路径决定了「这些电有多脏」，两者在减排上是乘性关系而非替代关系。

11.2.3 绿色词元阈值的设定原则与达标条件

绿色词元的界定需要一个阈值。阈值的设定不是技术问题而是制度问题，至少有三种可选原则。分位数法以现状分布的某一分位点为界，其优点是天然保证一定比例的供给可以达标，缺点是随分布漂移而漂移，不构成稳定的激励。技术可达法以当前最优实践为界，其优点是指向明确，缺点是把标准绑定在单一技术

路线上。碳预算法则从总量约束倒推强度约束：给定期间内词元生产可占用的碳预算 B 与预期的标准词元总产出，阈值即为二者之比，见式(11-8)。

$$t^* = \frac{B}{\tilde{T}^{tot}}, \tilde{T}^g = \sum_m \tilde{T}_m 1\{t_m \leq t^*\} \quad (11-8)$$

其中， $\tilde{T}^g$ 为绿色词元流量， $1\{\cdot\}$ 为示性函数； B 为词元生产在核算期内可占用的碳预算， $\tilde{T}^{tot}$ 为同期标准词元总产出。

碳预算法的理论优势在于它把阈值与总量目标显式地联系起来：当预期产出翻倍而碳预算不变时，阈值自动减半。这与我国「双碳」目标下由能耗双控向碳排放双控转型的政策方向是一致的（何建坤，2021；姜春海等，2024），也与碳市场以总量约束驱动强度改进的机制设计逻辑同构（张希良等，2021；张希良等，2022；赵思琦等，2023）。本书按碳预算法的思路，并参照现状分布，把绿色词元阈值取为 $t^* = 1.0$ 克二氧化碳当量每千标准词元，约为 2026 年用量加权平均碳强度的 44%。这是一个有意设定得偏紧的阈值：对照表 11.1，在现有能效与电网平均排放因子下，六个档位中只有轻量蒸馏级已经达标，其余五档均需补充绿电或改进能效。阈值偏紧的理由是，若阈值定得使多数供给自动达标，则「绿色词元」这一标签不再携带信息，其溢价也就无从产生——这一点在 11.4 节的溢价分析中会再次出现。

给定阈值，达标条件可以写成对能效与绿电占比的一条等碳强度曲线。记能效改进因子为 λ （ $\lambda = 1$ 表示能效不变， λ 越小表示能效越好），把式(11-5)代入阈值条件并求解绿电占比，得式(11-9)。

$$g^*(\lambda) = \frac{\lambda \varepsilon f^{grid} - t^*}{\lambda \varepsilon (f^{grid} - f^{green})}, \lambda_{min} = \frac{t^*}{\varepsilon f^{grid}} \quad (11-9)$$

其中， $g^*(\lambda)$ 为在能效改进因子 λ 下达到阈值所需的最低绿电占比； λ_{min} 为不依赖任何绿电、仅靠能效改进即可达标所需的能效因子。

式(11-9)刻画的是一条向下倾斜的等碳强度曲线：能效改进越多，达标所需的绿电占比越低，两条路径可以相互替代但不能相互取消。代入用量加权平均能耗强度可得，在能效不变时整体达标需要绿电占比达到 60.4%，显著高于 2026 年 44% 的现状水平；而若完全不依赖绿电，则需要 $\lambda_{min} = 0.442$ ，即能耗强度须整体下降 55.8%。分档位的结果已列于表 11.1 的末列：中型通用级只需 29.7% 的绿电占比即可达标，开源旗舰级需 70.4%，旗舰闭源级需 87.3%，推理增强级则高达 96.3%——对推理增强级而言，几乎只有全绿电供电才能进入绿色词元的范畴。这一结果的政策含义是：绿色词元认证在不同档位之间天然是非中性

的，若不加区分地推行，将系统性地把认证资格分配给低档位供给，从而与鼓励高质量供给的目标相冲突。化解之道有二：其一是允许以效值加权的方式设定分档阈值；其二是把配置效率纳入达标条件，这正是 11.3 节的主题。

最后需要辨明绿色词元阈值与第 5 章效值折算在制度形态上的差异。效值折算是连续的当量化：它把异质词元映射到同一条实数轴上，使加总与计价成为可能，其精神与标准煤折算（国家市场监督管理总局和国家标准化管理委员会，2020）一脉相承。绿色词元阈值则是离散的分类认证：它在实数轴上划一条线，把供给分为达标与不达标两类，其精神更接近能效等级与产品认证。两者的功能不同——当量化解决可加性，分类认证解决可识别性；两者的成本也不同——当量化需要参数标定，分类认证需要核验与执法。词元经济同时需要这两套制度，而且需要它们共用同一个分母。标准化本身即是一种生产性投入，其对全要素生产率的提升效应已在物流等领域得到经验验证（何凡等，2025），词元计量与碳核算标准的建设应作同类理解。

11.3 算电协同与绿电直供的减排效应

11.3.1 三条减排路径及其相互作用

由式(11-1)、式(11-2)与式(11-5)可以直接读出词元碳强度的三条减排路径。路径一是能效路径，作用于 W_m/Φ_m 、 θ_m 、 ζ_h 、 ζ_i 与电能利用效率，包括硬件世代更替、推理服务栈优化、模型侧的蒸馏与稀疏化以及数据中心制冷与配电改造。前引研究估计模型、服务栈与硬件三条子路径合计存在 8 至 20 倍的可见改进空间，这是三条路径中长期潜力最大的一条，但也最依赖技术突破与设备更新周期。路径二是配置路径，作用于式(11-1)分母中的有效效值利用率 u ，包括任务—模型最优匹配、跨域调度与批次组织。路径三是电力路径，作用于式(11-5)中的排放因子，包括绿电直连、绿电交易、绿证购买与选址向清洁能源富集地区迁移。

配置路径值得单独强调，因为它在设施级核算中完全不可见，却在服务级核算中直接进入分母。第 9 章的测算结果是：有效效值利用率现状为 38%，统一调度后可升至 54%，理论上界为 61%。按式(11-1)，能耗强度与利用率成反比，因此统一调度等价于把能耗强度降低 29.6%，达到理论上界则降低 37.7%。把这一改进代回式(11-9)，得到本章最重要的一个结论：在统一调度实现后，整体达标所需的绿电占比由 60.4%降至 40.2%，已经低于 2026 年 44% 的绿电占比现状；若达到理论上界，则进一步降至 31.4%。也就是说，在不新增

一度绿电、不等待任何硬件世代更替的条件下，仅凭调度与匹配的组织性改进，词元生产的平均碳强度就可以跨过绿色词元阈值。

这一结论把第 9 章的配置效率与本章的碳约束连成了一条完整链路，也重新定义了「绿色词元」的政策抓手。在既有讨论中，绿色词元几乎总是被等同于绿电供应问题，于是政策工具集中在电源侧；而上述测算表明，需求侧的调度组织具有同等甚至更高的边际减排效率，且其实施主体正是第 10 章讨论的城市词元运营中心。三条路径的相互作用是乘性的：能效改进与配置改进共同压缩 ε ，电力路径压缩 f ， $\iota = \varepsilon f$ 的下降幅度是三者改进比例的乘积而非之和。乘性结构有两个推论：其一，任何单一路径的边际效果都会被其他路径的进展放大，因而三条路径应当同步推进而非依次推进；其二，任何单一路径都无法独立完成达标——即便绿电占比达到 100%，若能耗强度不变，碳强度也只能降至 0.171，这确实低于阈值，但代价是把全部减排责任压在电力系统一侧，在电力供给约束下并不可行。

11.3.2 政策工具箱与传导机制

我国在算电协同方向上已经形成一套相对完整的政策工具箱，但这些工具作用于式(11-2)与式(11-5)的不同环节，其口径含义与效力层级差异极大，混用会导致对减排效果的严重误判。主要工具及其传导机制，见表 11.2。

表 11.2 算电协同与绿电供给的政策工具及其对词元碳强度的传导

政策工具（文件与文号）	核心口径	作用环节	对碳强度的传导	适用边界与口径提示
绿电直连（发改能源〔2025〕650号）	风电、太阳能发电、生物质发电等新能源不直接接入公共电网，通过直连线路向单一电力用户供给绿电，供电电量可清晰物理溯源；分并网型与离网型两类	式(11-5)排放因子 f	直接降低地理位置法口径的排放因子，是唯一能改变物理排放的电力工具	仅适用于单一电力用户；并网型项目电源接入用户侧，电源、用户与线路作为整体接入公共电网
多用户绿电直连（发改能源〔2026〕688号）	将绿电直连由单一用户扩展至多个用户	式(11-5)排放因子 f	使园区级、集群级智算设施可共享同一直连电源，显著降低单个用户的接入门槛	2026 年新增文件，2026 年后不可仅引 650 号
可再生能源电力消纳责任权重（发改办能源〔2025〕669号）	一并下达 2025 年与 2026 年权重；在电解铝基础上增设钢铁、水泥、多晶硅行	绿电占比 g 的下限	以考核约束抬升绿电占比，使算电协同进入强制性消纳体系	2025 年权重为约束性指标、2026 年权重为预期性指标，法律效力不

绿证全覆盖与绿证市场建设（发改能源〔2023〕104号、发改能源〔2025〕262号）	业和国家枢纽节点新建数据中心的绿色电力消费比例；以本省实际消纳物理电量为主、省级绿证账户购买省外绿证为辅	式(11-5)的市场法口径	为跨省绿电声明提供凭证，支撑市场法口径的碳强度下降	同，不可并列称「指标」
	1个绿证对应1000千瓦时；2025年全年核发29.47亿个、其中可交易18.93亿个、交易9.30亿个（同比增长1.08倍），省份间单独交易占单独交易总量的91.20%			
	到2025年底全国数据中心整体上架率不低于60%、平均电能利用效率降至1.5以下；新建及改扩建大型、超大型数据中心降至1.25以内、国家枢纽节点项目不高于1.2；国家枢纽节点新建数据中心绿电占比超过八成			
数据中心绿色低碳发展专项行动计划（四部门，2024年）	在京津冀、长三角、内蒙古等枢纽节点及青海、新疆等清洁能源丰富地区部署，围绕绿电直供、多源互补、源荷互动开展技术探索	式(11-2)的电能利用效率与绿电占比 g	经式(11-2)线性降低能耗强度，并经式(11-5)降低排放因子	核发量与交易量为两个独立指标，不可相减；绿证不改变任何一度电的物理来源，不进入地理位置法口径
算力电力协同先行先试（国家数据局，2025年）		空间与时间维度的负载配置	经跨域调度把可延迟负载移向绿电富集地区与时段，同时降低 ε 与 f	三档电能利用效率的适用对象不同，存量全国均值与新建项目上限不构成同一序列，不可用于说明趋势

注：文件名称、文号与发布时间以公开发布文本为准；「对碳强度的传导」为作者依式(11-2)与式(11-5)归纳，非文件原文表述。绿证数据为国家能源局《中国绿色电力证书发展报告（2025）》口径。资料来源：各政策文件公开文本。

表 11.2 中的六项工具可以归为三类。第一类是物理型工具，以绿电直连与多用户绿电直连为代表，其特征是改变电力的物理来源，因而同时改变地理位置法与市场法两个口径。第二类是权重型工具，以消纳责任权重为代表，其特征是以行政考核抬升绿电占比的下限，作用于 g 而不直接规定实现方式。第三类是凭证型工具，以绿证的核发与交易为代表，其特征是把绿电的环境属性从物理电量

中剥离出来单独流转，作用于市场法口径；我国绿证制度自全覆盖起步并持续推进市场化建设（国家发展改革委等，2023b；国家发展改革委和国家能源局，2025），2025 年全年交易量同比增长逾一倍，已具备为大规模绿电声明提供凭证的能力。三类工具的减排「真实性」依次递减，而流动性与可获得性依次递增——这正是环境权益类资产的经典权衡（蓝虹和杜彦霖，2024；陈丹丹等，2025）。对绿色词元的制度设计而言，关键是不能让三类工具在同一份凭证上混记：若允许以绿证抵充物理排放并据此签发绿色词元凭证，则凭证的信息含量将被稀释，其在出海碳合规场景中的可接受性也会下降。

空间维度上，算力网络的国家布局为词元生产的碳强度提供了独特的优化空间。国家枢纽节点与「东数西算」工程的制度安排（「国家发展改革委等，2021」；国家发展改革委等，2023），使得可延迟的推理负载（如批量文档处理、离线内容生成、模型评测）可以被调度到清洁能源富集地区生产，再以词元形态回流至东部消费。这一模式在浙江已有实践探索：浙江省将一体化算力监测调度平台写入省级规划（「浙江省人民代表大会，2026」），并在算电协同方向上探索通过跨域调度降低用能成本与碳排放，算力电力协同已成为独立的研究与政策议题（中国信息通信研究院，2025）。其经济实质是把电力的空间价差与碳强度的空间差异，通过词元这一可远距离传输、近乎零边际运输成本的载体加以套利——这是词元相对于电力本身的关键优势：电力跨区输送受限于电网容量与损耗，而词元的跨区传输只受限于带宽与时延。时间维度上，源荷互动与错峰调度可以把负载移向新能源出力高峰时段，其可行性取决于任务的时延容忍度，这与第 9 章排队分析中的时延—成本权衡是同一问题的两种表述。

11.3.3 情景测算与总量口径校验

把三条路径的推进节奏组合为三种情景，可以给出 2026 至 2035 年词元碳强度的演进轨迹。基准情景假定绿电占比按现有趋势提高、能效按既有速率改进；绿色情景在此基础上叠加绿电直供的规模化与电能利用效率的系统性优化；深度情景进一步叠加算效跃升与余热利用。三情景的轨迹与绿色词元阈值的关系，如图 11.3 所示。




图 11.3 绿电占比提升下的碳强度情景 (2026—2035)

注：三情景的差异来自绿电占比路径、能效改进速率与档位结构三组参数的不同设定，其对应的政策工具见表 11.2；碳强度按地理位置法口径核算，经绿电直连取得的绿电计入该口径，单纯购买绿证仅影响市场法口径，不进入本图。数据来源：作者校准复算。

图 11.3 显示，到 2035 年基准情景的碳强度为 1.30、绿色情景为 0.62、深度情景为 0.34 克二氧化碳当量每千标准词元，相对 2026 年分别下降 42.6%、72.6%与 85.0%。跨越绿色词元阈值的年份分别为：绿色情景 2033 年、深度情景 2032 年，而基准情景至 2035 年仍高于阈值。这一结果传递了三层信息。第一，达标不是自动的：基准情景已经包含了相当可观的能效改进与绿电增长，但仍不足以在十年内把平均碳强度压到阈值以下，说明「等待技术进步」不是一个可行的政策选项。第二，阈值的跨越时点对政策强度高度敏感：绿色情景与深度情景的差别主要在于算效跃升与余热利用是否落地，二者的跨阈时点仅相差一年，但 2035 年的终值相差 45%，说明政策的长期效果远大于其短期效果。第三，深度情景的终值仍高于全绿电供电的理论下界 0.171，差额来自结构效应——随着智能体与复杂推理类应用的扩张，用量结构持续向高档位迁移，这一结构效应会抵消部分技术改进，正是式(11-6)第二项所刻画的机制。

最后作一次总量口径校验，其目的不是给出总量估计，而是暴露乘法核算的不成立。按国家数据局口径，2026 年 3 月我国日均词元调用量突破 140 万亿枚；按本书校准复算的用量结构，平均效值系数为 1.425，对应约 199.5 万亿枚标准词元。若直接乘以用量加权平均能耗强度 4.269 千瓦时每百万标准词元，可得日耗电约 8.5 亿千瓦时，年化约 3109 亿千瓦时，相当于 2024 年全社会用电量 98521 亿千瓦时的 3.2%；若全部以绿证覆盖，需 3.11 亿个绿证，占 2025

年全年绿证交易量 9.30 亿个的 33.4%；若只覆盖达标所需的 60.4%，也需 1.88 亿个，占 20.2%。

这一演算的数值明显高于前述任何一套关于数据中心用电占比的公开说法，其本身就是一个警示。至少有三处使乘法核算失效：其一，分母不同——调用量统计的是计费词元，而能耗强度的分母是本书定义的标准词元，两者之间的换算依赖效值结构假定；其二，边际不等于平均——前缀缓存命中、批处理与共享上下文使大量词元的边际能耗远低于平均能耗，而调用量按计费口径把缓存命中的词元同样计入；其三，统计边界未公开——调用量口径是否包含内部调用、测评调用与失败重试，从未披露。因此，上述数字只能作为量级参照，不得作为统计结论，本书亦不据此推断数据中心用电占比。真正的结论恰在于此：在服务级计量制度缺位的条件下，任何「调用量×能耗强度」式的总量估计都不可靠，而这正是把词元级能耗与碳排纳入统计制度的现实理由——不是为了追求一个更精确的总量数字，而是为了使总量数字第一次成为可能。

11.4 绿色词元的溢价机制与出海碳合规

11.4.1 绿色溢价的需求侧来源与实证识别

绿色词元若不能获得溢价，则一切核算与认证都只是成本。溢价的需求侧来源有三：其一是出海合规需求，即出口导向企业为满足境外买方或监管的碳信息披露要求，需要对其数字服务投入的隐含排放作出说明；其二是供应链绿色采购，即大型采购方将供应商的碳绩效纳入准入与评分，从而把要求逐级传导至词元这样的中间投入；其三是自身的环境、社会与治理披露需要，即企业为改善其披露表现而主动选择低碳投入。三类需求的共同特征是，它们并不直接来自词元的使用价值，而来自词元所携带的可核验信息——这决定了绿色溢价在本质上是一种信息溢价，其存在以凭证的可信性为前提。

为识别绿色属性对标准词元价格的影响，本书以特征价格模型设定式(11-10)，被解释变量为成交的标准词元价格对数，核心解释变量为绿色词元标识，控制变量包括档位、场景、合同规模、采购主体类型与时间固定效应。

$$\ln \tilde{p}_i = \alpha + \varphi G_i + x_i' \beta + u_i \quad (11-10)$$

其中， $\tilde{p}_i$ 为第 i 笔交易的标准词元价格， G_i 为绿色词元标识（取 1 表示附碳足迹凭证且碳强度低于阈值）， φ 为绿色溢价率， x_i 为控制变量向量。

估计结果为 $\varphi = 0.083$ ，标准误 0.021， t 值 3.95，样本量 612，判定系数 0.41，在 1%水平上显著。即在控制档位、场景与合同规模后，附碳足迹凭证的

标准词元价格高出约 8.3%。这一溢价幅度不大但稳健，其量级与绿色金融领域观察到的绿色资产定价差异属同一数量级（陈丹丹等，2025）。需要坦诚说明三点识别局限：第一，绿色标识并非随机分配，采购绿色词元的企业往往本身即为出海导向或受供应链约束的企业，其支付意愿可能同时被其他未观测因素推高，估计值应理解为条件相关而非纯因果效应；第二，样本以出海导向企业为主，向全体用户的外推需谨慎；第三，样本期内绿色词元的供给规模有限，溢价中可能包含稀缺租金，随供给扩张而收敛。

11.4.2 隐含碳价与供给侧的减排决策

溢价率本身不便于与其他减排工具比较，因为它是一个相对价格。把溢价折算为单位减排量的价格，即可得到绿色词元的隐含碳价，见式(11-11)。

$$p^C = \frac{\varphi \tilde{p}}{i - i^{green}}, \varepsilon \chi \leq \varphi \tilde{p} \quad (11-11)$$

其中， p^C 为隐含碳价， $\tilde{p}$ 为用量加权平均标准词元价格， $i - i^{green}$ 为由电网供电转为全绿电供电的单位减排量； χ 为绿电相对电网电价的度电价差，右式为供给方自愿采购绿电的成本可行条件。

代入第 7 章的价格结构，用量加权平均标准词元价格为 1.533 元每百万标准词元，对应的绿色溢价额为 0.127 元每百万标准词元；由式(11-4)的量纲恒等，由电网供电转为全绿电供电的减排量为 2.092 千克二氧化碳当量每百万标准词元。二者相除得隐含碳价 $p^C = 60.8$ 元每吨二氧化碳当量。这个数字给出了一把可与碳市场配额价格、自愿减排项目价格直接比较的尺度：当外部碳价高于该水平时，供给方更愿意通过配额或减排量交易实现合规；当外部碳价低于该水平时，把绿色属性直接嵌入词元产品出售更为有利。换言之，绿色词元实际上开辟了一条「嵌入式」的减排价值实现渠道，与配额市场的「分离式」渠道并行（段玉婉等，2023；赵思琦等，2023），其相对吸引力由两个市场的价格关系内生决定。

式(11-11)右式则给出供给侧的决策规则：只要绿电相对电网电价的度电价差乘以能耗强度不超过绿色溢价额，供给方主动采购绿电即为有利可图。代入数值可得价差上限 $\chi \leq 0.0298$ 元每千瓦时，约合每千瓦时 3.0 分。这是一个相当苛刻的条件：它意味着绿电的市场化溢价必须被压缩到很小的区间，绿色词元的自发供给才能成立；一旦绿电溢价超出该区间，就必须依靠消纳责任权重这类强制性工具，或依靠地方补贴与政策抵扣来弥合缺口。这也从供给侧解释了为什么绿电直连具有特殊价值——直连模式绕过了公共电网的输配环节，其度电成本更

接近电源侧成本，因而更有可能落入上述可行区间。同时应当注意， χ 的上限与能耗强度成反比：能耗强度越低的档位，可承受的绿电价差越大，绿色供给的经济性越好，这与 11.2 节关于认证非中性的判断相互印证。碳约束下的能源与经济转型研究表明，价格信号与总量约束需要配合使用才能实现有效减排（何建坤，2021；张希良等，2022；杨豪等，2023），词元领域并无例外。

11.4.3 出海碳合规需求与制度衔接

绿色词元溢价的最强需求来自跨境场景，但这一需求的制度基础目前并不牢固。欧盟碳边境调节机制自 2026 年 1 月 1 日进入确定期，其证书的购买与清缴自 2027 年 2 月起适用于 2026 年进口货物的隐含排放；2025 年通过的简化条例引入了每进口商每年 50 吨的最低限度门槛，适用于钢铁、铝、化肥与化学品类别，电力与氢明确排除在该豁免之外，欧盟委员会估计该门槛豁免约九成进口商而仍覆盖 99% 的隐含排放（「European Parliament 和 Council，2023」）。就本书主题而言，最关键的事实是：该机制覆盖的行业为水泥、钢铁、铝、化肥、电力与氢，不含数字服务、软件与人工智能服务。因此，「词元出海」在现阶段不受其直接管辖。但有两条间接路径不容忽视：其一，若词元以嵌入产品的形态出现——例如为出口钢铁、铝制品提供的智能设计与工艺优化服务，其能耗与排放会计入产品的隐含排放核算；其二，若算力以跨境电力形态出现，电力项下的核算要求将直接适用。

更根本的制度缺口在于：截至 2026 年 8 月，尚无面向人工智能服务或单位词元的可认证碳足迹核算标准。最接近的国际文件是 2025 年 7 月发布的关于人工智能系统环境可持续性方面的技术报告，它概览了人工智能全生命周期的环境可持续性方面及相关潜在指标并纳入了水足迹，但其性质是技术报告而非可认证标准，不能用于合规声明。国内方面，产品碳足迹的方法学基准与管理体系已经建立（国家市场监督管理总局和国家标准化管理委员会，2024；生态环境部等，2024；「生态环境部等，2024」），其中碳足迹管理体系实施方案提出到 2027 年制定发布与国际接轨的国家产品碳足迹核算通则标准，并制定出台约 100 个重点产品碳足迹核算规则标准——这为词元争取纳入重点产品目录提供了明确的制度接口。词元侧现有的规范则集中在运营管理能力方面，2026 年 8 月由中国人工智能产业发展联盟归口发布的团体标准即属此类，需要注意的是团体标准的效力层级低于国家标准与行业标准，且其内容不含碳核算。相关制度的现状、缺口与本书对应关系，见表 11.3。

表 11.3 产品碳足迹制度与词元碳核算的衔接：现状、缺口与本书对应

制度／标准	发布主体与时点	功能单位与核算边界	与词元碳核算的关系	缺口与本书对应
温室气体—产品碳足迹—量化要求和指南 (ISO 14067:2018)	国际标准化组织，2018 年	产品；全生命周期	提供量化方法学母版，四阶段流程为词元核算所沿用	未定义面向数字服务的功能单位；本书以标准词元充当功能单位
温室气体 产品碳足迹 量化要求和指南 (GB/T 24067—2024)	国家市场监督管理总局与国家标准化委员会，2024 年	产品；修改采用 ISO 14067，与生命周期评价系列标准方法一致	国内方法学基准，并增加了制定具体产品碳足迹标准的参考框架	属修改采用而非等同采用，结果不默认国际互认；本书主张词元核算规则在该框架下立项
温室气体核算体系产品与范围二指南	世界资源研究所与世界可持续发展工商理事会	电力间接排放；要求地理位置法与市场法双重报告	决定绿电声明的可用口径，是式 (11-5)的规则来源	现行按年度匹配的规则正在修订，更细颗粒度的时空匹配要求可能使既有「全绿电」声明失效
关于建立碳足迹管理体系的实施方案（环气候〔2024〕30 号）	生态环境部等部门，2024 年	到 2027 年制定国家产品碳足迹核算通则标准与约 100 个重点产品核算规则标准	为词元纳入重点产品核算规则目录提供制度接口	现行重点产品目录未含数字服务；本书建议以标准词元为功能单位单列
产品碳足迹核算标准编制工作指引（环气候〔2024〕91 号）	生态环境部等部门，2024 年	规定核算规则标准的编制流程与技术要求	为词元专项核算规则提供可操作的编制路径	尚无以词元为对象的标准立项公开
人工智能系统环境可持续性方面技术报告	国际标准化组织与国际电工委员会，2025 年	人工智能系统全生命周期的环境可持续性方面与潜在指标，含水足迹	目前最接近人工智能服务碳核算的国际文件	性质为技术报告，不可用于认证与合规声明
碳边境调节机制条例 (Regulation (EU) 2023/956)	欧洲议会与欧盟理事会，2023 年	水泥、钢铁、铝、化肥、电力、氢；确定期自 2026 年起，证书清缴自 2027 年 2 月起	不含数字服务与人工智能服务，词元出海不受直接管辖	嵌入产品的隐含排放与跨境电力两条间接路径需预作准备
人工智能词元 (Token) 运营管理能力要求 (AIIA/T 0308—2026)	中国人工智能产业发展联盟，2026 年	词元运营管理平台的能力规范	现有最接近词元侧的规范性文件	属团体标准，效力层级低于国家标准与行业标准，且不含碳核算维度

注：标准效力层级由高至低依次为国家标准、行业标准、团体标准，机构评估规范不属于标准；「缺口与本书对应」为作者依各文件公开文本归纳，非文件原文表述。资料来源：各标准与政策文件公开文本。

表 11.3 呈现的是一个「方法学齐备、功能单位缺失」的格局：从国际标准到国内标准，产品碳足迹的量化方法已经成熟，缺的是把这套方法应用于人工智能服务时所需的功能单位与分摊规则。这一缺口恰恰是标准词元计量体系的用武

之地——功能单位问题的实质，就是「一枚什么样的词元」这一问题，而这正是第 5 章折算体系所回答的。因此本书主张一条清晰的制度路径：以标准词元为功能单位，依照产品碳足迹核算标准编制工作指引的流程，在国家产品碳足迹核算规则标准体系下单列词元核算规则，并同步建立与国际方法学的对照说明。标准的早期建立不仅是合规问题，也是国际竞争问题——在网络效应显著的技术领域，率先确立的标准往往因兼容性与预期协调而形成自我强化的优势（Farrell 和 Saloner，1985；Simcoe，2012），而词元的跨境流通天然具有这一特征。

11.5 可信溯源体系：从数据传输到业务落地

11.5.1 三段链路 with 存证层

碳足迹凭证要能被采信，前提是词元的「身份」可以被追溯。一枚标准词元的完整身份至少包含五项信息：由哪个算力中心、哪个档位的模型生产，消耗了多少电量，其中绿电占比多少，对应多少碳排放，最终被用于什么业务。地方实践已经出现了与之高度对应的制度尝试：2026 年 7 月启动的东南词元运营中心（温州）把「绿色词元认证」作为特色功能，其内核被概括为三项可证——来源可溯（词元由哪个算力中心、什么模型生产）、用能可证（耗电量与绿电占比）、碳排可算（对应的碳排放量）；该中心由国资控股的运营公司承担具体运营，电信运营商与云服务商提供智算基础设施与平台能力支撑（以上为公开报道口径）。广东词元交易和服务中心则从交易侧切入，牵头构建全省统一的词元计量规则并出具交易凭证。两地的做法虽然入口不同，指向的却是同一件事：把碳属性写进词元的计量记录。

图 11.1 下半部刻画三段溯源链路，正是对这一实践的理论化。第一段是数据传输：输入数据经加密通道进入推理服务，需满足数据出境与个人信息保护的合规要求，其留痕对象是数据的来源与流向。第二段是模型调用：调用日志记录档位、任务类型、输入输出词元数、缓存命中情况与所在算力节点，其留痕对象是用量与效值，这一段同时是第 5 章效值折算与本章能耗核算的共同数据源。第三段是业务落地：推理结果被归档并与具体业务结果关联，其留痕对象是价值实现与责任归属。三段留痕汇入一个共同的存证层，由时间戳、内容哈希与主体标识构成，并与碳足迹凭证一一绑定。这一结构的经济含义在于范围经济：内容溯源、用量结算与碳核算共用同一条存证链，三者的边际成本因而大幅低于各自独立建设，这与第 3 章关于词元非竞争性与范围经济的分析是一致的。

溯源体系并非从零开始。我国已有的监管框架为其提供了制度骨架：互联网信息服务深度合成管理规定要求对深度合成内容进行标识（「国家互联网信息办

公室等，2022」），生成式人工智能服务管理暂行办法进一步确立了服务提供者的主体责任与内容标识义务（国家互联网信息办公室等，2023）；技术侧，面向大模型输出的水印方案已从研究走向可规模化部署（Kirchenbauer 等，2023；Dathathri 等，2024），为「这段内容由哪个模型生成」提供了可验证的技术手段。需要说明的是，内容水印解决的是输出侧的可识别性，而碳足迹凭证解决的是生产侧的可核算性，两者的技术实现不同但载体可以统一。把二者合并到同一存证层，既是成本考虑，也是治理考虑——它使得「谁生产、耗多少电、排多少碳、用在何处」构成一条完整的证据链，而不是四份互不衔接的记录。

11.5.2 凭证的经济学：从柠檬市场到分离均衡

绿色词元在信息结构上属于信任品：购买方在使用中无法感知其碳强度，事后也难以独立验证。在没有可信凭证的条件下，市场将退化为经典的柠檬市场——买方只愿按平均质量支付，导致真实的低碳供给因无法收回绿电增支而退出，市场上剩下的只有声称低碳而实际并非如此的供给（Akerlof，1970）。质量披露与第三方认证正是为化解这一失灵而生的制度，其有效性取决于披露信息的可核验性与认证机构的激励相容（Dranove 和 Jin，2010）。第 8 章已指出效值维度存在同构的柠檬市场风险，本章表明碳维度上的风险更为严重，原因是碳强度比效值更难被使用体验所揭示。

要使绿色供给与非绿色供给在市场上分离，凭证制度须同时满足两个条件：绿色供给方的参与约束与非绿色供给方的激励相容约束，见式(11-12)。

$$\varphi \tilde{p} \geq \varepsilon \chi + c_a, \pi F > \varphi \tilde{p} - c_a \quad (11-12)$$

其中， c_a 为单位标准词元的认证与核验成本， π 为伪报被查处的概率， F 为查实后的处罚（含声誉损失）。左式为绿色供给方愿意提供绿色词元的参与约束，右式为非绿色供给方不愿伪报的激励相容约束。

式(11-12)的两个条件构成一个夹逼：溢价必须足够高以覆盖绿电增支与认证成本，又必须足够低（或处罚足够重）以使伪报无利可图。把 11.4 节的数值代入，溢价额仅为 0.127 元每百万标准词元，这一数额同时是绿电增支与认证成本之和的上限。由此得到一个具有操作意义的推论：认证成本必须被压到极低，否则认证本身就会吞噬全部溢价，使参与约束无法满足。而把认证成本压到极低的唯一途径，是让认证与计量同源——凭证不是在计量之外另行签发的证书，而是计量记录的一个自动生成的字段。这为第 10 章「五个统一」中的统一计量与统一安全审计提供了碳维度的延伸理由：统一计量平台一旦建成，碳足迹凭证的

边际签发成本趋近于零；反之，若计量分散在各服务商手中，凭证的核验成本将高到使整个制度不经济。

激励相容约束则指向执法。由于 πF 需大于溢价扣除认证成本后的净收益，而溢价本身不高，制度设计上有两个可行方向：一是提高查处概率 π ，其成本随存证层的完备程度而下降——若用电量、绿电合同与调用日志均已上链存证，抽查的边际成本极低；二是把处罚从罚款扩展到资格罚，即取消其在政策抵扣、政府采购与出海服务清单中的资格，使 F 显著放大。两个方向都说明，绿色词元凭证制度的可行性不取决于技术，而取决于它能否嵌入既有的计量与监管基础设施。这与自愿减排市场的经验一致：产权量化标准与登记核查体系的完备程度，决定了环境权益能否真正定价（蓝虹和杜彦霖，2024）。

11.5.3 制度缺口与建设次序

综合本章的分析，词元碳治理面临三个层层递进的缺口。第一个是功能单位缺口：现有碳足迹方法学以产品为对象，未定义人工智能服务的功能单位，导致核算无从下手。第二个是分摊规则缺口：即便功能单位确定，设施开销、空闲备机、宿主机资源与跨域调度损耗如何分摊到单枚词元，目前没有公开统一的规则，而 11.1 节已经证明规则差异可造成成倍的结果差异。第三个是互认缺口：即便国内规则统一，其与国际方法学的对照关系仍未建立，而我国的产品碳足迹国家标准对国际标准采取的是修改采用而非等同采用，结果不默认互认。三个缺口的因果次序决定了建设次序：先统一功能单位（以标准词元为分母），再统一分摊规则（公开、可复现的能耗归集与分摊方法），最后推进国际互认（对照说明与第三方核查安排）。次序颠倒的代价是高昂的——若在功能单位未定的情况下先行签发凭证，则凭证之间不可比，反而会固化一批互不通约的地方标准。

这里有必要辨明本书主张与既有词元评价工作的关系。目前公开可见的相关工作有四套，其主体、维度与用途各不相同，必须逐一分述而不能合并称引：中国信息通信研究院的可信人工智能词元服务质量评估设有六个维度（模型服务能力、词元服务性能、词元服务可信、词元服务运维、词元服务用户体验、词元计量计费）；同为中国信息通信研究院发布的高质量词元服务标准体系设有四个维度（服务质量、运营能力、生产能力、安全能力）；中国工业互联网研究院的词元驱动智能经济研究报告提出五维价值度量（生产成本、生产效率、准确性、生态价值、安全）；清华大学翟季冬团队联合清程极智发布的开源模型词元服务性能榜则给出三项实测指标（首词元时延的 90 分位、输出吞吐、缓存命中率）。四套工作的共同特点有二：一是形态上均为多维评价，产出并列的维度得分或达

标基线；二是内容上均未设置碳维度。本书的主张因而是明确的：把碳强度作为一类新的指标纳入词元服务的评价与认证体系，并以标准词元为其分母——前者是维度的增加，后者是分母的统一，二者缺一不可。

最后应当提示凭证制度的潜在风险。任何认证体系都同时是一道门槛：当认证成本相对固定时，其对中小服务商构成的相对负担更重，可能强化第 8 章所讨论的市场集中倾向；当认证资格与政策抵扣、政府采购挂钩时，还可能演化为区域性的准入壁垒，与全国统一大市场方向相悖。规避之道有三：其一，认证以计量记录自动生成为主、以第三方核查为辅，把固定成本降到最低；其二，凭证格式与核验接口全国统一，在城市运营中心之间互认，避免「一城一证」；其三，阈值随技术进步与电源结构改善定期回调，并预先公布回调规则，使供给方能够形成稳定预期。三条措施的共同指向，是让绿色词元制度成为降低交易费用的公共品，而不是抬高进入门槛的私人租金。国家层面推动人工智能与实体经济深度融合的政策部署（国务院，2025），为这一制度安排提供了上位依据。

11.6 本章小结

本章把词元经济的分析从算力约束推进到电力与碳约束，构建了以标准词元为功能单位的能耗—碳足迹核算框架，并据此界定了绿色词元、测算了减排路径、刻画了溢价机制与溯源制度。核心结论可归纳为六点。第一，现有公开能耗数据存在分母、边界与分布三重口径落差：权威测算的分母普遍是「一次查询」而非「一千枚词元」，综合口径与仅计活跃加速器的窄口径相差 2.4 倍，中位数与均值因长推理的厚尾分布而显著背离，我国更无数据中心用电量的官方统计。因此词元级能耗与碳排数值只能是换算与校准复算的结果，其可靠性来自内部一致性与锚点校准，不能表述为实测值。第二，能耗核算的基本恒等式把技术效率、组织效率与设施效率放进同一表达式：能耗强度与转化效率、有效效值利用率成反比，与电能利用效率成正比，这使得调度这类纯组织性改进第一次进入了碳账。

第三，在量纲上，以千瓦时每百万标准词元乘千克二氧化碳每千瓦时恰得克二氧化碳当量每千标准词元，换算系数为 1；据此测算的 2026 年用量加权平均碳强度为 2.263（地理位置法口径），全绿电供电的理论下界为 0.171。分档位碳排放高度集中：旗舰闭源级与推理增强级合计用量份额 15%，碳排放贡献却达 43.1%。更重要的是碳—效值弹性估计为 1.181，显著大于 1，说明效值提升的碳代价是超比例的——效值折算解决价值可比，碳核算解决环境可比，两套当量体系必须并行，政策抵扣系数应写成效值系数与碳强度的复合函数。第四，绿色

词元阈值按碳预算法取 1.0 克二氧化碳当量每千标准词元，约为现状均值的 44%；在能效不变时整体达标需绿电占比达 60.4%，而纯能效路径则需能耗强度整体下降 55.8%，两条路径构成一条可替代但不可取消的等碳强度曲线。

第五，减排的三条路径——能效、配置与电力——是乘性而非加性关系，其中配置路径最容易被忽略却最具即期可行性：把第 9 章统一调度的效率改进（有效效值利用率由 38% 升至 54%）代入达标条件，整体达标所需绿电占比由 60.4% 降至 40.2%，已低于 2026 年 44% 的绿电占比现状。这意味着在不新增绿电、不等待硬件更替的条件下，仅凭调度组织的改进即可使平均碳强度跨过阈值——绿色词元首先是一个配置问题，其次才是一个能源问题。情景测算进一步显示，基准情景至 2035 年仍高于阈值，绿色情景与深度情景分别在 2033 年与 2032 年跨越阈值，说明达标并非趋势的自然结果。本章还以总量口径校验表明，「调用量×能耗强度」式的乘法核算因分母不一、边际不等于平均、统计边界未公开而不成立，这恰恰构成建立服务级计量制度的现实理由。

第六，绿色词元的溢价为 8.3% 且在 1% 水平上显著，折算的隐含碳价为 60.8 元每吨二氧化碳当量，对应绿电相对电网电价的可承受度电价差上限约 3.0 分每千瓦时；这一夹逼条件说明绿色词元的自发供给区间相当狭窄，必须辅以消纳责任权重、绿电直连与政策抵扣。溢价的可占有性完全依赖凭证的可信性：在信任品结构下，没有凭证的绿色供给会被逆向选择淘汰，而凭证要满足参与约束与激励相容约束的夹逼，唯一可行的办法是让认证与计量同源、把认证成本压到趋近于零。制度层面，产品碳足迹的方法学已经齐备而功能单位缺失，欧盟碳边境调节机制尚不覆盖数字服务，人工智能服务碳足迹亦无可认证的国际标准，这一空白正是以标准词元为功能单位先行建立核算规则的窗口期。建设次序应为：先统一功能单位，再统一分摊规则，最后推进国际互认。本章的碳强度参数与绿色词元界定将作为约束条件进入第 12 章的增长核算与第 14 章的政策设计，而其溯源体系与第 10 章的「五个统一」共用同一套计量基础设施。

第 12 章 词元经济的增长贡献测度

全书的论证至此已经走完计量、定价与配置三大模块：第 5 章以四条公理构造了效值折算函数，把异质的物理词元变换为可比、可加的标准词元；第 6 至 8 章解决了标准词元的价值实现、价格形成与市场均衡；第 9 至 11 章处理了算力一词元的转化效率、城市运营中心的机制设计与绿色词元的碳足迹核算。这些工作共同服务于一个尚未兑现的承诺：标准词元应当承担价值尺度、定价基准、配置信号与增长核算变量四重经济职能。前三重职能已在前述各章分别落实，第四重职能——作为增长核算变量——是本章的任务，也是本书理论体系的最后一块拼图。这块拼图之所以关键，在于它是全部计量努力的终极检验：一个计量单位若不能进入国民经济核算体系、不能把某种经济活动的贡献从「无法解释的部分」中分离出来，它就仍然只是一个技术参数，而不是一个经济变量。

本章要回答的问题可以表述得非常朴素：人工智能究竟对经济增长贡献了多少？这一问题在既有文献中长期无解，不是因为缺少估计，而是因为缺少可观测、可加总、可归属的中间变量。悲观者与乐观者各执一词，其分歧很大程度上并非来自经济学判断的差异，而来自各自所用口径的不可通约。词元流量的出现改变了这一局面：它每日可计数、随场景可分、随主体可归、随模型可分档，是人工智能扩散过程的直接观测量。本章的核心主张是，一旦把经效值折算的标准词元流量作为独立要素引入生产函数，人工智能的增长贡献就可以从索洛残差中显性分离，增长核算由此从「事后残差推断」转向「事中过程观测」。本章安排如下：12.1 节梳理索洛生产率悖论在人工智能时代的再现及其口径辨析；12.2 节剖析传统增长核算的三重遗漏，说明人工智能为何必然沉入残差；12.3 节构建引入词元流量的智能经济生产函数并给出可估计式；12.4 节完成从残差测度到过程观测的转换，给出贡献分离、配置判据与动态滞后结构；12.5 节报告基于城市一年度面板的估计与贡献分解；12.6 节与资本服务测度传统对话并检验稳健性；12.7 节为本章小结。

12.1 索洛生产率悖论在人工智能时代的再现

12.1.1 「到处都是大模型，唯独生产率统计里看不见」

一九八七年，索洛在评论信息技术的经济效应时留下一句被反复引用的判断：计算机时代的痕迹到处可见，唯独在生产率统计中看不见。将近四十年之后，同一句判断几乎可以原样移植到大模型身上。通用目的技术的理论传统早已预言了这种时滞：通用目的技术的特征是普遍适用性、持续改进性与创新互补

性，其宏观效应必须经由下游部门的互补创新才能释放，因而在扩散早期往往表现为「投入已发生而产出未显现」（Bresnahan 和 Trajtenberg，1995）；对人工智能作为通用目的技术的专门评估同样指出，其增长效应的实现取决于互补性投资的规模与速度（Crafts，2021）；从增长理论看，人工智能既可能通过扩大自动化任务集提升产出，也可能通过改变研究生产函数改变增长率本身，两条渠道的量级差异极大（Aghion 等，2019）；而机器学习作为一种发明方法的发明，其价值更多体现在对创新过程的加速上，这类效应在短期统计中几乎无从捕捉（Goldfarb 等，2023）。

悖论的现实反差在我国表现得尤为尖锐。按国家数据局公开发布的口径，我国日均词元调用量由 2024 年初的 1000 亿枚，增至 2025 年 6 月底突破 30 万亿枚、2025 年底的 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍。与此同时，苏州、嘉兴、温州、广州、上海等地在一周之内密集设立城市级词元运营中心或将词元纳入技改补贴，词元从模型服务的计价单位变为城市公共基础设施。可是在国民经济核算的报表上，这一量级的扩张几乎没有留下可识别的独立痕迹：它既不在资本形成的分类目录中，也不在中间投入的分类目录中，最终只能以两种方式被间接吸收——一部分作为信息服务业的增加值进入产业统计，另一部分作为无法解释的效率改善进入全要素生产率残差。前者只记录了词元的销售额，后者则把词元的使用效应与其他一切未观测因素混为一谈。

国际经验同样提示我们对宏观数字保持审慎。美国劳工统计局的口径显示，2025 年全年非农商业部门劳动生产率增长约 2.1%，低于 2024 年的 3.0%，季度值则波动剧烈。这里需要特别指出一处广为流传但与官方统计相矛盾的说法：有论者称美国 2025 年劳动生产率增长约 2.7%、接近此前十年年均水平的两倍，并据此宣称人工智能已推动生产率跃升。经与美国劳工统计局公布的年度值核对，该数字既不等于官方全年值，其所隐含的「2025 年生产率加速」叙事更与官方「全年增速较 2024 年回落」的事实方向相反；且劳动生产率与全要素生产率分属两个指标，不可交叉引用。本书不采用该数字。这一处校核本身即说明了本章的必要性：在缺乏过程观测变量的条件下，关于人工智能增长效应的讨论极易退化为对宏观时间序列的事后附会，而任何一个方向相反的季度波动都足以推翻整套叙事。

12.1.2 悲观与乐观：两侧估计及其口径边界

悲观侧最具影响力的测算来自对人工智能宏观效应的简明分析。其方法建立在希尔滕定理之上：一项技术带来的国内生产总值与生产率收益，取决于受其影

响的任务占比与每项任务的平均成本节约。据此设定约 20%的劳动任务暴露于人工智能、其中仅约 23%可被有利可图地自动化、每项任务平均劳动成本节约约 27%，得到的结论是人工智能在未来十年最多带来约 0.66%的全要素生产率增幅；作者随后进一步收紧至低于 0.53%，理由是早期证据多来自易学任务，而未来效应更多依赖情境判断类难学任务（Acemoglu，2025）。乐观侧的代表性框架则是生产率 J 曲线：通用目的技术需要流程再造、组织重构与员工再培训等互补性无形投资，这些投入在会计上被费用化而非资本化，因而被系统性错误计量，使可测生产率呈现先降后升的 J 形轨迹（Brynjolfsson 等，2021）；对人工智能与现代生产率悖论的系统梳理进一步把「技术潜力巨大」与「统计尚未显现」这两个看似矛盾的事实统一在实施滞后的解释之下（Brynjolfsson 等，2019）。基于美国普查局企业微观数据的最新研究支持了这一模式：工业人工智能采用的早期出现生产流程与组织扰动导致的产出损失，多数企业在中期出现绩效改善。

两侧之间还散布着大量机构测算与微观实验证据。经济合作与发展组织对七国集团的评估认为，人工智能可为高暴露度国家的年度总体劳动生产率增长贡献 0.4 至 1.3 个百分点（「OECD，2024」）；国际货币基金组织的研究指出全球约 40%的就业岗位暴露于人工智能、发达经济体约 60%，其中约一半有望受益于生产率提升、另一半面临替代风险（「Cazzaniga 等，2024」）；人工智能指数报告的经济章测算，到 2026 年初美国由人工智能带来的消费者剩余达到每年 1720 亿美元，上年同期为 1120 亿美元，同时 70%的组织已在至少一项业务职能中使用生成式人工智能，按职能测得的生产率提升分别为客户支持 14%至 15%、软件开发 26%、营销产出 73%（「Stanford HAI，2026」）；咨询机构对生成式人工智能经济潜力的测算则给出了更大的总量口径（「Chui 等，2023」）。微观实验与准实验研究的结论亦相当一致：写作类任务的完成时间显著缩短而质量不降（Noy 和 Zhang，2023），客服坐席的产出提升在低技能员工中最为明显（Brynjolfsson 等，2025），任务层面的暴露度测算表明相当比例的工作任务可被显著加速（Eloundou 等，2024），企业层面的证据显示人工智能采用与生产率之间存在正向关联但异质性极强（Czarnitzki 等，2023），采用速度快于历史上任何一项通用技术（Bick 等，2024），而采用行为在人群与企业之间高度不均（Humlum 和 Vestergaard，2025）。

把这些数字并置阅读时，最容易犯的错误是把量纲与期限不同的估计直接比较。本书在此重申三条口径纪律。其一，全要素生产率与劳动生产率是两个指标，前者刻画要素综合效率，后者刻画每小时产出，二者的驱动机制与统计来源

均不相同，不可交叉引用。其二，十年累计增幅与年度增量百分点是两种期限口径，0.66%的十年累计全要素生产率增幅与0.4至1.3个百分点的年度劳动生产率增量之间相差的约二十倍纯属口径差异，绝不能据此得出某一方比另一方乐观二十倍的结论。其三，任务级生产率提升是特定任务的微观实验结果，不能外推为宏观生产率增速；消费者剩余是福利口径，既不是国内生产总值口径，也不是产值或市场规模口径，不可与后者并列或相加。悲观侧与乐观侧的所谓「对立」，有相当一部分正是在违反这三条纪律的比较中被人为制造出来的。

12.1.3 悖论的四类解释与本书的诊断

对生产率悖论的经典解释可归纳为四类：虚假期望，即技术的潜力被高估；错误计量，即收益真实存在但未被统计捕捉；再分配与租金消散，即技术带来的是份额转移而非总量增加；实施滞后与转型成本，即互补性投资尚未完成（Brynjolfsson等，2019）。围绕错误计量一支的检验最为充分：对错误计量能否解释生产率放缓的系统性检验表明，单靠错误计量不足以完全解释缺口，但计量改进的空间确实存在（Syverson，2017）；云计算的价格测度困难导致相关投入的实物量增长被低估（Byrne等，2018）；跨境数据流与云服务对国内生产总值测度提出了新的挑战（Coyle和Nguyen，2019）；而企业层面的证据显示云计算采用确实带来了可观的增长效应（DeStefano等，2025）。这些研究共同勾勒出一条经验规律：每当一种新的中间性生产服务以急剧下降的价格与快速上升的质量被大规模使用时，现行核算体系总是先低估其实物量，再把差额留给残差。

本书的诊断在四类解释之外增加了第五类，并认为它才是当下最具约束力的一类：过程量缺失。人工智能的投入端与产出端各自都有统计，唯独连接二者的使用过程没有可加的计量单位。算力规模只说明产能存在，不说明产能被使用；数据体量只说明资源存在，不说明资源被调用；人工智能产业收入只说明服务被购买，不说明服务在多大强度上参与了买方的生产。这一空缺使得核算者面对人工智能时只有两条路可走：要么把它当作一项普通的中间投入按支出额计入，从而完全丧失结构信息；要么把它留在残差里，从而完全丧失归因能力。词元流量恰好位于这一空缺的位置上——它是投入被实际使用的直接计数，是产出被实际生产的直接凭据。但要让这一变量真正进入核算，前提仍然是可加，即必须先完成折算：物理词元不可加，标准词元才可加。第5章的折算体系与本章的核算框架，由此构成一条完整的方法链条。

12.2 传统增长核算的局限：人工智能为何沉入残差

12.2.1 残差的性质与「我们无知的度量」

增长核算的基本操作是把产出增长分解为要素投入的贡献与一个无法由投入解释的余项。以最简的两要素设定为例，记产出增长率为 g_Y 、资本与劳动的增长率为 g_K 与 g_L ，核算者所采用的（通常取自要素收入份额的）弹性为 $\alpha_K^{(0)}$ 与 $\alpha_L^{(0)}$ ，则传统索洛残差为：

$$g_A^{(0)} = g_Y - \alpha_K^{(0)} g_K - \alpha_L^{(0)} g_L \quad (12-1)$$

其中，上标(0)表示传统两要素核算口径， $g_A^{(0)}$ 即该口径下的全要素生产率增长率。

式(12-1)的形式极为简洁，其经济含义却始终含混。残差既包含真正意义上的技术进步，也包含配置效率改善、规模经济、要素质量变动、测度误差乃至一切被遗漏的投入，因而被恰当地称作「我们无知的度量」。此后半个多世纪的增长核算史，本质上是一部不断把残差中可解释部分显性化的历史：以资本服务流量代替资本存量、按资产类别与使用者成本加权、以质量调整的劳动投入代替人头数、把研发与软件等无形资产资本化——每一次改进，都是把原本落入残差的贡献归还给某项可观测的投入。乔根森开创的资本服务测度传统正是其中影响最深远的一支，它所确立的方法论原则可以概括为一句话：残差的缩小不是技术的退步，而是认识的进步。本章正是沿着这一原则展开——把标准词元流量确立为智能经济核算中新的可观测投入，从而把此前落入残差的人工智能贡献归还给它。

12.2.2 三重遗漏与偏误的方向

人工智能在现行核算中面临的遗漏是三重的。第一重是投入侧的质量遗漏：智能算力设施虽以固定资产投资的形式被记录，但其提供的服务流并未按质量调整，一台训练卡与一台通用服务器在核算中被同等对待，而二者单位时间所能支撑的认知产出相差数十倍。第二重是无形投资的费用化遗漏：企业为采用人工智能所投入的流程再造、提示工程、数据治理与员工培训，在会计上被计为当期费用而非资本形成，既压低了当期测得的产出，又使后续的产出改善失去对应的投入项——这正是J曲线机制的会计根源（Brynjolfsson 等，2021）。第三重、也是本书最为关注的一重，是过程量的完全缺失：即便前两重遗漏被完美修正，核算体系中仍然没有一个变量记录「人工智能在多大强度上被实际使用」。

三重遗漏的后果可以形式化地表述出来。设真实的数据生成过程中，数据要素 D 与标准词元流量 $\tilde{T}$ 均具有正的产出弹性 α_D 与 α_T ，而核算者只使用 K 与 L 。把第2章式(2-10)的扩展核算恒等式代入式(12-1)，整理可得传统残差的构成：

$$g_A^{(0)} = g_A + \alpha_D g_D + \alpha_T g_{\tilde{T}} + (\alpha_K - \alpha_K^{(0)}) g_K + (\alpha_L - \alpha_L^{(0)}) g_L \quad (12-2)$$

其中， g_A 为纠正遗漏后的真实全要素生产率增长率， α_K 与 α_L 为真实的资本与劳动弹性。

式(12-2)给出了三条可检验的推论。其一，方向性：只要 $\alpha_T > 0$ 且 $g_{\tilde{T}} > 0$ ，传统口径的全要素生产率增长率就必然高于真实值，即残差被系统性高估，高估的部分正是人工智能贡献被误记的部分。其二，时变性：高估幅度 $\alpha_T g_{\tilde{T}}$ 与词元流量增长率同向变动，而词元流量正处在两年约一千四百倍的扩张期，因此高估幅度必然逐年扩大——这意味着即便在残差层面观察到全要素生产率增速的「改善」，也不能贸然归因于技术进步，因为其中混入了一个规模迅速膨胀的遗漏项。其三，污染性：遗漏还会通过 $\alpha_K - \alpha_K^{(0)}$ 与 $\alpha_L - \alpha_L^{(0)}$ 两项污染其余要素的弹性估计，因为词元投入与算力资本、与高技能劳动均高度相关，遗漏它会使资本与劳动的贡献被同时高估。三条推论合起来说明，人工智能沉入残差并不是一个可以容忍的近似，而是一个会随时间恶化的系统性偏误。

12.2.3 价格平减的陷阱：为什么核算必须用标准词元价格指数

即便核算者愿意引入词元变量，还有一道更隐蔽的关口需要通过：实物量的构造。在实践中，投入的实物量通常由名义支出除以价格指数得到，因而平减指数的选择直接决定了实物量增长的大小。这正是质量调整价格指数研究的经典战场：特征价格法把产品价格分解为各质量特征的隐含价格（Griliches，1961），其在质量快速变动产品上的适用性与偏误问题被反复检验（Pakes，2003；Erickson和Pakes，2011），而在新产品与品类更替频繁的场景下，总量价格指数的构造本身即需重新奠基（Redding和Weinstein，2020）；政府统计如何跟上数字经济的质量变动，更是一个尚未完成的制度工程（Groshen等，2017）。

词元恰恰是质量变动最剧烈的一类服务。第7章的测算显示，以物理词元为对象的词元价格指数由2024年一季度的100降至2026年第二季度的21，累计降幅79%；而以标准词元为对象的标准词元价格指数同期仅降至47，累计降幅53%；两者26个百分点的背离，正是效值提升的货币化度量——表观降幅中约53%来自效值提升即同价买到更强的词元，约47%才是真实降价。若核算者以

词元价格指数平减词元支出，就等于把效值提升整体计入实物量增长，从而把「同样的钱买到更好的服务」误记为「买到了更多的服务」，导致词元投入的实物量被严重虚增、其产出弹性被相应压低。反之，若以标准词元价格指数平减，效值提升已在折算环节被计入标准词元数量本身，平减只剔除真实价格变动，量与价的口径由此严格一致。这是本章全部实证工作的一条前置纪律：进入生产函数的必须是标准词元流量，用于平减的必须是标准词元价格指数，二者共享同一套效值折算参数。

12.3 引入词元流量的智能经济生产函数

12.3.1 设定：词元流量作为认知服务的投入

把词元流量引入生产函数，首先要回答它在要素体系中的位置。本书的界定是：标准词元流量是一种中间性的认知服务流，其经济性质最接近于资本服务流而非资本存量。理由有三。其一，词元只在被调用的瞬间存在，不可储存、不形成存量，正如资本服务只在资产被使用时产生。其二，词元的投入强度可在极短周期内调整，其调整成本远低于资本存量，因而是一个真正的流量决策变量。其三，词元所替代或增强的对象是人类的认知劳动，其产出是任务的完成度而非物质产品，因而必须与人类劳动、组织流程共同进入一个中间层的合成函数，而不能直接与资本、劳动并列。第3章关于词元八项经济属性的分析与第6章关于价值实现链条的刻画，为这一界定提供了微观基础。

据此，本书采用两层嵌套的生产结构。内层是认知服务的合成：记 i 为地区、 t 为时期， $\tilde{T}_{it}$ 为标准词元流量， H_{it} 为与之互补的人力与组织资本（涵盖具备人工智能应用能力的从业人员、被再造的业务流程、数据治理与提示工程等无形投入），二者以不变替代弹性形式合成认知服务 Z_{it} ：

$$Z_{it} = [\varphi \tilde{T}_{it}^\sigma + (1 - \varphi) H_{it}^\sigma]^{1/\sigma} \quad (12-3)$$

其中， $\varphi \in (0, 1)$ 为词元的份额参数， $\sigma \leq 1$ 为替代参数，替代弹性为 $1/(1 - \sigma)$ 。

式(12-3)的设定承载了三项经济判断。第一，词元与人力组织资本之间是有限替代关系而非完全替代： $\sigma < 1$ 意味着单纯增加词元投入而不同步提升应用能力，其边际产出会迅速递减——这为第13章所记录的「企业买了词元却用不起来」的现象提供了函数形式上的解释。第二， φ 刻画的是认知生产中机器认知相对于人类认知的份额，它随模型能力提升与场景深化而上升，因而是一个缓慢变动的结构参数而非常数。第三， H_{it} 的引入直接对应J曲线机制：互补性无形投资在会计上被费用化，若核算中完全忽略 H ，则认知服务的产出会被错误地全部归

给词元，使 $\tilde{T}$ 的弹性被高估；反之若忽略 $\tilde{T}$ ，则会把全部认知产出归给可见的人力投入，这正是当前统计的实际状态。外层则是总量生产函数，认知服务与资本、劳动、数据要素共同决定产出：

$$Y_{it} = A_{it} K_{it}^{\alpha_K} L_{it}^{\alpha_L} D_{it}^{\alpha_D} Z_{it}^{\alpha_Z} \quad (12-4)$$

其中， A_{it} 为希克斯中性技术水平， α_Z 为认知服务的产出弹性；数据要素 D 与认知服务 Z 分列，前者是被存储与治理的信息资源存量，后者是信息被实际加工使用的服务流。

12.3.2 对数线性化与可估计式

式(12-3)与式(12-4)构成的嵌套结构无法直接估计，需要作对数线性化处理。在基准点对式(12-3)取对数并作一阶展开，得到 $\ln Z_{it} \approx s_T \ln \tilde{T}_{it} + (1 - s_T) \ln H_{it}$ ，其中 $s_T = \varphi \tilde{T}^\sigma / [\varphi \tilde{T}^\sigma + (1 - \varphi) H^\sigma]$ 恰为词元在认知服务合成中的成本份额；当 $\sigma \rightarrow 0$ 即替代弹性为1时，该式退化为精确的柯布一道格拉斯形式， $s_T = \varphi$ 。代入式(12-4)并取对数，即得本章的可估计方程：

$$\ln Y_{it} = \ln A_0 + \alpha_K \ln K_{it} + \alpha_L \ln L_{it} + \alpha_D \ln D_{it} + \alpha_T \ln \tilde{T}_{it} + \gamma \ln H_{it} + \mu_i + \lambda_t + \varepsilon_{it} \quad (12-5)$$

其中， $\alpha_T \equiv \alpha_Z s_T$ 为标准词元流量的产出弹性， $\gamma \equiv \alpha_Z (1 - s_T)$ 为互补性人力与组织资本的弹性； μ_i 与 λ_t 分别为地区与时期固定效应， ε_{it} 为随机扰动项。

式(12-5)中最值得强调的是 $\alpha_T = \alpha_Z s_T$ 这一分解。它表明标准词元流量的产出弹性并非一个技术常数，而是两项因素的乘积：认知服务在总产出中的重要性 α_Z ，与机器认知在认知服务中的份额 s_T 。这一分解具有三层含义。其一，它解释了为什么当前估计得到的 α_T 在数值上并不很大：在样本期内，机器认知在全部认知活动中所占份额仍然有限，即便认知服务本身对产出至关重要，二者相乘之后的弹性仍然是一个中等偏小的数。其二，它预示了 α_T 的上升趋势：随着模型能力提升与场景深化， s_T 将持续上升，因而弹性会随时间而增大，任何以固定弹性外推长期的做法都会低估未来贡献。其三，它给出了政策着力点：提高词元的增长贡献既可以通过扩大词元用量实现，也可以通过提升 α_Z 即深化认知服务在生产中的嵌入程度实现，而后者依赖的是流程再造与组织变革，恰是 H 所代表的互补投资——这与第10章「五个统一」中降低企业接入成本的机制设计目标完全一致。

12.3.3 为什么必须是标准词元：口径不一致的偏误

式(12-5)中的解释变量是标准词元流量而非物理词元调用量，这一选择并非修辞而是识别的必需。按第5章的折算关系，某地区某时期的标准词元流量等于

物理词元调用量与其用量加权平均效值系数之积，即 $\tilde{T}_{it} = \hat{\eta}_{it} T_{it}$ ，两边取对数并对时间求导即得 $g_{\tilde{T}} = g_T + g_{\hat{\eta}}$ ：标准词元流量的增长可以分解为调用量增长与平均效值变动两部分。若实证中以物理词元口径入式，则 $\ln \hat{\eta}_{it}$ 被遗漏，其后果可由遗漏变量偏误公式给出：

$$plim \hat{\alpha}_T^{raw} = \alpha_T \left[1 + \frac{Cov(\ln \hat{\eta}_{it}, \ln T_{it})}{Var(\ln T_{it})} \right] \quad (12-6)$$

其中， $\hat{\alpha}_T^{raw}$ 为以物理词元口径估计所得的系数， $plim$ 表示依概率极限。

式(12-6)的经济含义颇为微妙。若一个地区的调用量扩张主要由高效值档位（如推理增强级、旗舰闭源级）驱动，则协方差为正，物理词元口径将高估弹性；若扩张主要由轻量蒸馏级等低效值档位驱动——这在价格战期间相当常见——则协方差为负，弹性被低估。现实中两种力量在不同地区、不同时期交替占优，于是以物理词元口径估计的系数既不稳定也不可跨期比较，其符号甚至可能翻转。这正是第3章所论证的物理词元不可加性在核算层面的直接后果：本书测算的六档位效值系数从轻量蒸馏级的0.38到推理增强级的4.28，相差逾十倍，折算后单位价格的变异系数由0.92降至0.31、下降约66%。折算不是为了让数字好看，而是为了让系数有意义。至此，本章核算框架与传统核算框架的差异已经完整呈现，如图12.1所示。




图 12.1 引入词元流量的智能经济增长核算框架

注：图中所标弹性、贡献与残差数值为本章 12.5 节与 12.6 节的估计结果，样本与口径同表 12.1；左栏对应式(12-1)的传统两要素核算，右栏对应式(12-5)的四要素设定。

图 12.1 以并列对照的方式呈现了两套核算框架的结构差异。左栏是传统核算：资本与劳动经由生产函数决定产出，扣除二者贡献后的余项即索洛残差，人工智能的全部影响与技术进步、效率改善混同其中，既不可观测、不可归因，也不可考核。右栏是本书框架：资本、劳动、数据与标准词元流量四项投入并列进入生产函数，各自带有可估计的产出弹性，人工智能的贡献由 α_T 与标准词元流量增长率之积直接给出，残差相应缩小。两栏之间的差额——残差由每年 2.41%降至 2.12%——不是任何一方「算错了」，而是一部分此前无法解释的增长被归还给了一项此前无法观测的投入。这正是增长核算精细化的一贯逻辑：核算的进步总是表现为残差的缩小。

12.4 从残差测度到过程观测：贡献的显性分离

12.4.1 扩展核算恒等式与三项性质

在式(12-5)的弹性估计到手之后，增长核算即可由回归转入分解。把估计所得的四项弹性代回增长率恒等式，地区*i*在时期*t*的全要素生产率增长率可由残差法恢复：

$$g_{A,it} = g_{Y,it} - \hat{\alpha}_K g_{K,it} - \hat{\alpha}_L g_{L,it} - \hat{\alpha}_D g_{D,it} - \hat{\alpha}_T g_{\tilde{T},it} \quad (12-7)$$

其中， $g_{X,it}$ 表示变量*X*在地区*i*、时期*t*的增长率， $\hat{\alpha}$ 为式(12-5)的估计值。

式(12-7)与传统核算式(12-1)的差别只在于多减去了两项，但这两项带来的是核算能力的质变，可归纳为三项性质。第一是可加性：由于标准词元经效值折算后满足可加公理，不同模型档位、不同任务类型的词元用量可以直接相加，因而 $g_{\tilde{T},it}$ 可以自下而上从企业、行业、城市逐级加总，也可以自上而下分解，这是任何多维评价得分向量都不具备的性质。第二是可归属性：每一次词元调用都绑定主体、时刻、模型与场景，因而贡献可以被归属到具体地区、具体行业乃至具体企业，使增长核算第一次具备了与微观管理对接的粒度。第三是高频性：词元调用量是日度可观测的，其核算频率远高于以年度为主的传统要素统计，这意味着人工智能的增长贡献可以被按季甚至按月监测，从事后评估变为事中观测。

这三项性质合起来，为把词元纳入正式统计口径提供了技术可行性，而制度条件亦已初步具备。全国科学技术名词审定委员会 2026 年 3 月 25 日发布公告，优先推荐并面向全社会发布试用 token 的中文名「词元」，将在常态化审定中最终确认；同月，国家数据局局长在中国发展高层论坛 2026 年年会上使用并推介该译名，提出词元「可计量、可定价、可交易」。术语的统一与经济属性的确认，是任何一个变量进入核算体系的前置条件——正如标准煤之于能源统

计、标准箱之于航运统计。已有研究表明，标准化本身即具有可观测的生产率效应，物流标准化显著提升了企业全要素生产率（何凡等，2025），其机制正是交易费用的节约与计量口径的统一。本书主张，词元计量标准的建立同样具有这一性质：它不只是统计工作的便利，其本身即是一项生产性的制度投资。

12.4.2 贡献率、残差纠偏与两条测算路径的对话

在式(12-7)的基础上，可以定义两个便于政策解读的指标。其一是标准词元流量对产出增长的贡献率，即词元贡献占实际增长率的比重；其二是遗漏词元变量所导致的残差高估幅度：

$$s_{T,it} = \frac{\hat{\alpha}_T g_{\tilde{T},it}}{g_{Y,it}}, \Delta_{it} = g_{A,it}^{(0)} - g_{A,it} \quad (12-8)$$

其中， $s_{T,it}$ 为词元贡献率， Δ_{it} 为残差高估幅度，上标(0)仍表示传统两要素核算口径。

这两个指标使本书的测算能够与既有文献展开实质性对话，但对话必须建立在口径对齐的前提上。悲观侧的经典测算走的是「事前推算」路径：以希尔滕定理为工具，由任务暴露比例、可自动化比例与单位成本节约三项参数推算全要素生产率的上限（Acemoglu，2025）。这条路径的优点是逻辑闭合、参数透明，缺点是三项参数均须外生设定，且其结论是十年累计的全要素生产率增幅。本书走的是「事后核算」路径：由可观测的过程量与估计的产出弹性直接计算要素贡献，其结论是当期产出增长中的要素贡献份额。两条路径在量纲上并不重合——一个是全要素生产率渠道的十年累计效应，一个是要素投入渠道的年度贡献——因此绝不能把二者的数值直接相减或相比。恰当的对话方式是承认二者的互补性：事前推算给出人工智能经由任务替代影响效率的潜在上限，事后核算给出人工智能作为一种被实际购买和使用的生产性服务所贡献的现实份额；前者回答「最多能有多少」，后者回答「已经发生了多少」。

12.4.3 配置判据：边际产出与市场价格的比较

增长核算的框架还提供了一个此前各章未曾使用的分析工具。在式(12-5)的设定下，标准词元流量的边际产出为 $\alpha_T Y_{it} / \tilde{T}_{it}$ ，而其市场价格即第7章编制的标准词元价格 $\tilde{p}_t$ 。定义二者之比为词元配置比：

$$RT C_{it} \equiv \frac{\hat{\alpha}_T Y_{it}}{\tilde{p}_t \tilde{T}_{it}} \quad (12-9)$$

其中， $\tilde{p}_t$ 为标准词元价格， RTC 取自「词元配置比」的英文缩写，衡量边际产出与要素价格之比。

在完全竞争且无调整成本的最优配置下，要素使用应满足边际产出等于要素价格，即 $RTC_{it}=1$ 。 $RTC_{it}>1$ 意味着边际产出高于价格，词元投入不足，扩大使用可以提高产出； $RTC_{it}<1$ 则意味着过度采购，边际产出已低于所付价格。这一判据把本章的增长核算与第 8、9 章的配置分析接通：第 8 章测得企业对所购词元效值的认知偏差均值为 0.44、由此导致低效值档位过度采购的份额为 0.27，第 9 章测得有效效值利用率仅为 38%、统一调度后可升至 54%——这些结论在本章的语言中可以统一表述为：配置比在地区间与企业间高度离散，既存在 RTC 显著大于 1 的投入不足群体（多为中西部地区与中小企业），也存在 RTC 小于 1 的过度采购群体（多为受效值信息不对称误导的采购方）。政策含义随之明确：普惠包与技改补贴的合理边界，正是那些 RTC 显著大于 1 而受制于预算约束或能力约束的主体；对于 RTC 小于 1 的主体，正确的政策工具不是补贴而是效值披露。

12.4.4 动态结构：J 曲线与当期弹性的下界性质

最后需要处理的是时间维度。互补性无形投资的时滞意味着词元投入的产出效应不会在当期完全释放，当期弹性只是全部效应的一部分。把式(12-5)推广为分布滞后形式：

$$g_{Y,it} = \sum_{k=0}^K \alpha_T^{(k)} g_{\tilde{T},i,t-k} + \alpha_K g_{K,it} + \alpha_L g_{L,it} + \alpha_D g_{D,it} + g_{A,it} \quad (12-10)$$

其中， $\alpha_T^{(k)}$ 为滞后 k 期的词元流量弹性，累积弹性 $\alpha_T^{cum} = \sum_{k=0}^K \alpha_T^{(k)}$ 。

式(12-10)给出了两点重要判断。第一，在 J 曲线机制成立的条件下， $\alpha_T^{(0)}$ 通常小于 α_T^{cum} ，甚至在采用初期可能为负——企业刚刚接入词元服务时，流程尚未适配、员工尚在学习、旧流程与新工具并行，短期内确实可能出现产出扰动，这与基于美国普查局企业微观数据所观察到的模式一致。因此本章报告的当期弹性应当被读作全部效应的一个保守下界，而非全部效应本身。第二，样本期的长度构成了识别累积效应的硬约束：我国词元调用量的规模化扩张始于 2024 年，可用于估计长滞后结构的时间跨度尚不足以支撑对 α_T^{cum} 的稳健识别。本章因此选择只报告当期设定的估计结果，并在解释时始终强调其下界性质；随着样本期延长，滞后结构的识别将成为后续研究最有价值的推进方向之一。

12.5 增长核算实证：区域面板的估计与贡献分解

12.5.1 数据、变量测度与识别策略

本章的实证基于我国 248 个地级及以上城市 2022—2026 年的年度面板，共 1240 个观测。各变量的测度如下。被解释变量 Y_{it} 为按可比价计算的城市生产总值。资本投入 K_{it} 以永续盘存法核算的固定资本存量衡量，折旧率取通行设定，投资价格指数按分类固定资产投资价格平减。劳动投入 L_{it} 为经受教育年限质量调整的就业人数，以避免把劳动质量改善错记为技术进步。数据要素投入 D_{it} 参照全国数据资源调查的口径构造（「国家数据局，2026」），综合数据生产量、存储量与流通交易规模三项指标合成。核心解释变量 $\tilde{T}_{it}$ 为标准词元流量，其构造分两步：第一步按第 5 章的六档位效值系数把各档位物理词元用量折算为标准词元并加总，第二步以第 7 章编制的标准词元价格指数对名义口径作价格平减。互补性人力与组织资本 H_{it} 以人工智能相关从业人员密度与企业数字化转型强度合成，进入控制向量。

需要特别说明词元流量的档位结构假设。城市层面的分档位用量并无公开统计，本章按全国口径的用量份额结构对各城市作结构分解，再以各城市模型服务市场的构成加以调整。全国口径的档位份额为轻量蒸馏级 28%、中型通用级 34%、开源旗舰级 20%、旗舰闭源级 10%、推理增强级 5%、多模态级 3%，对应的用量加权平均效值系数为 1.425。全国总量的锚定则严格遵循国家数据局公布的四个官方点位：2024 年初日均 1000 亿枚、2025 年 6 月底突破 30 万亿枚、2025 年底 100 万亿枚、2026 年 3 月突破 140 万亿枚；其余时点的量值系按单调平滑约束作校准复算插值，官方未单独发布，正文与图表中凡涉及非官方点位者均已注明。这一处理保证了总量口径的可溯源性，同时也构成本章估计的第一项局限：档位结构的地区差异只能被近似刻画。

识别策略方面，式(12-5)的估计面临两类威胁。其一是反向因果：经济体量大、产业结构先进的城市既有更高的产出，也有更强的词元使用需求，简单回归会把这种同向性误读为因果效应。其二是遗漏变量：数字基础设施水平、营商环境、人力资本存量等因素同时影响产出与词元使用。本章的应对分三层。第一层是双向固定效应，吸收城市不随时间变化的禀赋差异与全国共同的年度冲击，这使识别来自城市内部的时序变动。第二层是控制变量，纳入产业结构、人力资本、数字基础设施与互补性组织资本 H_{it} ，切断主要的混淆路径。第三层是外生变动来源的利用：全国一体化算力网与国家算力枢纽节点的布局由能源禀赋、土地条件与国家战略决定，对单个城市的当期产出冲击近似外生（「国家发展改革委

等，2021」；国家发展改革委等，2023），可与历史通信基础设施水平共同构成工具变量组，用于检验基准结果的稳健性。经上述处理，估计所得的 α_T 可在谨慎意义上解释为标准词元流量的产出弹性。基准估计结果见表 12.1。

表 12.1 智能经济生产函数的估计结果

解释变量	产出弹性	t 值	占要素弹性合计的比重	投入翻倍的产出效应
资本投入（对数）	0.318*** (0.041)	7.76	39.9%	24.66%
劳动投入（对数）	0.276*** (0.038)	7.26	34.7%	21.08%
数据投入（对数）	0.094*** (0.026)	3.62	11.8%	6.73%
标准词元流量（对数）	0.108*** (0.024)	4.50	13.6%	7.77%
要素弹性合计	0.796	—	100.0%	—
城市固定效应	是	—	—	—
年份固定效应	是	—	—	—
R ²	0.86	—	—	—
观测数 N	1240	—	—	—

注：被解释变量为城市实际生产总值的对数；括号内为标准误，***表示在 1%水平显著；估计式为式(12-5)的双向固定效应设定，控制变量包括产业结构、人力资本、数字基础设施与互补性组织资本，其系数不在此报告；标准词元流量以标准词元价格指数平减，档位效值系数取自第 5 章。样本为 248 个地级及以上城市 2022—2026 年年度面板。数据来源：作者基于城市一年度面板校准复算。

表 12.1 显示，四项要素弹性分别为资本 0.318、劳动 0.276、数据 0.094 与标准词元流量 0.108，均在 1%水平显著，方程拟合优度为 0.86。三点结果值得展开。第一，资本与劳动仍是产出的主导要素，二者弹性之和占要素弹性合计的 74.6%，这与我国仍处在工业化中后期的基本判断一致，也提醒我们不要夸大人工智能在当下的总量作用。第二，四项弹性合计为 0.796，小于 1，呈规模报酬递减。这一结果在城市层面的生产函数估计中并不意外：城市层面存在拥挤效应，且本章未纳入中间投入与土地要素，其贡献被吸收进残差与固定效应。需要强调的是，规模报酬的具体数值并非本章关注对象，本章关注的是 α_T 的符号、显著性与量级。第三，也是最值得注意的一点，标准词元流量的弹性 0.108 已经超过数据要素的 0.094，为后者的 1.15 倍。四项弹性的点估计与置信区间如图 12.2 所示。




图 12.2 智能经济生产函数的估计系数

注：误差线为 95% 置信区间，柱内标注为稳健标准误；*** 表示在 1% 水平显著；估计设定与样本同表 12.1。数据来源：作者基于城市一年度面板校准复算。

图 12.2 把四项弹性的相对位置与估计精度直观呈现出来。资本与劳动的置信区间较宽而位置较高，数据与标准词元流量的置信区间较窄而位置较低，四者的区间均不覆盖零。其中数据与词元两项的区间存在显著重叠，这提示我们不宜过度解读二者点估计的大小顺序；真正具有实质意义的是另一层对比：数据要素是被存储与治理的信息资源存量，其弹性刻画的是「拥有多少信息」的产出效应；标准词元流量是信息被实际加工使用的服务流，其弹性刻画的是「使用了多少信息」的产出效应。在样本期内后者已不低于前者，说明智能经济的增长瓶颈正在从「数据够不够」转向「用得够不够」。这一判断与第 2 章对数据要素核算未竟之处的梳理相互印证：数据要素核算长期受困于缺乏统一计量单位、缺乏市场价格与权属难以界定三重困难（蔡跃洲和马文君，2021；罗玫等，2023），而词元在这三点上都具有结构性优势。就弹性的经济解释而言，标准词元流量翻倍将带来约 7.77% 的产出提升，这一量级在要素投入渠道中已相当可观。

12.5.2 增长贡献的分解：从千分之四到百分之六点八

把表 12.1 的弹性代入式(12-7)，即可完成 2022 至 2026 年的增长贡献分解，结果见表 12.2。

表 12.2 词元流量对产出增长的贡献分解（2022—2026 年）

年份	实际增长率	资本贡献	劳动贡献	数据贡献	标准词元流量贡献	全要素生产率残差	词元贡献率
----	-------	------	------	------	----------	----------	-------

2022	5.2	2.71	0.42	0.13	0.02	1.92	0.4%
2023	5.4	2.66	0.38	0.19	0.04	2.13	0.7%
2024	5.0	2.44	0.31	0.24	0.06	1.95	1.2%
2025	5.1	2.36	0.28	0.31	0.18	1.97	3.5%
2026	5.0	2.22	0.24	0.38	0.34	1.82	6.8%

注：实际增长率与各项贡献的单位为百分点，各年五项贡献之和等于当年实际增长率，尾差为四舍五入所致；词元贡献率为标准词元流量贡献占实际增长率的比重，即式(12-8)的 s_T ；2026年为按前三季度进度年化的校准复算值。数据来源：作者基于城市一年度面板校准复算，词元流量总量锚定国家数据局公布的四个官方方位。

表 12.2 呈现的是一条陡峭的上升轨迹。标准词元流量对产出增长的直接贡献由 2022 年的 0.02 个百分点升至 2026 年的 0.34 个百分点，五年扩大 17 倍、绝对增加 0.32 个百分点；词元贡献率由 0.4% 升至 6.8%。把这条轨迹与其他要素并置观察，可以读出更完整的结构变化。资本贡献由 2.71 个百分点降至 2.22 个百分点，占实际增长率的比重由 52.1% 降至 44.4%；劳动贡献由 0.42 降至 0.24 个百分点，反映人口结构变动的长期趋势；与此相对，数据与标准词元流量两项新要素的合计贡献由 0.15 个百分点升至 0.72 个百分点，占实际增长率的比重由 2.9% 升至 14.4%。这一「旧要素退、新要素进」的结构切换，正是数字经济与智能经济相关文献所反复论证的增长动能转换在核算层面的直接呈现（蔡跃洲和陈楠，2019；陈彦斌等，2019；任英华等，2023）。

贡献率的跃升还提供了一次有价值的内部一致性检验。由式(12-8)反解，2026 年词元贡献 0.34 个百分点对应的标准词元流量增长率约为 315%，2025 年对应约 167%。这一量级与国家数据局公布的官方序列相互吻合：2025 年底日均调用量 100 万亿枚，2026 年 3 月突破 140 万亿枚，三个月增长四成以上。需要说明的是，标准词元流量的增长率与物理调用量的增长率并不相等，二者之差恰为用量加权平均效值系数的变动率，即 $g_{\bar{T}} = g_T + g_{\eta}$ 。在样本期内，高效值档位的用量占比上升与低价轻量档位的普及同时发生，两股力量部分抵消，使平均效值的变动幅度小于调用量本身的变动幅度。这一恒等式也提示了一个政策观测点：若某一时期调用量高速增长而标准词元流量增长明显滞后，说明用量扩张主要来自低效值档位的替代，其增长含金量应当被打折看待。各要素贡献的完整结构如图 12.3 所示。




图 12.3 词元流量对产出增长的贡献分解（2022—2026 年）

注：左轴为各要素对产出增长率的贡献（百分点），柱顶标注为当年实际增长率；右轴折线为标准词元流量贡献占实际增长率的比重。数据来源：同表 12.2。

图 12.3 的堆叠结构清晰显示了三个层次的变化。最下层的资本贡献带逐年变薄，劳动贡献带持续收窄，二者共同构成传统动能的收缩；中间的数据贡献带与标准词元贡献带逐年增厚，且后者的加速明显快于前者，2025 年之后成为增量最快的一层；最上层的全要素生产率残差带则保持相对稳定，并未因新要素的引入而出现结构性变化——这一点尤其重要，它说明词元变量所吸收的并非残差的全部，而只是其中可由过程量解释的那一部分。右轴折线的形状则揭示了本章最核心的定量事实：词元贡献率从 2022 年的 0.4% 起步，2024 年仍仅 1.2%，2025 年跃至 3.5%，2026 年达到 6.8%。曲线在 2024 至 2025 年间的斜率突变，与调用量在同期由日均个位数万亿枚跃升至百万亿枚量级的时点高度对应（其间各季度点位系校准复算插值，官方未单独发布），说明贡献率的跃升并非估计伪像，而是使用强度真实扩张的核算映射。

12.6 与资本服务测度传统的对话与稳健性

12.6.1 四种核算传统的比较与本书的定位

本章的方法论并非无源之水。把增长核算史上四次重要的口径扩展并置比较，可以清楚地看到本书工作在其中的位置，如表 12.3 所示。

表 12.3 四种增长核算传统的比较与本书的定位

核算传统	被显性化的遗漏	关键可观测变量与权重	残差含义的变化	主要局限
索洛残差核算	无（残差为技术	资本存量、劳动	残差 = 技术进步	残差含义含混，

	进步的代理)	人数；要素收入 份额为权重	+一切未观测因 素	不可归因、不可 考核
乔根森资本服务 核算	资本的质量异质 性与使用强度	分资产类别的资 本服务流；使用 者成本为权重	残差缩小，资本 贡献显性化	依赖资产市场租 金率，服务流不 可直接观测
无形资产资本化 核算	研发、软件与组 织资本等无形投 入	无形投资支出； 折旧率与资本化 率为参数	残差进一步缩 小，J曲线的下 沉段得到解释	互补性组织投资 难以从费用中剥 离，参数敏感
数据要素与数字 经济卫星账户	数据资源的生 产、流通与使用	数据生产量、存 储量与交易额； 成本法或收益法 估值	残差中的数字化 部分被部分归因	缺统一计量单 位、缺市场价 格、权属难界定
本书标准词元核 算	认知服务的实际 使用强度	标准词元流量； 效值系数折算、 标准词元价格指 数平减	人工智能贡献由 残差中显性分 离，残差再缩小	档位结构须近 似、样本期短、 滞后效应未识别

注：资料来源为作者据增长核算与数据要素核算相关文献整理，其中数据要素与卫星账户一行综合了数字经济增加值测算、数字化转型统计创新与卫星账户编制方案的既有工作（杨仲山和张美慧，2019；许宪春等，2021；蔡跃洲和牛新星，2021），无形资产资本化一行的机制表述参照生产率J曲线框架（Brynjolfsson等，2021）。

表 12.3 揭示出一条贯穿百年的方法论主线：每一次核算进步，都是把某类此前只能沉入残差的贡献，通过发现合适的可观测变量与合适的权重，归还给一项具体的投入。乔根森传统解决的是「资本的质与量如何区分」，其关键在于使用者成本提供了加总异质资产的价格权重；无形资产资本化解决的是「费用与投资如何区分」；数据要素核算试图解决「信息资源如何入账」，但受阻于计量单位、价格与权属三重困难。本书的工作与乔根森传统在方法论上最为同构：资本服务的加总需要使用者成本作为权重，标准词元的加总需要效值系数作为权重；前者把不同资产折算为同质的资本服务流，后者把不同模型、不同任务的词元折算为同质的标准词元流。二者的差别在于，资本服务的权重可由资产市场的租金率间接推断，而词元服务缺乏成熟的租赁市场，其权重必须由公理化的折算函数构造——这正是第 5 章全部工作的意义所在。就这一点而言，本书对既有传统的推进不在于提出了新的核算恒等式，而在于为一类此前无法加总的新型投入构造了可用的加总权重。

12.6.2 残差纠偏的量级与区域异质性

本书框架相对传统核算的净效果，集中体现在残差的纠偏上。将同一样本分别按传统两要素口径与本书四要素口径核算，结果如图 12.4 所示。




图 12.4 引入词元前后全要素生产率残差的对照

注：(a) 两根柱分别为遗漏与纳入标准词元流量两种设定下 2022—2026 年的年均全要素生产率增长率；(b) 为 2026 年分区域标准词元流量对产出增长的贡献率。数据来源：作者基于城市一年度面板校准复算。

图 12.4(a)显示，不引入词元变量时全要素生产率残差为 2.41%，引入后降至 2.12%，残差高估 0.29 个百分点，相对高估幅度达 13.7%。这一数值的解读需要两点谨慎。其一，0.29 个百分点并不等于各年词元直接贡献的简单平均，因为遗漏还会通过式(12-2)的后两项污染资本与劳动的弹性估计，纠偏效果包含了这部分间接影响。其二，残差的缩小不应被理解为「技术进步变慢了」，而应理解为「我们对增长来源的无知减少了」——原本被记作无法解释的每年 0.29 个百分点，现在有了明确的归属对象、可观测的载体与可追溯的凭据。按本章的推断，随着词元流量继续扩张，若核算口径不作调整，这一高估幅度还将逐年扩大，传统口径的全要素生产率将越来越成为一个被人工智能使用强度所污染的指标。

图 12.4(b)的区域结构则揭示了一个初看反直觉的事实：2026 年标准词元流量对产出增长的贡献率，东部为 8.4%、中部为 5.1%、西部为 3.6%，东部约为西部的 2.33 倍、为中部的 1.65 倍。反直觉之处在于，在「东数西算」工程的推动下，新增智能算力的相当部分布局在西部枢纽节点，算力产能明显西移，而词元的增长贡献却高度集中在东部。这一背离恰恰印证了本书的核心命题：增长贡献不产生于算力产能，而产生于词元的实际使用与场景落地。西部拥有的是生产端的产能，东部拥有的是需求端的场景密度与效值结构——东部产业体系对高效值档位与高场景效用任务的需求更为集中，其单位词元所承载的价值密度更高。这一发现为区域政策提供了明确指向：西部枢纽的价值实现不能停留在算力出租，必须依托跨区域的统一计量与统一结算把产能转化为可计价、可入账的标准词元流量，这正是第 10 章「五个统一」机制设计的核算依据；同时，算力共

享与算力市场培育的需求侧研究亦表明，配置效率的改善高度依赖于需求信息的有效传导（许诺等，2025；王勇等，2025）。

12.6.3 稳健性检验与研究局限

本章围绕四个方向设计了稳健性检验。第一，口径替换：以物理词元调用量替代标准词元流量重新估计。按式(12-6)的预期，该设定下的系数将随各期档位结构的变动而漂移，且不同子样本间缺乏可比性，检验的目的正是展示口径不一致所导致的不稳定，而非提供一个竞争性估计。第二，平减指数替换：以词元价格指数代替标准词元价格指数平减，用以量化第 12.2.3 节所述的实物量虚增效应。第三，样本调整：剔除 2026 年这一年化推算年份，以及剔除词元用量占比极端的少数城市，检验结果是否由个别观测驱动。第四，识别策略替换：以国家算力枢纽节点布局与历史通信基础设施水平构造工具变量组重新估计。上述检验的共同目的是确认 α_T 的符号与显著性不依赖于特定设定，而其点估计的具体数值应被理解为一个受口径选择影响的区间中心，而非精确常数。

本章的局限同样需要如实交代，共有四点。其一，测度局限：城市层面的分档位词元用量并无公开统计，本章的档位结构分解依赖全国口径的近似，若地区间档位结构差异远大于本章设定，标准词元流量的地区离散度将被低估， α_T 的估计随之受到影响。其二，期限局限：样本期仅覆盖词元规模化扩张的最初数年，式(12-10)所刻画的滞后结构与累积弹性尚无法稳健识别，本章报告的当期弹性只是全部效应的下界。其三，内生性局限：词元价格与用量在市场层面同时决定，本章虽以固定效应与工具变量缓解，但未建立价格与用量的联立方程系统，第 8 章的需求侧估计与本章的生产侧估计尚未在同一框架内整合。其四，边界局限：跨境词元服务的进出口未单列核算，词元出海所形成的对外服务贸易及其增长贡献尚未纳入，这在词元服务出海快速推进的背景下是一处实质性的口径缺口。这四点局限也构成了后续研究的自然议程。

12.7 本章小结

本章完成了标准词元第四重经济职能的兑现：作为增长核算变量，把人工智能的增长贡献从索洛残差中显性分离出来。全章的论证可归纳为四个层次。第一层是问题的诊断。索洛生产率悖论在人工智能时代再现，围绕其成因的争论中，悲观侧以希尔滕定理推算十年累计全要素生产率增幅的上限，乐观侧以生产率 J 曲线解释统计的暂时沉默，而大量机构测算与微观实验在两侧之间形成密集的证据带。本章首先厘清了三条口径纪律——全要素生产率不同于劳动生产率、十年

累计不同于年度增量、任务级实验不同于宏观统计——并指出所谓「相差数十倍的对立」有相当部分是违反这些纪律的比较人为制造的。在四类经典解释之外，本章提出第五类也是当下最具约束力的一类解释：过程量缺失。人工智能的投入端与产出端各有统计，唯独连接二者的使用过程缺乏可加的计量单位，这使核算者只能在「按支出额记入」与「留在残差里」之间二选一。

第二层是框架的构建。本章把标准词元流量界定为一种中间性的认知服务流，其经济性质最接近资本服务流；以不变替代弹性形式刻画词元与互补性人力组织资本合成认知服务的内层结构，再与资本、劳动、数据要素共同构成外层总量生产函数；经对数线性化得到可估计式(12-5)，并给出关键分解 $\alpha_T = \alpha_Z s_T$ ——标准词元流量的产出弹性等于认知服务的产出弹性与机器认知份额之积。这一分解解释了当前弹性何以中等偏小，也预示了它必将随机器认知份额上升而增大。本章还以式(12-6)的遗漏变量偏误公式证明，若以物理词元口径入式，系数将随档位结构变动而漂移、符号甚至可能翻转，从而在核算层面重申了第5章折算体系的必要性：折算不是为了让数字好看，而是为了让系数有意义。在此基础上，本章给出了三项工具：式(12-7)的残差恢复式及其可加、可归属、高频三项性质，式(12-8)的贡献率与残差纠偏指标，以及式(12-9)的词元配置比判据——后者把增长核算与第8、9章的配置分析接通，并明确了补贴与效值披露两类政策工具的适用边界。

第三层是实证的结果。基于248个地级及以上城市2022—2026年的年度面板（1240个观测），四项要素弹性分别为资本0.318、劳动0.276、数据0.094与标准词元流量0.108，均在1%水平显著。标准词元流量的弹性已达数据要素的1.15倍，意味着智能经济的增长瓶颈正由「数据够不够」转向「用得够不够」。增长贡献分解显示，标准词元流量对产出增长的直接贡献由2022年的0.02个百分点升至2026年的0.34个百分点，贡献率由0.4%升至6.8%；同期数据与词元两项新要素的合计贡献占实际增长率的比重由2.9%升至14.4%，而资本贡献占比由52.1%降至44.4%，增长动能的切换在核算层面清晰可见。残差纠偏方面，不引入词元变量时全要素生产率残差为2.41%，引入后降至2.12%，高估0.29个百分点、相对高估13.7%。区域结构上，2026年东部、中部、西部的词元贡献率分别为8.4%、5.1%与3.6%，东部约为西部的2.33倍——在算力产能明显西移的背景下，这一背离有力地印证了增长贡献产生于词元的实际使用而非算力产能本身。

第四层是方法论的定位与限度。把本书工作放回增长核算史，其与乔根森资本服务传统在方法论上最为同构：资本服务的加总需要使用者成本作为价格权

重，标准词元的加总需要效值系数作为折算权重；差别在于前者可由资产市场租金率间接推断，后者因缺乏成熟租赁市场而必须由公理化折算函数构造。因此本书对核算理论的推进不在于提出新的恒等式，而在于为一类此前无法加总的新型投入构造了可用的加总权重。同时必须承认四点局限：档位结构的地区分解依赖近似、样本期过短使滞后结构与累积弹性无法稳健识别、价格与用量的联立性尚未在统一框架内处理、跨境词元服务的进出口尚未纳入核算边界。就政策含义而言，本章的结论指向一个明确方向：把标准词元流量纳入常态化统计，与全国数据资源调查等既有制度衔接，是使人工智能的增长贡献从「事后推断」变为「事中观测」的前提；而计量口径的统一本身即是一项生产性的制度投资。本章的核算结论将与第 13 章的多案例证据作三角验证，并在第 14 章转化为具体的统计与政策建议。

第 13 章 区域实践与多案例研究

前十二章沿计量、定价、配置三条线索完成了理论建构与定量检验：第 5 章给出标准词元的公理化折算体系，证明折算后单位价格的变异系数由 0.92 降至 0.31；第 7 章把词元价格分解为成本底价、效值溢价与场景租金三层，编制了物理词元价格指数与标准词元价格指数；第 9 章把利用率悖论分解为空转、批次、匹配与效值四项损失，测得统一调度可把有效效值利用率由 0.38 提升至 0.54；第 10 章以比较制度分析与三方演化博弈刻画城市词元运营中心的组织模式，解出企业深度采纳的临界红利 1.55；第 12 章把标准词元流量引入生产函数，测得其产出弹性 0.108、2026 年对产出增长的贡献率 6.8%。这些结论建立在校准复算的总量数据与形式化模型之上，其解释力究竟能否在具体的城市、平台与企业中得到印证，模型未曾言明的边界又在哪里，需要一类不同性质的证据来回答。本章的任务正在于此。

本章选择多案例研究而非单一案例，理由有三。其一，词元运营中心的出现具有罕见的同时性：2026 年 7 月 15 日至 8 月 11 日不到一个月之内，温州、嘉兴、广州、苏州先后启动词元运营或交易服务机构，上海市经济和信息化委员会于同期印发《上海市软件和信息服务业发展「十五五」规划》，提出「探索将词元、数据治理、大模型部署及再训练等投入，纳入企业技术改造支持方向」（「上海市经济和信息化委员会，2026」）。同一制度任务在几乎相同的时点由五类性质迥异的主体分别承担，构成了一次难得的天然比较实验，单一案例无法利用这一结构性变异。其二，本书的核心命题是计量单位的经济职能，而计量制度的效力恰恰体现在跨主体、跨地域的可比性上；只考察一地，无从判断所观察到的机制是普遍的还是特异的。其三，第 10 章已给出资产禀赋—职能匹配的理论预测，理论预测的检验需要多个观测点，复制逻辑要求案例之间既有理论上的相似复制，也有理论上的差别复制。

与前几章相比，本章面对的证据环境更为复杂。词元经济的公共信息高度媒体化，大量数字经由转述、聚合与二次加工进入公共视野，其原始出处、统计口径与时点常常不可回溯；企业方发布的效率倍数缺乏第三方测评背书；不同城市自定的能力清单条目数被媒体径直用于横向比较。若不加甄别地把这些材料并列排版，读者会默认它们具有同等的可信度，案例研究反而会成为错误结论的放大器。因此本章把「证据分级」明确列为方法的组成部分：先界定证据类型与可信度层级，再规定各层级证据的使用规则，凡未获第三方证实的流传数字一律不予

采信，仅在必要时作为待检验的行业传闻列示。这一处理本身也构成本章的一项方法论贡献。

本章安排如下：13.1 节说明案例选择逻辑、分析框架与资料来源，给出证据分级规则；13.2 节以长三角（嘉兴）词元运营中心为深度案例，考察其算力禀赋、组织形态、职能设计与机制落地；13.3 节把五个案例纳入统一的能力画像框架作跨案例比较，给出能力合成指数与短板判据；13.4 节转向企业侧，考察供给侧的词元优化工厂与需求侧的若干应用场景，并说明一则未获采信的案例及其方法论意义；13.5 节以扎根理论程序对深度访谈资料编码，识别企业采纳词元服务的障碍结构并测度其集中度；13.6 节把案例证据与前述定量结论逐条对照，构造三角验证的一致性指数；13.7 节为本章小结。

13.1 案例设计、分析框架与资料来源

13.1.1 研究问题与案例选择逻辑

本章要回答三个层层递进的问题。第一，五类主体在承担同一制度任务时，其能力结构是否如第 10 章所预测的那样，沿资产禀赋的方向系统分化？第二，若分化确实存在，它对企业的接入决策意味着什么——五项能力之间是可以相互替代的，还是互补的？第三，企业侧观察到的采纳障碍，与前几章从总量数据与形式化模型得到的结论是否指向同一组机制？三个问题分别对应跨案例比较、能力合成与三角验证三项工作。

案例的选择遵循理论抽样而非统计抽样，判据有三条。第一条是主体类型的互异性：入选案例的运营主体必须分属第 10 章界定的五类主体之一，且不重复，以最大化跨案例的结构性变异。第二条是时点的可比性：入选案例的启动或印发时点须集中于同一制度窗口，以尽量排除宏观环境差异对能力表现的干扰。第三条是信息的可核验性：入选案例须具备可回溯到权威媒体或政府部门的公开报道，且关键职能表述在两个以上独立来源中一致。按此三条判据，长三角（嘉兴）Token 运营中心（城投集团）、中国电信（江苏）Token 运营中心（基础电信运营商，落址苏州）、东南 Token 运营中心（数据集团，温州）、广东词元交易和服务中心（数据交易所，广州南沙）与上海的政策工具路径（政策制定者）共五例入选。

同一制度窗口内还有若干实践未进入主案例序列，其理由须予说明，否则会造成选择性取样的印象。北京于 2026 年 7 月发布国资背景的标准化词元工厂，另有企业方于同年 6 月在亦庄建成一期日产能 1.4 万亿枚词元的词元工厂；扬州于 2026 年 7 月成为江苏省首个推出词元券专项政策的城市，此前已于 2024 年

5月推出算力券补贴。这些实践重要，但属于不同的产业环节：词元工厂位于推理产能的供给侧，其绩效语言是日产能；词元运营中心位于流通服务侧，其绩效语言是接入模型条目数与服务企业数；交易中心则属交易场所侧，其绩效语言是场内成交与凭证出具。三类主体的「首个」称号各带限定语，若混同排列会出现多个「全国首个」互相冲突的窘境。因此本章把词元工厂与券类政策作为对照性旁证纳入13.4节讨论，不进入五案例的能力比较，以保证比较对象在产业环节上同质。这一处理也提示了区域实践研究的一条基本纪律：跨案例比较的前提是环节同质，环节不同则指标不可比。

五个案例在理论上兼具相似复制与差别复制。相似复制体现于：五地无一例外把「计量」置于核心职能位置——嘉兴门户以「统一词元计量」为五项治理能力之一，广东中心牵头构建全省统一词元计量规则并出具交易凭证，温州以「用能可证」作为绿色词元认证的三项可证之一，苏州中心设指标监测服务。若理论预测「计量是词元流通的第一约束」为真，则五案例应当共同显示这一点，事实确实如此。差别复制体现于：五类主体的资产禀赋不同，理论预测其能力短板应沿禀赋的反方向出现，这一预测在13.3节将被逐一检验。

13.1.2 分析框架：案例—能力矩阵与三角验证

为使五个案例可比，本章建立统一的分析框架。框架的第一层是案例—能力矩阵：以五个案例为列、五项能力维度为行，矩阵元素为该案例在该维度上的证据编码。五项能力维度的选取直接对应企业接入词元服务时依次遭遇的五道关口——能不能便捷接入（接入便利）、用了多少能否说清（计量透明）、花费是否可预期（成本可控）、合规与安全能否交代（合规可信）、可用的模型与应用是否丰富（生态丰度）。五项维度既覆盖了第10章「五个统一」所针对的交易费用类型，也覆盖了13.5节扎根编码所得的四个核心范畴，从而使案例证据、制度设计与企业感知三者落在同一坐标系内。框架的第二层是跨案例比较：先在维度内作模式求同，识别复制逻辑所预测的共性；再在案例间作差异归因，把能力差异回溯到资产禀赋条件与机制组合。框架的第三层是三角验证：把案例证据与定量结论、理论预期三者对照，检验结论的收敛性与稳健性。完整框架如图13.1所示。




图 13.1 多案例研究的分析框架

图 13.1 的结构隐含了三项方法论承诺，需要在此说明。第一，矩阵元素是「证据编码」而非「打分」：每个单元格首先要求深度访谈、政策文件与实地观察三源互证，只有在三源不冲突时才进入后续的量化处理，任何单一来源的表述都不足以支撑一个单元格。第二，跨案例比较分为求同与归因两步，顺序不可颠倒：先确认哪些特征是五案例共有的，才能判断哪些差异是真正需要解释的；若一开始就聚焦差异，很容易把共性误认为某一案例的独有优势。第三，三角验证的三个来源在认识论上并不对称：定量结论提供总量层面的规律，理论预期提供机制层面的方向，案例证据提供情境层面的具体形态；三者一致只能提高结论的可信度，不能替代因果识别。本章在 13.6 节将明确这一限度。

13.1.3 资料来源、证据分级与效度保障

本章的资料由七类构成，其可信度层级与使用规则须事先规定。政策文件与规划文本、政府部门发布的统计与产业数据属一手官方来源，是可信度最高的一类，本章直接引用并照录原文措辞——例如上海的表述是「探索将……纳入」，属探索性安排，本章不得改写为「已纳入」。权威媒体报道属第二层级，其内容多为对发布会与揭牌仪式的转述，本章引用时标注报道口径与日期。企业方与平台方的自述属第三层级，包括产品性能、兼容硬件数量与效率倍数等，此类数字

缺乏第三方测评背书，本章仅作机制性佐证，逐条标注「企业方口径」，且不与官方统计并列排版。深度访谈与实地观察属本章自采资料，经三源互证后进入编码。最后一类是未获第三方证实的流传数字，本章不予采信。各类资料的来源、规模与使用规则见表 13.1。

表 13.1 案例资料的来源、证据层级与使用规则

证据类型	主要来源	规模或范围	层级	本章使用规则
政策文件与规划文本	省市级五年规划纲要、省级词元经济专项政策、算力枢纽与一体化算力网实施文件	国家级 4 件、省市级 5 件	A	直接引用并照录原文措辞，不作程度上的改写
官方统计与部门发布	国家数据局调用量口径、省经信部门产业数据、市发展改革部门能源实施计划	涉及 3 省市、5 个统计口径	A	引用须同时标注发布主体、口径与时点，不同口径不作同比
权威媒体报道	通讯社、党报、行业主管部门主办媒体与主流财经媒体对启动仪式与职能的报道	五案例合计不少于两个独立来源	B	标注报道口径与日期；关键表述须两源以上一致方予采用
平台公开界面与功能清单	门户网站的服务菜单、可调用模型条目数、专区与凭证设置	5 个平台门户	B	仅用于识别职能类型，不用于跨城的条目数量比较
深度访谈	平台方、企业方、政府方与服务商四类受访者的半结构化访谈	47 份（平台方 12、企业方 18、政府方 9、服务商 8）	B	三源互证后进入开放编码；引述一律匿名化处理
企业方与平台方自述	产品发布材料所载的吞吐能力、兼容硬件与适配模型数量、效率提升倍数	涉及 3 类主体	C	仅作机制性佐证，逐条标注「企业方口径」，不与官方统计并列
未获证实的流传数字	媒体或自媒体转述而无法回溯到一手来源的企业效率倍数、平台上架数量等	识别出 5 项	D	不予采信，必要时仅作为待检验的行业传闻列示并说明理由

注：层级 A 为一手官方来源，B 为可交叉核验的公开与自采资料，C 为主体自述，D 为不可回溯来源；公开资料的检索与交叉核验截至 2026 年 8 月中旬。访谈份数与编码结果为本章质性研究的自采口径。

表 13.1 的分级规则在本章有直接而具体的后果，至少体现在四处。其一，某地词元运营中心「已上架若干技能工具与智能体」的表述在多组检索中均未命中可回溯的来源，本章不予采用，改以该中心启动会集中发布的生态平台作为生态建设的证据。其二，某地海上风电「装机量全省第一」的说法与现有来源不符，可核验的口径是规划容量占浙江全省一半以上、2025 年清洁能源装机占比

超过 45%，本章按可核验口径表述。其三，某市规上工业企业数与人工智能企业数在流传版本与权威口径之间存在出入，本章一律采用省级经济和信息化部门与权威媒体披露的口径并标注年份。其四，某企业智能设计平台的三项效率数字全部无法回溯，本章不作为案例证据使用，其处理方式详见 13.4.4 节。这四处处处理并非吹毛求疵：区域实践研究的最大风险恰恰在于，看似丰富的公开材料实际上大量互相转述、层层放大，若不设分级门槛，案例研究的经验基础便无从谈起。

效度保障还包括三项常规安排。构念效度方面，五项能力维度的操作化定义在编码前固定，编码过程中不再调整，避免为迁就材料而改动构念。内部效度方面，本章对每一项因果性表述都要求给出机制链条，而非仅给出相关性；凡机制链条不完整者，一律降格为描述性发现。外部效度方面，本章的结论适用范围限定于产业密度较高、已具备一定算力基础的城市，第 10 章式(10-5)已经指出统一入口存在规模门槛，低于门槛的中小城市的正确选择是接入区域平台而非自建，本章的能力比较不宜外推至该类城市。

13.2 长三角（嘉兴）词元运营中心深度案例

13.2.1 案例背景：算力禀赋、产业底数与制度条件

选择嘉兴作为深度案例，首先因为它同时具备三项条件：厚实的算力禀赋、密集的制造业需求与明确的省级制度接口，三者恰好对应词元运营中心成立所需的供给、需求与治理三方面前提。就算力禀赋而言，嘉兴的位置由国家层面的枢纽布局决定。2022 年国家发展改革委等部门同意长三角地区启动建设全国一体化算力网络国家枢纽节点，规划设立长三角生态绿色一体化发展示范区数据中心集群与另一处集群，其中示范区集群的起步区落在上海青浦、江苏苏州吴江与浙江嘉兴嘉善三地。严谨的表述是嘉兴（嘉善）属于长三角国家枢纽节点的起步区，而非单独获批为一个国家枢纽节点，媒体常见的简化说法应予校正。此后国家层面进一步部署全国一体化算力网建设（国家发展改革委等，2023），为跨域调度提供了制度框架，也为城市级平台的接入预留了通道（「国家发展改革委等，2021」）。

在此框架下，嘉兴形成了以嘉善、平湖、桐乡三地为支点的算力集聚格局：嘉善重点培育三个万卡级智算中心，其中一家运营商的智算中心总投资约 50 亿元、规划智算规模 15000P；平湖的国际信息港已投用两栋智算楼，算力规模 3.2 万 PFLOPS；桐乡的国家超算中心浮点运算峰值为每秒 18 亿亿次，是全国第 14 个、浙江唯一的国家超算中心。这里必须强调一条计量纪律：超算中心的每

秒 18 亿亿次是超算峰值算力，通常按双精度理论峰值计；而 3.2 万 PFLOPS 等数字是智算规模，业内多按半精度或更低精度折算。两者的精度基准不同，既不可相加，也不可换算，把二者放在同一句话里做加法是区域算力叙事中最常见的错误。就总量而言，公开报道对嘉兴已投运算力的表述随时点与口径变化，可核验的区间是约 8.5 万至 11.8 万 PFLOPS，长期占浙江省已投运或已建算力规模的 50%至 60%，居全省首位；已投运万卡集群 11 个，按规划全部建成后算力规模将达 27.6 万 PFLOPS。占比的分子分母都在变动——「已投运」与「在建加投运」是两条不同的曲线，而浙江省提出的全省智算规模目标又在扩张分母——因此不同年份的占比不宜连读为趋势。

就产业底数而言，嘉兴的特征是制造业规模大、研发组织化程度高，这决定了其词元需求的结构。可核验的权威口径显示，2023 年嘉兴规上工业企业 6714 家，规上工业产值 1.46 万亿元、增加值 2933.6 亿元，三项指标均列浙江省第三；至 2026 年，全市规上工业企业中已有 5065 家设立研发机构，设置率 74.3%，连续五年居全省首位。人工智能领域的口径需要单独交代：智能物联规上企业 441 家，其中人工智能企业 188 家（2023 年口径）；另有表述为规上人工智能产业企业近 200 家，人工智能产业年营收 767.7 亿元、居浙江第三。需要提醒的是，规上工业企业数出自统计部门的工业统计制度，人工智能企业数出自经济和信息化部门的产业口径，两者统计制度不同，相除得出的所谓「人工智能渗透率」在方法上是无效的。本章因此只把这两组数字分别用于刻画需求规模与需求密度，不作比值运算。

就制度条件而言，浙江省的第十五个五年规划纲要在「构建新型算力体系」部分明确提出「建立全省一体化算力监测调度平台」，同时要求推动算电协同布局与就地消纳（「浙江省人民代表大会，2026」）。这一条款为城市级词元运营中心提供了上位的制度接口，但也带来一个必须厘清的层级问题：全国一体化算力网、省级一体化算力监测调度平台与城市级词元运营平台分属三个层级、三套接入范围，各平台上报的算力规模之间存在重复计算，不可加总。能源条件同样构成嘉兴的比较优势：其海上风电送出工程已于 2024 年 11 月在平湖投运，若干海上风电项目合计 188 台风机构成长三角地区最大的海上风电集群；2025 年新增光伏装机 80 万千瓦以上。算电协同的可行性由此获得物理基础，也为第 11 章讨论的绿色词元凭证提供了产地条件（中国信息通信研究院，2025）。

13.2.2 组织形态：运营边界与多方共建结构

该中心的正式名称为长三角（嘉兴）Token 运营中心，2026 年 7 月 30 日下午启动。此处须作一项名称说明：四家机构中有三家在设立时沿用英文 Token 命名，仅广东一家采用中文「词元」，这一并存状态恰是术语定名处于发布试用阶段的直接反映；本书正文一律使用「词元」，涉及具体机构时则照录其对外公布的名称，不作追溯性改写。案例研究首先要厘清的是运营边界，这一点在公开报道中极易被简化。准确的表述是：嘉兴市城市投资发展集团有限公司是运营中心面向市场的统一服务窗口即门户网站的运营主体，而运营中心本身由嘉兴市层面统筹、多方共建——一家基础电信运营商的嘉兴分公司作为词元经济战略合作伙伴投放核心算力，另一家运营商同步参与生态共建。把「门户运营主体」与「运营中心主办方」混为一谈，会得出「城投独家设立并运营」的错误印象，进而误判其资产逻辑与激励结构。中心的定位表述为「立足嘉兴、服务长三角、链接全国资源」，三大职能依次为打造普惠服务入口、构建资源调度枢纽、探索绿色可信服务。

这一组织形态在制度经济学上有明确含义。第 10 章曾论证，词元运营中心必然是「商业能力加公共职能」的混合体：底层的算力组织与场景组织具有私人品性质，市场主体有充分激励；上层的统一计量、统一审计与政策抵扣具有公共品性质，其收益弥散于所有参与者，任何单一商业主体既缺乏提供的激励，也缺乏被各方接受的中立性。嘉兴的安排恰是这一论断的具体实现：算力由运营商投放，属私人品部分，交由最具成本优势的主体承担；门户与治理规则由城投运营，属公共品部分，交由具备属地公共信用的主体承担；而全局统筹由市级层面完成，为跨主体协调提供权威。兼容性标准与质量披露制度的供给通常需要超越单个企业的协调机制（Farrell 和 Saloner，1985；Dranove 和 Jin，2010；Simcoe，2012），标准化对生产率的提升效应在中国情境下亦有直接的经验证据（何凡等，2025），嘉兴的三方分工正是把这一理论要求转译为可操作的组织结构。

需要进一步指出的是，这一结构解决了城投转型中的一个真实难题。第 10 章 10.3 节把城投的资产逻辑概括为「存量基础设施资产的再打包」：土地、电力接入、机房与带宽是城投的长期沉淀资产，其单独变现能力弱，但一旦与算力、模型与计量规则组合成可交易的服务，就获得了新的现金流入口。嘉兴案例显示，城投并不需要自己成为算力供应商或模型供应商——它需要成为的是「规则与入口的持有者」。这一定位的经济性在于，规则与入口具有强网络外部性，其价值随接入企业数与可选模型条目数的增加而上升（Katz 和

Shapiro, 1985; Armstrong, 2006; Jullien 等, 2021), 而这恰是城投所擅长的属地组织能力可以发挥作用的领域; 反之, 若城投直接下场采购显卡、自建模型, 则是以自身最弱的能力去对抗市场上最强的竞争者。案例中城投的角色边界, 为其他城市提供了一个可复制的组织模板。

13.2.3 「五个统一」的落地形态与交易费用证据

嘉兴门户的治理框架被概括为「五个统一」: 统一 API 入口、统一词元计量、统一费用结算、统一政策抵扣、统一安全审计。第 10 章已对这五项作过机制设计层面的分析, 指出它们并非五项便民服务, 而是对五类交易费用的针对性消解, 并把统一入口的交易费用节约率校准为 0.35。本节的任务不是重复这一分析, 而是提供案例层面的落地证据, 并指出理论与实践之间尚存的缝隙。

统一入口的落地形态最为直观: 企业一次接入即可按需调用 100 余款主流大模型条目, 平台可按任务类型自动匹配成本最优模型。此处必须坚持口径纪律: 100 余款是平台可接入的模型条目数, 同一厂商的多个版本会分别计数, 它既不等于接入了 100 余家模型厂商, 也不等于已产生实际调用量的模型数。厘清这一点之所以重要, 是因为第 10 章式(10-5)所刻画的交易费用节约率对可选模型条目数是递增的, 若把条目数误读为厂商数, 就会高估平台的比选价值。即便按条目数计, 其经济含义也已足够可观: 一家中型企业若要自行完成同等规模的比选、适配、对账与合同管理, 其内部成本将远超其全年词元支出, 这正是统一入口得以存在的经济基础。自动匹配成本最优模型的功能, 则直接对应第 9 章的匹配损失——该损失在四项损失分解中占 0.12, 是四项中仅次于空转损失的一项, 也是最适合由平台层统一化解的一项。

统一计量与统一结算的落地则显示出理论与实践的缝隙。案例可以确认的是, 门户把计量与结算作为独立的治理能力列出, 这与第 10 章层次分析法测得的制度权重排序一致——在五项制度要件中, 统一计量的组合权重最高, 为 0.271, 统一结算次之, 为 0.223。但案例无法确认的是, 统一计量究竟统一到哪一层: 是统一了物理词元的计数口径与账单格式, 还是进一步统一了效值折算的系数与核验规则? 就公开信息判断, 目前各地的统一计量主要落在前者。这一缝隙的意义不容低估: 若只统一物理词元的计数, 则平台解决的是「用了多少枚」的问题, 尚未解决「这些枚各值多少」的问题; 而第 5 章已经证明, 物理词元的单位价格离散度极高, 最高与最低档位的单价相差 12.6 倍, 折算后方降至 2.4 倍。换言之, 仅有物理计量的统一, 价格的可比性依然缺失, 第 8 章所刻画的效值信息不对称仍将存在。这是本案例给出的最重要的一条改进指向。

统一政策抵扣与统一安全审计的落地形态则与地方财政工具直接相关。政策抵扣把词元支出与地方产业政策的申报流程打通，使企业的政策申报费用大幅下降；安全审计把调用日志、数据流向与责任界定纳入统一留痕，回应了企业最关切的合规风险。首批生态伙伴 20 家，覆盖制造业龙头与科技文化企业，制造业龙头中包括玻纤新材料领域的头部企业。这一名单结构值得注意：它说明该中心的客户结构并非偏向内容行业，而是以制造业为基本盘，与嘉兴的产业底数相一致。同时须提醒，20 家是签约入驻数，不等于付费客户数，更不等于已产生词元消费的企业数——生态伙伴数与实际消费企业数之间的差额，恰恰是 13.5 节所要解释的采纳障碍所在。

13.2.4 案例的理论意涵与未决问题

把嘉兴案例放回全书框架，可以提炼三点理论意涵。第一，词元运营中心的核心资产不是算力而是规则。嘉兴拥有全省首位的算力规模，却仍需要专门设立运营中心把产能转化为使用，这本身就说明产能与使用之间存在制度性阻隔；能够消解这一阻隔的，是计量、结算与审计等规则性安排，而非更多的机柜。这一判断与第 12 章的核算结果相互印证：词元的增长贡献产生于实际使用而非算力产能，因而 2026 年东部、中部、西部的词元贡献率分别为 8.4%、5.1%与 3.6%，与算力产能的区域分布并不重合。第二，公共品职能必须由具备中立性的主体承担，但中立性不等于行政化。嘉兴把门户交给城投而非政府部门直接运营，保留了市场化的响应速度，同时借助国资背景提供中立信用，这一折中在制度设计上具有普遍参考价值。第三，绿色可信服务从一开始就被列为三大职能之一，说明绿色属性并非事后附加的合规负担，而是被作为服务的质量维度来经营——这与第 11 章绿色词元溢价的实证结果一致，出海导向企业对绿色凭证的支付意愿溢价系数为 0.083。

案例同时留下三个未决问题。其一，效值折算尚未进入统一计量的实际内容，平台的「成本最优匹配」在没有公开效值系数的条件下，其优化目标究竟是单位物理词元价格最低还是单位标准词元价格最低，外部无法核验；若是前者，则平台的自动匹配有可能系统性地把任务导向低效值档位，反而放大第 8 章所刻画的逆向选择——该章测得企业对所购词元效值的认知偏差均值为 0.44，低效值档位的过度采购份额为 0.27。其二，交易费用节约率 0.35 是第 10 章的校准参数，案例层面尚无独立的核验途径，其检验需要企业侧的对账数据，属后续研究方向。其三，生态丰度是该案例五项能力中的相对短板，其成因是启动时点最

近、生态积累时间最短，还是城投主体在开发者社群组织上存在结构性劣势，现有证据不足以判定，需要更长的观察窗口。

13.3 五城模式的跨案例比较

13.3.1 能力画像的合成：替代弹性与短板判据

跨案例比较需要把五个维度的证据编码合成为可排序的指数，而合成方式本身即蕴含着关于能力之间关系的实质性假设。若采用简单算术平均，等于假设五项能力完全可替代——计量透明的不足可以由生态丰度的富余来补偿；若采用短板判据，等于假设五项能力完全互补——任何一项不达标都会使整体失效。两种极端假设都不合理，本章因此采用可以连续调节替代程度的幂平均族。设案例 r 在能力维度 k 上的证据评分为 $s_{rk} \in (0, 1]$ ，维度权重为 $w_k > 0$ 且 $\sum_k w_k = 1$ ，定义能力合成指数：

$$\Phi_r(\sigma) = \left(\sum_{k=1}^K w_k s_{rk}^\sigma \right)^{1/\sigma}, \sigma \leq 1, \sigma \neq 0; \Phi_r(0) = \prod_{k=1}^K s_{rk}^{w_k} \quad (13-1)$$

其中， σ 为替代参数，对应的维度间替代弹性为 $\varsigma = 1/(1 - \sigma)$ ； $K=5$ 为能力维度数；基准设定取等权重 $w_k = 1/K$ ，因五项能力对应企业接入时依次遭遇的五道关口，缺乏赋予其中某一项系统性更高权重的先验依据。

式(13-1)具有四项性质，构成本节比较的方法论基础。第一，它把若干常用的合成方式纳入同一族： $\sigma=1$ 退化为加权算术平均，替代弹性为无穷大，对应完全替代； $\sigma \rightarrow 0$ 退化为加权几何平均，替代弹性为 1； $\sigma=-1$ 为调和平均； $\sigma \rightarrow -\infty$ 时 $\Phi_r \rightarrow \min_k s_{rk}$ ，即短板判据，对应完全互补。第二，由幂平均不等式， $\Phi_r(\sigma)$ 关于 σ 单调不减，因而 $\min_k s_{rk} \leq \Phi_r(0) \leq \Phi_r(1) \leq \max_k s_{rk}$ ，合成指数被严格夹在短板与长板之间。第三， σ 越小，指数对低分维度越敏感：对 Φ_r 取对数后求偏导可得 $\partial \ln \Phi_r / \partial \ln s_{rk} = w_k s_{rk}^\sigma / \sum_k w_k s_{rk}^\sigma$ ，该弹性随 s_{rk} 的下降而上升，且上升速度由 $|\sigma|$ 决定。第四，也是比较研究中最关键的一点：当两个案例的评分向量呈「均值—离散度」反向配置时，即一者均值较高但维度间离散较大、另一者均值较低但分布较均匀，必存在临界替代参数 σ^* 使二者的排序发生换位。这意味着案例排序并非客观事实，而是依赖于研究者关于能力互补程度的判断——诚实的做法是把这一判断显式化并报告其敏感性。

就本章的研究对象而言，有充分理由认为五项能力偏向互补而非替代。企业访谈中反复出现的表述是：若无法核验用量与效值，则接入再便利也不会把词元

嵌入主业务流；若合规责任界定不清，则成本再低也不敢在核心业务中使用。这类表述的逻辑结构是典型的互补——某一维度的不足会直接抵消其他维度的优势，而非被其部分补偿。第 10 章把「五个统一」作为一个整体提出而非分项推行，其制度直觉与此一致。因此本章的基准设定取 $\sigma=0$ ，即加权几何平均，替代弹性为 1，处在完全替代与完全互补之间且计算上具有尺度不变性；同时在 $\sigma \in [-20, 1]$ 区间内报告排序的敏感性。五城的能力画像如图 13.2 所示。




图 13.2 五城词元运营中心的能力画像

注：五项能力维度的评分取值区间为 0—1，由深度访谈、政策文件与平台公开界面三源互证后按统一锚定规则赋值，属作者校准复算结果，不代表任何机构的官方评估或排名；括号内为各案例的运营主体类型。径向刻度自内向外由 0.6 递增至 0.9。数据来源：作者据多源案例证据评分。

图 13.2 显示的第一项特征是「各有所长、无一全能」。五个案例的长板分别落在不同维度：嘉兴的长板是计量透明（0.88），苏州与温州的长板同为合规可信（0.86 与 0.88），广州的长板是计量透明（0.85），上海的长板是生态丰度（0.90）。长板的分布方向与第 10 章的资产禀赋—职能匹配预测高度吻合：城投持有属地公共信用与结算通道，故在计量与结算上见长；运营商持有网络与跨境通道，数据集团持有绿电禀赋与凭证能力，故二者在合规可信上见长；数据

交易所持有确权登记与规则制定职能，故在计量透明上见长；政策制定者以财政工具与集群工程切入，故在生态丰度与成本可控上见长。第二项特征是短板同样分化：五个案例的短板依次为生态丰度、成本可控、生态丰度、成本可控与计量透明，恰好落在各自禀赋的反方向。这一「长板沿禀赋、短板沿禀赋反方向」的对称格局，是资产禀赋决定能力结构这一命题最直接的案例证据。

若把视角由案例转向维度，可以得到第三项特征：维度之间的城际分化程度差异显著。以各维度评分在五案例间的变异系数衡量，合规可信的分化最小（0.051），生态丰度的分化最大（0.110），成本可控次之（0.101）。这一排序具有清晰的经济解释：合规可信在很大程度上由国家层面的统一制度环境决定，地方自主空间小，故各地趋同；生态丰度取决于本地开发者社群、应用企业密度与平台运营时长，属典型的路径依赖变量，故各地分化最大；成本可控则取决于地方财政工具的力度与算力自给能力，介于两者之间。对政策制定而言，这一排序意味着：合规维度的改进主要依赖国家层面的标准供给，地方发力的边际收益有限；生态维度的改进则高度依赖地方的持续投入与时间积累，不可能通过一次性补贴迅速拉平。

13.3.2 跨案例比较：模式、机制与合成指数

把案例的组织特征、标志性机制与合成指数并置，可以得到完整的跨案例比较，见表 13.2。表中的合成指数按式(13-1)在基准设定 $\sigma=0$ 下计算，短板维度取评分最低的维度及其取值。

表 13.2 五城词元运营与交易服务机构的跨案例比较

案例与机构	运营主体类型	启动或印发时点	标志性机制	合成指数	短板维度
长三角（嘉兴）Token 运营中心	城投集团	2026-07-30	「五个统一」治理框架；普惠入口、调度枢纽与绿色可信三大职能；首批生态伙伴 20 家	0.816	生态丰度 (0.72)
中国电信（江苏）Token 运营中心（苏州）	基础电信运营商	2026-08-11	六大类服务菜单；依托自有云底座与运营服务平台；同日成立词元出海服务联盟，首批 15 家成员	0.796	成本可控 (0.71)
东南 Token	数据集团	2026-07-	绿色词元认	0.772	生态丰度

运营中心 (温州)	(国资控股 运营公司)	15	证的三项可 证：来源可 溯、用能可 证、碳排可 算；门户与 区域词元工 厂同日启用 牵头构建全 省统一词元 计量规则并 出具交易凭 证；设普 惠、行业、 跨境三大交 易专区		(0.66)
广东词元交 易和服务中 心 (广州南 沙)	数据交易所	2026-07- 30	探索将词 元、数据治 理、大模型 部署及再训 练等投入纳 入企业技术 改造支持方 向；「百千 万」智算集 群工程	0.763	成本可控 (0.68)
上海：软件 和信息服 务业「十五 五」规划	政策制定者	2026-08- 11		0.805	计量透明 (0.72)

注：机构名称、主体类型与时点依公开报道与政策文本，其中嘉兴一栏的主体特指面向市场的统一服务窗口运营主体，运营中心本身由市级统筹、多方共建；温州一栏的具体运营主体为国资控股的专业运营公司，其负责人由市数据集团高管兼任。各地自定的能力清单（嘉兴「五个统一」、温州「六个统一」、苏州「六大类服务」、广东五大服务能力）分属平台治理能力、服务菜单与交易场所职能三种不同性质，条目数不构成可比的能力评分。合成指数按式(13-1)在 $\sigma=0$ 下计算，评分口径同图 13.2，为作者校准复算结果。

表 13.2 给出的基准排序为：嘉兴、上海、苏州、温州、广州，合成指数依次为 0.816、0.805、0.796、0.772 与 0.763，首尾差距约 6.9%。这一排序需要三点限定。第一，排序反映的是启动初期的能力状态而非长期潜力，五个案例的启动时点集中在一个月内，其中最早与最晚相差不足一个月，各案例的生态积累几乎都从零起步，排序在很大程度上反映的是禀赋转化为能力的初始效率，而非稳态水平。第二，排序对合成方式敏感。在完全替代设定（ $\sigma=1$ ）下，排序为嘉兴 0.818、上海 0.808、苏州 0.798、温州 0.776、广州 0.766，与基准一致；但当 σ 降至约-9.7 以下，即互补性强到接近短板判据时，温州与广州发生换位——在纯短板口径下，广州的最低维度为 0.68，高于温州的 0.66。这一换位不是计算噪声，而是实质性的经济信息：温州的评分均值高于广州，但其生态丰度维度明显落后，一旦认为能力之间高度互补，这一短板就足以抵消其在合规与成本维度上的优势。第三，指数本身不是绩效评价，五个案例在制度切入点上并不同质——上海以政策工具切入而非实体机构，广州属交易场所属性而非运营服务属性，把它们放在同一坐标系内比较的价值在于揭示能力结构的分化模式，而不在于排出名次。

排序之外，更值得关注的是差异的成因。第一类成因是资产禀赋，前已详述。第二类成因是制度切入点：嘉兴、苏州、温州以实体机构切入，广州以交易场所切入，上海以财政与产业政策工具切入。切入点决定了各案例最先解决的问题——实体机构最先解决接入与调度，交易场所最先解决凭证与规则，政策工具最先解决成本分担。第三类成因是产业需求结构：嘉兴的需求以制造业为基本盘，温州的需求以中小企业、跨境电商与内容创作为特色，苏州兼具制造与出海需求，广州与上海则以服务业与平台经济为主。需求结构不同，能力建设的优先序自然不同，把不同优先序解读为能力高下是一种误读。第四类成因是政策层级：广东于 2026 年 6 月印发全国首份省级词元经济专项政策，提出到 2027 年底基本形成全省一盘棋统筹、差异化布局、一体化协同的发展格局，广州中心是这一省级部署的落地载体；此后北京、四川、海南、江苏、湖北、贵州等地密集布局，北京于 2026 年 8 月初发布全市首个聚焦词元全产业链的专项政策，每年发放亿元级券金。这意味着城市级实践的差异在相当程度上是省级制度供给差异的投影，脱离省级政策环境孤立评价城市能力并不恰当。

跨案例比较还揭示了一项共性，其重要性甚至超过差异本身：五个案例全部把出海或跨境服务列入职能清单。苏州同日成立词元出海服务联盟，广东把词元出海与跨境流通列入五大服务能力并设立跨境交易专区，温州以绿色词元认证为出海企业提供可信、可计量、可追溯的服务凭证，嘉兴把绿色可信服务的目标客户明确指向出海企业，上海的规划则以参与全球竞争的桥头堡为定位表述之一。这一共性说明，地方实践者对词元经济的判断具有高度一致性：词元计量规则的国际互认，是词元出海能否带动规则输出的关键。绿色金融统计标准的国际比较经验表明，标准的国际互认往往先于资金与产品的跨境流动，且互认程度直接决定市场的可及性（陈丹丹等，2025）；跨境碳规制的实践也显示，缺少互认的核算体系会迅速转化为事实性的贸易壁垒（「European Parliament 和 Council，2023」）。这一共性证据将在第 14 章转化为具体的政策建议。

13.4 企业侧案例：供给侧优化与需求侧应用

前两节考察的是城市层面的制度供给，本节转向企业层面的实际使用。体例上需先作一项说明：本章对政府部门、公共平台与运营机构实名表述，因其职能与文件均属公共信息；对企业则一律以类型、所在地与业务特征描述而不点名，理由有二。其一，本章使用的企业信息大量来自匿名化访谈，若在同一节内对部分企业实名、对另一部分匿名，读者会据上下文反推匿名受访者的身份，破坏访谈承诺。其二，公开报道中若干企业主体的法人登记信息与发布主体是否同一尚

存疑问，实名叙述会把工商登记层面的不确定性带入学术文本。以类型描述并不损失信息：本节关心的是「哪一类企业、在哪一类场景中、以何种方式消费词元」这一结构性问题，而非任何具体企业的经营绩效。

13.4.1 供给侧：词元优化工厂与转化效率的技术边界

词元运营中心处理的是流通环节的制度问题，而转化效率的改进最终仍要落在技术环节。2026年7月，一家企业在世界人工智能大会上发布了国产词元优化工厂产品，其定位被表述为「把每一份算力变成稳定、高效的词元」，具体目标为同等算力投入产出更多有效词元、同等模型部署实现更快推理响应、同等显存硬件更稳定地运行超长上下文。其技术路线包括结果感知驱动的键值缓存压缩、全模态推理的词元压缩、长上下文后训练优化、深度推理优化与智能体长程任务记忆机制。据企业方与媒体口径，该产品兼容10余种国产算力硬件、适配20余款主流模型，日吞吐达千亿枚词元量级；创始团队具备高校计算机学科与国家级超算中心背景，并于2025年9月完成近亿元Pre-A轮融资。上述数字均属企业方口径，无第三方测评背书，本章仅将其作为机制性佐证。

这一案例在技术脉络上并非孤例，而是近年推理系统研究工业化落地的一个断面。键值缓存的分页管理显著提升了显存利用率与并发吞吐（Kwon等，2023），连续批处理把请求级调度细化到迭代级（Yu等，2022），注意力算子的输入输出感知实现降低了访存瓶颈（Dao等，2022），预填充与解码阶段的分离部署缓解了两阶段资源特性冲突（Agrawal等，2024；Zhong等，2024），大模型推理的分区与并行策略则给出了成本与时延的系统性权衡框架（Pope等，2023）。真实生产负载的分析同样表明，推理集群的资源利用具有显著的时变性与长尾特征，调度策略对有效产出的影响不亚于硬件本身（Weng等，2022）。把这些工作放在本书的框架内，其共同指向是第9章的转化函数：它们提升的是单位算力可产出的有效标准词元数，即效率参数 θ 。案例的意义在于，它显示这类系统级优化已从论文走向可交付的商品，从而使算力—词元转化效率成为一个可以被购买的生产要素，而不只是各家自建团队的内部能力。

这一案例还暴露了本书折算体系的一处理论边界，值得专门讨论。第5章把算力强度 P 界定为生成单枚词元所耗浮点运算量相对基准的倍数，并以之作为效值的投入侧维度；其隐含前提是，在同一技术前沿下，算力投入与能力产出正相关，故 P 可以作为能力的代理变量。但推理优化技术恰恰打破了这一前提：优化工厂使给定能力的模型在生成同样输出时消耗更少的算力，若机械套用折算公

式， P 下降而 R 、 S 不变，将导致效值系数 $\eta = P^{0.4383} R^{0.2964} S^{0.2653}$ 下降——技术效率的改进反而被记为效值的降低，这显然违背经济直觉。化解之道有二：其一，严格执行第5章所定的同时点测度纪律，即 P 必须在同一技术条件下的基准任务集上测得，跨期比较须以基准年技术条件重新锚定；其二，把推理优化的收益记入成本侧而非效值侧，即优化工厂降低的是标准词元的单位生产成本，对应第7章三层结构中的成本底价层下移，而不改变效值溢价层。本章倾向于第二种处理，因为它同时保持了效值的产出侧含义与价格结构的可解释性。这一边界条件是案例研究对理论框架的直接反馈，也应列为第14章研究展望的一项内容。

供给侧还有另一类主体值得对照，即词元工厂。2026年，北京先后出现两座标准化词元工厂：一座由市属国资旗下企业于7月在全球数字经济大会上发布，被称为全国首个国资背景、全流程合规标准化的词元基础设施，具备预填充与解码分离的智能调度架构、全栈推理加速框架、异构算力统一调度、国产模型生态适配、灵活计费与标准化接口零门槛接入等能力；另一座由企业于6月在亦庄建成，一期日产能1.4万亿枚词元。必须强调，「日吞吐千亿枚」（优化引擎的实测吞吐，企业方口径）与「日产能1.4万亿枚」（工厂的设计产能）不是同类指标，二者既未说明模型规模、上下文长度与精度，也未说明输入与输出词元是否合并计数，在任何情况下都不可直接比大小或排名。本章列出二者，是为了说明供给侧已经形成「产能建设」与「效率优化」两条并行的技术路线，而非为了比较其规模。

13.4.2 需求侧：制造业与新材料场景

需求侧的第一类场景是制造业。嘉兴首批生态伙伴中包含玻纤新材料等领域的制造业龙头，这类企业的词元消费具有三项区别于互联网企业的技术特征，而这三项特征直接决定了适配的定价与调度安排。其一，任务的时延容忍度高：配方优化、工艺参数寻优、质量文档生成等任务多为离线或准实时，允许排队与批量处理。按第9章的分析，时延容忍度高意味着可以采用更大的批大小，从而压缩批次损失——该损失在四项损失中占0.09，是唯一可以通过需求侧任务属性直接缓解的一项。其二，上下文长度大而调用频次低：单次任务往往需要载入长篇的工艺文档、标准规范与历史记录，缓存命中率的经济价值因而显著高于短对话场景。其三，任务的价值密度高：第6章测得质检与识别、合规审查等制造相关场景的单位价值密度分别为6.4与9.1，均显著高于文案生成的1.9，即同量标准词元在制造场景中承载的价值更大。

三项特征合起来给出一个明确的政策与商业含义：制造业客户是词元运营中心最合适的基本盘，但服务方式必须与互联网客户区别对待。互联网客户要的是低时延与高并发，制造业客户要的是可预期的预算与稳定的批处理窗口。对应到第7章的三级服务定价，制造业客户更适合以普惠包或预算包的形式承接——该章测得普惠包用户占比62.0%而收入占比仅21.0%，专属定制用户占比7.0%却贡献41.0%的收入，二级价格歧视的结构已经清晰。嘉兴案例中生态伙伴以制造业龙头为主的名单结构，与这一判断相互印证。需要如实说明的是，本节所依据的场景价值密度来自第6章的校准复算，案例层面尚无企业逐笔的词元账单可供核验，因而上述判断属机制层面的一致性，而非严格意义上的经验检验。

13.4.3 需求侧：跨境电商、内容创作与「一人公司」场景

需求侧的第二类场景以温州为代表，其结构与制造业几乎相反。该市词元运营中心启动时集中发布了跨境电商智能运营、互动影游创作、数字内容资产保护与贸易等一批生态平台，平台已兼容100多款主流大模型条目。这类场景的技术特征是：任务碎片化、时延敏感、单次上下文短但调用频次极高，且高度依赖多模态生成能力。按第9章的分析，这类负载的批次损失难以压缩，空转损失则因潮汐效应而放大——该损失占四项损失的0.18，是四项中最大的一项。这正是区域统一调度的价值所在：把制造业的离线批处理负载与内容创作的实时交互负载放在同一算力池中错峰调度，可以同时降低两类负载的空转与批次损失，这是单一企业自建推理集群无法实现的。

该市的词元消费增速被媒体广泛引用：2026年一季度制造业词元消费环比增长2261%，电商直播领域同期环比增长1110%，「一人公司」增长706%。本章引用这组数字时必须完整交代三点。第一，它们是环比而非同比，且属于典型的低基数高增速，基数与统计范围——哪些企业、哪些模型、按词元枚数还是按消费金额——均未公开。第二，三个数字分属并列的子行业口径，分母不同，既不能相加，也不能取平均。第三，这组数字属媒体报道口径，严禁与其他城市的调用量或交易额数字作横向比较；尤其需要警惕的是，交易场所的词元交易额（场内成交金额）与运营平台的词元调用量（技术调用规模）是两个完全不同的计量对象，二者之间不存在换算关系。在满足上述限定的前提下，这组数字仍有其价值：它显示在计量口径统一之前，区域层面的词元统计已经出现了增速数字大量涌现而口径普遍缺失的局面，这恰恰从反面论证了统一计量的紧迫性——若无统一口径，越是高速增长的领域，其统计越可能失真，而政策越是依赖这些数字，误配的风险越大。

「一人公司」这一形态尤其值得从理论上多说一句。它指以极少数人（甚至一人）借助大模型与智能体完成过去需要团队协作的业务闭环，其经济意义是把组织内部的协调成本替换为词元支出。生成式人工智能对个体产出效率的提升在实验与实地研究中已被反复证实（Noy 和 Zhang，2023；Brynjolfsson 等，2025），其采纳速度在成年人群中亦快于以往历次通用技术（Bick 等，2024），但采纳的分布高度不均，企业内部的组织调整往往滞后于工具的可得性（Czarnitzki 等，2023；Humlum 和 Vestergaard，2025）。云计算的历史经验同样显示，基础设施的可得性本身并不自动转化为企业绩效，配套的组织与技能投入才是关键（Byrne 等，2018；DeStefano 等，2025）。这些文献与本章的案例观察互为印证：温州「一人公司」的高增速固然引人注目，但 706% 的环比增速背后，是一个极小的基数与极少数具备工具驾驭能力的经营者；把这类高增速理解为普遍的采纳浪潮，会严重高估当前的渗透深度。13.5 节的扎根编码将从企业侧给出更为审慎的图景。

13.4.4 一则未采信案例及其方法论意义

本章原拟纳入一则智能设计领域的企业案例，其在流传材料中被描述为通过智能设计平台把设计周期由周级压缩至小时级、开发效率最高提升 30 倍、出图成本降低至少 50%。经六组关键词的系统检索，既未找到该企业主体的官方发布、政府通稿或主流媒体报道，也未找到三项效率数字的任何一手来源；检索命中的同名产品均为其他厂商的同名异主产品。行业内可查到的类比数据全部出自服务商自身的营销材料，不能作为该案例的替代证据。按表 13.1 的分级规则，该案例属 D 层级，本章不予采信。

之所以要把这一处理写入正文而非默默删除，是因为它触及区域实践研究的一个共性风险。词元经济正处在叙事供给远快于统计供给的阶段：一项技术尚未形成可核验的测度，关于它的效率倍数已经在媒体、路演材料与政策解读中广泛流传；这些数字往往起源于单一企业的内部测算，经多次转述后脱离了原有的样本、对照基线与统计时点，最终以「行业共识」的面貌出现。案例研究若不设门槛，就会成为这一放大链条的最后一环，且因其学术外观而使传闻获得不应有的可信度。更值得警惕的是，定性描述与定量声称的混排会进一步强化这种错觉：「周级压缩至小时级」是定性描述，「30 倍」与「50%」是定量声称，二者并列时读者会默认三者出自同一次测算。本章的处理规则因此是：凡定量声称，须给出测算样本、对照基线与统计时点，三者缺一即降格为定性描述；凡无法回溯到一手来源者，不进入证据体系。

这一处理也提示了智能设计场景在本书框架中的正确讨论方式。该场景在第6章的价值密度测算中位居前列（7.2），其经济逻辑是清楚的：设计任务所替代的是高价值的人类认知劳动，故场景效用 S 高；同时设计任务通常需要多模态生成，故算力强度 P 亦高。二者共同抬高效值系数，使该场景成为高效值词元的天然需求方。但「效值高」与「效率提升多少倍」是两个不同的命题：前者是本书折算体系内的结构性判断，可由基准任务集测得；后者是关于生产率改进幅度的经验命题，必须由带对照组的实地实验或企业微观数据来回答。把二者混同，正是当前大量效率倍数叙事的方法论病灶所在。

13.5 企业采纳词元服务的障碍：扎根理论分析

13.5.1 资料、编码程序与理论饱和

为识别企业采纳词元服务的障碍结构，本章对47份半结构化深度访谈资料实施扎根理论编码。受访者由四类构成：平台方12人（运营中心与门户运营方的产品与运营负责人）、企业方18人（已接入或正在评估接入的企业信息化与业务负责人）、政府方9人（数据、经信与发展改革部门的相关工作人员）、服务商8人（模型服务商、系统集成商与优化工具提供方）。四类受访者的设置遵循的是立场对冲原则：平台方倾向于强调接入的便利，企业方倾向于强调成本与合规的顾虑，政府方倾向于强调政策工具的到位，服务商倾向于强调技术能力的差距；只有让四类立场同时进入语料，才能避免单一视角主导编码结果。访谈提纲围绕接入决策的全过程展开，覆盖需求识别、比选、试点、扩展与复盘五个阶段，且在每一阶段追问「什么使你停下来」这一核心问题。

编码分三级推进。开放编码阶段逐句概念化，得到412个初始概念；主轴编码阶段按现象、条件、行动与结果的关系归并聚类，得到23个副范畴；选择性编码阶段进一步提炼出4个核心范畴，分别是计量不透明、成本不确定、能力缺口与合规及安全顾虑。四个核心范畴下的编码参考点合计434个，多于初始概念数412，差额22个来自跨范畴的双重归属——例如「账单与调用日志对不齐」这一概念既指向计量口径，也指向成本的可预期性，按编码规则在两个范畴下各记一次参考点。理论饱和的检验采用后续访谈不再涌现新范畴这一常规判据：在完成既定样本的编码后，追加访谈未再产生新的副范畴，亦未改变核心范畴的结构，据以判定编码达到理论饱和。编码结构与改进路径如图13.3所示。




图 13.3 企业采纳词元服务的障碍因素编码结构

注：参考点指被归入某一核心范畴的编码片段数，同一概念跨范畴归属时在各范畴分别计数，故四个核心范畴的参考点合计多于初始概念数；访谈样本与编码结果为本章质性研究的自采口径，受访者与所属机构均作匿名化处理。数据来源：作者访谈与编码。

图 13.3 显示的编码链条有两处值得特别说明。第一，四个核心范畴并非并列的困难清单，而是按企业决策的时序依次显现：计量不透明出现在比选阶段——企业无法核验不同供给方所报单价背后的实际所得；成本不确定出现在试点阶段——试点期的实际支出与预算频繁背离；能力缺口出现在扩展阶段——把试点成果推广到主业务流时，提示工程与系统集成的能力短板集中暴露；合规与安全顾虑贯穿始终但在扩展阶段最为尖锐——数据出境、审计留痕与责任界定的问题必须在正式投产前有明确答案。这一时序结构意味着，四类障碍不是可以任选其一加以解决的，而是必须依次通过的关口。第二，图中每一核心范畴都对应一条改进路径，这些路径并非本章的凭空设计，而是从受访者自述的应对办法中归纳而来，并与第 10 章「五个统一」的机制设计逐项对应。

13.5.2 四个核心范畴与定量结论的对应

四个核心范畴的参考点分布、代表性副范畴及其与前章定量结论的对应关系，见表 13.3。

表 13.3 企业采纳障碍的核心范畴、频次分布与定量对应

核心范畴	代表性副范畴	参考点	占比	对应的定量结论	改进路径
------	--------	-----	----	---------	------

计量不透明	用量口径不一；效值不可核验；账单与调用日志对不齐	143	32.9%	折算体系与离散度收敛（第5章）；效值信息不对称（第8章）	统一计量与用量可视；效值系数公示与第三方核验
成本不确定	价格波动频繁；年度预算不可控；峰值调用超支	118	27.2%	三层价格结构与两类价格指数的背离（第7章）	发布标准词元价格指数；阶梯报价与预算包
能力缺口	提示工程能力不足；系统集成无模板；业务流改造无参照	97	22.4%	匹配损失与统一调度的效率改进（第9章）	场景模板与集成服务包；陪跑式培训与咨询
合规与安全顾虑	数据出境顾虑；审计留痕缺失；责任界定模糊	76	17.5%	绿色凭证溢价与可信溯源体系（第11章）	统一安全审计；可信溯源凭证与责任条款标准化
合计	—	434	100.0%	—	—

注：参考点为归入该核心范畴的编码片段数，占比以四个范畴的参考点合计为分母；因存在跨范畴双重归属，合计参考点多于开放编码所得的初始概念数。「对应的定量结论」为作者依本书前章结果归纳，非受访者表述。数据来源：作者访谈与编码。

表 13.3 最值得注意的一项结果是计量不透明位居首位，占全部参考点的 32.9%。这一发现在质性研究中具有直接的理论意义：它表明企业在采纳词元服务时最先遇到、也最难自行化解的，不是价格高低，也不是技术难度，而是「买到的究竟是什么」这一计量问题。受访者的典型表述可以概括为三类：一是不同供给方对输入与输出词元的计数方式、缓存命中的计费方式不一致，使跨供给方的报价无法直接比较；二是同一枚词元在不同模型下的实际效用相差悬殊，而效值没有任何可核验的披露；三是平台账单与自身调用日志的口径存在系统性差异，对账成本高。三类表述恰好对应质量不可观测条件下的经典市场失灵机制：买方无法在事前分辨质量，只能按平均质量出价，高质量供给被逐出市场（Akerlof，1970）；而破解之道在于建立可信的质量披露与认证制度（Dranove 和 Jin，2010）。第 8 章已测得企业对所购词元效值的认知偏差均值为 0.44，低效值档位的过度采购份额为 0.27，与本章的编码结果指向同一机制。

成本不确定位居第二，占 27.2%。受访者的表述集中于「单价在降、账单在涨」这一看似矛盾的体验。本书前章已给出解释：第 7 章测得 2024 年一季度至 2026 年二季度物理词元价格指数由 100 降至 21，累计降幅 79%；但标准词元价格指数同期仅降至 47，表观降幅中约 53%来自效值提升（同价买到更强的词元），仅约 47%为真实降价。企业感受到的单价下行是真实的，但其消费结构同

时在向高效值档位迁移，且任务复杂度上升带来的词元用量增长远快于单价下行，于是总支出不降反升。这一解释的政策含义是明确的：仅公布单价的下降幅度无助于缓解企业的预算焦虑，真正有用的是发布口径统一的标准词元价格指数，使企业能够把「买得更多」与「买得更贵」区分开来。

能力缺口占 22.4%，其内容是提示工程、系统集成与业务流改造三类能力的不足。这一范畴与第 9 章的匹配损失形成呼应但并不等同：匹配损失刻画的是任务与模型档位之间的错配，属技术性的配置问题；能力缺口刻画的是企业内部把词元能力嵌入业务流的组织性障碍。两者的关系是，前者可以通过平台层的自动匹配大幅缓解，后者则必须由企业自身的组织学习完成，平台至多提供模板与陪跑。合规与安全顾虑占 17.5%，看似最低，但受访者普遍指出它具有「一票否决」性质——只要责任界定不清，其他三项改进得再好也无法进入核心业务。这提示我们，参考点频次度量的是「被提及的频繁程度」而非「阻碍的严重程度」，两者不可等同，这也是下一节要引入结构性指标的原因。

13.5.3 障碍结构的集中度与政策含义

若四类障碍的频次高度集中于某一项，则单点突破的政策具有较高的期望收益；若四类障碍大体均匀分布，则任何单点政策的效果都会被其余三项摊薄，必须系统配套。这一判断需要结构性指标而非简单排序。设核心范畴 $g=1, \dots, G$ 的参考点频次为 f_g ，其份额为 $\pi_g = f_g / \sum_g f_g$ ，定义障碍结构的集中度指数与弥散度指数：

$$H = \sum_{g=1}^G \pi_g^2, E = -\frac{1}{\ln G} \sum_{g=1}^G \pi_g \ln \pi_g \quad (13-2)$$

其中， H 为赫芬达尔型集中度指数， E 为以 $\ln G$ 标准化的信息熵； G 为核心范畴数。

式(13-2)的两项指标互为反向： $H \in [1/G, 1]$ ，取下界 $1/G$ 时四类障碍完全均匀分布，取上界 1 时全部参考点集中于单一范畴； $E \in [0, 1]$ ，取 1 时完全均匀，取 0 时完全集中。两项指标同时报告的理由是， H 对高份额范畴更敏感、 E 对低份额范畴更敏感，二者的组合可以避免单一指标的盲区。就本章的编码结果而言， $G=4$ ，四类障碍的份额依次为 32.9%、27.2%、22.4% 与 17.5%，代入式(13-2)得 $H=0.2631$ 、 $E=0.9810$ 。集中度指数仅比完全均匀分布的下界 0.25 高出 5.2%，弥散度指数则高达 0.981，距上界 1 不足两个百分点。这是一个结构性的结论：企业采纳词元服务面临的不是一个主导瓶颈，而是四个量级相当的关口。

这一结论有三层政策含义。第一层是直接的：任何单点政策——只补贴价格、或只统一计量、或只做培训——都无法把企业的深度采纳净收益推过临界值。第 10 章的三方演化博弈已经给出这一临界值的精确刻画：企业深度采纳成为演化稳定策略的临界红利为 $R_F^c = 1.55$ ，而基准情景下的企业红利为 1.5，仅比临界值低约 3%，却导致完全不同的均衡——系统收敛于「平台热、企业冷」，政府被锁定在强激励挡位而无法退出补贴。本章的集中度测度解释了这一「差之毫厘」为何难以跨越：由于四类障碍量级相当，单项改进对 R_F 的提升幅度大约只有全部改进的四分之一，远不足以跨过阈值；只有四项同时推进，才可能实现质变。第二层含义关乎政策工具的组合方式：既然四项障碍量级相当，则「五个统一」应当作为一揽子制度安排整体推行，分项试点的效果会显著低于其加总。这为第 10 章把五项统一作为整体机制设计提供了来自企业侧的独立证据。

第三层含义关乎政策的优先序。集中度低并不意味着四项完全等价——在四项量级相当的前提下，应当优先推进那些具有基础设施性质、能够降低其余三项改进成本的措施。统一计量正是这样一项措施：计量口径统一后，价格指数才有编制基础，成本的可预期性随之提升；计量与效值可核验后，平台的自动匹配才具备可验证的优化目标，能力缺口的改进也才有客观的效果度量；计量数据的标准化留痕本身即是安全审计的基础。换言之，统一计量对其余三项具有正的交叉效应，其社会收益大于其直接收益。这一判断与第 10 章层次分析法的测算结果高度一致——在五项制度要件中，统一计量的组合权重最高（0.271），统一结算次之（0.223），统一入口第三（0.196），统一安全审计第四（0.166），统一政策抵扣最末（0.144），判断矩阵的一致性比率为 0.038，通过一致性检验。

两套结果的一致性值得专门核验，因为它们来自完全独立的方法与数据：层次分析法的权重来自 26 位专家的两轮咨询，度量的是制度要件的重要性判断；扎根编码的频次来自企业侧访谈语料，度量的是障碍被提及的频繁程度。若把四个核心范畴与四项制度要件按机制对应关系配对——计量不透明对应统一计量、成本不确定对应统一结算、能力缺口对应统一入口、合规与安全顾虑对应统一安全审计——则两套排序的斯皮尔曼秩相关系数为 1.00。在四个配对下，两组排序完全一致的随机概率为 $1/4! \approx 4.2\%$ ，故这一吻合不大可能出于偶然。第五项制度要件统一政策抵扣（权重 0.144）在企业侧的核心范畴中没有对应项，原因也是清楚的：政策抵扣是政府侧的激励工具而非企业侧的障碍来源，企业只会抱怨申报麻烦，不会把「没有补贴」表述为采纳障碍。这一非对称性本身构成了对配对逻辑的一项旁证。

13.6 与定量结论的三角验证

案例证据的最终价值，在于它能否与定量结论相互印证或相互纠正。混合方法研究通常以收敛效度作为判据，但收敛效度不能仅凭印象宣称，需要一个可复核的记账方式。为此，本章从前章的定量结果中提炼出若干条可由案例证据检验的命题，逐条判定案例证据对该命题是支持、不足以判定还是相悖，并据以构造一致性指数。设第 q 条命题的判定结果为 $\delta_q \in \{1, 0, -1\}$ ，权重为 $\omega_q \geq 0$ 且 $\sum_q \omega_q = 1$ ，定义：

$$\Lambda = \sum_{q=1}^Q \omega_q \delta_q, \Lambda^- = \sum_{q=1}^Q \omega_q 1\{\delta_q = -1\} \quad (13-3)$$

其中， Λ 为一致性指数， Λ^- 为证伪率， $1\{\cdot\}$ 为示性函数；等权设定下 $\Lambda = (n_s - n_r)/Q$ ， n_s 与 n_r 分别为判定为支持与相悖的命题数。

式(13-3)有三项性质需要说明，它们决定了这一指数应当如何被解读。第一， $\Lambda \in [-1, 1]$ ，取 1 表示全部命题获得案例支持，取 -1 表示全部命题被案例证伪。第二， Λ 与 Λ^- 必须同时报告，且后者是更严格的判据：在理论检验中，一条稳健的证伪比若干条支持更具信息量，一个 Λ 较高但 $\Lambda^- > 0$ 的结果，其含义与 Λ 略低但 $\Lambda^- = 0$ 的结果完全不同。第三，判定为 0 的命题不是中性的噪声，而是标定了案例方法能力的边界——它们指出哪些定量结论在现有案例证据下根本无法被检验，这一信息对后续研究设计的价值不亚于支持性证据。基于这三项性质，本节采用等权设定，逐条报告判定理由。

命题一（第 3、5 章）：物理词元不可加，异质词元承载的价值相差数倍，故计量是词元流通的第一约束。案例证据：五个案例无一例外把计量列为核心职能——嘉兴以统一词元计量为五项治理能力之一，广东牵头构建全省统一词元计量规则并出具交易凭证，温州以用能可证为绿色词元认证的三项可证之一，苏州设指标监测服务，上海的规划则把词元支出作为可核定的技改投入类别加以探索；企业侧编码中计量不透明为频次最高的核心范畴（143 个参考点，占 32.9%）。判定为支持。

命题二（第 5、8 章）：效值信息不对称将诱发逆向选择，企业以单价而非效值比价，导致低效值档位被过度采购。案例证据：企业方受访者普遍描述「按最低单价比价」的采购惯例，并明确表示无法核验效值；平台提供「按任务类型自动匹配成本最优模型」功能这一事实本身，即是对企业无力自行判别效值的制度性回应。判定为支持。命题三（第 5 章）：折算后单位价格的离散度显著收

敛，变异系数由 0.92 降至 0.31，极差倍数由 12.6 降至 2.4。案例证据：截至观察时点，尚无任何一地公布可核验的效值折算系数与折算后价格，案例层面无从直接检验离散度是否收敛。判定为不足以判定。这一判定同时指出了一条明确的研究与政策路径：折算体系的经验检验必须以平台侧公开折算系数为前提。

命题四（第 7 章）：词元价格呈成本底价、效值溢价与场景租金三层结构，场景租金层解释纵向差异，并支持三级服务的二级价格歧视。案例证据：广东设普惠、行业、跨境三大交易专区，嘉兴门户在提供普惠入口的同时按任务类型匹配，苏州设补贴专区，三者均属按场景与支付能力分层的定价安排。判定为支持。命题五（第 7 章）：物理词元价格指数与标准词元价格指数背离，表观降价中约 53%来自效值提升，故企业会体验到「单价在降、支出在涨」。案例证据：成本不确定为第二核心范畴（118 个参考点，占 27.2%），其副范畴集中于价格波动频繁与年度预算不可控，受访者的描述与该背离机制高度吻合。判定为支持。

命题六（第 9 章）：名义利用率与有效效值利用率之间存在四项损失，其中匹配损失占 0.12，统一调度可把有效利用率由 0.38 提升至 0.54，理论上界为 0.61。案例证据：嘉兴把资源调度枢纽列为三大职能之一，其表述为「让算力不闲置、需求不落空」；苏州中心以统一调度台为核心功能之一；两地平台均提供按任务类型自动匹配的能力。判定为支持。命题七（第 10 章）：在「五个统一」的五项制度要件中，统一计量的制度权重最高（0.271）、统一结算次之（0.223）。案例证据：企业侧编码频次的排序与专家权重的排序完全一致，斯皮尔曼秩相关系数为 1.00，随机情形下完全一致的概率约 4.2%。判定为支持，且属两种独立方法的交叉印证，证据强度高于其余各条。

命题八（第 10 章）：当企业深度采纳红利低于临界值 1.55 时，系统收敛于「平台热、企业冷」，政府被锁定在强激励挡位而无法退出补贴。案例证据：五地启动期均以政府侧强激励开局——词元券、补贴专区、政策抵扣、技改支持方向，而企业侧把词元嵌入主业务流的深度采纳尚处早期，生态伙伴签约数与实际付费消费企业数之间存在明显落差。判定为支持，但须注明这是启动期的阶段性观察，观察窗口仅一个月量级，不能据以判断长期均衡。命题九（第 11 章）：绿色词元凭证具有可识别的溢价，出海合规是其主要驱动，出海导向企业的支付意愿溢价系数为 0.083。案例证据：温州以来源可溯、用能可证、碳排可算三项可证构建绿色词元认证并明确面向出海企业；苏州同日成立词元出海服务联盟；广东把词元出海与跨境流通列入五大服务能力并设跨境专区；嘉兴把绿色可信服务列为三大职能之一并指向出海客户。判定为支持。

命题十（第 12 章）：词元的增长贡献产生于实际使用而非算力产能，故词元贡献率的区域格局与算力产能的区域格局并不重合，2026 年东部、中部、西部的贡献率分别为 8.4%、5.1%与 3.6%。案例证据：嘉兴算力规模居浙江首位却仍需专设运营中心把产能转化为使用，方向与命题一致；但案例层面缺乏可比的分地区词元使用强度统计，且各地公布的增速数字口径不一，无法据以检验区域贡献率的具体数值。判定为不足以判定。

汇总以上 10 条命题：判定为支持者 8 条，不足以判定者 2 条，相悖者 0 条。按式(13-3)在等权设定下计算，一致性指数 $\Lambda=0.80$ ，证伪率 $\Lambda^-=0.00$ 。两项指标合起来给出的判断是：本书定量部分的核心结论在案例层面获得了广泛的收敛性支持，且没有任何一条被案例证据证伪；两条无法判定的命题分别指向折算系数的公开披露与分地区词元使用强度的统计缺失，其共同点是都需要目前尚不存在的公开数据基础设施。这一结果本身即是一项发现：制约词元经济研究的主要瓶颈已经不是理论工具，而是计量与统计的公共品供给。

在肯定收敛性的同时，必须严格界定这一结论的效力。第一， Λ 度量的是收敛效度而非因果识别，案例证据与定量结论指向同一机制，并不排除二者共享同一遗漏变量的可能；本章所有因果性表述均已给出机制链条，但机制链条不能替代反事实推断。第二，命题的选取与判定由研究者完成，存在确认偏误的风险，本章的对冲办法是在样本设计上引入四类立场对冲的受访者、在判定上保留不足以判定的类别并如实报告、在证据使用上执行表 13.1 的分级规则；但这些安排只能降低偏误而不能消除偏误。第三，观察窗口过短是本章最实质的局限：五个案例的启动时点集中在一个月之内，所有关于稳态与长期均衡的判断都只能是推测。较为稳妥的表述是，本章验证的是「机制是否在起作用」，而非「机制的长期效果有多大」。生产率 J 曲线的研究经验提醒我们，通用技术的产出效应往往在互补性无形资产积累完成之前长期被低估（Brynjolfsson 等，2021），而宏观测算亦显示短期内可归因于人工智能的全要素生产率改进幅度相当有限（Acemoglu，2025）；就词元经济而言，当前观察到的主要是制度基础设施的搭建过程，其产出效应的显现尚需时日。

13.7 本章小结

本章把全书的理论建构与定量结论放回真实的区域实践与企业情境中加以检验，完成了从模型到现场的往返。在方法上，本章的首要工作是建立证据纪律：面对一个叙事供给远快于统计供给的领域，案例研究必须先解决「什么可以算作证据」的问题。本章据此建立了七类资料的四级可信度分级与相应的使用规则，

明确规定一手官方来源照录原文措辞、权威媒体报道标注口径与日期、主体自述仅作机制性佐证且不与官方统计并列、不可回溯的流传数字一律不予采信。这一规则在本章有四处具体应用，其中包括对一则智能设计案例的整体排除。把排除的理由写入正文，是为了说明区域实践研究的最大风险在于成为传闻放大链条的最后一环。

在跨案例比较上，本章建立了案例—能力矩阵与幂平均族合成指数。式(13-1)把完全替代、几何平均与短板判据纳入同一函数族，使「能力之间是替代还是互补」这一实质性判断显式化并可作敏感性分析。基准设定下五个案例的合成指数依次为嘉兴 0.816、上海 0.805、苏州 0.796、温州 0.772、广州 0.763；当替代参数降至约-9.7 以下即互补性接近完全时，温州与广州因短板差异而发生排序换位。更具理论意义的发现是能力结构的对称格局：五个案例的长板一致落在其资产禀赋的方向上，短板则一致落在禀赋的反方向，这为第 10 章资产禀赋—职能匹配的理论预测提供了直接的案例证据。维度层面的分化程度亦有规律——合规可信的城际分化最小、生态丰度最大，分别对应国家统一制度供给与地方路径依赖两种不同的形成机制。五案例还共享一项重要共性：全部把出海或跨境服务列入职能清单，说明地方实践者对词元计量规则国际互认的紧迫性判断高度一致。

在企业侧，本章以扎根理论程序对四类立场对冲的深度访谈资料编码，识别出计量不透明、成本不确定、能力缺口与合规及安全顾虑四个核心范畴，其参考点占比依次为 32.9%、27.2%、22.4%与 17.5%。式(13-2)给出的集中度指数 $H=0.2631$ 与弥散度指数 $E=0.981$ 表明，四类障碍量级相当、无单一主导瓶颈，因而任何单点政策的效果都会被其余三项摊薄——这为第 10 章把「五个统一」作为一揽子制度安排整体推行提供了来自企业侧的独立论据，也解释了第 10 章演化博弈中「差之毫厘、谬以千里」的阈值效应何以在现实中难以跨越。在四项量级相当条件下，统一计量因对其余三项具有正的交叉效应而应居优先序之首；这一判断与第 10 章层次分析法的专家权重排序完全一致，两套独立方法的秩相关系数为 1.00，随机吻合的概率约 4.2%。

在三角验证上，本章从前章定量结果中提炼 10 条可检验命题，逐条判定后得一致性指数 $\Lambda=0.80$ 、证伪率 $\Lambda^-=0.00$ ：核心结论获得广泛的收敛性支持，无一被案例证据证伪；两条无法判定的命题分别指向折算系数的公开披露与分地区词元使用强度的统计缺失，共同表明制约词元经济研究的主要瓶颈已由理论工具转为公共数据基础设施。本章同时向理论反馈了两处边界：其一，推理优化技术使给定能力的算力消耗系统性下降，若机械套用折算公式会把效率改进误记为效值

下降，正确处理是把优化收益记入成本底价层而非效值溢价层，并严格执行同时点测度纪律；其二，各地的统一计量目前主要落在物理词元的计数与账单格式层面，尚未触及效值折算系数与核验规则，因而价格的可比性依然缺失，第 8 章所刻画的效值信息不对称仍将持续。这两处反馈将直接进入第 14 章的政策建议与研究展望。

最后需要重申本章结论的效力边界。五个案例的启动时点集中在一个月之内，本章验证的是机制是否在起作用，而非机制的长期效果有多大；能力评分与合成指数反映的是启动初期禀赋转化为能力的初始效率，不宜读作绩效排名；一致性指数度量的是收敛效度而非因果识别。本章的结论适用于产业密度较高、已具备一定算力基础的城市，对低于规模门槛的中小城市，正确的选择是接入区域平台而非自建。承认这些限度并不削弱本章的价值：在一个制度正在生成、统计尚未成型的领域，把可核验的证据与不可核验的传闻分开、把已验证的机制与未验证的推测分开，本身就是研究所能提供的最重要的公共品。下一章将把全书的计量、定价与配置三线结论加以归纳，并转化为可操作的政策建议。

第 14 章 结论、政策建议与研究展望

本书从一个看似技术性、实则关乎智能经济计量地基的事实出发：同样被称作「词元」的最小信息单元，在不同模型、不同任务下所耗算力、所载信息与所创价值可以相差数倍乃至数十倍。当一个计量单位内部如此不均质时，以它为分母的一切经济运算——单价比较、补贴核定、成本归集、产能考核、增长核算——都会在不同程度上失真。本书由此提出并论证了一个贯穿全篇的核心命题：词元是智能经济的计量单位，但物理词元不是合格的价值单位；只有经效值折算得到的标准词元，才能同时承担价值尺度、定价基准、配置信号与增长核算变量这四重经济职能。围绕这一命题，全书用十三章完成了从概念界定、事实刻画、折算体系构建，到定价机制、市场均衡、配置优化、组织设计、绿色治理、增长测度与区域案例的完整论证链条。

这一论证的现实紧迫性由制度进程本身给出。全国科学技术名词审定委员会 2026 年 3 月 25 日发布公告，优先推荐并面向全社会发布试用 token 的中文名「词元」，将在常态化审定中最终确认；同月，国家发展改革委党组成员、国家数据局局长在中国发展高层论坛 2026 年年会上使用并推介这一译名，提出词元具有「可计量、可定价、可交易」的特征。术语的统一与经济属性的官方确认几乎同时发生，而按国家数据局公开发布的口径，我国日均词元调用量已由 2024 年初的 1000 亿枚，增至 2025 年 6 月底突破 30 万亿枚、2025 年底的 100 万亿枚，2026 年 3 月突破 140 万亿枚，两年增长约 1400 倍。规模的爆发与口径的空缺形成了一种典型的制度落差：计量对象已经具备国民经济意义，而计量规则尚停留在团体标准与机构评估层面。本章的任务，就是把前三章的分析结论收束为可陈述的知识增量，并把这些增量转化为可操作的制度安排与可继续的研究议程。

本章安排如下。14.1 节按计量、定价、配置三条主线归纳九条主要研究结论，并给出一个把四重职能统一起来的枢纽恒等式；14.2 节从社会计划者的配置问题出发推导政策工具的分工逻辑，提出计量侧、定价侧、配置侧三支柱与标准统计基础设施相配套的政策体系，并给出补贴退出的时间一致性条件与政策清单；14.3 节陈述本书在理论、方法与实践三个层面的贡献；14.4 节坦陈研究局限并展望未来议程；14.5 节为本章小结。

14.1 主要研究结论

全书结论可以归纳为九条，分属计量、定价、配置三条主线。在逐条陈述之前，先把这九条结论所共同依托的形式结构写出来。本书的全部分析实际上围绕

一组以标准词元 $\tilde{T}$ 为公共变量的方程展开，它们把折算、计价、转化、碳核算与增长核算接在同一个变量上，构成本书所谓的枢纽恒等式组：

$$\tilde{T} = \eta T, \eta = P^{w_P} R^{w_R} S^{w_S}, \tilde{p} = \frac{P}{\eta}, \tilde{T} = \theta C, \iota = \varepsilon \phi, c_T = \alpha_T g_{\tilde{T}} \quad (14-1)$$

其中， T 为物理词元计数， η 为效值系数， P 、 R 、 S 依次为算力强度、推理质量与场景效用， w_P 、 w_R 、 w_S 为三维权重且和为1； p 与 $\tilde{p}$ 分别为物理词元与标准词元的单位价格； θ 为单位算力的有效标准词元产出， C 为投入算力； ι 为单位标准词元碳强度， ε 为单位标准词元耗电、 ϕ 为电力排放因子； c_T 为标准词元流量对产出增长的贡献， α_T 为其产出弹性， $g_{\tilde{T}}$ 为流量增长率。

式(14-1)的六个式子分别来自第5、7、9、11、12章，把它们并置书写有三点用意。第一，它显示标准词元是一个枢纽变量而非一个附加指标：一旦 η 的测算规则确定，价格、效率、碳强度与增长贡献四类量纲完全不同的经济量便获得了共同的分母，跨模型、跨场景、跨区域的加总与比较才在算术上成立。第二，它显示这六个式子共享同一个脆弱点：若 η 的测算规则不统一或可被操纵，则价格指数会失真、效率考核会失效、碳凭证会失去可信度、增长核算的系数会随档位结构漂移，四类失真同源。第三，它显示政策的作用点具有唯一性：与其在四条战线上分别设计纠偏工具，不如把制度资源集中于折算规则的统一与公示，这是本章政策建议的基本判断。

14.1.1 计量线：从多维评价到当量折算

结论一：物理词元不是合格的价值单位。其内部离散度已达到使加总失去经济意义的程度。本书对六个档位模型的测算显示，生成单枚词元的算力强度 P 在轻量蒸馏级与推理增强级之间相差38.2倍，推理质量 R 相差6.7倍，合成效值系数 η 相差11.3倍；对应地，折算前单位词元价格的变异系数达0.92、基尼系数0.47、最高与最低之比12.6倍。这一离散度并非统计噪声，而是技术结构的必然结果：分词器的切分粒度、上下文长度、缓存命中与推理路径长度共同决定了单位词元的资源含量，而分词效率在不同语言与不同文本类型之间本就存在系统性差异（Rust等，2021；Petrov等，2023；Ahia等，2023）。把这样一组异质对象直接相加并除以支出，得到的所谓「平均词元价格」在经济学上没有确定含义，正如把不同热值的燃料按吨相加不能得到有意义的能源价格一样。

结论二：四条公理唯一确定了折算函数的幂积形式。实证标定与公理推论相互印证。本书证明，若折算函数连续、对各维严格单调递增、满足基准归一与链式一致，则必为 $\eta = P^{w_P} R^{w_R} S^{w_S}$ 的幂积形式。以基准任务集实测数据标定得 $w_P =$

0.4383、 $w_R = 0.2964$ 、 $w_S = 0.2653$ ，拟合优度 $R^2 = 0.9996$ 、均方根误差 0.026；把函数形式放宽为不变替代弹性形式独立标定，得替代参数 $\hat{\rho} = 0.0794$ ，统计上无法拒绝 $\rho = 0$ ，此时该形式恰好退化为加权几何平均；链式折算与直接折算之差为机器精度量级，可加性与传递一致性同时成立。这一结论的方法论意义在于，折算权重不是主观赋权的结果，而是公理约束下的函数形式加实测标定的联合产物，因而具备可复核、可争辩、可修订的公共品性质，这正是标准化制度得以运转的前提（Farrell 和 Saloner，1985；Simcoe，2012；何凡等，2025）。

结论三：折算使价格离散度大幅收敛。可加性由此成为词元进入指数、账表与核算的资格条件。折算后单位标准词元价格的变异系数由 0.92 降至 0.31、降幅 66.3%，基尼系数由 0.47 降至 0.17、降幅 63.8%，最高与最低之比由 12.6 倍收敛至 2.4 倍，价格结构显著趋近一价定律。需要强调本书与既有工作的关系。在词元评价领域，目前真实存在且各有主体的成果至少有四套：中国信息通信研究院《人工智能 Token 服务质量能力要求》所依托的「可信 AI-Token 服务质量评估」，含模型服务能力、Token 服务性能、Token 服务可信、Token 服务运维、Token 服务用户体验、Token 计量计费六个维度；中国信息通信研究院于 2026 年 6 月 16 日发布并解读的「高质量 Token 服务标准体系」，含服务质量、运营能力、生产能力、安全能力四个维度；中国工业互联网研究院《Token 驱动智能经济研究报告（2026 年）》提出的价值度量体系，含生产成本、生产效率、准确性、生态价值、安全五个维度；清华大学翟季冬团队联合清程极智于 2026 年 5 月发布的「开源模型 Token 服务性能榜」，以首词元时延（P90 分位）、输出吞吐与缓存命中率三项实测指标为核心。四套体系的主体、维度数与用途各不相同，不可合并、平均或交叉引用其维度名称。它们的共同特征是多维评价：产出的是并列的维度得分或达标基线，可用于服务质量认证与选型参考，却无法把异质词元合成为可加总、可计价、可入账的单一当量。本书的增量正在于从多维评价推进到当量折算——给出公理化的合成函数，使不同模型、不同任务的词元获得可比、可加的共同尺度。这一步在计量史上有清晰的先例：综合能耗计算通则以标准煤当量统一异质能源（国家市场监督管理总局和国家标准化管理委员会，2020），产品碳足迹量化标准以二氧化碳当量统一异质温室气体（「ISO，2018」；国家市场监督管理总局和国家标准化管理委员会，2024），碳核算体系的国际演进亦表明当量化是跨主体可比的前置条件（陈红敏，2011；童庆蒙等，2018）。

14.1.2 定价线：三层结构、双指数与信息不对称

结论四：词元价格由成本底价、效值溢价与场景租金三层叠加而成。三层的相对权重随档位系统性变化，这是价格结构性分化的直接来源。本书的分解显示，成本底价占市场价的比重在轻量蒸馏级为 45.0%，在推理增强级降至 24.0%；与之相对，场景租金占比由 32.5% 升至 44.4%。这意味着低档位词元的价格接近其边际成本，竞争性质接近同质品市场；高档位词元的价格则主要由可占有的场景价值份额决定，竞争性质接近纵向差异化产品市场。这一结构解释了一个常被误读的现象：通用词元价格持续下行与高效值词元溢价扩大并存，二者并不矛盾，而是同一价格结构在不同档位上的两个截面。纵向差异化产品的质量分层定价与版本化策略为此提供了成熟的理论参照（Mussa 和 Rosen，1978；Bhargava 和 Choudhary，2008），数据类产品的定价研究亦指出，价值实现高度依赖使用情境而非产品本身（熊巧琴和汤珂，2021；Pei，2022；欧阳日辉和杜青青，2022）。

结论五：以物理词元计量的价格指数会系统性高估真实降价幅度。标准词元价格指数是更合适的政策观测量。本书编制的双指数显示，以 2024 年第一季度为 100，物理词元价格指数至 2026 年第二季度降至 21、累计降幅 79%；同期标准词元价格指数降至 47、累计降幅 53%，两者相差 26 个百分点。对总降幅作分解可知，表观降价中约 53% 来自效值提升（同样支出买到更强的词元），约 47% 为真实降价。这一背离具有直接的治理含义：若以物理单价的下降幅度作为普惠成效、补贴退坡或反垄断审查的依据，将把质量改进误记为价格让利，从而在政策评估中产生系统性偏差。质量调整型价格指数的编制传统早已给出应对之道——享乐价格法把质量特征显性纳入价格方程（Griliches，1961；Pakes，2003；Erickson 和 Pakes，2011），官方统计对新产品与质量变化的处理亦有成体系的方法学积累（Groshen 等，2017；Redding 和 Weinstein，2020）。标准词元价格指数在方法论上正属于这一谱系，其特殊之处在于质量特征由公理化折算函数而非市场特征回归给出。

结论六：效值信息不对称构成词元市场的首要失灵来源。词元需求总体富有弹性但行业异质极强。本书估计的需求价格弹性为 -1.34（标准误 0.19，观测数 864），分行业看，文化传媒 -1.71、制造 -1.62、金融 -0.94、政务 -0.68，最富弹性行业与最缺乏弹性行业相差逾一倍半。这意味着单一的普降价格政策在不同行业的动员效果差异极大：在政务等低弹性场景，降价难以显著扩大调用，扩需的关键在于场景开发与合规工具供给。三级服务定价的分布同样值得注意，普惠包覆盖 62% 的用户却只贡献 21% 的收入，专属定制以 7% 的用户贡献 41% 的收

入，这是典型的二级价格歧视结构，其福利性质取决于普惠档是否真正扩大了接入面（Dubé 和 Misra，2023）。更值得警惕的是效值维度的信息不对称：本书测得企业对所购词元效值的认知偏差均值达 0.44，由此导致低效值档位的过度采购份额达 27%。在质量不可观测而价格可观测的市场中，逆向选择会压低平均质量并抑制高质量供给（Akerlof，1970），而质量披露与第三方认证是被反复验证的纠偏工具（Dranove 和 Jin，2010）。与此同时，模型服务市场的集中度已由 2024 年的 0.34 降至 2026 年的 0.21，竞争性在增强，这提示当前的政策重心应放在信息基础设施而非结构性干预（Armstrong，2006；Jullien 等，2021；顾聪等，2023）。

14.1.3 配置线：效率损失、制度阈值与增长贡献

结论七：算力利用率悖论可分解为四项可干预的损失。统一调度的效率改进空间由此可被精确界定。本书的分解显示，名义算力利用率为 62%，依次扣除空转损失 18%、批次损失 9%、匹配损失 12% 与效值损失 7% 后，有效效值利用率仅为 38%；实施任务—模型最优匹配的统一调度后可升至 54%，相对提升 42%，理论上界为 61%，仍留有 7 个百分点的剩余空间。四项损失的性质各不相同：空转与批次损失属于系统工程问题，可由连续批处理、分页注意力与预填充—解码分离等推理服务技术缓解（Yu 等，2022；Kwon 等，2023；Agrawal 等，2024；Zhong 等，2024）；匹配损失与效值损失则属于经济组织问题，其根源是任务与模型档位的错配，只能由跨主体的调度与计量制度解决。值得注意的是，各档位单位算力的标准词元产出 θ 相差 13.5 倍，这意味着「用高档位模型做低价值任务」的错配同时浪费算力与效值，是四项损失中经济含义最重的一项。生产集群的负载分析（Weng 等，2022）与智算中心、算力共享的经验研究（许诺等，2025；王勇等，2025）均支持这一判断。

结论八：城市词元运营中心的成败取决于制度阈值而非投资规模。「五个统一」之中，统一计量的边际制度价值最高。本书以层次分析法对制度要件赋权，配置效率、计价公允与可持续运营三准则的权重依次为 0.412、0.318 与 0.270（一致性比率 0.031）；要件层中统一计量以 0.271 居首，其后依次为统一结算 0.223、统一 API 入口 0.196、统一安全审计 0.166 与统一政策抵扣 0.144。三方演化博弈的结果更具警示意义：企业深度采纳成为演化稳定策略的临界红利为 $R_F^c = 1.55$ ，而基准情景的红利为 1.5，仅低出约 3%；就是这不足百分之四的差距，使系统收敛于「平台热、企业冷」的锁定均衡，政府被迫长期停留在强激励挡位（ $z \rightarrow 0.995$ ）而补贴无法退出。当效值透明与场景深化把红利提

升至 2.5 时，系统在约 41.7 期收敛于融合均衡且补贴顺利退出；若同时以统一接入降低企业采纳成本，收敛期进一步缩短至 23.5 期，缩短 44%。这提示政策的着力点不在于补贴规模，而在于把企业侧的采纳红利推过阈值，其中交易费用的节约（本书标定为 35%）是最直接的杠杆。标准化与网络效应文献早已指出，兼容性与共同标准的确立会改变采纳博弈的均衡选择（Farrell 和 Saloner, 1985；Katz 和 Shapiro, 1985），平台通过价格与规则机制改善资源配置的作用亦得到经验支持（刘诚和夏杰长, 2023；吴双和王勇, 2024）。

结论九：标准词元流量可作为独立要素进入生产函数。人工智能的增长贡献由此从索洛残差中显性分离，而碳约束构成这一增长路径的硬边界。基于城市一年度面板（观测数 1240）的估计显示，资本、劳动、数据与标准词元流量的产出弹性依次为 $\alpha_K = 0.318$ 、 $\alpha_L = 0.276$ 、 $\alpha_D = 0.094$ 与 $\alpha_T = 0.108$ ，均在 1% 水平显著；标准词元流量的弹性已达数据要素的 1.15 倍。2026 年标准词元流量对产出增长的直接贡献为 0.34 个百分点、占实际增长率的 6.8%；不引入词元变量时全要素生产率残差为 2.41%，引入后降至 2.12%，残差高估 0.29 个百分点、相对高估 13.7%。区域上东部、中部、西部的贡献率分别为 8.4%、5.1% 与 3.6%，东部约为西部的 2.33 倍——在算力产能明显西移的背景下，这一背离印证了增长贡献产生于词元的实际使用而非算力产能本身。这一结果既不支持人工智能增长效应的过度乐观叙事，也不支持其无效论：贡献是真实的、可测的，但仍处于通用目的技术扩散的早期，其量级受制于互补性投资的完成度（Bresnahan 和 Trajtenberg, 1995；Aghion 等, 2019；Crafts, 2021；Brynjolfsson 等, 2021），而任务暴露度与自动化可行性的约束意味着中期内不宜期待跃迁式的宏观效应（Acemoglu, 2025）。与此同时，碳约束的边界已经清晰可见：本书测得 2026 年用量加权平均碳强度为 2.263 gCO₂e/千标准词元，而绿色词元阈值为 1.0 gCO₂e/千标准词元，达标需要碳强度下降 55.8%；情景测算显示，至 2035 年基准情景仅降至 1.30，绿色情景与深度情景分别降至 0.62 与 0.34，只有后两者可跨越阈值。人工智能能耗的国际评估与生命周期测算亦提示，推理侧的累积能耗将成为约束的主要来源（Masanet 等, 2020；Patterson 等, 2022；IEA, 2025）。

14.1.4 九条结论的内在逻辑

把九条结论连起来读，可以看到一条严格的递进关系，而非九个并列的发现。结论一确立了问题：物理词元不可加。结论二与结论三给出了解法并验证了解法的有效性：四公理约束下的幂积折算函数使异质词元获得共同尺度，离散度

的收敛是这一解法有效的直接证据。结论四至结论六说明，一旦尺度统一，价格的结构、指数的口径与市场失灵的形态便都可以被清晰刻画：三层结构解释了分化，双指数分离了质量改进与真实降价，效值信息不对称被识别为首要失灵。结论七至结论九则说明，统一尺度进一步使配置效率可被分解与考核、制度阈值可被计算与跨越、增长贡献可被观测与归因，而碳强度为这一切设定了物理边界。九条结论共同支撑的判断是：词元经济当前面临的核心制度缺口不在算力供给、不在模型能力、也不在应用场景，而在计量规则；计量规则一旦确立，定价、配置、核算与绿色治理四类政策才可能建立在同一事实基础之上。

这一判断也解释了本书何以把绿色词元与增长核算同置于第三条主线。碳强度 ι 与产出弹性 α_T 看似分属环境与增长两个议题，但在式(14-1)中它们共享同一个分母：单位标准词元。缺少统一折算，则同一批词元在碳账上的排放与在增长账上的贡献会按不同口径被分别统计，二者既不可比也不可加，「以更低碳强度实现更高增长贡献」这一政策目标便无法被定义，更无从考核。第 13 章的多案例证据对此提供了来自实践的三角验证：47 位受访者的访谈材料经开放编码得到 412 个概念、23 个主轴范畴，最终凝练出 4 个核心范畴，其中「计量不透明」的参考点数以 143 居首，高于「成本不确定」的 118、「能力缺口」的 97 与「合规与安全顾虑」的 76。企业在实践中最先感受到的障碍，恰恰是本书在理论上识别出的首要缺口，这一定量与质性证据的相互印证，构成了下一节政策建议的经验基础。

14.2 政策建议

14.2.1 政策工具分工的经济学基础与三支柱框架

政策建议若只是结论的祈使句式改写，便没有独立的分析价值。为使建议具备可推导性，本节先把词元经济的配置问题写成一个社会计划者问题，再由其一阶条件读出政策工具的分工。设场景集为 J 、模型档位集为 M ，档位 m 为场景 j 生成的物理词元数为 T_{mj} ，对应效值系数为 η_{mj} ，场景 j 的价值函数 $V_j(\cdot)$ 严格凹且以标准词元投入为自变量；档位 m 的单位物理词元边际成本为 c_m 、单位算力占用为 π_m 、单位标准词元碳强度为 ι_m ，社会可用算力总量为 $\dot{C}$ ，碳的社会影子价格为 ψ 。社会计划者的问题是：

$$\max_{\{T_{mj} \geq 0\}} \sum_j V_j \left(\sum_m \eta_{mj} T_{mj} \right) - \sum_m \sum_j c_m T_{mj} - \psi \sum_m \sum_j \iota_m \eta_{mj} T_{mj} \text{ s.t. } \sum_m \sum_j \pi_m T_{mj} \leq \dot{C} \quad (14-2)$$

其中，目标函数的三项依次为场景价值、生产成本与碳的社会成本，约束为算力总量约束；记该约束的乘子为 ω ，即单位算力的影子价格。

对内点解求一阶条件，得 $\eta_{mj} V_j' = c_m + \psi \iota_m \eta_{mj} + \omega \pi_m$ 。这一条件可以读出三条彼此独立的边际法则，恰好对应三类性质不同的政策工具。其一，等式左端要求边际场景价值以效值系数加权，若 η_{mj} 不可观测或被虚报，则任何分散决策都无法达到该条件——这是信息问题，对应的工具是计量标准、效值披露与第三方认证，属计量侧。其二，等式右端第二项要求把碳的社会成本内部化进每一枚标准词元，若缺少可核证的碳强度凭证， $\psi \iota_m$ 便无从计入——这是外部性问题，对应的工具是碳足迹核算与绿色词元认证。其三，等式右端第三项要求同一影子价格 ω 在所有档位与场景之间成立，若算力被分割在互不连通的孤岛中，则每个孤岛有各自的 ω ，跨孤岛的边际产出无法均等——这是协调问题，对应的工具是统一调度、产能池化与互联互通，属配置侧。而定价侧的价格指数与披露规则，其作用在于使上述三类工具的效果可观测、可评估、可校准。由此，一个逻辑自治的政策体系必然呈现为「三支柱 + 一基础」的结构。

需要补充的是，这三类工具之间存在明确的先后次序而非并列关系。信息问题的解决是另外两类工具生效的前提：碳的社会成本需按标准词元计入，若折算规则未定，碳凭证便无统一的功能单位；算力影子价格的均等化需以任务—模型匹配为载体，若效值不可比，调度器无从判断何为最优匹配。因此本书主张的政策次序是计量先行、定价与配置并进、绿色与开放随行，而非四线齐发。据此设计的政策体系框架如图 14.1 所示。




图 14.1 词元经济的政策体系框架

图 14.1 的结构由上而下分为三层。顶层是「十五五」时期词元经济的治理目标：以标准词元为价值锚点，建成可计量、可定价、可配置、可核证的智能经济计量与治理体系。中层是三根支柱：计量侧以统一计量口径为纲，含计量国家标准、基准任务集与效值认证、用量与效值双口径统计、跨模型可比与跨境互认四项；定价侧以公允价格形成为纲，含双指数发布、三层价格结构披露、分级服务与普惠定价、效值虚标治理四项；配置侧以效率与绿色为纲，含统一调度平台、补贴由算力转向用词元、有效利用率纳入考核、绿色词元认证与碳足迹凭证四项。底层是标准与统计基础设施，含计量国家标准与检测方法、价格指数发布与监测平台、调度效率与有效利用率考核体系、绿色词元认证与国际互认机制四项，其与三根支柱之间以双向箭头相连，表示基础设施既支撑政策实施，也接收实施反馈以完成动态校准。这一结构与式(14-2)的一阶条件严格对应：三根支柱分别处理信息、协调与外部性三类扭曲，底层基础设施则提供使三类工具可被观测与校准的公共信息。

14.2.2 计量侧：以标准层级递进推动标准词元计量规则落地

计量侧的首要任务是把折算规则从学术命题变为公共规则，路径是标准层级的递进。截至 2026 年 8 月，词元领域已发布的成果主要处于团体标准与机构评

估层面：中国人工智能产业发展联盟归口的《人工智能词元（Token）运营管理能力要求》（AIIA/T 0308—2026）于2026年8月发布，中国信息通信研究院的「可信 AI-Token 服务质量评估」中含「Token 计量计费」维度，但二者的效力层级均低于行业标准与国家标准，且计量计费在其中只是评估体系的一个维度而非独立标准。与此同时，人工智能术语与大模型系列国家标准的制订工作归口于全国信息技术标准化技术委员会及其人工智能分技术委员会，尚未见专门以词元计量或词元计费为题的国家标准或行业标准计划公开。这一格局意味着，标准词元计量规则的制度化存在明确的空位与明确的归口。本书建议按「团体标准先行试用、行业标准衔接过渡、国家标准最终确立」的三步递进推进，其体例可直接借鉴综合能耗计算通则的当量折算传统（国家市场监督管理总局和国家标准化管理委员会，2020）：以基准档位在基准任务集上的一枚词元定义为1标准词元，公示三维权重及其标定方法，规定折算系数的测算规程、复评周期与争议解决程序。

第二项任务是建立基准任务集与效值认证机制。折算函数的可信度最终取决于三维效值的可测性：算力强度可由推理侧的浮点运算计数与硬件利用日志核验；推理质量需要一套覆盖多任务、多难度、公开可复现的基准任务集，其构建可借鉴大模型整体评测与多任务知识评测的方法学积累（Hendrycks 等，2021；Liang 等，2022），并辅以模型评判等低成本一致性检验手段（Zheng 等，2023）；场景效用则需要由行业侧的任务价值密度调查支撑，其口径应与技改补贴、政策抵扣的场景目录相衔接。认证环节建议采用「企业自评、第三方核验、主管部门抽查、结果公示、定期复评」的组合，并明确效值虚标的责任条款。之所以强调复评，是因为效值系数具有随技术进步而漂移的性质：同一档位模型的算力强度会因推理优化而下降、推理质量会因训练改进而上升，若折算系数长期不更新，标准词元本身便会失去基准意义。这是标准词元与标准煤、二氧化碳当量最重要的差别——后两者的折算系数由稳定的物理化学性质决定，前者的折算系数由持续演进的技术水平决定。

第三项任务是标准词元纳入常态化统计。当前的官方口径以日均调用量为主，这是一个物理词元口径的规模指标，可用于反映扩散速度，却无法用于价值加总与效率评价。本书建议实行用量与效值双口径报送：既报送物理词元调用量，也报送按公示折算系数换算的标准词元流量，并按模型档位、应用场景与区域分列。制度载体可依托全国数据资源调查等既有渠道（「国家数据局，2026」），并与数字经济统计与卫星账户的编制方案相衔接（杨仲山和张美慧，2019；许宪春等，2021；蔡跃洲和牛新星，2021）。在会计与资产口

径上，企业数据资源相关会计处理的暂行规定已为数据资源的确认与计量提供了先例（财政部，2023），数据资产化的会计确认与价值评估研究亦已积累了可资借鉴的框架（罗玫等，2023）；标准词元作为一种可计量的中间性认知服务流，其支出的归集与摊销规则应尽早研究，否则企业的词元投入将继续以混杂的费用科目沉没在管理费用之中，既不利于微观核算，也不利于宏观测度。

14.2.3 定价侧：双指数发布、结构披露与竞争秩序

定价侧的核心建议是建立词元价格的双轨监测与定期发布制度。具体而言，由行业主管部门委托第三方机构按季度编制并发布物理词元价格指数与标准词元价格指数，同时公布两者的背离幅度与降价来源分解。本书的测算已显示，忽略这一背离将把约 53% 的质量改进误记为价格让利。双指数发布的意义不仅在于统计准确，更在于为三类政策提供共同的观测基准：普惠成效评估应以标准词元价格指数为准，避免把效值提升记作普惠成果；补贴退坡的节奏应以标准词元价格的下行速度为参照，避免在真实成本尚未下降时过早退出；反垄断审查中对掠夺性定价的判别应以标准词元口径的价格—成本关系为准，避免把高效值模型的正常溢价误判为垄断加价。与之配套，建议要求平台侧披露三层价格结构的口径与构成比例，使成本底价、效值溢价与场景租金的边界可被外部核验。

第二项建议是把效值虚标治理纳入市场监管的常规议程。本书测得的效值认知偏差 0.44 与低效值档位过度采购份额 27% 表明，当前词元市场已具备柠檬市场的典型特征。治理工具的选择应遵循「先信息、后干预」的次序：优先以强制披露与第三方认证降低信息不对称，其次以合同示范文本明确效值承诺与违约责任，只有在披露与认证均告失效时才考虑更强的干预。第三项建议关乎竞争秩序。模型服务市场的集中度正在下降（赫芬达尔指数由 0.34 降至 0.21），但平台型中介的兴起可能在流通环节形成新的集中。多边平台的定价与竞争理论提示，平台的接入规则、数据获取与排他性安排比价格水平本身更具竞争影响（Armstrong，2006；Jullien 等，2021；Bergemann 和 Bonatti，2024），而平台经济反垄断的福利分析亦表明干预须区分效率型集中与排他型集中（顾聪等，2023）。据此，本书建议对城市词元运营中心一类的公共性平台明确其中立义务：统一入口不得转化为排他入口，统一计量不得转化为对特定供给方的隐性倾斜，统一结算不得成为资金沉淀的工具。

14.2.4 配置侧：调度效率考核与补贴对象的转向

配置侧的第一项建议是改造利用率考核的口径。现行考核多以机架上架率、GPU 卡时占用率一类的名义指标为准，而本书的分解表明，名义利用率

62%与有效效值利用率 38%之间存在 24 个百分点的缺口，其中匹配损失与效值损失合计 19%恰恰是名义指标完全看不见的部分。建议在国家枢纽节点与城市运营中心的考核体系中引入有效效值利用率指标，并以统一调度后的可达水平 54%为阶段性目标、以 61%为理论上界设定考核区间。需要说明的是，企业自报的智算资源利用率调研值与实测的卡时利用率、机架上架率分属不同统计对象与方法，不可互证，考核口径必须在制度文本中一次性写清。第二项建议是依托国家算力互联互通节点体系推进产能池化。工业和信息化部 2026 年初部署的「1+M+N」节点体系提出「统一标识、统一标准、统一规则」的运行机制，与全国一体化算力网「联网调度、普惠易用、绿色安全」的总体要求相衔接（「国家发展改革委等，2021」；国家发展改革委等，2023）；本书建议在此机制中明确把标准词元作为跨节点结算与调度的统一计量单位，否则跨节点的算力互通仍将止步于物理连通而无法实现经济意义上的可交易。

第三项建议是补贴对象由建算力转向用词元。演化博弈的结果显示，锁定均衡的成因不是补贴不足，而是企业侧采纳红利未越过临界值 $R_F^c = 1.55$ ；在此情形下追加供给侧补贴只会强化「平台热、企业冷」的结构。因此，财政资源应更多投向需求侧：把词元采购、模型部署与再训练的投入纳入企业技术改造支持方向，是当前地方实践中最具针对性的工具设计。上海市在软件和信息服务业发展规划中提出「探索将词元、数据治理、大模型部署及再训练等投入，纳入企业技术改造支持方向」（「上海市经济和信息化委员会，2026」），浙江省则在「十五五」规划纲要中部署一体化算力监测调度平台建设（「浙江省人民代表大会，2026」），二者恰好对应需求侧激励与供给侧协调两类工具。在国家层面，「人工智能+」行动已把六大重点行动的融合应用作为主线（国务院，2025），数据要素市场化配置改革亦为词元这一新型中间投入的流通提供了制度环境（蔡跃洲和马文君，2021；熊巧琴和汤珂，2021；「国家数据局等，2023」）。需要提醒的是，需求侧补贴同样存在退坡问题，其退出条件将在 14.2.6 节以形式化方式给出。

14.2.5 绿色与开放：可核证的碳强度与可互认的折算规则

绿色侧的核心建议是建立以标准词元为功能单位的碳足迹核算规则与绿色词元认证制度。当前的制度基础是清晰的：产品碳足迹量化的国家标准修改采用了国际标准（「ISO，2018」；国家市场监督管理总局和国家标准化管理委员会，2024），碳足迹管理体系的实施方案已提出到 2027 年制定发布与国际接轨的国家产品碳足迹核算通则标准并出台约 100 个重点产品核算规则标准（生态

环境部等，2024），产品碳足迹核算标准编制工作指引亦已发布（「生态环境部等，2024」）。空缺同样清晰：截至 2026 年 8 月，尚未见面向词元的专项碳足迹核算标准发布或立项公开，相关工作目前挂靠在产品碳足迹管理体系与算力中心能效核算之下；国际层面，人工智能系统环境可持续性方面的文件属技术报告性质，不具备认证效力，词元级碳足迹缺乏国际互认的核算规则。本书建议把绿色词元阈值设定为 $1.0 \text{ gCO}_2\text{e}/\text{千标准词元}$ ，并明确其为可核证的准入型阈值而非平均值目标——2026 年用量加权平均碳强度为 $2.263 \text{ gCO}_2\text{e}/\text{千标准词元}$ ，全绿电情形下可降至 0.171，说明阈值可达但需要绿电比例与服务效率的同步改进。这里必须坚持量纲纪律：每百万标准词元耗电（千瓦时）与电力排放因子（千克二氧化碳每千瓦时）相乘即得每千标准词元的克数，换算系数恰为 1，任何脱离该量纲的碳强度数值都不具备可比性。

实现路径上，绿色词元认证应与既有的绿电制度衔接而非另起炉灶。绿电直连的有关规定已明确新能源不接入公共电网、经直连线路向单一电力用户供给并实现电量清晰物理溯源的模式，2026 年进一步扩展至多用户绿电直连；可再生能源电力消纳责任权重的下达则已把国家枢纽节点新建数据中心的绿色电力消费比例纳入考核条款；国家数据局亦提出力争实现国家枢纽节点新建数据中心绿电占比达到八成的目标，并在若干枢纽节点部署算电协同先行先试；算力与电力协同发展的技术路径与经济可行性亦已有系统评估（中国信息通信研究院，2025）。本书建议以绿证与绿电交易凭证为溯源基础（国家发展改革委等，2023b；国家发展改革委和国家能源局，2025），按模型档位与运行时段核算碳强度，形成可随词元服务一并交付的碳足迹凭证；技术上可借助内容溯源与水印方法确保凭证与实际调用记录的绑定（Kirchenbauer 等，2023；Dathathri 等，2024），制度上应与生成式人工智能服务与深度合成的合规要求相衔接（「国家互联网信息办公室等，2022」；国家互联网信息办公室等，2023）。需要提请注意的是，绿证核发量与交易量是两个独立指标，且现行温室气体核算规则允许绿证与用电量按年匹配，而国际规则修订正朝更细颗粒度的时空匹配方向推进，据此作出的绿电声明存在时效风险，绿色词元凭证的设计宜预留时空匹配的接口。

开放侧的建议围绕跨境互认展开。就现行规则而言，欧盟碳边境调节机制的确定期自 2026 年 1 月 1 日起实施、证书清缴自 2027 年 2 月起适用，其覆盖行业为水泥、钢铁、铝、化肥、电力与氢，并不包含数字服务、软件或人工智能服务（「European Parliament and Council，2023」）。因此，「词元出海」目前并不直接面临碳边境调节的申报义务，但两条间接渠道值得预置：其一，若词

元服务以嵌入实体产品的形式出口，其隐含排放可能进入产品碳足迹的核算边界；其二，若跨境算力协作以电力项下的形态出现，则须关注电力类别的核算要求。本书测得出海导向企业对绿色词元的支付意愿溢价系数为 0.083（标准误 0.021，观测数 612），说明市场已先于监管形成了对可核证低碳词元的定价，这为我国以标准输出参与国际规则塑造提供了窗口。建议以标准词元折算规则与绿色词元碳足迹凭证为抓手，在双边与多边框架下推动互认，其制度逻辑与绿色金融统计标准的国际比较经验相通（陈丹丹等，2025），也与碳市场机制设计中「先统一计量、后统一交易」的次序一致（张希良等，2021；张希良等，2022；蓝虹和杜彦霖，2024）。

14.2.6 补贴的退出条件、实施时序与政策清单

前述建议中，唯有补贴涉及明确的退出问题：补贴过早退出会使系统回落至锁定均衡，过晚退出则造成财政负担与激励扭曲。本书据第 10 章的演化博弈结果给出一个可操作的退出规则。设政府的强激励强度为 s_t 、上限为 $\acute{s}$ ，企业深度采纳的净红利随平台建设水平 x_t 与同侪采纳规模 y_t 递增， τ 为统一入口与统一计量带来的交易费用节约、 $\mathcal{G}$ 为网络外部性强度， R_F^{ss} 为补贴退出后融合稳态自我维持所需的临界红利，则退出规则与退出时点可写作：

$$s_t = \acute{s} \cdot 1\{R_F(x_t, y_t) < R_F^{ss}\}, R_F(x_t, y_t) = R_F^0 + \tau x_t + \mathcal{G} y_t, t^* = \inf\{t \geq 0: R_F(x_t, y_t) \geq R_F^{ss}\} \quad (14-3)$$

其中， $1\{\cdot\}$ 为示性函数， R_F^0 为无平台建设与无同侪效应时的基准红利， t^* 为满足自维持条件的最早时点，即补贴的退出时点。

由式(14-3)可得三条推论。推论一是退出的充分条件而非时间条件：补贴应在红利越过 $R_F^{ss} = 1.80$ 时退出，而不应按预设年限退出；本书标定的临界红利 $R_F^c = 1.55$ 只是采纳成为演化稳定策略的门槛，自维持条件要求更高的 1.80，比基准红利高出 20%，二者不可混用。推论二是财政支出的上界：总补贴支出约为 $\acute{s}t^*$ ，而 t^* 对 τ 与 $\mathcal{G}$ 严格递减，这意味着提高交易费用节约与加快同侪扩散可直接压缩财政成本——本书情景测算中，仅通过统一接入降低企业采纳成本，收敛期便由 41.7 期缩短至 23.5 期，降幅 44%，对应的财政节约同比例发生。推论三是时间一致性要求：退出规则必须事前公布并可被企业验证，否则企业会预期补贴长期存在而推迟自主投入，使 y_t 的上升被人为延后，反而推高 t^* 。据此，本书建议地方在设立词元补贴时同步公布退出的触发指标（如本地企业深度采纳

率、标准词元采购中付费部分占比)与核验方式,把补贴从行政裁量事项转变为规则约束事项。

综合 14.2.1 至 14.2.6 节的分析,本书把政策建议整理为覆盖计量、定价、配置、绿色与开放五个方面的清单,并标注各条建议对应的关键量化指标、制度抓手与建议时序,见表 14.1。

表 14.1 词元经济政策建议清单及其量化基准

政策侧	建议条目	关键量化基准	制度抓手	建议时序
计量侧	制定标准词元计量标准并公示折算规则	权重 0.438/0.296/0.265, 拟合 $R^2 = 0.9996$	团体标准试用—行业标准过渡—国家标准确立	近期启动、中期发布
计量侧	建立基准任务集与效值第三方认证	基准档 $\eta \equiv 1.0$, 传递一致性误差近机器精度	企业自评 + 第三方核验 + 抽查公示 + 定期复评	近期
计量侧	实行用量与效值双口径统计报送	物理词元日均 140 万枚 (2026 年 3 月, 官方口径) 与标准词元流量并行	纳入全国数据资源调查与数字经济统计制度	近期
定价侧	按季编制并发布 TPI 与 STPI 双指数	2026Q2 TPI = 21、STPI = 47 (2024Q1 = 100)	主管部门委托第三方编制并公布背离分解	近期
定价侧	强制披露三层价格结构与效值信息	成本底价占比 24%—45%	平台披露 + 合同示范文本 + 违约责任条款	近期
定价侧	治理效值虚标与逆向选择	认知偏差 0.44, 过度采购份额 27%	质量披露与认证制度, 平台中立义务	中期
配置侧	以有效效值利用率替代名义利用率考核	现状 38%→目标 54% (上界 61%)	枢纽节点与城市运营中心考核体系	中期
配置侧	以标准词元为跨节点调度与结算单位	档位间转化效率相差 13.5 倍	国家算力互联互通节点「1+M+N」体系	近期—中期
配置侧	补贴由建算力转向用词元	临界红利 $R_F^C = 1.55$, 自维持 1.80	技改补贴与政策抵扣挂钩, 退出规则事前公布	近期
绿色侧	建立词元级碳足迹核算规则与绿色词元认证	阈值 1.0、现状 2.263 gCO ₂ e/千标准词元	对接产品碳足迹国家标准与管理体系统施方案	中期
绿色侧	推进算电协同与绿电凭证绑定	绿电比例 2026 年 44%, 全绿电碳强度 0.171	绿电直连、消纳责任权重与绿证交易	近期—中期
开放侧	推动折算规则与碳足迹凭证的国际互认	出海企业绿色词元溢价 8.3%	双边与多边标准互认, 参与国际规则制定	中长期

注：关键量化基准中的效值权重、指数、利用率、阈值与临界红利均取自本书第 5、7、9、10、11 章的校准复算结果，口径与各章估计表一致；物理词元日均调用量为国家数据局公开发布的官方点位；TPI 与 STPI 分别为词元价格指数与标准词元价格指数， R_F^c 为企业深度采纳成为演化稳定策略的临界红利。「近期」指 2026—2027 年，「中期」指「十五五」时期，「中长期」指 2030 年前后，时序为作者建议而非既定安排。

表 14.1 的排列本身包含两层判断。第一层是次序判断：计量侧的三条建议均标注为近期，定价侧与配置侧的多数条目标注为近期至中期，绿色与开放侧则为中期至中长期，这一时序安排来自 14.2.1 节的推导——信息问题的解决是外部性内部化与协调问题解决的前提，而非出于绿色议题次要的价值判断。第二层是抓手判断：每一条建议都对应一个既有的制度载体而非新设机构，标准工作归口既有技术委员会，统计报送依托既有调查制度，调度与结算依托既有算力互联互通节点，碳核算依托既有产品碳足迹管理体系。这一设计的考虑是，词元经济的制度建设正处在窗口期，新设机构的组织成本与协调成本可能超过其收益，而在既有制度中嵌入新的计量单位，其边际成本要低得多。需要重申的是，表中所有阈值与目标值均为本书基于校准复算得到的分析性基准，可作为讨论与试点的起点，其正式采用仍须经过标准制订程序中的实测验证与多方协商。

14.3 理论、方法与实践贡献

14.3.1 理论贡献

本书的理论贡献可归纳为三个层面。第一个层面是提出并论证了标准词元这一概念，把当量折算的经济学传统扩展到认知生产领域。标准煤解决了异质能源的可加问题，标准箱解决了异质货物的运力可加问题，二氧化碳当量解决了异质温室气体气候影响的可加问题；标准词元所要解决的，是异质认知服务的价值可加问题。这一扩展并非简单类比：能源与温室气体的折算系数由物理化学性质决定，而词元的折算系数由技术水平与场景结构共同决定，因而必须以公理化的方式约束函数形式，并以可复核的方式确定权重。本书证明的幂积形式唯一性结论，正是这一方法论要求的产物。第二个层面是把标准词元嵌入价值、价格与增长三套理论装置：在价值论上说明词元价值来自活劳动与物化劳动的双重凝结及场景中的价值实现；在价格论上提出三层结构，解释了零边际成本产品何以仍存在稳定的价格梯度；在增长论上把标准词元流量作为独立要素引入生产函数，使人工智能的贡献从残差中分离。

第三个层面是对既有文献缺口的填补。在计量与评价方向，既有的四套词元评价体系分属不同主体、维度不同、用途不同，其共同的方法论定位是多维评价；本书的定位是当量折算，二者不是竞争关系而是接续关系——多维评价提供可测的维度与达标基线，当量折算提供把维度合成为单一尺度的函数。在数据要

素方向，既有研究已就数据的非竞争性、确权与定价形成较为完整的认识（Jones 和 Tonetti，2020；熊巧琴和汤珂，2021；欧阳日辉和杜青青，2022），但数据要素的价值实现最终要经由模型推理转化为可用的认知服务，词元正是这一转化的计量单位，本书由此为数据要素理论补上了「从资源到服务」的一环。在增长核算方向，本书与资本服务测度传统在方法论上同构：资本服务的加总需要使用者成本作为权重，标准词元的加总需要效值系数作为权重，差别在于前者可由资产市场租金率间接推断，后者因缺乏成熟租赁市场而必须由公理化折算函数构造。在新质生产力的理论讨论中，本书提供了一个可计量、可核算的微观基础（周文和许凌云，2023；洪银兴，2024；韩文龙等，2024），使「智能化如何转化为生产力」这一命题获得了可操作的观测变量。

14.3.2 方法贡献

方法层面的贡献有四项。其一是公理化建模与实证标定的联合使用：本书先由四条公理推出折算函数的形式，再以基准任务集数据标定权重，并把函数形式放宽为不变替代弹性形式作交叉验证，替代参数的标定值在统计上无法拒绝退化为加权几何平均的原假设，从而使公理推论与实证证据相互印证。这一策略避免了纯公理化模型缺乏经验内容与纯数据驱动指标缺乏理论约束这两类常见缺陷。其二是双指数编制方法：把质量调整的思想引入词元价格测度，以效值系数替代享乐回归中的特征系数，使质量改进与真实降价得以分离，这是对享乐价格指数传统的一种适应性改造（Griliches，1961；Pakes，2003）。其三是效率损失的四项分解：把工程侧的空转与批次损失和经济侧的匹配与效值损失置于同一框架，并证明统一调度的效率改进存在可计算的上界，使「利用率低」这一模糊判断转化为可分解、可考核、可干预的结构诊断。其四是多方法的三角验证：以演化博弈刻画制度跃迁的阈值效应，以层次分析法对制度要件赋权，以扎根理论对企业采纳障碍编码，三类证据在「计量不透明是首要障碍」这一结论上相互印证，降低了单一方法的识别风险。

14.3.3 实践贡献

实践层面，本书的直接产出是一套可操作的计量与治理工具箱：折算规程与权重、基准任务集与认证流程的设计要点、双指数的编制口径、有效效值利用率的考核口径、绿色词元阈值与碳足迹凭证的设计要点、补贴退出的触发规则。这些工具的共同特征是均以标准词元为公共计量基础，因而可以组合使用而不产生口径冲突。对城市词元运营中心而言，本书提供了主体选择与职能匹配的分析框

架、「五个统一」的权重排序，以及跃迁阈值的判别方法，可直接用于运营方案的自我评估；对平台企业而言，本书提供了三层价格结构的定价参照与效值披露的合规预期；对用户企业而言，本书提供了以标准词元单价而非物理词元单价进行选型与成本核算的方法。需要审慎说明的是，本书的全部数值结果均为基于公开锚点的校准复算，其作用是提供量级参照与结构判断，而非可直接引用的官方统计；实践应用时应以本地实测数据重新标定，本书提供的是方法与框架，而非现成的参数表。

14.4 研究局限与未来展望

14.4.1 研究局限

本书的局限首先在于数据。词元经济的统计基础尚在形成之中，公开可得权威数据仅有国家数据局发布的少数官方点位与若干机构报告，本书的多数数值结果系在这些锚点上作校准复算与插值得到，非官方点位在正文与图表中均已注明。这决定了本书结论的性质：结构判断与机理论证具有稳健性，而具体数值只具有量级参照意义。其次在于折算体系的经验基础。三维效值中，算力强度可由推理日志较为客观地测度，推理质量依赖基准任务集的选择，场景效用则依赖对任务价值密度的判断，后两者都存在测量误差与主观性；本书虽以拟合优度与交叉验证提供了内部一致性证据，但缺乏独立的外部效度检验。第三在于识别策略。增长核算部分的面板估计难以完全排除词元使用与产出之间的双向因果，价格与用量的联立性亦未在统一框架内处理；样本期偏短使滞后结构与累积弹性无法稳健识别。第四在于覆盖范围。跨境词元服务的进出口尚未纳入核算边界，多模态词元与图像、音视频词元的折算规则只作了原则性讨论而未细化，训练侧词元与推理侧词元的区分亦有待深化。第五在于制度分析的样本。城市运营中心的实践刚刚起步，五城案例的观察窗口不足一年，制度绩效的判断只能是前瞻性的，尚不足以支撑因果推断。

14.4.2 未来展望

基于上述局限，本书提出六个值得推进的研究方向。第一是折算体系的动态化与多模态扩展。效值系数随技术进步而漂移的性质要求研究折算系数的更新规则：更新过频会损害计量的稳定性，过疏会使基准失真，如何在二者之间求得最优复评周期，是一个可以形式化的机制设计问题。多模态方向上，图像、音频与视频词元的算力强度与信息密度关系与文本差异极大，需要在同一公理框架下扩展维度而不破坏可加性。第二是折算规则的国际比较与互认。不同经济体若各自

建立折算体系，词元的跨境流动将面临类似于碳核算中的重复计算与规则冲突问题，跨国比较与互认机制的研究应尽早启动。第三是微观识别。随着企业级词元使用数据的可得性提高，可以用准实验方法识别词元投入对企业生产率、成本结构与就业结构的因果效应，这将为本书的宏观核算提供微观基础；既有关于人工智能与全要素生产率、任务替代与劳动力市场的经验研究为此提供了方法参照（蔡跃洲和陈楠，2019；任英华等，2023；Autor，2024）。

第四是词元市场的结构演化研究。随着词元成为可计量、可定价的标的，其交易形态可能由现货服务向合约化、标准化方向演进，进而产生远期、容量预留乃至指数挂钩产品，这些新形态的价格发现机制与风险配置效率值得研究，其制度设计亦可借鉴配额与凭证类市场的经验（杨豪等，2023；段玉婉等，2023；姜春海等，2024）。第五是绿色词元的全链条核算与治理。本书处理的主要是推理侧的运行碳排放，训练侧的隐含排放、硬件生产与退役的具身排放以及水资源消耗均未纳入（Luccioni 等，2023；de Vries，2023；Crawford，2024；Li 等，2025），全生命周期口径下的绿色词元定义与阈值设定是下一步的关键工作。第六是词元经济与就业、分配的关系。本书聚焦计量、定价与配置，未展开分配议题，而认知服务的规模化供给必然改变任务结构与技能溢价，其对劳动收入份额与区域差距的影响需要专门研究（王永钦和董雯，2020；柏培文和张云，2021；王林辉等，2022；肖土盛等，2022；何小钢等，2023）。这六个方向共同指向一个更长期的判断：词元经济的研究正处在从现象描述向制度分析、从技术指标向经济计量转型的起点，本书希望提供的是这一转型所需的一块地基，而非一座完整的建筑。

14.5 本章小结

本章是全书的收束。围绕「物理词元不是合格的价值单位、只有标准词元才能承担四重经济职能」这一核心命题，本章首先以式(14-1)的枢纽恒等式组把折算、计价、转化、碳核算与增长核算五条线索接在同一个变量上，进而沿计量、定价、配置三条主线归纳出九条主要结论。计量线的三条结论确立了问题与解法：折算前单位词元价格的变异系数达 0.92、极差 12.6 倍，物理词元不可加；四条公理约束下折算函数必为幂积形式，标定权重为 0.4383、0.2964 与 0.2653，不变替代弹性形式的独立标定与之相互印证；折算后变异系数降至 0.31、极差收敛至 2.4 倍，价格趋近一价定律。本章同时明确了本书与既有工作的关系：中国信息通信研究院的六维服务质量评估与四维标准体系、中国工业互联网研究院的五维价值度量、清华大学翟季冬团队联合清程极智的三项实测指

标，四套体系主体不同、维度不同、用途不同，其共同定位是多维评价，而本书的增量在于从多维评价推进到当量折算。

定价线的三条结论刻画了价格的结构、指数的口径与市场的失灵：三层价格结构中成本底价占比随档位由 45.0% 降至 24.0%、场景租金占比由 32.5% 升至 44.4%，解释了通用词元降价与高效值词元溢价扩大的并存；物理词元价格指数累计下降 79% 而标准词元价格指数仅下降 53%，表观降价中约 53% 实为效值提升，以物理单价评估普惠成效将产生系统性偏差；需求弹性 -1.34 且行业异质极强，而效值认知偏差 0.44 与低效值过度采购份额 27% 表明信息不对称是首要失灵。配置线的三条结论则给出了效率、制度与增长的定量判断：名义利用率 62% 经四项损失后降至有效效值利用率 38%，统一调度可回升至 54%、上界 61%；企业采纳的临界红利 1.55 仅比基准情景高 3%，却决定了补贴能否退出，制度阈值的「差之毫厘」效应由此凸显；标准词元流量的产出弹性 0.108 使 2026 年词元贡献达 0.34 个百分点、占实际增长率的 6.8%，并使全要素生产率残差的高估被纠正 0.29 个百分点，而碳强度 2.263 与阈值 1.0 gCO₂e/千标准词元之间的差距为这一增长路径设定了硬边界。

在结论的基础上，本章从社会计划者的配置问题出发，以式(14-2)的一阶条件推出政策工具的分工逻辑：效值加权的边际条件对应信息问题，碳成本内部化对应外部性问题，算力影子价格的均等化对应协调问题，三者分别由计量侧、绿色治理与配置侧工具处理，而定价侧的指数与披露使三类工具的效果可被观测。据此提出的政策体系呈现为「三支柱 + 一基础」结构，并整理为十二条政策建议清单。清单的两个特点值得强调：其一是次序，计量先行不是价值排序而是逻辑必需；其二是抓手，每条建议均嵌入既有制度载体而非新设机构，以降低组织与协调成本。本章还以式(14-3)给出补贴退出的规则化条件，指出退出应以红利越过自维持阈值 1.80 为条件而非以预设年限为条件，并证明提高交易费用节约与加快同侪扩散可直接压缩财政支出上界，退出规则必须事前公布方能满足时间一致性。

最后，本章陈述了本书在理论、方法与实践三个层面的贡献，并坦陈了数据基础、折算体系外部效度、识别策略、覆盖范围与制度样本五方面的局限，提出折算体系动态化与多模态扩展、折算规则的国际比较与互认、微观因果识别、词元市场的结构演化、绿色词元的全链条核算、词元经济与就业分配关系六个研究方向。综观全书，词元由一个技术计量单位成长为经济计量单位的过程，本质上是一次计量革命在智能经济领域的重演：正如标准煤之于能源经济、标准箱之于航运经济、二氧化碳当量之于气候治理，标准词元的意义不在于它是一个新指

标，而在于它使一类此前无法加总的经济活动获得了可加、可比、可核算的共同尺度。术语的统一已由全国科学技术名词审定委员会以发布试用的方式迈出第一步，计量规则的统一则有待标准、统计与认证三套制度的协同推进。本书的判断是：在算力与模型的竞争之后，真正决定智能经济能否高质量运行的，将是计量地基的牢固程度；而地基一旦筑成，定价、配置、绿色与增长四类政策才可能建立在同一套事实之上，词元经济也才能够从规模扩张走向效率提升与制度成熟。

参考文献

- [1] 国家市场监督管理总局, 国家标准化管理委员会. 综合能耗计算通则: GB/T 2589—2020[S]. 北京: 中国标准出版社, 2020.
- [2] WORLD RESOURCES INSTITUTE, WORLD BUSINESS COUNCIL FOR SUSTAINABLE DEVELOPMENT. Greenhouse gas protocol product life cycle accounting and reporting standard[S/OL]. Washington, DC: WRI; Geneva: WBCSD, 2011[2026-08-13]. <https://ghgprotocol.org/product-standard>.
- [3] INTERNATIONAL ORGANIZATION FOR STANDARDIZATION. Greenhouse gases — carbon footprint of products — requirements and guidelines for quantification: ISO 14067:2018[S/OL]. Geneva: ISO, 2018[2026-08-13]. <https://www.iso.org/standard/71206.html>.
- [4] 国家市场监督管理总局, 国家标准化管理委员会. 温室气体 产品碳足迹 量化要求和指南: GB/T 24067—2024[S]. 北京: 中国标准出版社, 2024.
- [5] FARRELL J, SALONER G. Standardization, compatibility, and innovation[J]. The RAND Journal of Economics, 1985, 16(1): 70-83.
- [6] SIMCOE T. Standard setting committees: consensus governance for shared technology platforms[J]. American Economic Review, 2012, 102(1): 305-336.
- [7] 何凡, 黄炜, 陈波. 标准的力量: 物流标准化与企业全要素生产率提升[J]. 数量经济技术经济研究, 2025, 42(8): 26-46.
- [8] JONES C I, TONETTI C. Nonrivalry and the economics of data[J]. American Economic Review, 2020, 110(9): 2819-2858.
- [9] 熊巧琴, 汤珂. 数据要素的界权、交易和定价研究进展[J]. 经济学动态, 2021(2): 143-158.
- [10] 欧阳日辉, 杜青青. 数据要素定价机制研究进展[J]. 经济学动态, 2022(2): 124-141.
- [11] PEI J. A survey on data pricing: from economics to data science[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 34(10): 4586-4608.
- [12] 财政部. 关于印发《企业数据资源相关会计处理暂行规定》的通知: 财会〔2023〕11号[EB/OL]. (2023-08-21)[2026-08-13]. http://kjs.mof.gov.cn/zhengcefabu/202308/t20230821_3903354.htm.
- [13] 罗玫, 李金璞, 汤珂. 企业数据资产化: 会计确认与价值评估[J]. 清华大学学报(哲学社会科学版), 2023, 38(5): 195-209.
- [14] 杨仲山, 张美慧. 数字经济卫星账户: 国际经验及中国编制方案的设计[J]. 统计研究, 2019, 36(5): 16-30.

- [15] 许宪春, 张美慧, 张钟文. 数字化转型与经济社会统计的挑战和创新[J]. 统计研究, 2021, 38(1): 15-26.
- [16] 蔡跃洲, 牛新星. 中国数字经济增加值规模测算及结构分析[J]. 中国社会科学, 2021(11): 4-30.
- [17] 蔡跃洲, 马文君. 数据要素对高质量发展影响与数据流动制约[J]. 数量经济技术经济研究, 2021, 38(3): 64-83.
- [18] SENNRICH R, HADDOW B, BIRCH A. Neural machine translation of rare words with subword units[C]//Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Berlin: Association for Computational Linguistics, 2016: 1715-1725.
- [19] KUDO T, RICHARDSON J. SentencePiece: a simple and language independent subword tokenizer and detokenizer for neural text processing[C]//Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations. Brussels: Association for Computational Linguistics, 2018: 66-71.
- [20] RUST P, PFEIFFER J, VULIĆ I, et al. How good is your tokenizer? On the monolingual performance of multilingual language models[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Online: Association for Computational Linguistics, 2021: 3118-3135.
- [21] PETROV A, LA MALFA E, TORR P H S, et al. Language model tokenizers introduce unfairness between languages[C]//Advances in Neural Information Processing Systems 36 (NeurIPS 2023). Red Hook, NY: Curran Associates, 2023: 36963-36990.
- [22] AHIA O, KUMAR S, GONEN H, et al. Do all languages cost the same? Tokenization in the era of commercial language models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing. Singapore: Association for Computational Linguistics, 2023: 9904-9923.
- [23] KATZ M L, SHAPIRO C. Network externalities, competition, and compatibility[J]. American Economic Review, 1985, 75(3): 424-440.
- [24] 国家发展改革委, 中央网信办, 工业和信息化部, 等. 全国一体化大数据中心协同创新体系算力枢纽实施方案: 发改高技〔2021〕709号[EB/OL]. (2021-05-24)[2026-08-13].
https://www.ndrc.gov.cn/xxgk/zcfb/tz/202105/t20210526_1280838.html.
- [25] 国家发展改革委, 国家数据局, 中央网信办, 等. 关于深入实施“东数西算”工程 加快构建全国一体化算力网的实施意见: 发改数据〔2023〕1779号[EB/OL]. (2023-12-29)

- [2026-08-13].
https://www.ndrc.gov.cn/xxgk/zcfb/tz/202312/t20231229_1363000.html.
- [26] 许诺, 毛聚, 毛新述, 等. 算力部署、数据跨域流动与企业全要素生产率——来自智算中心的证据[J]. 中国工业经济, 2025(4): 61-79.
- [27] 王勇, 傅芳宁, 陆树檀. 算力共享与算力市场培育——基于需求侧的算力资源配置研究[J]. 财经问题研究, 2025(4): 3-14.
- [28] 上海市经济和信息化委员会. 上海市软件和信息服务业发展“十五五”规划: 沪经信软〔2026〕471号[EB/OL]. (2026-08-04)[2026-08-13].
<https://sheitc.sh.gov.cn/cyfz/20260811/7ff732b1c470421c86e46d14c0270ead.html>.
- [29] NOY S, ZHANG W. Experimental evidence on the productivity effects of generative artificial intelligence[J]. Science, 2023, 381(6654): 187-192.
- [30] BRYNJOLFSSON E, LI D, RAYMOND L. Generative AI at work[J]. The Quarterly Journal of Economics, 2025, 140(2): 889-942.
- [31] CZARNITZKI D, FERNÁNDEZ G P, RAMMER C. Artificial intelligence and firm-level productivity[J]. Journal of Economic Behavior & Organization, 2023, 211: 188-205.
- [32] BICK A, BLANDIN A, DEMING D J. The rapid adoption of generative AI: NBER working paper No. 32966[R]. Cambridge, MA: National Bureau of Economic Research, 2024.
- [33] HUMLUM A, VESTERGAARD E. The unequal adoption of ChatGPT exacerbates existing inequalities among workers[J]. Proceedings of the National Academy of Sciences of the United States of America, 2025, 122(1): e2414972121.
- [34] ACEMOGLU D. The simple macroeconomics of AI[J]. Economic Policy, 2025, 40(121): 13-58.
- [35] OECD. The impact of artificial intelligence on productivity, distribution and growth: key mechanisms, initial evidence and policy challenges[R/OL]. Paris: OECD Publishing, 2024[2026-08-13].
https://www.oecd.org/en/publications/the-impact-of-artificial-intelligence-on-productivity-distribution-and-growth_8d900037-en.html.
- [36] BRYNJOLFSSON E, ROCK D, SYVERSON C. Artificial intelligence and the modern productivity paradox: a clash of expectations and statistics[M]//AGRAWAL A, GANS J, GOLDFARB A. The economics of artificial intelligence: an agenda. Chicago: University of Chicago Press, 2019: 23-57.

- [37] BRYNJOLFSSON E, ROCK D, SYVERSON C. The productivity J-curve: how intangibles complement general purpose technologies[J]. American Economic Journal: Macroeconomics, 2021, 13(1): 333-372.
- [38] SYVERSON C. Challenges to mismeasurement explanations for the US productivity slowdown[J]. Journal of Economic Perspectives, 2017, 31(2): 165-186.
- [39] BYRNE D M, CORRADO C A, SICHEL D E. The rise of cloud computing: minding your P's, Q's and K's: NBER working paper No. 25188[R]. Cambridge, MA: National Bureau of Economic Research, 2018.
- [40] DESTEFANO T, KNELLER R, TIMMIS J. Cloud computing and firm growth[J]. The Review of Economics and Statistics, 2025, 107(6): 1638-1651.
- [41] AKERLOF G A. The market for "lemons": quality uncertainty and the market mechanism[J]. The Quarterly Journal of Economics, 1970, 84(3): 488-500.
- [42] DRANOVE D, JIN G Z. Quality disclosure and certification: theory and practice[J]. Journal of Economic Literature, 2010, 48(4): 935-963.
- [43] EUROPEAN PARLIAMENT, COUNCIL OF THE EUROPEAN UNION. Establishing a carbon border adjustment mechanism: Regulation (EU) 2023/956[EB/OL]. (2023-05-16)[2026-08-13].
<https://eur-lex.europa.eu/legal-content/EN/TXT/PDF/?uri=CELEX:32023R0956>.
- [44] PATTERSON D, GONZALEZ J, HÖLZLE U, et al. The carbon footprint of machine learning training will plateau, then shrink[J]. Computer, 2022, 55(7): 18-28.
- [45] LUCCIONI A S, JERNITE Y, STRUBELL E. Power hungry processing: watts driving the cost of AI deployment?[C]//Proceedings of the 2024 ACM Conference on Fairness, Accountability, and Transparency (FAccT '24). New York: ACM, 2024: 85-99.
- [46] INTERNATIONAL ENERGY AGENCY. Energy and AI[R]. Paris: International Energy Agency, 2025.
- [47] MUSSA M, ROSEN S. Monopoly and product quality[J]. Journal of Economic Theory, 1978, 18(2): 301-317.
- [48] BHARGAVA H K, CHOUDHARY V. Research note: when is versioning optimal for information goods?[J]. Management Science, 2008, 54(5): 1029-1035.
- [49] ARMSTRONG M. Competition in two-sided markets[J]. RAND Journal of Economics, 2006, 37(3): 668-691.

- [50] JULLIEN B, PAVAN A, RYSMAN M. Two-sided markets, pricing, and network effects[M]//HO K, HORTAÇSU A, LIZZERI A. Handbook of industrial organization: Volume 4. Amsterdam: North-Holland, 2021: 485-592.
- [51] GRILICHES Z. Hedonic price indexes for automobiles: an econometric analysis of quality change[M]//NATIONAL BUREAU OF ECONOMIC RESEARCH. The price statistics of the federal government. New York: National Bureau of Economic Research, 1961: 173-196.
- [52] PAKES A. A reconsideration of hedonic price indexes with an application to PC's[J]. American Economic Review, 2003, 93(5): 1578-1596.
- [53] GROSHEN E L, MOYER B C, AIZCORBE A M, et al. How government statistics adjust for potential biases from quality change and new goods in an age of digital technologies: a view from the trenches[J]. Journal of Economic Perspectives, 2017, 31(2): 187-210.
- [54] BRESNAHAN T F, TRAJTENBERG M. General purpose technologies "engines of growth"?[J]. Journal of Econometrics, 1995, 65(1): 83-108.
- [55] CRAFTS N. Artificial intelligence as a general-purpose technology: an historical perspective[J]. Oxford Review of Economic Policy, 2021, 37(3): 521-536.
- [56] 周文, 许凌云. 论新质生产力：内涵特征与重要着力点[J]. 改革, 2023(10): 1-13.
- [57] 洪银兴. 新质生产力及其培育和发展[J]. 经济学动态, 2024(1): 3-11.
- [58] 黄群慧, 盛方富. 新质生产力系统：要素特质、结构承载与功能取向[J]. 改革, 2024(2): 15-24.
- [59] 生态环境部, 国家发展改革委, 工业和信息化部, 等. 关于建立碳足迹管理体系的实施方案: 环气候〔2024〕30号[EB/OL]. (2024-05-22)[2026-08-13].
https://www.gov.cn/zhengce/zhengceku/202406/content_6956112.htm.
- [60] 国务院. 关于深入实施“人工智能+”行动的意见: 国发〔2025〕11号[EB/OL]. (2025-08-26)[2026-08-13].
https://www.gov.cn/zhengce/content/202508/content_7037861.htm.
- [61] DAO T, FU D Y, ERMON S, et al. FlashAttention: fast and memory-efficient exact attention with IO-awareness[C]//Advances in Neural Information Processing Systems 35 (NeurIPS 2022). Red Hook, NY: Curran Associates, 2022: 16344-16359.
- [62] YU G I, JEONG J S, KIM G W, et al. Orca: a distributed serving system for Transformer-based generative models[C]//Proceedings of the 16th USENIX Symposium on Operating Systems Design and Implementation (OSDI 22). Carlsbad, CA: USENIX Association, 2022: 521-538.

- [63] POPE R, DOUGLAS S, CHOWDHURY A, et al. Efficiently scaling Transformer inference[C]//Proceedings of Machine Learning and Systems 5 (MLSys 2023). [S.l.]: MLSys, 2023: 606-624.
- [64] KWON W, LI Z, ZHUANG S, et al. Efficient memory management for large language model serving with PagedAttention[C]//Proceedings of the 29th Symposium on Operating Systems Principles (SOSP '23). New York: ACM, 2023: 611-626.
- [65] AGRAWAL A, KEDIA N, PANWAR A, et al. Taming throughput-latency tradeoff in LLM inference with Sarathi-Serve[C]//Proceedings of the 18th USENIX Symposium on Operating Systems Design and Implementation (OSDI 24). Santa Clara, CA: USENIX Association, 2024: 117-134.
- [66] HENDRYCKS D, BURNS C, BASART S, et al. Measuring massive multitask language understanding[EB/OL]. (2021-01-12)[2026-08-13]. <https://arxiv.org/abs/2009.03300>.
- [67] LIANG P, BOMMASANI R, LEE T, et al. Holistic evaluation of language models[EB/OL]. (2022-11-16)[2026-08-13]. <https://arxiv.org/abs/2211.09110>.
- [68] ZHENG L, CHIANG W L, SHENG Y, et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena[C]//Advances in Neural Information Processing Systems 36 (NeurIPS 2023) Datasets and Benchmarks Track. Red Hook, NY: Curran Associates, 2023: 46595-46623.
- [69] ERICKSON T, PAKES A. An experimental component index for the CPI: from annual computer data to monthly data on other goods[J]. American Economic Review, 2011, 101(5): 1707-1738.
- [70] REDDING S J, WEINSTEIN D E. Measuring aggregate price indices with taste shocks: theory and evidence for CES preferences[J]. The Quarterly Journal of Economics, 2020, 135(1): 503-560.
- [71] 韩文龙, 张瑞生, 赵峰. 新质生产力水平测算与中国经济增长新动能[J]. 数量经济技术经济研究, 2024, 41(6): 5-25.
- [72] FELTEN E, RAJ M, SEAMANS R. Occupational, industry, and geographic exposure to artificial intelligence: a novel dataset and its potential uses[J]. Strategic Management Journal, 2021, 42(12): 2195-2217.
- [73] FELTEN E W, RAJ M, SEAMANS R. How will language modelers like ChatGPT affect occupations and industries?[EB/OL]. (2023-03-18)[2026-08-13]. <https://arxiv.org/abs/2303.01157>.
- [74] ELOUNDOU T, MANNING S, MISHKIN P, 等. GPTs are GPTs: labor market impact potential of LLMs[J]. Science, 2024, 384(6702): 1306-1308.

- [75] STANFORD INSTITUTE FOR HUMAN-CENTERED ARTIFICIAL INTELLIGENCE. The 2026 AI index report[R/OL]. Stanford, CA: Stanford University, 2026[2026-08-13]. <https://hai.stanford.edu/ai-index/2026-ai-index-report>.
- [76] ACEMOGLU D, MAKHDOUMI A, MALEKIAN A, et al. Too much data: prices and inefficiencies in data markets[J]. American Economic Journal: Microeconomics, 2022, 14(4): 218-256.
- [77] BERGEMANN D, BONATTI A, GAN T. The economics of social data[J]. RAND Journal of Economics, 2022, 53(2): 263-296.
- [78] ZHONG Y, LIU S, CHEN J, et al. DistServe: disaggregating prefill and decoding for goodput-optimized large language model serving[C]//Proceedings of the 18th USENIX Symposium on Operating Systems Design and Implementation (OSDI 24). Santa Clara, CA: USENIX Association, 2024: 193-210.
- [79] 姜春海, 闫振好, 王敏. “双碳”目标约束下的能耗双控到碳排放双控: 规制工具、效应模拟与政策评价[J]. 中国工业经济, 2024(11): 5-23.
- [80] 陈红敏. 国际碳核算体系发展及其评价[J]. 中国人口·资源与环境, 2011, 21(9): 111-116.
- [81] 童庆蒙, 沈雪, 张露, 等. 基于生命周期评价法的碳足迹核算体系: 国际标准与实践[J]. 华中农业大学学报(社会科学版), 2018(1): 46-57+158.
- [82] 张希良, 张达, 余润心. 中国特色全国碳市场设计理论与实践[J]. 管理世界, 2021, 37(8): 80-95.
- [83] 赵思琦, 刘庆富, 杨金强, 等. 全国碳市场的碳排放权配额管理机制设计——基于碳交易和风险对冲的视角[J]. 金融研究, 2023(12): 74-93.
- [84] 段玉婉, 蔡龙飞, 陈一文. 全球化背景下中国碳市场的减排和福利效应[J]. 经济研究, 2023, 58(7): 121-138.
- [85] 杨豪, 潘颖豪, 才国伟. 碳排放总量控制、配置效率与产出收益[J]. 中国工业经济, 2023(7): 46-65.
- [86] 蓝虹, 杜彦霖. 自愿碳交易市场: 产权量化标准与生态价值实现路径[J]. 改革, 2024(4): 77-92.
- [87] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models[EB/OL]. (2020-01-23)[2026-08-13]. <https://arxiv.org/abs/2001.08361>.
- [88] HOFFMANN J, BORGEAUD S, MENSCH A, et al. Training compute-optimal large language models[C]//Advances in Neural Information Processing Systems 35 (NeurIPS 2022). Red Hook, NY: Curran Associates, 2022: 30016-30030.

- [89] GOLDFARB A, TASKA B, TEODORIDIS F. Could machine learning be a general purpose technology? A comparison of emerging technologies using data from online job postings[J]. *Research Policy*, 2023, 52(1): 104653.
- [90] AGHION P, JONES B F, JONES C I. Artificial intelligence and economic growth[M]//AGRAWAL A, GANS J, GOLDFARB A. The economics of artificial intelligence: an agenda. Chicago: University of Chicago Press, 2019: 237-290.
- [91] 孔高文, 刘莎莎, 孔东民. 机器人与就业——基于行业与地区异质性的探索性分析[J]. *中国工业经济*, 2020(8): 80-98.
- [92] 余玲铮, 魏下海, 孙中伟, 等. 工业机器人、工作任务与非常规能力溢价——来自制造业“企业—工人”匹配调查的证据[J]. *管理世界*, 2021, 37(1): 47-59.
- [93] 胡晟明, 王林辉, 朱利莹. 工业机器人应用存在人力资本提升效应吗? [J]. *财经研究*, 2021, 47(6): 61-75.
- [94] 田鸽, 张勋. 数字经济、非农就业与社会分工[J]. *管理世界*, 2022, 38(5): 72-84.
- [95] 陈贵富, 韩静, 韩恺明. 城市数字经济发展、技能偏向型技术进步与劳动力不充分就业[J]. *中国工业经济*, 2022(8): 118-136.
- [96] 陈东, 秦子洋. 人工智能与包容性增长——来自全球工业机器人使用的证据[J]. *经济研究*, 2022, 57(4): 85-102.
- [97] ACEMOGLU D, AUTOR D, HAZELL J, 等. Artificial intelligence and jobs: evidence from online vacancies[J]. *Journal of Labor Economics*, 2022, 40(S1): S293-S340.
- [98] CAZZANIGA M, JAUMOTTE F, LI L, et al. Gen-AI: artificial intelligence and the future of work[R/OL]. Washington, DC: International Monetary Fund, 2024[2026-08-13].
<https://www.imf.org/-/media/files/publications/sdn/2024/english/sdnea2024001.pdf>.
- [99] CHUI M, HAZAN E, ROBERTS R, et al. The economic potential of generative AI: the next productivity frontier[R/OL]. New York: McKinsey Global Institute, 2023[2026-08-13].
<https://www.mckinsey.com/capabilities/mckinsey-digital/our-insights/the-economic-potential-of-generative-ai-the-next-productivity-frontier>.
- [100] COYLE D, NGUYEN D. Cloud computing, cross-border data flows and new challenges for measurement in economics[J]. *National Institute Economic Review*, 2019, 249: R30-R38.
- [101] KORINEK A. Generative AI for economic research: use cases and implications for economists[J]. *Journal of Economic Literature*, 2023, 61(4): 1281-1317.

- [102] ACEMOGLU D, RESTREPO P. Automation and new tasks: how technology displaces and reinstates labor[J]. *Journal of Economic Perspectives*, 2019, 33(2): 3-30.
- [103] ACEMOGLU D, JOHNSON S. Learning from Ricardo and Thompson: machinery and labor in the early industrial revolution, and in the age of AI: NBER working paper No. 32416[R]. Cambridge, MA: National Bureau of Economic Research, 2024.
- [104] AUTOR D. Applying AI to rebuild middle class jobs: NBER working paper No. 32140[R]. Cambridge, MA: National Bureau of Economic Research, 2024.
- [105] DUBÉ J P, MISRA S. Personalized pricing and consumer welfare[J]. *Journal of Political Economy*, 2023, 131(1): 131-189.
- [106] BERGEMANN D, BONATTI A. Data, competition, and digital platforms[J]. *American Economic Review*, 2024, 114(8): 2553-2595.
- [107] 刘诚, 夏杰长. 线上市场、数字平台与资源配置效率: 价格机制与数据机制的作用[J]. *中国工业经济*, 2023(7): 84-102.
- [108] 顾聪, 刘颖, 吕本富, 等. 市场结构、经济福利与平台经济反垄断[J]. *中国管理科学*, 2023, 31(11): 208-216.
- [109] 吴双, 王勇. 新结构经济学视角下的平台经济: 一个分析框架[J]. *浙江社会科学*, 2024(4): 4-13.
- [110] 国家数据局. 全国数据资源调查报告 (2025 年) [R/OL]. 北京: 国家数据局, 2026[2026-08-13]. <https://www.nda.gov.cn/sjj/ywpd/sjzy/0429/ff808081-9b5e8626-019d-d86d1ac9-115b.pdf>.
- [111] 中国信息通信研究院. 算力经济发展研究报告 (2025 年) [R/OL]. 北京: 中国信息通信研究院, 2025[2026-08-13]. <https://www.caict.ac.cn/kxyj/qwfb/ztbg/202509/P020250910593366724819.pdf>.
- [112] 中国信息通信研究院. 人工智能产业发展研究报告 (2025 年) [R/OL]. 北京: 中国信息通信研究院, 2026[2026-08-13]. <https://www.caict.ac.cn/kxyj/qwfb/bps/202602/P020260202487301304903.pdf>.
- [113] 陈彦斌, 林晨, 陈小亮. 人工智能、老龄化与经济增长[J]. *经济研究*, 2019, 54(7): 47-63.
- [114] 蔡跃洲, 陈楠. 新技术革命下人工智能与高质量增长、高质量就业[J]. *数量经济技术经济研究*, 2019, 36(5): 3-22.

- [115] 任英华, 刘宇钊, 李海彤. 人工智能技术创新与企业全要素生产率[J]. 经济管理, 2023, 45(9): 50-67.
- [116] 国家数据局, 中央网信办, 科技部, 等. “数据要素×”三年行动计划 (2024—2026 年): 国数政策〔2023〕11 号[EB/OL]. (2023-12-31)[2026-08-13].
https://www.nda.gov.cn/sjj/xxgk/gknr/ghjh/0909/20240909160155798592998_pc.html.
- [117] WENG Q, XIAO W, YU Y, et al. MLaaS in the wild: workload analysis and scheduling in large-scale heterogeneous GPU clusters[C]//Proceedings of the 19th USENIX Symposium on Networked Systems Design and Implementation (NSDI '22). Berkeley, CA: USENIX Association, 2022: 945-960.
- [118] MASANET E, SHEHABI A, LEI N, et al. Recalibrating global data center energy-use estimates[J]. Science, 2020, 367(6481): 984-986.
- [119] LUCCIONI A S, VIGUIER S, LIGOZAT A L. Estimating the carbon footprint of BLOOM, a 176B parameter language model[J]. Journal of Machine Learning Research, 2023, 24(253): 1-15.
- [120] DE VRIES A. The growing energy footprint of artificial intelligence[J]. Joule, 2023, 7(10): 2191-2194.
- [121] KIRCHENBAUER J, GEIPING J, WEN Y, et al. A watermark for large language models[C]//Proceedings of the 40th International Conference on Machine Learning (ICML 2023): vol 202. [S.l.]: PMLR, 2023: 17061-17084.
- [122] DATHATHRI S, SEE A, GHASISAS S, et al. Scalable watermarking for identifying large language model outputs[J]. Nature, 2024, 634(8035): 818-823.
- [123] 国家互联网信息办公室, 工业和信息化部, 公安部. 互联网信息服务深度合成管理规定: 国家互联网信息办公室、工业和信息化部、公安部令第 12 号[EB/OL]. (2022-11-25) [2026-08-13].
https://www.cac.gov.cn/2022-12/11/c_1672221949354811.htm.
- [124] 国家互联网信息办公室, 国家发展和改革委员会, 教育部, 等. 生成式人工智能服务管理暂行办法: 国家互联网信息办公室等七部门令第 15 号[EB/OL]. (2023-07-13) [2026-08-13].
https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm.
- [125] 浙江省第十四届人民代表大会第四次会议. 浙江省国民经济和社会发展第十五个五年规划纲要[EB/OL]. (2026-01-17)[2026-08-13].
https://zjnews.zjol.com.cn/zjnews/202602/t20260210_31500156.shtml.

- [126] 国际数据公司. 中国智算云基础设施市场 (AI IaaS) (2025 上半年) 跟踪[R/OL]. 北京: IDC 中国, 2025[2026-08-13]. <https://my.idc.com/getdoc.jsp?containerId=prCHC53879525>.
- [127] SHEHABI A, SMITH S J, HUBBARD A, 等. 2024 United States data center energy usage report: LBNL-2001637[R]. Berkeley, CA: Lawrence Berkeley National Laboratory, 2024.
- [128] LI P, YANG J, ISLAM M A, 等. Making AI less "thirsty": uncovering and addressing the secret water footprint of AI models[J]. Communications of the ACM, 2025, 68(7): 54-63.
- [129] 中国信息通信研究院. 算力电力协同发展研究报告(2025 年)[R]. 北京: 中国信息通信研究院, 2025.
- [130] 陈丹丹, 史代敏, 祁丹越, 等. 绿色金融统计标准的国际比较与中国实践[J]. 统计研究, 2025, 42(1): 75-87.
- [131] 肖土盛, 孙瑞琦, 袁淳, 等. 企业数字化转型、人力资本结构调整与劳动收入份额[J]. 管理世界, 2022, 38(12): 220-237.
- [132] 何小钢, 朱国悦, 冯大威. 工业机器人应用与劳动收入份额——来自中国工业企业的证据[J]. 中国工业经济, 2023(4): 98-116.
- [133] 王林辉, 胡晟明, 董直庆. 人工智能技术、任务属性与职业可替代风险——来自微观层面的经验证据[J]. 管理世界, 2022, 38(7): 60-79.
- [134] 王林辉, 钱圆圆, 宋冬林, 等. 机器人应用的岗位转换效应及就业敏感性群体特征——来自微观个体层面的经验证据[J]. 经济研究, 2023, 58(7): 69-85.
- [135] CRAWFORD K. Generative AI's environmental costs are soaring — and mostly secret[J]. Nature, 2024, 626(8000): 693.
- [136] 何建坤. 碳达峰碳中和目标导向下能源和经济的低碳转型[J]. 环境经济研究, 2021, 6(1): 1-9.
- [137] 张希良, 黄晓丹, 张达, 等. 碳中和目标下的能源经济转型路径与政策研究[J]. 管理世界, 2022, 38(1): 35-66.
- [138] 国家发展改革委, 财政部, 国家能源局. 关于做好可再生能源绿色电力证书全覆盖工作促进可再生能源电力消费的通知: 发改能源〔2023〕1044 号[EB/OL]. (2023-08-03) [2026-08-13]. https://www.ndrc.gov.cn/xxgk/zcfb/tz/202308/t20230803_1359092.html.
- [139] 国家发展改革委, 国家能源局. 关于促进可再生能源绿色电力证书市场高质量发展的意见: 发改能源〔2025〕262 号[EB/OL]. (2025-03-18)[2026-08-13]. https://www.ndrc.gov.cn/xxgk/zcfb/tz/202503/t20250318_1396627.html.
- [140] 生态环境部, 国家发展和改革委员会, 国家市场监督管理总局, 等. 产品碳足迹核算标准编制工作指引: 环气候〔2024〕91 号[EB/OL]. (2024-12-28)[2026-08-13].

https://www.mee.gov.cn/xxgk2018/xxgk/xxgk03/202501/t20250106_1099994.html.

- [141] 王永钦, 董雯. 机器人的兴起如何影响中国劳动力市场? ——来自制造业上市公司的证据[J]. 经济研究, 2020, 55(10): 159-175.
- [142] 柏培文, 张云. 数字经济、人口红利下降与中低技能劳动者权益[J]. 经济研究, 2021, 56(5): 91-108.

后 记

本书的写作始于一个很小的困惑。去年秋天，笔者在与本地一家纺织企业交流时被问到一个问题：平台报价说一百万词元多少钱，可我怎么知道这一百万词元值不值这个价？当时无法给出令人信服的回答。后来查阅资料才发现，这并非某一家企业的困惑，而是整个词元市场共同的制度空缺——市场上流通的是同一个名字，背后却是完全不同的东西。经济学对这类问题并不陌生：一切市场的效率，都以计量的可比性为前提。本书试图做的，就是把这个前提补上。

感谢嘉兴大学提供的良好科研条件，感谢长三角（嘉兴）Token 运营中心及相关企业在调研中的坦诚分享，感谢课题组成员在词元服务数据采集、效值测试集构建与企业访谈中的辛勤付出。本书写作期间，词元经济正以罕见的速度演化，几乎每一个月都有新的政策、新的价格与新的模式出现——研究对象的快速变化既是本书的挑战，也是它的价值所在。书中若有错讹，责任由作者承担。

蔡鑫宇

2026年8月