

词元价格下行与智能服务支出的背离*

——质量调整价格指数与回弹效应的分解

蔡鑫宇

(嘉兴大学经济学院 314001)

内容提要：智能服务以词元计价，而词元并不同质。本文以享乐回归构造质量调整的标准词元价格指数：2023年1月至2026年6月，名义单位价值指数累计下降93.2%，质量调整指数累计下降98.7%，名义口径低估真实降价与投入增长。质量调整价格上的需求价格弹性为-1.3908，名义口径高估33.7%；绝对值大于1使价格通道净效应为正，单价下行反而推高支出。以名义价格平减将低估人工智能的真实成本节约。

关键词：词元 质量调整价格指数 需求价格弹性 回弹效应

Falling Token Prices and Rising Spending on Intelligent Services: Quality-Adjusted Price Index and the Rebound Effect

Abstract: Intelligent services are priced by the token, yet tokens are not a homogeneous good. Using hedonic regressions on a model-tier monthly panel, this paper constructs a quality-adjusted standard-token price index. From January 2023 to June 2026 the nominal unit-value index falls by 93.2% while the quality-adjusted index falls by 98.7%, so the nominal measure understates both the true price decline and the growth of real input. On an industry-quarter panel the price elasticity of demand for intelligent services is -1.3908 under two-way fixed effects, whereas the nominal price measure overstates its absolute value by 33.7%. Because the absolute elasticity exceeds unity, the net effect of the price channel is positive: falling unit prices raise rather than reduce spending. Deflating with nominal token prices therefore understates the real cost saving brought by artificial intelligence and misstates its contribution to productivity.

Key Words: Token; Quality-Adjusted Price Index; Price Elasticity of Demand; Rebound Effect

一、引言

词元是大模型处理与交换信息的最小单位，也是智能服务计价、结算与统计的基本单位。2026年3月25日，全国科学技术名词审定委员会发布公告，优先推荐以词元作为人工智能领域名词 token 的中文名，并面向全社会发布试用；国家数据局则从经济属性出发，强调词元“可计量、可定价、可交易”，同时承担计量单位、结算单位与统计单位三重职能。一种新的中间投入品一旦获得公认的计量单位，其价格与数量就可以进入核算体系。但计量

*蔡鑫宇，男，浙江嘉兴人，嘉兴大学经济学院，副教授，E-mail: caixinyu@zjxu.edu.cn。感谢匿名审稿人的宝贵意见，文责自负。

单位的确立并不等于计量问题的解决：只有当单位本身同质，以该单位表示的价格才是可比的价格，以该单位加总的数量才是可加的数量。本文的出发点，正是这一前提在智能服务上并不成立。

数量侧与价格侧的公开记录都相当醒目。国家数据局公布的全国日均词元调用量，由2024年初的约1000亿枚增至2026年3月的逾140万亿枚，两年放大约1400倍。价格侧，斯坦福大学以人为本人工智能研究院《2025年人工智能指数报告》按质量恒定口径统计，达到同一固定能力水平的最低查询报价由2022年11月的20.00美元降至2024年10月的0.07美元，总降幅约286倍。若把这两组数字直接相乘，总支出理应大幅收缩，支出侧给出的却是相反的方向：企业级大模型接口支出由2024年末的35亿美元升至2025年年中的84亿美元，半年增长约140%。^①单价大幅下行而支出不降反升，这一背离正是本文要解释的现象。

背离本身并不神秘：支出等于价格乘以数量，数量的扩张幅度超过价格的下降幅度即可。真正要回答的是其中的价格与数量究竟是什么。同一枚词元由经济档模型产出还是由旗舰档模型产出，其承载的有效认知服务量可以相差数倍。当用量在档位之间迁移、模型能力又逐月改进时，以物理词元计的单价既不是企业面对的真实价格，加总所得的数量也不是企业获得的真实服务量。由此产生三个待解的问题：名义降价之中有多少是真实降价，有多少是质量提升被误记为降价？在质量调整之后的正确价格上，需求价格弹性有多大，支出上升是否来自回弹效应（rebound effect），即价格下降引致用量以更大比例扩张？名义价格指数偏离真实价格又会造成什么统计与政策后果？

把不同质的物理量折算成同质的效用量，是价格测度的常规做法：能源统计以标准煤折算不同热值的燃料，信息技术设备与云计算的价格统计以享乐回归（hedonic regression）剥离性能改进^[1-4]。本文沿这一传统把智能服务的有效投入定义为“标准词元”：设物理词元量为 T 、效值系数为 η ，有效投入为 ηT ，企业面对的真实价格为名义单价除以效值系数。效值

^①接口支出数字来自 Menlo Ventures 面向企业技术决策者的调研，为美国市场、美元口径，仅含企业在大模型接口上的支出，不含自建推理与订阅制产品；本文只用其增长方向作对照，不与后文人民币口径的支出序列相除或换算。

系数不可直接观测，也不能由单一评测分数替代，只能由价格对特征的联合建模估出；这一步做完，价格与数量才各归其位。

本文的做法分三步。第一步，以模型档位—供给方为观测单位构造月度价格特征面板（12家代表性供给方、21个档位—供给方组合、44个月、924个观测），做时期虚拟变量与特征并列的享乐回归，以时期虚拟变量的系数作为质量调整的标准词元价格指数，并与名义指数并列比较。第二步，把名义价格的累计变化分解为真实价格、质量与结构三项。第三步，以20个行业、14个季度、280个观测的行业—季度面板估计需求价格弹性，以算力硬件租金与电价的行业暴露构造份额—移动式成本推移工具变量，并把支出的对数变化分解为价格效应、纯回弹效应与非价格数量效应。^①

主要发现有三。其一，质量调整之后的价格降幅明显大于名义降幅。2023年1月至2026年6月，以单位价值计的名义词元价格指数累计下降93.2%（年均降速2.201倍），同期质量调整的标准词元价格指数累计下降98.7%（年均3.548倍）。名义指数并未高估、而是低估了真实降价幅度，相应地也低估了真实投入量的增长。三重分解的对象是支出份额加权的对数均价指数（同期累计下降94.2%，与单位价值口径分列不作互换），其真实价格效应为-4.327个对数点，质量效应为2.014，结构效应为-0.511：质量改进把观测均价托高，抵消了约七成的名义降幅。

其二，在质量调整价格上，需求价格弹性的绝对值大于1，价格下行通过回弹放大用量。双向固定效应估计给出的弹性为-1.3908（聚类稳健标准误0.148），以名义价格估计则为-1.8596，绝对值高估33.7%。支出对质量调整价格的弹性等于1加上需求弹性，估计值为-0.3908，原假设为弹性等于-1的单侧p值为0.0081，野聚类自助法（wild cluster bootstrap）给出的p值为0.015，即在5%水平上可以判定价格下降会推高支出。样本期内总支出的对数变化为7.105，其中价格效应-4.126、纯回弹5.738、任务复杂化1.367、共同扩散与其他

^①档位层面的明细挂牌价与行业层面的词元用量、接口支出均不公开，故本文的分析样本是按前述公开锚校准生成的模拟面板，而非真实抽样或实际采集的数据；全部数字由随附代码产生、可复现，总量与档位价比等关键维度已与公开锚对齐，详见第四部分数据小节。

4.125；仅价格通道本身的净效应即为 1.612，足以使支出上升。改用工具变量的系数重算，价格通道净效应升至 2.351，两套口径同号，故背离的成立不取决于选用哪一个弹性估计。

其三，价格结构的演化与 2026 年的转向都不支持把降价简单外推。档位均价之比在收敛而非扩大：旗舰档与经济档的输出均价比由 2023 年 1 月的 7.036 倍降至 2026 年 6 月的 3.119 倍，与公开记录的约 3 倍相吻合，而同期个体报价的最高与最低之比仍达 8.2 倍。降幅本身也在收敛：标准词元价格指数的年均降速由 2023 年 1 月至 2024 年 10 月的 7.691 倍降至 2024 年 10 月以后的 1.575 倍。2026 年年中的结构性提价与峰谷分时定价更使价格掉头向上：2026 年 6 月至 8 月名义指数回升 35.5%，质量调整指数回升 32.3%。智能服务的成本下行并非可以无限延续的技术规律。

与既有研究相比，本文的边际贡献有三。第一是测度贡献。本文把能源统计的标准煤折算思想与信息技术产品价格统计的享乐回归传统引入智能服务，构造以标准词元为计量基准的质量调整价格指数，并给出名义降价的三重分解——真实价格效应、质量效应与结构（档位替代）效应。既有的质量调整研究处理的是硬件与标准化服务，其计价单位在时间上固定而只有性能在变^[5-6]；智能服务的特殊之处在于计价单位本身的含义随模型档位而变，因而必须先把单位标准化，再谈价格可比。

第二是参数贡献。本文在质量调整后的价格上估计需求价格弹性，并给出“单价下降—支出上升”背离成立的定量条件，即弹性绝对值大于 1。这一估计澄清了一个方向性的误判：由于名义价格等于真实价格乘以效值系数，而效值系数随时间上升，以名义价格估计的弹性绝对值会被系统性放大（本文测得的放大幅度为 33.7%）。以成本推移工具变量识别供给侧价格变动时，两口径的估计-1.5698 与-1.4602 相互收敛，从反面印证固定效应下的口径差距确由质量改进与档位替代混入名义价格所致。本文还把智能体化对用量的独立贡献从纯价格回弹中分离出来。

第三是政策贡献。以名义词元价格编制的统计口径会低估智能服务的真实降价幅度，从而低估企业获得的真实投入增长，也低估人工智能带来的真实成本节约。用名义指数平减名义支出，会在生产率核算中把智能服务的数量贡献记少、把价格贡献记多；在补贴核定与投

资回报评估中，则会低估同一笔预算所能购得的服务量。本文据此给出可操作的编制方案：以档位—特征为质量维度定期估计效值系数，以固定权重与链式指数并列发布，并在结构转向期单独标注断点。

本文余下部分安排如下：第二部分给出三组典型事实并评述文献；第三部分构建理论框架并提出三个命题；第四部分构造质量调整的词元价格指数并给出三重分解；第五部分估计需求价格弹性并做支出变化的回弹分解；第六部分报告异质性、稳健性与统计口径含义；第七部分是结论与政策建议。需要预先说明的是，分析样本是按公开锚校准生成的模拟面板，其价值在于完整展示由测度到识别的推断链条，量级结论应在这一限定下理解。

二、典型事实与文献评述

（一）三组典型事实

1. 价格：名义单价的深度下行与结构转向

价格侧最具可比性的公开序列来自质量恒定口径。斯坦福大学以人为本人工智能研究院《2025 年人工智能指数报告》记录，在同一固定能力水平上，市场最低查询报价由 2022 年 11 月的每百万词元 20.00 美元降至 2024 年 10 月的 0.07 美元，总降幅约 286 倍。该口径固定能力而只让价格变动，本身已接近享乐思想，因而是质量调整价格指数的天然对照基准；但它刻画的是全市场报价的下沿，不代表企业实际购买的档位组合。^①同一报告还指出，词元推理价格的年度降幅因任务而异，每年下降 9 倍至 900 倍不等。两个数量级的跨度意味着，用单一价格序列概括词元降价必然丢失信息。

名义挂牌价格的第二个特征是档位分层及其稳定性。在同一供给方内部，旗舰档与经济档的输出价之比约为 3 倍，且在调价前后基本不变：调价前两档输出价分别为每百万词元 6 元与 2 元，调价后高峰时段分别为 27 元与 9 元。档位间的相对价格结构相当稳固，容易变动的是用户在档位之间的分布。一旦大量用量由高档位迁往低档位，按物理词元加权的观测

^①该口径的两个时点相隔 23 个月，本文一律按时点作差折年，得年均约 19.11 倍；因其为固定能力水平下的最低报价，与本文按代表性供给方篮子编制的质量调整指数口径不同，正文只作方向性对照，不与本文指数相除或互换。

均价便会下降，而这一下降并不对应任何一个档位的真实降价——把档位替代记成价格下降，是名义单价口径的第一个隐患；若模型能力逐月改进而报价不变，真实降价被完全隐藏，这是第二个隐患。

第三个特征是 2026 年的价格转向。2026 年 8 月，代表性供给方大幅上调价格并实行峰谷分时定价，工作日高峰时段价格翻倍，夜间、周末与节假日维持平峰低价；行业定价逻辑由“低价抢份额”转向“价值定价”，市场上同时出现继续降价与逆势提价的分化。这一转向有两层含义：其一，词元价格的深度下行不是可以无限外推的趋势；其二，分时定价把需求的时间分布直接引入了企业的有效购进价格，构成价格内生性的现实来源，也为后文的识别策略埋下伏笔。

与价格下行同时发生的是算力供给的快速扩张。工业和信息化部在国务院新闻办发布会上通报，截至 2026 年 6 月底，我国智能算力规模达 2185 EFLOPS（FP16），同比增长 177%；全国算力设施整体上架率为 71.4%，东、中、西与东北地区的智算规模占全国比例分别为 55.9%、10.6%、32.6%与 0.9%。算力布局的地区不均衡，加之硬件租金与电价在地区间的差异，意味着不同行业因其算力采购的地区结构不同而面对不同的成本冲击，这正是本文构造份额—移动式成本推移工具变量的现实基础^[7]。

2. 数量：调用量的量级跃迁

数量侧的变化比价格下行更为剧烈。国家数据局公布的全国日均词元调用量，2024 年初约为 1000 亿枚，2025 年 6 月底突破 30 万亿枚，2025 年底约 100 万亿枚，2026 年 3 月突破 140 万亿枚；以 2024 年初为基数，2025 年 6 月底已是其 300 倍，2026 年 3 月是其 1400 倍。上述数字为官方在若干时点公布的口径数据，时点之间并无连续序列，本文在使用时逐一注明发布主体与时点，非锚点期的数值一律标注为校准插值或外推。

数量增长的一部分来自用户与场景的扩散，另一部分来自单位任务本身的复杂化。一家代表性前沿模型研发机构公开的工程实测显示，智能体工作流的词元消耗通常约为对话式交互的 4 倍，多智能体系统约为典型单轮对话的 15 倍；同一实测还发现，词元用量可以解释其研究评测中约 80%的绩效方差。这提示了一条与价格无关的用量增长通道：即使单位任务

的价格保持不变，任务组织方式由单轮问答转向智能体 workflow，词元消耗也会成倍上升。该实测出自研究系统的内部环境，不能外推为行业平均，本文只用作该机制的存在性证据与量级参照，并在回弹分解中把这一通道与纯价格回弹严格区分。

3. 支出：不降反升与口径分层

支出侧是背离的直接体现。前引 Menlo Ventures 的调研显示，企业级大模型接口支出半年增长约 140%；同一起来源的另一口径显示，2025 年全球企业生成式人工智能支出为 370 亿美元，为 2024 年 115 亿美元的约 3.2 倍，其中应用层 190 亿美元、基础设施层 180 亿美元。两个口径的覆盖范围并不相同，因而不可相除或混用；但二者指向同一方向：在单价深度下行的同时，企业用于智能服务的支出仍在成倍增加。而支出恒等于价格乘以数量，含信息的不是这一恒等式本身，是其中的价格与数量按什么口径计量。

（二）文献评述

1. 人工智能的经济影响

第一支文献考察人工智能作为通用目的技术对就业、任务结构与生产率的影响。任务分析框架把技术进步刻画为对既有任务的替代与新任务的创造^[8-9]，并据此评估其宏观后果^[10]；新工作的长期演化提供了历史参照^[11]；大模型的职业暴露度测算^[12]与随机对照实验^[13-14]分别从暴露面与生产率两端给出估计，而基于国别劳动力市场的证据提示短期总量效应可能相当有限^[15]。中文文献沿相近路径展开，讨论通用目的技术扩散与索洛悖论^[16]、生成式人工智能对个体与组织的影响^[17]、增长与分配后果^[18]、职业需求的替代与创造^[19]、机器人应用的岗位转换^[20]，以及企业层面的效率与创新效应^[21-23]；算力与数字基础设施部署的微观效应亦已有证据^[24-26]。

这一支文献的共同特征，是把人工智能视为外生的技术冲击，考察其在使用端的后果，而几乎不追问智能服务本身的价格与数量如何测度：实证操作上，人工智能投入通常由采纳虚拟变量、专利与岗位文本、算力实物量等代理变量刻画^[27-28]。一旦要进入核算，就必须回答用什么价格平减名义支出。倘若平减因子取自以物理词元计的名义单价，而单位词元所承

载的服务量本身在快速改进，真实投入的增长就会被系统性记少。测度问题因此不是这一支文献的旁支，而是其核算结论可靠性的前提。

2. 质量调整价格指数与享乐方法

第二支文献正是为解决这一前提而发展起来的。享乐回归把商品价格分解到特征上，用特征价格剥离质量变化^[1]；对消费价格指数偏误的系统评估把质量调整确立为价格统计的核心议题^[29-30]。在技术进步最快的部门，质量调整的量级足以改写结论：半导体与信息技术设备的质量调整价格指数下行速度远快于名义价格^[2,5]；数字服务与云计算的价格测度已有系统讨论^[3,6]，官方统计机构对云计算生产者价格指数的质量调整实践则展示了其操作难度^[4]。方法论上，享乐指数与基于需求的精确指数何者更可靠，仍是活跃的争论^[31-32]。

已有应用的对象大多是硬件或标准化程度较高的服务，其计价单位在时间上固定，变化的只是单位所附带的性能：一片芯片、一个虚拟机小时的含义不随年份漂移。智能服务的情形更进一步——变化的不仅是质量，还有计价单位本身的含义，而档位结构又在用量迁移中不断变化，于是质量改进与结构替代同时作用于同一个观测均价，方向相反、量级相当。计量单位不同质会抬高交易的计量成本^[33]；质量难以观测时价格甚至不能充分传递信息，认证与披露制度因而成为市场运转的条件^[34-35]。为智能服务确立可比的计量单位，既是统计问题，也是市场制度问题^[36]。

3. 回弹效应与需求估计

第三支文献提供了把价格变化映射到用量与支出的分析框架。能源经济学中的回弹效应指效率提升降低了能源服务的有效价格，从而引致用量扩张，抵消一部分节能收益；其大小取决于需求价格弹性，直接回弹、间接回弹与宏观回弹的分解已有成熟处理^[37-38]。其临界条件十分清晰：弹性绝对值小于1时有效价格下降会使支出下降，大于1时用量的扩张幅度超过价格的下降幅度、支出反而上升。本文所要解释的背离，在形式上正是回弹超过百分之百的情形。差别在于，能源场景中的有效价格等于能源价格除以设备能效，能效有工程口径可

以直接观测；智能服务中与能效对应的单位词元效值既不由供给方披露，也不能由单一评测分数替代，只能由价格与特征的联合建模估出。

需求弹性的识别是这一框架落地的难点。差异化产品需求的估计与工具变量选择已有系统的实践指南^[39]；在线市场的弹性估计还需处理搜寻摩擦与价格离散^[40-42]，而信息成本本身又会改变价格分布与需求响应^[43]。智能服务市场同时具备这两重特征：档位内部的个体报价离散显著大于档位之间的均价差距，而分时定价与拥塞加价使企业的有效购进价格随自身需求波动，价格因此不能被视为外生给定，本文据此选择供给侧的成本推移作为识别来源。

4. 既有研究的空白与本文定位

就笔者所见，既有研究尚未把智能服务的计量单位不同质这一测度问题与需求响应连起来考察：人工智能的经济影响文献关心使用端的后果，而绕开了价格测度；质量调整价格指数文献提供了成熟的方法，却未处理计价单位本身随质量漂移、且用量在异质单位之间迁移的情形；回弹效应文献给出了从价格到支出的传导框架，却依赖一个在智能服务上并不可得的、可直接观测的效率指标。三支文献各自完备，接口处却是空的，而这一空缺恰恰是解释背离的关键：价格测错，弹性就估错；弹性估错，支出分解与成本节约的核算就跟着错。

三、理论框架与命题

（一）标准词元与真实价格

智能服务以词元计价，但物理词元不是同质商品。同一枚输出词元，出自能力前沿的档位与出自轻量档位，完成同一件认知任务所需的数量相差数倍：前者一次给出可用结果，后者需要反复追问、校验与重写。把两者按枚数直接相加，等于把不同热值的燃料按重量相加。能源统计以标准煤化解这一问题，本文循同一思路定义标准词元。设档位—供给方单元 m 在期 t 的效值系数为 η_{mt} ，它把物理词元折算为具有同一任务完成能力的标准词元，则有

$$\tilde{T}_{mt} = \eta_{mt} T_{mt}, \tilde{p}_{mt} = \frac{p_{mt}}{\eta_{mt}}, \tilde{p}_{mt} \tilde{T}_{mt} = p_{mt} T_{mt} \quad (1)$$

式(1)有三点性质需要强调。第一，支出对计量单位不变， η 的归一化只影响把一笔支出的变化划归价格还是划归数量——而这正是价格指数编制的全部要害。第二， η 不可直接观测，须由可观测特征合成，合成方式决定测度的可信度。第三，企业的最优化在 $\tilde{p}$ 上进行：替代的临界点由 $\tilde{p}$ 与人工单位成本之比决定，这与任务分工文献中自动化沿任务序列推进的逻辑一致^[8,11]。计价维度与使用维度的错位本身也是一种计量成本：当合约按易于计数的属性定价、而买方真正消费的是另一组不易计数的属性时，价格信号会在未被计价的维度上失真^[33]。

效值系数的经验合成沿用享乐回归的传统^[1,31]。设单元 m 在期 t 的特征向量为 x_{mt} ，含能力得分、上下文窗口、输出时延、多模态、缓存计价与推理增强，则

$$\ln p_{mt} = \alpha_t + x'_{mt} \beta + \epsilon_{mt} \quad (2)$$

其中 α_t 为时期效应，在特征给定的条件下刻画质量恒定的价格水平； β 为特征的隐含价格。以基期用量加权的特征束为基准归一，效值系数即 $\ln \eta_{mt} = \beta' (x_{mt} - \dot{x}_0)$ 。这一设定把质量定义为市场对特征的估值，而非工程意义上的性能排名。须讲明的是，效值系数依任务而异： η 严格说来是档位—任务对的函数，式(1)中的 η_{mt} 是在给定任务组合下的加总。由此有两点后果：其一，任何质量调整价格指数都是篮子指数，可比性以任务组合稳定为前提；其二，按任务分层编制分指数在概念上正确，却需要任务层面可观测的用量权重，现行公开统计尚不具备这一条件。

（二）指数偏误的方向

以支出份额 w_{mt} 加权的对数均价定义名义价格指数 $\ln P_t^N = \sum_m w_{mt} \ln p_{mt}$ ，以时期效应定义质量调整价格指数 $\ln \tilde{P}_t = \alpha_t$ 。在份额固定于基期的情形下，对式(2)取加权平均并在两期之间作差，得

$$\ln P_t^N - \ln P_0^N = (\alpha_t - \alpha_0) + \beta' (\dot{x}_t - \dot{x}_0) \quad (3)$$

右端第一项是质量恒定的真实价格变化，第二项是特征束改进带来的质量变化。由式(2)可知 $\alpha_t = \overline{\ln p_t} - \beta' \dot{x}_t$ ，故特征束只要改进， α_t 就必然比观测均价下行得更快。此处的质量改进率并非只能定性讨论的修正项：它就是式(3)右端第二项，可由估出的隐含价格与特征束的实际变动直接算出，因而可测、可复算、可逐期分解。由此得到

命题 1（指数偏误的方向） 若质量随时间改进，即 $\beta'(\dot{x}_t - \dot{x}_0) > 0$ ，则名义价格指数的下降幅度小于质量调整价格指数，二者之差恰等于质量改进率。以物理词元计价的名义价格指数系统性低估真实降价幅度。

这一方向值得特别申明，因为直觉容易走向反面：既然模型越来越强而挂牌价越来越低，名义降价似乎已经把好处说满了。代数上恰恰相反：名义单价记录的是买到一枚物理词元要花多少钱，使用者关心的却是完成一件任务要花多少钱，当同一枚词元的效值上升时，后者的下降必然快于前者。其计量后果可由平减恒等式直接读出：

$$\Delta \ln \tilde{T}_t = \Delta \ln E_t - \Delta \ln \tilde{P}_t \quad (4)$$

推论 1（平减偏误） 以名义价格指数 P^N 替代真实价格指数 $\tilde{P}$ 平减名义支出，真实投入量的增长被少记 $\beta' \Delta \dot{x}$ ；智能服务带来的真实成本节约被低估，生产率核算中本应记入数量的部分被误划给价格。

这一逻辑并非词元市场独有：消费价格指数的质量偏误研究早已指出，忽略质量改进会高估价格上涨、低估真实产出^[29-30]；半导体、云计算与消费数字服务的价格测度也反复表明，不作质量调整的价格序列会系统性偏离真实成本路径^[3-6]。词元的特殊之处只在于量级。

（三）回弹的临界弹性条件

智能服务支出为 $E = \tilde{p} \tilde{T}$ 。设需求 $\tilde{T}(\tilde{p})$ 的价格弹性为 ε ，对支出恒等式取对数并全微分，得

$$\frac{d \ln E}{d \ln \tilde{p}} = 1 + \varepsilon, \varepsilon \equiv \frac{d \ln \tilde{T}}{d \ln \tilde{p}} \quad (5)$$

命题 2（回弹的临界条件） 当且仅当 $\varepsilon < -1$ 时，真实价格下行提高智能服务支出。定义回弹率 $R = |\varepsilon|$ ， $R > 1$ 即效率改进所许诺的节约被用量扩张全部吃掉且有余，对应能源经济学中的超回弹。

回弹率的表述在此有明确边界。能源经济学的识别难点在于必须把价格通道与收入通道、扩散通道分开^[37-38]。智能服务的情形更复杂：价格下行的同时任务本身在复杂化，市场又同时处在扩散阶段。把这三股力量笼统称作回弹，会把与价格无关的数量增长记到弹性头上。本文因此设定

$$\ln \tilde{T}_{it} = \varepsilon \ln \tilde{p}_{it} + \gamma z_{it} + \mu_i + \lambda_t + u_{it} \quad (6)$$

其中 z_{it} 为智能化程度， μ_i 与 λ_t 分别为行业与时期固定效应。把式(6)代入支出恒等式，支出的对数变化恒等分解为

$$\Delta \ln E = \Delta \ln \tilde{p} + \varepsilon \Delta \ln \tilde{p} + \gamma \Delta z + \Delta \lambda \quad (7)$$

右端四项依次是价格效应、纯回弹效应、任务复杂化效应与共同扩散效应。只有前两项之和构成价格通道的净效应，命题 2 的临界条件也只对这两项成立。把任务复杂化与市场扩散一并计入所得到的总回弹必然高于 $|\varepsilon|$ ，据此宣称回弹超过百分之百没有意义：它混淆了价格引致的用量扩张与技术扩散本身。

若不作质量调整，直接以名义词元价格与物理词元用量估计弹性，会得到什么？由 $\ln p = \ln \tilde{p} + \ln \eta$ 与 $\ln T = \ln \tilde{T} - \ln \eta$ ，两期之间的名义口径弹性为

$$\varepsilon^N = \frac{\Delta \ln T}{\Delta \ln p} = \frac{\Delta \ln \tilde{T} - \Delta \ln \eta}{\Delta \ln \tilde{p} + \Delta \ln \eta} \quad (8)$$

记 $a = -\Delta \ln \tilde{p} > 0$ 、 $b = \Delta \ln \eta > 0$ 、 $q = \Delta \ln \tilde{T} > 0$ ，并设名义价格与真实价格同向下行（即 $a > b$ ），则 $|\varepsilon^N| > |\varepsilon|$ 等价于 $a(q - b) > q(a - b)$ ，整理后等价于 $q > a$ ，也就是等价于 $|\varepsilon| > 1$ 。这表明名义口径的偏误不是一个固定倍数，其方向取决于真实弹性落在临界值的哪一侧：真实需求越是富有弹性，名义口径把它记得越夸张；真实需求若缺乏弹性，名义口径反而会把需求反应记得比实际温和。

推论 2（名义口径的弹性偏误） 在真实弹性绝对值大于 1 的区间内，以名词元价格与物理词元用量估计的弹性绝对值严格大于真实弹性，即名义口径放大回弹强度；命题 2 的成立与否，恰是这一放大是否发生的分界。

命题 1 与推论 2 作用于不同对象，方向却互相加强：名义口径下的图景是价格降幅有限、需求反应极其敏感，真实口径下则是价格降幅极大、需求反应中等偏强，两幅图景对补贴核定与投资回报评估给出的建议并不相同。

（四）档位纵向差异化与指数编制

供给侧不是单一商品市场，而是纵向差异化的档位结构：经济档同质性高，价格竞争把加成压得很薄；旗舰档与推理增强档处在能力前沿，短期内难以复制，得以保有租金；需求侧则随价格下行与任务分工的细化持续向低档位迁移。份额迁移与价格下行同时发生，使指数编制的口径选择成为实质性问题^[2]。三种常用口径分别为

$$P_t^L = \frac{\sum_m p_{mt} q_{m0}}{\sum_m p_{m0} q_{m0}}, P_t^P = \frac{\sum_m p_{mt} q_{mt}}{\sum_m p_{m0} q_{mt}}, P_t^U = \frac{\sum_m p_{mt} q_{mt} / \sum_m q_{mt}}{\sum_m p_{m0} q_{m0} / \sum_m q_{m0}} \quad (9)$$

单位价值指数 P^U 即当期支出除以当期物理词元量，是统计上最易获得、也最常被引用的口径，本文以下称名义价格指数。但它把用量迁往便宜档位这一结构变化整个记成了降价：即使每个档位的挂牌价纹丝不动，只要份额向低价档位移动， P^U 也会下行。固定篮子指数不记这一项，二者之差正是档位替代对单位价值的拉低作用。而 Laspeyres 与 Paasche 之比由价格相对数与数量相对数的协方差决定：

$$\frac{P_t^P}{P_t^L} - 1 = \frac{Cov_{w_0}(p_{mt}/p_{m0}, q_{mt}/q_{m0})}{E_{w_0}[p_{mt}/p_{m0}] \cdot E_{w_0}[q_{mt}/q_{m0}]} \quad (10)$$

教科书中 Laspeyres 通常不低于 Paasche，因为需求方向相对降价的品种替代，价格相对数与数量相对数负相关。词元市场未必如此：若用量迁往的档位恰好是降幅较小的档位，协方差转为正号，Paasche 反而高于 Laspeyres。这不是编制错误，而是替代模式的直接反映。定基与链式的取舍是同一问题的另一面：链式指数逐期更新权重，能跟上份额的快速迁移，

代价是累积链式漂移；定基指数不漂移，却在结构剧变时失去代表性。词元市场的份额迁移既快又基本单向，两种口径的差距因而可以直接读作份额迁移速度的一个度量，本文对二者并列报告，不预先择一。

命题 3（结构分化与指数编制） 在档位纵向差异化的市场结构下：其一，单位价值指数把档位替代计入降价，与固定篮子指数之差等于份额迁移项；其二，当用量迁往降幅较小的档位时，Paasche 指数高于 Laspeyres 指数，与常见次序相反；其三，在效值系数上归一之后，权重方案与指数公式的选择对结果的影响被压缩，Laspeyres、Paasche、Fisher 与链式指数趋于一致。

第三条给出一个可直接检验的判据：若质量调整做得恰当，指数公式之间的分歧自然收敛；反之，若归一之后各公式仍显著分歧，说明特征集合遗漏了定价上重要的维度。享乐方法与基于需求的精确指数方法各有长短^[32]，本文取享乐路径，是因为档位特征可观测而档位层面的效用参数不可得。命题 1 与命题 3 的检验见第四部分，命题 2 的检验见第五部分。

四、质量调整词元价格指数的构造

（一）数据与样本

实证部分使用两套面板。甲卷为价格特征面板，观测单位是档位—供给方×月，区间 2023 年 1 月至 2026 年 8 月，共 44 期；截面为 12 家代表性供给方旗下的 21 个档位—供给方单元，其中经济档 6 家、均衡档 6 家、旗舰档 5 家、推理增强档 4 家，平衡面板共 924 个观测；记录输入价、输出价与混合单价（元／百万词元）、六项特征以及月度词元用量。

乙卷为需求支出面板，观测单位是行业×季，区间 2023Q1 至 2026Q2，共 14 期，截面为 20 个行业，平衡面板共 280 个观测；记录物理词元用量与标准词元用量、名义价格与质量调整价格、智能服务支出、智能体化程度、行业智能化基础、大型企业用量占比，以及用于构造成本推移工具的算力硬件租金暴露与电价暴露；其中行业智能化基础与大型企业用量占比按标准化分布赋值，不与具体行业名称挂钩。两卷通过档位用量份额相连，甲卷的享乐估计结果直接进入乙卷的价格变量。两卷的时间窗口有意错开：甲卷延伸至 2026 年 8 月，以便

把结构性提价与峰谷分时定价纳入观察范围；乙卷止于 2026 年第二季度，因为提价之后行业层面的用量与支出尚无完整季度可用。

需要明确交代数据的性质。档位层面的明细挂牌价与行业层面的词元用量、智能服务支出目前均不公开，本文因此不使用抽样或采集所得的微观数据，而是按已核实的公开锚校准生成模拟面板，用以完整展示从质量调整、指数编制到弹性识别的全链条；全部数字由随附代码一次性产生，可复现。代价是外部效度，收益是每一个环节的口径都可以被追溯与复算。^①

校准检验可用三项。其一，面板加总的季度词元量与校准锚序列的各季比值恒为 1.0，而该锚序列在四个时点上与国家数据局发布的数值一致，其余各期为插值与外推。其二，2026 年 6 月旗舰档与经济档的均价比为 3.119 倍，与公开记录的约 3 倍对齐。其三，期末加权智能化倍数为 3.909，接近公开记录的智能体工作流 4 倍。非锚点期的调用量为校准插值与外推，本文引用时一并注明。

表 1 报告两卷主要变量的描述统计。价格单位统一为元／百万词元；能力得分与输出时延经标准化处理；效值系数以 2023 年 1 月的用量加权特征束为 1 归一，故其取值可直接读作相对于基期典型词元的效值倍数。样本期内效值系数的均值为 7.63，取值区间自 0.27 至 29.13：区间上端意味着一枚输出词元在完成任务的意义上约相当于基期典型词元的 29 枚，这正是按枚数加总所无法处理的那一部分异质性。

表 1 变量定义与描述统计

变量	单位／取值	均值	标准差	最小值	最大值
甲栏：价格特征面板（档位—供给方×月，N=924）					
输出价	元／百万词元	12.7238	18.4978	1.4069	158.9184
输入价	元／百万词元	3.1165	5.1178	0.2472	47.0932
质量调整输出价	元／百万词元	3.5226	6.5618	0.2862	45.4832
效值系数	基期束=1	7.6275	6.1702	0.2698	29.1337

①校准锚为第二部分逐条列出的公开发布数字：国家数据局公布的全国日均词元调用量、同一供给方旗舰档与经济档的输出价之比、2026 年 8 月的结构性提价与峰谷分时定价，以及智能体工作流与多智能体系统相对单轮问答的词元消耗倍数。模拟面板不是实际抽样或采集所得，正文一切以样本为对象的表述均在此意义上成立；模型一律使用抽象档位名，不挂靠任何具体商业产品或供给方。

能力得分	标准化	0.0000	1.0005	-3.2653	1.5854
上下文窗口	ln 千词元	5.1791	1.0470	1.3509	7.4415
输出时延	标准化	0.0000	1.0005	-1.4842	2.9578
多模态	0/1	0.7121	0.4530	0.0000	1.0000
支持缓存计价	0/1	0.6677	0.4713	0.0000	1.0000
推理增强	0/1	0.1905	0.3929	0.0000	1.0000
乙栏：需求支出面板（行业×季，N=280）					
标准词元用量	ln 万亿枚	2.4051	3.9988	-6.5899	10.6680
物理词元用量	ln 万亿枚	1.0061	3.5077	-6.5261	8.4570
质量调整价格	ln 元/百万词元	-0.5483	1.4107	-2.4780	3.3516
名义价格	ln 元/百万词元	0.8507	0.8759	-0.4742	3.3358
智能服务支出	ln 亿元	-2.7484	2.7891	-8.2219	3.8535
智能体化程度	复杂度指数	0.9979	0.3872	0.1484	1.6534
行业智能化基础	标准化	0.0000	1.0018	-1.8589	1.7543
大型企业用量占比	比例	0.3066	0.1148	0.1193	0.4802
算力硬件租金暴露	Bartik	0.0000	0.0906	-0.3930	0.3843
电价暴露	Bartik	0.0000	0.0230	-0.0535	0.1032

注：甲栏为 12 家代表性供给方的 21 个档位—供给方单元在 44 个月上的平衡面板，乙栏为 20 个行业在 14 个季度上的平衡面板。效值系数以 2023 年 1 月的用量加权特征束为 1 归一。Bartik 暴露为地区成本移动项按行业基期算力分布加权所得，已在行业与时期两个维度上去均值。样本为按公开锚校准生成的模拟面板，声明见正文与脚注。

（二）享乐回归的设定与结果

享乐方程即式(2)：以对数价格对 43 个时期虚拟变量与 6 个特征作最小二乘回归，不设供给方固定效应——供给方层面的定价偏移留在扰动项中，标准误按供给方聚类（12 簇）。时期虚拟的系数 α_t 即质量调整价格指数的对数，特征系数 β 即隐含价格。表 2 并列报告输出价、输入价与混合单价三个方程。

表 2 享乐回归结果

特征	输出价 (1)	输入价 (2)	混合单价 (3)
能力得分（标准化）	0.6356*** (0.0941)	0.6361*** (0.0932)	0.6359*** (0.0935)
ln 上下文窗口（千词元）	0.2520*** (0.0661)	0.2498*** (0.0636)	0.2508*** (0.0646)
ln 输出时延（标准化）	-0.1101 (0.0887)	-0.1057 (0.0860)	-0.1076 (0.0870)
多模态（0/1）	0.1192** (0.0442)	0.1172** (0.0498)	0.1180** (0.0473)
支持缓存计价（0/1）	-0.1044 (0.0636)	-0.0944 (0.0586)	-0.0985 (0.0605)
推理增强（0/1）	0.6865***	0.6782***	0.6818***

	(0.1640)	(0.1621)	(0.1627)
时期虚拟变量	是	是	是
观测值	924	924	924
供给方聚类数	12	12	12
R^2	0.9669	0.9678	0.9694
偏 R^2	0.9441	0.9386	0.9426

注：因变量为对数价格。括号内为按供给方聚类的稳健标准误（12 簇）。***、**、* 分别表示在 1%、5%和 10%的水平上显著。下同。各列均含 43 个时期虚拟变量，其系数即质量调整价格指数。偏 R^2 为把时期虚拟投影掉后特征对同期截面价差的净解释力。

系数的量级与方向都合乎定价常识。能力得分提高一个标准差，同期价格高 0.6356 个对数点，折合 88.8%；上下文窗口翻一番，价格高 19.1%；推理增强相对特征相同的非推理单元溢价 98.7%，系数为各特征之最；多模态溢价 12.7%，在 5%的水平上显著。输出时延与缓存计价的系数为负而不显著（-0.1101 与 -0.1044），方向合理但未能与零区分开。三个方程的特征系数高度一致（能力得分分别为 0.6356、0.6361 与 0.6359），与样本中输入价对输出价之比稳定在 0.2243（标准差 0.0271）互相印证，故以输出价方程构造效值系数不会因计价结构而失真。

关于拟合优度须作两项限定。其一，输出价方程的 R^2 为 0.9669，但其中绝大部分由时期虚拟贡献；把时期虚拟投影掉之后，特征对同期截面价差的净解释力为 0.9441。模拟面板在供给方层面只设了一个未观测定价偏移，而真实挂牌价中同档位不同供给方的报价差异要大得多，该偏 R^2 只是模拟设定下的上界。其二，样本由参数已知的生成过程校准而来，故可直接检验估计量能否找回真值：六个特征系数的标准化偏离（估计值减真值再除以标准误）依表 2 的行序分别为-1.109、1.392、-0.189、0.660、0.088、-0.387，全部落在正负两个标准误以内，既未见系统性偏离，也未出现恰好等于真值的可疑吻合。这只说明在给定的生成过程中估计程序能够无偏地找回隐含价格，不能论证享乐方法在真实挂牌价上同样有效。

（三）指数编制：名义指数与质量调整指数

由估计所得的时期虚拟系数与隐含价格，可同时构造效值系数与两套指数：

$$\ln \hat{\eta}_{mt} = \hat{\beta}'(x_{mt} - \dot{x}_0), \tilde{p}_{mt} = p_{mt} / \hat{\eta}_{mt} \tag{11}$$

$$STPI_t = 100 \exp(\hat{\alpha}_t - \hat{\alpha}_0), NPI_t = 100 \frac{\sum_m p_{mt} q_{mt} / \sum_m q_{mt}}{\sum_m p_{m0} q_{m0} / \sum_m q_{m0}} \quad (12)$$

标准词元价格指数（Standard-Token Price Index, STPI）即质量恒定的时期效应；名义词元价格指数（Nominal Token Price Index, NPI）取单位价值口径，即当期支出除以当期物理词元量。此处须提请注意：名义口径实际有两个，除单位价值指数外，还有支出份额加权的对数均价指数（记作 NPI^q ）。前者是本文正文引用降幅时的默认口径，后者是下一小节三重分解的分解对象，二者数值不同，凡引用累计降幅必须点明是哪一个，全文不得混用。图1绘出NPI与STPI的走势。




图1 名义词元价格指数与质量调整价格指数的走势对比

资料来源：作者依据式(11)与式(12)对校准生成的模拟面板计算。

注：纵轴为对数刻度，基期为2023年1月=100。NPI为单位价值口径的名义价格指数，即当期支出除以当期物理词元量；STPI为享乐回归时期虚拟系数所得的质量调整价格指数。阴影区为2026年7月起的结构性提价与峰谷分时定价期。

两条线的分离与命题1一致——命题1直接刻画的是份额加权的对数均价指数，单位价值口径还多含一重档位替代，方向相同。2023年1月至2026年6月，单位价值口径的NPI

累计-93.248%，相当于 14.811 倍、年均 2.201 倍；同期 STPI 累计-98.679%，相当于 75.725 倍、年均 3.548 倍。质量调整指数的降幅大于名义指数：名义口径低估了真实降价，从而低估了真实投入量的增长，也低估了智能服务带来的真实成本节约。两条指数的累计降幅之差为 1.632 个对数点，其中既有命题 1 所指的质量改进，也有档位替代的一份，下一小节的三重分解把二者拆开。

降幅在时间上明显收敛。STPI 在 2023 年 1 月至 2024 年 10 月的年均降幅为 7.691 倍，2024 年 10 月至 2026 年 6 月收敛至 1.575 倍；NPI 同期由 3.388 倍收敛至 1.399 倍。2026 年 6 月至 8 月出现方向逆转，NPI 与 STPI 分别回升 35.509%与 32.262%，与公开观察到的结构性提价和峰谷分时定价相合。把过去三年的降价速度线性外推因而没有依据。与前沿口径的对照则需格外小心：第二部分引述的质量恒定口径（按时点作差折年 19.11 倍）追踪的是固定能力水平上的全市场最低报价，而本文 STPI 在大致重叠的窗口内年均降幅为 7.691 倍，方向一致而幅度保守得多——最低报价只需一家供给方把价格打下去便会下移，篮子指数却要等份额与报价一同变化，两个口径不可相除、不可互换。

指数公式之间的分歧同样值得报告。以 2026 年 6 月为例，定基 Laspeyres 为 8.9196、Paasche 为 10.5732、Fisher 为 9.7113、链式 Fisher 为 9.2293，而单位价值指数仅为 6.7515、档位简单算术平均为 8.2999。固定篮子指数系统性高于单位价值指数，高出 32.1%：单位价值把用量迁往便宜档位记成了降价，固定篮子不记，二者之差就是档位替代对单位价值的拉低作用（这个量与下一小节 Bennet 分解中衡量质量束变化的结构效应定义不同，数值不可互相替代）。此外，Paasche 高于 Laspeyres，与教科书常见的次序相反，原因在式(10)中：用量迁往的经济档恰恰是降幅较小的档位（2023 年 1 月至 2026 年 6 月经济档均价累计-83.7%，旗舰档累计-92.8%），协方差因而为正。这不是编制错误，而是替代模式的直接反映，报告 Fisher 指数时须一并说明。

命题 3 的第三条则得到了干净的验证。同为 2026 年 6 月，质量调整口径下的 Laspeyres、Paasche、Fisher 与链式 Fisher 分别为 1.3163、1.3107、1.3135 与 1.3103，极差只有 0.0060 个指数点；而名义口径下四者的极差达 1.6536 个指数点。把档位折算为标准词元

之后，篮子里近似只剩一种商品，权重方案与公式选择的影响随之被压缩，这既支持命题 3，也从侧面说明式(2)的特征集合没有遗漏定价上的主要维度。定基与链式的差距承载同一信息：名义口径下链式 Fisher 比定基低出 5.0%，质量调整口径下收缩到 0.2%——名义口径的这点漂移来自份额的持续单向迁移，质量调整之后几乎消失，说明份额迁移的实质是买方在质量与价格之间重新选点。

档位价格结构的演变可以佐证命题 3 的前两条。旗舰档与经济档的均价比由 2023 年 1 月的 7.036 倍收敛至 2026 年 6 月的 3.119 倍，2026 年 8 月结构性提价后为 2.835 倍，始终在三倍量级，与公开记录的同一供给方旗舰档与经济档输出价约 3 倍相符。与此同时，全市场个体最高报价与最低报价之比仍高达 8.200 倍（2023 年 1 月为 18.753 倍）。档位内的价格竞争把档位均价比压回了三倍量级，而跨供给方、跨档位的个体报价极差仍在十倍上下，这正是纵向差异化与横向价格离散并存的市场结构^[40,42,44]。

（四）名义降价的三重分解

把名义降价拆成真实价格、质量与结构三项，需要一个恒等的分解。记单元 m 的质量束为 $a_{mt} = x'_{mt} \hat{\beta}$ ，份额为 w_{mt} ，取两期均值 $\dot{w}_m$ 与 $\dot{a}_m$ ，则份额加权对数均价的变化可作 Bennet 分解：

$$\Delta \ln P^{Ng} = \Delta \hat{\alpha} + \sum_m \dot{w}_m \Delta a_m + \sum_m \dot{a}_m \Delta w_m + \Delta \epsilon \quad (13)$$

右端四项依次是真实价格效应、质量效应、结构（档位替代）效应与残差，其加总恒等于左端。此处必须重申口径：式(13)的分解对象是支出份额加权的对数均价指数 NPI^g ，2023 年 1 月至 2026 年 6 月累计 -94.224%，而不是图 1 中的单位价值指数 NPI（同期累计 -93.248%）。凡在正文中说名义价格累计下降多少，必须与所引的分解同口径。图 2 与表 3 报告分解结果；支出侧的回弹分解见第五部分。




图2 名义降价的三重分解（真实价格/质量/结构）

资料来源：作者依据式(13)对校准生成的模拟面板计算。

注：分解对象为支出份额加权的对数均价指数（2023年1月至2026年6月累计-94.224%），非图1的单位价值指数。柱旁标注上行为对数变化，为负表示压低名义价格、构成降幅，为正表示抬高名义价格、抵消降幅；下行为该项占名义总变化的比重，因总变化为负而与上行反号。

表3 名义降价的三重分解

项	2023.01—2026.06	2023.01—2024.10	2024.10—2026.06	2023.01—2026.08
名义价格总变化	-2.8515 (100.0%)	-2.2647 (100.0%)	-0.5868 (100.0%)	-2.5423 (100.0%)
真实价格效应	-4.3271 (151.8%)	-3.5702 (157.7%)	-0.7569 (129.0%)	-4.0475 (159.2%)
质量效应	2.0135 (-70.6%)	1.6097 (-71.1%)	0.3609 (-61.5%)	2.0135 (-79.2%)
结构（档位替代）效应	-0.5105 (17.9%)	-0.2809 (12.4%)	-0.1867 (31.8%)	-0.5208 (20.5%)
残差	-0.0274 (1.0%)	-0.0233 (1.0%)	-0.0041 (0.7%)	0.0124 (-0.5%)
恒等式误差	0.0000	0.0000	0.0000	0.0000

注：分解对象为支出份额加权的对数均价指数，非表内其他各处引用的单位价值指数。每格上行为对数变化，下行括号内为该项占名义总变化的比重；比重为正表示该项构成降幅的一部分，为负表示抵消降幅。真实价格效应取自享乐回归的时期虚拟系数。恒等式误差为四项加总与总变化之差，四个窗口均在机器精度内为零。末列把2026年7月起的结构性提价期一并纳入，其余各列止于2026年6月。

三項的经济含义各不相同。真实价格效应为-4.3271个对数点，占名义总降幅的151.8%——真实降价比观测到的降价猛烈得多，超出的部分正是被质量改进吃掉的那一块。质量效

应为 2.0135 个对数点，占-70.6%，折合 7.49 倍：若特征束停留在 2023 年 1 月的水平，名义均价指数的期末水平会由 5.776 降至 0.771；这一项就是命题 1 中的偏误项。结构效应为 -0.5105 个对数点，占 17.9%，单独看相当于把名义均价压低 40.0%：用量向经济档迁移，观测均价随之下行，但每个档位的真实价格并未改变。残差为-0.0274 个对数点，占 1.0%，恒等式误差在机器精度内为零。

分阶段的对照揭示了驱动力的转移。2023 年 1 月至 2024 年 10 月，真实价格效应占名义降幅的 157.7%，质量效应占-71.1%，结构效应占 12.4%；2024 年 10 月至 2026 年 6 月，三项分别为 129.0%、-61.5%与 31.8%。质量效应的相对权重下降而结构效应上升，意味着早期的名义降价主要由能力跃迁驱动，后期则更多由用量向经济档迁移驱动；当增量主要来自档位替代时，名义价格的下行空间必然收窄。表 3 末列把窗口延长到 2026 年 8 月，名义价格总变化由-2.8515 收窄至-2.5423，真实价格效应同步由-4.3271 收窄至-4.0475，而质量效应两个窗口同为 2.0135、几乎未动：提价冲击的是真实价格而不是词元的效值。

最后需要说明一项分层结果的性质。把样本按任务类型切分后重估享乐方程，STPI 的年均降幅在通用问答类为 5.268 倍，编码与工具调用类为 3.548 倍，长文本与多模态类为 2.241 倍。方向上这支持一个判断：单一价格指数不足以刻画词元降价。但这一分层只是演示，不是识别——三类任务并非各自独立观测的市场，而是按特征取值对同一批单元作的切分，其降幅差异在很大程度上由特征权重的设定决定；按任务类型编制分指数的可行性，本文只能提出而无法在此证成。

五、需求弹性估计与回弹效应分解

（一）需求方程的设定与基准结果

需求方程即式(6)。被解释变量为行业标准词元用量的对数，核心解释变量为该行业面对的质量调整价格的对数，控制变量为智能体化程度 z_{it} ；行业固定效应吸收各行业在规模、任务构成与数字化起点上的固定差异，时期固定效应吸收模型能力跃迁、算力扩张与政策推动等共同冲击。样本为 20 个行业在 2023Q1 至 2026Q2 共 14 个季度上的平衡面板，280 个观

测，标准误按行业聚类（20 簇）。各行业面对的质量调整价格由其档位使用结构与第四部分估计的效值系数合成，故同一季度不同行业的真实价格并不相同；剔除两组固定效应之后剩下的正是这一部分变异，弹性由它识别。

两套口径必须成对使用：质量调整价格对应标准词元用量，名义价格对应物理词元用量；混搭估出的既不是真实弹性也不是名义弹性。表 1 乙栏显示，质量调整价格的对数标准差为 1.4107，名义价格为 0.8759：质量调整之后价格的离散度扩大而非缩小，因为效值系数本身在行业间高度分化（对数标准差 0.5778），把原先被档位结构掩盖的真实价差释放了出来。

表 4 并列报告五个设定，用意在于把口径差别与识别差别分开看。第(1)、(2)、(4)列为质量调整价格口径，第(3)、(5)列为名义价格口径，口径之别检验推论 2；第(1)列为混合最小二乘，第(2)、(3)列为双向固定效应，第(4)、(5)列为工具变量两阶段最小二乘（two-stage least squares, 2SLS），识别之别检验价格的外生性。混合最小二乘只作对照而非识别结果：不含双向固定效应时，识别变异几乎全部来自价格与用量的共同时间路径，而其标准误反映不出这一脆弱——改按季度聚类得到 0.1968，与按行业聚类的 0.1978 几乎相同，恰说明问题不在聚类方式而在识别本身。本文的基准估计是第(2)列与第(4)列。

表 4 需求价格弹性：基准估计与工具变量估计

项	混合 OLS (1)	双向固定 效应 (2)	双向固定 效应 (3)	2SLS (4)	2SLS (5)
价格口径	质量调整	质量调整	名义	质量调整	名义
价格弹性 ϵ	-2.1900*** (0.1978)	-1.3908*** (0.1482)	-1.8596*** (0.2775)	-1.5698*** (0.3597)	-1.4602*** (0.3699)
智能化程度 γ	1.6225** (0.6846)	1.1255** (0.4626)	0.9669* (0.5080)	1.1509** (0.4692)	0.9586* (0.5232)
行业固定效应	否	是	是	是	是
时期固定效应	否	是	是	是	是
第一阶段 F	—	—	—	25.267	111.738
Hansen J (p 值)	—	—	—	0.0003 (0.9873)	0.4508 (0.5019)
$H_0: \epsilon = -1$ 的 t	—	-2.6365	—	-1.5843	—
单侧 p 值	—	0.0081	—	0.0648	—
观测值	280	280	280	280	280
聚类数	20	20	20	20	20

组内 R^2	0.8249	0.4606	0.3779	—	—
----------	--------	--------	--------	---	---

注：被解释变量为标准词元用量的对数（第(3)、(5)列为物理词元用量的对数）。括号内为按行业聚类的稳健标准误。第(1)列的 R^2 为总 R^2 ，第(2)、(3)列为组内 R^2 。第(4)、(5)列的工具为算力硬件租金与电价的行业暴露，第一阶段 F 为聚类稳健的联合 Wald 统计量除以工具个数。 $H_0: \varepsilon = -1$ 的检验只对两个质量调整口径的基准设定报告，单侧备择为 $\varepsilon < -1$ 。

双向固定效应给出的质量调整口径弹性为-1.3908（标准误 0.1482），名义口径为-1.8596（标准误 0.2775），名义口径把弹性的绝对值放大了 33.71%，正是推论 2 所预言的方向：名义口径把效值改进同时从价格降幅与用量增幅中扣掉，式(8)的分子与分母被同一个量压缩，而分母（价格降幅）本身较小，相对压缩的幅度更大，商的绝对值因而被抬高。混合最小二乘的两个数字同样保持这一次序（-2.1900 对-3.1089），但绝对值整体偏大，说明不作任何控制时价格与用量的共同时间趋势会被整个记到弹性头上。

弹性的量级需要落到可感知的尺度上。以第(2)列为准，质量调整价格每下降 10%，行业的标准词元用量上升 15.8%，智能服务支出上升 4.2%；临界量 $d \ln E / d \ln \tilde{p} = 1 + \varepsilon = -0.3908$ 小于零，命题 2 的条件成立。检验 $H_0: \varepsilon = -1$ 得 $t = -2.6365$ ，单侧 p 值 0.0081；考虑到聚类数只有 20 个，另做野聚类自助法（ $B=999$ ）重做推断， p 值为 0.015，两种推断都在 5%的水平上拒绝弹性等于-1。这是本文关于 $|\varepsilon| > 1$ 的显著性证据的全部来源。换一个更直观的说法：真实价格若降到原来的一半，标准词元用量将增至约 2.62 倍，而支出不降反升约 31.1%。降价没有省钱，只是把预算配置到了更多的任务上。

弹性绝对值大于 1 的经济来源值得点明。智能服务的需求不是对某一件既定商品的需求，而是对认知任务承接能力的派生需求。真实价格下行不只是让企业在原有任务上多买几枚词元，更是把一批原先由人工完成、或因不划算而干脆不做的任务推过替代的临界点，需求因而在广延边际上扩张。任务层面的实验与实地证据显示，生成式模型能在写作、编码与客服等一大批任务上直接替代或加速人工^{[13][14]}，可被推过临界点的任务存量相当庞大，这正是弹性绝对值可以稳定大于 1 的微观基础。智能体化程度的系数为 1.1255（标准误 0.4626， p 值 0.025），在 5%的水平上显著；样本期内该指数对应的加权词元消耗倍数由 1.16 倍升至 3.91 倍，落在公开记录的单轮问答 1 倍与多智能体系统约 15 倍之间。这一通道与价格无关，若并入弹性，回弹的强度会被系统性高估^{[37][38]}。

（二）成本推移工具变量

价格在这里未必外生。第二部分记述的峰谷分时定价把一个原本就存在的机制显性化了：高峰时段的限流、降级与重试同样会抬高完成同一件任务的实际支出，只是不写在价目表上。行业自身的需求冲击因而会经由排队拥塞与时段结构进入其有效购进价格，使价格与扰动项正相关，双向固定效应估计的弹性绝对值因此向零偏。^①处理办法是找到只从供给侧推动价格、且不直接进入行业用量方程的变动。

本文采用份额—移动式（Bartik）成本推移工具：份额为各行业基期推理算力在东、中、西、东北四个地区的分布，移动为各地区的算力硬件租金指数与电价指数，成本份额取硬件 0.72、电力 0.28。行业*i*在期*t*的成本暴露为

$$B_{it}^k = \sum_r s_{ir,0} \Delta \ln c_{rt}^k, k \in \{hw, el\} \quad (14)$$

其中 $s_{ir,0}$ 为行业*i*基期算力落在地区*r*的份额， c_{rt}^k 为地区*r*的第*k*类成本指数。两个暴露变量均已在行业与时期两个维度上去均值，故其变异来自份额结构与地区成本移动的交互，而非全国性的成本共同趋势。这一构造的现实基础是算力供给的地区不均衡：第二部分引述的官方数据显示，东、中、西、东北地区的智算规模占比分别为 55.9%、10.6%、32.6%与 0.9%，地区间的电价与机架租金差异由此转化为供给方成本的横截面差异^{[24][7]}。第一阶段方程为

$$\ln \tilde{p}_{it} = \theta_{hw} B_{it}^{hw} + \theta_{el} B_{it}^{el} + \gamma_1 z_{it} + \mu_i + \lambda_t + v_{it} \quad (15)$$

排他性不能由数据检验，只能由构造与制度事实来论证。行业并不直接购买机架与电力，其算力使用经由供给方的服务合约中介，因此地区成本移动影响行业词元用量的唯一自然通道就是购进价格。两处可能的漏洞需要言明：若某行业本身即算力硬件或电力的生产者，成本移动会经营收渠道直接影响其自身用量；若基期算力份额与行业的长期增长路径相关，份额本身可能携带趋势。本文以时期固定效应与暴露变量的双向去均值缓解前者，后者

^①本文的分析样本按公开锚校准生成，其数据生成过程中把行业需求冲击进入有效购进价格的传导系数设为 0.30。该系数是模拟设定的参数，不是对真实市场的估计。

则要求份额的外生性只在增量意义上成立，是份额—移动式工具的一般代价。过度识别检验只能检验两个工具是否一致，在至少一个工具有效的前提下才有解释力，不能证明工具集整体外生。

第一阶段的结果支持工具的相关性。硬件租金暴露的系数为 1.8019（标准误 0.2752），电价暴露为 3.0996（标准误 1.0919），两者均为正号——成本上行推高购进价格。聚类稳健的联合 F 统计量为 25.267，既高于常用的 10 这一经验界，也高于两工具情形下 Stock-Yogo 10% 偏误临界值 19.93。过度识别的 Hansen J 统计量为 0.0003（ p 值 0.9873），不能拒绝两个工具同时外生；仅用硬件租金一个工具的恰好识别估计为 -1.5678，与两工具结果几乎重合。

2SLS 的质量调整口径弹性为 -1.5698（标准误 0.3597），绝对值大于双向固定效应的 -1.3908；名义口径为 -1.4602（标准误 0.3699），与质量调整口径已相当接近。两口径在工具变量下的收敛本身就是一条旁证：成本推移只挑出与效值改进无关的供给侧价格变动，当被利用的价格变异不再携带质量信息时，用名义价格还是用质量调整价格自然差别不大；反过来说，双向固定效应下两口径相差 33.71%，这一差距只能归于质量改进与档位替代被计入了名义价格。

但内生性的证据到此为止，不宜再往前推一步。以控制函数形式做的 Durbin-Wu-Hausman 检验给出的系数为 0.2298（标准误 0.3424， $t=0.6712$ ， p 值 0.510），在常规水平上不能拒绝价格外生；20 个行业的聚类稳健推断本就检验力有限，这一结果既不能证明价格外生，也不能证明价格内生。因此本文的表述限于：2SLS 的点估计绝对值大于双向固定效应，方向与拥塞加价所隐含的向零偏一致，工具变量的作用是方向性佐证，而非经检验确立的必要修正。这一克制在显著性陈述上同样必须坚持：工具变量口径的临界量为 $1+\varepsilon=-0.5698$ ，检验 $H_0: \varepsilon=-1$ 得 $t=-1.5843$ ，单侧 p 值 0.0648——点估计支持 $|\varepsilon|>1$ ，但标准误更大，未达 5% 的水平。本文关于 $|\varepsilon|>1$ 在 5% 水平上显著的结论，只依据双向固定效应估计；工具变量口径只支持点估计的方向。两个口径的点估计分别为 -1.5698 与 -1.3908，均在 -1 以下。

模拟面板还允许做一件真实数据做不到的事——直接检验估计量能否找回真值。在弹性异质的设定下，双向固定效应最小二乘的估计目标不是各行业弹性的算术平均（-1.7500），而是以各行业价格组内方差为权的加权平均（-1.8107）。以后者为基准，双向固定效应估计距真值 2.832 个标准误，2SLS 距真值 0.67 个标准误：成本推移工具把偏误基本消掉。这只说明估计量在本文设定的环境中表现如何，不能代替真实数据上的识别检验。图 3 汇总各设定的估计。




图 3 需求弹性估计的系数图（含工具变量与分组）

资料来源：作者依据式(6)、式(14)与式(15)对校准生成的模拟面板估计。
注：横轴为需求价格弹性，误差棒为按行业聚类稳健标准误算得的 95%置信区间，虚线为 $\epsilon = -1$ 参考线。上三行为全样本设定，下两行为分组估计，组间差异的检验见第六部分。

（三）支出变化的回弹分解

弹性与临界条件确立之后，回弹分解要回答的是量级问题：支出的实际增长中，有多少经由价格通道，有多少与价格无关。窗口取 2023Q1 至 2026Q2，区间内智能服务支出的对数

变化为 7.1046；同期质量调整价格的对数变化为-4.1255，标准词元用量为 11.2301；若改用名义口径，价格为-2.5448、物理词元用量为 9.6494。两套口径给出同一个支出变化，却给出很不相同的价格与数量分工，这是命题 1 在支出侧的直接体现。

按式(7)分解，价格效应为-4.1255 个对数点（占支出总变化的-58.1%）：若用量不变，仅真实价格的下行就会把支出压低到原来的 1.62%。纯回弹效应为 5.7378，占 80.8%；任务复杂化效应为 1.3673，占 19.2%，相当于把用量放大 3.92 倍；共同扩散与其他数量效应为 4.1250，占 58.1%；四项加总与总变化之差在机器精度内为零。前两项同源於同一个价格变化，后两项则与该行业面对的价格无关；混在一起就分不清哪一部分是价格政策可以撬动的。

关键的一项是前两项之和。价格效应与纯回弹效应相加得 1.6123 个对数点，占支出总变化的 22.7%，折合支出增长 401.45%。这就是背离的定量条件：即使把任务复杂化与市场扩散全部剥离，单靠价格通道本身也足以让支出上升约四倍。能源经济学称之为超回弹，其成立只取决于 $|\varepsilon|$ 是否大于 1^{[37][38]}，与扩散速度无关。弹性口径的选择不改变这一结论，只改变量级：改用第(4)列 2SLS 的弹性与智能化系数重算，纯回弹效应升至 6.4763（占 91.2%），价格通道净效应升至 2.3507（占 33.1%，折合支出增长 949.34%），共同扩散与其他数量效应相应降至 3.3557。由于双向固定效应的弹性绝对值向零偏，基准分解中的纯回弹是下界、扩散项是上界；两套口径的价格通道净效应同号且都远离零。图 4 与表 5 并列报告二者。




图4 支出变化的回弹分解瀑布图

资料来源：作者依据式(7)与表4的弹性估计对校准生成的模拟面板计算。

注：纵轴为对数变化，右轴为占支出总变化的比重，窗口为2023Q1至2026Q2。实心柱为基准口径（双向固定效应弹性 $\epsilon = -1.3908$ ），斜纹柱为工具变量口径（ $\epsilon = -1.5698$ ）；价格通道净效应为价格效应与纯回弹效应之和。

表5 支出变化的回弹分解

项	基准口径 $\epsilon = -1.3908$	占总变化	工具变量口径 $\epsilon = -1.5698$	占总变化
支出总变化	7.1046	100.0%	7.1046	100.0%
价格效应	-4.1255	-58.1%	-4.1255	-58.1%
纯回弹效应	5.7378	80.8%	6.4763	91.2%
任务复杂化效应	1.3673	19.2%	1.3982	19.7%
共同扩散与其他	4.1250	58.1%	3.3557	47.2%
价格通道净效应	1.6123	22.7%	2.3507	33.1%
恒等式误差	0.0000	—	0.0000	—

注：窗口为2023Q1至2026Q2，各项为对数变化，占比以支出总变化为分母。价格效应为质量调整价格的对数变化，纯回弹效应为弹性与价格效应之积，任务复杂化效应为智能化系数与其均值变化之积；价格通道净效应为前两项之和，两口径分别折合支出增长401.45%与949.34%。两列的支出总变化与价格效应相同，差别来自所用的弹性与智能化系数：基准列取表4第(2)列，工具变量列取第(4)列。

共同扩散与其他数量效应这一项容易被误读。它来自时期固定效应的变化，把模型能力的公共跃迁、新场景的涌现、政策推动与企业内部采纳节奏一并吸收，其中绝大部分与任何单一行业面对的价格无关：全国日均词元调用量两年放大约 1400 倍，这样的量级跃迁不是价格弹性所能承载的。若把这一项算进回弹，本文样本上的回弹率会由 1.3908 升到 2.7221，数字更醒目，却不再是任何一个可用于政策推演的参数。

把窗口缩短可以看到通道权重的变化。2024Q4 至 2025Q2 的半年内，支出增长 370.4%，价格通道净效应仅 0.2133（折合支出增长 23.78%），扩散项占到 73.5%；把起点后移到 2024Q1，价格通道净效应为 0.5581，扩散项占 85.1%。越是靠近扩散最猛烈的时段，价格通道的相对权重越低；而在全样本这一较长的窗口上，价格通道重新占到支出总变化的 22.7%。回弹的度量因此对窗口高度敏感，报告回弹率时必须写明区间。需要说明的是，公开调研记录的企业接口支出同期半年增长约 140%，为美国市场、美元口径且只含接口支出，与本文人民币口径的全口径支出不可相除、不可互相校验，只作方向性对照。

六、异质性、稳健性与统计口径含义

（一）弹性的异质性

总量弹性是各行业弹性的加权平均，其背后的分布同样有政策含义。本文按两个维度分组重估式(6)：一是行业智能化基础，以其标准化取值的中位数（-0.0178）为界；二是企业规模结构，以大型企业用量占比的中位数（0.315）为界；每组各 140 个观测、10 个行业，组间差异以两组系数之差的 z 统计量检验。这两个维度分别对应把降价转化为用量的两类前提：任务是否已被拆解为模型可以承接的形态，以及企业是否具备把新价格迅速落到生产流程上的组织能力。结果见表 6 甲栏。

智能化基础高的行业弹性为-1.5628（标准误 0.1229），低的行业为-1.1281（标准误 0.1482），相差-0.4347， $z = -2.2583$ ， p 值 0.024，在 5%的水平上显著。这一差别符合任务改造的成本逻辑：已经把业务流程拆解为可由模型承接的任务模块的行业，把降价转化为新用量所需的额外投入很小；尚未完成这一步的行业则仍受制于数据接口、流程改造与人员适

配等互补投入^{[21][23]}。值得注意的是低组弹性的绝对值仅 1.1281，与临界值-1的距离不足一个标准误，即在统计上无法与-1区分：在这些行业，降价是否推高支出并无把握，价格通道净效应至多很薄。

企业规模结构给出同向但更弱的结果。大型企业用量占比高的行业弹性为-1.6176（标准误 0.1346），占比低的行业为-1.2371（标准误 0.1518），相差-0.3805， $z = -1.8759$ ， p 值 0.061，仅在 10%的水平上边际显著，不宜过度解读。可作的谨慎判断是：规模企业有工程团队把价格下行转化为新场景，中小企业则更多依赖第三方平台的现成能力^{[26][45]}。

异质性的政策含义与直觉相反。若把降价视为普惠的成本红利，那么弹性越大的行业越能把红利转化为用量，降价本身就会拉开行业之间智能化程度的差距。这意味着单靠价格下行不足以缩小行业间的采纳鸿沟：对低弹性行业而言，制约用量的不是价格而是流程改造、数据接口与人员适配等互补投入。还须说明的是，在斜率异质的面板中，双向固定效应估计量收敛到以各行业价格组内方差为权的加权平均而非简单平均（本文数据生成过程中前者为-1.8107，后者为-1.7500），故报告总量弹性时须同时说明其权重含义，否则容易被读成代表性行业的弹性。

（二）稳健性

表 6 乙栏列出弹性的八个稳健性设定。需求面板止于 2026 年第二季度，结构性提价落在窗口之外，相应的检验是剔除样本末两个季度，弹性为-1.4498；剔除用量最大的三个行业为-1.4387，加入档位结构控制为-1.4851，加入行业特定线性时间趋势为-1.6308，仅用 2023Q1 至 2025Q2 的早期样本为-1.4930。改按季度聚类不改变点估计，只把标准误由 0.1482 降到 0.0759，可见按行业聚类更保守。八个设定的点估计落在[-1.6308, -1.2900]之间，全部小于-1。其中两个设定尤其值得注意：加入档位结构控制之后弹性并未向零收缩，说明识别出的用量反应不只是行业在档位之间的重新配置；加入行业特定线性时间趋势之后绝对值反而略有上升，说明基准结果并非由行业增长趋势与价格下行的偶然同向所致。

动态设定值得单独一提。加入价格的一期滞后后，当期系数为-1.3744（标准误0.1381），滞后项系数为0.0845（标准误0.1259）而不显著，长期弹性为-1.2900（标准误0.2029）。长期与当期弹性接近，意味着用量对价格的调整在当季基本完成。这与智能服务的技术特征相符：切换档位或扩大调用规模不需要重资产投入。回弹的时间形态因而与能源不同——能源效率改进的回弹要经由设备更替缓慢释放，词元价格下行的回弹则几乎在同一期内完成，这意味着价格政策的效果会来得很快、退得也很快。

价格指数一侧同样做了两项检验。剔除2026年7月与8月的结构转向期后重估享乐方程，质量调整指数在2026年6月的年均降幅为3.539倍（累计-98.667%），与全样本的3.548倍几无差别；改用中位数回归估计享乐方程，指数期末水平为1.3076，年均降幅3.559倍。两项检验说明第四部分的指数结论既不由结构转向期驱动，也不由少数极端报价驱动。至于结构断点本身，分时定价意味着同一档位在同一个月内存在多个价格，若采集时只取其一，指数就会出现与买方真实购进成本无关的跳变；相应的处理是按时段用量加权采集并显式标注断点，而不是把它当作异常值平滑掉。以上各项只能表明结论对设定不敏感，无法弥补识别本身的局限。

表6 异质性与稳健性检验

设定或分组	价格弹性 ϵ	标准误	p 值	观测值
甲栏：异质性分组（分组变量的中位数为界）				
行业智能化基础：高组	-1.5628	0.1229	<0.001	140
行业智能化基础：低组	-1.1281	0.1482	<0.001	140
行业智能化基础：组间差异	-0.4347	0.1925	0.024	280
企业规模结构：高组	-1.6176	0.1346	<0.001	140
企业规模结构：低组	-1.2371	0.1518	<0.001	140
企业规模结构：组间差异	-0.3805	0.2029	0.061	280
乙栏：稳健性设定（双向固定效应，质量调整价）				
剔除样本末两个季度（2026Q1—Q2）	-1.4498	0.1464	<0.001	240
剔除用量最大的三个行业	-1.4387	0.1717	<0.001	238
加入档位结构控制	-1.4851	0.1396	<0.001	280
加入行业特定线性时间趋势	-1.6308	0.0936	<0.001	280
改按季度聚类（14簇）	-1.3908	0.0759	<0.001	280

仅 2023Q1—2025Q2	-1.4930	0.1405	<0.001	200
动态设定：当期弹性	-1.3744	0.1381	<0.001	260
动态设定：长期弹性	-1.2900	0.2029	<0.001	260

注：各行均为式(6)的双向固定效应估计，被解释变量为标准词元用量的对数，除注明外标准误按行业聚类。甲栏的组间差异为高组系数减低组系数，其 p 值由两组独立估计的 z 检验给出。乙栏动态设定的长期弹性为当期系数与滞后系数之和。基准设定的弹性为-1.3908（标准误 0.1482），见表 4 第(2)列。

（三）统计口径的含义

本文的测度结论最终要落回统计口径。由式(1)，效值系数的对数变化同时等于两个差：

$$\Delta \ln \tilde{T} - \Delta \ln T = \Delta \ln \eta = \Delta \ln P^N - \Delta \ln \tilde{P} \tag{16}$$

左端是真实投入增长与名义投入增长之差，右端是两套价格指数的降幅之差。二者恒等，意味着价格指数上少记的降幅就是数量上少记的增长。在需求面板上，这一缺口为 1.5807 个对数点：标准词元用量的对数增长 11.2301，物理词元用量的对数增长 9.6494。换算成倍数，正确口径下的真实投入增长是以名义词元价格平减所得结果的 4.86 倍。这不是小数点后的修正，而是量级上的遗漏。

第一个后果落在生产率核算上。在增长核算中，产出增长减去各要素与中间投入的加权增长即为全要素生产率残差。若智能服务作为中间投入的真实数量增长被系统性记少，被记少的那一块就转而进入残差，表现为全要素生产率的虚增；与此同时，同一笔支出变化中被划归价格的比重被记多。这恰恰颠倒了通用目的技术扩散期的真实情形^{[16][10]}。消费价格指数和质量偏误曾引出一整轮统计口径改革^{[29][30]}，信息技术与云计算服务的价格测度至今仍是官方统计的难题^{[6][4]}；词元只是把同一问题以更快的节奏重演了一遍。

第二个后果落在补贴核定上。当前面向算力与模型调用的支持政策，多以物理词元量或名义单价为发放依据。按式(16)，样本期内以物理词元计量的用量增长倍数只及以标准词元计量的 1/4.86，按枚数发放的补贴因而会把实际支撑的服务能力增长记少；更麻烦的是激励方向：按枚数补贴等于奖励多买便宜档位的词元，而不是奖励买到能把任务真正做完的词元；档位替代本身能把观测均价压低 40.0%（第四部分结构效应），这部分并非真实成本节约，却会被计入补贴绩效。以标准词元作为核定单位，才能使补贴与效值对齐。

第三个后果落在投资回报评估上。企业内部评估智能化项目时，习惯把账单总额的上升读作成本失控，把单价下行读作已经省下的钱。本文的分解给出了另一种读法：在 $|\varepsilon|>1$ 的条件下，价格通道净效应为正是弹性的必然结果而非项目的失败，样本期内仅价格通道就把支出推高 401.45%。正确的评估对象不是账单总额，而是完成单位任务所耗的标准词元成本与被新纳入任务本身的价值。三项后果合起来看，编制质量调整的词元价格指数不只是统计技术问题，而是让核算、补贴与投资决策建立在同一套可比价格上的前提。

七、结论与政策建议

（一）主要结论

第一，名义词元价格指数低估了真实降价幅度，而非高估。2023 年 1 月至 2026 年 6 月，单位价值口径的名义指数累计-93.248%（年均 2.201 倍），质量调整指数累计-98.679%（年均 3.548 倍）。对支出份额加权的对数均价指数（同期累计-94.224%）作三重分解，真实价格效应占名义降幅的 151.8%，质量效应占-70.6%，结构效应占 17.9%，残差占 1.0%。质量效应为正号，说明能力改进把观测均价托高：同样一笔钱买到的词元变强了，这份收益被记进了价格，于是名义降价看上去比真实降价温和。

第二，在质量调整价格上，需求价格弹性的绝对值大于 1，支出上升主要经由回弹通道实现。双向固定效应估计的弹性为-1.3908，名义口径为-1.8596，后者把绝对值放大了 33.71%； $H_0: \varepsilon = -1$ 的单侧 p 值为 0.0081，野聚类自助法为 0.015，在 5%的水平上拒绝。工具变量估计为-1.5698，方向一致而标准误更大。回弹分解显示，价格效应与纯回弹效应之和为 1.6123 个对数点（工具变量口径为 2.3507），即不计任务复杂化与市场扩散，仅价格通道本身就足以让支出上升。任务复杂化另贡献 1.3673 个对数点，与价格无关，不应计入回弹。

第三，以名义词元价格平减将低估真实投入增长，并使核算、补贴与投资评估建立在错误的价格上。名义与质量调整两套口径给出同一笔支出变化，却相差 1.5807 个对数点的数量增长，正确口径下的真实投入增长是名义平减所得结果的 4.86 倍。其后果是全要素生产率残

差虚增、按枚数发放的补贴激励用量而非效值、企业把弹性大于 1 所必然带来的账单上升误读为项目失控——三者同源于一件事：把不同效值的词元按枚数相加。

（二）政策建议

第一，建立质量调整的词元价格指数的常规编制制度。可行的做法是先立样本框后编指数：以代表性供给方的档位—任务单元为抽样单位，按月采集挂牌价与可观测特征，保持特征清单的跨期可比与版本留痕；再以享乐回归的时期效应编制质量调整指数，同时公布固定篮子指数与单位价值指数，使档位替代与真实降价可分开阅读。鉴于公开报告记录的词元推理价格年降幅因任务而异，区间可达每年 9 倍至 900 倍，总指数之外还应编制按任务类型分层的分指数。这项工作可与工业和信息化部拟印发的《算力标准体系建设指南》相衔接，该指南推动建立算力服务能力评估与算力市场化定价等标准^[36]。

第二，明确计价规则并推动账单的可核验披露。指数的质量取决于原始记录的质量，而当前的计价口径在输入与输出、是否命中缓存、是否处于高峰时段之间差别很大，账单却往往只给出一个合计金额。建议在服务合约与结算凭证中分项标注词元用量与对应单价，并留存可核验的调用记录。计价维度与使用维度错位所产生的计量成本^[33]、质量不可观测所引致的逆向选择^[34]，都要靠可核验的披露来压缩，第三方评测与认证在此可以承担质量披露的职能^[35]。

第三，在统计核算与政策工具中替换平减因子与核定单位。生产率核算中，智能服务作为中间投入应以质量调整价格平减；补贴与算力券的核定应以标准词元而非物理词元为单位，使支持力度与实际获得的服务能力对齐；投资回报评估应以完成单位任务的标准词元成本为口径，而不以账单总额的增减为准。词元的计量、结算与统计三重职能既已确立，把质量调整的价格指数补上，才算把这三重职能真正落到统计口径上。

（三）研究局限

本文的局限首先在数据。分析样本是按公开锚校准生成的模拟面板，其价格路径、调用量总量与档位价比均已对齐公开发布的锚点，但行业与档位的横截面结构出自设定而非观

测。^①因此本文的贡献应被理解为测度框架与识别策略的示范，而非对中国智能服务市场弹性的最终估计；享乐方程的偏 R^2 达到 0.9441，高于真实挂牌价数据可期的水平，即为模拟设定所致的上界。

其次是样本长度与识别的边界。价格面板只有 44 个月，需求面板只有 14 个季度、20 个行业，结构性提价期只覆盖两个月，转向之后的价格路径无法可靠估计。聚类数偏少同样限制了推断：Durbin-Wu-Hausman 检验的 p 值为 0.510，在 20 个行业上不能拒绝价格外生，故本文只报告工具变量点估计的方向，不据此宣称价格内生已获检验支持。再次是分解本身的近似性质：式(7)建立在总量层面的对数线性近似上，而弹性在行业间是异质的，用一个总量弹性去乘总量价格变化，会把组间弹性差异连同权重变化一并折进扩散项；第四部分的三重分解也有类似问题——享乐方程若遗漏定价上重要的特征，遗漏部分会同时污染质量效应与真实价格效应，而占比仅 1.0%的残差察觉不到这种污染。

循此而下有三个方向。其一，以真实的调用明细与结算账单重做本文的测度链条，并检验享乐特征集合在真实报价上的解释力；其二，把指数按任务类型分层编制，使不同任务结构的使用者能读到与自己相关的价格路径；其三，从简约式弹性转向供给侧定价行为的结构估计^[39]，把档位纵向差异化下的加成、峰谷分时定价与拥塞外部性一并纳入模型。词元的价格测度刚刚开始，而它已经是许多重要核算数字的分母。

参考文献

- [1] GRILICHES Z. Hedonic price indexes for automobiles: an econometric analysis of quality change[M]//The Price Statistics of the Federal Government. New York: National Bureau of Economic Research, 1961: 173-196.
- [2] AIZCORBE A M. Price measures for semiconductor devices[R]. FEDS Working Paper No. 2002-13. Washington, D.C.: Board of Governors of the Federal Reserve System, 2002.
- [3] BYRNE D M, CORRADO C A, SICHEL D E. The rise of cloud computing: minding your P's, Q's and K's[R]. Cambridge, MA: National Bureau of Economic Research, 2018. NBER Working Paper No. 25188.
- [4] SAWYER S D, O'BRYAN C. Exploring quality adjustment in PPI cloud computing[J]. Monthly Labor Review, 2023.
- [5] BYRNE D M, OLINER S D, SICHEL D E. How fast are semiconductor prices falling?[J]. Review of Income and Wealth, 2018, 64(3): 679-702.

①全部实证数字由随附的 data_gen.py 产生并可复现，校准锚与其来源逐条列于 data/facts.md。本文的实证部分意在完整展示从质量调整测度到弹性识别再到回弹分解的方法链条，各项参数的量级不应外推为对真实市场的估计。

- [6] BYRNE D M, CORRADO C. Accounting for innovations in consumer digital services: IT still matters[M]//Measuring and Accounting for Innovation in the Twenty-First Century. Chicago: University of Chicago Press, 2021: 471-518.
- [7] 中国信息通信研究院云计算与大数据研究所. 算力经济发展研究报告（2025 年）[R]. 北京: 中国信息通信研究院, 2025.
- [8] ACEMOGLU D, RESTREPO P. Automation and new tasks: how technology displaces and reinstates labor[J]. *Journal of Economic Perspectives*, 2019, 33(2): 3-30.
- [9] ACEMOGLU D, RESTREPO P. Tasks, automation, and the rise in U.S. wage inequality[J]. *Econometrica*, 2022, 90(5): 1973-2016.
- [10] ACEMOGLU D. The simple macroeconomics of AI[J]. *Economic Policy*, 2025, 40(121): 13-58.
- [11] AUTOR D, CHIN C, SALOMONS A, et al. New frontiers: the origins and content of new work, 1940-2018[J]. *The Quarterly Journal of Economics*, 2024, 139(3): 1399-1465.
- [12] ELOUNDOU T, MANNING S, MISHKIN P, et al. GPTs are GPTs: labor market impact potential of LLMs[J]. *Science*, 2024, 384(6702): 1306-1308.
- [13] NOY S, ZHANG W. Experimental evidence on the productivity effects of generative artificial intelligence[J]. *Science*, 2023, 381(6654): 187-192.
- [14] BRYNJOLFSSON E, LI D, RAYMOND L. Generative AI at work[J]. *The Quarterly Journal of Economics*, 2025, 140(2): 889-942.
- [15] HUMLUM A, VESTERGAARD E. Large language models, small labor market effects[R]. Cambridge, MA: National Bureau of Economic Research, 2025. NBER Working Paper No. 33777.
- [16] 程文. 人工智能、索洛悖论与高质量发展: 通用目的技术扩散的视角[J]. *经济研究*, 2021, 56(10): 22-38.
- [17] 陈钊, 张洲, 钟岳霖. 生成式人工智能的影响: 个体、组织与社会[J]. *经济学(季刊)*, 2026, 26(3): 623-667.
- [18] 陈斌开, 张梓润, 夏俊杰, 陈思. 人工智能、经济增长与财富分配[J]. *经济学(季刊)*, 2026, 26(3): 668-691.
- [19] 胡涟漪, 盖庆恩, 潘珊. 人工智能与职业需求——基于任务内容的替代、互补与创造效应分析[J]. *经济学(季刊)*, 2026, 26(3): 713.
- [20] 王林辉, 钱圆圆, 宋冬林, 等. 机器人应用的岗位转换效应及就业敏感性群体特征——来自微观个体层面的经验证据[J]. *经济研究*, 2023(7): 69-85.
- [21] 姚加权, 张银澎, 郭李鹏, 等. 人工智能如何提升企业生产效率? ——基于劳动力技能结构调整的视角[J]. *管理世界*, 2024, 40(2): 101-116+133+117-122.
- [22] 李玉花, 林雨昕, 李丹丹. 人工智能技术应用如何影响企业创新[J]. *中国工业经济*, 2024(10): 155-173.
- [23] 黄先海, 孙涌铭, 陈梦涛. 企业数字化转型与颠覆性技术创新——来自专利网络与 SBERT 模型的微观证据[J]. *中国工业经济*, 2024(10): 137-154.
- [24] 许诺, 毛聚, 毛新述. 算力部署、数据跨域流动与企业全要素生产率——来自智算中心的证据[J]. *中国工业经济*, 2025(4): 61-79.
- [25] 焦豪, 崔瑜, 张亚敏. 数字基础设施建设与城市高技能创业人才吸引[J]. *经济研究*, 2023(12): 150-166.
- [26] DESTEFANO T, KNELLER R, TIMMIS J. Cloud computing and firm growth[J]. *The Review of Economics and Statistics*, 2025 (网络首发) : 1-47. DOI:10.1162/rest_a_01393.
- [27] 陈永伟. 人工智能与经济学: 关于近期文献的一个综述[J]. *东北财经大学学报*, 2018(3): 6-21.
- [28] KORINEK A. Generative AI for economic research: use cases and implications for economists[J]. *Journal of Economic Literature*, 2023, 61(4): 1281-1317.
- [29] BOSKIN M J, DULBERGER E R, GORDON R J, GRILICHES Z, JORGENSON D W. Consumer prices, the consumer price index, and the cost of living[J]. *Journal of Economic Perspectives*, 1998, 12(1): 3-26.
- [30] U.S. GENERAL ACCOUNTING OFFICE. Consumer price index: update of Boskin Commission's estimate of bias[R]. GAO/GGD-00-50. Washington, D.C.: U.S. General Accounting Office, 2000.

- [31] AIZCORBE A M. A Practical Guide to Price Index and Hedonic Techniques[M]. Oxford: Oxford University Press, 2014.
- [32] EHRLICH G, HALTIWANGER J, JARMIN R S, JOHNSON D, OLIVARES E, PARDUE L W, SHAPIRO M D, ZHAO L. Quality adjustment at scale: hedonic versus exact demand-based price indices[J]. American Economic Review, 2026, 116(6): 1955-1995.
- [33] BARZEL Y. Measurement cost and the organization of markets[J]. Journal of Law and Economics, 1982, 25(1): 27-48.
- [34] AKERLOF G A. The market for “lemons”: quality uncertainty and the market mechanism[J]. The Quarterly Journal of Economics, 1970, 84(3): 488-500.
- [35] DRANOVE D, JIN G Z. Quality disclosure and certification: Theory and practice[J]. Journal of Economic Literature, 2010, 48(4): 935-963.
- [36] YANG L. The economics of standards: A literature review[J]. Journal of Economic Surveys, 2024, 38(3): 717-758. DOI:10.1111/joes.12555.
- [37] GILLINGHAM K, RAPSON D, WAGNER G. The rebound effect and energy efficiency policy[J]. Review of Environmental Economics and Policy, 2016, 10(1): 68-88.
- [38] BORENSTEIN S. A microeconomic framework for evaluating energy efficiency rebound and some implications[J]. The Energy Journal, 2015, 36(1): 1-22.
- [39] CONLON C, GORTMAKER J. Best practices for differentiated products demand estimation with PyBLP[J]. The RAND Journal of Economics, 2020, 51(4): 1108-1161.
- [40] BAYE M R, MORGAN J, SCHOLTEN P. Information, search, and price dispersion[M]//HENDERSHOTT T. Handbook on Economics and Information Systems: Volume 1. Amsterdam: Elsevier, 2006: 323-377.
- [41] ELLISON G, ELLISON S F. Search, obfuscation, and price elasticities on the Internet[J]. Econometrica, 2009, 77(2): 427-452.
- [42] MOHAPATRA D, MOHAPATRA D P, DUBEY R S. Price dispersion across online platforms: evidence from hotel room prices in London (UK)[J]. Applied Economics, 2024, 56(52): 6598-6610. DOI:10.1080/00036846.2023.2275219.
- [43] GOLDFARB A, TUCKER C. Digital economics[J]. Journal of Economic Literature, 2019, 57(1): 3-43.
- [44] VARIAN H R. A model of sales[J]. The American Economic Review, 1980, 70(4): 651-659.
- [45] 熊巧琴, 汤珂, 张丰羽. 第三方数字平台能否帮助中小微企业提升经营收益? ——来自百万商户大数据的证据[J]. 经济学(季刊), 2023, 23(5): 1704-1722.